


IKTT 807

Ekonometrik Modelleme ve Uygulamaları

Ders Notları



İktisat Tezli Yüksek Lisans Programı

Ana kaynak: Bruce E. Hansen, *Econometrics* (2021 revizyonu)

İçindekiler

Bu Ders Notu Nasıl Kullanılmalı?	xi
Ekonometrik Terimler ve İngilizce Karşılıkları	xiii
Hansen ile Ortak Notasyon Rehberi	xvi
Başlangıç Araç Kutusu: Olasılık, Notasyon ve Matrisler	1
0.1 Rassal Değişken ve Dağılım	1
0.2 Beklenen Değer, Varyans ve Kovaryans	1
0.3 Koşullu Beklenen Değer	2
0.4 Anakütle, Örneklem, Parametre ve Tahmin Edici	3
0.5 Vektör ve Matris Gösterimi	3
0.6 En Küçükleme ve Birinci Derece Koşulu	4
0.7 Büyük Sayılar Yasası ve Merkezi Limit Teoremi	4
0.8 Olabilirlik, Skor ve Sayısal Optimizasyon	5
1 Ampirik Ekonometrik Modelleme ve Regresyonun Temeli	6
1.1 Ekonometrinin Olasılıksal Yaklaşımı	6
1.1.1 Araştırma sorusundan tahmin hedefine	7
1.2 Gözlemsel Veri ve Rassallık	8
1.2.1 Veri yapısı ile çıkarım arasındaki bağ	8
1.3 Dağılımdan Koşullu Beklentiye	9
1.3.1 Koşullandırma ne yapar?	9
1.4 Koşullu Beklenti Hatası ve Ortogonalite	10
1.4.1 Koşullu ortalamanın sıfır olması	10
1.5 Koşullu Ortalama Neden Özel Bir Tahmin Hedefidir?	11
1.6 Doğrusal Koşullu Ortalama ve En İyi Doğrusal Öngörücü	12
1.6.1 Durum 1: Koşullu ortalama gerçekten doğrusaldır	12
1.6.2 Durum 2: Koşullu ortalama doğrusal değildir	13
1.7 Basit Regresyon Katsayısının Anakütle Yorumu	14
1.8 Örneklem Karşılığı: En Küçük Kareler (OLS)	15
1.8.1 Matris biçiminde türetim	15
1.8.2 Örneklem artıklarının ortogonalitesi	16

1.9	Basit OLS Formülü ve Sezgisi	16
1.10	Çoklu Regresyonun Temel Yorumu	17
1.10.1	Doğrusal katsayı hangi ağırlıklı ilişkiyi yakalar?	18
1.11	Regresyon, Korelasyon ve Nedensellik	18
1.12	Regresyonun Üç Ayrı Kullanım Amacı	19
1.13	Ampirik Uygulama Laboratuvarı: CPS Ücret–Eğitim İlişkisi	19
1.13.1	Adım 1: Araştırma sorusunu ve tahmin hedefini yazmak	20
1.13.2	Adım 2: Ham veriden analiz örneklemine	21
1.13.3	Adım 3: Regresyondan önce veriyi tanımak	21
1.13.4	Adım 4: Koşullu ortalamaları önce grafik ve tabloyla görmek	22
1.13.5	Adım 5: Koşullu ortalamadan doğrusal projeksiyona	23
1.13.6	Adım 6: Bir makaledeki çok sütunlu regresyon tablosunu okumak	24
1.13.7	Adım 7: Yazılım çıktısından makale tablosuna geçmek	27
1.13.8	Adım 8: Sonuçları ampirik metne dönüştürmek	28
1.13.9	Adım 9: Aynı analizi kendiniz nasıl kurarsınız?	28
1.13.10	Logaritmik sonuç değişkenine kısa not	30
1.14	Yeniden Üretilabilir Ampirik Çalışma	30
1.15	Temel Sonuçlar	31
1.16	Bölüm Sonu Egzersizleri	32
2	Doğrusal Regresyon ve Güvenilir Çıkarım	35
2.1	Çoklu Regresyon Katsayısının Anlamı	35
2.1.1	Frisch–Waugh–Lovell sezgisi	36
2.1.2	Varyans ayrıştırması ve R^2	37
2.2	Fonksiyonel Biçim: Katsayıyı Doğru Ölçekte Okumak	41
2.2.1	Düze–düzey modeli	41
2.2.2	Log–düzey modeli	42
2.2.3	Düze–log modeli	42
2.2.4	Log–log modeli	42
2.3	Doğrusal Olmayan Etkileri Doğrusal Regresyonla Kurmak	43
2.3.1	Karesel terim	43
2.3.2	Kukla değişkenler	44
2.3.3	Etkileşimler	44
2.4	Eksik Değişken Yanlılığı: Neden Katsayı Değişir?	45
2.5	Tahmin Belirsizliği: OLS’nin Büyük Örneklem Dağılımı	46
2.6	Homoskedastisite ve Heteroskedastisite	47
2.6.1	Dayanıklı standart hata her sorunu çözmez	48
2.7	Kümelenmiş Bağımlılık ve Küme-Dayanıklı Çıkarım	49
2.7.1	Katsayı değişmez, belirsizlik değişir	49
2.7.2	Küme-dayanıklı kovaryans matrisi	50

2.7.3	Ne kadar büyür? Basit bir sezgi	50
2.7.4	Hangi düzeyde kümelemeli?	51
2.8	Katsayının Fonksiyonlarına Geçmek: Delta Yöntemi	51
2.8.1	Temel sonuç	52
2.8.2	Üç somut örnek	52
2.9	Güven Aralığı ve Hipotez Testi	53
2.9.1	Testin dört temel kavramı	53
2.9.2	Ortak hipotezler: Wald testi	54
2.10	İstatistiksel ve Ekonomik Anlamlılık	55
2.11	Temel Model Tanılaması	56
2.11.1	Artıklar ve fonksiyonel biçim	56
2.11.2	Kaldıraç ve etkili gözlemler	56
2.11.3	Çoklu doğrusal bağlantı	56
2.12	Ampirik Uygulama: Aynı Katsayı, Farklı Çıkarım	57
2.13	Ampirik Uygulama Laboratuvarı: Regresyon Tablosunu Güvenilir Okumak	58
2.13.1	Adım 1: Araştırma sorusunu ve hedef katsayıyı açıkça tanımlamak	58
2.13.2	Adım 2: Birden çok spesifikasyon kurmak	59
2.13.3	Adım 3: Katsayı ile standart hatayı birbirinden ayırmak	59
2.13.4	Adım 4: Heteroskedastisite tanısını makale diliyle okumak	60
2.13.5	Adım 5: Etkileşim katsayısını doğru yorumlamak	60
2.13.6	Adım 6: Yazılımda güvenilir standart hatayı açıkça istemek	60
2.13.7	Adım 7: Bir makale tablosunu hangi sırayla okumalıyız?	61
2.13.8	Kendi analizinizde uygulanacak pratik protokol	61
2.14	Temel Sonuçlar	62
2.15	Bölüm Sonu Egzersizleri	62
3	Tanımlama, Nedensellik ve İçsellik	67
3.1	Dört Ayrı Kavram: Tahmin Hedefi, Tanımlama, Tahmin Edici ve Tahmin	67
3.2	Nedensel Etki: Gözlenen Sonuçtan Farklı Bir Nesne	68
3.3	Ham Grup Farkı Neyi Ölçer?	69
3.4	Rassal Atama Neden Güçlüdür?	70
3.5	Gözlemsel Veride Koşullandırma ile Tanımlama	71
3.6	Nedensel Diyagramla Açık Yolları Görmek	72
3.7	Doğrusal Projeksiyon Parametresi ile Yapısal Parametre	72
3.8	İçsellikğin Temel Kaynakları	73
3.8.1	Eksik değişken / gözlenemeyen karıştırıcı	73
3.8.2	Ters nedensellik ve eşanlılık	74
3.8.3	Seçim ve karar değişkenleri	74
3.8.4	Açıklayıcı değişkende ölçüm hatası	74
3.9	Örneklem Büyüdükçe İçsellik Kaybolur mu?	75

3.10	Koşullandırma Setinin Rolü	76
3.11	Tanımlama ile Model Uyumunu Birbirinden Ayırmak	77
3.12	Kontrollü Simülasyon: İçsellik Yanlılığını Görmek	77
3.13	Bir Nedensel Çalışmayı Okurken Sorulacak Sorular	78
3.14	Araçsal Değişkene Geçiş	78
3.15	Ampirik Uygulama Laboratuvarı: Rastgele Atama ile Seçilmiş Alt Grubu Ayırmak	79
3.15.1	Adım 1: Araştırma sorusu ve atama birimi	79
3.15.2	Adım 2: Denge tablosunu mekanik bir sınav gibi okumamak	79
3.15.3	Adım 3: Ham fark ile kovaryat ayarlı tahmini karşılaştırmak	79
3.15.4	Adım 4: Aynı veride seçilmiş bir grubun neden nedensel karşılaştırma olmadığını görmek	80
3.15.5	Makale çıktısını okurken sorulacak tanımlama soruları	81
3.16	Temel Sonuçlar	81
3.17	Bölüm Sonu Egzersizleri	82
4	Araçsal Değişkenler ve 2SLS	86
4.1	Araçsal Değişken Probleminin Temel Kurulumu	86
4.2	Araç Geçerliliğinin Üç Bileşeni	87
4.2.1	Uygunluk / relevance	87
4.2.2	Dışsallık / ortogonallık	87
4.2.3	Dışlama kısıtı	88
4.3	Yapısal Denklem, İlk Aşama ve İndirgenmiş Biçim	88
4.3.1	Yapısal denklem	89
4.3.2	İlk aşama	89
4.3.3	İndirgenmiş biçim	89
4.4	Wald Tahmin Edicisi: En Şeffaf IV Durumu	90
4.5	Moment Koşulundan Just-Identified IV Tahmin Edicisine	90
4.6	Tanımlama: Rank Koşulu	91
4.7	İki Aşamalı En Küçük Kareler (2SLS)	92
4.8	Neden İkinci Aşamamın Sıradan OLS Standart Hatası Yanlıdır?	93
4.9	İlk Aşama Gücü ve Zayıf Araç Problemi	94
4.10	Aşırı Tanımlama ve Araç Geçerliliği Testleri	95
4.11	İçsellik Testleri	95
4.12	Heterojen Etkiler ve LATE	96
4.13	Hansen'in Kolej Yakınlığı Örneği	97
4.14	2SLS Uygulaması ve Yazılım Mantığı	97
4.15	Moment Koşulundan GMM'ye Geçiş	98
4.16	IV Çalışmasını Eleştirel Okuma Kontrolü	99
4.17	Ampirik Uygulama Laboratuvarı: Card Verisiyle İlk Aşamadan 2SLS'ye	99
4.17.1	Adım 1: Yapısal denklem, ilk aşama ve indirgenmiş biçim	100

4.17.2	Adım 2: Sonuçları tek bir tanımlama zinciri olarak okumak	100
4.17.3	Adım 3: Araç geçerliliğini p-değerinden türetmemek	100
4.17.4	Adım 4: 2SLS'i yazılım komutunun arkasındaki iki projeksiyon olarak görmek	101
4.17.5	Bir IV makalesindeki tabloyu nasıl okumalıyız?	101
4.18	Temel Sonuçlar	102
4.19	Bölüm Sonu Egzersizleri	103
5	İkili ve Ayrık Sonuç Modelleri	106
5.1	Bağımlı Değişkenin Desteği Neden Önemlidir?	107
5.2	İkili Sonuçlarda Koşullu Ortalama Bir Olasılıktır	107
5.3	Doğrusal Olasılık Modeli	108
5.3.1	LPM'nin güçlü tarafları	108
5.3.2	LPM'nin sınırlamaları	108
5.4	Tek İndeks Modelleri: Probit ve Logit	109
5.4.1	Marjinal etki neden katsayı değildir?	110
5.5	Gizli Değişken Yorumu ve Ölçek Normalizasyonu	110
5.6	Olabilirlik: 0 ve 1 Gözlemlerinin Ortak Dili	111
5.6.1	Logit modelinin skor denklemi	112
5.7	Maksimum Olabilirlik Tahmin Edicisinin Belirsizliği	112
5.7.1	Skordan asimptotik dağılıma	113
5.7.2	Bilgi matrisi eşitliği ve iki farklı standart hata	113
5.7.3	Marjinal etkinin standart hatası	114
5.8	Marjinal Etkilerin Raporlanması	114
5.8.1	Ortalama marjinal etki	115
5.8.2	Kukla değişkende türev yerine sonlu fark	115
5.9	Hansen'in CPS Evlilik Uygulaması	115
5.10	Çok Kategorili Sonuçlar: Multinomial Modeller	117
5.11	Sıralı Sonuçlar: Ordered Probit ve Ordered Logit	117
5.12	Sayım Sonuçları: Poisson Regresyonu	118
5.13	Model Seçimi İçin Karar Şeması	119
5.14	Makale Sonuçlarını Okuma ve Raporlama	119
5.15	Ampirik Uygulama Laboratuvarı: İkili Sonuçlarda Katsayıdan Olasılığa Geçmek	120
5.15.1	Adım 1: Aynı araştırma sorusunu üç model ailesiyle sormak	120
5.15.2	Adım 2: Logit katsayısını neden doğrudan yorumlamıyoruz?	121
5.15.3	Adım 3: Tahmin edilen olasılık profilini okumak	121
5.15.4	Adım 4: Yazılım çıktısından AME tablosuna geçmek	122
5.15.5	Adım 5: Kukla değişken için türev değil sonlu fark	122
5.15.6	Bir ikili sonuç makalesindeki tabloyu nasıl okumalıyız?	123
5.16	Temel Sonuçlar	123

5.17	Bölüm Sonu Egzersizleri	124
6	Sansürleme ve Örneklem Seçimi	127
6.1	Üç Farklı Veri Yapısını Ayırılım	127
6.2	Klasik Sansürlü Regresyon Modeli	128
6.3	Sansürleme Olasılığı ve Üç Koşullu Ortalama	129
6.4	Naif OLS Neden Eğimi Bozabilir?	129
6.4.1	Kontrollü benzetim	130
6.5	Tobit Olabilirliği	130
6.6	Tobit Katsayısı Nasıl Yorumlanır?	131
6.6.1	Gizli sonuç üzerindeki etki	131
6.6.2	Sansürlenmeme olasılığı üzerindeki etki	131
6.6.3	Gözlenen koşullu ortalama üzerindeki etki	132
6.7	Tobit'in Güçlü Varsayımları	132
6.8	Hansen'in Filipinler Transfer Uygulaması	133
6.9	Örneklem Seçimi Yanlılığı	133
6.10	Seçim Mekanizmasını Bir Gizli Denklemlle Kurmak	134
6.11	Heckman İki Aşamalı Tahmin	135
6.12	Dışlama Kısıtı Neden Önemlidir?	136
6.13	Seçim Düzeltmesini Benzetimle Görmek	137
6.14	Sansürleme ile Seçimi Karıştırmamak	137
6.15	Makale Okurken Kontrol Listesi	138
6.16	Ampirik Uygulama Laboratuvarı: Sıfır Yığılmasından Sansürlü Modele	138
6.16.1	Adım 1: Hansen'in veri hazırlama zincirini yeniden üretmek	139
6.16.2	Adım 2: Gelir etkisini doğrusal olmak zorunda bırakmamak	139
6.16.3	Adım 3: Tobit katsayısını OLS katsayısı gibi okumamak	141
6.16.4	Adım 4: Sıfırların ekonomik anlamını sorgulamak	141
6.16.5	Hansen'in CLAD karşılaştırması ne öğretiyor?	142
6.16.6	Kendi tezinizde sansürlü/seçilmiş sonuç için protokol	142
6.17	Temel Sonuçlar	142
6.18	Bölüm Sonu Egzersizleri	143
7	Kantil Regresyon	145
7.1	Ortalama Neden Her Zaman Yeterli Değildir?	145
7.2	Medyan Regresyonu	146
7.3	Kantil Regresyon için Asimetrik Mutlak Kayıp (Check Loss)	147
7.4	Kantillerin Optimizasyon Karakterizasyonu	148
7.5	Doğrusal Kantil Regresyon Modeli	148
7.6	Örneklem Tahmin Edicisi	149
7.7	Kantil Katsayıları Nasıl Yorumlanır?	150
7.8	Kantil Profilleri ve Dağılımsal Heterojenlik	150

7.9	OLS ile Kantil Regresyon Aynı Şeyi Ölçmez	151
7.10	CPS Ücret Uygulaması: Kantil Profili	151
7.11	Standart Hatalar ve Çıkarım	152
7.12	Kantil Kesişmesi Problemi	153
7.13	Kantil Regresyon ve Nedensel Yorum	154
7.14	Kantil Regresyon Ne Zaman Özellikle Yararlıdır?	154
7.15	Makale Tablosu Nasıl Okunur?	155
7.16	Ampirik Uygulama Laboratuvarı: Ortalama Katsayıdan Dağılımsal Profile	155
7.16.1	Adım 1: Kantil katsayılarını tek tek değil profil olarak okumak	156
7.16.2	Adım 2: “Katsayılar farklı” ile “fark istatistiksel olarak kanıtlandı” ayrımı	157
7.16.3	Adım 3: Koşullu kantil heterojenliğini bireysel tedavi heterojenliğiyle karıştırmamak	157
7.16.4	Adım 4: Kod ve raporlama	157
7.16.5	Hansen’in DDK örneği: nokta tahmini ile belirsizliğin birlikte okunması	158
7.16.6	Kendi tezinizde kantil regresyon için protokol	158
7.17	Temel Sonuçlar	159
7.18	Bölüm Sonu Egzersizleri	159
8	Parametrik Olmayan Regresyon	162
8.1	Fonksiyonel Biçim de Bir Varsayımdır	162
8.2	En Basit Sezgi: Yakındaki Gözlemler Daha Fazla Bilgi Taşır	163
8.3	Nadaraya–Watson Kernel Regresyonu	164
8.4	Yerel Doğrusal Regresyon	165
8.5	Bant Genişliği: Esnekliğin Asıl Düğmesi	166
8.6	Çapraz Doğrulama ile Bant Genişliği Seçimi	167
8.7	Seri Regresyonu: Fonksiyonu Baz Fonksiyonlarla Yaklaştırmak	167
8.7.1	Kübik spline sezgisi	167
8.8	Hansen Verisiyle Uygulama: Test Puanı ve Başlangıç Başarısı	168
8.9	Boyutluluk Laneti	169
8.10	Kısmen Doğrusal Model	170
8.11	Çıkarım ve Güven Bantları	171
8.12	Hangi Yöntem Ne Zaman?	172
8.13	Ampirik Uygulama Laboratuvarı: DDK Verisinde Bant Genişliği Bir Model Kararıdır	172
8.13.1	Adım 1: Araştırma sorusu	172
8.13.2	Adım 2: Hansen’de iki farklı CV yaklaşımının farklı h seçmesi	172
8.13.3	Adım 3: Aynı veri, farklı düzgünlük	173
8.13.4	Adım 4: Kümeli yapıyı tuning aşamasına da taşımak	173
8.13.5	Bir nonparametrik makale çıktısını okurken	174
8.14	Temel Sonuçlar	175

8.15	Bölüm Sonu Egzersizleri	175
9	Regresyon Süreksizliği	178
9.1	Bir Eşik Neden Nedensel Bilgi Üretebilir?	178
9.2	Potansiyel Sonuçlarla Sharp RDD	179
9.3	Süreklilik Varsayımının İçeriği	180
9.4	Yerel Doğrusal RDD Tahmini	181
9.5	Bant Genişliği RDD’de Neyi Değiştirir?	182
9.6	Nokta Tahmini ile Çıkarım İçin Bant Genişliği Aynı Problem Değildir	182
9.7	Hansen’in Head Start Uygulaması	183
9.8	Bant Genişliği Duyarlılığı: Aynı Veri, Farklı Yerellik	183
9.9	Kovaryatlar RDD’yi Kurtarır mı?	185
9.10	Manipülasyon ve Running Variable Yoğunluğu	185
9.11	Grafiksel Raporlama	186
9.12	Bulanık (Fuzzy) RDD	187
9.13	Plasebo ve Sağlamlık Kontrolleri	188
9.14	RDD’nin Nedensel Yorumunun Sınırı	189
9.15	Ampirik Uygulama Laboratuvarı: RDD Sonuç Tablosunu Tasarım Olarak Okumak	189
9.15.1	Adım 1: Katsayıdan önce tasarım satırlarını okuyun	189
9.15.2	Adım 2: Bant genişliği tablosunu sonuç avcılığı için değil duyarlılık için kullanmak	190
9.15.3	Adım 3: Hansen’in tahminini yeniden üretmek: bant genişliği ölçeği	190
9.15.4	Adım 4: RDD grafiğini “güzel sıçrama” diye değil belirsizlikle birlikte okumak	191
9.15.5	Bir RDD makalesini değerlendirmek için kısa kontrol listesi	192
9.16	Temel Sonuçlar	192
9.17	Bölüm Sonu Egzersizleri	193
10	Yeniden Örnekleme: Jackknife ve Bootstrap	195
10.1	Temel Problem: Tahmin Edicinin Örnekleme Dağılımını Bilmiyoruz	195
10.2	Jackknife: Bootstrap’tan Önceki Yeniden Örnekleme	196
10.2.1	Regresyonda hesap kısayolu	197
10.2.2	Kümelenmiş veride jackknife	197
10.2.3	Jackknife mi bootstrap mı?	197
10.3	Nonparametrik Bootstrap Algoritması	198
10.4	Bootstrap Standart Hatası	198
10.5	Regresyonda Gözlem Çiftleri Bootstrap’ı (Pairs Bootstrap)	199
10.6	Normal-Yaklaşım Bootstrap Güven Aralığı	200
10.7	Percentile Güven Aralığı	200
10.8	Percentile-t Güven Aralığı	201

10.9	Parametrik Bootstrap	201
10.10	Wild Bootstrap: Heteroskedastisiteyi Korumak	202
10.11	Uygulama: Analitik ve Bootstrap Belirsizliğini Karşılaştırmak	202
10.12	Kaç Bootstrap Tekrarı?	203
10.13	Seed ve Yeniden Üretilbilirlik	204
10.14	Bağımlı Veride Yeniden Örnekleme Birimi	204
10.15	Bootstrap Ne Zaman Sorunlu Olabilir?	205
10.15.1	Yanlış yeniden örnekleme birimi	205
10.15.2	Zayıf tanımlama	205
10.15.3	Sınır ve düzgün olmayan problemler	205
10.15.4	Seyrek tasarım ve tekillik	205
10.15.5	Tanımlama ve model hatası	206
10.16	Analitik mi Bootstrap mı?	206
10.17	Ampirik Uygulama Laboratuvarı: Aynı Katsayı İçin Analitik ve Bootstrap Belirsizliği	207
10.17.1	Adım 1: Orijinal tahmin	207
10.17.2	Adım 2: Pairs bootstrap ile 1.000 yeniden örnekleme	207
10.17.3	Adım 3: Bootstrap kodunda yeniden örnekleme birimini açıkça görmek	208
10.17.4	Adım 4: Bootstrap tablosunu okurken dört soru	209
10.17.5	Adım 5: Bootstrap'ın çözemediği problemi görünür kılmak	209
10.18	Temel Sonuçlar	209
10.19	Bölüm Sonu Egzersizleri	210
11	Model Seçimi ve Düzenleştirme	212
11.1	Model Seçimi Neden Bir Ekonometrik Problemdir?	212
11.2	Yanlılık–Varyans Dengesi	213
11.3	AIC ve BIC: Uyum ile Karmaşıklık Birlikte Değerlendirmek	214
11.4	Ayırma Örnekleme (Hold-Out): Eğitim ve Test Örnekleme	215
11.5	Leave-One-Out ve K-Katlı Çapraz Doğrulama	216
11.6	Yüksek Boyutlu Regresyon	216
11.7	Düzenleştirmenin Genel Fikri	217
11.7.1	Neden standartlaştırma gerekir?	217
11.8	Ridge Regresyonu	218
11.9	Lasso: Küçültme ve Değişken Seçimini Birleştirmek	219
11.10	Ceza Parametresi Nasıl Seçilir?	220
11.11	Elastic Net	221
11.12	Post-Lasso	222
11.13	Model Seçimi Sonrası Çıkarım Problemi	222
11.14	Kontrollü Uygulama: Ridge, Lasso ve Post-Lasso	223
11.15	Ampirik Uygulama Laboratuvarı: Model Seçimini Gerçekten Dış-Örnekleme Değerlendirmek	223

11.15.1	Adım 1: Aday modeller	224
11.15.2	Adım 2: Test setini tuning için kullanmamak	225
11.15.3	Adım 3: Model seçimi tablosunda hangi sayılar görünmeli?	226
11.15.4	Adım 4: Tahmin ile yapısal çıkarım ayrımını korumak	226
11.16	Tez Çalışmasında Model Seçimi İçin Pratik Protokol	227
11.17	Bölüm Sonu Egzersizleri	227
12	Double/Debiased Machine Learning	230
12.1	Temel Problem: Çok Kontrol, Tek Hedef Parametre	230
12.2	Neden “Y’yi En İyi Açıklayan Değişkenleri Seçmek” Yetmez?	231
12.3	Double Selection Lasso	232
12.4	Artıklaştırma (Partialling-Out): Yüksek Boyutlu Bileşeni Ayırmak	233
12.5	Ortogonal Moment Fikri	234
12.6	Örneklem Bölme (Sample Splitting) Neden Eklenir?	235
12.7	Çapraz Uyarılama (Cross-Fitting) ve DML2 Algoritması	235
12.8	DML İçin Düzenlilik Koşulları: Ortogonallık Tek Başına Yeterli Değildir	236
12.9	DML Standart Hatası	237
12.10	DML Hangi Problemi Çözmez?	238
12.11	Kontrollü Uygulama: Naif Seçim, Double Selection ve DML	239
12.12	Yardımcı Modeller İçin Hangi Algoritmalar Kullanılır?	241
12.12.1	Lasso ve Post-Lasso	241
12.12.2	Regresyon ağaçları	241
12.12.3	Rassal ormanlar	241
12.12.4	Uygulama ilkeleri	242
12.13	Çapraz Uyarılamada Veri Sızıntısı	242
12.14	Rassal Bölme ve Yeniden Üretilbilirlik	243
12.15	Ampirik Uygulama Laboratuvarı: DML’i Tanımlama Stratejisinin Yerine Koy- mamak	244
12.15.1	Adım 1: Aynı estimand için üç tahmin yolu	244
12.15.2	Adım 2: Çapraz uyarlamayı okul kümelerine saygılı yapmak	245
12.15.3	Adım 3: DML makalesindeki sonuç tablosunu nasıl okumalıyız?	245
12.15.4	Adım 4: Benzer OLS ve DML sonuçlarını nasıl yorumlamalıyız?	246
12.15.5	Kendi tezinizde DML için uygulama protokolü	246
12.16	Bütünleşik Tez Araştırma Akışı	247
12.17	Bölüm Sonu Egzersizleri	249
	Seçilmiş İleri Okumalar	251
	A Bölüm Sonu Egzersizleri İçin Çözüm ve Açıklamalar	253
	Kaynakça	277

Bu Ders Notu Nasıl Kullanılmalı?

Bu ders notu, IKTT 807 Ekonometrik Modelleme ve Uygulamaları dersi için hazırlanmıştır. Ana içerik ve notasyon omurgası Hansen (2021) temel alınarak oluşturulmakta; anlatım, dersin haftalık akışına ve uygulama gereksinimlerine göre yeniden düzenlenmektedir. Metin, bir yöntemi yalnızca yazılım komutu olarak tanıtmak yerine araştırma sorusu, olasılıksal model, tanımlama, tahmin, çıkarım ve yorum arasındaki bağlantıyı kurmayı amaçlar.

Bu metin bir *özet ders notu* olarak tasarlanmamıştır. Amaç, öğrencinin ders sırasında ve sonrasında başvurabileceği, kavramların neden ortaya çıktığını, yöntemlerin hangi varsayımlara dayandığını ve ampirik sonuçların nasıl okunacağını yeterli ayrıntıyla açıklayan bağımsız bir kaynak oluşturmaktır. Bu nedenle bazı bölümlerde aynı kavram önce sezgisel, sonra matematiksel, ardından ampirik açıdan yeniden ele alınır. Öğrenciden beklenen, bu ayrıntılı metinden kendi çalışma özetini çıkarmasıdır.

Her konu mümkün olduğunca aynı akışı izler:

1. araştırma problemi ve motivasyon,
2. gerekli kavramlar ve notasyon,
3. ekonometrik model ve temel varsayımlar,
4. tahmin yönteminin matematiksel yapısı,
5. sonuçların ampirik ve ekonomik yorumu,
6. yöntemin hangi koşullarda yanıltıcı olabileceği,
7. Hansen veri tabanına dayalı ampirik uygulama laboratuvarı,
8. makale/yazılım çıktısının adım adım okunması ve tez uygulama protokolü,
9. bölüm sonu egzersizleri.

Ampirik uygulama laboratuvarları nasıl kullanılmalı?

Uygulama bölümlerinde amaç yalnız kodun çalışması değildir. Her laboratuvar araştırma sorusu ve tahmin hedefiyle başlar; ham veya kaynak-veriden analiz örnekleme geçişi, model/tuning kararlarını, sonuç tablosunu ve ekonomik yorumu birlikte ele alır. Öğrenci önce metindeki tabloyu bir makale okur gibi yorumlamalı, ardından verilen **Kod** bloklarını kullanarak aynı çıktıyı yeniden üretmeli ve son olarak “kendi tezinizde” kontrol listesiyle yöntemi farklı bir araştırma sorusuna taşımalıdır.

Bu bölümün amacı

Bir formülü kullanabilmek için üç soruya birlikte cevap verebilmek gerekir: *Bu formül hangi anakütle büyüklüğünü hedefliyor? Hangi veri ve varsayımlar altında anlamlıdır? Elde edilen sayı araştırma sorusuna nasıl çevrilir?* Ders boyunca matematiksel gösterim bu üç sorunun birbiriyle bağını kurmak için kullanılacaktır.

Kod parçaları, hesaplamanın nasıl üretildiğini görünür kılmak için verilecektir. Dersin temel hedefi belirli bir yazılım sözdizimini ezberlemek değil, farklı yazılımlarda aynı ekonometrik nesneleri tanıyabilmektir. Bu nedenle parametre, tahmin edici, tahmin, hata, artık, standart hata ve tahmin hedefi gibi kavramların ayrımı metin boyunca özellikle korunacaktır.

Ekonometrik Terimler ve İngilizce Karşılıkları

Bu ders notunda öğrencilerin uluslararası literatürü doğrudan izleyebilmesi için yaygın İngilizce terimler ilk kullanımda parantez içinde verilir. Sonraki kullanımlarda, anlam kaybı yaratmadığı sürece Türkçe karşılık tercih edilir. Aşağıdaki tablo metin boyunca izlenen temel terminoloji standardını özetler.

Türkçe kullanım	İngilizce karşılık	Bu nottaki anlamı
Tahmin hedefi	estimand	Anakütlede öğrenilmek istenen büyüklük.
Tanımlama	identification	Tahmin hedefinin gözlenen veri dağılımından hangi varsayımlarla belirlenebildiği.
Tahmin edici	estimator	Örnekleme parametre tahminine dönüştüren rassal kural.
Tahmin	estimate	Belirli bir örnekleme tahmin edicinin aldığı sayısal değer.
Tedavi / temel ilgi değişkeni	treatment	Nedensel tasarımda veya hedef katsayı probleminde etkisi incelenen değişken.
Sonuç değişkeni	outcome	Araştırmanın açıklamaya veya tahmin etmeye çalıştığı değişken.
Başarıya göre gruplama	tracking	Öğrencilerin başlangıç başarısına göre ayrı sınıflara yerleştirilmesi. Duflo–Dupas–Kremer deneyindeki müdahalenin ve tracking değişkeninin adı olduğu için metinde İngilizce adıyla kullanılır.
Eşik değişkeni	running variable	RDD’de tedavi kuralını belirleyen sürekli değerlendirme değişkeni.
Eşik	cut-off	RDD’de tedavi olasılığının keskin veya olasılıksal olarak değiştiği değer.
Kesilme	truncation	Belirli bir bölgedeki birimlerin veri setine hiç girmemesi.
Sansürleme	censoring	Birim örnekleme kalırken latent sonucun sınır değerinde raporlanması.

Türkçe kullanım	İngilizce karşılık	Bu nottaki anlamı
Asimetrik mutlak kayıp	check loss	Kantil regresyonda kullanılan $\rho_\tau(u)$ kayıp fonksiyonu.
Gözlem çiftleri bootstrap'ı	pairs bootstrap	(Y_i, X_i) satırlarının birlikte yeniden örneklenmesi.
Ayırma örnekleme	hold-out sample	Model kurma sürecinin dışında tutulan değerlendirme örnekleme.
Kat	fold	K -katlı çapraz doğrulama veya çapraz uyarlamadaki veri parçası.
Eğitim / test örnekleme	training / test sample	Modelin öğrenildiği ve nihai performansın değerlendirildiği veri bölümleri.
Veri sızıntısı	data leakage	Test/held-out bilgisine model kurma veya ön işleme sırasında dolaylı erişim.
Yardımcı bileşen	nuisance component	Doğrudan ilgi konusu olmayan fakat hedef parametre için öğrenilmesi gereken fonksiyon veya parametre.
Örnekleme bölme	sample splitting	Yardımcı modeller ile hedef parametrenin farklı veri parçalarında tahmin edilmesi.
Çapraz uyarlama	cross-fitting	Her gözlemin yardımcı tahmininin, o gözlemi eğitimde kullanmayan modelden üretilmesi.
Artıklaştırma	partialling-out	Y ve temel ilgi değişkeninden kontrollerin öngörülebilir kısmının çıkarılması.
Yumuşak eşikleme	soft-thresholding	Lasso'nun ortogonal tasarımı katsayıları sıfıra doğru eşikleyerek küçültmesi.
Kutulanmış ortalamalar	binned means	RDD grafiğinde eşik değişkenini aralıklara bölerek hesaplanan yerel ortalamalar; ana çıkarım grafiğinin yerine kullanılmamalıdır.
Yanlılık düzeltmeli çıkarım	bias-corrected inference	Düzgünleştirme yanlılığını çıkarım aşamasında açıkça hesaba katan yaklaşım.
Düzenleştirme	regularization	Karmaşıklık ceza terimiyle kontrol eden tahmin yaklaşımı.
Çapraz doğrulama	cross-validation	Ayrılan veri parçalarında tahmin hatasını ölçerek tuning/model seçimi yapma yöntemi.
Küme	cluster	Gözlemlerin içinde bağımlı, arasında bağımsız kabul edildiği gruplama birimi.
Küme-dayanıklı standart hata	cluster-robust standard error	Küme içi keyfi bağımlılığa izin veren sandviç kovaryans tahmini.

Türkçe kullanım	İngilizce karşılık	Bu nottaki anlamı
Tasarım etkisi	design effect	Kümelenme nedeniyle varyansın kaç kat büyüdüğünü gösteren $\tau = 1 + (m - 1)\rho$ çarpanı.
Delta yöntemi	delta method	Katsayıların doğrusal olmayan bir fonksiyonunun standart hatasını türetme kuralı.
Testin boyutu	size	Sıfır hipotezi doğruyken reddetme olasılığı (α).
Testin gücü	power	Sıfır hipotezi yanlışken reddetme olasılığı.
Skor	score	Log-olabilirliğin parametreye göre türevi.
Bilgi matrisi eşitliği	information matrix equality	Doğru belirtim altında skor varyansı ile ortalama eğriliğin eşit olması.
Dışarıda bırakma	leave-one-out	Bir gözlemi çıkarıp kalan veriyle tahmin etme işlemi; jackknife ve LO-OCV'nin ortak temeli.
Yardımcı model öğrencisi	nuisance learner	Yardımcı fonksiyonları tahmin etmek için kullanılan algoritma (Lasso, ağaç, rassal orman vb.).

Terminoloji neden iki dilli?

Amaç Türkçe anlatım ile uluslararası ekonometrik literatür arasında bir sözlük köprüsü kurmaktır. Bir makalede *estimand*, *cross-fitting* veya *running variable* ifadesi görüldüğünde, öğrencinin bu terimi nottaki kavramsal karşılığıyla doğrudan eşleştirebilmesi beklenir.

Hansen ile Ortak Notasyon Rehberi

Bu notların notasyon referansı, Bruce E. Hansen'in *Econometrics* kitabının 11 Mart 2021 tarihli sürümüdür (Hansen, 2021). Bölüm numaraları ve sayfa göndermeleri bu sürüme aittir. Yazı biçimi tek başına bir niceliğin boyutunu belirlemez; tanım, gözlem indisi ve çarpımın boyutları birlikte okunur.

Rassal değişken, gerçekleşme ve yığılmış örneklem

Hansen §1.3'te rassal skalerleri ve rassal vektörleri normal italik büyük harfle (Y, X, Z), gerçekleşmiş değerleri küçük harfle (y, x, z), genel deterministik vektörleri küçük italik veya kalın italik harfle gösterir. Hata değişkenleri e, u, v küçük harf kuralının istisnalarıdır. Yunan parametreleri ($\beta, \theta, \gamma, \eta$) skaler veya vektör olabilir; boyutları tanımlanır. Matrisler kalın italik büyük harfidir: $\mathbf{X}, \mathbf{Q}, \mathbf{V}, \mathbf{\Omega}$.

Tek sonuçlu regresyonda Y_i skaler, X_i ise $k \times 1$ regresör vektörüdür. Küçük x , X 'in belirli bir gerçekleşmesini gösteriyorsa aynı boyuttaki vektördür. Küçük y ise skaler Y 'nin gerçekleşmesidir. Bu nedenle bütün küçük x, y simgelerini aynı anda vektör saymak doğru değildir.

İndissiz denklem tek bir rassal gözlemi temsil eder. $Y = X'\beta + e$ yazıldığında $Y, e \in \mathbb{R}$ skaler rassal değişkenler, $X \in \mathbb{R}^k$ rassal sütun vektörü, $\beta \in \mathbb{R}^k$ parametre sütun vektörüdür. Gözlem indisi yalnızca yazılmamıştır:

$$\underbrace{Y}_{1 \times 1} = \underbrace{X'}_{1 \times k} \underbrace{\beta}_{k \times 1} + \underbrace{e}_{1 \times 1}.$$

Normal italik X burada skaler değildir; kalın yazılmaması Hansen'in rassal vektör konvansiyonudur. $X'\beta$ skaler *doğrusal indekstir*. Gözlem indisi eklenince

$$Y_i = X_i'\beta + e_i, \quad i = 1, \dots, n$$

elde edilir. Sabit ayrı indisleniyorsa $X_i = (1, X_{i1}, \dots, X_{i,k-1})'$ ve $\beta = (\beta_0, \dots, \beta_{k-1})'$ ile $X_i'\beta = \beta_0 + \sum_{j=1}^{k-1} \beta_j X_{ij}$ olur. Burada i gözlemi, j regresörü sayar. Bu gözlem düzeyi gösterimi, aşağıdaki yığılmış örneklem gösteriminden ayırdır.

Hansen §3.10–3.11, bütün örnekleme şu biçimde yığar:

$$\mathbf{Y} = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad \mathbf{X} = \begin{pmatrix} X_1' \\ \vdots \\ X_n' \end{pmatrix}, \quad \mathbf{e} = \begin{pmatrix} e_1 \\ \vdots \\ e_n \end{pmatrix}, \quad \mathbf{Y} = \mathbf{X}\beta + \mathbf{e}.$$

Burada $\mathbf{Y}$ ve $\mathbf{e}$, $n \times 1$ vektörler; $\mathbf{X}$, $n \times k$ matristir. Yığılmış sonuç vektörünün büyük $\mathbf{Y}$ olması

kaynağın kendi konvansiyonudur. OLS'nin iki gösterimi aynı nesneyi verir:

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \left(\sum_{i=1}^n X_i X_i'\right)^{-1} \sum_{i=1}^n X_i Y_i.$$

$$\hat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\hat{\beta}, \quad \hat{e}_i = Y_i - X_i'\hat{\beta}, \quad \mathbf{X}'\hat{\mathbf{e}} = \mathbf{0}_k.$$

Kalın simgeler **bm** ile kalın italik yazılır. Normal italik X anakütle rassal vektörü, kalın $\mathbf{X}$ örneklem matrisi olarak ayrı tutulur.

Boyutlar ve temel işlemler

Sembol	Boyut	Anlam
n, k	skaler	Gözlem sayısı; sabit terim dahil regresör sayısı
X_i, β, b	$k \times 1$	Gözlem regresörleri; parametre; aday parametre
$\mathbf{X}, \mathbf{Z}$	$n \times k, n \times \ell$	Regresör ve araç örneklem matrisleri
$\mathbf{Y}, \mathbf{e}, \hat{\mathbf{e}}$	$n \times 1$	Yığılmış sonuç, hata ve artık
$\mathbf{I}_r, \mathbf{0}_r, \mathbf{1}_r$	$r \times r, r \times 1, r \times 1$	Birim matris; sıfır ve birler vektörleri
$\mathbf{Q}_{XX}$	$k \times k$	$E[XX']$, ikinci moment matrisi
$\mathbf{R}, \mathbf{r}$	$q \times k, q \times 1$	$\mathbf{R}\beta = \mathbf{r}$ doğrusal kısıtları
$1\{A\}$	skaler	A gerçekleşirse 1, aksi hâlde 0

Kesme işareti $'$ transpoz, $\|a\|_2 = (a'a)^{1/2}$ Öklid normu, E , var, cov ve corr beklenti, varyans, kovaryans ve korelasyon operatörleridir. $\xrightarrow{p}$ olasılıkta, $\xrightarrow{d}$ dağılımda yakınsamayı gösterir. $o_p(a_n)$, a_n 'ye bölündüğünde olasılıkta sıfıra yakınsayan terimdir; $O_p(a_n)$ aynı ölçekle bölündüğünde olasılıkta sınırlı terimdir.

Sabit terim açıkça ayrılan skaler örneklerde β_0 sabit, $\beta_1, \dots, \beta_{k-1}$ eğimlerdir; buna karşılık $X'\beta$ gösteriminde k sabit sütununu da içerir. Bu yerel indisleme $\beta = (\beta_0, \dots, \beta_{k-1})'$ ve $X = (1, X_1, \dots, X_{k-1})'$ tanımıyla okunur. β_0 burada bütün parametre vektörünün “gerçek değeri” için kullanılmaz. Düzenileştirme bölümünde p yalnız cezalandırılan eğimlerin sayısıdır ve sabit terim ayrı tutulur.

Varyansın iki ölçeği

Hansen §7.8, regresyonun sonlu örneklem gösteriminde $\mathbf{X}'$ e koşullu $\hat{\beta}$ kovaryansını $\mathbf{V}_{\hat{\beta}}$, $\sqrt{n}(\hat{\beta} - \beta)$ limitinin kovaryansını $\mathbf{V}_{\beta}$ ile gösterir. Üstteki şapka, bu matrislerin örneklemden tahminini belirtir:

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(\mathbf{0}_k, \mathbf{V}_{\beta}), \quad \widehat{\mathbf{V}}_{\beta} = n\widehat{\mathbf{V}}_{\hat{\beta}}.$$

Standart hata hesabında kullanılan matris $\widehat{\mathbf{V}}_{\hat{\beta}}$ 'dir. 0, HC0–HC3 ve CL üst etiketleri sırasıyla homoskedastik, heteroskedastisiteye dayanıklı ve bu notlarda tanımlanan küme-dayanıklı tahminleri ayırır. Skaler θ için aynı ayırım kalın olmayan V_{θ} ve $V_{\hat{\theta}}$ ile yapılır. $\hat{V}_i$ DML'de bir artık skaleridir; kovaryans matrisi $\widehat{\mathbf{V}}_{\beta}$ ile farklı nesnedir.

Bölümlerde kullanılan yerel ve ek semboller

Bir sembol bölüm değiştiğinde yeni bir nesneyi temsil ediyorsa tanımı yeniden verilir. Aşağıdaki eşleştirme özellikle kaynağı okurken kullanılmalıdır.

Regresyon ve çıkarım (1–2). $m(x) = E[Y | X = x]$ koşullu ortalamadır. SSE, TSS ve ESS artık, toplam ve açıklanan kareler toplamlarıdır ve bu notlarda açıkça tanımlanır. Delta yönteminde ek $\mathbf{a}(\beta) = \partial h(\beta) / \partial \beta$ gradyan vektörüdür. h_{ii} kaldırma ve $\hat{\beta}_{(-i)}$ gözlem dışarıda bırakma tahmini Hansen §3.19–3.20 ile aynıdır.

Nedensellik ve IV (3–4). Y_1, Y_0 potansiyel sonuçlar, $\theta = Y_1 - Y_0$ bireysel etkidir. ATE ve ATT ilgili ortalama etkileri adlandırır. D_1, D_0 , ikili aracın iki durumundaki potansiyel tedavi kararlarıdır. $\mathbf{\Gamma}_{22} \in \mathbb{R}^{\ell_2 \times k_2}$ dışlanmış araçların ilk aşama katsayı matrisi; $\mathbf{P}_Z$ araç uzayına projeksiyon; $\mathbf{W}$ GMM ağırlık matrisi; $\hat{\mathbf{g}}(b)$ örneklem moment vektörüdür. Normal W kontrol vektörü ile kalın $\mathbf{W}$ farklıdır.

İkili ve ayrık sonuçlar (5). G bağlantı dağılım fonksiyonu, $g = G'$ yoğunluk, Λ lojistik, Φ standart normal dağılım fonksiyonudur. Q olabilirlik eğriliği, Ω skor kovaryansdır (§25.7–25.8). $\mathbf{s}_i$ ve $\mathbf{s}_n$ gözlem ve toplam skor için tanımlanan ek vektörlerdir. AME ve ME ortalama ve gözlem marjinal etkilerini etiketler. Bu bölümün g 'si DML'deki yapısal fonksiyon değildir.

Sansürleme ve seçim (6). Y^* gizli sonuç, S^* seçim indeksi, S seçim göstergesi, $\lambda(v) = \phi(v)/\Phi(v)$ ters Mills oranıdır. $\sigma_{21} = \text{cov}(e, u)$, $\text{var}(u) = 1$ normalizasyonu ile seçim düzeltmesinin katsayısıdır (§27.10). Tahmin edilmiş oran $\hat{\lambda}_i$, bu katsayının tahmini $\hat{\sigma}_{21}$ 'den ayrı tutulur.

Kantil regresyonu (7). $q_\tau(x)$ koşullu kantil fonksiyonu ve $Q_\tau[Y | X]$ kantil operatörüdür (§24). Bu bölümde $m(x) = q_{0.5}(x)$ koşullu medyandır. ρ_τ asimetrik kayıp, ψ_τ kantil skorudur. $\mathbf{V}_{\beta_\tau}$, kantil indeksini açık tutmak için $\mathbf{V}_{\beta'}$ 'nin alt indisi genişletilmiş biçimdir.

Esnek regresyon (8). K kernel fonksiyonu olarak bir argümanla, baz sayısı olarak ise skaler kullanılır; her kullanım yerinde tanımlanır. h bant genişliği, J düğüm sayısıdır. Hansen'in $Y = m(X) + Z'\beta + e$ kısmen doğrusal modeli, tek doğrusal regresörlü örnekte $Z = D$, $\beta = \theta$, $m = g$ eşleştirmesiyle yazılır. Yapısal g , $m_Y = E[Y | X]$ ile karıştırılmaz.

RDD (9). X koşu değişkeni, c eşik, $R_i = X_i - c$ yerel merkezlenmiş değişken, h bant genişliğidir. Hansen'in $\theta(c)$ hedefi keskin tasarıda eşikteki koşullu etkiyi verir. Bulanık tasarım hedefi θ_{FRD} ayrı tanımlanır.

Bootstrap (10). Yıldız * bootstrap örnekleme veya tahminini; $b = 1, \dots, B$ tekrar indisini; B tekrar sayısını gösterir. b aday regresyon katsayısı olarak kullanıldığında bağlam farklıdır. $\hat{\theta}_{(-i)}$ gözlem dışarıda bırakma tahmini, $\bar{\theta}^*$ bootstrap ortalamasıdır.

Düzenleştirme (11). λ ceza, α Hansen'in Elastic Net L_2 ağırlığıdır. λ_y yazılım ölçeğindeki ek ceza simgesidir ve dönüşümü model bazında verilir. $\mathbf{X}'\mathbf{X} = \mathbf{H}'\mathbf{D}\mathbf{H}$, $\mathbf{D} = \text{diag}(r_1, \dots, r_p)$, $\mathbf{H}$ ortonormal matris olarak Hansen §29.5'i izler. Bu matris $\mathbf{D}$ ile tedavi skaler D ayrıdır.

DML (12). $D = X'\gamma + V$, $Y = X'\eta + U$ indirgenmiş biçimlerdir. Ek $m_D = E[D | X]$, $m_Y = E[Y | X]$, $\nu = (m_Y, m_D)$ fonksiyonları ile η katsayı vektörü ayrıdır. M anakütle momenti, ψ gözlem skoru, φ normalize etki katkısı, J moment eğiminin eksi işaretlisidir.

A_k Hansen §29.22'deki eğitim dışında tutulan gözlem-indis kümesidir. $\widehat{\mathbf{U}}, \widehat{\mathbf{V}}$ yığılmış, $\widehat{U}_i, \widehat{V}_i$ tek gözlemlilik artıklardır. $\|f\|_{P,2}$ anakütle L_2 normudur.

Sık yapılan hata

Aynı simgenin farklı modellerde kullanılması, nesnelerin aynı olduğu anlamına gelmez. Özellikle X 'in skaler mi vektör mü olduğu, D 'nin tedavi mi $\mathbf{D}$ özdeğer matrisi mi olduğu, m 'nin ortalama mı medyan mı olduğu ve V 'nin artık mı varyans mı olduğu ilk tanımdan okunmalıdır. Boyutlar ve yerel tanımlar, aşağıdaki tüm bölümlerde bu rehberle birlikte geçerlidir.

Başlangıç Araç Kutusu: Olasılık, Notasyon ve Matrisler

Bu bölümün amacı

Bu bölüm, ilerleyen konularda sürekli kullanılacak temel dili tek yerde toplar. Amaç; rassal değişken, beklenen değer, koşullu beklenen değer, varyans–kovaryans, örneklem ile anakütle ayrımı, vektör–matris gösterimi ve en küçükleme problemlerini gerektiği anda okuyabilecek ortak bir notasyon oluşturmaktır.

0.1 Rassal Değişken ve Dağılım

Ekonometrik modelde gözlemlenmeden önce değeri kesin olarak bilinmeyen nicelikler rassal değişken olarak temsil edilir. Ücret, tüketim, yatırım, firma kârlılığı veya sınav puanı gibi değişkenlerin gerçekleşen değerleri veri setinde sabit sayılar olarak görünür; fakat ekonometrik analiz bu gözlemleri daha geniş bir olasılık mekanizmasının gerçekleşmeleri olarak ele alır. Hansen’in olasılık yaklaşımında bu düşünce, ekonometrik modelin temelidir (Hansen, 2021).

Bir rassal değişkeni Y ile gösterelim. Dağılım fonksiyonu

$$F_Y(y) = P(Y \leq y)$$

şeklinde tanımlanır. Sürekli bir değişken için yoğunluk $f_Y(y)$ kullanıldığında, bir aralığa düşme olasılığı yoğunluğun o aralık üzerindeki alanı ile bulunur. Ders boyunca yoğunlukla dağılımın tamamını değil, dağılımdan türeyen bazı fonksiyonları kullanacağız.

0.2 Beklenen Değer, Varyans ve Kovaryans

Sürekli bir Y değişkeninin beklenen değeri

$$E[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy$$

olarak yazılır. Kesikli değişkende integralin yerini olasılıklarla ağırlıklandırılmış toplam alır. Beklenen değer doğrusal bir operatördür:

$$E[a + bY + cZ] = a + bE[Y] + cE[Z].$$

Varyans, değişkenin ortalama çevresindeki yayılımını ölçer:

$$\text{var}(Y) = E[(Y - E[Y])^2].$$

İki değişkenin doğrusal birlikte hareketi kovaryans ile özetlenir:

$$\text{cov}(X, Y) = E[(X - E[X])(Y - E[Y])].$$

Korelasyon ise kovaryansı değişkenlerin standart sapmalarıyla ölçekler:

$$\text{corr}(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{\text{var}(X) \text{var}(Y)}}.$$

Sık yapılan hata

$\text{cov}(X, Y) = 0$ olması, genel olarak X ile Y 'nin bağımsız olduğu anlamına gelmez. Sıfır kovaryans yalnızca doğrusal ilişkinin olmadığına işaret eder. Bu ayrım özellikle doğrusal regresyonu koşullu beklentinin bir yaklaşımı olarak yorumlarken önem kazanacaktır.

0.3 Koşullu Beklenen Değer

X hakkında bilgi sahibi olduğumuzda Y 'nin ortalaması değişebilir. Bu bilgiye göre hesaplanan ortalama

$$E[Y | X = x]$$

ile gösterilir. x değiştikçe bu değer de değiştiği için

$$m(x) = E[Y | X = x]$$

bir fonksiyondur. Buna **koşullu beklenti fonksiyonu** denir. Rassal değişkenin kendisiyle yazıldığında $m(X) = E[Y | X]$ biçimini kullanırız.

Koşullu beklentinin en sık kullanılacak özelliklerinden biri yinelenen beklentiler yasasıdır:

$$E[E[Y | X]] = E[Y].$$

Bu eşitlik, önce her X alt grubunda ortalama alıp sonra bu grup ortalamalarını uygun biçimde birleştirmenin anakütle ortalamasını verdiğini söyler.

Koşullu beklentinin iki özelliği bu ders boyunca sürekli kullanılacaktır. Birincisi, X 'in bilinen bir fonksiyonu koşul içinde sabit gibi dışarı alınabilir:

$$E[h(X)Y | X] = h(X) E[Y | X].$$

İkincisi yinelenen beklentiler yasasıdır:

$$E\{E[Y | X]\} = E[Y].$$

Bu yasa, koşullu momentlerden koşulsuz moment üretmemizi sağlar. Örneğin $E[e | X] = 0$ ise otomatik olarak $E[e] = 0$ ve uygun $h(X)$ için $E[h(X)e] = 0$ elde edilir. OLS ve GMM momentlerinin önemli kısmı bu basit kurala dayanır.

0.4 Anakütle, Örneklem, Parametre ve Tahmin Edici

Anakütledeki bilinmeyen bir büyüklüğü θ ile gösterelim. Örneğin $\theta = E[Y]$ olabilir. Elimizde n gözlemden oluşan rassal örneklem varsa,

$$(Y_1, X_1), \dots, (Y_n, X_n),$$

örneklemden hesaplanan bir kural $\hat{\theta}$ ile gösterilir ve **tahmin edici** adını alır. Belirli bir veri seti kullanıldığında $\hat{\theta}$ sayısal bir **tahmin** üretir.

Bu ayrım regresyonda merkezi önemdedir:

$$\beta \quad \text{anakütle parametresi}, \quad \hat{\beta} \quad \text{örneklem tahmin edicisi}.$$

Aynı veri üretim sürecinden yeni bir örneklem çekilse β değişmez; $\hat{\beta}$ ise örneklemden örnekleme değişebilir.

Parametre rassal değildir; bilinmeyen anakütle özelliğidir. Tahmin edici ise örneklemin fonksiyonu olduğu için örneklemden örnekleme değişen rassal bir değişkendir. Örneğin β anakütle regresyon katsayısı, $\hat{\beta}$ OLS tahmin edicisidir; gözlenen veri üzerinde hesaplanan sayısal değer de tahmindir.

Standart hata $\hat{\beta}$ 'nin örnekleme değişkenliğini tahmin eder. Bu nedenle “katsayının standart sapması” ifadesi yerine “tahmin edicinin standart hatası” demek daha doğrudur. Aynı parametre farklı tahmin edicilerle tahmin edilebilir ve bunların yanlışlık/varyans özellikleri farklı olabilir.

0.5 Vektör ve Matris Gösterimi

Birden fazla açıklayıcı değişken olduğunda

$$X = \begin{pmatrix} X_1 \\ X_2 \\ \vdots \\ X_k \end{pmatrix}, \quad \beta = \begin{pmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{pmatrix}$$

ve doğrusal ifade

$$X'\beta = \beta_1 X_1 + \dots + \beta_k X_k$$

biçiminde yazılır. Burada $'$ transpoz işaretidir; bu gösterimde X ve β , $k \times 1$ sütun vektörleridir. X_j bileşen indisi, X_i ise örneklem bağlamında i 'inci gözlemin tüm regresör vektörüdür. Sabit terim varsa bir bileşen 1'dir ve k bu bileşeni de içerir.

Örneklemde tüm gözlemleri bir araya getirdiğimizde

$$Y = \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix}, \quad X = \begin{pmatrix} X'_1 \\ \vdots \\ X'_n \end{pmatrix}$$

kullanılır. Böylece n ayrı denklem tek satırda

$$Y = X\beta + e, \quad e = (e_1, \dots, e_n)'$$

olarak yazılabilir. Boyutlar $\mathbf{Y}, \mathbf{e} \in \mathbb{R}^n$ ve $\mathbf{X} \in \mathbb{R}^{n \times k}$ 'dir. Kalın $\mathbf{X}$ örneklem tasarım matrisini, tek bir gözleme ait X_i ise açıklayıcı değişkenler vektörünü ifade eder.

Ters matris ve tam sütun rankı

$\mathbf{X}'\mathbf{X}$ matrisinin tersinin bulunabilmesi için açıklayıcı değişken sütunlarının tam doğrusal bağımlılık taşıması gerekir. Örneğin bir açıklayıcı değişken diğerlerinin tam doğrusal birleşimi ise katsayılar tekil olarak belirlenemez. Bu durum ileride çoklu doğrusal bağlantı ve kukla değişkenler bağlamında yeniden ele alınacaktır.

0.6 En Küçükleme ve Birinci Derece Koşulu

Birçok ekonometrik tahmin edici bir amaç fonksiyonunu en küçükleyen parametre değeridir. Tek değişkenli basit bir problemde

$$\hat{\theta} = \arg \min_t Q(t)$$

yazarız. Eğer $Q(t)$ türevlenebilir ve iç çözüm varsa, aday çözüm

$$\frac{dQ(t)}{dt} = 0$$

koşulunu sağlar. Çok boyutlu parametrelerde aynı düşünce gradyan ile kullanılır:

$$\frac{\partial Q(\beta)}{\partial \beta} = 0.$$

En küçük kareler tahmin edicisi tam olarak bu yapıdan elde edilecektir.

Araç kutusundan taşınacak temel dil

İlerleyen bölümlerde $E[\cdot]$ anakütle ortalamasını, $E[\cdot | X]$ koşullu ortalamayı, β anakütle parametresini, $\hat{\beta}$ örneklem tahmin edicisini ve $\mathbf{X}'\beta$ doğrusal indeks yapısını gösterecektir. Bu notasyon bütün ders boyunca korunacaktır.

0.7 Büyük Sayılar Yasası ve Merkezi Limit Teoremi

Ekonometride büyük örneklem teorisinin iki temel aracı büyük sayılar yasa (LLN) ve merkezi limit teoremidir (CLT). LLN, uygun koşullarda örneklem ortalamalarının anakütle beklentilerine yaklaştığını söyler. Örneğin

$$\frac{1}{n} \sum_{i=1}^n X_i Y_i \xrightarrow{p} E[XY].$$

Bu sonuç OLS gibi momentlere dayanan tahmin edicilerin tutarlılığını anlamamıza yardım eder: örneklem momentleri büyük n 'de hedef anakütle momentlerini temsil eder.

CLT ise normalize edilmiş örneklem toplamlarının yaklaşık normal dağılıma yöneldiğini söyler. Basit ortalama için

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N(0, \sigma^2).$$

Regresyon tahmin edicilerinin t istatistikleri ve güven aralıkları daha karmaşık olsa da aynı temel fikir kullanılır. Büyük örneklem normalitesi “veriler normal dağılmalıdır” demek değildir;

tahmin edicinin uygun ölçeklenmiş dağılımının çok sayıda gözlemin toplam etkisiyle normale yaklaşmasıdır.

Sık yapılan hata

Büyük n tanımlama hatasını çözmez. LLN ve CLT, doğru anakütle hedefine yönelen bir tahmin edicinin örnekleme davranışını açıklar. Eğer endojenlik nedeniyle OLS yanlış parametreye yakınsıyorsa, daha büyük örneklem yanlış hedefi daha hassas tahmin eder.

0.8 Olabilirlik, Skor ve Sayısal Optimizasyon

Bazı modellerde tahmin edici kareli hata yerine olabilirlik fonksiyonunu optimize eder. Parametre θ altında bir gözlemin olasılık/yoğunluk katkısı $f(Y_i | X_i; \theta)$ ise bağımsız örneklem olabilirliği

$$L_n(\theta) = \prod_{i=1}^n f(Y_i | X_i; \theta)$$

ve log-olabilirlik

$$\ell_n(\theta) = \sum_{i=1}^n \log f(Y_i | X_i; \theta)$$

L_n örneklem olabilirliği ve ℓ_n örneklem log-olabilirliği için kullanılan ek simgelerdir. Maksimum olabilirlik tahmin edicisi $\hat{\theta} = \arg \max_{\theta} \ell_n(\theta)$ 'dır.

Logaritma çarpımı toplama dönüştürür ve aynı maksimum noktasını korur. Skor vektörü $s_n(\theta) = \partial \ell_n(\theta) / \partial \theta$ eğimi, Hessian ise ikinci türev matrisini gösterir. Kapalı biçimli çözüm olmadığında Newton veya quasi-Newton türü sayısal optimizasyon yöntemleri kullanılır. Logit, Probit, Tobit ve ordered modellerde bu mantık tekrar karşımıza çıkacaktır.

Optimizasyonun yakınsaması modelin doğru tahmin edildiği anlamına gelmez. Nümerik algoritma yalnız verilen amaç fonksiyonunun optimumunu bulur; model varsayımları ve tanımlama ayrıca değerlendirilmelidir.

Ampirik Ekonometrik Modelleme ve Regresyonun Temeli

Bu bölümün amacı

Bu bölümün sonunda ekonometrinin olasılıksal yaklaşımını açıklayabilecek; gözlemsel veride değişkenlerin neden rassal kabul edildiğini tartışabilecek; koşullu beklenti fonksiyonunu tanımlayıp hata teriminin temel özelliklerini türetebilecek; koşullu ortalamanın neden kareli hata kaybı altında en iyi öngörücü olduğunu gösterebilecek; doğrusal koşullu ortalama ile en iyi doğrusal öngörücü arasındaki farkı kurabilecek; anakütledeki doğrusal projeksiyon katsayısını ve örneklemdaki OLS tahmin edicisini elde edebilecek; regresyon katsayısını betimleyici, öngörücü ve nedensel yorumlardan hangisinin desteklediğini ayırt edebilecek ve ampirik bir çalışmanın yeniden üretilebilir biçimde nasıl düzenleneceğini açıklayabileceksiniz.

Bağlantı

Başlangıç Araç Kutusu'nda beklenen değer, koşullu beklenti, varyans-kovaryans, örneklem-anakütle ayrımı ve matris gösterimini topladık. Şimdi bu araçları tek bir sorunun etrafında birleştiriyoruz: *Bir ekonomik sonucu açıklamak veya öngörmek istediğimizde regresyon gerçekte hangi anakütle nesnesini temsil eder?*

1.1 Ekonometrinin Olasılıksal Yaklaşımı

Ekonometri, ekonomik teori ile veriyi yalnızca bir denklem aracılığıyla yan yana getirme işi değildir. Modern yaklaşımda ekonomik değişkenler bir olasılık modelinin parçaları olarak ele alınır. Hansen, bu yaklaşımın temelini Haavelmo'nun olasılıksal ekonomi anlayışıyla ilişkilendirir ve gözlenen ekonomik büyüklüklerin deterministik bir modelin kusursuz çıktıları olarak değil, rassallık içeren bir veri üretim sürecinin gerçekleşmeleri olarak düşünülmesi gerektiğini vurgular (Hansen, 2021).

Bu bakış açısının pratik sonucu önemlidir. Örneğin aynı eğitim düzeyine sahip iki çalışanın ücreti aynı olmak zorunda değildir. Aynı büyüklükte iki firmanın yatırımı farklı olabilir. Benzer kredi notuna sahip iki müşterinin geri ödeme davranışı farklılaşabilir. Ekonometrik model, bu heterojenliği sonradan eklenen bir “gürültü” olarak değil, doğrudan modelin olasılıksal yapısının bir parçası olarak görür.

Ampirik ekonometrik modelleme

Ampirik ekonometrik modelleme; araştırma sorusunu, gözlenebilir değişkenleri, olasılıksal veri üretim sürecini, hedeflenen anakütle büyüklüğünü ve bu büyüklüğü örneklemden tahmin edecek yöntemi birlikte tanımlama sürecidir.

1.1.1 Araştırma sorusundan tahmin hedefine

Bir araştırma sorusu önce sözlü olarak ifade edilir. Örneğin:

Çalışanların eğitim düzeyi yükseldikçe saatlik ücretlerinin koşullu ortalaması nasıl değişmektedir?

Bu soru henüz bir regresyon denklemi değildir. Önce sonucu ve açıklayıcı bilgiyi tanımlarız:


$$Y = \log(\text{saatlik ücret}), \quad X = \text{eğitim yılı}.$$

Ardından hangi anakütle nesnesini öğrenmek istediğimizi açıklarız. Burada doğal hedef

$$m(x) = E[Y \mid X = x]$$

koşullu beklenti fonksiyonudur. Bu fonksiyon, eğitim düzeyi x olan alt popülasyonda log ücretin ortalamasını verir.

Bu küçük adım ekonometrik modellemenin merkezindedir: **önce tahmin hedefi, sonra tahmin edici**. Yazılımın verdiği katsayıların ne anlama geldiği, hangi anakütle nesnesinin hedeflendiği bilinmeden belirlenemez.



Şekil 1.1: Ampirik ekonometrik modellemenin temel karar zinciri

Bu yaklaşımı benimsemek, “hata terimi”nin modele sonradan eklenen teknik bir ayrıntı olmadığını anlamayı gerektirir. Ekonomik davranış aynı gözlenebilir koşullar altında bile farklılaşabilir; çünkü araştırmacının gözlemediği tercihler, beklentiler, kurumlar, ölçüm hataları ve çok sayıda küçük şok sonuç üzerinde birlikte etkili olur. Olasılıksal model bu heterojenliği sistematik biçimde temsil eder. Dolayısıyla bir ekonometrik model yalnızca ortalama ilişkinin denklemini değil, gözlenen verinin hangi rassal mekanizmayla ortaya çıkabileceğine ilişkin bir çerçeveyi de içerir.

Bu çerçevenin ikinci sonucu, bir modelin “doğru” olup olmadığı sorusunun tek başına yeterli olmamasıdır. Uygulamada çoğu ekonometrik model gerçek veri üretim sürecinin eksiksiz betimi değildir; belirli bir araştırma sorusu için yararlı bir yaklaşım olabilir. Bu nedenle araştırmacı, modeli değerlendirirken üç ayrı soruyu ayırmalıdır: (i) hedeflenen anakütle büyüklüğü nedir, (ii)

bu büyüklük gözlenen dağılımdan hangi varsayımlarla öğrenilebilir ve (iii) kullanılan tahmin edici bu hedefe hangi örneklem özellikleri altında yaklaşır? Hansen’in yapısal, yarı-yapısal ve semiparametrik yaklaşımlar arasında yaptığı ayrımın ortak noktası da budur: ekonometrik çıkarım, olasılıksal model ile tahmin hedefi arasındaki bağı açık kurmalıdır (Hansen, 2021).

Bir tez sorusunu ekonometrik soruya çevirirken

“X, Y’yi etkiliyor mu?” biçimindeki genel bir soru doğrudan tahmin edilemez. Önce hangi Y ölçüsünün kullanılacağı, X’in hangi karşılaştırmayı temsil ettiği, diğer bilgilerin nasıl koşullandırılacağı ve hedefin koşullu ortalama, olasılık, kantil ya da nedensel etki olup olmadığı belirlenmelidir. Aynı veri seti, farklı tahmin hedefleri için farklı ve aynı anda geçerli ekonometrik analizlere yol açabilir.

1.2 Gözlemsel Veri ve Rassallık

Ekonomide kullanılan verilerin büyük bölümü gözlemseldir. Araştırmacı çoğu durumda kişilerin eğitimini, firmaların yatırımını, ülkelerin kurumlarını veya hanehalklarının tüketimini deneysel olarak atamaz; gerçekleşmiş seçimleri ve sonuçları gözlemler. Hansen’in vurguladığı gibi gözlemsel veride bütün değişkenleri potansiyel olarak birlikte belirlenen rassal değişkenler olarak ele almak güvenli başlangıç noktasıdır (Hansen, 2021).

Bir yatay kesit örnekleminde

$$(Y_i, X_i), \quad i = 1, \dots, n$$

gözlemlerimiz olsun. Standart rassal örneklem çerçevesinde gözlemlerin aynı ortak dağılımdan geldiğini ve birbirinden bağımsız olduğunu yazarız:

$$(Y_i, X_i) \stackrel{iid}{\sim} F_{Y,X}.$$

Buradaki bağımsızlık, Y_i ile X_i ’nin bağımsız olduğu anlamına gelmez. Tam tersine regresyonun amacı çoğu zaman Y ile X arasındaki sistematik bağımlılığı incelemektir. Bağımsızlık varsayımı farklı gözlem birimleri arasındadır: (Y_i, X_i) ile (Y_j, X_j) , $i \neq j$.

Sık yapılan hata

“Bağımsız değişken” terimi, açıklayıcı değişkenin hata teriminden veya başka değişkenlerden istatistiksel olarak bağımsız olduğunu garanti etmez. Bu notta mümkün olduğunca *açıklayıcı değişken*, *regresör* veya *kovaryat* ifadeleri kullanılacaktır.

1.2.1 Veri yapısı ile çıkarım arasındaki bağ

Bu derste birinci hafta yatay kesit mantığı üzerinde duracağız. Ancak temel ilke daha geneldir: gözlemler arasında bağımlılık varsa, tahmin edicinin belirsizliği bu bağımlılık yapısını dikkate almalıdır. Aynı firmanın tekrarlanan gözlemleri, aynı sınıftaki öğrenciler veya aynı bölgede yaşayan bireyler birbirinden tamamen bağımsız olmayabilir. Bu nedenle “hangi veri yapısına sahibiz?” sorusu yalnızca veri tanımı değil, aynı zamanda çıkarım sorusudur. Hansen’in rassal örneklem ve kümelenmiş örneklem ayrımı bu bağlantıyı açık biçimde kurar (Hansen, 2021).

Rassal örneklem varsayımı çoğu yatay kesit uygulamasında iyi bir başlangıç noktasıdır; fakat

veri toplama süreci bu varsayımla uyumlu değilse, standart hata formülünü mekanik biçimde kullanmak yanıltıcı olabilir. Örneğin öğrenciler sınıflar içinde, çalışanlar firmalar içinde veya haneler bölgeler içinde kümelenmişse aynı kümedeki gözlemler ortak şoklara maruz kalabilir. Katsayı tahmininin cebri değişmese bile bu ortak bileşen tahmin edicinin örnekleme varyansını değiştirir. Bu nedenle veri yapısı, “hangi komutu çalıştıracamızdan” önce gelen bir tasarım bilgisidir.

Benzer biçimde gözlem biriminin ne olduğu açıkça tanımlanmalıdır. Bir satır bir bireyi mi, firma-yıl gözlemini mi, ülkeyi mi yoksa bir işlemi mi temsil ediyor? Örneklem büyüklüğü n ancak bu birim tanımlandıktan sonra anlamlıdır. Çok büyük görünen bir veri seti, gerçekte az sayıda bağımsız bilgi kümesine dayanabilir. Bu ders panel ve zaman serisi modellerini ayrı derslerin konusu olarak bıraksa da, “bağımsız bilgi birimi” fikrini bütün uygulamalarda koruyacağız.

1.3 Dağılımdan Koşullu Beklentiye

Bir değişkenin yalnızca ortalamasını bilmek çoğu araştırma sorusu için yetersizdir. Ücret örneğinde

$$\mu_Y = E[Y]$$

tüm çalışanların ortalama log ücretini verir. Fakat araştırmacının asıl ilgisi eğitim, deneyim veya başka özelliklere göre ortalamanın nasıl değiştiği olabilir. Bu durumda koşullu beklentiye geçeriz.

Koşullu beklenti fonksiyonu (CEF)

Y sonuç değişkeni ve X açıklayıcı bilgi vektörü olsun. Koşullu beklenti fonksiyonu

$$m(x) = E[Y \mid X = x]$$

olarak tanımlanır. Rassal değişken gösteriminde $m(X) = E[Y \mid X]$ yazılır.

Örneğin X yalnızca eğitim yılı ise $m(12)$ lise mezunlarının, $m(16)$ dört yıllık üniversite mezunlarının ortalama sonucunu temsil edebilir. X vektör olduğunda

$$X = (\text{eğitim}, \text{deneyim}, \text{cinsiyet}, \dots)'$$

ve $m(x)$ bu özelliklerin belirli bir birleşimine sahip alt popülasyonun koşullu ortalamasını verir.


1.3.1 Koşullandırma ne yapar?

Koşullandırma, anakütleyi bilgiye göre alt gruplara ayırır. Bu nedenle koşullu ortalama, ham grup farklarından çok daha esnek bir nesnedir. Birden fazla değişkene koşullandığımızda

$$E[Y \mid X_1 = x_1, X_2 = x_2]$$

X_1 ile sonuç arasındaki ilişkiyi X_2 düzeyi belirliyen incelememize izin verir. Fakat bu ifade tek başına nedensel bir “diğer her şey sabit” deneyini kurmaz. Nedensel yorum için ayrıca tanımlama varsayımı gerekir; bu ayrımı bölümün ilerleyen kısmında kuracağız.

Şekil 1.2’de aynı eğitim düzeyinde farklı Y değerleri gözlenmesine rağmen koşullu ortalama düzgün bir ilişkiyi özetler. Regresyonun ilk görevi, bireysel sonuçların tamamını açıklamak değil, belirli bir hedef fonksiyon hakkında bilgi üretmektir.



Şekil 1.2: Bireysel heterojenlik ile koşullu ortalama fonksiyonunun ayrılması

1.4 Koşullu Beklenti Hatası ve Ortogonallık

Koşullu ortalamayı tanımladıktan sonra her gözlemi iki parçaya ayırabiliriz:

$$Y = m(X) + e, \quad (1.1)$$

burada

$$e = Y - m(X).$$

e , gerçekleşen sonuç ile koşullu ortalama arasındaki sapmadır. Bu hata terimi tanım gereği önemli bir özelliğe sahiptir.

1.4.1 Koşullu ortalamanın sıfır olması

$$E[e | X] = E[Y - m(X) | X] \quad (1.2)$$

$$= E[Y | X] - E[m(X) | X] \quad (1.3)$$

$$= m(X) - m(X) \quad (1.4)$$

$$= 0. \quad (1.5)$$

Bu sonuç bir tahmin varsayımı değil, e 'nin nasıl tanımlandığının sonucudur. Yinelenen beklentiler yasasıyla

$$E[e] = E\{E[e | X]\} = 0$$

elde edilir.

Daha güçlü bir sonuç, X 'in herhangi bir uygun fonksiyonu $h(X)$ için

$$E[h(X)e] = 0 \quad (1.6)$$

olmasıdır. Çünkü

$$E[h(X)e] = E\{E[h(X)e | X]\} = E\{h(X) E[e | X]\} = 0.$$

Koşullu ortalama hatasının temel özelliği

$Y = m(X) + e$ ayrışımında e yalnızca ortalaması sıfır bir hata değildir; X verildiğinde koşullu ortalaması sıfırdır. Bu nedenle e , X 'in her uygun fonksiyonuna ortogonaldır. Regresyon teorisindeki pek çok moment koşulu bu yapının doğrusal veya yaklaşık biçimlerinden doğar.

Sık yapılan hata

$E[e | X] = 0$ koşulu, e ile X 'in bağımsız olduğunu söylemez. Örneğin hata varyansı X 'e bağlı olabilir. Dolayısıyla koşullu ortalama sıfır iken heteroskedastisite bulunabilir. Bu ayrım ikinci konuda standart hata tahminine geçerken merkezi olacaktır.

Ortogonalite kavramını yalnızca bir cebir sonucu olarak değil, ekonometrik bilginin sınırı olarak okumak yararlıdır. $e = Y - m(X)$, X kullanılarak koşullu ortalama düzeyinde öngörülemez kısımdır. Bu, tek tek bireyler için e 'nin küçük olması gerektiği anlamına gelmez. Aksine, koşullu ortalama doğru kurulsun bile bireysel sonuçların etrafındaki saçılım büyük olabilir. Modelin görevi her gözlemi kusursuz açıklamak değil, seçilen koşullandırma bilgisinin taşıdığı sistematik ortalama yapıyı ayırmaktır.

Ayrıca $E[h(X)e] = 0$ sonucu, daha sonra göreceğimiz moment koşullarına doğrudan geçiş sağlar. Doğrusal regresyonda $h(X) = X$ seçimi normal denklemleri üretirken, araçsal değişkenlerde hata ile ortogonal olduğu düşünülen başka bir değişken Z moment koşulunda yer alacaktır. Bu bakımdan OLS ve IV birbirinden tamamen kopuk teknikler değildir; her ikisi de uygun ortogonalite koşulunu örneklemde kullanarak bilinmeyen parametreyi belirler.

1.5 Koşullu Ortalama Neden Özel Bir Tahmin Hedefidir?

Bir X bilgisi kullanarak Y 'yi öngörmek istediğimizi düşünelim. Herhangi bir öngörü kuralını $g(X)$ ile gösterelim. Gerçekleşen tahmin hatası

$$Y - g(X)$$

ve ortalama kareli tahmin hatası

$$E[(Y - g(X))^2]$$

olsun. Hansen'in temel sonucu, kareli hata kaybı altında en iyi öngörücünün koşullu beklenti olduğunu söyler (Hansen, 2021).

Bunu doğrudan görebiliriz. $Y = m(X) + e$ yazalım:

$$E[(Y - g(X))^2] = E[(e + m(X) - g(X))^2] \quad (1.7)$$

$$= E[e^2] + 2E[e\{m(X) - g(X)\}] \quad (1.8)$$

$$+ E[(m(X) - g(X))^2]. \quad (1.9)$$

Orta terim Denklem (1.6) nedeniyle sıfırdır. Dolayısıyla

$$E[(Y - g(X))^2] = E[e^2] + E[(m(X) - g(X))^2] \geq E[e^2]. \quad (1.10)$$

Eşitlik ancak $g(X) = m(X)$ olduğunda elde edilir.

Koşullu beklenti en iyi kareli-hata öngörücüsüdür

$$m(X) = E[Y | X]$$

X 'in bütün fonksiyonları arasından Y 'nin ortalama kareli tahmin hatasını en küçükleyen fonksiyondur. Bu sonuç doğrusal regresyon varsayımı gerektirmez.

Bu sonuç iki farklı araştırma amacını ayırmamıza yardım eder. Amaç öngörü ise koşullu ortalamayı mümkün olduğunca iyi yaklaşmak doğrudan anlamlıdır. Amaç nedensel etki ise iyi tahmin tek başına yeterli değildir; koşullu ortalamadaki değişimin bir müdahale etkisi olarak yorumlanabilmesi için ek varsayımlar gerekir.

1.6 Doğrusal Koşullu Ortalama ve En İyi Doğrusal Öngörücü

Koşullu ortalama $m(X)$ her zaman doğrusal değildir. Buna rağmen doğrusal modeller ekonometrinin merkezindedir. Burada iki ayrı durumu dikkatle ayırmalıyız.

1.6.1 Durum 1: Koşullu ortalama gerçekten doğrusaldır

Burada $Y, e \in \mathbb{R}$ skaler rassal değişkenler, $X \in \mathbb{R}^k$ rassal regresör sütun vektörü ve $\beta \in \mathbb{R}^k$ parametre sütun vektörüdür. İndissiz gösterim tek bir rassal gözlemi temsil eder; $X'\beta$ çarpımının boyutu $(1 \times k)(k \times 1) = 1 \times 1$ 'dir. Normal italik X , bu gösterimde bir vektördür.

Eğer

$$E[Y | X] = X'\beta, \quad (1.11)$$

ise

$$Y = X'\beta + e, \quad E[e | X] = 0.$$

Gözlem indisi açık yazıldığında aynı denklem $Y_i = X_i'\beta + e_i$, $i = 1, \dots, n$ olur; X_i yine $k \times 1$ vektördür. Bütün gözlemler yığıldığında ise $\mathbf{Y} = \mathbf{X}\beta + \mathbf{e}$ yazılır: $\mathbf{Y}, \mathbf{e} n \times 1$, $\mathbf{X} n \times k$ boyutundadır. Bu durumda β , koşullu ortalama fonksiyonunun parametresidir. Örneğin $X = (1, X_1)'$ ve

$$E[Y | X_1 = x] = \beta_0 + \beta_1 x$$

ise β_1 koşullu ortalamanın eğimidir.

Doğrusal CEF varsayımı güçlü fakat yorumu temizdir. X_j sürekliyse ve modelde yalnız doğrusal terim olarak yer alıyorsa (karesi ya da başka bir değişkenle etkileşimi yoksa) β_j , diğer X bileşenleri sabitken koşullu ortalamanın X_j yönündeki türevidir. Bu ifade bir anakütle fonksiyonunun özelliğidir; örneklem tahmini $\hat{\beta}_j$ bu bilinmeyen eğimi tahmin eder. Dolayısıyla tahmin ile hedef parametreyi birbirinden ayırmak yine önemlidir.

Doğrusallık ampirik olarak tam doğru olmak zorunda değildir; çoğu sosyal bilim uygulamasında yaklaşık model olarak kullanılır. Eğer eğrilik ekonomik olarak önemliyse karesel terim, etkileşim, spline veya nonparametrik yöntemlerle CEF esnetilebilir. Bu nedenle doğrusal CEF başlangıç modeli, alternatif fonksiyonel biçimlerin karşılaştırılacağı bir referans olarak görülmelidir.

1.6.2 Durum 2: Koşullu ortalama doğrusal değildir

Gerçek $m(X)$ bilinmiyor veya doğrusal değilse yine de bütün doğrusal fonksiyonlar arasındaki en iyi yaklaşımı arayabiliriz. Anakütlede

$$\beta = \arg \min_{b \in \mathbb{R}^k} E[(Y - X'b)^2] \quad (1.12)$$

tanımını kullanalım. Bu β , **doğrusal projeksiyon katsayısıdır**; $X'\beta$ ise Y 'nin X üzerindeki **en iyi doğrusal öngörüsüdür**.

Amaç fonksiyonunu açalım:

$$S(b) = E[(Y - X'b)^2] \quad (1.13)$$

$$= E[Y^2] - 2b'E[XY] + b'E[XX']b. \quad (1.14)$$

Birinci derece koşulu

$$\frac{\partial S(b)}{\partial b} = -2E[XY] + 2E[XX']b = 0$$

verir. Buradan normal denklemler

$$E[XX']\beta = E[XY] \quad (1.15)$$

ve $E[XX']$ terslenebilir ise

$$\boxed{\beta = (E[XX'])^{-1} E[XY]} \quad (1.16)$$

elde edilir.

Projeksiyon hatasını

$$e = Y - X'\beta$$

tanımladığımızda [Denklem \(1.15\)](#)

$$E[Xe] = 0 \quad (1.17)$$

ortogonalite koşuluna eşdeğerdir.


Sık yapılan hata

Doğrusal projeksiyonda $E[Xe] = 0$ elde edilir; fakat genel olarak $E[e | X] = 0$ elde edilmez. İki koşul aynı değildir. $E[e | X] = 0$, doğrusallık doğruysa koşullu ortalama modelinin özelliğidir. $E[Xe] = 0$ ise en iyi doğrusal yaklaşımın normal denklemidir.

Şekil 1.3, doğrusal modelin her zaman “doğru veri üretim süreci” olarak okunmaması gerektiğini gösterir. Doğrusal projeksiyon, doğrusal olmayan bir koşullu ortalamanın dağılım tarafından ağırlıklandırılan en iyi doğrusal özet olabilir.

Bu ayrım ampirik yorum bakımından kritiktir. Doğrusal projeksiyon katsayısı, gerçek $m(x)$ doğrusal olmadığında tek bir “yapısal eğim” olmak zorunda değildir. Katsayı, X dağılımındaki farklı bölgelerdeki yerel eğimleri belirli ağırlıklarla özetler. Dolayısıyla örneklemin X dağılımı değiştiğinde, aynı temel koşullu ortalama ilişkisi altında bile en iyi doğrusal özet değişebilir. Bu nedenle bir regresyon katsayısını başka bir ülkeye, döneme veya alt gruba taşıırken yalnızca katsayının istatistiksel anlamlılığına değil, kapsanan kovaryat dağılımına da dikkat etmek gerekir.

Örneğin ücret–deneyim ilişkisi genç çalışanlarda hızlı, ileri deneyim düzeylerinde daha yavaş



Şekil 1.3: Doğrusal projeksiyon, doğrusal olmayan koşullu ortalamayı yaklaşık olarak özetleyebilir

artıyorsa tek doğrusal eğim bu iki bölgeyi bir ortalama ile temsil eder. Böyle bir model betimleyici amaçla yararlı olabilir; fakat “bir yıl ek deneyim her çalışan için aynı miktarda ücret artışı yaratır” sonucu çıkmaz. Karesel terimler, spline’lar veya parametrik olmayan yöntemler sonraki bölümlerde bu kısıtı gevşetmenin farklı yollarını sağlayacaktır.

1.7 Basit Regresyon Katsayısının Anakütle Yorumu

Sabit terimli basit doğrusal projeksiyonu

$$Y = \alpha + \beta X + e, \quad E[e] = 0, \quad E[Xe] = 0$$

olarak yazalım. Beklenen değer aldığımızda

$$\alpha = E[Y] - \beta E[X]$$

elde edilir. Merkezi değişkenlerle

$$Y - E[Y] = \beta\{X - E[X]\} + e$$

yazabiliriz. Her iki tarafı $X - E[X]$ ile çarpıp beklenen değer aldığımızda

$$\text{cov}(X, Y) = \beta \text{var}(X) + E[(X - E[X])e] \quad (1.18)$$

$$= \beta \text{var}(X). \quad (1.19)$$

Dolayısıyla

$$\beta = \frac{\text{cov}(X, Y)}{\text{var}(X)}. \quad (1.20)$$

Bu formül, regresyon eğiminin kovaryansı X ’in varyansı ile ölçeklendiğini gösterir. Korelasyonla ilişkiyi görmek için

$$\text{cov}(X, Y) = \text{corr}(X, Y)\sigma_X\sigma_Y$$

yazarsak

$$\beta = \text{corr}(X, Y) \frac{\sigma_Y}{\sigma_X}.$$

Dolayısıyla korelasyon birimsiz bir ilişki ölçüsü iken regresyon eğimi Y birimi / X birimi taşır.

Eğim katsayısının betimleyici yorumu

$\beta = 0,08$ ve $Y = \log(\text{ücret})$, $X = \text{eğitim}$ ise doğrusal projeksiyon düzeyinde eğitim yılı bir birim daha yüksek gözlemler için tahmin edilen log ücret yaklaşık 0,08 daha yüksektir. Bu cümle koşullu/ilişkisel bir betimlemedir. “Bir kişiye bir yıl daha eğitim verirse ücreti yüzde 8 artar” biçimindeki nedensel cümle aynı katsayıdan otomatik olarak çıkmaz.

1.8 Örneklem Karşılığı: En Küçük Kareler (OLS)

Şimdi anakütledeki [Denklem \(1.12\)](#) probleminin örneklem karşılığını kuruyoruz. Elimizde n gözlem olsun. Anakütle karesel hata fonksiyonu

$$S(b) = E[(Y - X'b)^2]$$

gözlenemez; çünkü ortak dağılım bilinmemektedir. Bunun doğal örneklem karşılığı

$$\hat{S}(b) = \frac{1}{n} \sum_{i=1}^n (Y_i - X_i'b)^2 \quad (1.21)$$

olur. OLS tahmin edicisi

$$\hat{\beta} = \arg \min_b \hat{S}(b) = \arg \min_b \sum_{i=1}^n (Y_i - X_i'b)^2 \quad (1.22)$$

şeklinde tanımlanır. $1/n$ sabiti en küçükleyen b 'yi değiştirmede için iki ifade eşdeğerdir.

1.8.1 Matris biçiminde türetim

Örneklem tasarım matrisini $\mathbf{X}$ ve sonuç vektörünü $\mathbf{Y}$ ile gösterelim. Kareli artıklar toplamı

$$SSE(b) = (\mathbf{Y} - \mathbf{X}b)'(\mathbf{Y} - \mathbf{X}b)$$

şeklindedir. Açarsak

$$SSE(b) = \mathbf{Y}'\mathbf{Y} - 2b'\mathbf{X}'\mathbf{Y} + b'\mathbf{X}'\mathbf{X}b.$$

b 'ye göre türev

$$\frac{\partial SSE(b)}{\partial b} = -2\mathbf{X}'\mathbf{Y} + 2\mathbf{X}'\mathbf{X}b$$

ve birinci derece koşulu

$$\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y} \quad (1.23)$$

olur. $\mathbf{X}'\mathbf{X}$ terslenebilirse

$$\boxed{\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}} \quad (1.24)$$

elde edilir.

Bu formül, Denklem (1.16)'nın örneklem analogudur:

$$E[XX'] \longleftrightarrow \frac{1}{n} \mathbf{X}'\mathbf{X}, \quad E[XY] \longleftrightarrow \frac{1}{n} \mathbf{X}'\mathbf{Y}.$$

Anakütle ve örneklem paralelliği

Doğrusal projeksiyon katsayısı anakütlede karesel kaybı en küçükler. OLS tahmin edicisi aynı problemi örneklem ortalamalarıyla çözer. Bu nedenle OLS'yi yalnızca “noktalar arasından geçen en iyi doğru” olarak değil, belirli bir anakütle optimizasyon probleminin örneklem karşılığı olarak okumak daha geneldir.

1.8.2 Örneklem artıklarının ortogonalitesi

Tahmin edilen değer ve artık

$$\hat{Y}_i = X_i' \hat{\beta}, \quad \hat{e}_i = Y_i - \hat{Y}_i$$

olsun. Denklem (1.23)

$$\mathbf{X}'\hat{\mathbf{e}} = 0$$

şeklinde yazılabilir. Dolayısıyla her açıklayıcı değişken sütunu ile OLS artıkları arasındaki örneklem içi iç çarpım sıfırdır. Modelde sabit terim varsa açıklayıcı değişkenlerden biri 1 sütunudur ve

$$\sum_{i=1}^n \hat{e}_i = 0$$

elde edilir.

Sık yapılan hata

$\mathbf{X}'\hat{\mathbf{e}} = 0$ OLS'nin cebirsel bir özelliğidir ve kullanılan örneklemde her zaman sağlanır. Buna karşılık $E[Xe] = 0$ anakütle projeksiyon özelliğidir; $E[e | X] = 0$ ise doğrusal koşullu ortalama modelinin daha güçlü koşuludur. Bu üç ifadeyi birbirine karıştırmamak gerekir.

Anakütledeki $E[(Y - X'b)^2]$ kriterinin örneklem karşılığı, daha önce tanımladığımız $\hat{S}(b)$ kriteridir. OLS, gözlenen örneklemde bu kriteri en küçükleyen b değerini seçer. Buradaki amaç, her gözlemin hatasını sıfır yapmak değil, artık karelerinin toplamını bütün örneklem için en küçükleme. Gözlem sayısı regresör sayısından büyük olduğunda tek bir doğrusal model genel olarak bütün noktaların üzerinden geçemez; OLS en küçük toplam kareli sapmayı seçer.

Örneklem momentleri anakütle momentlerine yaklaştığında OLS tahmin edicisi doğrusal projeksiyon katsayısına yaklaşır. Bu bağlantı büyük sayılar yasasının ekonometrik rolünü gösterir: örneklemde hesaplanan $\mathbf{X}'\mathbf{X}/n$ ve $\mathbf{X}'\mathbf{Y}/n$ matrisleri uygun koşullarda $E[XX']$ ve $E[XY]$ momentlerine yakınsar.

1.9 Basit OLS Formülü ve Sezgisel

Sabit terimli basit regresyonda

$$Y_i = \alpha + \beta X_i + e_i$$

OLS eğimi


$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2} = \frac{\widehat{\text{cov}}(X, Y)}{\widehat{\text{var}}(X)} \quad (1.25)$$

ve sabit

$$\hat{\alpha} = \bar{Y} - \hat{\beta}\bar{X} \quad (1.26)$$

olarak elde edilir.

Bu eşitlik iki önemli sezgi sağlar. Birincisi, X hiç değişmiyorsa paydadaki varyans sıfırdır ve eğim belirlenemez. İkincisi, X ile Y aynı yönde birlikte hareket ettikçe kovaryans ve dolayısıyla eğim pozitifleşir.



Şekil 1.4: OLS, kareli artıklar toplamını en küçükleyen katsayıyı seçer

1.10 Çoklu Regresyonun Temel Yorumu

Birden fazla açıklayıcı değişken olduğunda

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_{k-1} X_{k-1} + e \quad (1.27)$$

yazarız. Burada k sabit terim dahil katsayı sayısıdır; $X = (1, X_1, \dots, X_{k-1})'$ ve $\beta = (\beta_0, \dots, \beta_{k-1})'$ olarak tanımlanır. Eğer bu denklem gerçekten doğrusal CEF ise

$$E[Y \mid X_1, \dots, X_{k-1}] = \beta_0 + \beta_1 X_1 + \cdots + \beta_{k-1} X_{k-1}.$$

Bu durumda β_j , diğer açıklayıcı değişkenlerin koşullandırma değerleri aynı tutulduğunda X_j 'deki bir birimlik değişimle koşullu ortalamadaki doğrusal değişimi verir (X_j modelde karesi ya da başka bir değişkenle etkileşimiyle yer almıyorsa).

Ancak iki farklı “sabit tutma” fikrini ayırmak gerekir:

1. **İstatistiksel koşullandırma:** Aynı X_{-j} değerlerine sahip gözlemlerin koşullu ortalamalarını karşılaştırmak.
2. **Nedensel müdahale:** Aynı birimin X_j değerini dışarıdan değiştirip diğer tüm yapısal faktörleri değiştirmemek.

Birinci ifade regresyon modelinin tanımıyla ilgilidir. İkinci ifade ek bir tanımlama argümanı gerektirir.

1.10.1 Doğrusal katsayı hangi ağırlıklı ilişkiyi yakalar?

Doğrusal CEF yanlış olsa bile çoklu regresyon katsayıları en iyi doğrusal projeksiyonun parçalarıdır. Bu nedenle bir katsayının anlamı, modeldeki diğer değişkenlerden bağımsız düşünülemez. X_j 'nin diğer kovaryatlarla ilişkili kısmı ayrıştırıldığında, β_j temelde Y ile X_j 'nin diğer X 'lerce açıklanamayan bileşeni arasındaki doğrusal ilişkiyi ölçer. Bu sonuç daha sonra Frisch–Waugh–Lovell mantığı ve eksik değişken yanlılığıyla ayrıştırılacaktır.

Çoklu regresyon katsayısının en güvenli başlangıç yorumu, diğer regresörlerin taşıdığı doğrusal bilgiyi ayırdıktan sonra kalan ilişki üzerindendir. Bu düşünce Bölüm 2'de Frisch–Waugh–Lovell teoremiyle açık hale gelecektir. Şimdilik şu sezgi yeterlidir: eğitim katsayısını eğitim ile ücret arasındaki ham fark olarak okumayız; yaş, deneyim veya başka kontroller modele girdiğinde katsayı, bu değişkenlerin doğrusal olarak açıkladığı ortak değişimi ayırdıktan sonra kalan eğitim değişiminin ücretle ilişkisini özetler.

Bu nokta “kontrol eklemek her zaman modeli iyileştirir” anlamına gelmez. Bir değişkenin modele alınması katsayının hangi karşılaştırmayı temsil ettiğini değiştirir. Araştırmacı kontrol setini yazılımın otomatik seçimine veya yalnızca R^2 artışına göre değil, araştırma sorusuna ve veri üretim sürecine göre belirlemelidir. Özellikle nedensel çalışmalarda tedaviden sonra belirlenen değişkenleri kontrol etmek yeni yanlılıklar oluşturabilir; bu konu Bölüm 3'te yeniden ele alınacaktır.

1.11 Regresyon, Korelasyon ve Nedensellik

Regresyon ile nedensellik arasındaki ayrım ekonometrik modellemenin en kritik noktalarından biridir. Gözlemsel veride

$$E[Y | X = x_1] - E[Y | X = x_0]$$

iki alt grubun koşullu ortalamaları arasındaki farktır. Nedensel etki ise aynı ekonomik birimin veya aynı tür birimlerin farklı müdahale durumlarındaki sonuç farkını hedefler.

Basit bir tedavi değişkeni $D \in \{0, 1\}$ için potansiyel sonuçları

$$Y_1, \quad Y_0$$

ile gösterelim. Bireysel nedensel etki

$$Y_1 - Y_0$$

ancak aynı birey için iki potansiyel sonucun ikisini birden gözlemleyemediğimiz için doğrudan gözlenmez. Anakütle ortalama nedensel etki


$$ACE = E[Y_1 - Y_0]$$

olarak tanımlanabilir.

Buna karşılık basit grup farkı

$$E[Y | D = 1] - E[Y | D = 0]$$

ancak tedavi ataması ile potansiyel sonuçları belirleyen gözlenemeyen faktörler arasında uygun bağımsızlık/tanımlama koşulları varsa *ACE* ile eşleşir. Hansen, rassal atama veya koşullu bağımsızlık gibi koşullar altında regresyonun nedensel anlam kazanabileceğini, aksi hâlde gözlenen farkın seçim mekanizmasını da taşıyabileceğini gösterir (Hansen, 2021).



Şekil 1.5: Gözlemsel regresyonda nedensel yorumun neden ek varsayıma ihtiyaç duyduğu

Sık yapılan hata

“Diğer açıklayıcı değişkenler kontrol edildi” cümlesi tek başına nedenselliği kanıtlamaz. Kontrol değişkenlerinin hangi seçim mekanizmasını kapattığı ve hangi değişkenlerin gözlenemediği araştırma tasarımı içinde gerekçelendirilmelidir.

1.12 Regresyonun Üç Ayrı Kullanım Amacı

Aynı regresyon denklemi farklı amaçlarla kullanılabilir. Bu nedenle bir modelin “iyi” olup olmadığı tek bir ölçüte indirgenemez.

Tablo 1.1: Regresyonun üç temel kullanım amacı

Amaç	Temel soru	Öncelikli değerlendirme
Betimleme / ilişki	Y 'nin koşullu ortalaması X ile nasıl değişiyor?	Katsayının anlamı, fonksiyonel biçim, örneklem kapsamı
Öngörü	Yeni bir gözlem için Y ne kadar iyi tahmin edilebilir?	Örneklem dışı hata, genelleme, aşırı uyum
Nedensel çıkarım	X 'e müdahale edildiğinde Y ne kadar değişir?	Tanımlama, içsellik, karşı-olgusal mantık

Bir değişken güçlü öngörücü olabilir ama nedensel olmayabilir. Örneğin kredi temerrüdünü iyi öngören bir davranış göstergesi, doğrudan politika müdahalesi olarak değiştirildiğinde temerrüdü aynı ölçüde değiştirmeyebilir. Tersine, nedensel olarak önemli bir müdahalenin toplam tahmin varyansına katkısı sınırlı olabilir.

1.13 Ampirik Uygulama Laboratuvarı: CPS Ücret–Eğitim İlişkisi

Bu bölümde şimdiye kadar kurduğumuz koşullu beklenti, doğrusal projeksiyon ve OLS kavramlarını gerçek bir veri seti üzerinde birlikte kullanacağız. Amaç yalnızca bir regresyon çalıştırmak değildir. Uygulama üç beceriyi aynı anda geliştirecek biçimde tasarlanmıştır:

1. bir ampirik makaledeki veri ve regresyon tablosunun nasıl okunacağını görmek,
2. yazılım çıktısındaki sayıların hangi ekonometrik nesnelere karşılık geldiğini ayırt etmek,
3. benzer bir analizin tez çalışmasında hangi sırayla kurulacağını öğrenmek.

Uygulamada Hansen'in ders kitabıyla birlikte sağlanan `cps09mar` veri tabanını kullanıyoruz. Veri, Mart 2009 Current Population Survey'den (CPS) elde edilmiştir. Hansen'in veri açıklamasında tam zamanlı çalışan örnekleme, haftada en az 36 saat ve yılda en az 48 hafta çalışan, askerî mesleklerde bulunmayan ve kullanılan temel değişkenleri tahsis edilmiş (allocated) gözlemlerden oluşan bireyler olarak tanımlanır. Bu seçim sonunda 50.742 gözlem kalmaktadır (Hansen, 2021). Bu örneklem Hansen'in ücret dağılımı, koşullu ortalama ve regresyon örneklerinde sık kullandığı veri tabanıdır.

1.13.1 Adım 1: Araştırma sorusunu ve tahmin hedefini yazmak

Uygulamayı şu araştırma sorusuyla başlatalım:

Tam zamanlı çalışanların eğitim düzeyi yükseldikçe saatlik ücretlerinin koşullu ortalaması nasıl değişmektedir?

Saatlik ücreti

$$wage_i = \frac{earnings_i}{hours_i \times weeks_i}$$

olarak tanımlayalım ve sağa çarpık ücret dağılımı nedeniyle sonuç değişkenini

$$Y_i = \log(wage_i)$$

seçelim. Eğitim değişkeni tamamlanan eğitim yılını temsil etsin. İlk tahmin hedefimiz

$$m(x) = E[\log(wage_i) \mid education_i = x] \quad (1.28)$$

koşullu beklenti fonksiyonudur.

Buradaki ilk önemli ders şudur: *araştırma sorusu doğrudan “eğitim katsayısı kaçtır?” değildir.* Önce hangi anakütle nesnesini öğrenmeye çalıştığımızı belirtiriz. Regresyon katsayısı, bu nesneye belirli bir fonksiyonel biçim altında yaklaşmanın bir yoludur.

Makale okurken ilk sorulacak üç soru

Bir regresyon tablosuna geçmeden önce şu üç bilgiyi bulun:

1. Bağımlı değişken tam olarak nedir ve hangi birimde ölçülmektedir?
2. Temel açıklayıcı değişken nedir ve hangi karşılaştırmayı temsil etmektedir?
3. Yazarın hedefi ilişkiyi betimlemek mi, öngörü yapmak mı, yoksa nedensel bir etkiyi tanımlamak mıdır?

Bu üç soru cevaplanmadan katsayıyı yorumlamak erken olur.

1.13.2 Adım 2: Ham veriden analiz örnekleme

Hansen veri paketindeki ham CPS dosyası 207.921 gözlem içerir. Kitabın veri hazırlama betiği, önce tahsis edilmiş değişkenleri tanımlar; eğitim kategorilerini okul yılına dönüştürür; potansiyel deneyimi

$$experience_i = age_i - education_i - 6$$

olarak oluşturur ve negatif değerleri sıfıra çeker. Saatlik ücret yalnızca pozitif yıllık ücret geliri olanlar için hesaplanır. Daha sonra tam zamanlı çalışan, askerî olmayan ve tahsis edilmemiş örneklem seçilir.

Bu veri hazırlama zincirini açıkça belgelemek önemlidir. Bir tezde yalnızca “CPS verisi kullanılmıştır” demek yeterli değildir. Hangi gözlemlerin analiz örnekleme girdiği ve türetilmiş değişkenlerin nasıl oluşturulduğu yeniden üretilebilir biçimde yazılmalıdır.

Kod 1.1: Hansen CPS verisinden analiz örneklemini üretmenin temel adımları (özet; çalıştırılabilir tam betik: `scripts/generate_konu01_application.py`)

```
# Ham dosya Hansen veri paketindeki cps09mar.asc'dir.
data = pd.read_csv("cps09mar.asc", sep=r"\s+")

# Saatlik ucret ve potansiyel deneyim
hrwage = earnings / (hours * weeks)
experience = np.maximum(age - education - 6, 0)

# Hansen'in tam zamanli calisan orneklemi
sample = data.loc[
    (hours > 35) &
    (weeks >= 48) &
    (hrwage > 0) &
    (job < 9800) &
    (allocated == 0)
].copy()

sample["lwage"] = np.log(sample["hrwage"])
assert len(sample) == 50742
```

Son satırdaki kontrol yalnız programlama ayrıntısı değildir. Veri açıklamasında beklenen gözlem sayısı ile koddan elde edilen gözlem sayısının aynı olması, veri hazırlama sürecinde erken bir doğrulama noktasıdır.

1.13.3 Adım 3: Regresyondan önce veriyi tanımak

Regresyon çalıştırmadan önce örneklemin temel özelliklerini inceleyelim. [Tablo 1.2](#), analizde kullanacağımız temel değişkenlerin betimsel istatistiklerini göstermektedir.

Bu tablo tek başına birkaç önemli noktayı gösterir. Ortalama saatlik ücret yaklaşık \$23,90 iken medyan yaklaşık \$19,23'tür. Ortalama medyandan belirgin biçimde yüksektir; bu durum ücret dağılımının sağ kuyruğunda yüksek ücretli gözlemlerin bulunduğu işaret eder. Log ücretin kullanılması, bu tür sağa çarpıklığı azaltan ve oransal farkların yorumunu kolaylaştıran bir dönüşümdür.

Kadın göstergesinin ortalaması 0,4257 olduğuna göre örneklemin yaklaşık yüzde 42,57'si kadındır. Bir kukla değişkenin ortalamasının ilgili grubun örneklem payına eşit olduğu burada

Tablo 1.2: CPS tam zamanlı çalışan örnekleme: seçilmiş betimsel istatistikler

Değişken	Ortalama	Std. sapma	Medyan	En küçük	En büyük
Saatlik ücret	23,9027	20,7111	19,2308	0,0004	266,0557
Log saatlik ücret	2,9462	0,6759	2,9565	-7,8633	5,5837
Eğitim yılı	13,9246	2,7444	13	0	20
Potansiyel deneyim	22,2082	11,6645	22	0	75
Kadın göstergesi	0,4257	0,4945	0	0	1
Yaş	42,1317	11,4876	42	15	85

Not: $N = 50.742$. Saatlik ücret, yıllık ücret ve maaş gelirinin haftalık çalışma saati ile yıllık çalışma haftası çarpımına bölünmesiyle elde edilmiştir. Kaynak: Hansen `cps09mar` veri paketi; hesaplamalar bu ders notu için yeniden üretilmiştir.

doğrudan görülmektedir.

1.13.4 Adım 4: Koşullu ortalamaları önce grafik ve tabloyla görmek

Hansen'in koşullu beklenti tartışmasının temel avantajlarından biri, regresyonu çalıştırmadan önce veri içindeki grup örüntülerini görünür kılmasıdır. Örneğin erkekler ve kadınlar için ortalama log ücretler sırasıyla

$$\overline{\log(wage)}_{men} = 3,0459, \quad \overline{\log(wage)}_{women} = 2,8116$$

olarak bulunur. Bu değerler Hansen'in kitapta raporladığı yaklaşık 3,05 ve 2,81 değerlerini yeniden üretmektedir (Hansen, 2021).

Eğitim düzeyine göre koşullu ortalamaları daha ayrıntılı inceleyelim.


Tablo 1.3: Eğitim düzeyine göre örneklem koşullu ortalamaları

Eğitim yılı	N	Ortalama log ücret	Ortalama ücret	Medyan ücret
0	73	2,2782	10,8505	9,8000
4	256	2,3124	11,3116	9,7556
6	602	2,3153	11,2951	10,0000
8	424	2,4008	12,8193	11,0577
9	575	2,3522	12,2011	10,8974
10	565	2,4405	13,7815	12,0192
11	1304	2,4722	14,0420	12,0192
12	13896	2,7121	17,6127	15,3846
13	9254	2,8392	20,1711	17,0940
14	5608	2,9316	21,4943	19,2308
16	11640	3,2011	30,1216	24,0385
18	4670	3,3813	35,1626	28,8462
20	1875	3,6890	51,7647	40,0641

Not: Tablo, her eğitim kategorisi içindeki örneklem ortalamalarını göstermektedir. Bu sayılar nedensel eğitim etkileri değildir.

Şekil 1.6, eğitim arttıkça ortalama log ücretin genel olarak yükseldiğini, ancak ilişkinin tam olarak doğrusal olmadığını ve erkek-kadın farkının eğitim düzeyleri boyunca da gözlemlendiğini

göstermektedir.



Şekil 1.6: Eğitim düzeyine ve cinsiyete göre ortalama log saatlik ücret

Burada iki tür heterojenlik görünmektedir. Birincisi, eğitim düzeyi arttıkça koşullu ortalama yükselir. İkincisi, aynı eğitim kategorisinde erkek ve kadın çalışanların ortalama log ücretleri farklıdır. Bu grafik bize hangi kontrol değişkenlerinin “doğru” olduğunu söylemez; fakat tek değişkenli ücret–eğitim ilişkisinin daha zengin bir ortak dağılımın yalnızca bir özeti olduğunu gösterir.

Grafiği bir makalede nasıl okuruz?

Bir grafik gördüğünüzde yalnız eğimin yönüne bakmayın. Şunları sorun:

1. x eksenindeki hangi bölgelerde çok veya az gözlem vardır?
2. ilişki yaklaşık doğrusal mı, yoksa belirgin eşikler/eğrilikler var mı?
3. alt gruplar aynı örüntüyü mü gösteriyor?
4. grafik ham ilişkiyi mi, yoksa kontroller sonrası tahmin edilmiş ilişkiyi mi gösteriyor?

Örneğin Şekil 1.6 ham koşullu ortalamaları gösterir; yaş veya deneyim bakımından eşleştirilmiş bir karşılaştırma değildir.

1.13.5 Adım 5: Koşullu ortalamadan doğrusal projeksiyona


Şimdi yalnızca eğitimi kullanan basit doğrusal projeksiyonu tahmin edelim:

$$\log(wage_i) = \beta_0 + \beta_1 education_i + e_i. \quad (1.29)$$

Tahmin edilen denklem

$$\log(\widehat{wage}_i) = 1,4396 + 0,1082 education_i \quad (1.30)$$

olmaktadır. Şekil 1.7, eğitim kategorilerindeki örneklem koşullu ortalamalarını ve bu noktalara karşılık gelen doğrusal projeksiyonu birlikte göstermektedir. Nokta büyüklükleri ilgili eğitim kategorisinin örneklem büyüklüğüyle orantılıdır.



Şekil 1.7: Eğitim düzeyine göre koşullu ortalama ve OLS doğrusal projeksiyonu

Grafik, OLS doğrusunun bütün eğitim kategorilerindeki koşullu ortalamalardan geçmek zorunda olmadığını açıkça gösterir. Özellikle çok düşük eğitim kategorilerinde koşullu ortalamalar doğrunun üzerindedir. Buna karşılık 12–18 yıl aralığında doğrusal yaklaşım örüntüyü daha yakından izlemektedir. OLS'nin yaptığı şey her kategoriye ayrı ayrı kusursuz tahmin etmek değil, bütün gözlemler üzerinde kareli hatayı en küçükleyen doğrusal özeti seçmektir.

Sık yapılan hata

Koşullu ortalama noktalarının doğrusal olmaması, OLS hesabının “yanlış” olduğu anlamına gelmez. Fakat OLS katsayısının gerçek CEF'nin sabit eğimi olarak yorumlanmasını zayıflatır. Böyle bir durumda katsayı en iyi doğrusal projeksiyonun eğimidir. Fonksiyonel biçim seçimi ilerleyen konularda yeniden ele alınacaktır.

1.13.6 Adım 6: Bir makaledeki çok sütunlu regresyon tablosunu okumak

Ampirik makalelerde tek bir regresyon yerine aynı araştırma sorusunun farklı spesifikasyonları genellikle yan yana verilir. Bu uygulamada üç modeli karşılaştıralım:

$$\text{Model 1:} \quad \log(wage_i) = \beta_0 + \beta_1 education_i + e_i. \quad (1.31)$$

$$\begin{aligned} \text{Model 2: } \log(wage_i) &= \beta_0 + \beta_1 education_i + \beta_2 experience_i \\ &+ \beta_3 \frac{experience_i^2}{100} + e_i. \end{aligned} \quad (1.32)$$

$$\begin{aligned} \text{Model 3: } \log(wage_i) &= \beta_0 + \beta_1 education_i + \beta_2 experience_i \\ &+ \beta_3 \frac{experience_i^2}{100} + \delta female_i + e_i. \end{aligned} \quad (1.33)$$

Bu modelleri “birincisi yanlış, üçüncüsü doğru” biçiminde sıralamak doğru değildir. Her sütun farklı bir doğrusal projeksiyonu ve dolayısıyla farklı bir koşullandırma kümesini temsil eder. Sütunlar arasındaki değişim, katsayının hangi karşılaştırmayı özetlediğinin nasıl değiştiğini anlamamıza yardım eder.

Tablo 1.4: Log saatlik ücret için OLS regresyonları: makale-formatlı çıktı

	(1)	(2)	(3)
	Eğitim	+ Deneyim profili	+ Kadın göstergesi
Eğitim	0,1082*** (0,0010)	0,1126*** (0,0010)	0,1148*** (0,0010)
Deneyim		0,0363*** (0,0008)	0,0356*** (0,0008)
Deneyim ² /100		-0,0578*** (0,0017)	-0,0563*** (0,0016)
Kadın			-0,2596*** (0,0052)
Sabit	1,4396*** (0,0139)	0,9368*** (0,0165)	1,0211*** (0,0162)
<i>N</i>	50.742	50.742	50.742
<i>R</i> ²	0,1930	0,2368	0,2728

Not: Bağımlı değişken log saatlik ücrettir. Parantez içinde klasik OLS standart hataları verilmiştir. *** $p < 0,01$. Bu bölümde standart hata ve yıldızlar yalnız tablo okuma pratiği için gösterilmektedir; güvenilir çıkarım ve heteroskedastisiteye dayanıklı standart hatalar Bölüm 2’de ele alınacaktır. Kaynak: Hansen cps09mar verisi; hesaplamalar bu ders notu için yapılmıştır.

Sık yapılan hata

Bu tablo Hansen’in kendi ücret regresyonu tablosunun (Bölüm 4.21) bir replikasyonu *değildir*. Hansen orada en az 12 yıl eğitimi olanlarla sınırlı $n = 46.943$ örneklemini kullanır ve modele evlilik durumu, sendika üyeliği ve ırk göstergeleri de ekler; bu nedenle özellikle kadın göstergesinin katsayısı çok daha küçüktür. Burada amaç aynı sayıyı üretmek değil, aynı veriyle daha basit bir spesifikasyon zincirini adım adım okumaktır. Bir tezde başka bir çalışmanın sonucuna atıf yapılırken örneklem tanımı ve kontrol setinin aynı olup olmadığı mutlaka kontrol edilmelidir.


Tabloyu satır satır değil, sütun mantığıyla okumak

Bir makale tablosunda önce sütunların neyi değiştirdiğini belirleyin. Tablo 1.4’te:

- sütun (1) yalnız eğitim ile log ücret arasındaki doğrusal ilişkiyi özetler;

- sütun (2), çalışanların potansiyel deneyim profili aynı koşullandırma setine eklendiğinde eğitim katsayısının nasıl değiştiğini gösterir;
- sütun (3), buna ayrıca kadın göstergesini ekler.

Eğitim katsayısı 0,1082’den 0,1148’e yükselmektedir. Bu değişimi otomatik olarak “kontroller yanlılığı düzeltti” biçiminde yorumlamamalıyız. Kontroller eklendiğinde tahmin edilen doğrusal projeksiyon değişir. Katsayının nedensel eğitim getirisine yaklaşıp yaklaşmadığını söylemek için hangi değişkenlerin karıştırıcılık (confounding) mekanizmasını kapattığını ayrıca gerekçelendirmek gerekir.



Şekil 1.8: Farklı spesifikasyonlarda eğitim katsayısı ve yüzde 95 güven aralıkları

Katsayıyı ekonomik büyüklüğe çevirmek

Model (3)’te eğitim katsayısı 0,1148’dir. Log-düzey modelinde küçük katsayılar yaklaşık yüzde fark olarak okunabilir. Yaklaşık yorum: eğitim yılı bir birim daha yüksek gözlemlerde koşullu ortalama log ücret 0,1148 daha yüksektir; bu, ücretin (koşullu geometrik ortalamasının) yaklaşık yüzde 11,48 daha yüksek olmasına karşılık gelir. Daha kesin dönüşüm (yuvarlanmamış $\hat{\beta}_1$ ile)

$$100\{\exp(\hat{\beta}_1) - 1\} \approx 12,16$$

yüzdedir.

Bu cümlede kullanılan “eğitim yılı bir birim daha yüksek gözlemler” ifadesine dikkat edin. Model henüz eğitimde dışsal bir müdahaleyi tanımlamadığı için “bir kişiye bir yıl daha eğitim verirse ücreti yüzde 12,16 artar” demiyoruz.

Model (3)’te kadın katsayısı $-0,2596$ ’dır. Eğitim ve deneyim profili sabit tutulduğunda kadın çalışanların koşullu log ücretinin erkek çalışanlara göre daha düşük olduğunu gösteren bir projeksiyon katsayısıdır. Ücret (koşullu geometrik ortalaması) için kesin dönüşüm (yuvarlanmamış $\hat{\delta}$ ile; tablodaki $-0,2596$ ile $-22,86$ çıkar)

$$100\{\exp(\hat{\delta}) - 1\} \approx -22,87$$

yüzdedir. Bu sonuç da tek başına ayrımcılığın nedensel ölçüsü olarak yorumlanamaz; gözlenen ve gözlenmeyen ücret belirleyicileri konusunda ek bir araştırma tasarımı gerekir.

R^2 ne söylüyor, ne söylemiyor?

R^2 , sütun (1)'de 0,1930, sütun (3)'te 0,2728'dir. Deneyim profili ve cinsiyet göstergesi eklendiğinde örneklem içi açıklanan varyans payı yükselmektedir. Ancak daha yüksek R^2 şu üç iddiadan hiçbirini tek başına kanıtlamaz:

1. modelin fonksiyonel biçimi doğrudur,
2. eğitim katsayısı nedenseldir,
3. model yeni örneklemelerde daha iyi öngörü yapacaktır.

İlk iddia spesifikasyon ve tanılamayla, ikinci iddia tanımlamayla, üçüncü iddia ise örneklem dışı performansla ilgilidir. R^2 'nin tanımı, varyans ayrıştırması ve düzeltilmiş ile dışarıda-bırak sürümleri Bölüm 2.1.2'de ele alınmaktadır.

Bir makale tablosunu okuma sırası

Çok sütunlu bir regresyon tablosunda şu sırayı kullanın:

1. bağımlı değişken ve birimi,
2. örneklem ve N ,
3. her sütunda hangi kontrol/tanım/spesifikasyon değişiyor,
4. ilgi katsayısının işareti ve ekonomik büyüklüğü,
5. standart hata veya güven aralığı,
6. katsayının sütunlar arasında kararlı olup olmadığı,
7. uyum ölçüleri,
8. en son olarak yazarın yaptığı nedensel yorumun tanımlama stratejisiyle desteklenip desteklenmediği.

Yıldızlara ilk satırda bakmak genellikle yanlış okuma sırasıdır.

1.13.7 Adım 7: Yazılım çıktısından makale tablosuna geçmek

Aynı Model (3), `statsmodels` tarafından aşağıdaki gibi bir çıktı parçasıyla raporlanabilir:

Yazılım çıktısı: Model (3) için temel bölüm

Dependent variable: log hourly wage (lwage)
No. observations: 50742
R-squared: 0.273

variable	coef	std err	t	P> t	[0.025	0.975]
const	1.0211	0.0162	63.20	0.000	0.9894	1.0527
education	0.1148	0.0010	120.45	0.000	0.1129	0.1167
experience	0.0356	0.0008	45.15	0.000	0.0341	0.0372
experience2_100	-0.0563	0.0016	-34.47	0.000	-0.0595	-0.0531
female	-0.2596	0.0052	-50.11	0.000	-0.2698	-0.2495

Makale tablosu ile yazılım çıktısı farklı nesneler değildir. Makale tablosu, yazılım çıktısının araştırma sorusu açısından önemli kısımlarının daha okunabilir biçimde düzenlenmiş halidir. Örneğin `education` satırında:

- `coef` tahmin edilen katsayıyı $\hat{\beta}_1$,
- `std err` katsayı tahmininin standart hatasını,
- `t` katsayı / standart hata oranını,
- `P>|t|` ilgili testin p -değerini,
- son iki sütun yüzde 95 güven aralığını

gösterir. Çıkarımın hangi varsayımlara bağlı olduğu Bölüm 2’de ayrıntılandırılacaktır. Şimdilik önemli olan, katsayı ile standart hatanın farklı kavramlar olduğunu ve makale tablosunda parantez içindeki sayının çoğu zaman standart hata olduğunu tanımaktır.

1.13.8 Adım 8: Sonuçları ampirik metne dönüştürmek

Regresyon tablosunun amacı sayıları tekrar etmek değil, araştırma sorusuna kontrollü bir cevap vermektir. Bu uygulamadaki bulgular şu şekilde raporlanabilir:

Örnek ampirik raporlama

Mart 2009 CPS tam zamanlı çalışan örnekleminde eğitim ile log saatlik ücret arasında pozitif bir ilişki bulunmaktadır. Yalnız eğitim değişkenini içeren spesifikasyonda eğitim katsayısı 0,1082’dir. Potansiyel deneyim ve deneyimin karesi eklendiğinde katsayı 0,1126’ya, kadın göstergesi de kontrol edildiğinde 0,1148’e yükselmektedir. Son spesifikasyonda bu katsayı, deneyim profili ve cinsiyet sabitken eğitim yılı bir birim daha yüksek gözlemlerin koşullu ortalama log ücretinin 0,1148 daha yüksek, yani saatlik ücretinin yaklaşık yüzde 11,5 daha yüksek olduğunu göstermektedir. Bu ilişki, eğitim kararının içselliğini ele alan bir tanımlama stratejisi kurulmadığı için nedensel eğitim getirisi olarak yorumlanmamalıdır.

Bu paragrafta dört iyi uygulama vardır. Veri ve örneklem belirtilmiştir; katsayıların hangi spesifikasyonlarda değiştiği raporlanmıştır; büyüklük ekonomik birime çevrilmiştir; nedensel yorum konusunda modelin izin verdiği sınır korunmuştur.

1.13.9 Adım 9: Aynı analizi kendiniz nasıl kurarsınız?

Bir tezde benzer bir regresyon uygulaması yaparken aşağıdaki sıra pratik bir başlangıç protokölüdür:

1. **Araştırma sorusunu yazın.** Katsayı değil ekonomik ilişki veya etki ile başlayın.
2. **Tahmin hedefini belirleyin.** Ortalama ilişki mi, olasılık mı, kantil mi, nedensel etki mi?
3. **Ham veriyi koruyun.** Temizleme adımlarını kodla üretin.
4. **Analiz örneklemini açıklayın.** Dışlanan gözlemler, eksik değerler ve filtreler raporlanmalıdır.

5. **Değişkenleri belgeleyin.** Birimler, log dönüşümleri, kuklalar ve türetilmiş değişkenler açık olmalıdır.
6. **Önce betimleyin.** Tablo ve grafiklerle veri desteğini görün.
7. **Basitten geniş modele ilerleyin.** Sütunlar arasında hangi bilginin eklendiğini bilinçli biçimde değiştirin.
8. **Katsayıyı ekonomik büyüklüğe çevirin.** Yalnız işaret ve yıldız raporlamayın.
9. **Tanımlama dilini koruyun.** Gözlemsel ilişkiyi nedensel etki gibi yazmayın.
10. **Çıktıyı koddan üretin.** Tablo ve şekilleri elle kopyalamak yerine yeniden üretilebilir betiklerden oluşturun.

Kod 1.2: Konu 1 uygulamasının yeniden üretilebilir analiz iskeleti

```
import numpy as np
import pandas as pd
import statsmodels.api as sm

# Ders notuyla birlikte verilen temizlenmiş CPS dosyası
df = pd.read_csv("data/cps09mar_ikt807.csv")

# 1) Kosullu ortalamalar
cef = (
    df.groupby("education", as_index=False)
        .agg(n=("lwage", "size"), mean_lwage=("lwage", "mean"))
)

# 2) Uc ic ice spesifikasyon
specs = {
    "m1": ["education"],
    "m2": ["education", "experience", "experience2_100"],
    "m3": ["education", "experience", "experience2_100", "female"],
}

models = {}
for name, cols in specs.items():
    X = sm.add_constant(df[cols])
    models[name] = sm.OLS(df["lwage"], X).fit()

print(models["m3"].summary())
```

Ham Hansen CPS dosyasından başlayan tam yeniden üretim betiği ve analizde kullanılan temizlenmiş veri dosyası ders notuyla birlikte verilmektedir.

Uygulamanın ana dersi

Bir ampirik regresyon uygulamasında hedef yalnız `fit()` komutunun çalışması değildir. İyi analiz; araştırma sorusu, tahmin hedefi, veri oluşturma süreci, betimsel kanıt, spesifikasyonların mantığı, katsayıların ekonomik yorumu, belirsizlik ve tanımlama sınırlarının birlikte raporlanmasıdır. Makaledeki regresyon tablosu bu zincirin yalnızca görünür son halkasıdır.

1.13.10 Logaritmik sonuç değişkenine kısa not

$Y = \log(wage)$ kullanıldığında doğrusal modeldeki küçük bir β katsayısı yaklaşık yüzde değişim olarak okunabilir. Örneğin

$$\Delta \log(wage) \approx 0,05$$

yaklaşık yüzde 5 farkı temsil eder. Daha kesin dönüşüm

$$100\{\exp(\beta) - 1\}$$

şeklinde. Fonksiyonel biçimlerin sistematik yorumu ikinci konuda ayrıntılandırılacaktır.

Logaritma kullanımı yalnızca “yüzde yorum” kolaylığı için değildir. Pozitif ve sağa çarpık ekonomik değişkenlerde log dönüşümü büyük gözlemlerin etkisini azaltabilir, ilişkiyi daha yaklaşık doğrusal hale getirebilir ve mutlak fark yerine oransal farkların ekonomik olarak daha anlamlı olduğu durumları temsil edebilir. Ücret, satış, firma büyüklüğü ve fiyat gibi değişkenlerde bu nedenle yaygındır.


Bununla birlikte $\log(Y)$ modeli ile Y modeli farklı tahmin hedeflerine sahiptir. $E[\log(Y) | X]$ 'i modellemek, genel olarak $\log\{E[Y | X]\}$ 'i modellemekle aynı değildir. Log katsayılarının düzeydeki aritmetik ortalama etkisi olarak yorumlanması ek varsayımlar gerektirir. İkinci bölümde log-düzye ve log-log modellerini daha sistematik biçimde ayracağız.

1.14 Yeniden Üretilbilir Ampirik Çalışma

Ekonometrik sonuç yalnızca raporlanan katsayı tablosundan ibaret değildir. Hansen, ampirik araştırmanın veri, veri işlemleri ve kodla birlikte yeniden üretilebilir olması gerektiğini özellikle vurgular (Hansen, 2021). Bu dersin uygulamalarında da aynı ilkeyi kullanacağız.

Minimum bir proje yapısı aşağıdaki gibi düşünülebilir:

```
project/
  data_raw/      # ham veri; degistirilmez
  data_clean/    # kodla uretilen analiz verisi
  src/           # veri temizleme ve tahmin kodlari
  outputs/       # tablolar, grafikler, model ciktilari
  README.md      # calistirma sirasi ve veri aciklamasi
```



Her çıktı, hangi veri ve hangi kod adımıyla üretildiği izlenebilecek biçimde yeniden oluşturulabilmelidir.

Şekil 1.9: Yeniden üretilebilir ampirik çalışma zinciri

Bu yaklaşım özellikle tez çalışmalarında üç avantaj sağlar. Birincisi, model değişikliklerinin hangi sonuçları etkilediği izlenebilir. İkincisi, veri temizleme sırasında yapılan dönüşümler unutulmaz. Üçüncüsü, danışman veya ortak yazar aynı sonucu yeniden üretebilir.

Yeniden üretilebilirlik yalnızca nihai kod dosyasını paylaşmak değildir. Veri setinin ham kaynaktan analize hazır hale gelmesine kadar hangi dönüşümlerin yapıldığı, eksik değerlerin nasıl

ele alındığı, hangi gözlemlerin dışlandığı, hangi değişkenlerin yeniden kodlandığı ve tablo/şekillerin hangi betiklerden üretildiği izlenebilir olmalıdır. İyi bir proje yapısında ham veri değişmeden saklanır; temizlenmiş veri kod tarafından üretilir ve nihai sonuçlar elle kopyalanmak yerine koddan türetilir.

Bu disiplin aynı zamanda ekonometrik hataları azaltır. Bir katsayının farklı bir dosyada elle yeniden hesaplanması, tabloya yanlış standart hata taşınması veya son anda değiştirilen örneklem filtresinin bazı şekillere yansımaması sık karşılaşılan sorunlardır. Tekrarlanabilir bir işlem zinciri, sonuçları yalnız başkaları için değil araştırmacının kendisi için de denetlenebilir hale getirir. Hansen'in replikasyon vurgusu bu nedenle yöntemsel bir ek değil, ampirik araştırmanın parçasıdır (Hansen, 2021).

1.15 Temel Sonuçlar

Bu bölümde regresyonu bir yazılım komutu olmaktan çıkarıp anakütle hedefi olarak kurduk. Temel sonuçlar şunlardır:

1. Ekonometrik değişkenler olasılıksal bir veri üretim sürecinin parçalarıdır; gözlemsel veride açıklayıcı değişkenlerin de rassal kabul edilmesi doğal başlangıçtır.
2. Koşullu beklenti $m(X) = E[Y | X]$, Y 'nin X bilgisi verildiğinde ortalama davranışını tanımlar.
3. $Y = m(X) + e$ ayrışımında $E[e | X] = 0$ ve daha genel olarak $E[h(X)e] = 0$ olur.
4. Koşullu beklenti, ortalama kareli hata altında bütün X fonksiyonları arasındaki en iyi öngörücüdür.
5. CEF doğrusal değilse $X'\beta$, en iyi doğrusal yaklaşım olarak tanımlanabilir. Anakütle projeksiyon katsayısı

$$\beta = (E[XX'])^{-1} E[XY]$$

biçimindedir ve projeksiyon hatası $E[Xe] = 0$ koşulunu sağlar.

6. OLS, anakütle karesel kayıp probleminin örneklem analogudur:

$$\hat{\beta} = (X'X)^{-1} X'Y.$$

7. $X'\hat{e} = 0$ örneklem cebirinin bir sonucudur; $E[e | X] = 0$ ile aynı iddia değildir.
8. Regresyon ilişkisi betimleyici veya öngörüselsel olarak anlamlı olabilir; nedensel yorum için ayrıca tanımlama varsayımları gerekir.
9. Yeniden üretilebilirlik, ekonometrik modellemenin sonradan eklenen bir raporlama ayrıntısı değil, ampirik araştırmanın parçasıdır.

1.16 Bölüm Sonu Egzersizleri

Egzersiz 1.1: Araştırma sorusundan tahmin hedefine

Aşağıdaki araştırma sorularının her biri için (i) sonuç değişkenini Y , (ii) temel açıklayıcı bilgiyi X , (iii) doğal bir tahmin hedefini yazınız.

1. Hane geliri yükseldikçe gıda harcamasının koşullu ortalaması nasıl değişmektedir?
2. Bir müşterinin mevcut özellikleri kullanılarak kredi temerrüt olasılığı ne kadar iyi öngörülebilir?
3. Bir işbaşı eğitim programının çalışan verimliliği üzerindeki ortalama nedensel etkisi nedir?

Son soruda koşullu beklenti ile nedensel tahmin hedefi arasındaki farkı özellikle belirtiniz.

Egzersiz 1.2: Yinelenen beklentiler

$X \in \{0, 1\}$ olsun ve $P(X = 1) = 0,4$. Ayrıca

$$E[Y | X = 0] = 10, \quad E[Y | X = 1] = 16.$$

1. $E[Y]$ değerini yinelenen beklentiler yasasıyla hesaplayınız.
2. $e = Y - E[Y | X]$ için $E[e | X = 0]$ ve $E[e | X = 1]$ nedir?
3. Bu bilgiler e ile X 'in bağımsız olduğunu kanıtlar mı? Neden?

Egzersiz 1.3: Koşullu ortalama hatasının ortogonalitesi

$e = Y - m(X)$ ve $m(X) = E[Y | X]$ olsun. Yinelenen beklentiler yasasını kullanarak

$$E[X^2 e] = 0$$

sonucunu türetiniz. Daha sonra bu sonucun $E[e | X] = 0$ koşulunun bir sonucu olduğunu, tersinin ise genel olarak doğru olmadığını açıklayınız.

Egzersiz 1.4: En iyi öngörücü ispatı

Herhangi bir $g(X)$ öngörücüsü için

$$E[(Y - g(X))^2] = E[(Y - m(X))^2] + E[(m(X) - g(X))^2]$$

eşitliğini adım adım gösteriniz. Hangi adımda koşullu beklenti hatasının ortogonalitesini kullandığınızı açıkça belirtiniz. Eşitlikten $m(X)$ 'in neden en iyi kareli-hata öngörücüsü olduğu sonucunu çıkarınız.

Egzersiz 1.5: Doğrusal projeksiyon katsayısı

$X = (1, Z)'$ olsun. Anakütle en küçük kare problemi

$$\min_{a,b} E[(Y - a - bZ)^2]$$

çözerek

$$b = \frac{\text{cov}(Z, Y)}{\text{var}(Z)}, \quad a = E[Y] - bE[Z]$$

sonuçlarını elde ediniz.

Egzersiz 1.6: CEF ile BLP arasındaki fark

Gerçek koşullu ortalamanın

$$m(x) = 2 + x + 0,5x^2$$

olduğunu varsayınız. X hem negatif hem pozitif değerler alıyor olsun.

1. $m(x)$ doğrusal mıdır?
2. $Y = a + bX + e$ doğrusal projeksiyonu tahmin edildiğinde $a + bX$ 'i “gerçek koşullu ortalama” olarak adlandırmak doğru mudur?
3. Buna rağmen doğrusal projeksiyon hangi optimizasyon anlamında iyi bir özet olabilir?

Egzersiz 1.7: Örneklem OLS

Aşağıdaki dört gözlem verilsin:

$$(X_i, Y_i) = (1, 2), (2, 3), (3, 5), (4, 8).$$

Sabit terimli basit regresyon için

1. $\bar{X}$ ve $\bar{Y}$ 'yi,
2. $\hat{\beta}$ ve $\hat{\alpha}$ 'yi,
3. her gözlemin $\hat{Y}_i$ ve $\hat{e}_i$ değerini hesaplayınız.

Son olarak $\sum_i \hat{e}_i = 0$ ve $\sum_i X_i \hat{e}_i = 0$ eşitliklerini sayısal olarak doğrulayınız.

Egzersiz 1.8: Normal denklemler

Matris biçiminde OLS amaç fonksiyonu

$$SSE(b) = (\mathbf{Y} - \mathbf{X}b)'(\mathbf{Y} - \mathbf{X}b)$$

olsun. Amaç fonksiyonunu açınız, b 'ye göre türev alınız ve normal denklemleri elde ediniz. $\mathbf{X}'\mathbf{X}$ terslenemiyorsa neden tek bir OLS katsayı vektörü belirlenemediğini açıklayınız.

Egzersiz 1.9: Üç farklı ortogonalite ifadesi

Aşağıdaki ifadeleri ayrı ayrı açıklayınız ve hangilerinin cebirsel örneklem özelliği, hangilerinin anakütle projeksiyon özelliği, hangisinin koşullu ortalama özelliği olduğunu belirtiniz:

$$\mathbf{X}'\mathbf{e} = 0, \quad E[Xe] = 0, \quad E[e | X] = 0.$$

Bu üç ifadenin birbirine eşitmiş gibi kullanılmasının neden ciddi bir kavramsal hata olacağını tartışınız.

Egzersiz 1.10: Öngörü ve nedensellik

Bir banka veri setinde geçmiş gecikme sayısı X , gelecek yıl temerrüt göstergesi Y olsun. X 'in Y 'yi çok iyi öngördüğü bulunuyor.

1. Bu sonuç hangi araştırma amacı için doğrudan değerlidir?
2. “Gecikme sayısını idari olarak bir azaltırsak temerrüt olasılığı düşer” sonucu otomatik olarak çıkar mı?
3. Nedensel iddia için hangi tür ek argümana ihtiyaç vardır?

Egzersiz 1.11: Gözlemsel seçim

Bir üniversite isteğe bağlı bir destek programı sunuyor. Programa katılan öğrencilerin dönem sonu notu ortalama 8 puan daha yüksek bulunuyor. Çalışma motivasyonu gözlenemiyor ve yüksek motivasyonlu öğrencilerin programa katılma olasılığı daha fazla.

1. D program katılımı, Y not ve U motivasyon olmak üzere olası bir nedensel diyagramı tarif ediniz.
2. $E[Y | D = 1] - E[Y | D = 0]$ neden programın ortalama nedensel etkisini aşabilir?
3. Bu problemde regresyona yaş ve cinsiyet eklemek motivasyon kaynaklı seçimi otomatik olarak çözer mi?

Egzersiz 1.12: Yeniden üretilebilir tez klasörü

Bir tez çalışması için veri temizleme, betimsel istatistik, temel regresyon, sağlamlık analizi ve nihai tablo üretimi yapılacaktır. Yeniden üretilebilir bir klasör yapısı tasarlayınız. Her dosyanın hangi diğer dosyayı girdi olarak aldığını ve hangi çıktıyı ürettiğini bir akış diyagramı veya maddeler hâlinde belirtiniz. Ham verinin neden doğrudan elle değiştirilmemesi gerektiğini açıklayınız.

Doğrusal Regresyonun Modern Kullanımı ve Güvenilir Çıkarım

Bu bölümün amacı

Bu bölümün sonunda çoklu doğrusal regresyon katsayılarını ceteris paribus ve doğrusal projeksiyon açısından yorumlayabilecek; Frisch–Waugh–Lovell mantığını kullanarak bir katsayının diğer regresörlerden arındırılmış ilişkiyi nasıl ölçtüğünü açıklayabilecek; R^2 'yi varyans ayrıştırmasından türetilen neyi ölçtüğünü ve neyi ölçmediğini düzeltilmiş ve dışarıda-bırak sürümleriyle birlikte yorumlayabilecek; doğrusal, logaritmik, karesel, kukla değişkenli ve etkileşimli modellerde katsayı yorumunu doğru kurabilecek; eksik değişken yanlılığının yönünü ve büyüklüğünü belirleyen mekanizmayı türetebilecek; OLS tahmin edicisinin büyük örneklem dağılımını sezgisel ve matematiksel olarak kurabilecek; homoskedastik, heteroskedastisiteye dayanıklı ve küme-dayanıklı kovaryans matrisi tahminlerini ayırt edebilecek; kümelenmiş verinin çıkarımı nasıl değiştirdiğini tasarım etkisi üzerinden hesaplayabilecek; katsayıların doğrusal olmayan fonksiyonları için delta yöntemiyle standart hata türetebilecek; güven aralığı, t ve Wald testlerini uygulayabilecek; p -değeri, hata türleri ve testin gücü kavramlarını doğru kullanabilecek; istatistiksel anlamlılık ile ekonomik anlamlılık birbirinden ayırabilecek ve temel model tanılamasını sistematik biçimde yürütebileceksiniz.

Bağlantı

Bölüm 1'de regresyonu bir yazılım komutundan önce bir anakütle hedefi olarak kurduk. Koşullu beklenti, en iyi doğrusal öngörücü, anakütle projeksiyonu ve örneklem OLS arasındaki ayrımı gördük. Bu bölümde aynı yapıyı ampirik araştırmada gerçekten kullanılan model biçimleri ve çıkarım araçlarıyla genişletiyoruz. Temel soru artık şudur: *Bir OLS katsayısı hangi karşılaştırmayı özetler ve o katsayı hakkındaki belirsizliği nasıl güvenilir biçimde ölçeriz?*

2.1 Çoklu Regresyon Katsayısının Anlamı

Y ve e skaler rassal değişkenler; $X = (1, X_1, \dots, X_{k-1})'$ ve $\beta = (\beta_0, \dots, \beta_{k-1})'$ $k \times 1$ sütun vektörleri olsun. İndissiz gösterim bir rassal gözlem içindir; normal italik X bir vektördür ve

$X'\beta$ skaler doğrusal indekstir. Doğrusal projeksiyon veya doğrusal koşullu ortalama modeli

$$Y = X'\beta + e \quad (2.1)$$

şeklindedir. Gözlem indisiyle $Y_i = X_i'\beta + e_i$ yazılır. Bütün n denklem yığıldığında $\mathbf{Y} = \mathbf{X}\beta + \mathbf{e}$ elde edilir; $\mathbf{X}$ 'in i . satırı X_i' 'dir. Örnekleme OLS

$$\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$$

ile hesaplanır. Ancak ampirik araştırmada esas mesele formülü bilmek değil, $\hat{\beta}_j$ katsayısının hangi karşılaştırmayı temsil ettiğini doğru kurmaktır.

Basit regresyonda eğim, X_j ile Y arasındaki ham doğrusal ilişkiyi özetler. Çoklu regresyonda ise β_j , diğer regresörlerin doğrusal katkısı ayrıştırıldıktan sonra kalan X_j değişimi ile Y değişimi arasındaki ilişkiyi temsil eder. Bu nedenle çoklu regresyon katsayısının klasik yorumu “diğer değişkenler sabitken” biçimindedir. Fakat bu ifade mekanik kullanılmamalıdır.

Ceteris paribus yorumu

Doğrusal modelde β_j , diğer regresörlerin değerleri sabit tutulduğunda X_j 'de bir birimlik farkla ilişkilendirilen koşullu ortalama veya doğrusal projeksiyon farkıdır (X_j modelde karesi ya da başka bir değişkenle etkileşimiyle yer almıyorsa). Bu yorum matematiksel olarak bir kısmi türev ya da koşullu karşılaştırmadır; nedensel “müdahale etkisi” olduğu ayrıca gösterilmelidir.

Örneğin

$$E[\log(\text{wage}) \mid \text{education}, \text{experience}] = \beta_0 + \beta_1 \text{education} + \beta_2 \text{experience}$$

modelinde β_1 , aynı deneyim düzeyinde eğitim yılı bir birim farklı olan gözlemlerin koşullu ortalama log ücret farkını verir. Bu, eğitim düzeyini deneysel olarak bir yıl artırmamanın nedensel etkisiyle aynı olmak zorunda değildir.

2.1.1 Frisch–Waugh–Lovell sezgisi

Çoklu regresyonun ceteris paribus mantığı en açık biçimde Frisch–Waugh–Lovell (FWL) ayrıştırmasıyla görülebilir. Basitlik için

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + e$$


modelini düşünelim. Önce X_1 'i X_2 ve sabit terim üzerine regres edip artıklarını r_1 ile gösterelim:

$$X_1 = \pi_0 + \pi_1 X_2 + r_1.$$

r_1 , X_1 'in X_2 tarafından doğrusal olarak açıklanamayan kısmıdır. FWL sonucuna göre çoklu regresyondaki β_1 katsayısı, Y 'nin r_1 üzerindeki basit regresyon eğimine eşittir:

$$\beta_1 = \frac{\text{cov}(r_1, Y)}{\text{var}(r_1)}. \quad (2.2)$$

Örnekleme de aynı ayrıştırma geçerlidir.



Şekil 2.1: FWL teoreminin kısmi ilişki sezgisi

FWL iki nedenle önemlidir. Birincisi, çoklu regresyondaki “diğer değişkenleri kontrol etmek” ifadesinin ne yaptığını açıklar. İkincisi, X_j 'nin diğer regresörler tarafından neredeyse tamamen açıklanması durumunda neden katsayı belirsizliğinin büyüdüğünü gösterir: geriye çok az bağımsız varyasyon kalır.

Sık yapılan hata

Bir kontrol değişkenini modele eklemek, otomatik olarak “nedensel kontrol” sağlamaz. FWL yalnızca doğrusal cebirsel ayrıştırmayı açıklar. Hangi değişkenlerin kontrol edilmesi gerektiği tanımlama problemidir ve Bölüm 3'te ele alınacaktır.

FWL sonucu çoklu regresyon katsayısına güçlü bir görsel yorum da verir. Önce ilgilenilen X_j değişkenini diğer kontroller üzerine regres edip artıklarını alın. Bu artıklar, X_j 'nin kontrol değişkenleri tarafından doğrusal olarak açıklanamayan kısmıdır. Aynı işlemi Y için yapın. Sonra iki artık arasındaki basit regresyon eğimi, tam çoklu regresyondaki X_j katsayısına eşittir. Böylece “diğer değişkenler sabitken” ifadesi fiziksel olarak bütün bireylerde kontrolleri aynı değere getirmek değil, doğrusal olarak ortak hareket eden bileşenleri ayırmak anlamına gelir.

Bu yorum, kontrol değişkenlerinin neden katsayıları değiştirebildiğini de açıklar. Yeni bir kontrol, hem Y hem de X_j ile ilişkiliyse iki artık serisini değiştirir ve dolayısıyla katsayının dayandığı karşılaştırma yeniden tanımlanır. Kontrol ekledikten sonra katsayının değişmesi otomatik olarak ilk modelin “yanlış”, ikinci modelin “doğru” olduğunu göstermez; hangi modelin araştırma sorusuna uygun olduğu tanımlama argümanına bağlıdır.

2.1.2 Varyans ayrıştırması ve R^2

Tablo 1.4 ve bu bölümün uygulamasındaki Tablo 2.3 katsayıların yanında R^2 'yi de raporlar. R^2 bir çıkarım aracı değil, OLS cebrinin bir sonucudur ve iki şeye dayanır: normal denklemler ($\mathbf{X}'\hat{\mathbf{e}} = 0$, Denklem (1.23)) ve modelde sabit terim bulunması. Bu alt bölümde ve bölümün geri kalanında k , sabit terim dahil $\mathbf{X}$ 'in sütun sayısıdır.

Örneklem ortalaması $\bar{Y}$, tahmin değerleri $\hat{Y}_i = \mathbf{X}_i'\hat{\boldsymbol{\beta}}$ ve artıklar $\hat{e}_i = Y_i - \hat{Y}_i$ olsun. Toplam, açıklanan ve artık kareler toplamaları

$$TSS = \sum_{i=1}^n (Y_i - \bar{Y})^2, \quad ESS = \sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2, \quad SSE = \sum_{i=1}^n \hat{e}_i^2 \quad (2.3)$$

biçimindedir. SSE , Bölüm 1'deki $SSE(b)$ amaç fonksiyonunun $b = \hat{\boldsymbol{\beta}}$ noktasındaki değeridir. Kısaltmalar kaynaktan kaynağa değişir: Wooldridge (2020) toplamı SST, açıklanan SSE, artığı SSR ile gösterir. Bu notlarda SSE her zaman artık kareler toplamıdır. Yazılımda aynı nesneler

statsmodels'te `ess` ve `ssr`, Stata `regress` çıktısında *Model* ve *Residual* satırlarıdır.

Varyans ayrıştırması

$\mathbf{X}$ sabit terim sütununu içeriyorsa

$$TSS = ESS + SSE. \quad (2.4)$$

İspat. $Y_i - \bar{Y} = (\hat{Y}_i - \bar{Y}) + \hat{e}_i$ özdeşliğinin karesi alınıp toplanırsa

$$TSS = ESS + SSE + 2 \sum_{i=1}^n (\hat{Y}_i - \bar{Y}) \hat{e}_i$$

elde edilir. Çapraz terimin ilk parçası normal denklemlerden sıfırdır: $\sum_i \hat{Y}_i \hat{e}_i = \hat{\beta}' \mathbf{X}' \hat{\mathbf{e}} = 0$. İkinci parça $\bar{Y} \sum_i \hat{e}_i$ 'dir ve sabit terim varken $\sum_i \hat{e}_i = 0$ olduğundan o da sıfırdır. $\square$

Sabit terim olmasa da $\sum_i Y_i^2 = \sum_i \hat{Y}_i^2 + \sum_i \hat{e}_i^2$ geçerlidir, çünkü bunun için yalnız ilk parça gerekir. Ortalama etrafındaki [Denklem \(2.4\)](#) ise ikinci parçayı, yani sabit terimi gerektirir ([Hansen, 2021](#), Bölüm 3.14).

Belirlilik katsayısı

Sabit terimli OLS regresyonunda

$$R^2 = \frac{ESS}{TSS} = 1 - \frac{SSE}{TSS}. \quad (2.5)$$

R^2 , Y 'nin örneklem varyasyonunun OLS uyumuyla açıklanan payıdır.

Sabit terimli modelde R^2 'nin dört cebirsel özelliği vardır:

1. **Sınırlar.** $ESS \geq 0$ ve $SSE \geq 0$ olduğundan $0 \leq R^2 \leq 1$ 'dir. $R^2 = 1$ ancak bütün artıklar sıfırsa, $R^2 = 0$ ise ancak bütün tahmin değerleri $\bar{Y}$ 'ye eşitse, yani bütün eğim tahminleri sıfırsa elde edilir.
2. **Korelasyon.** Sabit terim varken $\hat{Y}$ 'nin ortalaması $\bar{Y}$ 'dir ve çapraz terim yine sıfır olduğundan $\sum_i (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y}) = ESS$ olur. Dolayısıyla

$$\hat{\rho}_{Y\hat{Y}}^2 = \frac{ESS^2}{TSS \cdot ESS} = R^2$$

olur; yani R^2 , Y ile $\hat{Y}$ arasındaki örneklem korelasyonunun karesidir. Basit regresyonda $\hat{Y}$, X 'in doğrusal bir fonksiyonu olduğundan $R^2 = \hat{\rho}_{XY}^2$ olur.

3. **Ölçek değişmezliği.** Y yerine $a + cY$ ($c \neq 0$) kullanılırsa ya da regresörler tekil olmayan bir doğrusal dönüşümle yeniden tanımlanırsa R^2 değişmez. Örneğin ücretin dolar veya sent cinsinden ölçülmesi log ücret modelinin R^2 'sini değiştirmez. $\log Y$ ise Y 'nin doğrusal bir dönüşümü değildir; iki modelin TSS 'si farklı olduğundan R^2 'leri karşılaştırılmaz.
4. **Monotonluk.** Aynı örneklem ve aynı Y ile modele yeni regresörler eklendiğinde R^2 azalamaz. Büyük modelin amaç fonksiyonu, küçük modelin bütün katsayı vektörlerini (ek katsayılar sıfırken) de içeren daha geniş bir kümede en küçüklenir. Bu yüzden büyük modelin SSE 'si küçük modelinkini aşamaz; TSS ise değişmez. Eşitlik yalnız eklenen

regresörlerin OLS katsayıları tam sıfır çıktığında gerçekleşir (Hansen, 2021, Alıştırma 3.16).

Anakütle karşılığı

Sabit terim içeren doğrusal projeksiyonda $E[Xe] = 0$ koşulunun ilk bileşeni $E[e] = 0$ demektir. Dolayısıyla $\text{cov}(X'\beta, e) = \beta' E[Xe] = 0$ ve $\sigma^2 = E[e^2]$ ile $\text{var}(Y) = \text{var}(X'\beta) + \sigma^2$ olur. R^2 'nin anakütle karşılığı

$$\rho^2 = \frac{\text{var}(X'\beta)}{\text{var}(Y)} = 1 - \frac{\sigma^2}{\sigma_Y^2} \quad (2.6)$$

en iyi doğrusal öngörücünün açıkladığı varyans payıdır. $\hat{\sigma}^2 = SSE/n$ ve $\hat{\sigma}_Y^2 = TSS/n$ ile $R^2 = 1 - \hat{\sigma}^2/\hat{\sigma}_Y^2$ yazılabilir. Rassal örneklemede ve sonlu ikinci momentlerle iki varyans tahmincisi de tutarlı olduğundan $R^2 \xrightarrow{P} \rho^2$ sonucu elde edilir (Hansen, 2021, Bölüm 4.20).

ρ^2 bir katsayının büyüklüğünü değil, iki varyansın oranını ölçer. Basit regresyonda

$$\rho^2 = \frac{\beta^2 \text{var}(X)}{\beta^2 \text{var}(X) + \sigma^2}$$

olduğundan aynı β ve σ^2 ile X 'in yayılımı geniş bir anakütlerde ρ^2 yüksek, dar bir anakütlerde düşük olur. Aynı ekonomik ilişki bu nedenle farklı örneklemlerde çok farklı R^2 değerleri üretebilir.

Gürültü regresörleri ve düzeltilmiş R^2

Monotonluk, R^2 'yi model seçimi için elverişsiz kılar. Klasik normal regresyon modelinde ($e | \mathbf{X} \sim N(0, \sigma^2 \mathbf{I}_n)$) bütün eğim katsayıları sıfırken

$$F = \frac{R^2/(k-1)}{(1-R^2)/(n-k)} \sim F_{k-1, n-k}$$

olduğundan R^2 , Beta($(k-1)/2, (n-k)/2$) dağılımına uyar ve beklenen değeri

$$E[R^2] = \frac{k-1}{n-1} \quad (2.7)$$

olur. Y ile hiçbir ilişkisi olmayan regresörler bile ortalamada pozitif R^2 üretir: $n = 50$ gözlem ve 10 gürültü regresörüyle ($k = 11$) beklenen R^2 yaklaşık $10/49 \approx 0,20$ 'dir.

Theil (1961), R^2 'deki yanlış $\hat{\sigma}^2$ ve $\hat{\sigma}_Y^2$ yerine yansız karşılıkları

$$s^2 = \frac{SSE}{n-k}, \quad s_Y^2 = \frac{TSS}{n-1} \quad (2.8)$$

kullanmayı önermiştir:

$$\bar{R}^2 = 1 - \frac{s^2}{s_Y^2} = 1 - (1 - R^2) \frac{n-1}{n-k}. \quad (2.9)$$

s^2 , doğrusal koşullu ortalama modelinde ($E[e | \mathbf{X}] = 0$) homoskedastisite altında σ^2 'nin yansız tahmincisidir ve yazılımların klasik standart hatalarında kullanılan değerdir (Denklemler (2.26)). Düzeltilmiş R^2 'nin üç özelliği önemlidir:

1. $\bar{R}^2 \leq R^2$ 'dir ve $\bar{R}^2$ negatif olabilir: $\bar{R}^2 < 0$ ancak ve ancak $R^2 < (k-1)/(n-1)$ ise, yani R^2 saf gürültünün beklenen düzeyinin altındaysa.

2. Sütun sayısı k olan bir modele tek bir regresör eklemek $\bar{R}^2$ 'yi ancak ve ancak yeni regresörün klasik t istatistiği $|t| > 1$ ise artırır. $\bar{R}^2$ 'nin artması s^2 'nin azalması, yani $SSE_u/(n-k-1) < SSE_r/(n-k)$ demektir. Bu eşitsizlik $(SSE_r - SSE_u)/\{SSE_u/(n-k-1)\} > 1$ ile aynıdır ve sol taraf tek kısıtta $F = t^2$ 'dir (Denklem (2.36)). q regresör için koşul, bunları dışlayan klasik F 'nin 1'i aşmasıdır (Hansen, 2021, Alıştırma 9.1). $|t| > 1$ yaklaşık yüzde 32 düzeyinde bir teste karşılık gelir; bu yüzden $\bar{R}^2$ 'yi en büyükmek gereğinden fazla regresör seçme eğilimindedir.
3. Klasik normal modelde bütün eğimler sıfırken Denklem (2.7) ile $E[\bar{R}^2] = 0$ olur. Düzeltme gürültünün ortalama katkısını siler; tek bir örneklemede sileceğinin güvencesi yoktur.

Dışarıda-bırak R^2

Hansen'in önerdiği ölçü her gözlemi, o gözlem kullanılmadan tahmin edilen modelle öngörür (Hansen, 2021, Bölüm 4.20). $\hat{\beta}_{(-i)}$, i . gözlem çıkarılarak hesaplanan OLS tahmini olsun. Dışarıda-bırak öngörü hatası tek bir regresyondan hesaplanır:

$$\tilde{e}_i = Y_i - X_i' \hat{\beta}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}}, \quad h_{ii} = X_i' (\mathbf{X}' \mathbf{X})^{-1} X_i. \quad (2.10)$$

$h_{ii} \in [0, 1]$, gözlem i 'nin kaldıraç değeridir (Hansen, 2021, Bölüm 3.19–3.20). Buna göre

$$\tilde{R}^2 = 1 - \frac{\sum_{i=1}^n \tilde{e}_i^2}{TSS}. \quad (2.11)$$

$\tilde{e}_i$, Y_i 'yi kullanmayan gerçek bir öngörünün hatasıdır. Bu yüzden $\tilde{R}^2$ örneklem dışı uyumu ölçer: regresör eklendiğinde düşebilir ve model sabit ortalamadan kötü öngörüorsa negatif olur. $n^{-1} \sum_i \tilde{e}_i^2$ dışarıda-bırak çapraz doğrulama ölçütüdür (Bölüm 11). Hansen, uyum raporlanacaksa R^2 ve $\bar{R}^2$ yerine $\tilde{R}^2$ 'nin kullanılmasını önerir. $h_{ii} = 1$ olan bir gözlemden, örneğin yalnız bir gözlemi bulunan bir kukla kategorisinde, $\tilde{e}_i$ tanımsızdır: gözlem çıkarılınca o kategorinin katsayısı tahmin edilemez. Uygulamadaki M2 ve M3'te üç ırk kategorisinin her birinde tek gözlem bulunduğundan bu modellerde $\tilde{R}^2$, o gözlemler ayrıca ele alınmadan hesaplanamaz.

Kısmi R^2

FWL ile birleştiğinde R^2 bir regresör grubunun ek katkısını da ölçer. W modeldeki diğer regresörleri (sabit dahil), SSE_r yalnız W ile, SSE_u ise bütün regresörlerle elde edilen artık kareler toplamını gösterebilir. Kısmi R^2

$$R_{\text{kısmi}}^2 = \frac{SSE_r - SSE_u}{SSE_r} \quad (2.12)$$

olarak tanımlanır ve Y 'nin W 'den arındırılmış varyasyonunun eklenen regresörlerle açıklanan payını verir. Tek bir X_j eklendiğinde FWL'ye göre $R_{\text{kısmi}}^2$, Y ile X_j 'nin W üzerindeki artıkları arasındaki korelasyonun karesidir ve klasik t_j istatistiğiyle

$$R_{\text{kısmi}}^2 = \frac{t_j^2}{t_j^2 + n - k}$$

ilişkisini sağlar. Araçsal değişkenlerde ilk aşamanın kısmi R^2 'si aynı tanımdır: W dışsal kontroller, eklenen değişkenler ise dışlanmış araçlardır (Bölüm 4).

CPS’te sayısal kontrol

Tablo 1.4’teki üç model aynı $n = 50.742$ gözlemi ve aynı bağımlı değişkeni kullanır; ortak $TSS = 23.179,86$ ’dır. Model (3)’te $ESS = 6.322,65$ ve $SSE = 16.857,21$ olduğundan Denklem (2.4) sağlanır ve $R^2 = 6.322,65/23.179,86 = 0,2728$ bulunur. Üç uyum ölçüsü şöyledir:

	Model (1)	Model (2)	Model (3)
k	2	4	5
R^2	0,1930	0,2368	0,2728
$\bar{R}^2$	0,1930	0,2367	0,2727
$\tilde{R}^2$	0,1929	0,2366	0,2726

n çok büyük, k küçük olduğundan üç ölçü ancak dördüncü ondalıkta ayrışır; düzeltmelerin önemi k/n büyüdükçe artar.

İki uyarı sayısal olarak da görülür. Birincisi, log ücretin yalnız eğitime sabit terimsiz regresyonunda yazılım $R^2 = 0,951$ raporlar. Bu değer merkezlenmemiş $1 - SSE/\sum_i Y_i^2$ oranıdır. Aynı modelin $1 - SSE/TSS$ değeri yalnız 0,023’tür; sabitsiz modelin SSE ’si (22.638,61) sabitli Model (1)’inkinden (18.706,18) büyüktür. İkincisi, Tablo 2.3’teki M2’ye eğitim–kadın etkileşimi eklenerek M3’e geçildiğinde R^2 yalnız 0,00008 kadar artar ve kısmi R^2 yaklaşık 0,0001 olur. Buna karşın etkileşimin klasik t istatistiği 2,32’dir: büyük n ’de çok küçük bir kısmi R^2 bile kesin tahmin edilmiş bir kısmi ilişkiye karşılık gelebilir. Bu geçişte $|t| > 1$ olduğundan $\bar{R}^2$ de artar.

Sık yapılan hata

R^2 ancak aynı bağımlı değişkeni, aynı örnekleme ve sabit terimi kullanan modeller arasında karşılaştırılabilir; log ücret ile ücret düzeyinin TSS ’leri farklıdır. Sabitsiz modelde yazılımların raporladığı R^2 merkezlenmemiştir: `statsmodels` ve R $1 - SSE/\sum_i Y_i^2$ kullanır, Stata `regress, noconstant` da toplamı $\sum_i Y_i^2$ olarak alır. Yüksek R^2 nedenselliğin, doğru fonksiyonel biçimin veya örneklem dışı başarının kanıtı değildir. Düşük R^2 da katsayının kesin tahmin edilmediği anlamına gelmez; kesinliği standart hata belirler.

2.2 Fonksiyonel Biçim: Katsayıyı Doğru Ölçekte Okumak

Regresyon katsayılarının yorumu modeldeki dönüşümlere bağlıdır. Aynı sayısal katsayı farklı fonksiyonel biçimlerde farklı ekonomik anlam taşır. Bu nedenle ampirik tabloda bir katsayıyı yorumlamadan önce hem Y hem de ilgili X değişkeninin ölçeği kontrol edilmelidir.

2.2.1 Düzey–düzey modeli

$$Y = \beta_0 + \beta_1 X + e.$$

Burada X bir birim arttığında koşullu ortalama Y , β_1 birim değişir:

$$\frac{\partial E[Y | X]}{\partial X} = \beta_1.$$

Örneğin Y aylık tüketim (TL), X gelir (bin TL) ise $\beta_1 = 420$ katsayısı, gelirden 1 bin TL farkın tüketimde yaklaşık 420 TL farkla ilişkili olduğunu belirtir.

Birim seçimi katsayının sayısal değerini değiştirir: gelir TL yerine bin TL yazılırsa eğim 1.000 kat değişir, fakat ekonomik ilişki aynı kalır. Bu nedenle regresyon tablosunda birimler mutlaka açık verilmelidir.

2.2.2 Log–düzey modeli

$$\log Y = \beta_0 + \beta_1 X + e.$$

Modelin doğrudan hedefi $E[\log Y \mid X]$ olduğu için, X bir birim değiştiğinde Y 'nin koşullu geometrik ortalaması yaklaşık $100\beta_1$ yüzde değişir. Küçük katsayılarda bu yaklaşım oldukça iyidir. Daha kesin ifade

$$100\{\exp(\beta_1) - 1\} \quad (2.13)$$

şeklindedir.

Örneğin $\beta_1 = 0,08$ ise yaklaşık yorum yüzde 8'dir; kesin dönüşüm

$$100(e^{0,08} - 1) \approx 8,33$$

yüzdedir.

Birden fazla birimlik değişim için tam dönüşüm

$$100\{\exp(\beta_1 \Delta X) - 1\}$$

biçimini alır. β_1 büyük veya ΔX birden fazla birimse bu tam dönüşüm daha güvenlidir. Ayrıca $Y > 0$ olmalıdır; sıfır veya negatif gözlemleri mekanik biçimde düşürmek örneklem seçimi yaratabilir.

2.2.3 Düzey–log modeli

$$Y = \beta_0 + \beta_1 \log X + e.$$

X 'te yaklaşık yüzde 1'lik değişim Y 'de $\beta_1/100$ birimlik değişimle ilişkilidir. Türev kullanarak

$$\frac{\partial E[Y \mid X]}{\partial X} = \frac{\beta_1}{X}$$

ve küçük bir ΔX için

$$\Delta Y \approx \beta_1 \frac{\Delta X}{X}$$

elde edilir.

Bu model, açıklayıcı değişkendeki mutlak farktan çok oransal farkların önemli olduğu durumlarda yararlıdır; örneğin firma büyüklüğünde bir birimlik değil yüzdesel değişim ekonomik olarak anlamlı olabilir.

2.2.4 Log–log modeli

$$\log Y = \beta_0 + \beta_1 \log X + e.$$

Bu modelde $g(X) = \exp\{E[\log Y \mid X]\}$ koşullu geometrik ortalamayı gösterebilir. O zaman β_1 bu

geometrik ortalamanın esnekliğidir:

$$\beta_1 = \frac{\partial E[\log Y \mid X]}{\partial \log X} = \frac{\partial \log g(X)}{\partial \log X}. \quad (2.14)$$

Dolayısıyla X 'te yüzde 1'lik değişim, koşullu geometrik ortalama da yaklaşık yüzde β_1 değişimle ilişkilidir.

Tablo 2.1: Temel fonksiyonel biçimlerde katsayı yorumu

Model	β_1 'in temel yorumu	Tipik kullanım
$Y = \beta_0 + \beta_1 X + e$	X 'te 1 birim fark, Y 'de β_1 birim fark	Doğal ölçekler
$\log Y = \beta_0 + \beta_1 X + e$	X 'te 1 birim fark, koşullu geometrik ortalama da yaklaşık $100\beta_1\%$ fark	Oransal sonuçlar
$Y = \beta_0 + \beta_1 \log X + e$	X 'te 1% fark, Y 'de yaklaşık $\beta_1/100$ birim fark	Azalan marjinal ilişki
$\log Y = \beta_0 + \beta_1 \log X + e$	X 'te 1% fark, koşullu geometrik ortalama da yaklaşık $\beta_1\%$ fark	Esneklik

Fonksiyonel biçim seçimi iki farklı kararı birlikte içerir: ilişkinin matematiksel şekli ve katsayının hangi ölçekte yorumlanacağı. Düzey, logaritma, karesel terim veya etkileşim kullanmak yalnızca model uyumunu değiştirmez; “bir birim değişim” ifadesinin ekonomik anlamını da değiştirir. Bu nedenle bir regresyon tablosunu yorumlamadan önce bağımlı ve açıklayıcı değişkenlerin hangi dönüşümlerle modele girdiği kontrol edilmelidir.

Özellikle logaritmik modellerde küçük değişimler için kullanılan yüzde yaklaşımı ile tam yüzde değişim birbirinden ayrılmalıdır. Log–düzey modelinde X bir birim arttığında yaklaşık yüzde değişim 100β iken, sonlu değişim için daha doğru ifade $100\{\exp(\beta\Delta x) - 1\}$ 'dir. Katsayı küçük olduğunda iki sonuç çok yakın olabilir; büyük katsayılar da fark önem kazanır. Benzer biçimde kukla değişkenin log bağımlı değişken üzerindeki etkisinde tam dönüşüm kullanmak daha güvenlidir.

2.3 Doğrusal Olmayan Etkileri Doğrusal Regresyonla Kurmak

“Doğrusal regresyon” ifadesi, modelin değişkenlerde mutlaka doğrusal olduğu anlamına gelmez. OLS için temel doğrusal yapı parametrelerdedir. Regresör vektörüne X^2 , $\log X$, kukla veya etkileşim terimleri eklenebilir.

2.3.1 Karesel terim

$$E[Y \mid X] = \beta_0 + \beta_1 X + \beta_2 X^2. \quad (2.15)$$


Bu modelde β_1 tek başına “ X 'in etkisi” değildir. Marjinal değişim

$$\frac{\partial E[Y \mid X]}{\partial X} = \beta_1 + 2\beta_2 X \quad (2.16)$$

ile X düzeyine bağlıdır. Dönüm noktası, $\beta_2 \neq 0$ ise

$$X^* = -\frac{\beta_1}{2\beta_2}$$

olarak bulunur.



Şekil 2.2: Karesel modelde marjinal ilişkinin X düzeyine göre değişmesi

2.3.2 Kukla değişkenler

$D \in \{0, 1\}$ olsun:

$$E[Y | D, X] = \beta_0 + \delta D + \beta_1 X.$$

Aynı X düzeyinde iki grup arasındaki koşullu ortalama farkı δ 'dır. Eğer sonuç logaritmik ise

$$\log Y = \beta_0 + \delta D + \beta_1 X + e$$

modelinde kukla katsayısının kesin yüzde yorumu

$$100\{\exp(\delta) - 1\} \quad (2.17)$$

olarak verilir.

Birden fazla kategori varsa bir referans kategori dışarıda bırakılır; aksi halde sabit terimle birlikte tam doğrusal bağlantı oluşur. Katsayılar referans gruba göre farkları verir. Referans kategoriyi değiştirmek tahmin edilen grup ortalamalarını değiştirmez; yalnız katsayıların temsil biçimini değiştirir.

2.3.3 Etkileşimler

$$E[Y | X, D] = \beta_0 + \beta_1 X + \delta D + \gamma(XD).$$

$D = 0$ grubu için

$$E[Y | X, D = 0] = \beta_0 + \beta_1 X,$$

$D = 1$ grubu için

$$E[Y | X, D = 1] = (\beta_0 + \delta) + (\beta_1 + \gamma)X.$$

Dolayısıyla koşullu grup farkı

$$\Delta(X) = \delta + \gamma X \quad (2.18)$$

şeklinde X 'e bağlıdır.

Sık yapılan hata

Etkileşimli modelde ana etki katsayıları koşullu katsayılardır. δ , $X = 0$ iken grup farkıdır; β_1 , referans grup $D = 0$ için eğimdir. $X = 0$ veri aralığının dışında veya ekonomik olarak anlamsızsa değişkeni anlamlı bir merkez etrafında yeniden merkezlemek yorumu kolaylaştırır.

Daha fazla polinom terimi eklemek otomatik olarak daha iyi bir model üretmez. Yüksek dereceli polinomlar özellikle veri desteğinin zayıf olduğu uçlarda kararsız davranabilir. İyi uygulamada dönüşüm seçimi ekonomik teori, saçılım grafikleri, artık analizi ve gerekirse çapraz doğrulama gibi bilgi kaynaklarının birlikte değerlendirilmesine dayanır. Bölüm 8'de parametrik olmayan ve spline temelli yaklaşımlar bu esnekliği daha sistematik biçimde ele alacaktır.

2.4 Eksik Değişken Yanlılığı: Neden Katsayı Değişir?

Hansen'in katsayı ayrıştırması, bir regresöre ait katsayının başka değişkenler modele eklendiğinde neden değişebileceğini açık biçimde gösterir (Hansen, 2021). Gerçek doğrusal koşullu ilişki

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + u, \quad E[u | X, Z] = 0 \quad (2.19)$$

olsun. Araştırmacı Z 'yi göz ardı ederek

$$Y = \tilde{\beta}_0 + \tilde{\beta}_1 X + v$$

regresyonunu tahmin etsin. Z 'nin X üzerindeki doğrusal projeksiyonunu

$$Z = \pi_0 + \pi_1 X + r$$

yazarsak, eksik modelin eğimi

$$\tilde{\beta}_1 = \beta_1 + \beta_2 \pi_1 \quad (2.20)$$

olur.


Bu formül eksik değişken problemini iki parçaya ayırır:

1. Z sonucu etkiliyor mu? $\beta_2 \neq 0$ mı?
2. Z , X ile ilişkili mi? $\pi_1 \neq 0$ mı?

İki koşuldan biri sıfırsa eksik değişken X katsayısını kaydırmaz. İkisi de sıfır değilse yön

$$\text{sign}(\tilde{\beta}_1 - \beta_1) = \text{sign}(\beta_2 \pi_1)$$

ile belirlenir.

Şekil 2.3: Eksik Z değişkeninin X katsayısını bozabileceği temel yapı**Yanlılığın yönünü ezberlemek yerine mekanizmayı kurun**

Örneğin eğitim (X) ile ücret (Y) ilişkisinde gözlenemeyen yetenek (Z) ücreti artırıyor ($\beta_2 > 0$) ve eğitimle pozitif ilişkiliyse ($\pi_1 > 0$), yetenek dışarıda bırakıldığında eğitim katsayısı yukarı doğru kayabilir. Bu yalnızca bir olası mekanizmadır; gerçek araştırmada yönün savunulması ekonomik ve kurumsal bilgi gerektirir.

Eksik değişken formülünü nasıl okumalı?

Gerçek model

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + u, \quad E[u | X, Z] = 0$$

olsun. Z dışarıda bırakılıp Y yalnız X üzerine regrese edilirse basit durumda olasılık limiti

$$\text{plim } \hat{\beta}_1^{short} = \beta_1 + \beta_2 \frac{\text{cov}(X, Z)}{\text{var}(X)}$$

şeklinde. İkinci terim eksik değişken yanlılığıdır. Yanlılığın işareti Z 'nin Y üzerindeki koşullu etkisi ile X - Z ilişkisinin işaretlerinin çarpımına bağlıdır. Formül, kontrol değişkeni eklenince katsayının neden değişebileceğini matematiksel olarak görünür kılar.

Çoklu regresyonda aynı fikir FWL üzerinden devam eder: eksik Z 'nin, diğer kontrollerden arındırılmış X ile kalan ilişkisi önemlidir. Bu nedenle ham korelasyon yerine koşullu ilişki düşünülmelidir.

2.5 Tahmin Belirsizliği: OLS'nin Büyük Örneklem Dağılımı

Bir örneklemde hesaplanan $\hat{\beta}$, farklı rassal örneklemlerde farklı değer alır. Standart hata bu örnekleme belirsizliğini ölçer. Hansen'in büyük örneklem yaklaşımında doğrusal projeksiyon için temel sonuç, uygun moment koşulları altında OLS'nin tutarlı ve asimptotik normal olmasıdır (Hansen, 2021).

Model

$$Y_i = X_i' \beta + e_i, \quad E[X_i e_i] = 0$$

ve

$$Q_{XX} = E[X_i X_i']$$

pozitif tanımlı olsun. OLS hatasını yeniden yazalım:

$$\hat{\beta} - \beta = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{e} \quad (2.21)$$

$$= \left(\frac{1}{n} \sum_{i=1}^n X_i X_i' \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n X_i e_i \right). \quad (2.22)$$

Büyük sayılar yasası ilk matrisi $\mathbf{Q}_{XX}$ 'ya yaklaştırır. Merkezi limit teoremi ise

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i e_i$$

teriminin yaklaşık normal davranmasını sağlar. Sonuçta

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} N(0, \mathbf{V}_\beta), \quad (2.23)$$

ve genel heteroskedastik durumda

$$\mathbf{V}_\beta = \mathbf{Q}_{XX}^{-1} \mathbf{\Omega} \mathbf{Q}_{XX}^{-1}, \quad \mathbf{\Omega} = E[X_i X_i' e_i^2]. \quad (2.24)$$

Burada $\mathbf{Q}_{XX}$, $\mathbf{\Omega}$ ve $\mathbf{V}_\beta$, $k \times k$ matrislerdir. $\mathbf{V}_\beta$, $\sqrt{n}(\hat{\beta} - \beta)$ limitinin kovaryansdır; $\hat{\beta}$ kovaryansının tahmini $\widehat{\mathbf{V}}_\beta$ ise yaklaşık $n^{-1}\mathbf{V}_\beta$ ölçeğindedir. Dolayısıyla $\widehat{\mathbf{V}}_\beta = n\widehat{\mathbf{V}}_\beta$ tanımı iki ölçeği ayırır (Hansen §7.8). Bu “sandviç” biçimi modern regresyon çıkarımının merkezindedir. Dış parçalar $\mathbf{Q}_{XX}^{-1}$ regresör tasarımı, orta parça $\mathbf{\Omega}$ ise hata varyansının regresörlerle nasıl değiştiğini taşır.

Buradaki mantık sırasını akılda tutmak yararlıdır. Tutarlılık yalnız $\hat{\beta} \xrightarrow{p} \beta$ sonucunu verir; standart hata için ayrıca yakınsama hızına ve limit dağılımına ihtiyaç vardır. $\sqrt{n}$ ile ölçeklemek tam olarak bu iki bilgiyi birlikte üretir.

2.6 Homoskedastisite ve Heteroskedastisite

Homoskedastisite

Eğer

$$E[e_i^2 | X_i] = \sigma^2$$

tüm X_i değerleri için sabitse hata koşullu homoskedastiktir. $E[e_i | X_i] = 0$ ise (doğrusal koşullu ortalama modeli) bu koşul $\text{var}(e_i | X_i) = \sigma^2$ demektir.

Heteroskedastisite

Eğer

$$E[e_i^2 | X_i] = \sigma^2(X_i)$$

X_i ile değişiyorsa hata koşullu heteroskedastiktir.

Homoskedastisite altında yinelenen beklentilerle

$$\mathbf{\Omega} = E[X_i X_i' e_i^2] = E[X_i X_i' E(e_i^2 | X_i)] = \sigma^2 \mathbf{Q}_{XX}$$

ve

$$\mathbf{V}_\beta = \sigma^2 \mathbf{Q}_{XX}^{-1} \quad (2.25)$$

olur. Örnekleme klasik kovaryans matrisi

$$\widehat{\mathbf{V}}_{\beta}^0 = s^2(\mathbf{X}'\mathbf{X})^{-1} \quad (2.26)$$

şeklinde. Burada $s^2 = SSE/(n - k)$, Bölüm 2.1.2’de tanımlanan serbestlik derecesi düzeltilmiş hata varyansı tahminidir (Denklem (2.8)); yazılımların “klasik” standart hataları bu formülden gelir.


Heteroskedastisite varsa katsayı tahmini aynı OLS katsayısı olabilir; fakat klasik standart hata formülü genel olarak güvenilir değildir. Heteroskedastisiteye dayanıklı kovaryans matrisi

$$\widehat{\mathbf{V}}_{\beta}^{HC0} = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum_{i=1}^n X_i X_i' \hat{e}_i^2 \right) (\mathbf{X}'\mathbf{X})^{-1} \quad (2.27)$$

biçimindedir. HC1, HC2 ve HC3 gibi düzeltmeler aynı temel sandviç yapısını küçük örneklem veya yüksek kaldıraç etkilerini dikkate alacak şekilde değiştirir.

Dayanıklı standart hata katsayısı değiştirmez

Aynı OLS spesifikasyonunda “robust” seçeneği $\hat{\beta}$ katsayılarını değil, tahmin edilen kovaryans matrisini ve dolayısıyla standart hata, t istatistiği, p -değeri ve güven aralığını değiştirir. Katsayının değişmesi için model, örneklem veya tahmin yöntemi değişmelidir.



Şekil 2.4: Heteroskedastisite için tipik “açılan yelpaze” artık deseni

2.6.1 Dayanıklı standart hata her sorunu çözmez

HC standart hatalar heteroskedastisiteye karşı dayanıklıdır; yanlış fonksiyonel biçim, eksik değişken, endojenlik, ölçüm hatası veya gözlemler arası bağımlılığı otomatik olarak düzeltmez. Özellikle gözlemler kümeler içinde bağımlıysa, örneğin aynı okuldan çok sayıda öğrenci gözleniyorsa, uygun çıkarım genellikle küme-dayanıklı kovaryans matrisi gerektirir. Hansen’in kümelenmiş örneklem tartışması bu ayrımı vurgular (Hansen, 2021).

Heteroskedastisiteye dayanıklı kovaryans matrisi, katsayı tahmininin hedefini değiştirmez; yalnızca belirli türde koşullu varyans yanlış belirtimine karşı belirsizlik hesabını düzeltir. Eğer modelde önemli bir değişken eksikse, açıklayıcı değişken hata terimiyle ilişkiliyse veya örneklem

seçimi varsa robust standart hata bu yanlışlıkları ortadan kaldırmaz. “Robust” sözcüğünün kapsamı bu nedenle açıkça belirtilmelidir: burada dayanıklılık, hata varyansının X ’e göre sabit olmamasına yöneliktir.

Temel mesaj, standart hata seçiminin veri yapısı ve örneklem tasarımıyla uyumlu olması gerektiğidir; tek bir “robust” seçeneği bütün bağımlılık biçimlerini kapsamaz.

Denklem (2.27) “ekmek-iç-ekmek” sandviç yapısı olarak anılır. Varyantları şöyle ayrılır: HC1 küçük örneklem serbestlik derecesi düzeltmesi olarak artık karelerini $n/(n - k)$ ile çarpar; HC2 her artık karesini $1 - h_{ii}$ ile böler; HC3 ise $(1 - h_{ii})^2$ ile böler. Buradaki h_{ii} , **Denklem (2.10)** ile tanımlanan kaldıraç değeridir. Son ikisi yüksek kaldıraçlı gözlemlerde varyansın aşağı yönlü yanlışlığını azaltmayı amaçlar ve küçük örneklemde daha ihtiyatlıdır.

Klasik ve dayanıklı standart hatanın birbirine yakın çıkması homoskedastisitenin kanıtı değildir; yalnız o örneklem ve o katsayı için iki hesabın benzer sonuç verdiğini gösterir. Fark büyükse hangi kovaryans yapısının veri üretim sürecine uygun olduğu gerekçelendirilmelidir.

2.7 Kümelenmiş Bağımlılık ve Küme-Dayanıklı Çıkarım

Heteroskedastisite, farklı gözlemlerin hata varyanslarının farklı olmasıydı. Şimdi daha ciddi bir sorunu ele alıyoruz: farklı gözlemlerin hataları birbiriyle *ilişkili* olabilir.

Bu durum ekonomik veride istisna değil, kuraldır. Aynı okuldaki öğrenciler ortak öğretmen ve müfredat şoklarına maruz kalır. Aynı ilde faaliyet gösteren firmalar ortak yerel talep şoku yaşar. Aynı hanenin bireyleri ortak gelir şoku paylaşır. Bu gözlemler bağımsız değildir.

Kümelenmiş örneklem

Gözlemler $g = 1, \dots, G$ kümelerine ayrılın ve küme g içinde n_g gözlem bulunsun. Toplam örneklem $n = \sum_{g=1}^G n_g$ ’dir. Temel varsayım, **kümelerin birbirinden bağımsız** olmasıdır. Küme *içindeki* bağımlılık yapısı ise serbest bırakılır; belirli bir biçim varsayılmaz.

Bu varsayımın nereden geldiğine dikkat edin. Bağımsızlık artık gözlem düzeyinde değil, küme düzeyinde kurulur. Dolayısıyla “kaç gözlem var?” sorusunun yerini “kaç bağımsız bilgi birimi var?” sorusu alır.

2.7.1 Katsayı değişmez, belirsizlik değişir

Küme g ’ye ait gözlemleri yığarak $\mathbf{Y}_g$ ($n_g \times 1$), $\mathbf{X}_g$ ($n_g \times k$) ve $\mathbf{e}_g$ ($n_g \times 1$) yazalım. Model

$$\mathbf{Y}_g = \mathbf{X}_g\beta + \mathbf{e}_g, \quad E[\mathbf{X}_g'\mathbf{e}_g] = 0$$

biçimindedir. OLS tahmin edicisi değişmez:

$$\hat{\beta} = \left(\sum_{g=1}^G \mathbf{X}_g' \mathbf{X}_g \right)^{-1} \left(\sum_{g=1}^G \mathbf{X}_g' \mathbf{Y}_g \right).$$

Değişen şey, $\hat{\beta} - \beta$ ifadesindeki toplamın artık n bağımsız terimden değil G bağımsız terimden oluşmasıdır:

$$\hat{\beta} - \beta = \left(\sum_{g=1}^G \mathbf{X}_g' \mathbf{X}_g \right)^{-1} \sum_{g=1}^G \mathbf{X}_g' \mathbf{e}_g.$$

Merkezi limit teoremi burada $G \rightarrow \infty$ üzerinden uygulanır, $n \rightarrow \infty$ üzerinden değil.

2.7.2 Küme-dayanıklı kovaryans matrisi

Sandviç yapısının orta parçası, gözlem düzeyinde $X_i X_i' \hat{e}_i^2$ toplamı yerine küme düzeyinde skor toplamalarının dış çarpımı olur:

$$\widehat{\mathbf{V}}_{\beta}^{CL} = (\mathbf{X}'\mathbf{X})^{-1} \left(\sum_{g=1}^G \mathbf{X}_g' \hat{\mathbf{e}}_g \hat{\mathbf{e}}_g' \mathbf{X}_g \right) (\mathbf{X}'\mathbf{X})^{-1}. \quad (2.28)$$

Burada $\hat{\mathbf{e}}_g$, küme g 'nin OLS artıklarından oluşan vektördür.

Formülün nasıl çalıştığını görmek için orta parçayı açalım. Küme g 'nin katkısı

$$\mathbf{X}_g' \hat{\mathbf{e}}_g \hat{\mathbf{e}}_g' \mathbf{X}_g = \left(\sum_{i \in g} X_i \hat{e}_i \right) \left(\sum_{i \in g} X_i \hat{e}_i \right)' = \sum_{i \in g} \sum_{j \in g} X_i X_j' \hat{e}_i \hat{e}_j$$

şeklinde. Yani formül, küme içindeki bütün $i \neq j$ çapraz terimlerini de toplar. HC0 yalnız $i = j$ terimlerini kullanıyordu.

Küme düzeltmesi ne yapar?

HC formülü küme içi çapraz terimleri sıfır kabul eder. Küme-dayanıklı formül bunları veriden tahmin eder. Aynı kümedeki artıklar aynı yönde hareket ediyor ve regresör de küme içinde benzer değerler alıyorsa (ör. küme düzeyinde atanan bir program) çapraz terimler ortalamada pozitif ve küme-dayanıklı standart hata tipik olarak HC'den *büyük* çıkar. Pratikte en sık karşılaşılan durum budur.

Uygulamada çoğunlukla küçük örneklem düzeltmeli biçim kullanılır:

$$\widehat{\mathbf{V}}_{\beta}^{CL,c} = \frac{G}{G-1} \cdot \frac{n-1}{n-k} \cdot \widehat{\mathbf{V}}_{\beta}^{CL}.$$

Bu çarpan, küme sayısı azaldıkça standart hatayı bir miktar büyütür.

2.7.3 Ne kadar büyür? Basit bir sezgi

Özel bir durumu ele alalım: bütün kümelerin büyüklüğü m olsun, regresör küme içinde sabit olsun ve küme içi hata korelasyonu her çift için ρ olsun. Bu durumda küme-dayanıklı varyans ile klasik varyansın oranı yaklaşık

$$\tau = 1 + (m-1)\rho \quad (2.29)$$

olur. Bu büyüklüğe **tasarım etkisi** denir; standart hata oranı yaklaşık $\sqrt{\tau}$ 'dur.

Sayısal örnek düşündürücüdür. Küme başına $m = 40$ öğrenci ve mütevazı bir küme içi korelasyon $\rho = 0,10$ alalım:

$$\tau = 1 + 39 \times 0,10 = 4,9, \quad \sqrt{4,9} \approx 2,2.$$

Yani doğru standart hata, kümelenmeyi yok sayan standart hatanın yaklaşık *iki katından* fazladır. Küçük görünen bir küme içi korelasyon, çıkarımı tamamen değiştirebilir.

Sık yapılan hata

ρ küçük diye kümelenmeyi ihmal etmek yaygın ve ciddi bir hatadır. [Denklem \(2.29\)](#)'da ρ küme büyüklüğü m ile çarpılır. Büyük kümelerde küçük bir korelasyon bile standart hatayı katlar. Bu yüzden “ t istatistiği çok büyük çıktı” gözlemi, kümelenmenin dikkate alınmadığı çalışmalarda bir güven işareti değil, bir uyarı işaretidir.

2.7.4 Hangi düzeyde kümelemeli?

Bu, formülden değil araştırma tasarımından çıkan bir karardır. Üç pratik ilke:

1. **Tedavi/atama düzeyi.** Temel açıklayıcı değişken hangi düzeyde değişiyorsa, en azından o düzeyde kümelenmelidir. Program okullara atandıysa okul düzeyinde kümelenir; öğrenci düzeyinde değil.
2. **Örnekleme tasarımı.** Veri çok aşamalı örneklemele toplandıysa, birincil örnekleme birimi doğal küme adaydır.
3. **Şokların ortak olduğu düzey.** Aynı yerel piyasa, aynı sektör-yıl veya aynı hane ortak gözlenmeyen bileşen taşıyorsa bu düzey dikkate alınmalıdır.

Genel eğilim, kümeyi *gereğinden dar* değil daha geniş tanımlamak yönündedir; çünkü çok dar kümeleme bağımlılığın bir kısmını yakalayamaz. Ancak bunun bir sınırı vardır: küme sayısı azaldıkça asimptotik yaklaşım bozulur.

Sık yapılan hata

[Denklem \(2.28\)](#)'in geçerliliği $G \rightarrow \infty$ varsayımına dayanır. Küme sayısı azken (kaba bir eşik olarak $G < 30-50$) küme-dayanıklı standart hatalar aşağı yönlü yanlı olur ve t testleri nominal düzeyden (ör. yüzde 5) daha sık reddeder: testin gerçek boyutu nominal boyutunu aşar. Bu durumda $G - 1$ serbestlik dereceli t dağılımı kullanmak, wild cluster bootstrap uygulamak ([Bölüm 10](#)) veya doğrudan küme düzeyinde toplulaştırılmış veriyle analiz yapmak alternatiflerdir. Yalnız “kümeledim” demek yeterli değildir; küme sayısı da raporlanmalıdır.

Tezde nasıl raporlanmalı?

Kümelenmiş çıkarım kullanan bir tabloda üç bilgi birlikte verilmelidir: kümeleme değişkeni (“okul düzeyinde kümelenmiş”), küme sayısı G ve gözlem sayısı n . Bu üçlü olmadan okuyucu çıkarımın güvenilirliğini değerlendiremez. Bu bölümün mantığı [Bölüm 3](#)'ün DDK2011 uygulamasında, [Bölüm 8](#)'in kümeli çapraz doğrulamasında ve [Bölüm 12](#)'nin okul-kümeli çapraz uyarlamasında tekrar karşımıza çıkacaktır.

2.8 Katsayının Fonksiyonlarına Geçmek: Delta Yöntemi

Araştırma sorusunun cevabı çoğu zaman doğrudan bir katsayı değildir. Örneklerimizden birkaçı:

- log-düzey modelinde kesin yüzde etki $100\{\exp(\beta_1) - 1\}$,

- karesel modelde dönüm noktası $-\beta_1/(2\beta_2)$,
- karesel modelde belirli bir noktadaki marjinal ilişki $\beta_1 + 2\beta_2x$,
- iki katsayının oranı β_1/β_2 .

Bunların hepsi $\theta = h(\beta)$ biçiminde, tahmin edilen katsayıların doğrusal olmayan fonksiyonlarıdır. Doğal tahmin edici $\hat{\theta} = h(\hat{\beta})$ 'dir. Peki standart hatası nedir?

2.8.1 Temel sonuç

$h(\cdot)$ türevlenebilir ve β civarında türevi sıfır olmayan bir fonksiyon olsun. Birinci dereceden Taylor açılımı

$$h(\hat{\beta}) \approx h(\beta) + \mathbf{a}(\beta)'(\hat{\beta} - \beta), \quad \mathbf{a}(\beta) = \frac{\partial h(\beta)}{\partial \beta}$$

verir. Buradaki $\mathbf{a}(\beta)$, skaler h fonksiyonunun $k \times 1$ gradyanı için tanımlanan ek bir vektördür; $\hat{\mathbf{a}} = \mathbf{a}(\hat{\beta})$ 'dir. Denklem (2.23)'ü kullanarak

$$\sqrt{n}\{h(\hat{\beta}) - h(\beta)\} \xrightarrow{d} N(0, \mathbf{a}(\beta)' \mathbf{V}_\beta \mathbf{a}(\beta)) \quad (2.30)$$

elde edilir. Bu sonuç **delta yöntemi** olarak bilinir. Örneklem karşılığı, standart hatanın doğrudan hesabını verir:

$$se\{h(\hat{\beta})\} = \sqrt{\hat{\mathbf{a}}' \hat{\mathbf{V}}_\beta \hat{\mathbf{a}}}, \quad \hat{\mathbf{a}} = \frac{\partial h(\beta)}{\partial \beta} \Big|_{\beta=\hat{\beta}}. \quad (2.31)$$

Sezgi basittir. $\hat{\beta}$ küçük bir belirsizlik taşıyorsa, bu belirsizlik $h(\cdot)$ fonksiyonunun eğimiyle ölçeklenerek $\hat{\theta}$ 'ya aktarılır. Fonksiyon dik ise belirsizlik büyür; düz ise küçülür.

2.8.2 Üç somut örnek

Kesin yüzde etki. $h(\beta) = 100\{\exp(\beta_1) - 1\}$ ise $\partial h/\partial \beta_1 = 100 \exp(\beta_1)$ ve diğer türevler sıfırdır. Dolayısıyla

$$se\{100(e^{\hat{\beta}_1} - 1)\} = 100 e^{\hat{\beta}_1} se(\hat{\beta}_1).$$

Örneğin $\hat{\beta}_1 = 0,1148$ ve $se = 0,0010$ ise kesin yüzde etkinin standart hatası $100 \times 1,1216 \times 0,0010 \approx 0,11$ yüzde puandır.

Karesel modelde marjinal ilişki. $h(\beta) = \beta_1 + 2\beta_2x$ aslında doğrusaldır; türev vektörü $(1, 2x)'$ olur ve

$$\text{var}(\hat{\beta}_1 + 2x\hat{\beta}_2) = \text{var}(\hat{\beta}_1) + 4x^2 \text{var}(\hat{\beta}_2) + 4x \text{cov}(\hat{\beta}_1, \hat{\beta}_2).$$

Kovaryans terimini unutmak sık yapılan bir hatadır ve standart hatayı ciddi biçimde yanlış verir.

Oran. $h(\beta) = \beta_1/\beta_2$ için türev vektörü

$$\left(\frac{1}{\beta_2}, -\frac{\beta_1}{\beta_2^2} \right)'$$

olur. Paydadaki β_2^2 terimine dikkat edin: β_2 sıfıra yaklaştıkça standart hata hızla büyür.

Sık yapılan hata

Delta yöntemi $a(\beta) \neq 0$ ve $h(\cdot)$ 'nin β civarında düzgün olması varsayımlarına dayanır. Oran biçimindeki fonksiyonlarda payda sıfıra yakınsa birinci dereceden yaklaşım kötüleşir; tahmin edicinin gerçek dağılımı belirgin biçimde çarpık ve kalın kuyruklu olabilir. Bu, Bölüm 4'teki zayıf araç probleminin ve Bölüm 9'daki bulanık RDD'de küçük ilk aşama sıçramasının ortak matematiksel kaynağıdır. Böyle durumlarda delta yöntemi standart hatası yanıltıcıdır; zayıf tanımlamaya dayanıklı çıkarım tercih edilmelidir. Standart bootstrap da zayıf tanımlamayı onarmaz (Bölüm 10).

Delta yöntemi bu ders boyunca nerede kullanılacak?

Bu tek araç, ilerideki birçok standart hatanın ortak kaynağıdır: Bölüm 4'te Wald oranı, Bölüm 5'te Logit/Probit marjinal etkileri, Bölüm 6'da Tobit marjinal etkileri ve Bölüm 9'da bulanık RDD oranı. Yazılım bu hesapları genellikle otomatik yapar; fakat hangi fonksiyonun hangi kovaryans matrisiyle birleştirildiğini bilmek raporlamanın sorumluluğundadır.

2.9 Güven Aralığı ve Hipotez Testi

Bir katsayı için sıfır hipotezi

$$H_0 : \beta_j = \beta_{j,0}$$

olsun. Büyük örnekleme t -oranı

$$t = \frac{\hat{\beta}_j - \beta_{j,0}}{se(\hat{\beta}_j)} \quad (2.32)$$

yaklaşık standart normaldir. İki taraflı yüzde 95 güven aralığı yaklaşık

$$\hat{\beta}_j \pm 1,96 se(\hat{\beta}_j) \quad (2.33)$$

şeklinde.

Burada kritik nokta, $se(\hat{\beta}_j)$ 'nin hangi kovaryans matrisinden geldiğidir. Heteroskedastisite olasılığı varken klasik ve HC standart hatalar farklı çıkarım üretebilir; kümelenme varsa Denklem (2.28) kullanılmalıdır.

2.9.1 Testin dört temel kavramı

Test sonuçlarını doğru okumak için dört kavramı ayırmak gerekir. Bunlar ders boyunca p -değeri raporlanan her tabloda geçerlidir.

 p -değeri

Gözlenen test istatistiği t_{obs} olsun. p -değeri, sıfır hipotezi *doğruyken* en az bu kadar aşırı bir istatistik gözleme olasılığıdır. İki taraflı normal testte

$$p = 2\{1 - \Phi(|t_{obs}|)\}.$$

Örneğin $|t_{obs}| = 1,96$ için $p \approx 0,05$, $|t_{obs}| = 2,58$ için $p \approx 0,01$ 'dir.

Sık yapılan hata

p -değeri, “sıfır hipotezinin doğru olma olasılığı” *değildir*. Ayrıca “etkinin büyük olma olasılığı” da değildir. Koşullandırma yönü terstir: p -değeri, hipotez verildiğinde verinin olasılığını ölçer; verinin hipoteze verdiği olasılığı değil. Bu ayrım tez yazımında dil disiplininin temelidir.

İkinci ayrım iki hata türü arasındadır:

- **Tip I hata:** H_0 doğruyken reddetmek. Bu hatanın olasılığına testin *boyutu* (size) denir ve α ile gösterilir. Yüzde 5 düzeyinde test yaparken $\alpha = 0,05$ seçmiş oluruz.
- **Tip II hata:** H_0 yanlışken reddetmemek. Bu hatanın olasılığı β_{II} ise testin **gücü** (power) $1 - \beta_{II}$ 'dir.

Güç üç şeye bağlıdır: gerçek etkinin sıfırdan uzaklığı, standart hatanın küçüklüğü ve seçilen α . Bu nedenle güç, örneklem büyüklüğüyle artar ve gürültülü verilerde düşer.

“Anlamlı çıkmadı” ne demek değildir?

Reddedememek, sıfır hipotezinin doğru olduğunun kanıtı değildir. Düşük güçlü bir test, ekonomik olarak büyük bir etkiyi de kolayca reddedemez. Bu nedenle anlamsız bir sonucu “etki yoktur” diye raporlamak yanlıştır. Doğru raporlama güven aralığı üzerindendir: aralık dar ve sıfır etrafındaysa bu bilgilendirici bir sonuçtur; aralık çok genişse veri o soruya cevap verecek kadar bilgi taşıyor demektir.

Sık yapılan hata

Aynı veri setinde çok sayıda hipotez test edilirse, hepsi doğru olsa bile bazılarının tesadüfen reddedilmesi beklenir. Yüzde 5 düzeyinde 20 bağımsız test yapılırsa ortalama bir tanesinin “anlamlı” çıkması normaldir. Bu nedenle çok sayıda spesifikasyon deneyip yalnız anlamlı olanı raporlamak (p -hacking) geçersiz çıkarım üretir. Doğru uygulama, ana spesifikasyonu önceden belirlemek ve denenen bütün alternatifleri duyarlılık analizi olarak göstermektir.

2.9.2 Ortak hipotezler: Wald testi

Tek bir katsayı yerine

$$H_0 : \mathbf{R}\beta = \mathbf{r} \quad (2.34)$$

şeklinde q doğrusal kısıt test edilebilir. Burada $\mathbf{R}$, satır rankı q olan $q \times k$ kısıt matrisi; $\mathbf{r} \in \mathbb{R}^q$ ise bilinen kısıt vektörüdür ($q \leq k$). Wald istatistiği

$$W = (\mathbf{R}\hat{\beta} - \mathbf{r})' [\mathbf{R}\widehat{\mathbf{V}}_{\hat{\beta}}\mathbf{R}']^{-1} (\mathbf{R}\hat{\beta} - \mathbf{r}) \quad (2.35)$$

ve H_0 doğruyken büyük örnekleme

$$W \xrightarrow{d} \chi_q^2$$

olarak kullanılır.

Örneğin karesel bir modelde

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \gamma' Z + e$$

“ X ile hiçbir sistematik ilişki yok” hipotezi

$$H_0 : \beta_1 = 0, \quad \beta_2 = 0$$

şeklinde ortak test edilmelidir. Yalnızca β_2 'nin p -değerine bakmak farklı bir sorudur.

Kovaryans matrisi olarak homoskedastik $s^2(\mathbf{X}'\mathbf{X})^{-1}$ kullanılırsa Wald istatistiği (W_{hom}) iki OLS regresyonunun artık kareler toplamlarına indirgenir. SSE_u kısıtsız, SSE_r kısıtlı modelin artık kareler toplamı olsun. Doğrusal kısıtlarda

$$F = \frac{W_{hom}}{q} = \frac{(SSE_r - SSE_u)/q}{SSE_u/(n - k)} = \frac{(R_u^2 - R_r^2)/q}{(1 - R_u^2)/(n - k)} \quad (2.36)$$

olur (Hansen, 2021, Bölüm 9.14). Son eşitlik iki modelin TSS 'sinin aynı olmasını gerektirir: kısıt bazı regresörleri dışlamalı, iki model de aynı Y 'yi, aynı örnekleme ve sabit terimi kullanmalıdır. Tek kısıtta $F = t^2$ 'dir. Klasik OLS çıktısında raporlanan F , bütün eğimlerin sıfır olduğu hipotezi için bu istatistiktir: $F = \{R^2/(k - 1)\}/\{(1 - R^2)/(n - k)\}$.

Bu eşitlikler yalnız homoskedastik kovaryans matrisi için geçerlidir. HC veya küme-dayanıklı $\widehat{\mathbf{V}}_{\beta}$ ile Denklem (2.35) artık R^2 farkına indirgenmez. Heteroskedastisite altında R^2 farkından hesaplanan F geçerli çıkarım vermez; dayanıklı kovaryansla kurulan Wald testi kullanılmalıdır. Bölüm 2.1.2'deki M2–M3 karşılaştırmasında R^2 farkından hesaplanan F yaklaşık 5,40'tır ve klasik t^2 'ye eşittir ($t = 2,3236$); HC1 ile kurulan Wald istatistiği ise yaklaşık 4,48'dir.

Güven aralığı ile hipotez testi aynı örnekleme belirsizliğinin iki farklı sunumudur. İki taraflı yüzde 5 düzeyindeki $H_0 : \beta_j = \beta_{j,0}$ testi, $\beta_{j,0}$ değeri yüzde 95 güven aralığının dışında kaldığında reddedilir. Bu ilişki, yalnızca “ p -değeri 0,05'ten küçük mü?” sorusuna odaklanmak yerine tahminin büyüklüğünü ve belirsizlik aralığını birlikte yorumlamayı teşvik eder.

Bir güven aralığı “parametrenin bu örnekleme yüzde 95 olasılıkla aralıkta olduğu” anlamına gelmez. Klasik sıkı yorumda parametre sabittir; rassal olan, örneklemden örnekleme değişen aralıktır. Aynı prosedür çok sayıda bağımsız örnekleme yinelenirse, oluşturulan aralıkların yaklaşık yüzde 95'i gerçek parametreyi kapsar. Bu ayrım özellikle tez yazımında kesin olasılık dili kullanılmasını önler.

2.10 İstatistiksel ve Ekonomik Anlamlılık

Büyük örneklemelerde ekonomik olarak çok küçük katsayılar istatistiksel olarak hassas biçimde sıfırdan farklı bulunabilir. Tersine küçük örnekleme ekonomik olarak önemli bir etki geniş güven aralığı nedeniyle istatistiksel olarak belirsiz olabilir. Bu nedenle “anlamlı” kelimesi tek başına yeterli değildir.

Bir katsayıyı raporlarken en az dört bilgi birlikte düşünülmelidir:

1. işaret ve büyüklük,
2. ölçü birimi veya yüzde/esneklik yorumu,
3. standart hata ve güven aralığı,
4. ekonomik bağlamda anlamlı bir karşılaştırma ölçüğü.

Bir sonuç nasıl yazılmalı?

“Katsayı istatistiksel olarak anlamlıdır” yerine örneğin şu yapı daha bilgilendiricidir: “Eğitim katsayısı 0,074 ve HC1 standart hatası 0,012’dir. Modelin log ücret biçiminde olması nedeniyle bir ek eğitim yılı yaklaşık yüzde 7,4 daha yüksek koşullu ücretle ilişkilidir; yüzde 95 güven aralığı yaklaşık yüzde 5 ile yüzde 10 arasındadır.” Nedensel kelimeler ancak tanımlama gerekçesi varsa kullanılmalıdır.

2.11 Temel Model Tanılaması

Model tanılamasının amacı her testi mekanik olarak uygulamak değil, tahmin hedefinin ve çıkarımın hangi özelliklerinin kırılabilir olduğunu görmektir. Yatay kesit regresyonunda başlangıç için aşağıdaki kontroller yararlıdır.

2.11.1 Artıklar ve fonksiyonel biçim

Artık–tahmin grafiğinde sistematik eğrilik, doğrusal modelin koşullu ortalamaya yetersiz bir yaklaşım olduğuna işaret edebilir. Çözüm otomatik olarak daha yüksek dereceli polinom eklemek değildir; ekonomik teori ve veri aralığıyla uyumlu dönüşüm seçilmelidir.

Artık grafiğinde sistematik eğrilik, modelin koşullu ortalamadaki yapıyı tam yakalayamadığını düşündürür. Örneğin artıklar düşük ve yüksek tahminlerde pozitif, ortada negatif ise karesel bir ilişki olasıdır. Fan biçiminde artan saçılım ise heteroskedastisite sinyali olabilir. Artıklar tanı aracıdır; tek başına belirli bir alternatif modelin doğru olduğunu kanıtlamaz.

Ayrıca OLS artıklarının örnekleme regresörlere ortogonal olması, artık grafiğinin “hiç desen göstermemesi” garantisi değildir. Ortogonallik doğrusal momentleri sıfırlar; doğrusal olmayan desenler kalabilir.

2.11.2 Kaldıraç ve etkili gözlemler

Kaldıraç değeri h_{ii} (Denklemler (2.10)), gözlem i ’nin regresör uzayında ne kadar sıra dışı olduğunu ölçer. Yüksek kaldıraç tek başına hata değildir; fakat büyük artılla birleştiğinde katsayılar üzerinde güçlü etki oluşturabilir. Duyarlılık analizi “gözlemi sil ve istenen sonucu elde et” yaklaşımı değil, bulgunun belirli gözlemlere ne ölçüde dayandığını belgelemektir.

Yüksek kaldıraçlı bir gözlem, X uzayının merkezinden uzaktadır. Bu gözlem mutlaka büyük bir artışa sahip değildir ve mutlaka “hatalı” değildir. Etkili olabilmesi için hem tasarımda sıra dışı olması hem de regresyon doğrusunu kayda değer biçimde çekmesi gerekir. Bu nedenle kaldıraç, artık ve etki kavramlarını ayrı incelemek gerekir.

Bir gözlemi yalnızca sonucu değiştirdiği için silmek savunulabilir bir yöntem değildir. Önce veri hatası, ölçüm birimi, örneklem tanımı veya gerçek fakat uç bir ekonomik durum olup olmadığı araştırılmalıdır. Uç gözlem gerçekse ana analizde tutulup leave-one-out veya robustlaştırılmış alternatiflerle duyarlılık göstermek çoğu zaman daha bilimsel bir yaklaşımdır.

2.11.3 Çoklu doğrusal bağlantı

Regresörler arasında güçlü doğrusal ilişki, ceteris paribus karşılaştırma için kalan varyasyonu azaltır. Bu genellikle standart hataları büyütür fakat tek başına OLS katsayılarını yanlış yapmaz.

Kusursuz doğrusal bağlantıda ise $\mathbf{X}'\mathbf{X}$ tekildir ve katsayılar ayrı ayrı tanımlanamaz.

FWL bu etkiyi tam olarak ölçer. R_j^2 , X_j 'nin diğer regresörler (sabit dahil) üzerindeki regresyonunun R^2 'si, $\tilde{X}_{ji}$ bu regresyonun artığı ve $SST_j = \sum_i (X_{ji} - \bar{X}_j)^2$ olsun. $\sum_i \tilde{X}_{ji}^2 = SST_j(1 - R_j^2)$ olduğundan doğrusal koşullu ortalama modelinde ($E[e | X] = 0$) homoskedastisite altında

$$\text{var}(\hat{\beta}_j | \mathbf{X}) = \frac{\sigma^2}{SST_j(1 - R_j^2)}, \quad VIF_j = \frac{1}{1 - R_j^2} \quad (2.37)$$

elde edilir. VIF_j , varyansın X_j diğer regresörlerle ilişkisiz olsaydı alacağı değere oranıdır. Aynı payda HC kovaryansında da görünür: $\hat{V}_{\hat{\beta}_j}^{HC0} = \sum_i \tilde{X}_{ji}^2 \hat{e}_i^2 / (\sum_i \tilde{X}_{ji}^2)^2$. Uygulamadaki M2'de eğitim için $R_j^2 \approx 0,147$ ve $VIF_j \approx 1,17$ 'dir; eğitim katsayısının kesinliği bağlantıdan pek etkilenmez.

Tablo 2.2: Sık görülen tanılama bulguları ve doğru ilk soru

Bulgu	İlk sorulması gereken soru	Yanlış refleks
Yelpaze biçimli artıklar	Standart hata yapısı uygun mu?	Gözlemleri silmek
Eğri artık deseni	Ortalama fonksiyonu yanlış mı kurulmuş?	Yalnızca robust SE kullanmak
Yüksek kaldıraç	Sonuç birkaç gözleme mi dayanıyor?	Otomatik veri temizliği
Yüksek VIF / güçlü korelasyon	Hangi kısmi varyasyonla katsayı tanımlanıyor?	Değişkeni yalnızca VIF nedeniyle çıkarmak
Katsayı işaret değişimi	Tahmin hedefi ve kontrol seti nasıl değişti?	Bir modeli “doğru” ilan etmek

Tanılama, tek bir “model doğru mu?” testi değildir. Farklı grafik ve istatistikler farklı olası sorunlara duyarlıdır. Artık–tahmin grafiği fonksiyonel biçim ve değişen varyans hakkında ipucu verir; leverage gözlemleri açıklayıcı değişken uzayında sıra dışı noktaları gösterir; Cook tipi etkili gözlem ölçüleri bir gözlemin katsayılar üzerindeki etkisini birleştirir; VIF gibi ölçüler ise regresörler arasındaki doğrusal bağıntının katsayı belirsizliğini nasıl artırdığını özetler.

Tanılamanın amacı, sonuç görüldükten sonra istenen katsayıyı elde edene kadar modeli değiştirmek değildir. Daha sağlıklı yaklaşım, önceden makul bir ana spesifikasyon belirlemek, tanılamalarla bu spesifikasyonun hangi yönlerde kırılan olduğunu görmek ve gerekirse şeffaf duyarlılık analizleri raporlamaktır. Böylece tanılama, sonuç avcılığı yerine modelin sınırlarını anlamaya hizmet eder.

2.12 Ampirik Uygulama: Aynı Katsayı, Farklı Çıkarım

Bu bölümün uygulamasında amaç belirli bir veri setindeki sayıyı ezberlemek değil, aynı OLS katsayısının standart hata seçimine göre nasıl farklı belirsizlikle raporlanabildiğini görmek olacaktır. Ücret denkleminde

$$\log(\text{wage}_i) = \beta_0 + \beta_1 \text{education}_i + \beta_2 \text{experience}_i + \beta_3 \text{experience}_i^2 + \delta \text{female}_i + e_i \quad (2.38)$$

modelini düşünelim.

Kod iskeleti:

```
import numpy as np
```

```
import statsmodels.api as sm

# df: wage, education, experience, female degiskenlerini icersin
d = df.dropna(subset=["wage", "education", "experience", "female"]).copy()
d["lwage"] = np.log(d["wage"])
d["experience2"] = d["experience"] ** 2

X = sm.add_constant(d[["education", "experience", "experience2", "female"]])
ols = sm.OLS(d["lwage"], X).fit()
hc1 = ols.get_robustcov_results(cov_type="HC1")

print(ols.summary())
print(hc1.summary())
```

Aynı modelde karşılaştırılacak nesneler şunlardır:

1. $\hat{\beta}$ katsayılarının aynı kalıp kalmadığı,
2. klasik ve HC1 standart hataların farkı,
3. güven aralıklarının ne ölçüde değiştiği,
4. *experience* ve *experience*² terimlerinin ortak anlamlılığı,
5. deneyimin marjinal ilişkisinin

$$\hat{\beta}_2 + 2\hat{\beta}_3 experience$$

ile nasıl değiştiği,

6. log sonuç nedeniyle kukla değişken katsayısının kesin yüzde yorumunun nasıl yapıldığı.

Uygulamadaki araştırma disiplini

Önce modelin ekonomik anlamı ve katsayı ölçeği yazılır; daha sonra belirsizlik ölçüsü seçilir. “Robust kullandım, dolayısıyla model doğrudur” biçimindeki yorum kabul edilmez. Dayanıklı kovaryans matrisi yalnızca belirli bir çıkarım sorununa yanıt verir.

2.13 Ampirik Uygulama Laboratuvarı: Regresyon Tablosunu Güvenilir Okumak

Bu uygulamada Hansen’in *cps09mar* veri setinden oluşturulan 50.742 kişilik tam zamanlı çalışan örneklemine kullanacağız. Amaç yalnızca bir OLS katsayısı elde etmek değildir. Aynı araştırma sorusunun farklı spesifikasyonlarda nasıl raporlandığını, klasik ve heteroskedastisiteye dayanıklı standart hataların nasıl ayrıldığını ve bir makale tablosunun hangi sırayla okunması gerektiğini göstereceğiz (Hansen, 2021).

2.13.1 Adım 1: Araştırma sorusunu ve hedef katsayıyı açıkça tanımlamak

Basit araştırma sorumuz şudur:

Eğitim yılı ile saatlik ücret arasındaki koşullu ilişki, deneyim ve temel demografik özellikler dikkate alındığında ne ölçüdedir?

Bağımlı değişken saatlik ücretin logaritmasıdır:

$$Y_i = \log(wage_i).$$

Temel açıklayıcı değişken eğitim yılıdır. Bu bölümde eğitim katsayısını doğrudan “nedensel eğitim getirisi” olarak adlandırmıyoruz. Gözlemsel CPS verisinde yetenek, aile geçmişi ve eğitim tercihini etkileyen başka gözlenmeyen faktörler nedeniyle böyle bir yorum ek tanımlama varsayımları gerektirir. Buradaki hedef, doğrusal koşullu ilişkinin güvenilir biçimde tahmin ve rapor edilmesidir.

2.13.2 Adım 2: Birden çok spesifikasyon kurmak

Üç iç içe model kullanalım:

$$M1: \log(wage_i) = \beta_0 + \beta_1 education_i + u_i,$$

$$M2: \log(wage_i) = \beta_0 + \beta_1 education_i + \beta_2 experience_i + \beta_3 experience_i^2 \\ + \beta_4 female_i + \text{bölge} + \text{ırk/etnisite} + u_i,$$

$$M3: \log(wage_i) = \beta_0 + \beta_1 education_i + \delta(education_i \times female_i) + \dots + u_i.$$

M1 betimsel olarak en yalın ilişkidir. M2 deneyim ve demografik kompozisyon farklarını koşullandırır. M3 ise eğitim eğiminin kadın ve erkeklerde aynı olmak zorunda olmadığını kabul eder. Spesifikasyonların amacı “anlamlı katsayı bulmak” değil, araştırma sorusuna uygun koşullu ilişkiyi adım adım görünür kılmaktır.

2.13.3 Adım 3: Katsayı ile standart hatayı birbirinden ayırmak

Tablo 2.3: CPS uygulaması: eğitim katsayısı ve alternatif standart hatalar

Model	$\hat{\beta}_{education}$	Klasik SH	HC1 SH	R^2
M1	0,1082	0,0010	0,0011	0,1930
M2	0,1100	0,0010	0,0011	0,2828
M3	0,1083	0,0012	0,0015	0,2829


Tablo 2.3’te ilk okunması gereken sütun katsayıdır. M2’de eğitim katsayısı 0,1100’dür. Bağımlı değişken logaritmik olduğundan bu katsayı yaklaşık yüzde 11’lik bir ücret farkıyla ilişkilidir. Daha kesin dönüşüm

$$100\{\exp(0,1100) - 1\} \approx 11,63$$

olarak hesaplanır. Yani aynı kontrol değişkenleri sabit tutulduğunda bir ek eğitim yılı, örnekleme yaklaşık yüzde 11,6 daha yüksek saatlik ücretle ilişkilidir.

İkinci adım standart hatadır. HC1 kullanıldığında *katsayı değişmez*; yalnızca tahminin belirsizliği yeniden hesaplanır. Bu ayrım önemlidir. “Robust regresyon yaptım ve katsayı düzeldi” ifadesi genel olarak yanlıştır. Burada değişen tahmin edici değil, kovaryans matrisidir.

Şekil 2.5, üç modelde eğitim katsayısının yaklaşık aynı bölgede kaldığını gösterir. Bu, tek başına modelin doğru olduğu anlamına gelmez; fakat gözlenen katsayının temel kontrol setine karşı büyük ölçüde istikrarlı olduğunu gösteren yararlı bir spesifikasyon bulgusudur.



Şekil 2.5: CPS uygulamasında eğitim katsayısının spesifikasyona göre değişimi; çubuklar yüzde 95 HC1 güven aralıklarını gösterir

2.13.4 Adım 4: Heteroskedastisite tanısını makale diliyle okumak

M2 artıklarına Breusch–Pagan testi uygulandığında LM istatistiği yaklaşık 175,16 ve p-değeri 10^{-23} mertebesinde. Bu sonuç homoskedastisite varsayımıyla güçlü biçimde uyumsuz. Ancak buradan iki yanlış sonuç çıkarılmamalıdır:

1. Heteroskedastisite bulunması OLS katsayısını otomatik olarak yanlış yapmaz.
2. Robust standart hata kullanmak da eksik değişken veya içsellik problemini çözmez.

Bu örnekte doğru raporlama “heteroskedastisite bulunduğu için model geçersizdir” değil; “çıkarım heteroskedastisiteye dayanıklı standart hatalarla yapılmıştır” biçimindedir.

2.13.5 Adım 5: Etkileşim katsayısını doğru yorumlamak

M3'te erkekler referans grup olduğunda eğitim katsayısı yaklaşık 0,1083, eğitim–kadın etkileşimi ise 0,0044'tür. Dolayısıyla kadınlar için eğitim eğimi

$$0,1083 + 0,0044 \approx 0,1127$$

olur. İki katsayıyı ayrı ayrı yorumlamak yerine ilgili doğrusal birleşim hesaplanmalıdır. Bu örnekte etkileşim katsayısı küçük olmakla birlikte temel ders daha geneldir: etkileşimli modellerde ana etki, diğer etkileşim değişkeninin referans düzeyindeki eğimdir.

2.13.6 Adım 6: Yazılımda güvenilir standart hatayı açıkça istemek

Kod 2.1: CPS regresyonunda HC1 standart hatalarının hesaplanması

```
import statsmodels.formula.api as smf

m = smf.ols(
    "lwage ~ education + experience + experience2_100 + "
```

```
"female + C(region) + C(race) + hisp",
data=df,
).fit(cov_type="HC1")

print(m.summary())
```

Burada `cov_type="HC1"` katsayı denkleminde yeni bir değişken eklemeyiz. Aynı OLS katsayıları üzerinde heteroskedastisiteye dayanıklı standart hata hesabını etkinleştirir. Bir makalede “robust standart hatalar” ifadesini gördüğümüzde hangi robust türünün kullanıldığı ve veri kümesi ise kümelenme biriminin ne olduğu ayrıca kontrol edilmelidir.

2.13.7 Adım 7: Bir makale tablosunu hangi sırayla okumalıyız?

Uygulamalı bir regresyon tablosunda şu sıra oldukça güvenlidir:

1. **Bağımlı değişkeni kontrol edin.** Düzey mi, logaritma mı, oran mı?
2. **Temel katsayının birimini belirleyin.** Bir birimlik X değişimi ne demektir?
3. **Standart hata türünü bulun.** Klasik, HC, küme-robust veya bootstrap mı?
4. **Güven aralığı/p-değerini okuyun.** Yalnız yıldız sayısına bakmayın.
5. **Sütunlar arası spesifikasyon farkını okuyun.** Hangi kontroller eklenmiş veya çıkarılmış?
6. **Ekonomik büyüklüğü değerlendirin.** İstatistiksel olarak çok hassas ama ekonomik olarak küçük bir etki olabilir.
7. **Tanımlama dilini denetleyin.** Gözlemsel koşullu ilişki nedensel etki diye sunuluyor mu?

Bir tezde sonuç paragrafı nasıl yazılabilir?

“HC1 standart hataları kullanılan temel spesifikasyonda eğitim katsayısı 0,110 olarak tahmin edilmiştir. Bu değer, deneyim ve gözlenen demografik özellikler sabit tutulduğunda bir ek eğitim yılının saatlik ücrette yaklaşık yüzde 11,6 daha yüksek bir değerle ilişkili olduğunu göstermektedir. Katsayı alternatif spesifikasyonlarda benzer büyüklüktedir. Bununla birlikte CPS gözlemsel veri olduğundan, sonuç ek bir tanımlama stratejisi olmaksızın eğitimin nedensel getirisi olarak yorumlanmamaktadır.”

2.13.8 Kendi analizinizde uygulanacak pratik protokol

1. Araştırma sorusunu ve temel katsayının hedeflediği ilişkiyi yazılı olarak tanımlayın.
2. Regresyon çalıştırmadan önce bağımlı ve açıklayıcı değişkenlerin birimlerini kontrol edin.
3. Bir temel spesifikasyon ve ekonomik gerekçesi olan alternatif spesifikasyonlar belirleyin.
4. Veri yapısına uygun standart hata kullanın; yatay kesitte heteroskedastisiteye, kümeli tasarımda küme bağımlılığına dikkat edin.
5. Katsayı, standart hata, güven aralığı, örneklem büyüklüğü ve kontrol setini aynı tabloda görünür kılın.

6. Sonuç paragrafında önce büyüklüğü, sonra belirsizliği, en son nedensel yorum sınırını tartışın.

2.14 Temel Sonuçlar

1. Çoklu regresyon katsayısı, diğer regresörlerin doğrusal katkısı ayrıştırıldıktan sonra kalan varyasyonla tanımlanır. FWL teoremi bu ceteris paribus yapıyı açıklar.
2. Sabit terimli OLS'de $TSS = ESS + SSE$ 'dir ve $R^2 = 1 - SSE/TSS$ örneklem varyasyonunun açıklanan payıdır. R^2 iç içe modellerde azalamaz; bu yüzden model seçimi, nedensellik veya kesinlik ölçütü değildir. Uyum raporlanacaksa dışarıda-bırak $\tilde{R}^2$ daha bilgilendiricidir.
3. Fonksiyonel biçim katsayısının ölçü birimini belirler. Düzey, logaritma, karesel terim, kukla ve etkileşimler farklı yorum kuralları gerektirir.
4. Eksik değişken yanlılığının temel formülü $\tilde{\beta}_1 - \beta_1 = \beta_2 \pi_1$ 'dir. Hem eksik değişkenin sonucu etkilemesi hem de ilgili regresörle ilişkili olması gerekir.
5. OLS'nin büyük örneklem kovaryans matrisi genel olarak $Q_{XX}^{-1} \Omega Q_{XX}^{-1}$ biçimindedir. Homoskedastisite bunun özel durumudur.
6. Heteroskedastisiteye dayanıklı standart hata OLS katsayısını değiştirmez; katsayı belirsizliğinin tahminini değiştirir.
7. Dayanımlı standart hata yanlış model, endojenlik veya kümelenmiş bağımlılık gibi diğer sorunların genel çözümü değildir.
8. Tek katsayı testleri ile ortak hipotezler farklıdır. $R\beta = r$ biçimindeki kısıtlar Wald testiyle birlikte sınanabilir.
9. İstatistiksel anlamlılık ekonomik büyüklükten ayrı değerlendirilmelidir. Katsayı, güven aralığı ve ekonomik ölçek birlikte raporlanmalıdır.
10. Tanılama, sonuç istenen yönde olmadığı için model değiştirme aracı değil, spesifikasyon ve çıkarım kırılganlıklarını görünür kılma sürecidir.

2.15 Bölüm Sonu Egzersizleri

Egzersiz 2.1: FWL ve ceteris paribus

$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + e$ modelinde X_1 'in X_2 üzerindeki doğrusal projeksiyon artıklarını r_1 ile gösteriniz.

1. $\text{cov}(r_1, X_2) = 0$ sonucunu açıklayınız.
2. $\beta_1 = \text{cov}(r_1, Y) / \text{var}(r_1)$ ifadesinin ceteris paribus yorumunu nasıl desteklediğini yazınız.
3. X_1 ile X_2 neredeyse kusursuz ilişkiliyse neden $\hat{\beta}_1$ hassaslaşabilir?

Egzersiz 2.2: Fonksiyonel biçimler

Aşağıdaki modellerin her birinde $\beta_1 = 0,12$ olsun. X 'te bir birim veya yüzde 1 değişimin Y ile ilişkisini uygun ölçekte yorumlayınız:

1. $Y = \beta_0 + \beta_1 X + e$,
2. $\log Y = \beta_0 + \beta_1 X + e$,
3. $Y = \beta_0 + \beta_1 \log X + e$,
4. $\log Y = \beta_0 + \beta_1 \log X + e$.

Log-düzey modelinde kesin yüzde değişimi de hesaplayınız.

Egzersiz 2.3: Karesel model

$$\hat{Y} = 4 + 2,4X - 0,15X^2.$$

1. Marjinal ilişkiyi türetiniz.
2. $X = 2$, $X = 5$ ve $X = 8$ için marjinal ilişkiyi bulunuz.
3. Dönüm noktasını hesaplayınız.
4. Yalnızca 2,4 katsayısını " X 'in etkisi" olarak raporlamak neden yanlıştır?

Egzersiz 2.4: Etkileşimli model

$$\hat{Y} = 12 + 1,5X + 4D - 0,6XD.$$

1. $D = 0$ ve $D = 1$ için ayrı regresyon doğrularını yazınız.
2. $X = 3$ ve $X = 8$ için iki grup arasındaki koşullu farkı hesaplayınız.
3. Grupların hangi X değerinde aynı tahmini verdiğini bulunuz.

Egzersiz 2.5: Eksik değişken yanlılığının yönü

Gerçek modelde $Y = \beta_0 + \beta_1 X + \beta_2 Z + u$ olsun. Aşağıdaki dört durumda Z dışarıda bırakıldığında X katsayısının yukarı, aşağı veya yanlı olmayan yönde olup olmadığını belirleyiniz:

1. $\beta_2 > 0$, $\pi_1 > 0$,
2. $\beta_2 < 0$, $\pi_1 > 0$,
3. $\beta_2 < 0$, $\pi_1 < 0$,
4. $\beta_2 > 0$, $\pi_1 = 0$.

Egzersiz 2.6: Sandviç kovaryans matrisi

Genel asimptotik kovaryans matrisinin

$$\mathbf{V}_\beta = \mathbf{Q}_{XX}^{-1} \mathbf{\Omega} \mathbf{Q}_{XX}^{-1}$$

olduğunu kabul ediniz. Homoskedastisite altında $\mathbf{\Omega} = \sigma^2 \mathbf{Q}_{XX}$ olduğunu kullanarak $\mathbf{V}_\beta = \sigma^2 \mathbf{Q}_{XX}^{-1}$ sonucunu türetiniz. Heteroskedastisite varsa bu sadeleşmenin neden geçerli olmadığını açıklayınız.

Egzersiz 2.7: Klasik ve HC standart hata

Bir katsayı için $\hat{\beta} = 0,080$ bulunmuştur. Klasik standart hata 0,020, HC1 standart hata 0,035'tir.

1. Her iki standart hata altında t istatistiğini hesaplayınız.
2. Yaklaşık yüzde 95 güven aralıklarını bulunuz.
3. Katsayının neden aynı kaldığını, fakat çıkarımın değiştiğini açıklayınız.

Egzersiz 2.8: Wald testi

$\hat{\beta} = (0,10, 0,04)'$ ve iki katsayının kovaryans matrisi

$$\widehat{\mathbf{V}}_{\hat{\beta}} = \begin{pmatrix} 0,0025 & 0,0004 \\ 0,0004 & 0,0009 \end{pmatrix}$$

olsun. $H_0 : \beta_1 = \beta_2 = 0$ hipotezi için $\mathbf{R} = \mathbf{I}_2$ ve $r = 0$ kullanarak Wald istatistiğinin nasıl kurulacağını yazınız. Sayısal matrisi terslemek zorunlu değildir; her parçanın boyutunu belirtiniz.

Egzersiz 2.9: Kümelenmiş standart hata

Bir eğitim programı 60 okula rassal atanmıştır. Örnekleme okul başına ortalama 45 öğrenci, toplam 2.700 gözlem vardır. Program göstergesi okul düzeyinde sabittir.

1. Neden öğrenci düzeyinde bağımsızlık varsayımı burada savunulamaz?
2. Küme içi hata korelasyonu $\rho = 0,08$ ise [denklem \(2.29\)](#) ile tasarım etkisini ve standart hata oranını hesaplayınız.
3. HC1 standart hata 0,021 bulunmuşsa küme-dayanıklı standart hata yaklaşık ne olur?
4. Küme sayısının 60 olması hangi açıdan bir uyarı işaretidir ve ne yapılabilir?

Egzersiz 2.10: Delta yöntemi

Bir log ücret regresyonunda $\hat{\beta}_{exp} = 0,036$, $\hat{\beta}_{exp^2} = -0,00058$ bulunmuştur. Kovaryans

matrisi

$$\widehat{\text{var}} \begin{pmatrix} \hat{\beta}_{exp} \\ \hat{\beta}_{exp^2} \end{pmatrix} = \begin{pmatrix} 6,4 \times 10^{-7} & -1,1 \times 10^{-8} \\ -1,1 \times 10^{-8} & 2,6 \times 10^{-10} \end{pmatrix}$$

olsun.

1. $x = 10$ yılında marjinal ilişkiyi $\hat{\beta}_{exp} + 2x\hat{\beta}_{exp^2}$ ile hesaplayınız.
2. Bu büyüklüğün standart hatasını delta yöntemiyle bulunuz. Gradyan vektörünü açıkça yazınız.
3. Kovaryans terimini ihmal etseydiniz standart hata ne olurdu? Farkı yorumlayınız.
4. Dönüm noktası $-\hat{\beta}_{exp}/(2\hat{\beta}_{exp^2})$ için delta yöntemi standart hatası hangi durumda güvenilirmez olur?

Egzersiz 2.11: p -değeri ve güç

Bir araştırmacı 12 farklı kontrol setiyle aynı katsayıyı tahmin etmiş, yalnız $p = 0,03$ veren spesifikasyonu raporlamıştır.

1. Bu uygulama neden geçersiz çıkarım üretir?
2. Bütün hipotezler doğruyken yüzde 5 düzeyinde 12 bağımsız testten en az birinin reddedilme olasılığını yaklaşık olarak hesaplayınız.
3. Aynı araştırmacı başka bir değişken için $p = 0,42$ bulup “etki yoktur” sonucuna varmıştır. Bu ifade neden yanlıştır ve yerine ne yazılmalıdır?

Egzersiz 2.12: İstatistiksel ve ekonomik anlamlılık

Bir politika değişkeninin büyüme oranı üzerindeki katsayısı 0,003 ve standart hatası 0,0007 bulunmuştur. Değişkenin gerçekçi politika aralığının yalnızca 0 ile 0,2 arasında olduğunu varsayınız. Sonucun istatistiksel ve ekonomik anlamlılığını ayrı ayrı tartışınız.

Egzersiz 2.13: Model tanılaması

Bir OLS modelinde artık-tahmin grafiği belirgin U biçimi, ayrıca birkaç gözlem yüksek kaldıraç göstermektedir. Araştırmacı yalnızca HC3 standart hata kullanıp modeli değiştirmeden raporlamak istemektedir.

1. HC3 hangi soruna yanıt verebilir?
2. U biçimli deseni neden çözmez?
3. Yüksek kaldıraç gözlemleri için hangi duyarlılık analizi yapılabilir?

Egzersiz 2.14: Log kukla katsayısı

$\log Y = \beta_0 + \delta D + \beta'X + e$ modelinde $\hat{\delta} = -0,18$ bulunmuştur. Yaklaşık yüzde yorum ile kesin yüzde yorumu karşılaştırınız. İki yorum arasındaki farkın neden küçük katsayılarla azaldığını açıklayınız.

Egzersiz 2.15: Ampirik raporlama

Bir tez tablosunda şu bilgiler verilmiştir: eğitim katsayısı 0,065, HC1 standart hata 0,014; bağımlı değişken log ücret; deneyim ve deneyimin karesi modelde yer almaktadır. Bu sonucu iki cümleyle bilimsel biçimde raporlayınız. Birinci cümlede büyüklük ve belirsizliği, ikinci cümlede nedensel yorum için gerekli ihtiyatı belirtiniz.

Egzersiz 2.16: R^2 , düzeltilmiş R^2 ve F

Sabit terimli bir OLS modelinde $n = 125$, sabit dahil $k = 5$, $TSS = 400$ ve $SSE = 300$ 'dür.

1. ESS ve R^2 'yi bulunuz.
2. $\bar{R}^2$ 'yi hesaplayınız.
3. Bütün eğim katsayılarının sıfır olduğu hipotezi için klasik F istatistiğini R^2 ile hesaplayınız.
4. Modele bir regresör daha eklenince $SSE = 297$ olmuştur. R^2 ve $\bar{R}^2$ nasıl değişir? Yeni regresörün klasik t istatistiğinin mutlak değerini bulunuz ve $\bar{R}^2$ 'deki değişimle ilişkilendiriniz.

Egzersiz 2.17: R^2 'yi doğru karşılaştırmak

1. Sabit terimli modelde R^2 'nin Y ile $\hat{Y}$ arasındaki örneklem korelasyonunun karesine eşit olduğunu gösteriniz.
2. Sabit terim yoksa $TSS = ESS + SSE$ ayrıştırmasının hangi adımda bozulduğunu gösteriniz. Bu durumda yazılımların raporladığı R^2 hangi toplamı kullanır?
3. Bir araştırmacı log ücret modelinin R^2 'sini (0,27) ücret düzeyi modelinin R^2 'siyle (0,21) karşılaştırıp log modelin “daha iyi uyum” verdiğine karar vermiştir. Bu karşılaştırma neden geçersizdir?
4. Bir regresyonda $n - k = 400$ ve bir regresörün klasik t istatistiği 4'tür. Bu regresörün kısmi R^2 'sini hesaplayınız. Düşük kısmi R^2 ile yüksek t istatistiği birlikte nasıl yorumlanır?
5. Bir regresörün diğer regresörler üzerindeki regresyonunda $R_j^2 = 0,9$ bulunmuştur. VIF_j değerini ve bu regresörün homoskedastik standart hatasının, ilişkisiz regresör durumuna göre kaç kat büyüdüğünü hesaplayınız.

Tanımlama, Nedensellik ve İçsellik

Bu bölümün amacı

Bu bölümün sonunda bir ampirik çalışmada tahmin hedefi (estimand), tanımlama (identification), tahmin edici (estimator) ve tahmin (estimate) kavramlarını birbirinden ayırabilecek; potansiyel sonuçlar çerçevesinde bireysel ve ortalama nedensel etkileri tanımlayabilecek; gözlenen grup farkını tedavi etkisi ve seçim bileşenlerine ayırabilecek; koşullu bağımsızlık ve ortak destek varsayımlarının nedensel karşılaştırmayı nasıl tanımladığını açıklayabilecek; doğrusal projeksiyon parametresi ile yapısal/nedensel parametre arasındaki farkı matematiksel olarak gösterebilecek; eksik değişken, ters nedensellik, eşanlılık, ölçüm hatası ve seçim yoluyla içsellik nasıl ortaya çıktığını analiz edebilecek; OLS'nin içsellik altında hangi parametreye yakınsadığını gösterebilecek ve bir nedensel araştırma sorusunu tahmin yöntemine geçmeden önce tanımlama stratejisi açısından değerlendirebileceksiniz.

Bağlantı

Bölüm 2'de çoklu regresyon katsayısının diğer regresörlerden arındırılmış doğrusal ilişkiyi ölçtüğünü ve güvenilir standart hatanın ayrı bir çıkarım problemi olduğunu gördük. Fakat bir katsayının hassas biçimde tahmin edilmesi onun nedensel bir parametreyi ölçtüğünü garanti etmez. Bu bölümde “hangi katsayıyı tahmin ediyoruz?” sorusundan önce gelen daha temel soruyu ele alıyoruz: *Gözlenen veri dağılımı, öğrenmek istediğimiz nedensel büyüklüğü gerçekten belirliyor mu?*

3.1 Dört Ayrı Kavram: Tahmin Hedefi, Tanımlama, Tahmin Edici ve Tahmin

Ampirik araştırmada birbirine benzeyen dört kavramın ayrılması metodolojik disiplin sağlar.

Tahmin hedefi (estimand)

Araştırmacının anakütlede öğrenmek istediği büyüklüktür. Örneğin bir ortalama, regresyon katsayısı, ortalama nedensel etki, marjinal etki veya kantil farkı bir tahmin hedefi (estimand) olabilir.

Tanımlama (identification)

Bir tahmin hedefinin gözlenen verinin olasılık dağılımı ve açıkça belirtilen varsayımlar tarafından tekil biçimde belirlenmesidir. Hansen'in tanımında bir parametre θ , gözlenen veri dağılımı F 'nin bir fonksiyonu olarak tekil biçimde yazılabiliyorsa tanımlıdır: $\theta = g(F)$ (Hansen, 2021).

Tahmin edici ve tahmin

Tahmin edici, örneklem verisinin bir fonksiyonu olan rassal kuraldır; örneğin $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}$. Belirli örnekleme elde edilen sayısal değer tahmindir.

Bu ayrım şu sıralamayı zorunlu kılar:

$$\begin{aligned} \boxed{\text{Araştırma sorusu}} &\longrightarrow \boxed{\text{Estimand}} \longrightarrow \boxed{\text{Tanımlama}} \\ \boxed{\text{Tanımlama}} &\longrightarrow \boxed{\text{Tahmin edici}} \longrightarrow \boxed{\text{Tahmin ve çıkarım}}. \end{aligned} \quad (3.1)$$

Bir yöntem çok gelişmiş olsa bile estimand tanımlı değilse sorun çözülmez. Daha fazla veri, tanımlama eksikliğini tek başına gidermez; yalnızca gözlenen dağılımı daha hassas öğrenmemizi sağlar.

Bu ayrım yöntem seçimini de düzenler. Bir parametre tanımlanmamışsa daha karmaşık bir tahmin edici kullanmak sorunu çözmez. Buna karşılık parametre tanımlanmış olsa bile kötü sonuçlu örneklem özelliklerine sahip bir tahmin edici büyük belirsizlik yaratabilir. Örneğin geçerli fakat çok zayıf bir araç altında IV hedefi teorik olarak tanımlı olabilir; ancak örnekleme 2SLS tahmini son derece oynak olabilir. Dolayısıyla “yöntem çalıştı mı?” sorusunu hem tanımlama hem tahmin açısından ayrı değerlendirmek gerekir.

3.2 Nedensel Etki: Gözlenen Sonuçtan Farklı Bir Nesne

Hansen, nedensel etkiyi açıklamak için Rubin potansiyel sonuçlar çerçevesini kullanır (Hansen, 2021). İkili bir tedavi veya politika göstergesi

$$D \in \{0, 1\}$$

olsun. Her birey için iki potansiyel sonuç tanımlayalım:

$$Y_1 : \text{tedavi altında ortaya çıkacak sonuç}, \quad Y_0 : \text{tedavi yokken ortaya çıkacak sonuç}.$$

Bireysel nedensel etki

$$\theta = Y_1 - Y_0 \quad (3.2)$$

ve ortalama nedensel etki

$$ATE = E[Y_1 - Y_0] \quad (3.3)$$

olarak tanımlanır. Hansen aynı fikri average causal effect (ACE) terimiyle ifade eder; burada yaygın uygulamalı literatürle uyumlu olarak ATE kısaltmasını kullanacağız.


Gerçekte ise her birey için yalnızca

$$Y = DY_1 + (1 - D)Y_0 \quad (3.4)$$

gözlenir. $D = 1$ olan birey için Y_1 gözlenir, Y_0 karşı-olgusaldır; $D = 0$ için bunun tersi geçerlidir.

Nedensel çıkarımın temel problemi

Bireysel nedensel etki $Y_1 - Y_0$ aynı birey için iki karşıt durumda ortaya çıkacak sonuçları gerektirir. Aynı anda yalnızca biri gözlenebildiği için nedensel etki doğrudan gözlenen bir veri sütunu değildir.



Şekil 3.1: Bir birey için karşı-olgusal sonucun gözlenememesi

Bu nedenle nedensel etki bir regresyon katsayısıyla tanım gereği aynı şey değildir. Regresyon katsayısının nedensel etkiyi temsil etmesi için, gözlenen tedavi ve kontrol birimleri arasındaki farkın karşı-olgusal karşılaştırmayı geçerli biçimde taklit ettiğini gösteren bir tanımlama argümanı gerekir. Rassal deney, koşullu bağımsızlık, araçsal değişken veya RDD gibi tasarımlar bu argümanı farklı yollarla kurar.

3.3 Ham Grup Farkı Neyi Ölçer?

Tedavi gören ve görmeyen grupların ortalamalarını karşılaştırmak doğal bir başlangıçtır:

$$\Delta_{obs} = E[Y | D = 1] - E[Y | D = 0]. \quad (3.5)$$

Ancak bu farkın ATE veya tedavi görenler üzerindeki ortalama etki (ATT) ile eşit olması için ek koşullar gerekir.

Tedavi görenler için

$$E[Y | D = 1] = E[Y_1 | D = 1],$$

tedavi görmeyenler için

$$E[Y | D = 0] = E[Y_0 | D = 0].$$

Bir terim ekleyip çıkarırsak

$$\Delta_{obs} = E[Y_1 | D = 1] - E[Y_0 | D = 0] \quad (3.6)$$

$$= \underbrace{E[Y_1 - Y_0 | D = 1]}_{ATT} + \underbrace{\{E[Y_0 | D = 1] - E[Y_0 | D = 0]\}}_{\text{seçim farkı}}. \quad (3.7)$$

İkinci terim, tedavi hiç uygulanmasaydı bile iki grubun ortalama sonuçlarının farklı olup

olmayacağını gösterir. Bu terim sıfır değilse ham grup farkı ATT'yi içerdiği kadar seçim farkını da içerir.

Eğitim ve ücret örneği

Üniversite mezunları lise mezunlarından daha yüksek ücret alıyorsa gözlenen ücret farkı iki bileşeni karıştırabilir: üniversite eğitiminin gerçek getirisi ve üniversiteye gitme olasılığını da etkileyen yetenek, aile arka planı, motivasyon veya fırsat farkları. Hansen'in eğitim örneğinin temel mesajı tam olarak budur: tedavi seçimi gözlenemeyen özelliklerle ilişkiliyse regresyon farkı nedensel etki olmak zorunda değildir (Hansen, 2021).

Rassal atama bu seçim farkını sıfırlar; gözlemsel tasarımlar ise koşullandırma, araçsal değişken veya başka bir mekanizma ile karşı-olgusal bileşeni tanımlamaya çalışır.

3.4 Rassal Atama Neden Güçlüdür?

Eğer tedavi rassal atanıyorsa

$$D \perp\!\!\!\perp \{Y_0, Y_1\} \quad (3.8)$$

olur. Bu durumda tedavi ve kontrol gruplarının potansiyel sonuç dağılımları aynıdır:

$$E[Y_d | D = 1] = E[Y_d | D = 0] = E[Y_d], \quad d \in \{0, 1\}.$$

Dolayısıyla

$$E[Y | D = 1] - E[Y | D = 0] = E[Y_1] - E[Y_0] \quad (3.9)$$

$$= ATE. \quad (3.10)$$

Rassal atamanın gücü, tedaviyi gözlenemeyen potansiyel sonuçlardan ayırmasıdır. Deneysel verinin nedensel yorum için standart oluşturmasının nedeni budur.

Rassal atama, tedavi durumunu potansiyel sonuçlardan bağımsız hale getirerek seçim problemi tasarım aşamasında çözer. İdeal durumda

$$D \perp\!\!\!\perp \{Y_0, Y_1\}$$

olur. Böylece tedavi ve kontrol grupları, örnekleme dalgalanması dışında hem gözlenen hem gözlenmeyen özellikler bakımından karşılaştırılabilir hale gelir. Grup ortalamaları arasındaki fark, karşı-olgusal ortalama farkını tahmin eder.

Rassallık her örnekleme grupların tam eşit olacağını garanti etmez. Özellikle küçük örneklemelerde kovaryat dengesizlikleri rastlantısal olarak oluşabilir. Rassal tasarımın gücü, bu dengesizliğin sistematik seçimden değil bilinen bir atama mekanizmasından kaynaklanması ve örnekleme belirsizliği içinde değerlendirilebilmesidir. Gözlemsel veride ise tedavi kararı genellikle birey, firma veya politika yapıcının bilgi ve tercihlerine bağlıdır; bu yüzden aynı bağımsızlık sonucu doğrudan varsayılmaz.

3.5 Gözlemsel Veride Koşullandırma ile Tanımlama

Gözlemsel veride tedavi rassal olmayabilir. Fakat bazı durumlarda yeterince zengin bir gözlenen kovaryat vektörü X 'e koşullandığımızda tedavi seçimi potansiyel sonuçlardan ayrılabilir.

Koşullu bağımsızlık / seçilebilirlik

$$\{Y_0, Y_1\} \perp\!\!\!\perp D \mid X. \quad (3.11)$$

Bu koşul, aynı X değerlerinde tedavi alan ve almayan bireylerin potansiyel sonuçlar açısından karşılaştırılabilir olduğunu söyler.

Ayrıca karşılaştırmanın gerçekten yapılabilmesi için ortak destek gerekir:

$$0 < P(D = 1 \mid X = x) < 1 \quad (3.12)$$

ilgili x değerlerinde. Bu koşul, belirli kovaryat profillerinde hem tedavi hem kontrol gözlemlerinin bulunmasını ister.

Koşullu bağımsızlık altında

$$E[Y_1 \mid X = x] = E[Y \mid D = 1, X = x], \quad (3.13)$$

$$E[Y_0 \mid X = x] = E[Y \mid D = 0, X = x]. \quad (3.14)$$

Böylece koşullu ortalama nedensel etki

$$\theta(x) = E[Y_1 - Y_0 \mid X = x] = E[Y \mid D = 1, X = x] - E[Y \mid D = 0, X = x] \quad (3.15)$$

olarak tanımlanır ve

$$ATE = E_X[\theta(X)] \quad (3.16)$$

ile anakütleye ortalanabilir.

Sık yapılan hata


Koşullu bağımsızlık veriden doğrudan test edilebilen bir sonuç değildir; gözlenemeyen ortak nedenlerin kalmadığını savunan tanımlama varsayımdır. Regresyona çok sayıda kontrol eklemek bu varsayımı otomatik olarak doğru yapmaz.

Varsayımın ikna ediciliği alan bilgisi, veri toplama süreci ve değişkenlerin zamanlamasıyla savunulur; veriden okunamaz.

Ortak destek koşulunun içeriği de aynı ölçüde pratiktir. Bir alt grupta herkes tedavi almışsa, o grupta tedavisiz karşı-olgusalı veri içinden öğrenemeyiz. Çok esnek regresyon veya makine öğrenmesi bu bilgi eksikliğini gidermez; yalnızca veri desteğinin dışına ekstrapolasyon yapar. Bu nedenle propensity score dağılımı, örneklem örtüşmesi ve destek bölgeleri nedensel analizde yalnız teknik ayrıntı değil tanımlama bilgisidir.

3.6 Nedensel Diyagramla Açık Yolları Görmek

Bu dersin ana kaynağı Hansen olsa da, nedensel yapıyı görselleştirmek için basit ok diyagramları kullanmak yararlıdır. Aşağıdaki yapı klasik karıştırıcı (confounder) problemidir:



Şekil 3.2: Gözlenemeyen U hem tedaviyi hem sonucu etkilediğinde seçim/karıştırma yolu

$D \leftarrow U \rightarrow Y$ yolu açıksa, D ile Y arasındaki ilişki $D \rightarrow Y$ nedensel yoluyla birlikte U kaynaklı ilişkiyi de taşır. U gözleniyor ve uygun biçimde koşullandırılabilir; bu yol kapatılabilir; U gözlenemiyorsa basit regresyon kontrolü yetersiz kalabilir.

3.7 Doğrusal Projeksiyon Parametresi ile Yapısal Parametre

İçsellik kavramını doğru anlamak için Hansen’in yaptığı ayrım kritiktir (Hansen, 2021). Yapısal denklem

$$Y = X'\beta + e \quad (3.17)$$

olsun ve β , araştırmacının ekonomik veya nedensel modeli tarafından tanımlanan yapısal parametre olsun. Eğer

$$E[Xe] \neq 0, \quad (3.18)$$

ise X , β için endojendir.

Buna karşılık Y ’nin X üzerine doğrusal projeksiyon katsayısını

$$\beta^* = \{E[XX']\}^{-1} E[XY]$$

olarak tanımlarsak, projeksiyon hatası $e^* = Y - X'\beta^*$ tanım gereği

$$E[Xe^*] = 0$$

koşulunu sağlar. Dolayısıyla “projeksiyon katsayısı için endojenlik” diye bir sorun yoktur; sorun, projeksiyon katsayısının araştırmacının istediği yapısal parametreye eşit olmamasıdır.

Yapısal denklemi kullanarak

$$\beta^* = \{E[XX']\}^{-1} E[X(X'\beta + e)] \quad (3.19)$$

$$= \beta + \{E[XX']\}^{-1} E[Xe]. \quad (3.20)$$

İçsellik varsa ikinci terim sıfır değildir ve

$$\beta^* \neq \beta.$$

OLS ise uygun koşullarda β^* 'ya yakınsar:

$$\hat{\beta}_{OLS} \xrightarrow{p} \beta^*. \quad (3.21)$$

Bu nedenle OLS'nin sorunu “hesaplamanın yanlış” olması değil, doğru biçimde farklı bir anakütle nesnesini tahmin etmesidir.

İçsellik bir standart hata problemi değildir

$E[Xe] \neq 0$ olduğunda robust standart hata kullanmak OLS'nin β^* yerine yapısal β 'yı tahmin etmesini sağlamaz. İçsellik katsayı hedefini değiştirir; kovaryans matrisi düzeltilmesi yalnızca belirsizlik tahminini değiştirir.

Doğrusal yapısal model

$$Y = \alpha + \theta D + X'\gamma + u$$

ve yapısal dışsallık

$$E[u \mid D, X] = 0$$

sağlanıyorsa θ koşullu ortalama parametresi ve uygun yorum altında nedensel etki olabilir. Dışsallık bozulduğunda OLS yine matematiksel olarak bir doğrusal projeksiyon katsayısı tahmin eder; fakat bu katsayı θ ile aynı olmak zorunda değildir.

Bu ayrım önemli bir terminoloji disiplini: yazılım her zaman bir katsayı üretir, ancak yapısal parametreyi yalnız tanımlama koşulları altında tahmin eder. “OLS biased” dediğimizde çoğu zaman OLS'nin kendi projeksiyon hedefi için değil, ilgilendiğimiz yapısal θ için yanlış hedefe yöneldiğini kast ediyoruz.

3.8 İçselliliğin Temel Kaynakları

İçsellik tek bir mekanizma değildir. Aynı matematiksel koşul $E[Xe] \neq 0$ farklı ekonomik yapılardan doğabilir.

3.8.1 Eksik değişken / gözlenemeyen karıştırıcı

Gerçek model

$$Y = \beta X + \gamma U + \varepsilon$$

olsun. U gözlenmediği için hata içine girerse

$$e = \gamma U + \varepsilon.$$

$\text{cov}(X, U) \neq 0$ ise

$$\text{cov}(X, e) = \gamma \text{cov}(X, U) + \text{cov}(X, \varepsilon) \neq 0$$

olabilir. Bu, Bölüm 2'deki eksik değişken yanlışlığının yapısal parametre bağlamındaki biçimidir.

Bölüm 2'de gördüğümüz iki koşul burada da geçerlidir: dışarıda bırakılan değişken hem sonucu etkilemeli hem de ilgilenilen regresörle ilişkili olmalıdır. Fark şudur: orada hedef doğrusal projeksiyon katsayısıydı, burada yapısal parametredir. Yanlılığın işareti kabaca “ U 'nun Y etkisi $\times X$ ile U ilişkisi” ile belirlenir; fakat U gözlenmediği için büyüklüğü doğrudan hesaplanamaz.

3.8.2 Ters nedensellik ve eşanlılık

Eğer X yalnızca Y 'yi etkilemiyor, aynı zamanda Y veya Y 'yi belirleyen şoklar X 'i de etkiliyorsa karşılıklı belirlenme oluşur. Hansen'in arz–talep örneği en açık durumdur: piyasa fiyatı ve miktarı aynı denge mekanizmasında birlikte belirlenir (Hansen, 2021). Miktarı fiyat üzerine OLS ile regres etmek ne saf talep ne saf arz eğrisini verir.

Basit bir eşanlı sistem

$$Q = -\beta_d P + u_d, \quad Q = \beta_s P + u_s$$

olsun. Denge fiyatı P , hem u_d hem u_s şoklarının fonksiyonudur. Dolayısıyla talep denkleminde P ile u_d genellikle korelasyonludur.

Aynı yapı piyasa dışında da görülür: reklam satışları artırabilir, fakat yüksek satış beklentisi de reklam bütçesini artırabilir. Bu durumda OLS katsayısı tek yönlü yapısal eğimi değil, iki yönlü belirlenmenin bileşkesini yansıtır.

Zaman sıralaması tek başına ters nedenselliği çözmeyebilir. Gecikmeli X kullanmak bazen eşanlılığı azaltır; ancak beklenen gelecek sonuçlar bugünkü X kararını etkiliyorsa gecikme hâlâ endojen olabilir. Tanımlama ekonomik karar mekanizmasına dayanmalıdır.

3.8.3 Seçim ve karar değişkenleri

Eğitim, yatırım, reklam harcaması veya kredi kullanımı gibi X değişkenleri ekonomik aktörlerin kararlarıysa, kararın arkasındaki gözlenemeyen beklenti ve yetenekler aynı zamanda Y 'yi etkileyebilir. Hansen'in ücret–eğitim örneğinde yüksek yetenekli bireylerin daha fazla eğitim seçmesi bu mekanizmayı oluşturur (Hansen, 2021).

Eğitim, göç, kredi kullanımı, ihracat yapma, teknoloji yatırımı ve programa katılım gibi kararlar beklenen fayda ve maliyetlere göre alınır. Kararı etkileyen fakat araştırmacının gözlemediği yetenek, risk tercihi veya yönetim kalitesi aynı zamanda sonucu da etkiliyorsa, seçimin kendisi hata terimiyle ilişkili hale gelir.

Bu nedenle “ X bireyin kendi seçimi olduğu için endojendir” ifadesi tek başına yeterli değildir; seçim mekanizmasının sonuç denklemindeki gözlenmeyen bileşenle neden bağlantılı olduğu açıklanmalıdır. İyi bir ampirik çalışma, endojenlik iddiasını ekonomik davranış mekanizmasıyla temellendirir.

3.8.4 Açıklayıcı değişkende ölçüm hatası

Gerçek regresör Z gözlenemiyor, onun yerine

$$X = Z + u \quad (3.22)$$

gözleniyor olsun. Gerçek model

$$Y = \beta Z + \varepsilon, \quad \text{cov}(Z, \varepsilon) = 0$$

ve klasik ölçüm hatasında u , Z 'den ve ε 'dan bağımsız ve ortalaması sıfır olsun. $Z = X - u$ yazarsak

$$Y = \beta X + (\varepsilon - \beta u).$$

Yeni hata terimi

$$v = \varepsilon - \beta u$$

ve

$$\text{cov}(X, v) = \text{cov}(Z + u, \varepsilon - \beta u) \quad (3.23)$$


$$= -\beta \text{var}(u). \quad (3.24)$$

Dolayısıyla $\beta \neq 0$ ve $\text{var}(u) > 0$ ise gözlenen X endojendir.

Skaler ve sabit terimli durumda OLS eğiminin olasılık limiti

$$\text{plim } \hat{\beta}_{OLS} = \beta \frac{\text{var}(Z)}{\text{var}(Z) + \text{var}(u)} \quad (3.25)$$

olur. Çarpan 0 ile 1 arasındadır; klasik ölçüm hatası katsayısı sıfıra doğru küçültür. Bu attenuation bias olarak bilinir.



Şekil 3.3: $\text{var}(Z) = 1$ iken klasik ölçüm hatasının zayıflama çarpanı

Ölçüm hatası varyansı büyüdükçe çarpan küçülür ve bilgi sinyali zayıflar. Bu sonuç yalnız klasik hata için geçerlidir. Sistemik ölçüm hatası, bağımlı değişkende regresörlerle ilişkili hata veya kategorik yanlış sınıflandırma farklı yanlışlık biçimleri oluşturabilir.

“Endojenlik testi anlamlı çıktı, IV kullanalım” gibi mekanik bir yaklaşım yerine, endojenliğin kaynağı önce ekonomik olarak tanımlanmalıdır. Kaynak önemlidir çünkü uygun çözüm değişir. Gözlenebilir karıştırıcılar yeterliyse daha zengin koşullandırma işe yarayabilir; gözlenmeyen karıştırıcılar için geçerli bir araç veya tasarım gerekebilir; klasik ölçüm hatasında araçsal değişken yararlı olabilir; sonucun yalnız seçilmiş bir alt örnekte gözlenmesi (örneklem seçimi) ise örneklem seçimi modelini gerektirebilir (Bölüm 6). Bir yöntemin adı değil, tanımlama probleminin yapısı yöntem seçimimizi belirler.

3.9 Örneklem Büyüdükçe İçsellik Kaybolur mu?

Hayır. Bu ayrım özellikle tez çalışmalarında önemlidir. Örneklem büyüdükçe OLS'nin örnekleme hatası küçülür, fakat yanlış hedefe yaklaşıyorsa sorun daha hassas bir yanlış tahmine dönüşebilir.

Skaler model

$$Y = \alpha + \beta X + e$$

ve $\text{cov}(X, e) \neq 0$ olsun. Basit regresyon eğiminin olasılık limiti

$$\text{plim } \hat{\beta}_{OLS} = \beta + \frac{\text{cov}(X, e)}{\text{var}(X)}. \quad (3.26)$$

İkinci terim örneklem büyüklüğü n ile sıfıra gitmez. Bu nedenle içsellik esas olarak bir *tutarlılık* ve *tanımlama* problemidir.

Sık yapılan hata

“Örneklemimiz çok büyük, dolayısıyla endojenlik önemli değildir” ifadesi yanlıştır. Büyük örneklem tesadüfi belirsizliği azaltır; sistematik tanımlama hatasını ortadan kaldırmaz. Aksine, tahmin yanlış hedef etrafında daha da hassas hale gelir.

Örneğin eksik yetenek değişkeni eğitim ve ücretle pozitif ilişkiliyse, milyonlarca gözlem eğitim katsayısının standart hatasını çok küçültebilir; fakat katsayı hâlâ eğitim etkisi ile yetenek farkını birlikte taşıyabilir. Büyük veri “daha fazla bilgi” sağlar, ancak hangi karşı-olgusal karşılaştırmanın geçerli olduğu sorununu kendiliğinden çözmez.

3.10 Koşullandırma Setinin Rolü

Hansen’in koşullu nedensel etki tartışmasında gözlenen kovaryatlar X , tedavi kararı ile gözlenemeyen heterojenlik U arasındaki bağı ortadan kaldıracak bilgiyi taşımaktadır (Hansen, 2021). Yapı

$$Y = h(D, X, U)$$

ve temel koşul

$$D \perp\!\!\!\perp U \mid X \quad (3.27)$$

olarak düşünülebilir. Bu durumda aynı X değerlerinde tedavi alan ve almayan bireylerin U dağılımları karşılaştırılabilir hâle gelir ve koşullu ortalama farkı koşullu nedensel etkiyi açığa çıkarabilir.

Bu yaklaşım “modele mümkün olan bütün değişkenleri eklemek” anlamına gelmez. Esas soru, X setinin tedavi seçimi ile sonuç potansiyelleri arasındaki gözlenemeyen bağımlılığı kırmak için yeterli bilgi içerip içermediğidir. Hansen’in eğitim örneğinde yetenek türü doğrudan gözlenmez; fakat tedavi seçimini belirleyen yetenek testi skoru gözlemlendiğinde eğitim seçimi ile tür arasındaki bağımlılık koşullu olarak ortadan kalkar. Böylece farklı test skoru grupları için koşullu nedensel etkiler hesaplanabilir ve anakütle paylarıyla ortalananarak toplam ortalama etkiye ulaşılabilir (Hansen, 2021).

Kontrol setinin amacı

Kontrol değişkenlerinin rolü katsayıyı “daha anlamlı” yapmak değil, savunulan tanımlama varsayımını mümkün kılan karşılaştırmayı kurmaktır. Hangi X ’lerin yeterli olduğu veri tablosundan otomatik çıkmaz; ekonomik karar mekanizmasına ilişkin bilgi gerektirir.

Kontrol değişkeni seçimi nedensel analizde tahmin performansından farklı bir mantığa sahiptir. İdeal kontrol, tedaviden önce belirlenmiş ve hem tedavi hem sonuçla ilişkili ortak nedenleri temsil eder. Buna karşılık tedavinin sonucu etkilediği bir aracı (mediator) değişkeni kontrol etmek toplam etkiyi bloke edebilir. Tedavinin ve sonucun ortak sonucu olan bir çarpışan (collider)

değişkeni kontrol etmek ise daha önce kapalı bir ilişki yolunu açarak yeni yanlılık yaratabilir.

Bu nedenle kontrol sayısının artması nedensel modelin otomatik olarak iyileştiği anlamına gelmez. “Bütün mevcut değişkenleri modele ekledim” yaklaşımı, veri bilimi açısından öngörüye yararlı olsa bile nedensel hedef için hatalı olabilir. Değişkenlerin ekonomik zamanlaması ve nedensel rolü regresyona girmeden önce düşünülmelidir.

3.11 Tanımlama ile Model Uyumunu Birbirinden Ayırmak

Yüksek R^2 , düşük RMSE veya güçlü tahmin performansı nedensel tanımlamanın kanıtı değildir. Aynı şekilde düşük R^2 nedensel katsayının geçersiz olduğu anlamına gelmez. İki amaç farklıdır:

- **Tahmin sorusu:** Y ne kadar iyi öngörülüyor?
- **Nedensel soru:** D 'ye müdahale edilse Y nasıl değişirdi?

Bir değişken çok güçlü tahminci olabilir fakat müdahale edilebilir bir neden olmayabilir. Örneğin geçmiş hastalık göstergeleri gelecekteki sağlık harcamalarını güçlü öngörebilir; bu göstergelerin idari olarak “değiştirilmesi” aynı sonucu üretmez. Ekonomide benzer ayırım kredi skoru, firma büyüklüğü, bölgesel özellikler ve eğitim seçimi gibi birçok değişkende görülür.

Tersine, rassal deneyde tedavi etkisi nedensel olarak çok temiz tanımlanmış olsa bile bireysel sonuçlar gürültülü olduğu için R^2 düşük kalabilir. Bir tezde model uyum ölçüleri nedensellik kanıtı olarak sunulmamalı; nedensel iddia ayrı bir kurum/tasarım argümanı ile kurulmalıdır.

3.12 Kontrollü Simülasyon: İçsellik Yanlılığını Görmek

Simülasyonun avantajı gerçek β değerini bilmemizdir. Aşağıdaki veri üretim süreci eksik değişken kaynaklı içsellik açıkça gösterir:

$$U_i \sim N(0, 1), \quad (3.28)$$

$$X_i = 0,8U_i + v_i, \quad v_i \sim N(0, 1), \quad (3.29)$$

$$Y_i = 1 + 2X_i + 1,5U_i + \varepsilon_i, \quad \varepsilon_i \sim N(0, 1). \quad (3.30)$$

Gerçek yapısal X katsayısı $\beta = 2$ 'dir. Fakat U dışarıda bırakıldığında

$$e_i = 1,5U_i + \varepsilon_i$$

ve X_i ile e_i pozitif ilişkilidir. OLS'nin katsayısı 2'nin üzerinde yoğunlaşır. U_i , v_i ve ε_i birbirinden bağımsız olduğundan $\text{cov}(X, e) = 0,8 \times 1,5 = 1,2$ ve $\text{var}(X) = 0,8^2 + 1 = 1,64$ 'tür; [Denklem \(3.26\)](#) ile $\text{plim } \hat{\beta}_{OLS} = 2 + 1,2/1,64 \approx 2,73$ olur.

```
import numpy as np
import statsmodels.api as sm

rng = np.random.default_rng(807)
n = 2000
U = rng.normal(size=n)
v = rng.normal(size=n)
eps = rng.normal(size=n)
X = 0.8 * U + v
```

```

Y = 1 + 2 * X + 1.5 * U + eps

m_naive = sm.OLS(Y, sm.add_constant(X)).fit()
m_control = sm.OLS(Y, sm.add_constant(np.column_stack([X, U]))).fit()

print("U yok:", m_naive.params[1])
print("U kontrol edildi:", m_control.params[1])

```

Bu simülasyon iki kavramı ayırır. U gözlenebiliyorsa uygun kontrolle nedensel parametre geri kazanılabilir. Gerçek uygulamada U gözlenemiyorsa aynı çözüm mümkün değildir; alternatif tanımlama stratejisi gerekir.

3.13 Bir Nedensel Çalışmayı Okurken Sorulacak Sorular

Bir tez veya makalede “ X , Y ’yi etkiler” ifadesi görülürse katsayı tablosundan önce şu sorular sorulmalıdır:

1. Nedensel estimand nedir: ATE, ATT, LATE, marjinal etki, başka bir parametre mi?
2. Tedavi veya temel regresör nasıl belirleniyor?
3. Tedavi seçimiyle sonucu ortak etkileyen değişkenler nelerdir?
4. Bunların hangileri gözleniyor, hangileri gözlenemiyor?
5. Kullanılan tanımlama varsayımı nedir?
6. Bu varsayım altında gözlenen veri estimandı hangi formülle tanımlıyor?
7. Ortak destek veya uygun karşılaştırma grubu var mı?
8. Tahmin yöntemi tanımlanan estimand ile uyumlu mu?
9. Standart hatalar veri bağımlılık yapısıyla uyumlu mu?
10. Sonuç alternatif makul tanımlama kararlarına duyarlı mı?

3.14 Araçsal Değişkene Geçiş

Koşullu bağımsızlık için gerekli bütün karıştırıcılar gözlenmiyorsa regresyona daha fazla kontrol eklemek sorunu çözemeyebilir. Bu durumda dışsal bir varyasyon kaynağı aranabilir. Temel fikir, endojen X ’in yalnızca hata terimiyle ilişkili olmayan bir bileşenini kullanmaktır.

Bir Z değişkeni

- X ile sistematik ilişkiliyse,
- yapısal hata e ile ortogonal ise,

X ’te dışsal değişim üretmek için kullanılabilir. Bu değişken *araçsal değişken* (instrumental variable) olacaktır. Bölüm 4’te bu fikri moment koşulundan başlayarak IV ve 2SLS tahmin edicisine dönüştüreceğiz.

Bu yaklaşım güçlü varsayımlar getirir ve her endojenlik problemi için uygun araç bulunmaz. Bölüm 4’te amaç “bir enstrüman değişken seçip 2SLS çalıştırmak” değil, aracın kurumsal mantığını, ilk aşama gücünü ve LATE gibi yorum sınırlarını birlikte kurmak olacaktır.

3.15 Ampirik Uygulama Laboratuvarı: Rastgele Atama ile Seçilmiş Alt Grubu Ayırmak

Bu uygulamada Hansen'in Duflo–Dupas–Kremer veri setini kullanıyoruz. Veri, Kenya'da öğrencilerin başlangıç başarı düzeyine göre ayrı sınıflara yerleştirilmesini (tracking) okul düzeyinde rastgele atayan deneyden gelmektedir. Metinde *tracking* sözcüğünü bu müdahalenin ve veri setindeki değişkenin adı olarak kullanıyoruz. Bu veri seti tanımlama kavramını öğretmek için özellikle uygundur; çünkü aynı veri içinde hem okul düzeyinde rastgele atanmış bir müdahale hem de müdahale okullarında başlangıç başarısına göre oluşturulan seçilmiş alt gruplar bulunmaktadır (Hansen, 2021).

3.15.1 Adım 1: Araştırma sorusu ve atama birimi

Temel soru, öğrencileri başlangıç başarısına göre sınıflara ayıran tracking uygulamasının dönem sonu toplam test puanına etkisidir. Müdahale öğrenci düzeyinde değil, **okul düzeyinde** atanmıştır. Dolayısıyla aynı okul içindeki öğrencilerin hata terimleri bağımsız kabul edilmemelidir. Çıkarımda okul düzeyinde kümelenmiş standart hata kullanmak tasarımın parçasıdır.

Analiz örnekleminde toplam test puanı gözlenen 5.795 öğrenci vardır. Buradaki temel estimand, rastgele atanan tracking programının ortalama etkisidir. Randomization nedeniyle tedavi göstergesi ile potansiyel sonuçlar arasındaki bağımsızlık tasarım tarafından desteklenir; regresyon kontrolleri tanımlamayı yaratmak için değil, dengesizlikleri azaltmak ve hassasiyeti artırmak için kullanılabilir.

3.15.2 Adım 2: Denge tablosunu mekanik bir sınav gibi okumamak

Tablo 3.1: DDK2011: tracking grupları arasında seçilmiş başlangıç değişkeni farkları

Değişken	Fark	Küme SH	p-değeri
Başlangıç standart puanı	-0,0314	0,0140	0,024
Kadın öğrenci	0,0225	0,0128	0,079
Test yaşı	0,1820	0,0850	0,032
Okul yönetim komitesi (SBM)	0,0150	0,0924	0,871
Ek öğretmen	-0,0217	0,0119	0,067

Tablo 3.1'de bazı p-değerleri yüzde 5 veya yüzde 10 düzeyinin altındadır. Bu, randomization'ın “başarısız olduğunu” kanıtlamaz. Rastgele atama, sonlu örnekleme her kovaryatın iki grupta tam eşit olacağını garanti etmez. Çok sayıda kovaryat incelendiğinde bazı farkların yalnız örnekleme değişkenliği nedeniyle belirgin görünmesi mümkündür.


Denge tablosu bu nedenle bir geçerlik sınavı olarak değil, örneklem kompozisyonunu anlamak ve önceden belirlenmiş kovaryat ayarlamasının yararlı olup olmadığını değerlendirmek için kullanılmalıdır.

3.15.3 Adım 3: Ham fark ile kovaryat ayarlı tahmini karşılaştırmak

İki nokta tahmini birbirine oldukça yakındır. Buna rağmen p-değeri 0,074'ten 0,049'a geçmektedir. Bu örnek, “anamlı/anlamsız” ikili dilinin neden yanıltıcı olabileceğini gösterir. Ekonometrik

Tablo 3.2: DDK2011: tracking etkisi için iki temel tahmin

Model	$\hat{\theta}$	Küme SH	p-değeri	n
Ham fark	1,258	0,704	0,074	5.795
Kovaryat ayarlı	1,375	0,699	0,049	5.135



Şekil 3.4: DDK2011 tracking etkisi: ham ve kovaryat ayarlı tahminler

bulgunun özü, program etkisinin yaklaşık 1,3–1,4 test puanı civarında tahmin edilmesidir; yüzde 5 çizgisinin iki yanında kalan p-değerleri tamamen farklı ekonomik hikâyeler oluşturmaz.

Kovaryat ayarlı modelin örneklem büyüklüğü daha küçüktür; çünkü bütün kontrol değişkenleri her öğrenci için gözlenmemektedir. Dolayısıyla sütunlar arası fark yalnız “kontroller eklendi” diye yorumlanmamalı, örneklem kompozisyonunun da değiştiği görülmelidir.

3.15.4 Adım 4: Aynı veride seçilmiş bir grubun neden nedensel karşılaştırma olmadığını görmek

Tracking okullarında öğrenciler başlangıç başarısına göre düşük ve yüksek akışlara ayrılmıştır. *lowstream* göstergesi rastgele tedavi değildir; başlangıç performansına göre mekanik olarak oluşur. Nitekim tracking okullarında

$$std_mark_i = \alpha + \delta lowstream_i + e_i$$

regresyonunda

$$\hat{\delta} = -1,574, \quad SH = 0,016$$

elde edilir. Düşük akıştaki öğrencilerin başlangıç performansı sistematik biçimde çok daha düşüktür.

Bu nedenle dönem sonu test puanını doğrudan düşük ve yüksek akış arasında karşılaştırmak “lowstream’in nedensel etkisini” vermez. Burada seçim değişkenin tanımına gömülüdür. Aynı veri seti içinde tracking için randomization güçlü bir tanımlama kaynağı iken, lowstream karşılaştırması için aynı argüman kullanılamaz.

Kod 3.1: Okul düzeyinde kümelenmiş tracking regresyonu

```
import statsmodels.formula.api as smf

m = smf.ols(
    "totalscore ~ tracking + std_mark + girl + agetest + sbm + etpteacher",
    data=df,
).fit(
    cov_type="cluster",
    cov_kwds={"groups": df["schoolid"]},
)
```

Kodda kritik satır yalnız regresyon formülü değildir. **groups=schoolid** ifadesi atama biriminin okul olduğunu çıkarım aşamasına taşır. Bir makalede tedavi okul, firma, köy veya bölge düzeyinde atanmışsa standart hata stratejisi de bu tasarımla uyumlu olmalıdır.

3.15.5 Makale çıktısını okurken sorulacak tanımlama soruları

1. Tedavi nasıl atanmıştır: rastgele mi, politika kuralıyla mı, bireysel seçimle mi?
2. Atama birimi ile gözlem birimi aynı mıdır?
3. Standart hatalar hangi düzeyde kümelenmiştir?
4. Kovaryatlar tedaviden önce mi ölçülmüştür?
5. Kovaryat eklenince örneklem değişiyor mu?
6. Sonuç “program etkisi” mi, yoksa seçilmiş gruplar arası koşullu fark mı?
7. Yalnız p-değerinin eşik değiştirmesine bakılarak ekonomik sonuç abartılıyor mu?

Bu uygulamadan tez yazımına taşınacak ana ders

Tanımlama, regresyon komutundan önce gelir. Aynı OLS komutu rastgele atanmış bir tedavi katsayısı için nedensel bir estimand’ı tahmin edebilirken, seçilmiş bir grup göstergesi için yalnız koşullu ilişkiyi özetleyebilir. Yöntemin adı değil, değişkenin veri üretim sürecindeki rolü nedensel yorumu belirler.

3.16 Temel Sonuçlar

1. Nedensel araştırmada yöntem seçimi estimand ve tanımlamadan sonra gelir. Tahmin edici, tanımlama varsayımının yerine geçmez.
2. Potansiyel sonuçlar Y_1 ve Y_0 aynı bireyin iki karşıt durumdaki sonuçlarını tanımlar; bireysel nedensel etki ikisinin farkıdır.
3. Gözlenen tedavi-kontrol ortalama farkı genel olarak nedensel etki ile seçim farkını birlikte içerir.
4. Rassal atama tedaviyi potansiyel sonuçlardan ayırdığı için basit grup farkını ATE olarak tanımlar.
5. Gözlemsel veride koşullu bağımsızlık ve ortak destek, uygun kovaryatlara koşullandıktan sonra nedensel karşılaştırmayı tanımlayabilir.

6. Doğrusal projeksiyon katsayısı β^* ile yapısal parametre β aynı nesne değildir. İçsellikte $\beta^* = \beta + \{E[XX']\}^{-1} E[Xe]$ olur.
7. OLS içsellik altında hesaplama hatası yapmaz; projeksiyon katsayısını tutarlı tahmin eder fakat yapısal parametreyi tutarlı tahmin etmeyebilir.
8. Eksik değişken, eşanlılık, karar temelli seçim ve açıklayıcı değişkende ölçüm hatası içsellğin farklı ekonomik kaynaklarıdır.
9. Büyük örneklem içsellği ortadan kaldırmaz. Robust standart hata da içsellğin çözümü değildir.
10. Kontrol değişkeni seçimi nedensel yapıya göre yapılmalıdır; aracı (mediator) ve çarpışan (collider) değişkenleri mekanik kontrol etmek estimandı değiştirebilir veya yeni yanlılık yaratabilir.

3.17 Bölüm Sonu Egzersizleri

Egzersiz 3.1: Dört kavram

Aşağıdaki ifadeleri estimand, identification, estimator ve estimate başlıklarından biriyle eşleştiriniz:

1. $ATE = E[Y_1 - Y_0]$,
2. $\hat{\beta} = (X'X)^{-1}X'Y$,
3. “Rassal atama altında $E[Y | D = 1] - E[Y | D = 0] = ATE$ ”,
4. “Örnekleme eğitimi katsayısı 0,071 bulundu.”

Her kavramın araştırma akışında neden farklı bir rolü olduğunu açıklayınız.

Egzersiz 3.2: Potansiyel sonuçlar

Üç birey için potansiyel sonuçlar aşağıdaki gibi olsun:

	Y_0	Y_1
A	5	9
B	7	8
C	4	10

1. Her bireyin nedensel etkisini hesaplayınız.
2. ATE'yi bulunuz.
3. A ve C tedavi almış, B almamışsa gözlenen Y değerlerini yazınız.
4. Bu gözlenen veriden bireysel etkilerin neden doğrudan hesaplanamadığını açıklayınız.

Egzersiz 3.3: Seçim ayrıştırması

Bir mesleki eğitim programına katılanların ortalama geliri 40, katılmayanların 30 birimdir. Tedavi alanların program olmasaydı ortalama gelirinin 35 olacağı düşünülmektedir.

1. Gözlenen grup farkını bulunuz.
2. ATT'yi hesaplayınız.
3. Seçim farkını hesaplayınız.
4. Ham farkın neden ATT'yi abarttığını veya küçülttüğünü yorumlayınız.

Egzersiz 3.4: Rassal atama

$D \perp\!\!\!\perp \{Y_0, Y_1\}$ varsayımını kullanarak

$$E[Y | D = 1] - E[Y | D = 0] = ATE$$

sonucunu adım adım türetiniz. Hangi eşitliklerin bağımsızlık varsayımını kullandığınızı işaretleyiniz.

Egzersiz 3.5: Koşullu bağımsızlık

Bir burs programına katılım D , mezuniyet başarısı Y , lise not ortalaması ve aile geliri X olsun. Araştırmacı

$$\{Y_0, Y_1\} \perp\!\!\!\perp D | X$$

varsayımını kullanmaktadır.

1. Bu varsayımı sözel olarak açıklayınız.
2. Ortak destek koşulu neden ayrıca gereklidir?
3. Program yalnızca lise notu 90'ın üzerindeki öğrencilere açıksa düşük not bölgesinde hangi sorun ortaya çıkar?

Egzersiz 3.6: Yapısal ve projeksiyon katsayısı

$Y = \alpha + \beta X + e$ ve $\text{cov}(X, e) = 0,6$, $\text{var}(X) = 2$ olsun. Gerçek yapısal katsayı $\beta = 1,5$ 'tir.

1. Basit doğrusal projeksiyon katsayısı β^* 'yi hesaplayınız.
2. Büyük örneklem OLS hangi değere yakınsar?
3. Standart hatayı sıfıra yaklaştıracak kadar büyük örneklem toplamak β 'yi geri kazandırır mı?

Egzersiz 3.7: Klasik ölçüm hatası

Gerçek Z değişkeninin varyansı 4, ölçüm hatası u 'nın varyansı 1 olsun. Gerçek katsayı $\beta = 0,75$ 'tir.

1. Zayıflama çarpanını hesaplayınız.

2. OLS olasılık limitini bulunuz.
3. Ölçüm hatası varyansı 4'e yükselse sonuç nasıl değişir?

Egzersiz 3.8: Arz ve talep

Bir araştırmacı gözlenen piyasa fiyatı P ile miktar Q arasında OLS tahmin edip katsayıyı “talep eğrisi” olarak yorumlamaktadır. Arz ve talep şoklarının denge fiyatını birlikte belirlediğini varsayınız.

1. Neden P talep denkleminde endojen olabilir?
2. OLS'nin projeksiyon katsayısı neden talep parametresi olmak zorunda değildir?
3. Talep eğrisini tanımlamak için hangi tür dışsal arz kaydırıcısı yararlı olabilir?

Egzersiz 3.9: Koşullu nedensel etkiden ortalama etkiye

Hansen'in eğitim örneğine benzer biçimde, $X = H$ (yüksek test skoru) grubunda koşullu ortalama nedensel etki 8,5, $X = L$ (düşük test skoru) grubunda 5,5 olsun.

1. Anakütlenin yarısı H , yarısı L ise ATE'yi hesaplayınız.
2. $P(X = H) = 0,70$ olursa ATE nasıl değişir?
3. Koşullu etkilerin aynı kalmasına rağmen ATE'nin neden anakütle bileşimine bağlı olduğunu açıklayınız.

Egzersiz 3.10: Büyük örneklem yanılığı

İki araştırmacı aynı içsel regresyonu tahmin ediyor. Birincisinin $n = 500$, ikincisinin $n = 500.000$ gözlemi var. Her ikisinde de $\text{cov}(X, e) / \text{var}(X) = 0,20$.

1. OLS'nin yapısal katsayıdan asimptotik sapması iki çalışmada nedir?
2. Büyük çalışmada standart hata neden çok daha küçük olabilir?
3. “Daha anlamlı” sonuç neden “daha nedensel” sonuç değildir?

Egzersiz 3.11: Tanımlama denetimi

Bir tezde firma inovasyon harcamasının kârlılığı artırdığı iddia edilmektedir. İnovasyon harcaması yöneticiler tarafından seçiliyor; yöneticilerin gelecek talep beklentileri gözlenmiyor ve hem inovasyon kararını hem gelecekteki kârlılığı etkiliyor.

1. Olası içsellik kaynağını tanımlayınız.
2. Basit OLS'nin nedensel yorumunu neden sorgularsınız?
3. Kontrol stratejisiyle çözülebilmesi için hangi tür değişkenlerin gözlenmesi gerekir?
4. Gözlenemeyen beklentiler kalıyorsa hangi tür dışsal varyasyon kaynağı aranabilir?

Egzersiz 3.12: Simülasyon tasarımı

Denklem (3.30)'daki veri üretim sürecini kullanarak 1.000 Monte Carlo tekrarı tasarlayınız. Her tekrarda (i) U 'yu dışarıda bırakan OLS, (ii) U 'yu kontrol eden OLS katsayısını kaydediniz. İki tahmin edicinin ortalamasını gerçek $\beta = 2$ ile karşılaştırın. Kodun tamamını yazmanız zorunlu değildir; simülasyon algoritmasını açık ve yeniden üretilebilir biçimde tanımlayınız.

Araçsal Değişkenler ve İki Aşamalı En Küçük Kareler

Bu bölümün amacı

Bu bölümün sonunda araçsal değişken yaklaşımının içsel regresördeki dışsal varyasyonu nasıl ayırdığını açıklayabilecek; yapısal denklem, ilk aşama ve indirgenmiş biçim arasındaki ilişkiyi kurabilecek; araç geçerliliğini uygunluk (relevance), dışsallık/ortogonalite ve dışlama kısıtı açısından tartışabilecek; tek araç–tek endojen regresör durumunda Wald/IV tahmin edicisini türetebilecek; çoklu araç durumunda 2SLS tahmin edicisini projeksiyon matrisi üzerinden elde edebilecek; tanımlama için rank koşulunun anlamını açıklayabilecek; 2SLS standart hatalarının neden sıradan ikinci aşama OLS standart hatalarından farklı olduğunu gösterebilecek; zayıf araç, aşırı tanımlama ve içsellik testlerinin neyi sınıadığını ayırt edebilecek; heterojen etkiler altında IV’nin LATE yorumunu kurabilecek ve IV’yi moment koşulları üzerinden GMM çerçevesine bağlayabileceksiniz.

Bağlantı

Bölüm 3’te yapısal parametre β ile doğrusal projeksiyon katsayısı β^* ’nın içsellik altında ayrıştığını gördük. OLS, $E[Xe] \neq 0$ olduğunda yapısal parametreyi tutarlı tahmin etmeye-bilir. Araçsal değişken yaklaşımı, X ’in tamamını kullanmak yerine hata terimiyle ilişkisiz (ortogonal) olduğu savunulan bir Z değişkeninin ürettiği varyasyonu kullanır. Temel soru şudur: *Endojen X içinde nedensel karşılaştırma için güvenilir olan varyasyonu nasıl izole ederiz?*

4.1 Araçsal Değişken Probleminin Temel Kurulumu

Yapısal denklem

$$Y = X'\beta + e \quad (4.1)$$

olsun. β yapısal veya nedensel olarak yorumlamak istediğimiz parametre vektörüdür. İçsellik varsa

$$E[Xe] \neq 0$$

ve OLS genel olarak β için tutarlı değildir. Hansen araçsal değişken yaklaşımını bu noktadan başlatır (Hansen, 2021).

Bir Z araç vektörü bulduğumuzu varsayalım. Temel moment koşulu

$$E[Ze] = 0 \quad (4.2)$$

şeklindedir. Yapısal hata $e = Y - X'\beta$ olduğuna göre

$$E[Z(Y - X'\beta)] = 0. \quad (4.3)$$

Bu koşul, β 'yı gözlenen veri momentleri üzerinden tanımlayabilir.

Araçsal değişken

Bir Z değişkeni, yapısal denklemdeki endojen regresör(ler) için dışsal varyasyon sağlıyor ve yapısal hata ile ortogonal olduğu savunulabiliyorsa araç olarak kullanılabilir. Uygulamada bu iddia yalnızca istatistiksel korelasyon değil, ekonomik/kurumsal bir tanımlama argümanı gerektirir.

4.2 Araç Geçerliliğinin Üç Bileşeni

Uygulamalı literatürde araç geçerliliği çoğu zaman üç ayrı soruyla değerlendirilir.

4.2.1 Uygunluk / relevance

Araç, endojen regresör X ile sistematik ilişkili olmalıdır. Tek endojen regresör ve sabit terimi de içeren kontrol vektörü W için ilk aşama

$$X = Z'\pi + W'\delta + v \quad (4.4)$$

olarak yazılabilir. Dışlanmış araçların ilk aşama katsayısı sıfır olmamalıdır:

$$\pi \neq 0.$$

Birden fazla endojen regresör olduğunda bunun karşılığı (4.16) rank koşuludur.

Uygunluk, aracın endojen X 'te koşullu olarak değişim üretmesidir. Sabit terim dışında kontroller varsa ilgili koşul yalnız $\text{cov}(Z, X) \neq 0$ değil, W 'nin doğrusal etkisi ayrıldıktan sonra aracın hâlâ X 'i açıklamasıdır. İlk aşama regresyonu bu nedenle dışsal kontrolleri de içermelidir.

İstatistiksel olarak güçlü ilişki ekonomik olarak küçük olabilir veya tam tersi; örneklem büyüklüğü ilk aşama testini etkiler. Bu yüzden katsayı büyüklüğü, kısmi R^2 (Denklem (2.12)) ve test istatistikleri birlikte okunmalıdır.

4.2.2 Dışsallık / ortogonallık

Araç yapısal hata ile ilişkisiz olmalıdır:

$$E[Ze] = 0.$$

Bu koşul, aracın sonuca giden gözlenemeyen ortak nedenlerle ilişkili olmamasını gerektirir.


Dışsallık en basit doğrusal gösterimde $E[Ze] = 0$ momentidir. Bu koşul aracın yapısal sonuç denklemindeki gözlenmeyen şoklarla sistematik ilişkili olmamasını ister. Rassal politika

ataması, doğal deney veya kurumsal kural bu koşulu destekleyebilir; fakat çoğu gözlemsel IV uygulamasında dışsallık doğrudan veriden test edilemez.

Araç ile gözlenen kovaryatlar arasında denge kontrolleri destekleyici kanıt sunabilir. Yine de gözlenmeyen faktörlerle ilişki olmadığı sonucunu kesin kanıtlamaz; bu nedenle dışsallık argümanı bağlam bilgisinin merkezinde yer alır.

4.2.3 Dışlama kısıtı

Z , Y 'yi yalnızca endojen X üzerinden etkilemelidir; yapısal denklemde Z 'nin Y üzerinde ayrı bir doğrudan etkisi olmamalıdır. Bu koşul potansiyel sonuç ve yapısal model yorumunun parçasıdır ve çoğu uygulamada doğrudan test edilemez.



Şekil 4.1: Geçerli aracın temel nedensel yapısı

Sık yapılan hata

Bir aracın X ile güçlü korelasyonu yalnızca relevance için kanıttır; dışsallık veya dışlama kısıtını kanıtlamaz. “İlk aşama anlamlı, dolayısıyla araç geçerli” sonucu metodolojik olarak yanlıştır.

Üç bileşeni birlikte düşünmek gerekir. Bir değişken yalnızca X ile güçlü ilişkili olduğu için iyi bir araç değildir. Benzer biçimde ekonomik olarak dışsal görünen fakat X üzerinde neredeyse hiç değişim yaratmayan bir değişken de yararlı değildir. Geçerli araç, endojen değişkende dışsal bir değişim kaynağı üretmeli ve sonucu yalnız bu kanal üzerinden etkilemelidir.

Uygunluk (relevance) büyük ölçüde gözlenen veriden değerlendirilebilir; ilk aşama katsayıları ve ilgili testler bu konuda bilgi verir. Dışsallık ve dışlama kısıtı ise çoğunlukla araştırma tasarımının ekonomik argümanlarına dayanır ve doğrudan test edilemez. Aşırı tanımlama testleri bazı ortak kısıtları sınavabilir; fakat “test reddetmedi, araçlar geçerlidir” sonucu çıkarılamaz. Araç seçiminin en önemli kısmı bu nedenle çoğu zaman regresyon tablosunun dışında, kurum ve atama mekanizmasının açıklamasındadır.

4.3 Yapısal Denklem, İlk Aşama ve İndirgenmiş Biçim

Tek endojen regresör X , araç vektörü Z ve dışsal kontrol vektörü W için üç denklem ayırt edilmelidir.

Bu bölümde kullanılan notasyon

X skaler endojen regresör, W sabit terimi de içeren dışsal kontrollerin $k_1 \times 1$ vektörü, Z ise dışlanmış araçların $\ell_2 \times 1$ vektörüdür. Vektör katsayılar her zaman soldan transpoz ile yazılır: $W'\gamma$, $Z'\pi$, $Z'\lambda$. Tek araç bulunan özel durumda $\ell_2 = 1$ olduğundan $Z'\pi$ ile πZ aynı skaler ifadedir; metinde karışıklığı önlemek için genel $Z'\pi$ biçimi korunur. Katsayı ve hata harfleri bölüm boyunca, bölüm uygulaması dahil, aynı anlamda kullanılır: yapısal denklemde (β, γ, e) , ilk aşamada (π, δ, v) , indirgenmiş biçimde (λ, ρ, η) ; tek araçlı uygulamada skaler yazım $(\pi \text{ nearc4}_i)$ kullanılır. Moment koşulu, 2SLS ve GMM kesimlerinde ise X ve Z , Hansen'i izleyerek dışsal kontrolleri de içeren tam regresör ve araç vektörlerini gösterir; boyutları $k = 1 + k_1$ ve $\ell = \ell_2 + k_1$ 'dir.

4.3.1 Yapısal denklem

$$Y = X\beta + W'\gamma + e. \quad (4.5)$$

Burada β öğrenmek istediğimiz yapısal etkidir. β 'nin nedensel yorumu modelin yapısal anlamına ve araç varsayımlarına dayanır; yalnız bu denklemi yazmak nedensellik sağlamaz.

4.3.2 İlk aşama

$$X = Z'\pi + W'\delta + v. \quad (4.6)$$

İlk aşama, aracın ve dışsal kontrollerin endojen değişkeni nasıl açıkladığını gösterir. π , aracın endojen regresörde ne kadar dışsal varyasyon ürettiğini ölçer; π sıfıra yakınsa araç gerekli varyasyonu üretmez. Birden fazla araçta ilk aşama ortak anlamlılık ve kısmi uyum ölçüleri birlikte değerlendirilir.

4.3.3 İndirgenmiş biçim

$$Y = Z'\lambda + W'\rho + \eta. \quad (4.7)$$

λ , aracın sonuç değişkeniyle toplam ilişkisini ölçer.

İlk aşamayı yapısal denkleme yerleştirirsek

$$Y = (Z'\pi + W'\delta + v)\beta + W'\gamma + e = Z'(\pi\beta) + W'(\gamma + \delta\beta) + (e + \beta v)$$

elde edilir. Dolayısıyla indirgenmiş biçim parametreleri yapısal parametrelere

$$\lambda = \pi\beta, \quad \rho = \gamma + \delta\beta, \quad \eta = e + \beta v \quad (4.8)$$

ile bağlıdır. Tek araçlı durumda ($\ell_2 = 1$) λ ile π skalerdir ve $\pi \neq 0$ iken

$$\beta = \frac{\lambda}{\pi} \quad (4.9)$$

olur. IV'nin oran mantığı buradan gelir. Kontroller bu ilişkiyi bozmaz; yeter ki ilk aşama ve indirgenmiş biçim aynı W ile yazılsın.

Bu üç denklem aynı tasarımın farklı yüzlerini gösterir. Yapısal denklem, ilgilendiğimiz $X \rightarrow Y$ etkisini içerir. İlk aşama, aracın X üzerinde gerçekten bir değişim yaratıp yaratmadığını ölçer.

İndirgenmiş biçim ise aracın sonuç üzerindeki toplam ilişkisini gösterir. Tek endojen değişken ve tek araç durumunda λ/π oranı (dolaylı en küçük kareler), indirgenmiş biçimdeki $Z \rightarrow Y$ değişimini ilk aşamadaki $Z \rightarrow X$ değişimine böler; kontrol yoksa ve araç ikiliyse bu oran bir sonraki kesimdeki Wald tahmin edicisidir.

Bu yapı IV sonuçlarını teşhis etmek için çok yararlıdır. İlk aşama çok küçükse oran kararsızlaşır. İndirgenmiş biçim sıfıra yakınsa ve ilk aşama güçlü ise hedef etkinin de sıfıra yakın olması beklenir. Her iki bileşeni ayrı raporlamak, yalnız nihai 2SLS katsayısını vermekten daha şeffaftır ve okuyucunun aracın hangi mekanizma üzerinden çalıştığını görmesini sağlar.

4.4 Wald Tahmin Edicisi: En Şeffaf IV Durumu

$Z \in \{0, 1\}$ ikili bir araç, tek endojen regresör X ve yalnızca sabit terim olsun. Yapısal model

$$Y = \alpha + \beta X + e, \quad E[e | Z] = 0$$

şeklinde yazılsın. $Z = 1$ ve $Z = 0$ için koşullu beklentileri alalım:

$$E[Y | Z = 1] = \alpha + \beta E[X | Z = 1], \quad (4.10)$$

$$E[Y | Z = 0] = \alpha + \beta E[X | Z = 0]. \quad (4.11)$$

İki denklemi çıkarınca

$$E[Y | Z = 1] - E[Y | Z = 0] = \beta \{E[X | Z = 1] - E[X | Z = 0]\}.$$

Dolayısıyla ilk aşama farkı sıfırdan farklıysa ($E[X | Z = 1] \neq E[X | Z = 0]$, uygunluk)

$$\beta = \frac{E[Y | Z = 1] - E[Y | Z = 0]}{E[X | Z = 1] - E[X | Z = 0]}. \quad (4.12)$$

Örneklem karşılığı

$$\hat{\beta}_{Wald} = \frac{\bar{Y}_1 - \bar{Y}_0}{\bar{X}_1 - \bar{X}_0} \quad (4.13)$$

şeklinde. Hansen'in de vurguladığı gibi bu ifade IV'nin sezgisini çok açık gösterir: araçtaki değişimin Y üzerinde oluşturduğu ortalama fark, aynı değişimin X üzerindeki ortalama farkına bölünür (Hansen, 2021).

Oran neden büyüyebilir?

Payda olan ilk aşama farkı çok küçükse, küçük örnekleme dalgalanmaları bile IV oranını çok değiştirebilir. Bu, zayıf araç probleminin en basit sezgisidir: araç X 'i yeterince hareket ettirmiyorsa, Y 'deki araç kaynaklı değişimi X birimine çevirmek kararsız hâle gelir.

4.5 Moment Koşulundan Just-Identified IV Tahmin Edicisine

X ve Z aynı boyutta $k \times 1$ vektörler olsun. Temel moment koşulu

$$E[Z(Y - X'\beta)] = 0$$

şu denklemi verir:

$$E[ZY] - E[ZX']\beta = 0.$$

Eğer $E[ZX']$ terslenebilirse

$$\beta = \{E[ZX']\}^{-1} E[ZY]. \quad (4.14)$$

Anakütle momentlerini örneklem momentleriyle değiştirince

$$\hat{\beta}_{IV} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{Y} \quad (4.15)$$

ifadesi elde edilir. Burada $\mathbf{Z}$ ve $\mathbf{X}$, gözlem satırlarıyla oluşturulmuş $n \times k$ matrislerdir.

OLS ile fark doğrudan görülebilir:

$$\hat{\beta}_{OLS} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y}, \quad \hat{\beta}_{IV} = (\mathbf{Z}'\mathbf{X})^{-1}\mathbf{Z}'\mathbf{Y}.$$

OLS normal denklemleri $\mathbf{X}'(\mathbf{Y} - \mathbf{X}\hat{\beta}_{OLS}) = 0$ üzerine kurulurken IV momentleri $\mathbf{Z}'(\mathbf{Y} - \mathbf{X}\hat{\beta}_{IV}) = 0$ üzerine kuruludur.

Tek endojen regresör ve tek araç durumunda merkezlenmiş değişkenlerle moment koşulu

$$E[Z(Y - \beta X)] = 0$$

verir. $E[ZX] \neq 0$ ise buradan

$$\beta = \frac{E[ZY]}{E[ZX]}$$

ve örneklem karşılığı

$$\hat{\beta}_{IV} = \frac{\sum_i Z_i Y_i}{\sum_i Z_i X_i}$$

elde edilir. Pay araç-sonuç indirgenmiş biçim ilişkisini, payda araç-tedavi ilk aşama ilişkisini taşır. Paydanın sıfıra yaklaşması tahminin neden kararsızlaştığını doğrudan gösterir.

Sabit terim varsa değişkenleri ortalamadan arındırmak veya kovaryans gösterimi kullanmak gerekir. İkili Z durumunda bu oran grup ortalama farklarının Wald oranına dönüşür.

4.6 Tanımlama: Rank Koşulu

Araçların sayısı tek başına tanımlama için yeterli değildir. Endojen regresörleri bağımsız biçimde hareket ettirecek kadar farklı araç varyasyonu gerekir.

X içinde k_2 endojen regresör, Z içinde bunlar için ℓ_2 dışlanmış araç olsun. Gerekli sayı koşulu

$$\ell_2 \geq k_2$$

olmakla birlikte tek başına yeterli değildir. Dışlanmış araçların ilk aşama katsayı matrisi $\mathbf{\Gamma}_{22}$ ($\ell_2 \times k_2$; tek endojen regresörde $\mathbf{\Gamma}_{22} = \pi$) için temel rank koşulu

$$\text{rank}(\mathbf{\Gamma}_{22}) = k_2 \quad (4.16)$$

olmalıdır. Hansen bu koşulun, yapısal parametrelerin indirgenmiş biçimden tek türlü çözülebilmesi için gerekli ve yeterli olduğunu gösterir (Hansen, 2021).

Just-identified ve overidentified

Endojen regresör başına tam olarak yeterli bağımsız araç bilgisi varsa model just-identified; bundan daha fazla geçerli moment koşulu varsa overidentified (aşırı tanımlı) olarak adlandırılır.

Çok sayıda araç aynı doğrusal bilgiyi taşıyorsa sayı yüksek olsa bile rank artmayabilir. Dolayısıyla tanımlama “kaç araç var?” sorusundan çok “araçlar endojen regresörleri kaç bağımsız yönde hareket ettiriyor?” sorusudur.

Rank koşulu, araçların endojen regresörlerin bağımsız değişim yönlerini yeterince üretmesini ister. Bir endojen değişken için en az bir dışlanmış araç gerekir; birden fazla endojen değişken olduğunda yalnızca araç sayısının yeterli olması yetmez. Araçların ilk aşamalarda doğrusal olarak farklı bilgi taşıması gerekir. İki araç birbirinin neredeyse aynısıysa sayı olarak iki araç bulunmasına rağmen etkin tanımlama zayıf olabilir.

Bu nedenle order condition yalnız gerekli bir sayma koşuludur; rank condition ise gerçek tanımlama koşuludur. Uygulamada ilk aşama matrisinin yapısı, kısmi F türü ölçüler ve zayıf araç tanımları bu ayırımın örneklem karşılıklarını değerlendirmeye yardım eder.

4.7 İki Aşamalı En Küçük Kareler (2SLS)

Araç sayısı regresör sayısından fazla olduğunda basit $(Z'X)^{-1}$ formülü yoktur. 2SLS, X 'in Z uzayındaki projeksiyonunu kullanır.

Projeksiyon matrisi

$$P_Z = Z(Z'Z)^{-1}Z' \quad (4.17)$$


ve araçlarla tahmin edilen regresörler

$$\widehat{X} = P_Z X \quad (4.18)$$

olsun. İkinci aşamada Y , $\widehat{X}$ üzerine regres edilir. Katsayı

$$\widehat{\beta}_{2SLS} = (\widehat{X}'\widehat{X})^{-1}\widehat{X}'Y \quad (4.19)$$

$$= (X'P_Z X)^{-1}X'P_Z Y. \quad (4.20)$$



Şekil 4.2: 2SLS'nin projeksiyon mantığı

Buradaki “iki aşama” hesaplama sezgisidir. İstatistiksel olarak 2SLS tek bir tahmin edicidir. Özellikle standart hata hesabı ikinci aşamayı sıradan OLS regresyonuymuş gibi ele alamaz.

2SLS'yi “ilk aşamada $\widehat{X}$ üret, ikinci aşamada OLS yap” algoritması olarak öğrenmek yararlıdır; fakat yöntemin özünü biraz daha dikkatli okumak gerekir. İlk aşama, endojen X 'in araçlar ve

dışsal kontroller tarafından açıklanabilen kısmını ayırır. Bu kısım, araç geçerliyse yapısal hatayla ortogonal bir değişim kaynağıdır. İkinci aşama sonuç ile bu temizlenmiş değişim arasındaki ilişkiyi kullanır.

Projeksiyon matrisi gösterimi

$$P_Z = Z(Z'Z)^{-1}Z'$$

ve

$$\hat{\beta}_{2SLS} = (X'P_ZX)^{-1}X'P_ZY$$

2SLS'nin geometrisini açıklar. P_ZX , X 'in araç uzayına projeksiyonudur. Böylece yöntem bütün X varyasyonunu değil, yalnız araçların açıklayabildiği bileşeni kullanır. Bu özellik IV'nin neden OLS'den daha büyük standart hatalara sahip olabileceğini de açıklar: tanımlama için kullanılabilir varyasyonun bir bölümünden bilinçli olarak vazgeçeriz.

4.8 Neden İkinci Aşamanın Sıradan OLS Standart Hatası Yanlıştır?

İkinci aşama regresyonu, X yerine ilk aşamada aynı örneklemden tahmin edilen $\hat{X}$ 'i kullanır. Oysa yapısal artık

$$\hat{e}_i = Y_i - X_i'\hat{\beta}_{2SLS}$$

ile tanımlanır; ikinci aşamadaki

$$Y_i - \hat{X}_i'\hat{\beta}_{2SLS}$$

artığı yapısal hata için doğru artık değildir.

Bu nedenle manuel “önce X 'i tahmin et, sonra tahmin edilen X ile OLS çalıştır ve OLS standart hatasını al” prosedürü, ilk aşamada bütün araçlar ve dışsal kontroller kullanıldığında katsayıyı 2SLS ile sayısal olarak aynı verse de standart hatayı genel olarak yanlış verir. Hansen bunu IV egzersizlerinde özellikle vurgular (Hansen, 2021).

Heteroskedastisiteye dayanlı 2SLS kovaryans matrisi uygun ölçekle sandviç biçiminde yazılabilir:

$$\widehat{V}_{\hat{\beta}_{2SLS}} = (X'P_ZX)^{-1}X'Z(Z'Z)^{-1} \left(\sum_{i=1}^n Z_i Z_i' \hat{e}_i^2 \right) (Z'Z)^{-1}Z'X(X'P_ZX)^{-1}. \quad (4.21)$$

$\hat{X} = P_ZX$ olduğundan $X'Z(Z'Z)^{-1}Z_i = \hat{X}_i'$ 'dir; dolayısıyla (4.21), Y 'nin $\hat{X}$ üzerine regresyonunun HC0 sandviçiyle aynıdır, yalnız artık olarak $\hat{e}_i$ kullanılır. Uygulamada bu matris güvenilir IV yazılımları tarafından hesaplanmalıdır.

Formüldeki $\hat{e}_i$ yapısal artıktır; ikinci aşamanın mekanik OLS artığı X yerine $\hat{X}$ ile hesaplandığından ondan farklıdır. Bu nedenle yazılımda iki regresyonu elle arka arkaya çalıştırıp ikinci regresyonun standart hatasını kullanmak, nokta tahminini doğru verse bile çıkarımı yanlış verebilir.

Uygun 2SLS rutini standart hatayı yapısal artık $\hat{e}_i$ ve IV kovaryans formülüyle hesaplar. Heteroskedastisite olasılığında IV-robust kovaryans matrisi kullanılmalıdır. Bu örnek, “aynı katsayıyı elde etmek” ile “aynı istatistiksel prosedürü uygulamak” arasındaki farkı gösterir.

4.9 İlk Aşama Gücü ve Zayıf Araç Problemi

Araç geçerli olsa bile X ile çok zayıf ilişkiliyse 2SLS'nin sonlu örneklem davranışı kötü olabilir. İlk aşama


$$X = Z'\pi + W'\delta + v$$

ve dışlanmış araçlar için

$$H_0 : \pi = 0$$

ortak hipotezi relevance hakkında bilgi verir.

Tek endojen regresörlü klasik durumda ilk aşama F istatistiği sık raporlanır. Uygulamalı literatürde “ $F > 10$ ” yaygın bir kaba kuraldır; ancak bu evrensel bir geçerlilik sınırı değildir. Araç sayısı, heteroskedastisite, birden fazla endojen regresör ve hedeflenen testin boyut bozulması gibi unsurlar daha dikkatli zayıf araç tanılaması gerektirir. Hansen zayıf araçlar için ayrı test ve kritik değer tartışması verir (Hansen, 2021).



Şekil 4.3: İndirgenmiş biçim etkisi sabitken ilk aşama sıfıra yaklaştığında IV oranının kararsızlaşması

Sık yapılan hata

Zayıf araç problemi yalnızca “standart hata biraz büyür” problemi değildir. 2SLS tahmini OLS’ye doğru sonlu örneklem yanlılığı gösterebilir, dağılım normal yaklaşımdan ciddi sapabilir ve klasik güven aralıkları yanıltıcı olabilir. Bu nedenle araç gücü sonuç tablosunun ayrılmaz parçasıdır.

Zayıf araç problemi yalnızca standart hatanın büyümesi değildir. Araç endojen değişkeni çok az açıklıyorsa 2SLS’nin sonlu örneklem dağılımı normal yaklaşımdan ciddi biçimde sapabilir, tahmin OLS yönünde yanlı olabilir ve klasik t testlerinin nominal anlamlılık düzeyi bozulabilir. Bu nedenle “katsayı büyük ama anlamsız” biçimindeki sıradan hassasiyet yorumu zayıf araç sorununu tam olarak yakalamaz.

İlk aşama F istatistiği sık kullanılan bir tanı ölçüsüdür; fakat tek bir evrensel eşik bütün tasarımlar için yeterli değildir. Endojen regresör sayısı, araç sayısı, heteroskedastisite ve hangi çıkarım yönteminin kullanılacağı önemlidir. İyi uygulamada ilk aşama katsayıları, kısmi uyum ölçüleri ve zayıf tanımlamaya dayanlı çıkarım yöntemleri birlikte düşünülmelidir. Hansen de

zayıf araçların klasik 2SLS çıkarımını bozabileceğini özellikle vurgular (Hansen, 2021).

4.10 Aşırı Tanımlama ve Araç Geçerliliği Testleri

Araç sayısı endojen regresör sayısından fazlaysa model overidentified olur. Fazladan moment koşulları, modelin araç ortogonalitesiyle uyumunu kısmen sınamak için kullanılabilir.

Temel moment

$$\mathbf{g}(\beta) = E[Z(Y - X'\beta)] = 0$$

ve örneklem momenti

$$\hat{\mathbf{g}}(\hat{\beta}) = \frac{1}{n} \sum_{i=1}^n Z_i \hat{e}_i$$

olsun. Aşırı tanımlama testleri, fazladan moment koşullarının (aşırı tanımlayıcı kısıtların) tahmin edilen modelle uyumlu olup olmadığını, yani $\hat{\mathbf{g}}(\hat{\beta})$ örneklem momentinin sıfıra yeterince yakın olup olmadığını inceler. Homoskedastik klasik çerçevede Sargan, genel robust çerçevede Hansen J türü testler kullanılır.

Aşırı tanımlama testinin sınırı

Sıfır hipotezinin reddedilmesi en az bir araç/moment koşulunun veya yapısal spesifikasyonun sorunlu olduğuna işaret edebilir. Reddedilmemesi ise bütün araçların kesinlikle geçerli olduğunu kanıtlamaz. Test, araç geçerliliği için ekonomik argümanın yerine geçmez.

Birden fazla araç bulunduğu model, aynı yapısal parametreyi farklı moment koşullarıyla açıklamaya çalışır. Aşırı tanımlama testi bu momentlerin örneklemde birbirleriyle ne ölçüde uyumlu olduğunu sınar. Reddetme, en az bir araç veya model kısıtının sorunlu olduğuna ilişkin kanıt sağlar; fakat hangi aracın hatalı olduğunu tek başına söylemez.

Reddetmeme ise geçerliliğin kanıtı değildir. Bütün araçlar aynı yönde ihlal ediliyorsa veya testin gücü düşükse model yanlış olduğu halde test reddetmeyebilir. Dahası tam tanımlı modelde böyle bir test zaten mümkün değildir. Araç geçerliliği öncelikle kurumsal ve nedensel argümana dayanır; istatistiksel test bu argümanın yerine geçmez.

4.11 İçsellik Testleri

Durbin–Wu–Hausman türü içsellik testleri, belirli regresörlerin OLS için dışsal olup olmadığını sınamaya çalışır. Temel fikir OLS ile IV tahminlerinin sistematik olarak farklı olup olmadığını değerlendirmektir. Ancak yorum iki koşula bağlıdır:

1. IV araçlarının kendisi geçerli olmalıdır.
2. Test gücü araç gücüne ve örneklem yapısına bağlıdır.

Bu nedenle “Hausman reddetmedi, OLS kesinlikle nedenseldir” biçimindeki yorum aşırıdır.

Durbin–Wu–Hausman türü testler, belirli varsayımlar altında OLS ile IV arasındaki sistematik farkı kullanarak regresörün dışsal olup olmadığına ilişkin bilgi sağlar. Ancak testin gücü araç kalitesine bağlıdır. Zayıf veya geçersiz araç altında OLS–IV farkı güvenilir bir içsellik tanısı olmayabilir.

Ayrıca test reddetmedi diye regresörün kesin dışsal olduğu söylenemez; örneklem yetersiz olabilir. İçsellik testi, ekonomik endojenlik argümanını tamamlayan bir istatistiksel tanıdır, onun yerine geçmez.

4.12 Heterojen Etkiler ve LATE

Şimdi ikili tedavi D ve ikili araç Z düşünelim. Araç bazı bireylerin tedavi alma durumunu değiştiriyor olabilir. Potansiyel tedavi durumlarını

$$D_1, \quad D_0$$

ile gösterelim. Bireyler dört gruba ayrılabilir:

- **Compliers:** $D_1 = 1, D_0 = 0$,
- **Always-takers:** $D_1 = D_0 = 1$,
- **Never-takers:** $D_1 = D_0 = 0$,
- **Defiers:** $D_1 = 0, D_0 = 1$.

Monotonluk varsayımı defier bulunmadığını söyler:

$$P\{D_1 - D_0 < 0\} = 0. \quad (4.22)$$

Araç potansiyel sonuçlardan ve potansiyel tedavi durumlarından bağımsızsa (bağımsızlık), dışlama kısıtı geçerliyse ve ilk aşama farkı sıfırdan farklıysa, monotonluk altında Wald oranı

$$\frac{E[Y | Z = 1] - E[Y | Z = 0]}{E[D | Z = 1] - E[D | Z = 0]} \quad (4.23)$$

complier alt popülasyonundaki ortalama tedavi etkisini verir:

$$LATE = E[Y_1 - Y_0 | D_1 > D_0]. \quad (4.24)$$

Hansen, heterojen etkiler altında standart IV'nin LATE olarak yorumlanabileceğini ve bu etkinin kullanılan araca bağlı olabileceğini vurgular (Hansen, 2021).

IV etkisi hangi nüfusa aittir?

Tedavi etkileri heterojense IV tahmini genel ATE olmak zorunda değildir. Araç tarafından tedavi kararı değiştirilen compliers grubunun ortalama etkisini ölçebilir. Bu nedenle araç seçimi yalnızca istatistiksel güç değil, hangi alt popülasyonun etkisinin öğrenildiği açısından da önemlidir.

Sabit etki modelinde geçerli bütün araçların aynı β parametresini tanımlaması beklenir. Tedavi etkileri bireyler arasında farklılaştığında ise IV tahmininin yorumu değişir. İkili araç ve ikili tedavi bağlamında bağımsızlık ve monotonluk gibi koşullar altında Wald oranı, aracın tedavi kararını değiştirdiği *complier* alt popülasyonundaki ortalama nedensel etkiyi tanımlar. Bu LATE, bütün anakütlenin ortalama etkisi olmak zorunda değildir (Imbens ve Angrist, 1994; Hansen, 2021).

Bu sonuç araç seçiminin ekonomik önemini artırır. Üniversite yakınlığı aracı, yalnız yakınlık nedeniyle üniversiteye giden öğrencilerin etkisini; mali yardım aracı ise finansal teşvike duyarlı farklı bir grubun etkisini tanımlayabilir. Tedavi etkileri heterojense iki geçerli araç farklı LATE’ler üretebilir. Dolayısıyla IV tahminini raporlarken “etki kimin için?” sorusu en az “araç geçerli mi?” sorusu kadar önemlidir.

4.13 Hansen’in Kolej Yakınlığı Örneği

Hansen, Card (1995) örneğini kullanarak kolej yakınlığını eğitim için araç olarak tartışır (Hansen, 2021). Basit fikir şudur:

- X : eğitim yılı,
- Y : log ücret,
- Z : bireyin büyüdüğü bölgede dört yıllık koleje yakınlık göstergesi.

Koleje yakın yaşamamanın eğitim maliyetini düşürerek eğitim süresini artırabileceği relevance argümanıdır. Araç geçerliliği için daha zor soru, kolej yakınlığının ücretleri eğitim dışındaki kanallardan etkilememesi ve ücret potansiyelleriyle ilişkili gözlenemeyen bölgesel özellikleri taşımamasıdır.

Hansen’in raporladığı indirgenmiş biçim örneğinde kolej yakınlığı eğitim üzerinde pozitif ilk aşama etkisi üretir; log ücret indirgenmiş biçim katsayısının ilk aşama katsayısına oranı just-identified IV eğitim getirisi tahminini verir. Bu örnek iki önemli ders taşır:

1. güçlü görünen bir ekonomik hikâye bile dışlama kısıtının ayrıca savunulmasını gerektirir,
2. IV ile OLS’nin farklı olması tek başına hangisinin “doğru” olduğunu göstermez; araç geçerliliği ve heterojen etki yorumu birlikte düşünülmelidir.

4.14 2SLS Uygulaması ve Yazılım Mantığı

Bir endojen değişken, bir dışlanmış araç ve dışsal kontroller içeren model için Python’da `linearmodels` paketi doğrudan 2SLS tahmini yapabilir:

```
from linearmodels.iv import IV2SLS

# y: sonuc
# x_endog: endojen regresor
# z: dislanmis arac
# controls: dissal kontroller

formula = "y ~ 1 + controls + [x_endog ~ z]"
res = IV2SLS.from_formula(formula, data=df).fit(cov_type="robust")

print(res.summary)
```

Aynı mantığı manuel olarak görmek için:

```
import numpy as np
```

```

Y = y.to_numpy()[ :, None]
X = np.column_stack([np.ones(len(df)), controls, x_endog])
Z = np.column_stack([np.ones(len(df)), controls, z])

Pz = Z @ np.linalg.inv(Z.T @ Z) @ Z.T
beta_2sls = np.linalg.inv(X.T @ Pz @ X) @ (X.T @ Pz @ Y)
print(beta_2sls.ravel())

```

Manuel hesap kodu öğretici olsa da araştırma uygulamasında robust/clustered kovaryans, zayıf araç tanıları ve aşırı tanımlama testleri için doğrulanmış paket kullanmak daha güvenlidir.

Bir IV tablosunda en az ne raporlanmalı?

Yalnızca ikinci aşama katsayısını vermek yetersizdir. En azından endojen değişkenler ve araçlar açıkça tanımlanmalı; ilk aşama/araç gücü bilgisi, 2SLS katsayısı ve uygun standart hata, örneklem büyüklüğü, varsa aşırı tanımlama ve içsellik testleri, ayrıca dışlama kısıtının ekonomik gerekçesi verilmelidir.

Birden fazla dışsal kontrol varsa hem endojen X hem araç Z kontrollerden arındırılmış biçimde düşünülmelidir. Yazılım 2SLS'yi tek bir sistem olarak çözer ve dışsal kontroller hem ilk hem ikinci aşamada yer alır. İlk aşamada kontrolü unutup yalnız X 'i Z üzerine regres etmek farklı bir moment koşulu kullanır ve genel olarak doğru 2SLS sonucu değildir.

Raporlamada en azından ilk aşama ana araç katsayısı/gücü, 2SLS katsayısı ve uygun robust/clustered standart hata verilmelidir. Birden fazla araçta aşırı tanımlama istatistiği ve zayıf araç tanıları da tasarıma göre eklenir. Yazılım çıktısındaki otomatik “first stage F” değerinin hangi tür F olduğu kontrol edilmelidir; heteroskedastik veya kümelenmiş tasarımda klasik F uygun olmayabilir.

4.15 Moment Koşulundan GMM'ye Geçiş

IV'nin temelinde

$$E[Z(Y - X'\beta)] = 0$$

moment koşulu vardır. Araç sayısı parametre sayısından fazla olduğunda bütün örneklem momentlerini tam olarak sıfıra eşitlemek genellikle mümkün değildir. GMM, momentleri bir ağırlık matrisiyle mümkün olduğunca sıfıra yaklaştırır:

$$\hat{\beta}_{GMM} = \arg \min_b \hat{g}(b)'W\hat{g}(b), \quad (4.25)$$

burada

$$\hat{g}(b) = \frac{1}{n} \sum_{i=1}^n Z_i(Y_i - X_i'b)$$

ve W , $\ell \times \ell$ boyutlu pozitif tanımlı bir ağırlık matrisidir. Burada Hansen'in gösterimini izliyoruz; bu W , önceki kesimlerdeki kontrol vektörü W ile karıştırılmamalıdır. 2SLS, $W = (Z'Z)^{-1}$ seçimi altında doğrusal GMM'nin özel bir durumudur. Hansen Bölüm 13'te bu bağlantıyı ayrıntılandırır (Hansen, 2021). Bu derste GMM'yi bağımsız uzun bir konu olarak değil, IV'nin moment tabanlı genellemesi olarak kullanacağız.

IV yaklaşımının daha genel biçimi, bilinmeyen parametrenin bazı anakütle momentlerini sıfıra

eşitlemesi fikridir:

$$E[g_i(\theta_0)] = 0,$$

burada $g_i(\theta)$, i gözleminin verisine ve θ parametresine bağlı moment fonksiyonudur. Doğrusal IV'de $g_i(\beta) = Z_i(Y_i - X_i'\beta)$ seçilir. Örneklemde bu beklentiye örneklem ortalamasıyla değiştiririz ve momentleri mümkün olduğunca sıfıra yaklaştıran parametreyi ararız. Tam tanımlı durumda moment sayısı parametre sayısına eşittir; aşırı tanımlı durumda bütün momentleri aynı anda tam sıfır yapmak genellikle mümkün değildir.

GMM bu durumda moment sapmalarını bir ağırlık matrisi altında minimize eder. Ağırlık seçimi tahminin verimliliğini etkiler ve optimal ağırlık, moment koşullarının kovaryans yapısıyla ilişkilidir. Bu derste GMM'nin tam asimptotik teorisini geliştirmeyeceğiz; fakat bu bakış, IV, robust kovaryans ve daha sonraki ortogonal moment yöntemlerinin ortak mantığını görmemizi sağlar.

$g_i(\theta) \in \mathbb{R}^\ell$ gözlem moment vektörünü, $\widehat{g}(b)$ bunun örneklem ortalamasını gösterir. Kalın W matris ile normal italik W gözlem vektörü farklı nesnelerdir; ağırlığın pozitif bir sabitle ölçeklenmesi GMM çözümünü değiştirmez.

4.16 IV Çalışmasını Eleştirel Okuma Kontrolü

Bir tezde IV/2SLS gördüğünüzde aşağıdaki sıralama yararlıdır:

1. Endojen olduğu iddia edilen regresör hangisidir ve neden endojendir?
2. Araç hangi ekonomik/kurumsal mekanizmayla bu regresörü değiştirir?
3. İlk aşama gerçekten güçlü mü?
4. Dışlama kısıtını bozabilecek doğrudan kanallar nelerdir?
5. Araç ile yapısal hata arasında ortak nedenler olabilir mi?
6. Araç ve endojen regresör tanımlama açısından yeterli rank sağlıyor mu?
7. Standart hatalar 2SLS'ye ve veri bağımlılık yapısına uygun mu?
8. Birden fazla araç varsa aşırı tanımlama sonuçları nasıl yorumlanıyor?
9. Heterojen etki olasıysa tahmin ATE mi, LATE mi ve hangi compliers grubuna aittir?
10. OLS–IV farkı ekonomik olarak makul mü, yoksa zayıf araç veya geçersiz araç belirtisi olabilir mi?

4.17 Ampirik Uygulama Laboratuvarı: Card Verisiyle İlk Aşamadan 2SLS'ye

Bu uygulamada Hansen'in Card1995 veri setini kullanıyoruz. Klasik araştırma sorusu, eğitimin ücret üzerindeki etkisidir. Eğitim tercihi yetenek, aile geçmişi veya beklenen kazanç gibi gözlenmeyen faktörlerle ilişkili olabileceği için OLS katsayısı nedensel eğitim getirisini tanımlamayabilir. Araç değişken olarak bireyin büyüdüğü yerde dört yıllık bir koleje yakınlığı gösteren `nearc4` değişkeni kullanılmaktadır (Hansen, 2021).

4.17.1 Adım 1: Yapısal denklem, ilk aşama ve indirgenmiş biçim

Analiz örneklemini 3.010 gözlemden oluşmaktadır. Temel üç denklem, bölümün gösterimiyle şunlardır:

$$\begin{aligned}\text{Yapısal: } lwage_i &= \beta education_i + W_i' \gamma + e_i, \\ \text{İlk aşama: } education_i &= \pi nearc4_i + W_i' \delta + v_i, \\ \text{İndirgenmiş biçim: } lwage_i &= \lambda nearc4_i + W_i' \rho + \eta_i.\end{aligned}$$

W_i sabit terimle birlikte deneyim, deneyimin karesi, ırk, metropolitan alan ve bölge göstergelerini içermektedir. Bu üç denklem ayrı raporlama nesneleridir. İyi bir IV makalesi yalnız ikinci aşama katsayısını gösterip ilk aşamayı gizlememelidir.

4.17.2 Adım 2: Sonuçları tek bir tanımlama zinciri olarak okumak

Tablo 4.1: Card1995 uygulaması: OLS, ilk aşama, indirgenmiş biçim ve 2SLS

Büyüklik	Tahmin	HC1 SH
OLS eğitim katsayısı	0,0747	0,0036
İlk aşama: $nearc4 \rightarrow education$	0,3199	0,0851
İndirgenmiş biçim: $nearc4 \rightarrow lwage$	0,0421	0,0175
2SLS eğitim katsayısı	0,1315	0,0541

İlk aşama katsayısı yaklaşık 0,320'dir: diğer kontroller sabitken dört yıllık koleje yakınlık yaklaşık 0,32 yıl daha fazla eğitimle ilişkilidir. Robust ilk aşama t istatistiğinin karesi yaklaşık

$$F \simeq 14,14$$

olur. Bu değer aracın eğitimle kayda değer ilişkisi bulunduğunu gösterir; fakat " $F > 10$ ise araç kesinlikle güçlüdür" biçiminde evrensel bir kural olarak kullanılmamalıdır. Araç sayısı, endojen değişken sayısı ve heteroskedastisite gibi ayrıntılar zayıf araç değerlendirmesini etkiler.

İndirgenmiş biçimde koleje yakınlık log ücretle yaklaşık 0,0421 daha yüksek değerle ilişkilidir. Tek endojen değişken ve tek dışlanmış araç durumunda (4.9) oranı (dolaylı en küçük kareler)


$$\frac{\hat{\lambda}}{\hat{\pi}} = \frac{0,04207}{0,31990} \approx 0,1315$$

olur ve 2SLS katsayısına eşittir: tam tanımlı modelde yuvarlanmamış katsayıların oranı 2SLS tahmininin kendisidir. Tablodaki dört ondalık basamağa yuvarlanmış değerlerle hesaplanan $0,0421/0,3199 \approx 0,1316$ sonucundaki küçük fark yalnız yuvarlamadan gelir.

OLS katsayısının tam yüzde dönüşümü yaklaşık yüzde 7,8 iken 2SLS katsayısının dönüşümü yaklaşık yüzde 14,1'dir. Ancak "IV daha büyük olduğuna göre OLS aşağı yanlıdır" sonucu otomatik değildir. Geçerli araç varsayımları, ölçüm hatası, heterojen eğitim getirileri ve IV'nin hangi alt popülasyona ilişkin yerel etkiyi tanımladığı birlikte düşünülmelidir.

4.17.3 Adım 3: Araç geçerliliğini p-değerinden türetmemek

IV için iki ayrı soru vardır:



Şekil 4.4: Card1995 uygulamasında OLS ve 2SLS eğitim katsayıları

1. **İlgililik (relevance):** *nearc4* eğitimle ilişkili mi? İlk aşama bunu inceler.
2. **Dışsallık/dışlama:** *nearc4* ücreti eğitim dışında başka bir kanal üzerinden etkiliyor mu ve yapısal hata ile ortogonal mi?

İlk soru veriden doğrudan araştırılabilir. İkinci soru büyük ölçüde ekonomik ve kurumsal argümana dayanır. İlk aşamanın güçlü olması dışlama kısıtını kanıtlamaz. Aynı şekilde tam tanımlı modelde tek araç için aşırı tanımlama testi de yoktur.

4.17.4 Adım 4: 2SLS'i yazılım komutunun arkasındaki iki projeksiyon olarak görmek

Kod 4.1: Card uygulamasında ilk aşama ve indirgenmiş biçimin açıkça tahmini

```
first_stage = smf.ols(
    "ed76 ~ nearc4 + exp76 + exp762_100 + black + smsa76r + ...",
    data=df,
).fit(cov_type="HC1")

reduced_form = smf.ols(
    "lwage76 ~ nearc4 + exp76 + exp762_100 + black + smsa76r + ...",
    data=df,
).fit(cov_type="HC1")

oran = reduced_form.params["nearc4"] / first_stage.params["nearc4"] # 2SLS ile aynı
```

Tam analiz betiği 2SLS'nin matris formunu da üretmektedir. Öğrencinin yazılım kullanırken anlaması gereken nokta, 2SLS'nin endojen eğitim değişkeninin araçların açıkladığı bileşenini kullanarak yapısal katsayıyı tahmin ettiğidir.

4.17.5 Bir IV makalesindeki tabloyu nasıl okumalıyız?

Bir IV sonuç tablosunda aşağıdakileri arayın:

1. OLS karşılaştırması,
2. ilk aşama katsayıları ve zayıf araç tanıları,
3. hangi değişkenlerin araç, hangilerinin dahil edilen dışsal kontrol olduğu,
4. 2SLS katsayısı ve uygun robust/küme standart hatası,
5. birden fazla araç varsa aşırı tanımlama sonuçları,
6. IV estimand'ının hangi popülasyona ilişkin olduğunun tartışılması,
7. aracın dışlama kısıtını destekleyen kurumsal gerekçe.

Tez yazımında kaçınılacak ifade

“İçsellik testi anlamlı olduğu için IV modeli doğrudur” veya “ilk aşama F istatistiği 10’u geçtiği için araç geçerlidir” ifadeleri yeterli değildir. IV tasarımının güvenilirliği, araç ilgililiği ile dışlama/dışsallık argümanının birlikte savunulmasına bağlıdır.

4.18 Temel Sonuçlar

1. IV yaklaşımı endojen X 'in tamamını değil, araç Z tarafından üretilen ve yapısal hata ile ortogonal olduğu savunulan varyasyonu kullanır.
2. Geçerli araç için relevance, ortogonallik ve dışlama kısıtı birlikte düşünülmelidir. İlk aşama gücü dışlama kısıtının kanıtı değildir.
3. Tek ikili araç ve tek endojen regresör durumunda (sabit terim dışında kontrol yokken) Wald tahmin edicisi indirgenmiş biçim farkının ilk aşama farkına oranıdır.
4. Just-identified IV moment koşulu $E[Z(Y - X'\beta)] = 0$ 'dan doğrudan elde edilir.
5. Çoklu araç durumunda 2SLS X 'i Z uzayına projekte eder ve $\hat{\beta}_{2SLS} = (X'P_Z X)^{-1} X'P_Z Y$ biçimindedir.
6. Tanımlama yalnızca araç sayısıyla değil rank koşuluyla ilgilidir.
7. İkinci aşamadaki sıradan OLS standart hataları genel olarak 2SLS için doğru değildir; yapısal artık ve IV kovaryans matrisi kullanılmalıdır.
8. Zayıf araçlar tahmin dağılımını ve klasik çıkarımı ciddi biçimde bozabilir; ilk aşama tanıları zorunludur.
9. Aşırı tanımlama testleri araç geçerliliği için kısmi bilgi sağlar fakat ekonomik dışlama argümanının yerini tutmaz.
10. Heterojen tedavi etkilerinde IV, monotonluk ve diğer gerekli koşullar altında compliers için LATE'yi ölçebilir.
11. IV ve 2SLS, $E[Ze] = 0$ moment koşulu üzerinden GMM ailesinin doğal bir parçasıdır.

4.19 Bölüm Sonu Egzersizleri

Egzersiz 4.1: Araç koşullarını ayırma

Bir araştırmacı ücret Y 'yi eğitim yılı X üzerine regres etmekte ve en yakın üniversiteye uzaklığı Z araç olarak kullanmaktadır. Aşağıdaki iddiaları relevance, dışsallık veya dışlama kısıtı başlıklarıyla eşleştiriniz:

1. Uzaklık eğitim maliyetini ve dolayısıyla eğitim süresini değiştirir.
2. Uzaklık, eğitim dışında ücretleri etkileyen yerel işgücü piyasası özellikleriyle ilişkili değildir.
3. Uzaklığın ücret üzerinde eğitim dışındaki doğrudan kanalı yoktur.

Her iddianın neden ayrı savunulması gerektiğini açıklayınız.

Egzersiz 4.2: Wald oranı

İkili bir araç için

$$\bar{Y}_1 = 18, \quad \bar{Y}_0 = 15, \quad \bar{X}_1 = 12,5, \quad \bar{X}_0 = 12,0.$$

1. İndirgenmiş biçim farkını hesaplayınız.
2. İlk aşama farkını hesaplayınız.
3. Wald/IV tahminini bulunuz.
4. İlk aşama farkı 0,05 olsaydı aynı indirgenmiş biçim farkında tahmin nasıl değişirdi ve neden daha kırılgan olurdu?

Egzersiz 4.3: Moment koşulundan IV

$E[Z(Y - X\beta)] = 0$ ve skaler X, Z varsayınız. $E[ZX] \neq 0$ koşuluyla

$$\beta = \frac{E[ZY]}{E[ZX]}$$

sonucunu türetiniz. Sabit terim olduğunda kovaryans biçiminin

$$\beta = \frac{\text{cov}(Z, Y)}{\text{cov}(Z, X)}$$

olduğunu açıklayınız.

Egzersiz 4.4: 2SLS matrisi

$P_Z = Z(Z'Z)^{-1}Z'$ olduğunu kullanarak $P_Z' = P_Z$ ve $P_Z^2 = P_Z$ özelliklerini gösteriniz. Bu iki özelliğin P_Z 'nin bir ortogonal projeksiyon matrisi olduğunu neden ifade ettiğini açıklayınız.

Egzersiz 4.5: İki aşamayı cebirsel olarak birleştirme

$\widehat{\mathbf{X}} = \mathbf{P}_Z \mathbf{X}$ kullanarak

$$(\widehat{\mathbf{X}}' \widehat{\mathbf{X}})^{-1} \widehat{\mathbf{X}}' \mathbf{Y} = (\mathbf{X}' \mathbf{P}_Z \mathbf{X})^{-1} \mathbf{X}' \mathbf{P}_Z \mathbf{Y}$$

eşitliğini adım adım gösteriniz. Hangi adımda $\mathbf{P}_Z^2 = \mathbf{P}_Z$ kullandığınızı belirtiniz.

Egzersiz 4.6: Yanlış standart hata prosedürü

Bir araştırmacı önce $\mathbf{X}$ 'i $\mathbf{Z}$ üzerine OLS ile regres etmiş, sonra $\mathbf{Y}$ 'yi $\widehat{\mathbf{X}}$ üzerine OLS ile regres ederek ikinci regresyonun standart hatasını 2SLS standart hatası olarak raporlamıştır.

1. Katsayı tahmininin neden 2SLS katsayısıyla örtüşebileceğini açıklayınız.
2. Standart hatanın neden genel olarak yanlış olduğunu açıklayınız.
3. Yapısal artığın hangi formda hesaplanması gerektiğini yazınız.

Egzersiz 4.7: Rank koşulu

İki endojen regresör (X_1, X_2) ve iki dışlanmış araç (Z_1, Z_2) olsun. İlk aşama katsayı matrisi

$$\mathbf{\Gamma} = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}$$

olsun.

1. $\mathbf{\Gamma}$ 'nin rankını bulunuz.
2. İki araç bulunmasına rağmen iki endojen regresör neden ayrı ayrı tanımlanamayabilir?
3. İkinci satır $(2, 3)$ olsaydı durum nasıl değişirdi?

Egzersiz 4.8: Zayıf araç

Tek endojen regresörlü bir modelde iki araştırma grubu aynı ikinci aşama katsayısını yaklaşık 0,50 buluyor. Birinci grupta ilk aşama dışlanmış araç $F = 45$, ikinci grupta $F = 2,8$.

1. İki katsayıyı aynı güvenle yorumlar mısınız?
2. Zayıf araç durumunda hangi klasik asimptotik sonuçlar kırılganlaşabilir?
3. Yalnızca ikinci aşama p -değerine bakmak neden yetersizdir?

Egzersiz 4.9: Aşırı tanımlama testi

Bir endojen regresör ve üç dışlanmış araç içeren modelde robust Hansen J testi $p = 0,01$ vermiştir.

1. Sıfır hipotezi genel olarak neyi ifade eder?
2. Sonuç hangi tür soruna işaret eder?
3. Hangi aracın geçersiz olduğunu test tek başına söyler mi?
4. $p = 0,70$ olsaydı bütün araçların geçerliliği kanıtlanmış olur muydu?

Egzersiz 4.10: LATE ve complier yorumu

Bir iş arama programına katılım D , programa erişimi kolaylaştıran rastgele davet Z olsun. $Z = 1$ grubunda katılım oranı 0,60, $Z = 0$ grubunda 0,30; ortalama istihdam sonucu sırasıyla 0,72 ve 0,66 olsun.

1. Wald oranını hesaplayınız.
2. Monotonluk ve diğer IV koşulları altında bu sayı hangi grubun ortalama etkisidir?
3. Always-takers ve never-takers için bireysel etki bu tasarımla neden ayrı ayrı tanımlanmaz?

Egzersiz 4.11: OLS ve IV farkını yorumlamak

Bir eğitim getirisi çalışmasında OLS 0,07, 2SLS 0,13 bulmuştur.

1. “OLS yukarı yanlış olmalıydı; IV daha büyük olduğuna göre IV yanlıştır” sonucu neden zorunlu değildir?
2. Heterojen etkiler/LATE hangi açıklamayı sağlayabilir?
3. Zayıf araç veya geçersiz araç olasılıklarını hangi ek bilgilerle değerlendirmek gerekir?

Egzersiz 4.12: GMM bağlantısı

$\ell > k$ olduğunda $\hat{g}(b)$ moment vektörünü tam olarak sıfıra eşitlemenin genel olarak neden mümkün olmadığını açıklayınız. GMM amaç fonksiyonunda $\mathbf{W}$ ağırlık matrisinin rolünü belirtiniz. 2SLS'nin neden bu moment-temelli ailenin özel bir üyesi olduğunu sözel olarak açıklayınız.

İkili ve Ayırık Sonuç Değişkenleri: Olasılık Modelleri ve Sınırlı Bağımlı Değişkenler

Bu bölümün amacı

Bu bölümün sonunda bağımlı değişkenin ikili veya ayırık yapısının ekonometrik modeli neden değiştirdiğini açıklayabilecek; ikili sonuçlarda koşullu ortalamanın doğrudan bir olasılık olduğunu gösterebilecek; doğrusal olasılık modeli, Probit ve Logit modellerini aynı tahmin hedefi etrafında karşılaştıracak; Bernoulli olabilirliğinden Logit/Probit olabilirlik fonksiyonunu kurabilecek; maksimum olabilirlik tahmin edicisinin asimptotik dağılımını ve bilgi matrisi eşitliğini açıklayabilecek; marjinal etki standart hatalarının hangi iki adımdan geldiğini gösterebilecek; doğrusal olmayan modellerde katsayı ile marjinal etki arasındaki ayrımı matematiksel olarak açıklayabilecek; ortalama marjinal etkileri hesaplayıp yorumlayabilecek; kukla regresörlerde sonlu olasılık farkını kullanabilecek ve çok kategorili, sıralı ve sayım sonuçları için uygun model ailesini seçebileceksiniz.

Bağlantı

Bölüm 3 ve Bölüm 4'te temel sorumuz açıklayıcı değişkenin hata terimiyle ilişkili olup olmadığıydı. Bu bölümde farklı bir modelleme boyutuna geçiyoruz: *sonuç değişkeninin destek kümesi*. Sonuç 0/1, birkaç kategori veya negatif olamayan küçük tam sayılardan oluşuyorsa, doğrusal regresyon hâlâ yararlı bir referans noktasıdır; fakat koşullu dağılımın biçimi model seçiminin ayrılmaz parçası hâline gelir. Hansen'in sınırlı bağımlı değişken yaklaşımını bu bakışla kullanacağız (Hansen, 2021).

Ders içi öncelik

Derste çekirdek: doğrusal olasılık modeli; Logit ve Probit; Bernoulli olabilirliği; marjinal etkiler ve ortalama marjinal etkiler.

Notta genişletme/ileri okuma: Multinomial ve Ordered modeller ile sayım modelleri. Bu kısım tez araştırma sorusuna göre ayrıntılandırılabilir.

5.1 Bağımlı Değişkenin Desteği Neden Önemlidir?

Şimdiye kadarki regresyonlarda Y çoğunlukla reel sayı doğrusu üzerinde değişebilen bir sonuçtu. Oysa ampirik araştırmada sonuç değişkeni çoğu zaman doğası gereği sınırlıdır:

- bir firma pazara girdi mi: $Y \in \{0, 1\}$,
- bir kredi başvurusu onaylandı mı: $Y \in \{0, 1\}$,
- bireyin işgücü durumu: çalışan / işsiz / işgücü dışında,
- memnuniyet düzeyi: çok düşük, düşük, orta, yüksek, çok yüksek,
- bir yıldaki patent sayısı: $Y \in \{0, 1, 2, \dots\}$.

Bu örneklerde asıl nesne yalnızca $E[Y | X]$ değildir. Sonucun ayırık yapısı nedeniyle koşullu olasılıkların tamamı ekonomik anlam taşır. Modelin bu desteğe saygı göstermesi gerekir.

Sınırlı bağımlı değişken (limited dependent variable)

Destek kümesi reel sayı doğrusunun tamamı olmayan sonuç değişkenlerine sınırlı bağımlı değişken denir. İkili, çok kategorili, sıralı, sayım ve sansürlü değişkenler bu sınıfa girer. Sınırlama yalnızca teknik bir ayrıntı değildir; koşullu dağılımın nasıl modellenebileceğini belirler.

5.2 İkili Sonuçlarda Koşullu Ortalama Bir Olasılıktır

$Y \in \{0, 1\}$ olsun. $X = x$ verildiğinde Y Bernoulli dağılımlıdır ve

$$P(x) = P(Y = 1 | X = x)$$

cevap olasılığı olarak adlandırılabilir. İkili bir rassal değişken için

$$E[Y | X = x] = 0 \cdot P(Y = 0 | X = x) + 1 \cdot P(Y = 1 | X = x) \quad (5.1)$$

$$= P(Y = 1 | X = x) = P(x). \quad (5.2)$$

Dolayısıyla ikili sonuç modelinde koşullu ortalama ile cevap olasılığı aynı nesnedir.

Bu eşitlik önemli bir köprü kurar. Regresyonun koşullu ortalama mantığını terk etmiyoruz; yalnızca koşullu ortalamanın artık $[0, 1]$ aralığında olması gerektiğini kabul ediyoruz.

Modeli

$$Y = P(X) + e, \quad E[e | X] = 0 \quad (5.3)$$

şeklinde yazabiliriz. Fakat hata teriminin koşullu varyansı artık

$$\text{var}(e | X) = P(X)\{1 - P(X)\} \quad (5.4)$$

olur. Bu ifade, $P(X)\{1 - P(X)\}$, X ile değiştiği sürece (cevap olasılığı X ile değiştiğinde tipik durum budur) ikili regresyonda heteroskedastisitenin yapısal olarak var olduğunu gösterir.

İkili sonuçlarda iki temel sonuç

Birincisi, tahmin edilen koşullu ortalama doğrudan olasılık olarak yorumlanır. İkincisi, hata varyansı olasılığa bağlı olduğu için klasik homoskedastik OLS standart hataları doğrusal olasılık modelinde doğal varsayılan değildir.

5.3 Doğrusal Olasılık Modeli

En basit yaklaşım

$$P(Y = 1 | X) = X'\beta \quad (5.5)$$

modelidir. Bu model **doğrusal olasılık modeli** (linear probability model, LPM) olarak adlandırılır. Örneklemede doğrudan OLS ile tahmin edilir.

Bir sürekli regresör X_j için

$$\frac{\partial P(Y = 1 | X)}{\partial X_j} = \beta_j.$$

Dolayısıyla katsayı doğrudan olasılık değişimidir. Örneğin $\hat{\beta}_j = 0,04$ ise, X_j 'de bir birimlik fark cevap olasılığında yaklaşık 0,04, yani 4 yüzde puanlık farkla ilişkilidir.

5.3.1 LPM'nin güçlü tarafları

LPM'nin dört pratik avantajı vardır:

1. katsayılar doğrudan marjinal etkilerdir;
2. OLS ile son derece kolay tahmin edilir;
3. çok sayıda sabit etki, araçsal değişken veya yüksek boyutlu kontrol içeren yapılara kolayca genişletilebilir;
4. $X'\beta$ koşullu olasılığın en iyi doğrusal yaklaşımı olarak da okunabilir.

Bir başka güçlü taraf, katsayıların yüzde puan cinsinden doğrudan okunabilmesidir. Örneğin eğitim katsayısı 0,03 ise, diğer regresörler sabitken bir yıllık eğitim farkı modelin doğrusal yaklaşımında olay olasılığında 3 yüzde puanlık farkla ilişkilidir. Bu yorum, Logit/Probit'teki marjinal etki hesaplarına göre daha doğrudandır.


Bununla birlikte bu kolaylık, LPM'nin her araştırmada tercih edilmesi gerektiği anlamına gelmez. Özellikle tahmin edilen olasılıkların kendisi, kuyruk davranışı veya olasılığın X boyunca nasıl eğildiği araştırma sorusunun merkezindeyse doğrusal olmayan olasılık modeli daha uygun olabilir.

5.3.2 LPM'nin sınırlamaları

En belirgin sorun

$$X'\hat{\beta} < 0 \quad \text{veya} \quad X'\hat{\beta} > 1$$

olasılığıdır. Böyle bir tahmin matematiksel olarak OLS için sorun yaratmaz; fakat olasılık yorumu için geçersizdir. İkinci sorun, doğrusal marjinal etkinin bütün X düzeylerinde aynı kabul



Şekil 5.1: Doğrusal olasılık modelinde sınır ihlali ve S-biçimli bağlantı fonksiyonu

edilmesidir. Gerçekte olasılıklar 0 veya 1'e yaklaştıkça aynı büyüklükte bir indeks değişiminin olasılık üzerindeki etkisinin küçülmesi beklenebilir.

Sık yapılan hata

LPM'nin olasılık sınırlarını ihlal etmesi, her uygulamada otomatik olarak kullanılamaz olduğu anlamına gelmez. Araştırma hedefi yerel ortalama farkları veya kolay yorumlanan marjinal etkilerse LPM yararlı olabilir. Fakat bireysel olasılık tahmini ve özellikle uç bölgelerdeki öngörüler hedefleniyorsa sınırları koruyan modeller daha doğal bir seçimdir.

Bu bakış LPM'yi “yanlış, çünkü Y yalnız 0 ve 1 alıyor” biçimindeki basit eleştiriden ayırır. OLS'nin bağımlı değişkeninin sürekli olması gerekmez; asıl mesele doğrusal koşullu ortalama yaklaşımının araştırma amacı için yeterli olup olmadığıdır.

Denklem (5.4) nedeniyle LPM'de hata varyansı yapısal olarak heteroskedastiktir. Bu nedenle heteroskedastisiteye dayanıklı standart hata LPM'de doğal varsayılan seçimdir; klasik OLS standart hatası değil.

5.4 Tek İndeks Modelleri: Probit ve Logit

Sınır sorununu çözmenin doğal yolu doğrusal indeksi bir dağılım fonksiyonundan geçirmektir:

$$P(Y = 1 | X = x) = G(x'\beta), \quad (5.6)$$

burada $G : \mathbb{R} \rightarrow [0, 1]$ monoton artan bir bağlantı fonksiyonudur. İki temel seçim şunlardır:

$$\text{Probit: } G(v) = \Phi(v), \quad (5.7)$$

$$\text{Logit: } G(v) = \Lambda(v) = \frac{1}{1 + e^{-v}}. \quad (5.8)$$

İki dağılımın biçimi birbirine benzediğinden, iyi tanımlanmış birçok ampirik uygulamada tahmin edilen olasılıklar ve marjinal etkiler birbirine çok yakın çıkar. Buna karşılık ham katsayı büyüklükleri ölçek normalizasyonları farklı olduğu için doğrudan karşılaştırılmamalıdır.

5.4.1 Marjinal etki neden katsayı değildir?

$g(v) = G'(v)$ olsun. Sürekli bir X_j için zincir kuralı

$$\frac{\partial P(Y = 1 \mid X = x)}{\partial x_j} = \beta_j g(x' \beta) \quad (5.9)$$

verir. LPM'den farklı olarak β_j tek başına olasılık değişimini göstermez. Etki x noktasına bağlıdır.


Logit modelinde

$$g(v) = \Lambda(v)\{1 - \Lambda(v)\},$$

Probit modelinde ise

$$g(v) = \phi(v)$$

şeklindedir.



Şekil 5.2: Logit modelinde marjinal etkinin indeks düzeyine göre değişmesi

Şekil 5.2’de marjinal etki indeksi sıfıra yakın gözlemlerde en büyüktür. Olasılık 0 veya 1’e yaklaştıkça aynı β_j katsayısının olasılık üzerindeki etkisi küçülür.

Tek indeks $x' \beta$ bütün regresörleri tek bir indekste toplar; bağlantı fonksiyonu bu indeksi olasılığa dönüştürür. İki modelin merkezi bölgede ürettiği olasılıklar çoğu uygulamada oldukça benzerdir. Fark daha çok kuyruklarda ve katsayı ölçeğinde ortaya çıkar. Bu nedenle “Logit anlamlı, Probit anlamsız” gibi küçük farklılıklara aşırı anlam yüklemek yerine, tahmin edilen olasılıkların ve özellikle marjinal etkilerin ekonomik büyüklüğünü karşılaştırmak daha yararlıdır. Model seçimi teori, uygulama geleneği ve tahmin performansı ile desteklenebilir.

5.5 Gizli Değişken Yorumu ve Ölçek Normalizasyonu

Tek indeks modeli bir gizli değişken modeliyle de elde edilebilir. Gözlenemeyen sürekli bir eğilim

$$Y^* = X' \beta + u \quad (5.10)$$

olsun ve

$$Y = 1\{Y^* > 0\}.$$

O zaman

$$P(Y = 1 \mid X = x) = P(u > -x'\beta \mid X = x) \quad (5.11)$$

$$= G(x'\beta), \quad (5.12)$$

u , X 'ten bağımsız ve dağılım fonksiyonu G sıfır etrafında simetrik olduğunda tek indeks modelini verir.

Bu gösterim tercih, katılım veya kârlılık gibi uygulamalarda yararlıdır. Y^* gözlenen 0/1 sonucunun arkasındaki sürekli eğilim olarak düşünülebilir. Ancak önemli bir tanımlama problemi vardır. Eğer $u = \sigma\varepsilon$ ve ε , X 'ten bağımsız olup dağılım fonksiyonu G ise

$$P(Y = 1 \mid X = x) = G\left(\frac{x'\beta}{\sigma}\right).$$

Veri β ile σ 'yı ayrı ayrı değil, yalnızca oranlarını belirleyebilir. Bu nedenle hata ölçeği normalize edilir.

Katsayı karşılaştırmasında ölçek sorunu

Probit ve Logit katsayılarının farklı büyüklükte olması, iki modelin ekonomik olarak farklı marjinal etkiler verdiği anlamına gelmez. Katsayılar gizli indeksin ölçeğine bağlıdır. Uygulamada olasılıkları ve özellikle marjinal etkileri karşılaştırmak daha anlamlıdır.

Uygulamada Probit'te $\text{var}(u) = 1$, Logit'te lojistik dağılımın ölçeği standart biçimde normalize edilir. Bu normalizasyon, Logit ve Probit katsayılarının doğrudan büyüklük olarak karşılaştırılmamasının nedenidir; karşılaştırma marjinal etki ölçeğinde anlamlıdır.

5.6 Olabilirlik: 0 ve 1 Gözlemlerinin Ortak Dili

Probit ve Logit genellikle maksimum olabilirlik ile tahmin edilir. $p_i = G(X_i'\beta)$ olsun. Koşullu Bernoulli olasılık kütle fonksiyonu

$$P(Y_i = y_i \mid X_i) = p_i^{y_i} (1 - p_i)^{1-y_i}, \quad y_i \in \{0, 1\} \quad (5.13)$$

şeklinde dir. Bağımsız gözlemler altında olabilirlik

$$L_n(\beta) = \prod_{i=1}^n p_i^{Y_i} (1 - p_i)^{1-Y_i}$$

ve log-olabilirlik

$$\ell_n(\beta) = \sum_{i=1}^n [Y_i \log p_i + (1 - Y_i) \log(1 - p_i)] \quad (5.14)$$

olur.

Maksimum olabilirlik tahmin edicisi

$$\hat{\beta}_{ML} = \arg \max_b \ell_n(b)$$

olarak tanımlanır. Kapalı form çözüm genel olarak yoktur; sayısal optimizasyon gerekir.

Olabilirlik nasıl okunmalı?

Olabilirlik, parametrelerin “olasılığı” değildir. Belirli bir β değeri verildiğinde gözlediğimiz 0 ve 1 dizisinin model altında ne kadar uyumlu olduğunu ölçen bir kriterdir. MLE bu kriteri en büyük yapan parametre değerini seçer.

5.6.1 Logit modelinin skor denklemi

Logit için $p_i = \Lambda(X_i'\beta)$ ve türev özelliği sayesinde skor sadeleşir:

$$\frac{\partial \ell_n(\beta)}{\partial \beta} = \sum_{i=1}^n X_i(Y_i - p_i). \quad (5.15)$$

MLE’de (sayısal optimizasyonun toleransı içinde)

$$\sum_{i=1}^n X_i(Y_i - \hat{p}_i) = 0$$

sağlanır. Bu yapı OLS normal denklemlerini anımsatır; fakat artık tahmin edilen koşullu ortalama doğrusal değil, $\hat{p}_i = \Lambda(X_i'\hat{\beta})$ biçimindedir. Model sabit terim içeriyorsa bu denklemin sabite karşılık gelen satırı $\sum_i (Y_i - \hat{p}_i) = 0$ ’dır: tahmin edilen olasılıkların örneklem ortalaması, $Y = 1$ olanların örneklem payına eşittir. Bu eşitlik Logit’in kanonik bağlantısına özgüdür; Probit’te yalnız yaklaşık olarak sağlanır.

Denklem (5.13)’teki ifade $y_i = 1$ olduğunda p_i ’ye, $y_i = 0$ olduğunda $1 - p_i$ ’ye indirgenir; tek satırda iki durumu birlikte yazmanın kısa yoludur. Logaritma çarpımı toplama çevirir ve maksimum noktasını değiştirmez.

MLE’nin sezgisi şudur: gözlenen 1’lere yüksek, gözlenen 0’lara düşük başarı olasılığı veren parametre değerleri daha yüksek olabilirlik üretir. Ancak model her gözlemi kusursuz sınıflandırmaya çalışmaz; bütün örneklem olasılık yapısını dengeler. Olabilirlik fonksiyonunun doğru kurulması, bağımlı değişkenin destek kümesiyle doğrudan bağlantılıdır. Bu nedenle Tobit, ordered model veya sayım modeli gibi sonraki sınırlı sonuç modellerinde de tahmin mantığı aynı genel ilkeye dayanacaktır.

Bu bağlantı öğrencinin MLE’yi tamamen farklı bir matematik dünyası olarak görmesini engeller. OLS’de kareli hata minimize edilir; Logit’te Bernoulli log-olabilirliği maksimize edilir. Her iki durumda da amaç fonksiyonunun eğimi sıfırlandığında parametre tahmini elde edilir.

5.7 Maksimum Olabilirlik Tahmin Edicisinin Belirsizliği

Şimdiye kadar Logit ve Probit katsayılarını olabilirliği maksimize ederek elde ettik. Fakat katsayı tablolarında ve [Tablo 5.1](#) gibi marjinal etki tablolarında her tahminin yanında bir standart hata da vardır. Bu sayı nereden geliyor? OLS için [Bölüm 2](#)’de sandviç formülünü kurmuştuk; MLE için karşılığını burada kuruyoruz.

5.7.1 Skordan asimptotik dağılıma

Log-olabilirliğin parametreye göre türevine **skor** denir. Gözlem başına skor

$$\mathbf{s}_i(\beta) = \frac{\partial}{\partial \beta} \log f(Y_i | X_i; \beta)$$

olsun; toplam skor $\mathbf{s}_n(\beta) = \sum_{i=1}^n \mathbf{s}_i(\beta)$ 'dır. MLE, birinci derece koşulu

$$\mathbf{s}_n(\hat{\beta}_{ML}) = 0$$

sağlayan değerdir. Logit için bu koşul tam olarak [Denklem \(5.15\)](#)'te gördüğümüz denklemdir.

Model doğru belirtilmişse skorun gerçek parametrede koşullu ortalaması sıfırdır:

$$E[\mathbf{s}_i(\beta) | X_i] = 0. \quad (5.16)$$

Bu, OLS'deki $E[X_i e_i] = 0$ moment koşulunun olabilirlik karşılığıdır. Yapı aynıdır: tahmin edici, örneklemde sıfırlanan bir moment koşulundan doğar.

Buradan sonrası [Bölüm 2](#)'deki adımların tekrarıdır. $\hat{\beta}_{ML}$ etrafında birinci dereceden açılım ve büyük sayılar yasası ile merkezi limit teoremi birlikte kullanılarak

$$\sqrt{n}(\hat{\beta}_{ML} - \beta) \xrightarrow{d} N(0, \mathbf{Q}^{-1} \mathbf{\Omega} \mathbf{Q}^{-1}) \quad (5.17)$$

elde edilir. Buradaki iki matris

$$\mathbf{Q} = -E \left[\frac{\partial^2}{\partial \beta \partial \beta'} \log f(Y_i | X_i; \beta) \right], \quad \mathbf{\Omega} = E [\mathbf{s}_i(\beta) \mathbf{s}_i(\beta)']$$

şeklinde. $\mathbf{s}_i(\beta)$ ve $\mathbf{s}_n(\beta)$ burada tanımlanan $k \times 1$ skor vektörleri, $\mathbf{Q}$ ve $\mathbf{\Omega}$ ise $k \times k$ matrislerdir. Bu bölümde β anakütle hedefini gösterir: doğru belirtimde gerçek parametre, yanlış belirtimde beklenen log-olabilirliği en büyükleyen sözde-gerçek değerdir. Hansen'in model etiketleriyle bu son değer Logit için β^{logit} , Probit için β^{probit} 'dir (§25.7–25.8). $\mathbf{Q}$ log-olabilirliğin ortalama eğriliğini, $\mathbf{\Omega}$ ise skorun varyansını ölçer.

Eğrilik neden belirsizliği belirler?

$\mathbf{Q}$ 'yi görsel olarak düşünün. Log-olabilirlik fonksiyonu maksimum noktasında keskin bir tepe oluşturuyorsa, verinin parametre hakkında güçlü bilgisi vardır: küçük bir kayma olabilirliği hızla düşürür. Tepe basıksa çok sayıda parametre değeri veriyle neredeyse aynı derecede uyumludur ve tahmin belirsizdir. [Denklem \(5.17\)](#)'de $\mathbf{Q}^{-1}$ 'in görünmesinin nedeni budur: yüksek eğrilik, düşük varyans demektir.

5.7.2 Bilgi matrisi eşitliği ve iki farklı standart hata

Model *doğru belirtilmişse* önemli bir sadeleşme oluşur:

$$\mathbf{\Omega} = \mathbf{Q}. \quad (5.18)$$

Bu ilişkiye **bilgi matrisi eşitliği** denir ve ortak değere Fisher bilgisi adı verilir. Bu durumda [Denklem \(5.17\)](#) sadeleşerek

$$\sqrt{n}(\hat{\beta}_{ML} - \beta) \xrightarrow{d} N(0, \mathbf{Q}^{-1}) \quad (5.19)$$

biçimini alır. Klasik MLE standart hataları bu formülden gelir: örneklemede Q yerine gözlenen Hessian'ın negatifinin ortalaması, $\hat{Q} = -n^{-1} \partial^2 \ell_n(\hat{\beta}_{ML}) / \partial \beta \partial \beta'$ (bazı yazılımlarda beklenen bilgi matrisi), kullanılır ve $\hat{\beta}_{ML}$ 'nin tahmin edilen kovaryans matrisi $n^{-1} \hat{Q}^{-1}$ olur.

Model yanlış belirtilmişse eşitlik bozulur ve [Denklem \(5.17\)](#)'nin tam sandviç biçimi geçerli kalır; örneklemede $\hat{\Omega} = n^{-1} \sum_{i=1}^n s_i(\hat{\beta}_{ML}) s_i(\hat{\beta}_{ML})'$ ile tahmin edilen kovaryans matrisi $n^{-1} \hat{Q}^{-1} \hat{\Omega} \hat{Q}^{-1}$ 'dir. Bu nedenle Logit/Probit çıktılarında “robust” seçeneği tam olarak sandviç formülünü kullanır.

Aynı fikrin üçüncü kez karşımıza çıkışı

Yapı her seferinde aynıdır. OLS'de $Q_{XX}^{-1} \Omega Q_{XX}^{-1}$, MLE'de $Q^{-1} \Omega Q^{-1}$. Dış parçalar tahmin probleminin eğriliğini, orta parça momentin varyansını taşır. Doğru belirtim altında orta ve dış parçalar birbirini sadeleştirir; yanlış belirtimde sadeleşmez. Bu ortak kalıp [Bölüm 12](#)'deki ortogonal moment yaklaşımına kadar korunacaktır.

Sık yapılan hata

İkili sonuç modelinde “robust standart hata” ifadesinin anlamı OLS'dekinden farklıdır. LPM'de robust seçeneği bilinen bir heteroskedastisiteyi düzeltir ve doğal varsayılandır. Logit/Probit'te ise Bernoulli varyansı zaten modelin içindedir; sandviç formülü burada *yanlış belirtim* karşı bir düzeltmedir. Fakat bağlantı fonksiyonu veya indeks yalnızca sandviç standart hata katsayısı doğru hedefe getirmez; yalnız yanlış hedef etrafındaki belirsizliği daha dürüst ölçer. Kümelenme varsa ayrıca küme düzeyinde skor toplamaları kullanılmalıdır ([Bölüm 2.7](#)).

5.7.3 Marjinal etkinin standart hatası

Artık [Denklem \(5.20\)](#)'deki ortalama marjinal etkinin standart hatasının nereden geldiğini görebiliriz. AME, tahmin edilen katsayıların doğrusal olmayan bir fonksiyonudur:

$$\widehat{AME}_j = h_j(\hat{\beta}), \quad h_j(b) = \frac{1}{n} \sum_{i=1}^n b_j g(X_i' b).$$

Dolayısıyla [Bölüm 2.8](#)'deki delta yöntemi doğrudan uygulanır: h_j 'nin $\hat{\beta}$ 'daki gradyanı hesaplanır ve [Denklem \(2.31\)](#) ile birleştirilir.

[Tablo 5.1](#)'deki standart hatalar tam olarak bu iki adımın birleşimidir: önce [Denklem \(5.17\)](#)'nin örneklem karşılığıyla $\hat{\beta}$ 'nin kovaryans matrisi $n^{-1} \hat{Q}^{-1} \hat{\Omega} \hat{Q}^{-1}$, sonra delta yöntemiyle AME'ye aktarım. Yazılım bunu tek komutta yapar; fakat raporlarken hangi kovaryans matrisinin kullanıldığını bilmek araştırmacının sorumluluğundadır.

5.8 Marjinal Etkilerin Raporlanması

Doğrusal olmayan modelde araştırmacının raporlaması gereken temel büyüklük çoğu zaman marjinal etkidir. Sürekli X_j için gözlem i 'de

$$\widehat{ME}_{ij} = \hat{\beta}_j g(X_i' \hat{\beta}).$$

Bu değer gözlemden gözleme değişir.

5.8.1 Ortalama marjinal etki

En yaygın özetlerden biri ortalama marjinal etkidir (average marginal effect, AME):

$$\widehat{AME}_j = \frac{1}{n} \sum_{i=1}^n \hat{\beta}_j g(X_i' \hat{\beta}). \quad (5.20)$$

AME, örneklemdeki gözlemlerin her birinde marjinal etkiyi hesaplayıp sonra ortalamasını alır. Bu nedenle gerçek kovaryat dağılımını korur.

Bu yaklaşım, “ortalama birey” diye veri setinde var olmayabilecek yapay bir profil oluşturmaktan kaçınır. Özellikle çok sayıda kukla değişken veya doğrusal olmayan kovaryat bulunduğunda, ortalama kovaryatlarda marjinal etki ile AME anlamlı biçimde farklı olabilir.

AME yine bir model-temelli özet olup otomatik olarak nedensel değildir. X_j endojense veya kontrol seti nedensel karşılaştırmayı tanımlamıyorsa marjinal etki yalnız koşullu ilişkiyi gösterir. Bölüm 3'teki tanımlama mantığı doğrusal olmayan modellerde de aynen geçerlidir.

5.8.2 Kukla değişkende türev yerine sonlu fark

$D \in \{0, 1\}$ olduğunda D 'ye göre türev ekonomik olarak doğal değildir. Diğer değişkenler x düzeyinde tutulduğunda sonlu fark

$$\Delta_D(x) = G(x' \beta + \beta_D) - G(x' \beta) \quad (5.21)$$

olarak hesaplanır; burada ilk terim $D = 1$, ikinci terim $D = 0$ durumunu temsil eder. Örneklem ortalaması alınırsa kukla değişken için ortalama sonlu olasılık farkı elde edilir.

Sık yapılan hata

Logit veya Probit tablosunda $\hat{\beta}_j = 0,40$ görmek “olasılık 40 yüzde puan artar” anlamına gelmez. Katsayı gizli/tek indeks ölçeğindedir. Olasılık etkisi için marjinal etki veya uygun sonlu fark hesaplanmalıdır.

Bu nedenle raporlama üç düzeyi ayırmalıdır: katsayılar modelin indeks parametreleridir; tahmin edilen olasılıklar belirli kovaryat profilleri için doğrudan anlaşılır çıktılarıdır; marjinal etkiler ise X değişiminin olasılık ölçeğine çevrilmiş etkisini gösterir. Uygulamalı tezlerde yalnız Logit katsayılarını verip yüzde puan diliyle yorumlamak yaygın fakat ciddi bir hatadır.

5.9 Hansen'in CPS Evlilik Uygulaması

Hansen'in uygulamasını izleyerek Mart 2009 Current Population Survey verisinde 35 yaş ve altındaki çalışan erkeklerin evli olma olasılığını inceliyoruz. Analiz örnekleme 9.137 gözlemdir; sonuç değişkeni medeni durum kodu 1–3 olanlar için 1'dir (eşiyle birlikte, silahlı kuvvetlerdeki eşiyle veya eşi ayrı yaşayan evli). Açıklayıcılar yaş, eğitim yılı, dört gruplu ırk (referans: beyaz; siyah, Asyalı ve diğer), Hispanik göstergesi ve bölge göstergeleridir (referans: Kuzeydoğu). Tablo 5.1 robust standart hatalarla hesaplanan ortalama marjinal etkileri gösterir. Sürekli değişkenlerde (yaş, eğitim) türevin, göstergelerde ise referans kategoriye göre tahmin edilen olasılık farkının örneklem ortalaması alınmıştır (Denklem (5.21)).

Tablo 5.1: CPS uygulaması: Logit ve Probit ortalama marjinal etkileri

Değişken	Logit		Probit	
	AME	SH	AME	SH
Yaş	0,0441	0,0009	0,0445	0,0009
Eğitim	0,0027	0,0020	0,0028	0,0020
Siyah	-0,1617	0,0184	-0,1582	0,0181
Asyalı	0,0001	0,0210	0,0019	0,0212
Diğer ırk	-0,0971	0,0255	-0,0934	0,0249
Hispanik	-0,0173	0,0130	-0,0170	0,0129
Orta Batı	0,0559	0,0151	0,0557	0,0152
Güney	0,0709	0,0144	0,0706	0,0145
Batı	0,0840	0,0148	0,0825	0,0149

Spesifikasyon notu: ırk kategorileri ve ayrışma

CPS'teki ırk değişkeni 21 ayrıntılı kod içerir; bu alt örnekleme 18'i görülür. Bütün kodlar ayrı gösterge olarak modele konursa Logit yakınsamaz: 1-2 gözlemlili dört kategoride herkes evli ya da herkes bekârdır. Böyle bir kategoride olabilirlik, katsayı $\pm\infty$ 'a giderken artmaya devam eder ve sonlu bir MLE yoktur (*yarı-tam ayrışma*). Yazılım bu durumda uyarı verir veya tekil Hessian bildirir; çözüm kategorileri anlamlı gruplara toplamaktır. Referans grubun seçimi de sonucu etkiler: "diğer ırk" grubu beyazlarla birleştirilseydi referans grup heterojenleşir ve siyah ile Asyalı göstergeleri bu karma gruba göre yorumlanırdı. Tablodaki -0,097'lik "diğer ırk" etkisi bu seçimin önemsiz olmadığını gösterir. Tablo, Bölüm 5.15'in dördüncü adımında adım adım yeniden üretilir.

İki sonuç dikkat çekicidir. İlk olarak Logit ve Probit ham katsayıları farklı ölçeklerde olsa da AME'ler neredeyse aynıdır. İkinci olarak yaş katsayısının olasılık yorumu yaklaşık 4,4 yüzde puandır: bu örneklem ve spesifikasyonda yaşın bir yıl artması evli olma olasılığında ortalama yaklaşık 0,044'lük farkla ilişkilidir. Siyah göstergesi, diğer değişkenler aynıken yaklaşık 16 yüzde puan daha düşük bir evli olma olasılığıyla ilişkilidir; Asyalı göstergesinin etkisi ise sıfıra çok yakın ve belirsizdir.

Bu örnek aynı zamanda fonksiyonel biçim uyarısı taşır. Yaş ile evlilik olasılığı tüm yaşam döngüsü boyunca doğrusal değildir. Bu nedenle 35 yaş ve altındaki alt örnekleme doğrusal yaş indeksi makul bir yerel yaklaşım iken tam yaş aralığında aynı spesifikasyon yanıltıcı olabilir. Model ailesini doğru seçmek, fonksiyonel biçim sorununu otomatik çözmez.

Uygulama tablosu okunurken üç düzey ayırmak yararlıdır. Birinci düzey işaret ve istatistiksel belirsizliktir: hangi değişkenler evli olma olasılığıyla pozitif/negatif ilişkilidir? İkinci düzey büyüklüktür: AME kaç yüzde puandır ve ekonomik olarak büyük müdür? Üçüncü düzey model duyarlılığıdır: LPM, Logit ve Probit aynı genel olasılık desenini veriyor mu?

Tahmin edilen olasılıkları birkaç temsili kovaryat profili için göstermek katsayı tablosunu somutlaştırır. Ancak "temsili birey" örneği AME'nin yerine geçmez; AME bütün örneklem kovaryat dağılımı üzerinde ortalama alır.

5.10 Çok Kategorili Sonuçlar: Multinomial Modeller

Şimdi $Y \in \{1, 2, \dots, J\}$ ve kategorilerin doğal bir sırası olmadığını düşünelim. Örneğin ulaşım tercihi otomobil, otobüs, tren ve uçak olabilir. Her kategori için

$$P_j(x) = P(Y = j \mid X = x), \quad \sum_{j=1}^J P_j(x) = 1$$

tanımlanır.

Multinomial Logit modelinde bir referans kategori için katsayılar normalize edilerek

$$P_j(x) = \frac{\exp(x' \beta_j)}{\sum_{k=1}^J \exp(x' \beta_k)} \quad (5.22)$$

biçimi kullanılır. Bütün β_j 'leri aynı anda serbest bırakmak mümkün değildir; olasılıklar yalnızca kategoriler arasındaki göreceli indeksleri belirler. Bu nedenle genellikle bir kategori için $\beta_J = 0$ normalizasyonu yapılır.

Sık yapılan hata

Multinomial Logit'in önemli yapısal kısıtlarından biri ilgisiz alternatiflerden bağımsızlık (IIA) özelliğidir. Bir alternatifin eklenmesi veya çıkarılmasının diğer iki alternatif arasındaki göreceli seçimi yapay biçimde sabit tuttuğu durumlarda model uygun olmayabilir. Model seçimi yalnızca yazılımın yakınsamasıyla değil, karar yapısıyla değerlendirilmelidir.

Çok kategorili nominal sonuçlarda kategorilerin doğal bir sırası yoktur: ulaşım tercihi otomobil, otobüs, tren veya uçak olabilir. Multinomial Logit her alternatif için bir sistematik fayda/indeks kurar ve olasılıkların toplamını bire eşitleyen bir yapı üretir. Tanımlama için bir kategori referans alınır; katsayılar bu baz alternatife göre yorumlanır.

Multinomial Logit'in önemli kısıtlarından biri IIA (ilgisiz alternatiflerden bağımsızlık) özelliğidir. Basit modelde iki alternatif arasındaki odds oranı diğer alternatiflerin özelliklerinden etkilenmez. Yakın ikame alternatifler bulunduğu anda bu varsayım gerçekçi olmayabilir. Bu nedenle uygulamada yalnız katsayı tablosu değil, öngörülen kategori olasılıkları ve marjinal etkiler incelenmeli; alternatif yapısının IIA açısından makul olup olmadığı tartışılmalıdır (Hansen, 2021).

5.11 Sıralı Sonuçlar: Ordered Probit ve Ordered Logit

Kategoriler doğal bir sıraya sahipse bu bilgi kullanılmalıdır. Gizli sürekli değişken

$$Y^* = X' \beta + u$$

olsun; burada u , X 'ten bağımsız ve dağılım fonksiyonu G olan hata terimidir; X sabit terim içermez, çünkü sabit terim eşiklerden ayrı tanımlanamaz. Eşikler

$$\alpha_1 < \alpha_2 < \dots < \alpha_{J-1}$$

ile

$$Y = j \quad \text{eğer} \quad \alpha_{j-1} < Y^* \leq \alpha_j$$

şeklinde gözlenen sıralı sonuç elde edilir; burada $\alpha_0 = -\infty$, $\alpha_J = \infty$ alınır.

Koşullu kategori olasılığı

$$P(Y = j \mid X = x) = G(\alpha_j - x'\beta) - G(\alpha_{j-1} - x'\beta) \quad (5.23)$$

şeklindedir. $G = \Phi$ seçilirse Ordered Probit, lojistik dağılım seçilirse Ordered Logit elde edilir.

Burada bir regresörün katsayısı “ Y kategorisini bir birim artırır” diye yorumlanmaz. X ’teki değişim bütün kategori olasılıklarını birlikte değiştirir; her kategori için marjinal etki ayrı hesaplanmalıdır.

Sıralı modeller, kategorilerin sırasını kullanır fakat aralarındaki mesafeyi eşit varsaymaz. “Düşük–orta–yüksek” veya Likert tipi 1–5 yanıtlarında 1’den 2’ye geçiş ile 4’ten 5’e geçişin aynı nicel farkı temsil ettiği kabul edilmez. Bunun yerine gözlenmeyen sürekli bir Y^* eğilimi ve bu eğilimi kategorilere bölen eşikler düşünülür.

$Y^* = X'\beta + u$ ve eşikler $\alpha_1 < \dots < \alpha_{J-1}$ ise, her kategori olasılığı iki dağılım fonksiyonu değeri arasındaki farktır. Bir regresörün artması en düşük ve en yüksek kategori olasılıklarını belirli yönlerde değiştirir de orta kategorilerde marjinal etkinin işareti sabit olmayabilir. Bu nedenle ordered model katsayılarını doğrudan “ Y şu kadar artar” diye yorumlamak yerine kategori olasılıkları veya kümülatif olasılıklar raporlanmalıdır.

5.12 Sayım Sonuçları: Poisson Regresyonu

$Y \in \{0, 1, 2, \dots\}$ küçük olay sayılarını gösteriyorsa temel model Poisson regresyonudur. Koşullu Poisson parametresi

$$\lambda(x) = \exp(x'\beta) \quad (5.24)$$

olarak kurulur. Böylece pozitiflik otomatik sağlanır ve

$$P(Y = j \mid X = x) = \frac{e^{-\lambda(x)} \lambda(x)^j}{j!}. \quad (5.25)$$

Poisson dağılımında

$$E[Y \mid X] = \text{var}(Y \mid X) = \lambda(X).$$

Ancak ampirik uygulamada bu ortalama–varyans eşitliği çoğu kez tam sağlanmaz. Hansen’in vurguladığı önemli nokta şudur: koşullu ortalama

$$E[Y \mid X] = \exp(X'\beta)$$

doğru belirtilmişse, Poisson quasi-MLE (QMLE) katsayıları koşullu dağılım tam Poisson olmasa bile anlamlı olabilir; bu durumda robust kovaryans matrisi kullanmak gerekir.

Sürekli X_j için

$$\frac{\partial E[Y \mid X = x]}{\partial x_j} = \beta_j \exp(x'\beta), \quad \frac{\partial \log E[Y \mid X = x]}{\partial x_j} = \beta_j. \quad (5.26)$$

Dolayısıyla β_j , koşullu beklenen sayının X_j ’ye göre yarı-esnekliğidir ($\log E[Y \mid X]$ üzerindeki marjinal etki).

Sayım değişkenleri 0, 1, 2, ... değerlerini alır ve doğal olarak negatif olamaz. Poisson regresyo-


nunda koşullu ortalama genellikle

$$E[Y | X] = \exp(X'\beta)$$

biçiminde kurulur; üstel bağlantı pozitif tahminleri garanti eder. Katsayıların üstel yapısı nedeniyle X_j 'de bir birim artış koşullu ortalamayı yaklaşık $100\beta_j$ yüzde, tam olarak $100\{e^{\beta_j} - 1\}$ yüzde değiştirir.

Klasik Poisson dağılımı koşullu ortalama ile varyansı eşitler. Ekonomik verilerde aşırı saçılma sık görülebilir; varyans ortalamadan büyük olabilir. Bu durumda dağılım varsayımı tam doğru olmayabilir. Yine de koşullu ortalama doğru belirtildiğinde Poisson quasi-MLE türü yaklaşım ve dayanıklı standart hatalar yararlı olabilir. Uygulamada sıfırların çokluğu, aşırı saçılma ve sayım sürecinin ekonomik mekanizması ayrıca değerlendirilmelidir.

5.13 Model Seçimi İçin Karar Şeması



Şekil 5.3: Ayrık sonuçlarda temel model seçimi mantığı

Model seçiminin ilk adımı Y 'nin destek kümesidir, fakat tek adım değildir. İkili sonuçta LPM/Logit/Probit arasında seçim; sayımda Poisson veya daha esnek sayım modeli; sıralı kategoride ordered model; nominal çok kategoride multinomial yapı düşünülür. Sayım sorusu sıralılık sorusundan önce sorulur: sayımlar da doğal bir sıraya sahiptir, fakat aralarındaki mesafe anlamlıdır ve ordered model bu bilgiyi kullanmaz. Sonra araştırma hedefi sorulur: olasılık öngörüsü mü, marjinal ilişki mi, yapısal/nedensel etki mi?

Aynı destek kümesi içinde farklı tanımlama sorunları devam eder. İkili Y olması endojen X sorununu çözmez; IV Probit gibi yöntemler gerekebilir. Benzer biçimde panel/kümelenme veri yapısı standart hata seçimini etkiler. Sonuç dağılımı, tanımlama ve bağımlılık yapısı ayrı karar katmanlarıdır.

5.14 Makale Sonuçlarını Okuma ve Raporlama

İkili veya ayrık sonuç modelinde iyi bir ampirik raporlama en az şu unsurları açık etmelidir:

1. sonuç değişkeninin nasıl kodlandığı ve referans kategorinin ne olduğu,
2. model ailesi ve bağlantı fonksiyonu,
3. katsayıların mı yoksa marjinal etkilerin mi raporlandığı,
4. marjinal etkilerin AME, belirli bir kovaryat noktasındaki etki veya kukla değişken sonlu farkı olup olmadığı,
5. kovaryans/standart hata türü,
6. örneklem kısıtları ve fonksiyonel biçim,
7. nedensel yorum yapılıyorsa gerekli tanımlama varsayımları.

Örnek raporlama

“Probit modelinden elde edilen ortalama marjinal etki, yaşın bir yıllık artışının evli olma olasılığında ortalama yaklaşık 0,044'lük (4,4 yüzde puanlık) farkla ilişkili olduğunu göstermektedir (robust SH=0,001). Bu sonuç gözlemsel bir koşullu ilişki olarak yorumlanmakta; yaş katsayısına nedensel müdahale anlamı yüklenmemektedir.”

5.15 Ampirik Uygulama Laboratuvarı: İkili Sonuçlarda Katsayıdan Olasılığa Geçmek

Bu uygulamada Hansen'in CPS evlilik örneğini izleyerek 35 yaş ve altındaki çalışan erkeklerde evli olma olasılığını inceliyoruz. Analiz örnekleminde 9.137 gözlem vardır. Sonuç değişkeni

$$married_i \in \{0, 1\}$$

medeni durum kodu 1–3 olanlar için 1'dir; açıklayıcılar yaş, eğitim, dört gruplu ırk (referans: beyaz), Hispanik göstergesi ve bölge göstergeleridir (Hansen, 2021). Irkın ayrıntılı kodlarıyla Logit yakınsamaz; nedeni Bölüm 5.9'daki spesifikasyon notunda açıklanmıştır.

5.15.1 Adım 1: Aynı araştırma sorusunu üç model ailesiyle sormak

İkili sonuç için üç yaygın yaklaşımı karşılaştıralım:

1. doğrusal olasılık modeli (LPM),
2. Logit,
3. Probit.

LPM'de yaş katsayısı doğrudan olasılık farkı olarak okunabilir. Logit ve Probit'te ise ham katsayı tek indeks ölçeğindedir; doğrudan yüzde puan yorumu yapılmaz. Bu nedenle karşılaştırmayı **ortalama marjinal etkiler (AME)** üzerinden yapmak daha anlamlıdır. LPM'de standart hata HC1, Logit ve Probit'te sandviç (robust) kovaryanstan gelir.

Yaş için üç yöntem yaklaşık aynı ampirik mesajı vermektedir. Logit AME'si 0,0441 olduğundan, örnekleme yaşın bir yıl artması evli olma olasılığında ortalama yaklaşık **4,4 yüzde puanlık** farkla ilişkilidir. Bu ifade “olasılık yüzde 4,4 artar” demekle aynı değildir. Başlangıç olasılığı

Tablo 5.2: CPS evlilik uygulaması: LPM ve doğrusal olmayan modellerde olasılık etkileri

Model	Yaş etkisi	SH	Eğitim etkisi	SH
LPM	0,0466	0,0010	0,00245	0,00199
Logit AME	0,0441	0,0009	0,00266	0,00198
Probit AME	0,0445	0,0009	0,00281	0,00199

yüzde 50 ise 4,4 yüzde puan artış yaklaşık yüzde 8,8 göreceli artışa karşılık gelir; yüzde puan ve yüzde değişim ayrılmalıdır.

Eğitim için AME yaklaşık 0,0027–0,0028’dir; yani bir eğitim yılı yaklaşık 0,27–0,28 yüzde puanlık olasılık farkıyla ilişkilidir. Standart hatası yaklaşık 0,002 olduğundan bu ilişkide belirsizlik yaş katsayısına göre çok daha büyüktür.

5.15.2 Adım 2: Logit katsayısını neden doğrudan yorumlamıyoruz?

Logit modelinde

$$P(Y_i = 1 \mid X_i) = \Lambda(X_i' \beta)$$

ve sürekli X_j için marjinal etki

$$\frac{\partial P(Y_i = 1 \mid X_i)}{\partial X_{ij}} = \Lambda(X_i' \beta) \{1 - \Lambda(X_i' \beta)\} \beta_j$$

olur. Dolayısıyla aynı β_j farklı bireylerde farklı olasılık etkisi üretir. AME, bu bireysel marjinal etkilerin örneklem ortalamasını alır:

$$\widehat{AME}_j = \hat{\beta}_j \cdot \frac{1}{n} \sum_{i=1}^n \Lambda(X_i' \hat{\beta}) \{1 - \Lambda(X_i' \hat{\beta})\}.$$

Bu örnekte yaştan Logit katsayısı 0,2165, örneklemdeki ortalama ölçek çarpanı $\Lambda(1 - \Lambda)$ ise 0,2036’dır; çarpımları AME’yi (0,0441) verir. Probit’te katsayı 0,1315 ve ortalama ϕ 0,3380’dir; yuvarlanmamış değerlerle çarpım 0,0445’tir. Ham katsayıların oranı yaklaşık 1,65’tir: bu fark ekonomik değil, iki modelin gizli hata ölçeğini farklı normalize etmesinden gelir (Bölüm 5.5).


Bu nedenle bir makalede Logit katsayısı 0,40 görülmesi “ X bir birim artınca olasılık 40 yüzde puan artar” anlamına gelmez. Katsayıdan olasılık diline geçmek için marjinal etki, sonlu fark veya belirli bir kovaryat profilindeki tahmin edilen olasılık hesaplanmalıdır.

5.15.3 Adım 3: Tahmin edilen olasılık profilini okumak

Şekil 5.4, yaş arttıkça ortalama tahmin edilen evlilik olasılığının yükseldiğini gösterir: 18 yaşında 0,1067 olan ortalama olasılık 35 yaşında 0,8186’ya çıkar. Burada yatay eksenindeki her yaş için örneklemdeki herkesin yaşı o değere eşitlenmiş, diğer gözlenen kovaryatlar kendi değerlerinde tutulmuş, ardından bireysel tahminler ortalanmıştır. Bu, “ortalama bireyin olasılığı” ile aynı işlem değildir. Doğrusal olmayan modellerde

$$G(E[X]' \hat{\beta}) \neq E[G(X' \hat{\beta})]$$

olduğu için “ortalama kovaryatta tahmin” ve “ortalama tahmin” farklı olabilir. Profilin S biçimi de görülür: eğitim orta yaşlarda en büyük, uçlarda daha küçüktür.



Şekil 5.4: CPS Logit modelinde yaşa göre ortalama tahmin edilen evlilik olasılığı

5.15.4 Adım 4: Yazılım çıktısından AME tablosuna geçmek

Kod 5.1: Logit modelinde robust tahmin, sürekli değişkende AME ve göstergede sonlu fark

```
logit = smf.logit(
    "married ~ age + education + C(race4) + C(hisp) + C(region)",
    data=df,
).fit(displ=False, cov_type="HC0") # sandviç kovaryans

# Sürekli değişkenler: türevin örneklem ortalaması
ame = logit.get_margeff(at="overall", method="dydx").summary_frame()
print(ame.loc[["age", "education"]])

# Gösterge: herkes siyah (race4 = 2) ve herkes beyaz (race4 = 1)
# senaryolarında ortalama tahmin edilen olasılıkların farkı
siyah, beyaz = df.assign(race4=2), df.assign(race4=1)
print(logit.predict(siyah).mean() - logit.predict(beyaz).mean())
```

Burada ilk çıktı yaş ve eğitimin ortalama marjinal etkilerini standart hatalarıyla, ikinci çıktı ise siyah göstergesinin ortalama sonlu olasılık farkını verir; ikisi de olasılık ölçeğindedir (ham Logit katsayıları `logit.params` içindedir). Bütün değişkenler için bu hesap [Tablo 5.1](#)'i üretir; standart hatalar sandviç kovaryans matrisinden delta yöntemiyle gelir ([Bölüm 5.7](#)). Uygulama sekmesi ve indirilen Python, R ve Stata betikleri tabloyu standart hatalarıyla birlikte yeniden üretir. Bir tezde hangi tablonun ana metinde gösterileceği araştırma amacına bağlıdır; ancak ekonomik yorum olasılık ölçeğinde yapılacaksa AME veya tahmin edilen olasılıkların raporlanması çoğu okuyucu için daha anlaşılırdır.

5.15.5 Adım 5: Kukla değişken için türev değil sonlu fark

Cinsiyet, politika katılımı veya bölge göstergesi gibi $D \in \{0, 1\}$ bir değişkende türev yerine

$$\Delta_D(X) = G(X'\hat{\beta} + \hat{\beta}_D) - G(X'\hat{\beta})$$

hesaplanır. Her gözlem için $D = 1$ ve $D = 0$ senaryoları tahmin edilip farkların ortalaması alınır. Siyah göstergesi için türev tabanlı yaklaşım $\hat{\beta}_D \cdot n^{-1} \sum_i \Lambda_i(1 - \Lambda_i) = -0,1598$, sonlu fark ise $-0,1617$ 'dir. Bu örnekte fark küçüktür, çünkü olasılıklar 0,5 civarında ve katsayı orta büyüklüktedir; katsayı büyüdükçe veya olasılıklar 0 ya da 1'e yaklaştıkça fark büyür.

Yazılımların “marginal effects” komutlarının kukla değişkenleri nasıl ele aldığını açıkça kontrol etmek önemlidir. Örneğin statsmodels'in `get_margeff(dummy=True)` seçeneği çok düzeyli kategorik bir değişkenin kuklalarını birbirinden bağımsız 0/1 yapar ve bu yolla olanaksız kombinasyonlar (ör. aynı anda siyah ve Asyalı) üretir; Stata'da `i.` önekiyle girilen değişkenler için `margins` referans düzeyine göre farkı kendiliğinden alır.

5.15.6 Bir ikili sonuç makalesindeki tabloyu nasıl okumalıyız?

1. Sonuç değişkeninde 1 hangi olayı temsil ediyor?
2. Raporlanan sayılar ham Logit/Probit katsayısı mı, odds ratio mu, AME mi?
3. Sürekli ve kukla değişkenler için aynı etki tanımını mı kullanılmış?
4. Standart hatalar hangi kovaryans yapısına dayanıyor?
5. Tahmin edilen olasılıklar $[0, 1]$ aralığında mı ve model uç bölgelerde yeterli destek görüyor mu?
6. Logit ve Probit benzer olasılık sonuçları veriyor mu?
7. Modelin nedensel yorumu için hangi tanımlama varsayımı kullanılıyor?

Tez yazımında örnek sonuç dili

“Logit modelinden elde edilen ortalama marjinal etki, yaşı bir yıl artmasının evli olma olasılığında ortalama yaklaşık 4,4 yüzde puanlık pozitif bir farkla ilişkili olduğunu göstermektedir. Probit tahmini de 4,4 yüzde puan ile neredeyse aynıdır. Sonuçlar gözlemsel CPS verisine dayandığından katsayılar nedensel yaşam-döngüsü etkisi olarak yorumlanmamıştır.”

5.16 Temel Sonuçlar

1. İkili sonuçta $E[Y | X] = P(Y = 1 | X)$ eşitliği temel başlangıç noktasıdır.
2. LPM kolay yorumlanır; fakat olasılık sınırlarını ihlal edebilir ve ikili yapıda heteroskedastisite kaçınılmazdır.
3. Logit ve Probit, $G(X'\beta)$ biçimiyle olasılığı $[0, 1]$ aralığında tutar.
4. Doğrusal olmayan ikili modellerde katsayı olasılık değişimi değildir; marjinal etkiler raporlanmalıdır.
5. Ham Logit ve Probit katsayıları ölçek normalizasyonları farklı olduğu için doğrudan karşılaştırılmamalıdır.
6. Sırasız çok kategori, sıralı kategori ve sayım sonuçları farklı koşullu dağılım modelleri gerektirir.

7. Model ailesi sonuç değişkeninin desteğine uygun koşullu dağılımı sağlar; içsellik, seçim veya yanlış fonksiyonel biçim sorunlarını otomatik olarak çözmez.

5.17 Bölüm Sonu Egzersizleri

Egzersiz 5.1: İkili koşullu ortalama

$Y \in \{0, 1\}$ olsun ve $P(Y = 1 | X = x) = 0,37$ verilsin.

1. $E[Y | X = x]$ değerini bulunuz.
2. $\text{var}(Y | X = x)$ değerini hesaplayınız.
3. Sonucun neden ikili regresyonda heteroskedastisiteyi doğal hâle getirdiğini açıklayınız.

Egzersiz 5.2: LPM yorumu

Tahmin edilen model $\hat{P}(Y = 1 | X) = 0,18 + 0,055X$ olsun.

1. Eğim katsayısını yorumlayınız.
2. $X = 10$ ve $X = 18$ için tahmin edilen olasılıkları hesaplayınız.
3. İkinci tahmin LPM hakkında hangi sorunu görünür kılıyor?

Egzersiz 5.3: Logit olasılığı

$P(Y = 1 | X) = \Lambda(-1 + 0,8X)$ olsun.

1. $X = 0$ ve $X = 2$ için olasılıkları hesaplayınız.
2. $X = 0$ ve $X = 2$ noktalarında X 'in marjinal etkisini hesaplayınız.
3. Aynı 0,8 katsayısının neden iki noktada farklı olasılık etkisi verdiğini açıklayınız.

Egzersiz 5.4: Bernoulli olabirliği

Üç gözlem için $Y = (1, 0, 1)$ ve modelin tahmin ettiği olasılıklar $p = (0,8, 0,3, 0,6)$ olsun.

1. Örneklem olabirliğini hesaplayınız.
2. Log-olabirliği yazınız.
3. Alternatif bir model $p = (0,6, 0,5, 0,5)$ üretiyorsa hangi model gözlenen veri açısından daha yüksek olabirliğe sahiptir?

Egzersiz 5.5: MLE standart hatası

1. denklem (5.17)'deki Q ve Ω matrislerinin ne ölçtüğünü kendi cümlelerinizle yazınız.
2. Bilgi matrisi eşitliği hangi koşulda geçerlidir ve bozulduğunda hangi formül kullanılır?

3. Log-olabilirlik maksimum noktasında çok basık ise standart hata büyük mü küçük mü olur? Neden?
4. Bir Logit çıktısında “robust” seçeneğinin LPM’deki “robust” seçeneğinden farkı nedir?

Egzersiz 5.6: Katsayı mı, AME mi?

Bir Probit modelinde eğitim katsayısı 0,14 bulunmuştur. Araştırmacı “bir eğitim yılı katılım olasılığını 14 yüzde puan artırır” demektedir.

1. Bu yorum neden yanlıştır?
2. Doğru marjinal etki formülünü yazınız.
3. Ortalama marjinal etkinin nasıl hesaplanacağını açıklayınız.

Egzersiz 5.7: Kukla değişkende sonlu fark

Logit modelinde $P(Y = 1 | X, D) = \Lambda(-0,5 + 0,6X + 0,9D)$ olsun. $X = 1$ için $D = 0$ ve $D = 1$ olasılıklarını ve sonlu farkı hesaplayınız.

Egzersiz 5.8: CPS tablosu

Tablo 5.1’i kullanınız.

1. Yaş için Logit ve Probit AME’lerini karşılaştırınız.
2. “Siyah” göstergesi için olasılık farkını yüzde puan cinsinden yorumlayınız.
3. Eğitim değişkeninin nokta tahmini ile standart hatasını birlikte değerlendiriniz.
4. Ham Logit ve Probit katsayıları tabloya eklenmiş olsaydı neden yalnız büyüklük karşılaştırması yapmamak gerekirdi?

Egzersiz 5.9: Ordered model

Bir memnuniyet değişkeni 1=çok düşük, 2=düşük, 3=orta, 4=yüksek, 5=çok yüksek olarak kodlanmıştır.

1. Bu değişkeni sıradan doğrusal regresyonda kullanmanın hangi ölçüm varsayımını örtük olarak getirdiğini açıklayınız.
2. Ordered Probit modelinin gizli değişken ve eşik yapısını yazınız.
3. Bir regresörün katsayısının neden doğrudan “kategori sayısındaki değişim” olarak okunamayacağını açıklayınız.

Egzersiz 5.10: Multinomial referans kategori

Üç ulaşım seçeneği için Multinomial Logit kurulmaktadır: otomobil, otobüs, tren.

1. Neden bütün kategori sabitlerini ve katsayılarını aynı anda serbestçe tanımlayama-

yız?

2. Tren referans kategori seçilirse hangi normalizasyon yapılabilir?
3. IIA varsayımının bu uygulamada neden sorgulanabileceğine bir örnek veriniz.

Egzersiz 5.11: Poisson katsayısı

Doktor ziyareti sayısı için

$$E[Y | X] = \exp(0,4 + 0,20X)$$

modeli tahmin edilmiştir.

1. $X = 0$ ve $X = 2$ için beklenen ziyaret sayılarını hesaplayınız.
2. X 'in bir birim artmasının beklenen sayıya yaklaşık yüzde etkisini yorumlayınız.
3. Koşullu varyans ortalamadan büyükse hangi çıkarım düzeltmesi en azından düşünülmelidir?

Egzersiz 5.12: Model seçimi

Aşağıdaki sonuçlar için ilk tercih edeceğiniz model ailesini ve nedenini yazınız: (i) kredi temerrüdü evet/hayır, (ii) ürün tercihi A/B/C/D, (iii) kredi notu düşük/orta/yüksek, (iv) yıldaki iş kazası sayısı.

Egzersiz 5.13: Araştırma tasarımı

Bir işletme, çalışanların uzaktan çalışma seçiminin işten ayrılma olasılığı üzerindeki etkisini Logit modeliyle tahmin etmiş ve anlamlı bir AME bulmuştur. “Logit kullandığımız için sonuç nedenseldir” iddiasını değerlendiriniz. Sonuç değişkeninin yapısına uygun model seçimi ile nedensel tanımlama arasındaki farkı açıklayınız.

Sansürleme, Kesilme (Truncation) ve Örneklem Seçimi

Bu bölümün amacı

Bu bölümün sonunda sansürleme, kesilme (truncation) ve örneklem seçiminin birbirinden farklı veri üretim mekanizmaları olduğunu açıklayabilecek; gizli sonuç Y^* ile gözlenen sonuç Y arasındaki ilişkiyi kurabilecek; sansürleme altında tam örneklem OLS ve yalnız pozitif gözlemlerle OLS'nin neden farklı hedeflere yöneldiğini gösterebilecek; Tobit modelinin koşullu dağılımını ve olabilirliğini kurabilecek; Tobit katsayılarını gizli sonuç, sansürlenmeme olasılığı ve gözlenen koşullu ortalama açısından ayırabilecek; örneklem seçimi yanlılığını koşullu hata ortalaması üzerinden türetebilecek; Heckman iki aşamalı düzeltmesinde seçim denklemi, ters Mills oranı ve dışlama kısıtının rolünü açıklayabilecek ve ampirik bir çalışmada naif OLS ile seçim/sansürleme modellerini doğru karşılaştırabileceksiniz.

Bağlantı

Bölüm 5'te sonuç değişkeninin destek kümesinin model seçimini nasıl etkilediğini gördük. Bu bölümde daha incelikli bir durum vardır: gözlediğimiz veri, altında yatan sürekli ekonomik sonucun dönüştürülmüş veya seçilmiş bir kısmıdır. Dolayısıyla sorun yalnızca “ Y sınırlıdır” değildir; *hangi değerlerin neden gözlemlendiğini* modellemek gerekir. Hansen'in sansürleme ve seçim ayrımı bu bölümün omurgasını oluşturur (Hansen, 2021).

6.1 Üç Farklı Veri Yapısını Ayıralım

Sansürleme (censoring), kesilme (truncation) ve örneklem seçimi literatürde bazen birbirine karıştırılır. Oysa ekonometrik sonuçları farklıdır.

Sansürleme

Gizli sürekli sonuç Y^* bütün birimler için var, fakat belirli bir sınıрын ötesindeki değerler aynı gözlenen değere dönüştürülüyorsa veri sansürlüdür. Soldan sıfırda sansürleme için

$$Y = \max\{Y^*, 0\}.$$

$Y^* \leq 0$ olan birimlerin varlığını gözleriz; ancak gerçek gizli değerlerini gözlemeyiz.

Kesilme (truncation)

Belirli sınırın dışındaki birimler veri setine hiç girmiyorsa dağılım truncate edilmiştir. Örneğin yalnız $Y^* > 0$ olan birimleri gözlemek

$$Y^\# = Y^* \mid Y^* > 0$$

şeklinde düşünülebilir. Burada sınır altındaki birimlerin sayısı ve açıklayıcı değişkenleri dahi gözlenmeyebilir.

Örneklem seçimi

Bir sonucun gözlenip gözlenmemesi ayrı bir seçim mekanizmasına bağlıysa örneklem seçimi vardır. Seçim göstergesi $S \in \{0, 1\}$ ile

$$Y = Y^* \text{ yalnızca } S = 1 \text{ iken gözlenir.}$$

Seçim, sonuç denklemindeki gözlenemeyenlerle ilişkiliyse endojen seçim ortaya çıkar.

Tablo 6.1: Sansürleme, kesilme ve seçim arasındaki temel ayrım

	Sansürleme	Kesilme	Örneklem seçimi
Sınırdaki/eksik birim biliniyor mu?	Evet	Genellikle hayır	Seçim göstergesi varsa evet
Y^* gözleniyor mu?	Sınırın bir tarafında	Yalnız seçilen bölgede	Yalnız $S = 1$ için
Ana mekanizma	Değer dönüşümü	Örnekleme desteği	Katılım/gözlenme kararı
Naif OLS sorunu	Censored mean hede	Truncated mean hede	Seçim terimi eksikliği

Bu ayrım, olabilirliğin ve tanımlamanın nasıl kurulacağını değiştirir. Sansürlü bir gözlem “ Y^* ’ın gerçek değeri tam bilinmiyor ama eşik tarafında olduğunu biliyorum” bilgisi taşır. Kesilmiş gözlemlerde o birime ilişkin satır yoktur. Seçim modelinde ise gözlenme olasılığı, sonuç denklemindeki gözlenmeyen bileşenle ilişkili olabilir. Aynı ‘drop missing’ komutu bu üç veri üretim mekanizmasını birbirinden ayıramaz; araştırmacının veri toplama sürecini bilmesi gerekir.

6.2 Klasik Sansürlü Regresyon Modeli

Soldan sıfırda sansürlü klasik model

$$Y_i^* = X_i' \beta + e_i, \quad (6.1)$$

$$e_i \mid X_i \sim N(0, \sigma^2), \quad (6.2)$$


$$Y_i = \max\{Y_i^*, 0\} \quad (6.3)$$

şeklinde. Bu yapı Tobit veya Type I Tobit modeli olarak bilinir.

Burada üç farklı ekonomik/istatistiksel nesne vardır:

1. Y^* : gizli, sansürlenmemiş sonuç,

2. Y : gözlenen, sıfırda yığılma içeren sansürlü sonuç,
3. $Y^\#$: yalnız pozitif gözlemler kullanılırsa ortaya çıkan truncate edilmiş sonuç.



Şekil 6.1: Sansürlü regresyonda gizli sonuçtan gözlenen sonuca geçiş

6.3 Sansürleme Olasılığı ve Üç Koşullu Ortalama

Model altında sansürlenme olasılığı

$$P(Y = 0 \mid X = x) = \Phi\left(-\frac{x'\beta}{\sigma}\right). \quad (6.4)$$

Dolayısıyla $x'\beta$ yükseldikçe sansürlenme olasılığı düşer.

$\lambda(a) = \phi(a)/\Phi(a)$ ters Mills oranı olsun. Hansen'in verdiği üç koşullu ortalama ayrımı özellikle önemlidir:

$$m^*(x) = E[Y^* \mid X = x] = x'\beta, \quad (6.5)$$

$$m(x) = E[Y \mid X = x] = x'\beta\Phi\left(\frac{x'\beta}{\sigma}\right) + \sigma\phi\left(\frac{x'\beta}{\sigma}\right), \quad (6.6)$$

$$m^\#(x) = E[Y^* \mid X = x, Y^* > 0] = x'\beta + \sigma\lambda\left(\frac{x'\beta}{\sigma}\right). \quad (6.7)$$

Bunlar aynı regresyon fonksiyonu değildir. $m^*(x)$ gizli sonuç ortalamasıdır; $m(x)$ gözlenen sansürlü sonucun ortalamasıdır; $m^\#(x)$ yalnız pozitif gözlemlerdeki ortalamadır.

Hedef değiştiğinde “yanlılık” dili

Tam örneklemde OLS, genel olarak $m(x)$ 'in en iyi doğrusal projeksiyonunu hedefler; yalnız pozitif gözlemlerle OLS ise $m^\#(x)$ ilişkisini hedefler. Eğer araştırma hedefi gizli $m^*(x) = x'\beta$ ise iki yaklaşım da yanlış hedefe yönelir. Bu nedenle “sıfırları silelim” sansürleme probleminin genel çözümü değildir.

Kısa gösterim için $z = x'\beta/\sigma$ yazarsak sansürlenmeme olasılığı $P(Y > 0 \mid X = x) = \Phi(z)$, pozitif alt örneklem ortalaması $x'\beta + \sigma\phi(z)/\Phi(z)$ ve gözlenen ortalama $\Phi(z)x'\beta + \sigma\phi(z)$ olur. Aynı β bu üç fonksiyonda farklı marjinal etkilere dönüşür; Tobit yorumunun sıradan OLS yorumundan daha dikkatli olmasının nedeni budur.

6.4 Naif OLS Neden Eğimi Bozabilir?

Sansürleme koşullu ortalamayı doğrusal olmaktan çıkarır. Özel olarak (sabit dışındaki) regresörler ortak normal dağılımlıysa Hansen'in aktardığı Greene sonucu, tam örneklem OLS'nin hedeflediği

en iyi doğrusal öngörücünün (BLP) eğim katsayılarının

$$\beta_{BLP} = \beta(1 - \pi) \quad (6.8)$$

olduğunu, yani eğimlerin $1 - \pi$ çarpanıyla sıfıra doğru küçüldüğünü gösterir; burada $\pi = P(Y = 0)$ sansürlenme oranıdır. Bu sonuç özel varsayımlara bağlıdır fakat önemli bir sezgi verir: sansürleme arttıkça gözlenen doğrusal eğim gizli eğime göre düzleşebilir.

6.4.1 Kontrollü benzetim

Aşağıdaki veri üretim sürecini düşünelim:

$$X \sim U[-3, 3], \quad Y^* = 1 + X + e, \quad e \sim N(0, 1), \quad Y = \max\{Y^*, 0\}.$$

5.000 gözlemlik, tohumu 807 olan bir benzetimde (önce X , sonra e çekilir) yaklaşık yüzde 33,5 gözlem sıfırda sansürlenmektedir. Gerçek gizli eğim 1'dir. Uygulamanın Sezgi sekmesindeki ilk deneyin varsayılan ayarları bu benzetimdir; parametreler değiştirilerek sansürlenme oranının etkisi izlenebilir.

Tablo 6.2: Sansürleme benzetimi: aynı veri üretim sürecinde üç tahmin

Yöntem	Sabit	Eğim
Tam örneklem OLS, Y üzerinde	1,421	0,716
Yalnız $Y > 0$ OLS	1,484	0,745
Tobit MLE	1,006	1,002
Gerçek gizli model	1,000	1,000

Bu tek benzetim bir teorem değildir; fakat mekanizmayı açıkça gösterir. Sıfırları tam örneklemede tutmak da silmek de gizli eğimi geri getirmemektedir. Doğru tanımlanmış Tobit olabilirliği ise sansürleme mekanizmasını kullandığı için hedef parametreyi yaklaşık olarak geri kazanır.

Mekanizma şudur: $x'\beta$ çok düşükken gözlemlerin büyük bölümü sıfırda yığılır; $x'\beta$ yükseldikçe hem pozitif gözlenme olasılığı hem de pozitif değerlerin büyüklüğü artar. Bu nedenle $E[Y | X = x]$ genel olarak $x'\beta$ 'nın doğrusal fonksiyonu değildir; OLS bu doğrusal olmayan eğriye tek bir doğru uydurur.

Yalnız pozitif gözlemleri alıp OLS çalıştırmak da sorunu çözmez. Pozitif olma koşulu e 'nin dağılımını seçer: $Y^* > 0$ olan alt örneklemede hata teriminin koşullu ortalaması sıfır değildir ve x ile değişir. Tobit olabilirliği hem sıfır kütlelerini hem pozitif sürekli kısmı birlikte kullanarak bu mekanizmayı modellemeye çalışır.

6.5 Tobit Olabilirliği

Tobit modelinde gözlenen dağılım karma bir yapıdadır. $Y = 0$ gözlemleri bir olasılık kütleline, $Y > 0$ gözlemleri sürekli normal yoğunluğa katkı yapar.

Bir gözlem için

$$f(y | x) = \left[\Phi\left(-\frac{x'\beta}{\sigma}\right) \right]^{1_{\{y=0\}}} \left[\frac{1}{\sigma} \phi\left(\frac{y - x'\beta}{\sigma}\right) \right]^{1_{\{y>0\}}}. \quad (6.9)$$

Bu nedenle log-olabilirlik

$$\ell_n(\beta, \sigma) = \sum_{Y_i=0} \log \Phi\left(-\frac{X_i'\beta}{\sigma}\right) \quad (6.10)$$

$$+ \sum_{Y_i>0} \left[-\log \sigma + \log \phi\left(\frac{Y_i - X_i'\beta}{\sigma}\right) \right]. \quad (6.11)$$

Tobit MLE

$$(\hat{\beta}, \hat{\sigma}) = \arg \max_{b, s>0} \ell_n(b, s)$$

ile elde edilir.

Olabilirlikte iki bilgi kaynağı

Sıfır gözlemleri yalnızca “değersiz veri” değildir; $P(Y = 0 \mid X)$ hakkında bilgi taşırlar. Pozitif gözlemler ise hem gözlenme olasılığı hem de sürekli sonucun konumu hakkında bilgi taşır. Tobit’in tam örneklem avantajı bu iki bilgi türünü aynı olabilirlikte birleştirmesidir.

Buradaki kritik ayrım, sansürlü gözlemin katkısının bir yoğunluk değeri değil bir *olasılık* olmasıdır. $Y_i = 0$ gözlemi bize yalnız $Y_i^* \leq 0$ bilgisini verir; katkı $\Phi(-X_i'\beta/\sigma) = 1 - \Phi(X_i'\beta/\sigma)$ olasılığıdır. $Y_i > 0$ ise latent değer tam gözlendiği için normal yoğunluk katkısı kullanılır.

Bu yapı sınırlı bağımlı değişken modellerinin genel mantığını gösterir: gözlenen veri her birim için farklı türde bilgi taşıyabilir ve likelihood bu bilgiyi uygun olasılık/yoğunluk katkısıyla temsil eder.

6.6 Tobit Katsayısı Nasıl Yorumlanır?

β_j doğrudan gözlenen Y ortalamasının marjinal etkisi değildir. Üç ayrı etki sorusu vardır.

6.6.1 Gizli sonuç üzerindeki etki

$$\frac{\partial E[Y^* \mid X = x]}{\partial x_j} = \beta_j.$$

Bu, modelin gizli sürekli sonucuna ilişkin eğimdir.

Latent denklem ekonomik olarak anlamlı olsa bile Y^* her zaman doğrudan gözlenebilir bir büyüklük değildir. Örneğin istenen çalışma saati negatif olabilen teorik bir arz eğilimi olarak düşünülebilir; fiili saat ise sıfırdan küçük olamaz. Bu durumda β latent davranış indeksini açıklar. Araştırmacı latent kavramın alan açısından anlamlı olduğunu savunabilmelidir; aksi halde Tobit yalnız matematiksel bir kolaylık haline gelir.

6.6.2 Sansürlenmeme olasılığı üzerindeki etki

$$P(Y > 0 \mid X = x) = \Phi\left(\frac{x'\beta}{\sigma}\right),$$

dolayısıyla

$$\frac{\partial P(Y > 0 \mid X = x)}{\partial x_j} = \frac{\beta_j}{\sigma} \phi\left(\frac{x'\beta}{\sigma}\right). \quad (6.12)$$

Dolayısıyla bu etki sabit değildir; latent indeksin bulunduğu noktaya göre değişir. Yapı, Bölüm 5'teki Probit marjinal etki mantığının aynısıdır: katsayıları σ ile bölünmüş (β/σ) bir tek indeks modeli.

6.6.3 Gözlenen koşullu ortalama üzerindeki etki

Tobit'in özel normal-homoskedastik yapısında

$$\frac{\partial E[Y | X = x]}{\partial x_j} = \beta_j \Phi\left(\frac{x' \beta}{\sigma}\right). \quad (6.13)$$

Bu nedenle aynı β_j farklı x noktalarında gözlenen ortalamayı farklı büyüklüklerde değiştirir.

Sık yapılan hata

Tobit tablosundaki $\hat{\beta}_j$ 'yi doğrudan “ X_j bir birim artınca gözlenen Y şu kadar artar” diye okumak genel olarak yanlıştır. Önce hangi hedefin – gizli sonuç, pozitif olma olasılığı, gözlenen ortalama veya pozitif alt örneklem ortalaması – yorumlandığı belirtilmelidir.

Bu nedenle “Tobit katsayısı 2,4; X bir birim artınca gözlenen Y 2,4 artar” yorumu genel olarak yanlıştır. Araştırma sorusunun hangi sonucu hedeflediği önce belirlenmelidir. Eğer politika sorusu pozitif harcama yapma olasılığıyla ilgiliyse olasılık marjinal etkisi; toplam ortalama harcamayla ilgiliyse gözlenen koşullu ortalama marjinal etkisi raporlanmalıdır.

Gözlenen Y ortalaması hem sıfırdan pozitif bölgeye geçiş olasılığını hem de pozitif sonuçların büyüklüğünü birlikte içerir. Bu marjinal etki, $0 < \Phi(\cdot) < 1$ olduğundan mutlak değerce latent β_j 'den küçüktür ve X düzeyine göre değişir. Politika ilgisi toplam beklenen harcama, bağış veya çalışma saati ise çoğu zaman bu marjinal etki daha doğrudan ekonomiktir.

Uygulamada yazılımın `margins` benzeri komutunun hangi koşullu ortalamayı hesapladığı mutlaka kontrol edilmelidir; “Tobit marginal effect” tek bir nesne değildir.

6.7 Tobit'in Güçlü Varsayımları

Klasik Tobit modeli üç güçlü bileşen içerir:

1. gizli koşullu ortalamanın doğru fonksiyonel biçimi,
2. hata teriminin X 'ten bağımsız/homoskedastik yapısı,
3. normal dağılım varsayımı.

Özellikle normalite ve homoskedastisite, sansürlenme olasılığı ile pozitif gözlemlerin koşullu dağılımını aynı parametre setiyle birbirine bağlar. Bu nedenle klasik Tobit yanlış dağılım veya heteroskedastisiteye karşı sıradan OLS kadar toleranslı değildir.

Daha dayanıklı alternatifler

Hansen, normaliteye daha az bağımlı censored least absolute deviations (CLAD) ve censored quantile regression (CQR) yöntemlerini de tartışır. Bu dersin ana hedefi Tobit mantığını ve seçim problemini kurmaktır. CLAD/CQR, Bölüm 7'deki kantil regresyon mantığıyla doğal bir ileri bağlantı sağlar.

Bu üç bileşenin ortak sonucu şudur: klasik Tobit, aynı β vektörünün hem sıfırda olup olmama kararını hem de pozitif sonuç büyüklüğünü yönettiğini varsayar. Bir kişinin harcamaya başlayıp başlamamasını belirleyen mekanizma ile harcama yaptıktan sonraki miktarı belirleyen mekanizma farklıysa, tek denklemlili Tobit yapısı yetersiz kalır.

Bu nedenle uygulamada iki-aşamalı/hurdle türü modeller, sansürlü kantil yöntemleri veya daha esnek dağılımlar alternatif olabilir. Bu derste odak klasik Tobit mantığını anlamaktır: yöntem ancak sansürleme mekanizması ve latent denklem varsayımları araştırma bağlamıyla uyumluysa anlamlıdır. Model seçimi yalnız “Y’de çok sıfır var” gözlemine dayanmamalıdır.

6.8 Hansen’in Filipinler Transfer Uygulaması

Hansen, Cox–Hansen–Jimenez verisinde Filipinli hanelerin transfer gelirlerini inceler. Bazı transfer bileşenlerinde büyük bir sıfır yığılması vardır; örneğin yurt dışından transfer değişkeninde hanelerin çoğu sıfır değerindedir. Belirli transfer bileşenlerinin toplamı kullanıldığında sansürlenme oranı yaklaşık yüzde 18’dir. Hansen aynı esnek gelir spesifikasyonunu OLS, Tobit, LAD ve CLAD ile karşılaştırır.

Uygulamanın ana dersi yöntemler arası “hangisi daha anlamlı çıktı?” yarışı değildir. Sansürleme, ortalama ile medyan farkı ve dağılım varsayımları tahmin edilen regresyon düzeyini birlikte değiştirebilir. Veri bağlamında önce hangi gözlemlerin sansürlü olduğu, eşik noktasının ekonomik anlamı ve latent sonuç yorumunun makul olup olmadığı sorulmalıdır. Ardından OLS ve Tobit sonuçları arasındaki farkın hangi mekanizmadan kaynaklandığı tartışılır. Büyük fark otomatik olarak Tobit’in doğru olduğunu kanıtlamaz; yalnız sansürlemeyi yok saymanın sonuç üzerinde önemli olabileceğini gösterir.

Uygulama okurken standart hata ve marjinal etki hesaplarının hangi model varsayımlarına dayandığını da kontrol etmek gerekir. Tobit MLE dağılım yanlış belirtimine duyarlı olduğundan model diagnostikleri ve alternatif spesifikasyonlar sonuçların güvenilirliği açısından önem taşır (Hansen, 2021).

6.9 Örneklem Seçimi Yanlılığı

Sansürlemede bütün birimleri görürüz; yalnız bazı Y^* değerlerini tam gözlemeyiz. Örneklem seçiminde ise sonuç yalnız seçilen birimler için gözlenebilir. Gizli sonuç modeli

$$Y^* = X'\beta + e \quad (6.14)$$

ve seçim göstergesi S olsun. Seçilmiş örneklemde

$$E[Y | X, S = 1] = X'\beta + E[e | X, S = 1]. \quad (6.15)$$

Eğer

$$E[e | X, S = 1] \neq 0,$$

seçilmiş örneklemde OLS yapısal β ’yı hedeflemez.

Endojen seçim

Sonucun gözlenmesini belirleyen seçim mekanizması, sonuç denklemindeki gözlenemeyen faktörlerle ilişkiliyse seçim endojendir. Sorun “örneklemin küçük olması” değil, gözlenen alt örneğin sonuç hatası bakımından sistematik seçilmesidir.

Ücret regresyonu klasik örnektir. Potansiyel ücret herkes için kavramsal olarak tanımlı olabilir, fakat ücret yalnız çalışan kişilerde gözlenir. Çalışma kararı etkileyen gözlenemeyen motivasyon, sağlık veya beceri aynı zamanda potansiyel ücreti etkiliyorsa çalışanların ücret regresyonu rastgele bir alt örneklem değildir.

Örneklem seçimi probleminde Y yalnız belirli bir seçim gerçekleştiğinde gözlenir. Ücret örneğinde piyasa ücreti yalnız çalışan bireyler için gözlenebilir. Çalışma kararı beklenen ücretle ve gözlenmeyen motivasyon, sağlık veya aile koşullarıyla ilişkiliyse çalışanların ücret denklemini rassal bir alt örneklem değildir. Gözlenen ücretler, anakütlenin ücret dağılımından seçilmiş bir kesittir.

Basitçe çalışanlar üzerinde OLS çalıştırmak, seçim mekanizması sonuç denklemindeki hatayla ilişkiliyse $E[e | X, S = 1] \neq 0$ sorunuyla karşılaşır. Bu yanlışlık örneklem büyüdükçe kaybolmaz. Problem eksik gözlemlerin sayısından ziyade neden eksik olduklarıdır. Seçim gözlenebilir değişkenlere koşullu olarak rassalsa standart eksik veri yaklaşımları yeterli olabilir; Heckman modeli özellikle gözlenmeyen bileşenler arasında korelasyon ihtimalini modellemeye yöneliktir.

6.10 Seçim Mekanizmasını Bir Gizli Denklemlerle Kurmak

Seçim denklemi

$$S^* = Z'\gamma + u, \quad (6.16)$$

$$S = 1\{S^* > 0\} \quad (6.17)$$

olsun. e ile u ilişkiliyse seçilen birimlerde e 'nin ortalaması sıfır olmayabilir.

(e, u) , (X, Z) 'den bağımsız ve sıfır ortalamalı ortak normal dağılımlıysa ve seçim hatası $\text{var}(u) = 1$ olarak normalize edilmişse (Probit) Hansen'in seçilmiş örneklem koşullu ortalaması

$$E[Y | X, Z, S = 1] = X'\beta + \sigma_{21}\lambda(Z'\gamma) \quad (6.18)$$

şeklindedir. Burada

$$\lambda(v) = \frac{\phi(v)}{\Phi(v)}$$

ters Mills oranıdır ve $\sigma_{21} = \text{cov}(e, u)$ seçim ve sonuç gözlenemeyenleri arasındaki bağı temsil eder.

Bu denklem seçim yanlışlığını bir eksik değişken problemi olarak görmemizi sağlar. Seçilmiş örnekleme yalnız

$$Y = X'\beta + \text{hata}$$

yazıp $\lambda(Z'\gamma)$ terimini dışarıda bırakırsak, bu terim X ile ilişkili olduğunda eksik değişken yanlışlığı oluşur.

Klasik seçim modeli iki latent denklem kullanır:

$$Y_i^* = X_i' \beta + e_i, \quad S_i^* = Z_i' \gamma + u_i,$$

ve $Y_i = Y_i^*$ yalnız $S_i = 1\{S_i^* > 0\} = 1$ olduğunda gözlenir. Kritik unsur e_i ile u_i arasındaki korelasyondur. Eğer $\rho = \text{corr}(e, u) = 0$ ise seçim, X ve Z verildiğinde sonuç hatasıyla ilişkili değildir; $\sigma_{21} = 0$ olduğundan seçim terimi $\sigma_{21}\lambda(Z'\gamma)$ kaybolur ve seçilmiş örneklemde OLS β 'yı hedefler. $\rho \neq 0$ olduğunda ise gözlenme koşulu e 'nin dağılımını da seçer; $\text{var}(u) = 1$ normalizasyonuyla $\sigma_{21} = \rho\sigma_e$ olur.

Bu iki denklem, “verinin neden eksik olduğu” sorusunu açık bir ekonomik modele dönüştürür. Seçim denklemiindeki Z değişkenleri yalnız istatistiksel tahmin yardımcıları değil, örneğe girme kararının belirleyicileridir. Bu nedenle değişken seçimi ekonomik davranışla gerekçelendirilmelidir.

6.11 Heckman İki Aşamalı Tahmin

Heckman yaklaşımı, seçilmeyen birimler için de S ve Z bilgisinin gözlendiğini varsayar. Model

$$Y^* = X'\beta + e, \quad (6.19)$$

$$S^* = Z'\gamma + u, \quad (6.20)$$

$$S = 1\{S^* > 0\}, \quad (6.21)$$

$$Y = Y^* \quad \text{yalnızca } S = 1 \text{ iken} \quad (6.22)$$

şeklindedir.


İki aşama:

1. **Seçim denklemi:** tam örneklemde S üzerine Z ile Probit tahmin edilir ve $\hat{\gamma}$ elde edilir.
2. **Sonuç denklemi:** seçilmiş örneklemde

$$Y_i = X_i' \beta + \sigma_{21} \hat{\lambda}_i + \varepsilon_i, \quad \hat{\lambda}_i = \frac{\phi(Z_i' \hat{\gamma})}{\Phi(Z_i' \hat{\gamma})}$$

OLS ile tahmin edilir.

$\hat{\lambda}_i$ üretilmiş regresördür. Ayrıca γ bilinse bile, $\rho \neq 0$ iken seçilmiş örneklemdeki ikinci aşama hatası heteroskedastiktir. Bu nedenle sıradan ikinci aşama OLS standart hataları tam olarak doğru değildir; seçim düzeltmesine uygun kovaryans hesabı veya joint maximum likelihood kullanılmalıdır.



Şekil 6.2: Heckman iki aşamalı seçim düzeltmesinin akışı

Normal hata varsayımı altında seçim koşullu sonuç hatasının beklenen değeri ters Mills oranıyla ifade edilebilir. Seçim probitinden

$$\hat{\lambda}_i = \frac{\phi(Z_i'\hat{\gamma})}{\Phi(Z_i'\hat{\gamma})}$$

benzeri bir düzeltme terimi elde edilir (seçim tanımına göre biçim değişebilir). İkinci aşamada gözlenen örnekleme

$$Y_i = X_i'\beta + \sigma_{21}\hat{\lambda}_i + \text{hata}$$

regresyonu çalıştırılır. $\hat{\lambda}$ seçilmiş örnekleme hata teriminin sıfır olmayan koşullu ortalamasını temsil eden kontrol fonksiyonudur.

Bu prosedürü “eksik veriyi tahmin edip doldurma” yöntemi olarak düşünmemek gerekir. Heckman iki aşama gözlenmeyen sonuçları bireysel düzeyde imputasyonla tamamlamaz; seçim nedeniyle hata teriminde oluşan sistematik koşullu ortalamayı modele dahil eder. Ayrıca $\hat{\lambda}$ ilk aşamadan tahmin edildiği için ikinci aşamanın sıradan OLS standart hataları uygun düzeltme olmadan tam doğru değildir. Tam maksimum olabilirlik veya özel Heckman rutinleri çıkarımı birlikte ele alır (Heckman, 1979; Hansen, 2021).

6.12 Dışlama Kısıtı Neden Önemlidir?

Teorik olarak Z ile X tamamen aynı değişkenleri içerse bile model doğrusal olmayan ters Mills oranının biçiminden fonksiyonel tanımlama elde edebilir. Fakat bu yaklaşım pratikte kırılıktır. Daha ikna edici bir seçim modeli için Z içinde seçimi etkileyen fakat Y^* sonuç denklemini doğrudan etkilemeyen en az bir değişken bulunması tercih edilir.

Seçim denkleminde dışlama kısıtı

Z içinde yer alan bir değişkenin seçim olasılığını etkilemesi, ancak sonuç denklemi $Y^* = X'\beta + e$ içinde doğrudan yer almaması beklenir. Bu değişken seçim düzeltmesinin tanımlanmasına bağımsız varyasyon sağlar.

Örneğin potansiyel ücret denkleminde küçük çocuk sayısı veya yerel bakım erişimi çalışma kararını etkileyebilir. Fakat böyle bir değişkenin ücreti doğrudan etkilemediğini savunmak her uygulamada kolay değildir. Dışlama kısıtı veri içinden otomatik seçilmez; iktisadi/kurumsal gerekçe gerektirir.

Sık yapılan hata

“İlk aşamada anlamlı” olmak geçerli dışlama kısıtı için yeterli değildir. Araçsal değişkenlerde olduğu gibi burada da relevance ile exclusion ayrı iddialardır.

Seçim denkleminde bulunan fakat sonuç denkleminde doğrudan yer almayan en az bir değişken, modeli yalnız Probit’in doğrusal olmayan biçimine dayanarak değil ekonomik dışlama üzerinden tanımlamaya yardım eder. İyi bir dışlama değişkeni seçimi güçlü biçimde etkiler fakat potansiyel sonucu seçim kanalı dışında etkilemez. Örneğin çocuk bakımına erişim çalışma kararını etkileyebilir; ancak ücret teklifini doğrudan etkilemediği savunulabiliyorsa dışlama aday olabilir. Bu örnek bağlama göre dikkatle değerlendirilmelidir.

Dışlama kısıtı yoksa model teknik olarak dağılımsal fonksiyon biçiminden tanımlanabilir;

fakat pratikte X ile ters Mills oranı yüksek doğrusal ilişki gösterebilir ve sonuçlar kırılgan olur. Bu nedenle dışlama değişkeni seçimi IV'deki araç seçimine benzer biçimde esas olarak ekonomik ve kurumsal bir argümandır.

Seçim denklemindeki dışlama değişkeni Z_e , sonuç denklemindeki X 'te yer almaz. Eğer Z_e seçim olasılığını anlamlı biçimde değiştiriyorsa, aynı X profiline sahip gözlemler arasında seçim eğiliminde dışsal varyasyon üretir. Bu varyasyon, ters Mills oranının sonuç regresörlerinden ayrı hareket etmesine yardımcı olur.

Araçsal değişkenlerde olduğu gibi exclusion restriction veriden yalnızca istatistiksel ilişkiyle doğrulanamaz. Z_e 'nin sonucu doğrudan etkilemediği ekonomik olarak savunulmalıdır. Zayıf exclusion değişkeni, Heckman düzeltmesini yüksek fonksiyonel biçim bağımlılığına bırakabilir.

6.13 Seçim Düzeltmesini Benzetimle Görmek

Aşağıdaki yapıda gerçek sonuç denklemi

$$Y^* = 1 + 2X + e$$

ve seçim denklemi

$$S^* = 0,2 + 0,8X + 0,6Z + u, \quad S = 1\{S^* > 0\}$$

olsun. X , Z , u ve v bağımsız standart normal, $e = 0,6u + 0,8v$ olsun; böylece $\text{var}(e) = \text{var}(u) = 1$ ve $\text{corr}(e, u) = \sigma_{21} = 0,6$ olur. Z yalnız seçim denkleminde yer alan dışsal değişkendir (§6.12'deki Z_e); §6.10'daki gösterimle seçim regresörleri $(1, X, Z)$ 'dir ve birinci aşama Probit bu üçünü içerir. 10.000 gözlemlik, tohumu 807 olan benzetimde (X, Z, u, v) bu sırayla çekilir) gözlemlerin yaklaşık yüzde 55,8'i seçilir. Uygulamanın Sezgi sekmesindeki ikinci deneyin varsayılan ayarları bu benzetimdir.

Tablo 6.3: Endojen seçim benzetimi: naif OLS ve Heckman iki aşama

Yöntem	Sabit	X eğimi	$\hat{\lambda}$ katsayısı
Seçilmiş örneklemde naif OLS	1,389	1,849	–
Heckman iki aşama	0,992	2,038	0,632
Gerçek değerler	1,000	2,000	0,600 (σ_{21})

Naif OLS seçilmiş alt örnekte eğimi aşağı doğru çeker (1,849). Seçim denklemi ve ters Mills oranı kullanıldığında eğim gerçek 2 değerine yaklaşır (2,038); $\hat{\lambda}$ 'nın katsayısı (0,632) $\sigma_{21} = 0,6$ 'yı tahmin eder. Bu sonuç, yöntemin her veri setinde doğru olacağını değil, doğru tanımlanmış seçim mekanizmasının hangi problemi hedeflediğini gösterir. Seçim denkleminde Z 'nin etkisi sifıra çekildiğinde (dışlama kısıtı yok) Heckman tahmininin tekrarlanan örneklemdeki dağılımı belirgin biçimde genişler; Sezgi sekmesindeki üçüncü deney bunu Monte Carlo ile gösterir.

6.14 Sansürleme ile Seçimi Karıştırmamak

İki problem benzer matematiksel nesneler – normal dağılım, Probit, ters Mills oranı – içerdiği için karıştırılabilir. Ana ayrım şudur:

- Tobit'te sonuç Y tüm birimler için gözlenir; bazıları sınır değerine dönüştürülmüştür.

- Heckman seçiminde Y seçilmeyen birimler için eksiktir; fakat seçim göstergesi ve seçim açıklayıcıları gözlenebilir.

Tobit “çok sıfırlı her veri” için otomatik model değildir. Sıfırlar gerçek ekonomik sıfırlar olabilir ve arkasında negatif gizli talep bulunmayabilir. Benzer biçimde Heckman da “eksik gözlemler var” diye otomatik uygulanmaz; eksikliğin seçime dayalı veri üretim mekanizması modellenmelidir.

Pratik bir tanı sorusu şudur: sonuç eşikte gözleniyor mu, yoksa sonuç tamamen mi kayıp? Sıfır gelir, sıfır bağış veya ölçüm cihazının üst sınırında kayıtlı değer sansürleme olabilir. Ücret değişkeninin çalışmayanlarda hiç bulunmaması ise örneklem seçimi problemidir. Aynı sıfır kodu veri dosyasında iki farklı mekanizmayı gizleyebilir; kod kitabı ve veri toplama süreci incelenmelidir.

Yanlış sınıflandırma yanlış likelihood üretir. Seçim probleminde gözlenmeyen ücretlere sıfır yazıp Tobit çalıştırmak bu ücretlerin gerçekten sıfır olduğunu varsaymış olur; oysa ekonomik olarak ücret teklifi pozitif fakat gözlenmemiş olabilir.

6.15 Makale Okurken Kontrol Listesi

Sansürleme/seçim içeren bir çalışmada şu sorular sorulmalıdır:

1. Sınır değeri ekonomik olarak gerçek bir sıfır mı, ölçüm kuralı mı, yoksa gizli değerlerin sansürlenmesi mi?
2. Sansürlenmiş birimlerin X değerleri gözleniyor mu?
3. Sonuç seçilmemiş birimler için neden eksik?
4. Araştırmacının estimand’ı gizli sonuç ortalaması mı, gözlenen ortalama mı, pozitif olma olasılığı mı?
5. Tobit’in normalite ve homoskedastisite varsayımları savunulabilir mi?
6. Heckman seçim denklemi tam örneklemde tahmin edilebiliyor mu?
7. Seçim denklemi için ikna edici bir dışlama kısıtı var mı?
8. Üretilmiş ters Mills oranı ve ikinci aşama hatasının heteroskedastisitesi nedeniyle standart hatalar uygun biçimde hesaplanmış mı?

6.16 Ampirik Uygulama Laboratuvarı: Sıfır Yığılmasından Sansürlü Modele

Bu uygulamada Hansen’in Cox–Hansen–Jimenez (CHJ2004) Filipinler hanehalkı veri setini kullanıyoruz. Veri, gelir ile hanehalkının aldığı hükümet dışı transferler arasındaki ilişkiyi incelemek için uygundur ve sansürlü regresyonun neden yalnız “çok sıfır var” gözleminde ibaret olmadığını gösterir (Hansen, 2021).

6.16.1 Adım 1: Hansen'in veri hazırlama zincirini yeniden üretmek

Ham veri 8.863 hane içerir. Hansen'in veri oluşturma dosyası önce net hükümet dışı transferi

$$transfers = tabroad + tdomestic + tinkind - tgifts$$

olarak tanımlar. Daha sonra gelir değişkeninden transferleri ve emekli maaşını çıkarır:

$$income^{adj} = income - transfers - pension.$$

Düzeltilmiş gelirin en yüksek yüzde 2'lik bölümü çıkarılır ve negatif gelir gözlemleri dışlanır. Bu adımlar sonunda 8.684 hane kalır. Hansen'in veri arşivindeki CHJ2004 dosyası bu adımların sonucudur: dosyadaki `income` değişkeni zaten düzeltilmiş gelirdir ve düzeltme yeniden uygulanmamalıdır. Aşağıdaki kod ham `urban.dta` dosyası içindir. Uygulamadaki sansürlü sonuç, yurt dışından, yurt içinden ve aynı alınan transferlerin toplamıdır:

$$Y = tabroad + tdomestic + tinkind \geq 0.$$

Örneklemin yaklaşık yüzde 17,6'sında $Y = 0$ 'dır. Ortalama transfer yaklaşık 7.709 peso, medyan ise yalnız 1.200 pesodur. Ortalama-medyan farkı dağılımın güçlü sağ çarpıklığını görünür kılar.

Kod 6.1: CHJ2004 verisinin Hansen'in oluşturma mantığıyla hazırlanması

```
# Ham urban.dta için. Hansen'in CHJ2004 dosyasında bu adımlar uygulanmıştır;
# orada yalnız son satır (alınan transfer) hesaplanır.
df["transfers_net"] = (
    df["tabroad"] + df["tdomestic"] + df["tinkind"] - df["tgifts"]
)
df["income_adj"] = df["income"] - df["transfers_net"] - df["pension"]
cut = df["income_adj"].quantile(0.98)
df = df[(df["income_adj"] < cut) & (df["income_adj"] >= 0)].copy()

df["received"] = df["tabroad"] + df["tdomestic"] + df["tinkind"]
```

Bu kod bloğunun pedagojik önemi model tahmininden önce gelir. Ham veriden analiz örnekleme geçiş yeniden üretilmezse, daha sonra elde edilen Tobit katsayısının doğru yazılımla hesaplanmış olması araştırmayı güvenilir kılmaz.


6.16.2 Adım 2: Gelir etkisini doğrusal olmak zorunda bırakmamak

Hansen gelir fonksiyonunu beş düğümlü doğrusal spline ile esnekleştirir. Düğümler 10.000, 20.000, 50.000, 100.000 ve 150.000 pesodadır. Ayrıca yaş, eğitim kategorileri, medeni durum, cinsiyet, çocuk sayısı, hane büyüklüğü ve istihdam durumuna ilişkin 15 kontrol kullanılır (Hansen, 2021).

Aşağıdaki şekil aynı veri hazırlama ve spline yapısında üç farklı tahmin yaklaşımını gösterir. OLS gözlenen koşullu ortalamaya, LAD (en küçük mutlak sapma; medyan regresyonu, Bölüm 7) koşullu medyana; Tobit eğrisi ise klasik normal-homoskedastik modelde gizli sonuç denkleminin ilişkin tahmine karşılık gelir. Eğriler, kontroller örneklem ortalamalarında $x'\hat{\beta}$ değerleridir. Dolayısıyla çizgilerin farklı düzeylerde bulunması yalnız “hangi tahminci daha iyi?” sorusuyla yorumlanmamalıdır; tahmin hedefleri de farklıdır.

Seçilmiş gelir düzeylerinde tahmin edilen transfer profilleri şöyledir:

En belirgin yapı düşük gelir düzeylerinde transferlerin gelirle birlikte hızla azalması ve yaklaşık



Şekil 6.3: CHJ2004: gelir ve transfer ilişkisinin OLS, Tobit ve LAD ile tahmini

Tablo 6.4: CHJ2004: seçilmiş gelir düzeylerinde tahmin edilen transferler (bin peso)

Gelir	OLS	Tobit gizli ortalama	LAD medyan
0	16,62	15,70	10,60
10	10,09	9,24	3,50
20	7,00	4,91	2,98
50	6,70	3,37	2,63
100	7,37	3,50	2,26
150	7,72	3,60	2,24

20–50 bin peso sonrasında profilin büyük ölçüde yataylaşmasıdır. Bu desen, gelir düşüken özel transferlerin alıcı hanenin gelir kaybını kısmen telafi edebileceği fikriyle uyumludur. Hansen’in kitap uygulamasında da temel şeklin farklı tahminciler arasında oldukça kalıcı, fakat regresyon düzeyinin belirgin biçimde farklı olduğu vurgulanır (Hansen, 2021).

6.16.3 Adım 3: Tobit katsayısını OLS katsayısı gibi okumamak

Tobit modelindeki bir β_j , gizli sonuç Y^* denklemindeki eğimdir. Gözlenen Y üzerindeki marjinal etki ayrıca sansürlenmeme olasılığını içerir. Bu nedenle bir Tobit çıktısında tek bir katsayı satırından en az üç farklı ekonomik hedef türetilir:

1. Y^* gizli sonucu üzerindeki etki,
2. $P(Y > 0 \mid X)$ üzerindeki etki,
3. $E[Y \mid X]$ gözlenen ortalama üzerindeki etki.

Makale “Tobit katsayısı” deyip hangi hedefin yorumlandığını belirtmiyorsa sonuç bölümü eksiktir. Tablo 6.5, Tablo 6.4’teki Tobit profillerinde bu hedefleri hesaplar ($z = x'\hat{\beta}/\hat{\sigma}$, $\hat{\sigma} = 19,75$ bin peso).

Tablo 6.5: CHJ2004: aynı Tobit tahmininden gizli ortalama $m^*(x)$, sansürlenmeme olasılığı, gözlenen ortalama $m(x)$ ve pozitiflerde ortalama $m^\#(x)$ (bin peso)

Gelir	$m^*(x)$	$P(Y > 0 \mid x)$	$m(x)$	$m^\#(x)$
0	15,70	0,787	18,10	23,00
10	9,24	0,680	13,35	19,62
20	4,91	0,598	10,58	17,68
50	3,37	0,568	9,68	17,05
100	3,50	0,570	9,76	17,10
150	3,60	0,572	9,81	17,14

Aynı katsayı seti, 150 bin peso gelirden gizli ortalama olarak 3,60, gözlenen ortalama olarak 9,81 ve pozitif transfer alanlarda 17,14 bin peso verir. OLS eğrisiyle karşılaştırılması gereken nesne gizli ortalama değil, Tobit’in ima ettiği gözlenen ortalama değildir.

Bu karşılaştırma basit bir model kontrolüne de dönüşür. Tobit’in ima ettiği sansürlenmeme olasılığının örneklem ortalaması $n^{-1} \sum_i \Phi(X_i'\hat{\beta}/\hat{\sigma}) = 0,579$ iken verideki pozitif transfer payı 0,824’tür; ima edilen ortalama transfer 11,46 bin peso, gözlenen ortalama ise 7,71 bin pesodur. Normal-homoskedastik Tobit, çok sayıda küçük pozitif transferi ve uzun sağ kuyruğu aynı anda yakalayamamaktadır. Bu uyumsuzluk, dağılım varsayımına daha az dayanan CLAD gibi yöntemlerin neden tartışıldığını somutlaştırır.

6.16.4 Adım 4: Sıfırların ekonomik anlamını sorgulamak

Bu örnekte sıfır, transfer alınmadığını ifade eder ve klasik sansürlü model öğretimi için uygundur. Fakat birçok tezde sıfır iki aşamalı karar sürecinden doğabilir. Örneğin bir firmanın Ar-Ge harcaması sıfırsa önce “Ar-Ge yapma kararı”, ardından pozitif harcama miktarı ayrı mekanizmalar tarafından belirlenebilir. Böyle bir durumda tek denklem Tobit, her iki marjini aynı parametre setine zorladığı için aşırı kısıtlayıcı olabilir.

Sık yapılan hata

Y 'de çok sayıda sıfır görmek tek başına Tobit seçme gerekçesi değildir. Sıfırın sansürleme, gerçek ekonomik köşe çözümü, iki aşamalı katılım kararı veya veri kaydı mekanizmasından hangisine karşılık geldiği açıklanmalıdır.

6.16.5 Hansen'in CLAD karşılaştırması ne öğretiyor?

Bu bölümün uygulaması (Uygulama sekmesi ve indirilen Python, R, Stata betikleri) OLS, klasik Tobit ve LAD eğrilerini ve Tobit'in üç hedefini yeniden üretmektedir. Hansen aynı örnekte ayrıca sansürlü LAD (CLAD) tahminini raporlar ve güçlü çarpıklık ile sansürleme nedeniyle CLAD'ı çekici bir dayanıklı alternatif olarak tartışır (Hansen, 2021). Buradaki amaç CLAD'ın sayısal optimizasyon ayrıntılarını derste genişletmek değil, model varsayımları değiştiğinde estimand ve tahmincinin de değişebileceğini görmektir.

6.16.6 Kendi tezinizde sansürlü/seçilmiş sonuç için protokol

1. Sıfır veya sınır değerinin veri üretim mekanizmasını açıklayın.
2. Sansürleme ile truncation ve örneklem seçimini birbirinden ayırın.
3. Gizli sonuç yorumunun ekonomik olarak anlamlı olup olmadığını tartışın.
4. Tobit kullanıyorsanız normalite ve homoskedastisite varsayımlarının güçlü olduğunu açıkça belirtin.
5. Mümkünse OLS/LAD/Tobit veya iki parçalı alternatiflerle duyarlılık gösterin.
6. Tobit katsayısı yerine hangi marjinal etkinin raporlandığını belirtin.
7. Örneklem seçimi probleminde dışlama değişkeninin neden seçim denklemini etkileyip sonuç denklemini doğrudan etkilemediğini savunun.

6.17 Temel Sonuçlar

1. Sansürleme, kesilme ve seçim aynı veri problemi değildir.
2. Sansürlü modelde $m^*(x)$, $m(x)$ ve $m^\#(x)$ farklı koşullu ortalamalardır.
3. Sıfırları silmek gizli regresyonu genel olarak geri getirmez.
4. Tobit, sıfır gözlemlerinin olasılık katkısıyla pozitif gözlemlerin yoğunluk katkısını aynı olabilirlikte birleştirir.
5. Tobit katsayısı gözlenen Y ortalamasının doğrudan marjinal etkisi değildir.
6. Endojen seçim, seçilmiş örnekleme $E[e | X, S = 1] \neq 0$ yarattığında sonuç denkleminde eksik değişken benzeri yanlılık doğurur.
7. Heckman iki aşama, seçim Probit'inden türetilen ters Mills oranını sonuç denklemine ekler.
8. İyi bir dışlama kısıtı, seçim modelinin yalnız fonksiyonel biçime dayanmasını engeller ve ampirik ikna gücünü artırır.

6.18 Bölüm Sonu Egzersizleri

Egzersiz 6.1: Veri yapısını sınıflandırma

Aşağıdaki durumları sansürleme, kesilme veya örneklem seçimi olarak sınıflandırınız ve gerekçenizi yazınız.

1. Anket, negatif serveti “0 veya daha az” koduyla tek değerde raporluyor.
2. Veri tabanı yalnız yıllık satışı 1 milyon TL’nin üzerindeki firmaları içeriyor.
3. Ücret yalnız çalışan bireyler için gözleniyor; çalışmayanların yaş ve eğitim bilgileri mevcut.

Egzersiz 6.2: Sansürlenme olasılığı

$Y^* = 1 + 0,5X + e$, $e \sim N(0, 1)$ ve $Y = \max\{Y^*, 0\}$ olsun.

1. $X = 0$ ve $X = 2$ için $P(Y = 0 | X)$ hesaplayınız.
2. X arttıkça sansürlenme olasılığı neden azalır?

Egzersiz 6.3: Üç koşullu ortalama

Tobit modelinde $x'\beta = 1$ ve $\sigma = 1$ olsun. $\Phi(1) = 0,8413$, $\phi(1) = 0,2420$ kullanarak $m^*(x)$, $m(x)$ ve $m^\#(x)$ değerlerini hesaplayınız. Üçünün neden farklı olduğunu açıklayınız.

Egzersiz 6.4: Greene sezgisi

Özel normal-regresör durumunda gerçek eğim $\beta = 2$ olsun.

1. Sansür oranı $\pi = 0,05$, $0,20$ ve $0,50$ için $\beta_{BLP} = \beta(1 - \pi)$ hesaplayınız.
2. Sonuçlara göre sansürleme arttıkça doğrusal eğimin nasıl değiştiğini açıklayınız.
3. Bunun genel bir Tobit teoremi olmadığını, yalnız normal regresör varsayımı altında geçerli özel bir sonuç olduğunu belirtiniz.

Egzersiz 6.5: Tobit olabilirlik katkısı

İki gözlem için $(Y_1, Y_2) = (0, 3)$ olsun. Genel $\mu_i = X_i'\beta$ ve σ kullanarak her gözlemin log-olabilirlik katkısını ayrı ayrı yazınız. Neden iki katkının matematiksel biçimi farklıdır?

Egzersiz 6.6: Tobit marjinal etkisi

Bir Tobit modelinde $\beta_j = 1,5$ ve bir gözlem için $x'\beta/\sigma = 0,5$ olsun. $\Phi(0,5) = 0,6915$ kullanarak X_j ’nin gözlenen koşullu ortalama üzerindeki marjinal etkisini hesaplayınız. Bu değeri β_j ile karşılaştırınız.

Egzersiz 6.7: Benzetim tablosunu yorumlama

Tablo 6.2'yi kullanınız.

1. Tam örneklem OLS eğiminin gerçek eğimden sapmasını hesaplayınız.
2. Sıfırları silmenin problemi çözüp çözmediğini değerlendiriniz.
3. Tobit'in daha iyi performansının hangi model varsayımlarına bağlı olduğunu açıklayınız.

Egzersiz 6.8: Seçim yanlılığı koşulu

$Y = X'\beta + e$ ve seçim göstergesi S olsun. Seçilmiş örneklemde OLS'nin β için tutarlı olabilmesi açısından $E[e | X, S = 1]$ teriminin rolünü açıklayınız. S rastgele ise ne değişir?

Egzersiz 6.9: Heckman adımları

Ücret yalnız çalışanlarda gözleniyor. Elinizde bütün bireyler için yaş, eğitim, medeni durum ve küçük çocuk sayısı var.

1. Seçim denklemi ve ücret denklemini sembolik olarak yazınız.
2. İki aşamalı Heckman tahmininin dört işlem adımını sıralayınız.
3. Küçük çocuk sayısının dışlama kısıtı olarak kullanılabilmesi için hangi iktisadi savunmanın yapılması gerekir?

Egzersiz 6.10: Ters Mills oranı

Seçim Probit'inden iki birey için indeksler $Z_i'\hat{\gamma} = 0$ ve 1 bulunmuştur. $\phi(0) = 0,3989$, $\Phi(0) = 0,5$, $\phi(1) = 0,2420$, $\Phi(1) = 0,8413$ kullanarak ters Mills oranlarını hesaplayınız. Seçilme olasılığı yüksek olan bireyde λ neden daha küçüktür?

Egzersiz 6.11: Seçim benzetimi

Tablo 6.3'ü kullanınız. Naif OLS ve Heckman eğim tahminlerinin gerçek 2 değerine mutlak uzaklıklarını hesaplayınız. $\hat{\lambda}$ katsayısının sıfırdan farklı olması seçime ilişkin hangi yapıyla uyumludur?

Egzersiz 6.12: Yöntem eleştirisi

Bir makalede sağlık harcaması değişkeninin yüzde 45'i sıfırdır. Yazar “çok sıfır olduğu için Tobit kullandık” demektedir. Bu gerekçenin neden tek başına yetersiz olduğunu açıklayınız. En az üç veri üretim mekanizması alternatifi belirtiniz.

Kantil Regresyon ve Dağılımsal Heterojenlik

Bu bölümün amacı

Bu bölümün sonunda koşullu ortalama, koşullu medyan ve koşullu kantil arasındaki farkı açıklayabilecek; medyan regresyonunun mutlak sapmalar toplamını minimize etmesini türetebilecek; kantil regresyonun asimetrik check-loss fonksiyonunu kurabilecek; doğrusal kantil katsayısını “en iyi doğrusal kantil öngörücüsü” olarak yorumlayabilecek; örneklem kantil regresyon tahmin edicisini tanımlayabilecek; katsayıların farklı kantiller boyunca değişmesini dağılımsal heterojenlik olarak okuyabilecek; OLS ile kantil regresyonun aynı soruya cevap vermediğini açıklayabilecek; kantil kesişmesi ve standart hata seçimi gibi temel uygulama sorunlarını değerlendirebilecek ve ampirik sonuçları kantil profili biçiminde raporlayabileceksiniz.

Bağlantı

Bölüm 6’da sonuç dağılımının sınır ve seçim mekanizmalarının yalnız koşullu ortalamayı değil bütün gözlenen dağılımı etkilediğini gördük. Şimdi dağılımı bilinçli biçimde hedef nesne yapıyoruz. Regresyon artık “ X ortalama Y ile nasıl ilişkilidir?” sorusuyla sınırlı değildir; “ X , Y dağılımının alt, orta ve üst kısımlarıyla nasıl ilişkilidir?” sorusuna geçer. Hansen’in Bölüm 24 yaklaşımı bu bölümün temel kaynağıdır ([Hansen, 2021](#)).

7.1 Ortalama Neden Her Zaman Yeterli Değildir?

OLS ve koşullu beklenti bize

$$m(x) = E[Y | X = x]$$

fonksiyonunu veya onun doğrusal projeksiyonunu öğretir. Bu çok güçlü bir özet olmakla birlikte dağılımın tamamını temsil etmez. Aynı koşullu ortalamaya sahip iki grup çok farklı yayılım, çarpıklık veya kuyruk davranışı gösterebilir.

Örneğin bir eğitim politikasının sınav puanlarının ortalamasını yalnızca biraz artırdığını düşünelim. Politika düşük başarılı öğrencilerde çok güçlü, yüksek başarılı öğrencilerde ise sifıra yakın etki yaratıyorsa ortalama etki bu heterojenliği gizler. Benzer biçimde eğitim ücret dağılımının üst kısmıyla alt kısmında farklı ilişkiler gösterebilir.

Koşullu τ kantili

$0 < \tau < 1$ için koşullu kantil $q_\tau(x)$, sürekli dağılım altında

$$P\{Y \leq q_\tau(x) \mid X = x\} = \tau$$

şartını sağlayan değerdir. $q_{0.5}(x)$ koşullu medyandır; $q_{0.1}(x)$ alt yüzde 10 eşliğini, $q_{0.9}(x)$ üst yüzde 10 eşliğini temsil eder.

Koşullu ortalama dağılımın yalnız bir konum özetidir. Aynı ortalama sahip iki koşullu dağılım farklı yayılım, çarpıklık veya kuyruk davranışına sahip olabilir. Bir politika düşük gelir grubunu güçlü, yüksek gelir grubunu zayıf etkiliyorsa ortalama etki bu heterojenliği tek sayıda gizleyebilir. Kantil yaklaşımı, sonuç dağılımının farklı noktalarında X ile ilişkinin nasıl değiştiğini incelememize izin verir.

Kantiller özellikle uç gözlemlerin ekonomik anlam taşıdığı durumlarda yararlıdır. Ücret dağılımının alt yüzde 10'u, öğrencilerin düşük başarı kuyruğu veya firmaların yüksek kaldıraç kuyruğu ortalama davranıştan farklı mekanizmalara sahip olabilir. Ancak kantil regresyon “uç değerlerden kurtulmak” için otomatik bir robust yöntem değil, farklı bir tahmin hedefidir. Ortalama ile medyan ya da yüzde 90 kantili farklı anakütle nesneleridir.

7.2 Medyan Regresyonu

Koşullu medyan fonksiyonu

$$m(x) = q_{0.5}(x) = \text{med}(Y \mid X = x)$$

olsun. Medyan regresyon modeli

$$Y = m(X) + e, \quad \text{med}(e \mid X) = 0 \quad (7.1)$$

şeklinde yazılabilir.

Medyanın önemli optimizasyon özelliği, mutlak sapmayı minimize etmesidir. Bir rassal değişken için

$$\text{med}(Y) = \arg \min_a E|Y - a|. \quad (7.2)$$

Koşullu versiyonda da

$$m(x) = \arg \min_a E[|Y - a| \mid X = x].$$

Doğrusal medyan modeli

$$\text{med}(Y \mid X) = X' \beta_{0.5}$$


varsayılırsa anakütle parametresi

$$\beta_{0.5} = \arg \min_b E|Y - X'b| \quad (7.3)$$

ve örneklem tahmin edicisi

$$\hat{\beta}_{0.5} = \arg \min_b \sum_{i=1}^n |Y_i - X_i'b| \quad (7.4)$$

olur. Bu nedenle medyan regresyonu **least absolute deviations** (LAD) olarak da adlandırılır.



Şekil 7.1: OLS'nin kareli kaybı ile medyan regresyonunun mutlak kaybı

Şekil 7.1 önemli bir sağlamlık farkını gösterir. Büyük artıklar kareli kayıpta çok hızlı büyür; mutlak kayıpta doğrusal büyür. Bu nedenle medyan regresyonu uç gözlemlerin Y yönündeki etkisine OLS'den daha az duyarlıdır. Fakat bu özellik “LAD her zaman OLS'den daha iyidir” anlamına gelmez; iki yöntem farklı koşullu konum ölçülerini hedefler.

Fakat bu sağlamlık özelliğini nedensel veya dağılımsal yorumla karıştırmamak gerekir. Medyan regresyonu koşullu medyan fonksiyonunu hedefler. Eğer araştırma sorusu ortalama maliyet veya toplam beklenen çıktı ile ilgiliyse, uç gözlemlere duyarlı olsa bile koşullu ortalama doğru estimand olabilir. Yöntem seçimi önce ekonomik hedefe dayanmalıdır.

7.3 Kantil Regresyon için Asimetrik Mutlak Kayıp (Check Loss)

Genel τ kantili için mutlak kayıp asimetrik hâle getirilir. Bu nedenle kullanılan asimetrik mutlak kayıp (check loss) fonksiyonu

$$\rho_{\tau}(u) = u\{\tau - 1\{u < 0\}\} = \begin{cases} \tau u, & u \geq 0, \\ (\tau - 1)u, & u < 0 \end{cases} \quad (7.5)$$

olarak tanımlanır.


$\tau = 0,5$ için

$$\rho_{0.5}(u) = \frac{1}{2}|u|,$$

yani LAD elde edilir. $\tau = 0,1$ için negatif artıklar daha büyük ağırlık alır; model alt koşullu kuyruğu hedefler. $\tau = 0,9$ için pozitif artıkların ağırlığı büyür ve üst kuyruğa odaklanılır.

$\tau = 0,9$ seçiminin sezgisi şudur: pozitif artıklar daha ağır cezalandırıldığı için tahmin çizgisi, gözlemlerin yaklaşık yüzde 90'ını altında bırakacak biçimde yukarı taşınır.

Bu fonksiyonun köşeli olması optimizasyonun OLS'deki gibi basit normal denklemlerle çözülmesini engeller. Yine de amaç fonksiyonu konvektir ve modern nümerik yöntemlerle güvenilir biçimde minimize edilir. Kantil regresyonun hesaplaması bu nedenle OLS'den farklı, fakat tahmin hedefi mantığı benzer bir optimizasyon problemidir.



Şekil 7.2: Farklı kantillerde asimetrik check-loss fonksiyonu

7.4 Kantillerin Optimizasyon Karakterizasyonu

$\psi_\tau(u) = \tau - 1\{u < 0\}$ olsun. Sürekli dağılımda gerçek kantil q_τ için

$$E[\psi_\tau(Y - q_\tau)] = 0 \quad (7.6)$$

ve

$$q_\tau = \arg \min_a E[\rho_\tau(Y - a)] \quad (7.7)$$

sonuçları geçerlidir.

Neden? $\rho'_\tau(u) = \psi_\tau(u)$ olduğundan amaç fonksiyonunun a 'ya göre türevi sezgisel olarak

$$-E[\tau - 1\{Y < a\}] = P(Y < a) - \tau$$

şeklindedir. Sıfıra eşit olduğunda

$$P(Y < a) = \tau$$

elde edilir; yani a ilgili kantildir.

Koşullu olarak da

$$E[\psi_\tau\{Y - q_\tau(X)\} \mid X] = 0. \quad (7.8)$$

Bu, OLS'deki $E[e \mid X] = 0$ koşulunun kantil analogudur; fakat hata ortalamasını değil hata işaretlerinin belirli oranını düzenler.

Amaç fonksiyonu köşeli olduğu için bu eşitlik bazı gözlemlerde alt-türev (subgradient) anlamında değerlendirilir; yine de sezgi aynıdır: tahminin üstünde ve altında kalan kütleler sırasıyla τ ve $1 - \tau$ ağırlıklarıyla dengelenir.

Bu moment gösterimi, kantil regresyonun da OLS ve IV gibi moment/optimizasyon ailesinin bir parçası olduğunu görmemizi sağlar.

7.5 Doğrusal Kantil Regresyon Modeli

Doğrusal koşullu kantil modeli

$$Q_\tau[Y \mid X] = X'\beta_\tau \quad (7.9)$$

şeklindedir. Eğer gerçek koşullu kantil doğrusal değilse bile Hansen'in yaklaşımıyla

$$\beta_\tau = \arg \min_b E [\rho_\tau(Y - X'b)] \quad (7.10)$$

ile **en iyi doğrusal kantil öngörücüsü** tanımlanabilir.

Bu ayrım OLS'deki koşullu beklenti ile en iyi doğrusal projeksiyon ayırımına paraleldir. $X'\beta_\tau$ gerçek $q_\tau(x)$ fonksiyonu doğrusal olduğunda onu tam temsil eder; aksi hâlde veri dağılımına göre ağırlıklandırılmış doğrusal bir yaklaşımdır.

Birinci derece koşul sezgisel olarak

$$E [X \psi_\tau(Y - X'\beta_\tau)] = 0 \quad (7.11)$$

şeklindedir.

Sık yapılan hata

$\beta_{0.9,j}$ “ X_j 'nin yüksek Y gözlemleri üzerindeki etkisi” diye mekanik biçimde yorumlanmamalıdır. Kantil regresyon koşullu dağılımın 0,9 kantilini modeller. Bir gözlemin koşullu sıralaması X değiştiğinde aynı kalmak zorunda değildir. Nedensel kantil etkisi yorumu için ek tanımlama varsayımları gerekir.

7.6 Örneklem Tahmin Edicisi

Örneklem amaç fonksiyonu

$$M_n(b; \tau) = \frac{1}{n} \sum_{i=1}^n \rho_\tau(Y_i - X_i'b) \quad (7.12)$$

olsun. Kantil regresyon tahmin edicisi

$$\hat{\beta}_\tau = \arg \min_b M_n(b; \tau) \quad (7.13)$$

olarak tanımlanır.

OLS'nin aksine genel kapalı form çözüm yoktur. Amaç fonksiyonu parçalı doğrusaldır ve doğrusal programlama/nümerik optimizasyon yöntemleri kullanılır. Modern yazılımlarda bu hesap standarttır; önemli olan optimizasyonun hangi anakütle hedefini tahmin ettiğini bilmektir.

Tahmin edilen artıklar

$$\hat{e}_i(\tau) = Y_i - X_i'\hat{\beta}_\tau$$

için yaklaşık örneklem momenti

$$\frac{1}{n} \sum_{i=1}^n X_i \psi_\tau\{\hat{e}_i(\tau)\} \simeq 0 \quad (7.14)$$

sağlanır.

7.7 Kantil Katsayıları Nasıl Yorumlanır?

Basit model

$$Q_{\tau}[Y | X = x] = \beta_{0,\tau} + \beta_{1,\tau}x$$

olsun. $\beta_{1,\tau}$, x 'te bir birimlik farkla ilişkili koşullu τ kantil farkıdır.

Örneğin ücretin logaritması için

$$Q_{0.9}[\log wage | education] = \beta_{0,0.9} + 0,12 education$$

bulunursa, bir ek eğitim yılı koşullu log ücret dağılımının 90. kantilinde yaklaşık yüzde 12'lik farkla ilişkilidir. Bu yorum nedensel değildir; ayrıca log dönüşümünün geometrik/oransal yorum mantığı korunmalıdır.

Katsayılar kantiller boyunca değişebilir. Örneğin eğitim katsayısı $\tau = 0,10$ 'da 0,04, $\tau = 0,90$ 'da 0,09 ise eğitim-ücret ilişkisi dağılımın üst kısmında daha güçlü görünmektedir.


Bu yorum aynı bireyin “düşük kantilden yüksek kantile taşınması” anlamına gelmez. Koşullu kantiller farklı alt dağılım noktalarını tanımlar; bireysel rank'ın tedavi altında sabit kaldığını varsaymadıkça kantil katsayılarından bireysel etki dağılımı çıkarılamaz. Nedensel kantil etkileri için daha güçlü tanımlama koşulları gerekir.

7.8 Kantil Profilleri ve Dağılımsal Heterojenlik

Bir regresörün katsayısı kantiller boyunca aynıysa X dağılımı kabaca paralel biçimde kaydırıyor olabilir. Katsayılar kantiller boyunca değişiyorsa dağılımın farklı bölümleri farklı ilişki göstermektedir.

Üç kavramsal durum yararlıdır:

1. **Paralel kantiller:** eğimler aynı, yalnız sabitler farklıdır.
2. **Eğim heterojenliği:** $\beta_{j,\tau}$ kantille birlikte değişir.
3. **Doğrusal olmayan kantil fonksiyonu:** aynı kantilde X ile ilişki doğrusal olmayabilir.



Şekil 7.3: Kantiller boyunca eğim heterojenliği

$\hat{\beta}_j(\tau)$ değerini τ boyunca çizmek, tek bir tablodan daha fazla bilgi verebilir. Yatay bir profil, X_j ilişkisinin dağılım boyunca benzer olduğunu; artan veya azalan profil heterojenlik olduğunu düşündürür. Ancak komşu kantil tahminleri aynı veriyle elde edildiği için bağımsız değildir. “0,25 katsayısı anlamlı, 0,75 anlamsız; demek ki birbirinden farklı” sonucu geçerli değildir.

Kantiller arası farkı sınamak için ortak kovaryans yapısını kullanan test veya bootstrap gerekir. Güven bantlarının belirgin biçimde örtüşmesi de formal eşitlik testiyle aynı şey değildir.

7.9 OLS ile Kantil Regresyon Aynı Şeyi Ölçmez

OLS katsayısı

$$\beta^{OLS} = \arg \min_b E[(Y - X'b)^2]$$

koşullu ortalama/doğrusal projeksiyon hedefidir. Kantil katsayısı ise

$$\beta_\tau = \arg \min_b E[\rho_\tau(Y - X'b)]$$

ile farklı bir estimand’dır. Dolayısıyla $\hat{\beta}^{OLS}$ ile $\hat{\beta}_{0,5}$ farklı çıktığında önce “hangisi doğru?” değil, “hangi koşullu konum ölçüsünü hedefliyoruz?” sorusu sorulmalıdır.

Simetrik, homoskedastik ve yalnız konum kayması içeren özel yapılarda ortalama, medyan ve kantil eğimleri benzer olabilir. Buna karşılık heteroskedastisite veya katsayı heterojenliği olduğunda kantil profili önemli ek bilgi taşır.

Paralel kantillerin sezgisi

$Y = m(X) + e$ ve e , X ’ten bağımsızsa (yani e ’nin dağılımı her X değerinde aynıysa)

$$Q_\tau[Y | X = x] = m(x) + q_\tau(e).$$

Farklı kantiller yalnız dikey sabit kadar ayrılır; eğimler aynıdır. Bu nedenle kantil eğimlerinin belirgin biçimde değişmesi koşullu dağılımın yalnız konum değil şekil/yayılım bakımından da X ile değiştiğine işaret eder.

7.10 CPS Ücret Uygulaması: Kantil Profili

Hansen’in sık kullandığı Mart 2009 CPS tam zamanlı çalışan örneklemini kullanarak

$$Q_\tau[\log wage | X] = \beta_{0,\tau} + \beta_{1,\tau}education + \beta_{2,\tau}experience + \beta_{3,\tau}\frac{experience^2}{100} + \beta_{4,\tau}female \quad (7.15)$$


modelini düşünelim. 50.742 gözlem için seçilmiş kantil tahminleri aşağıdadır.

Tablo 7.1: CPS log ücret kantil regresyonu: seçilmiş katsayılar

	$\tau = 0,10$	0,25	0,50	0,75	0,90	OLS
Eğitim	0,1036	0,1095	0,1154	0,1193	0,1226	0,1148
Kadın	-0,1969	-0,2301	-0,2592	-0,2904	-0,3134	-0,2596
Deneyim	0,0368	0,0338	0,0332	0,0350	0,0378	0,0356
$experience^2/100$	-0,0650	-0,0559	-0,0513	-0,0512	-0,0542	-0,0563

Tablo iki güçlü dağılımsal örüntü gösterir. Eğitim eğimi alt kantilde yaklaşık 0,104 iken üst kantilde 0,123'tür. Yani eğitim ile koşullu log ücret arasındaki pozitif ilişki ücret dağılımının üst kısmında daha büyüktür. Kadın göstergesi ise alt kantilde yaklaşık $-0,197$, üst kantilde $-0,313$ 'tür; koşullu cinsiyet farkı üst ücret kantillerinde daha geniş görünmektedir.

Bu sonuçların “eğitimin nedensel getirisi” veya “cinsiyetin nedensel etkisi” olarak okunması doğru değildir. Model gözlemsel koşullu kantil ilişkilerini özetler. Nedensel kantil yorum için tedavi değişkeni ile yapısal heterojenliğe ilişkin ek koşullar gerekir.



Şekil 7.4: CPS uygulamasında eğitim katsayısının kantil profili; kesikli çizgi OLS eğimini gösterir

Ücret uygulamasında log dönüşüm kullanıldığında kantil katsayıları koşullu log-ücret kantillerindeki farkları gösterir. Küçük katsayılarda yüzde yorumu yaklaşık yapılabilir; büyük farklarda $100(e^\beta - 1)$ dönüşümü daha uygundur. Eğitim katsayısının üst kantillerde yükselmesi, eğitimle ilişkili ücret priminin yüksek ücret dağılımında daha büyük olduğuna dair betimleyici kanıt verir.

Bu desenin nedenini model tek başına açıklamaz. Yetenek tamamlayıcılığı, meslek seçimi, endüstri kompozisyonu veya ölçülmeyen heterojenlik alternatif mekanizmalardır. Kantil regresyon heterojenliği görünür kılar; ekonomik mekanizma ek teori ve tasarım gerektirir.

7.11 Standart Hatalar ve Çıkarım

Kantil regresyon tahmin edicisi uygun düzenlilik koşulları altında

$$\sqrt{n}(\hat{\beta}_\tau - \beta_\tau) \xrightarrow{d} N(0, \mathbf{V}_{\beta_\tau}) \quad (7.16)$$

şeklinde asimptotik normaldir. Genel kovaryans matrisi sandviç yapıdadır ve koşullu yoğunluğun hedef kantildeki değerini içerir. Sezgisel olarak hedef kantilin çevresinde çok az veri varsa tahmin daha belirsizdir.

Uygulamada üç yaklaşım yaygındır:

1. yoğunluk tahminine dayalı analitik standart hatalar,
2. robust sandviç kovaryans tahmini,
3. nonparametrik bootstrap.

Hansen, genel modelde bootstrap'ın özellikle yararlı olduğunu ve nihai analizde yeterli tekrar sayısının kullanılmasını vurgular. Kümeli veri yapısında bireysel gözlemler yerine kümelerin yeniden örneklenmesi gerekir.

Sık yapılan hata

Kantil regresyon katsayılarını yalnız nokta tahminlerine bakarak “heterojenlik kanıtı” diye raporlamak yeterli değildir. $\hat{\beta}_{0.1}$ ile $\hat{\beta}_{0.9}$ arasındaki farkın örnekleme belirsizliği de değerlendirilmelidir. Gerekirse ortak bootstrap ile katsayı farkı için güven aralığı kurulmalıdır.

Kantil tahmin edicisinin varyansı OLS'den farklıdır; çünkü amaç fonksiyonunun yerel davranışı, koşullu hata yoğunluğunun hedef kantil çevresindeki değerine bağlıdır. Yoğunluk düşükse küçük bir olasılık değişimini kantil değerine çevirmek daha büyük belirsizlik yaratır. Örneğin regresörsüz durumda ($X = 1$) tahmin edici örneklem kantili $\hat{q}_\tau$ 'dur; f , Y 'nin yoğunluğu olmak üzere $V_{\beta_\tau} = \tau(1 - \tau)/f(q_\tau)^2$, yani $\hat{q}_\tau$ 'nin varyansı yaklaşık $\tau(1 - \tau)/\{nf(q_\tau)^2\}$ 'dir ve hedef kantildeki yoğunluk $f(q_\tau)$ küçüldükçe büyür. Bu nedenle kantil regresyon standart hatası yalnız artık varyansına dayanan OLS formülüyle hesaplanamaz.

Pratikte analitik yoğunluk tahminleri veya bootstrap kullanılır. Kümelenmiş veride tek tek gözlemleri yeniden örneklemek küme içi bağımlılığı bozar; kümeleri blok olarak çekmek gerekir. Hansen özellikle kantil regresyonda bootstrap çıkarımının yararlı bir seçenek olduğunu tartışır (Hansen, 2021). Çıkarım yöntemi raporlanırken bootstrap tekrar sayısı ve kümelenme birimi açıkça belirtilmelidir.

7.12 Kantil Kesişmesi Problemi

Gerçek koşullu kantiller sıralıdır:

$$\tau_1 < \tau_2 \implies q_{\tau_1}(x) \leq q_{\tau_2}(x).$$

Ancak her kantil ayrı bir doğrusal regresyonla tahmin edildiğinde

$$X'\hat{\beta}_{\tau_1} > X'\hat{\beta}_{\tau_2}$$

bazı X değerlerinde ortaya çıkabilir. Buna **quantile crossing** denir.


Kesişme iki tür soruna işaret edebilir:

1. örnekleme belirsizliği,
2. doğrusal fonksiyonel biçimin gerçek kantil eğrilerini kötü yaklaştırması.

Çözüm seçenekleri arasında fonksiyonel biçimi iyileştirme, değişken dönüşümü, daha esnek seri/spline yapısı veya tahmin edilen kantilleri monotonlaştıran yöntemler vardır.

Her τ için regresyon ayrı tahmin edildiğinde teorik olarak $Q_{0.25}[Y | X] \leq Q_{0.50}[Y | X] \leq Q_{0.75}[Y | X]$ olması gerekirken tahmin edilen çizgiler bazı X değerlerinde kesişebilir. Bu, örnekleme hatası, zayıf veri desteği veya doğrusal kantil spesifikasyonunun farklı kantillerde uyumsuz davranmasından kaynaklanabilir.

Kesişme özellikle örneklem dışı bölgelerde veya çok sayıda regresör olduğunda daha belirgin olabilir. Çözüm olarak kantilleri birlikte kısıtlayan yöntemler veya sonradan monotonlaştırma



Şekil 7.5: Ayrı doğrusal tahminlerin destek bölgesinde kesişebilmesi

kullanılabilir; fakat temel ders, tek tek kantil katsayılarını mekanik olarak yorumlamadan önce tahmin edilen koşullu dağılımın kendi içinde tutarlı olup olmadığını kontrol etmektir.

7.13 Kantil Regresyon ve Nedensel Yorum

Koşullu kantil regresyon betimleyici/öngörücü bir dağılım modelidir. Nedensel yorum için Bölüm 3'teki temel problem geri döner. Bir tedavi D ve kontroller X için

$$Q_{\tau}[Y | D, X]$$

gözlemsel koşullu dağılımı tanımlar. Bunun X 'e koşullu potansiyel sonuç kantilleriyle eşit olabilmesi için koşullu bağımsızlık gibi tanımlama varsayımları gerekir; kantil etkilerinin bireysel düzeyde yorumlanması için ise ek monotonluk/rank koşulları gerekir.

Bu ayrım önemlidir çünkü “üst kantilde katsayı daha büyük” ifadesi otomatik olarak “tedavi üst gelir grubundaki bireyleri daha fazla etkiliyor” anlamına gelmez. Kantil, birey kimliği değil koşullu dağılımdaki konumdur.

Koşullu kantil regresyonu betimleyici olarak güçlüdür; nedensel yorum ise ayrı bir tanımlama sorusudur. D tedavi değişkeni endojense, $Q_{\tau}[Y | D, X]$ içindeki D katsayısı (X 'e koşullu) potansiyel sonuç kantil etkisini otomatik olarak vermez. Tedavi gruplarının koşullu olarak karşılaştırılabilirliği veya IV kantil regresyon gibi ek bir tanımlama tasarımı gerekir (IV kantil regresyonunda sıra benzerliği gibi koşullar tanımlamanın kendisi için gerekir).

Ayrıca “kantiller üzerindeki tedavi etkisi” birden fazla şekilde tanımlanabilir: iki potansiyel sonuç dağılımının aynı τ kantilleri arasındaki fark, bireysel tedavi etkilerinin τ kantiliyle aynı değildir. Bu ayrım tez çalışmalarında kavramların açık tanımlanmasını gerektirir.

7.14 Kantil Regresyon Ne Zaman Özellikle Yararlıdır?

1. Sonuç dağılımı belirgin biçimde çarpık veya kalın kuyrukluysa,
2. araştırma sorusu alt/üst kuyruk davranışıyla doğrudan ilgiliyse,
3. politika etkisinin dağılım boyunca heterojen olabileceği düşünülüyorsa,

4. ortalama sonuç sınırlı ekonomik bilgi veriyorsa,
5. uç gözlemlerin kareli kayıp üzerindeki baskısı istenmiyorsa.

Buna karşılık yalnız “robust olsun” gerekçesiyle kantil regresyon seçmek doğru değildir. Önce estimand belirlenmelidir: ortalama mı, medyan mı, belirli bir kantil mi, yoksa dağılımın tamamı mı?

7.15 Makale Tablosu Nasıl Okunur?

Kantil regresyon tablosunda şu unsurlar açık olmalıdır:

- raporlanan τ düzeyleri,
- bağımlı değişkenin ölçeği/dönüşümü,
- aynı kontrol setinin bütün kantillerde kullanılıp kullanılmadığı,
- standart hata veya bootstrap yöntemi,
- kantiller arası katsayı eşitliği test edilip edilmediği,
- örneklem ve ağırlıklandırma yapısı,
- nedensel yorum varsa tanımlama varsayımları.

Örnek raporlama

“Eğitim katsayısı koşullu log ücret dağılımının 0,10 kantilinde 0,104, medyanda 0,115 ve 0,90 kantilinde 0,123’tür. Nokta tahminleri eğitim–ücret ilişkisinin üst kantillerde daha güçlü olduğunu göstermektedir. Bu farklılığın örnekleme belirsizliği ayrıca kantiller arası katsayı farkı testi veya ortak bootstrap güven aralıklarıyla değerlendirilmelidir.”

Bir kantil regresyon tablosunda önce hangi τ değerlerinin sütunlarda olduğunu, sonra aynı değişkenin katsayı profilini, standart hata yöntemini ve örneklem büyüklüğünü kontrol edin. Bootstrap kullanıldıysa tekrar sayısı ve kümelenme birimi önemlidir. OLS sütunu varsa onu “doğru referans” değil, farklı bir estimand olan koşullu ortalama karşılaştırması olarak okuyun.

Sonuç metninde “etki yalnız üst kantilde vardır” gibi güçlü dil kullanmadan önce kantiller arası formal farkların sınanıp sınanmadığını ve nedensel tanımlamanın kurulup kurulmadığını kontrol edin.

7.16 Ampirik Uygulama Laboratuvarı: Ortalama Katsayıdan Dağılımsal Profile

Bu uygulamada yine Hansen’in CPS ücret verisini kullanıyoruz. OLS tek bir koşullu ortalama eğimi verirken kantil regresyon, eğitim ve diğer kovaryatların ücret dağılımının farklı noktalarıyla nasıl ilişkili olduğunu incelememizi sağlar (Hansen, 2021). Aynı 50.742 gözlem üzerinde

$$Q_\tau[\log(wage_i) | X_i] = \beta_{0,\tau} + \beta_{1,\tau}education_i + \beta_{2,\tau}experience_i + \beta_{3,\tau}experience_i^2/100 + \beta_{4,\tau}female_i$$

modelini tahmin ediyoruz.

7.16.1 Adım 1: Kantil katsayılarını tek tek değil profil olarak okumak


Tablo 7.2: CPS log ücret uygulaması: seçilmiş kantil katsayıları ve standart hatalar (kantillerde Hendricks–Koenker, OLS’de HC1)

τ	Eğitim	SH	Kadın	SH
0,10	0,1036	0,0017	−0,1969	0,0095
0,25	0,1095	0,0011	−0,2301	0,0061
0,50	0,1154	0,0009	−0,2592	0,0048
0,75	0,1193	0,0010	−0,2904	0,0055
0,90	0,1226	0,0014	−0,3134	0,0079
OLS	0,1148	0,0011	−0,2596	0,0051

Kantil katsayıları doğrusal programlama probleminin kesin çözümüdür (R `rq`, Stata `qreg`). Standart hatalar [Hendricks ve Koenker \(1992\)](#) sandviçidir: $\widehat{V}_{\beta_\tau} = \frac{\tau(1-\tau)}{n} \widehat{Q}_\tau^{-1} \widehat{Q}_{XX} \widehat{Q}_\tau^{-1}$, $\widehat{Q}_\tau = n^{-1} \sum_i \widehat{f}_i X_i X_i'$, $\widehat{Q}_{XX} = n^{-1} \mathbf{X}' \mathbf{X}$; her gözlemin koşullu yoğunluğu $\widehat{f}_i$, aynı modelin $\tau \pm h$ kantillerindeki tahmin farkından bulunur (h : Hall–Sheather bant genişliği; R’de `summary(m, se = "nid")`).

Eğitim katsayısı alt kantilde 0,1036 iken üst kantilde 0,1226’ya yükselmektedir. Logaritmik bağımlı değişken nedeniyle tam dönüşümler yaklaşık yüzde 10,9 ve yüzde 13,0’dır. Bu desen eğitim–ücret ilişkisinin ücret dağılımının üst bölümünde daha dik olabileceğini düşündürür.

Kadın katsayısı ise mutlak değerce büyümektedir: $\tau = 0,10$ kantilinde $-0,197$, $\tau = 0,90$ kantilinde $-0,313$ ’tür. Dolayısıyla koşullu ücret dağılımındaki cinsiyet farkı üst kantillerde daha geniş görünmektedir.



Şekil 7.6: CPS uygulamasında eğitim katsayısının kantil profili ve noktasal yüzde 95 güven bantları

7.16.2 Adım 2: “Katsayılar farklı” ile “fark istatistiksel olarak kanıtlandı” ayrımı

Şekil 7.6’da nokta tahminleri monoton biçimde artmaktadır. Fakat farklı kantillerde iki katsayının ayrı ayrı anlamlı olması, aralarındaki farkın da anlamlı olduğunu otomatik olarak göstermez. Örneğin

$$H_0 : \beta_{0.10,education} = \beta_{0.90,education}$$

için doğrudan katsayı farkının örnekleme dağılımı gerekir. İki tahmin aynı veriden geldiği için bağımsız değildir; ortak asimptotik kovaryansları

$$\text{Cov}(\hat{\beta}_{\tau_1}, \hat{\beta}_{\tau_2}) = \{\min(\tau_1, \tau_2) - \tau_1\tau_2\} H_{\tau_1}^{-1} \mathbf{X}' \mathbf{X} H_{\tau_2}^{-1}$$

ile verilir (Koenker, 2005). Farkın varyansı iki varyansın toplamından bu kovaryansın iki katı çıkarılarak bulunur; standart hata bunun kareköküdür. CPS örneğinde eğitim katsayısı için $\hat{\beta}_{0.90} - \hat{\beta}_{0.10} = 0,0189$ (SH 0,0021, $z = 8,90$), kadın katsayısı için $-0,1165$ (SH 0,0116, $z = -10,04$) bulunur: bu örnekte fark güçlü biçimde anlamlıdır. Aynı test ortak bootstrap tekrarlarıyla da yapılabilir (Bölüm 10).

Bu ayrım tez yazımında önemlidir. “Tüm kantillerde katsayı anlamlı ve büyüklükler farklıdır; dolayısıyla heterojenlik vardır” ifadesi eksik bir çıkarım olabilir. Daha doğru yaklaşım, profilin ekonomik desenini göstermek ve gerektiğinde kantiller arası eşitlik hipotezini ayrıca sınamaktır.

7.16.3 Adım 3: Koşullu kantil heterojenliğini bireysel tedavi heterojenliğiyle karıştırmamak

Kantil regresyon katsayısı

$$\beta_{\tau}$$

koşullu sonuç dağılımının τ kantilindeki ilişkiyi özetler. Aynı bireyin “eğitim verilseydi ücretinin hangi kantilde değişeceği” gibi bir nedensel heterojenlik yorumu için ek yapısal varsayımlar gerekir. Gözlemsel CPS uygulamasında sonuçlarımız betimsel koşullu dağılım ilişkileridir.

Sık yapılan hata

“Eğitim üst gelir grubundaki bireylere daha çok kazandırıyor” ifadesi, standart koşullu kantil regresyon sonucundan doğrudan çıkmaz. Model üst koşullu ücret kantilindeki eğimin daha büyük olduğunu gösterir; bireysel tedavi etkisi heterojenliği daha güçlü tanımlama koşulları gerektirir.

7.16.4 Adım 4: Kod ve raporlama

Kod 7.1: Aynı spesifikasyonun birden fazla kantilde tahmin edilmesi: kesin çözüm ve Hendricks–Koenker standart hataları

```
import numpy as np
from scipy.optimize import linprog
from scipy.stats import norm

X = np.column_stack([np.ones(len(df)),
                     df[["education", "female", "experience", "experience2_100"]]])
y = df["lwage"].to_numpy()
```

```

def kantil(tau):
    # Doğrusal programlamanın kesin çözümü (dual problem); R rq ve Stata qreg ile aynı
    r = linprog(-y, A_eq=X.T, b_eq=(1 - tau) * X.sum(axis=0),
                bounds=(0, 1), method="highs")
    return -r.eqlin.marginals

def hk_kovaryans(tau):
    # Hendricks-Koenker: yoğunluk tau-h ve tau+h kantil doğrularının farkından (R: se
    # = "nid")
    z = norm.ppf(tau)
    h = (len(y) ** (-1 / 3) * norm.ppf(0.975) ** (2 / 3)
          * (1.5 * norm.pdf(z) ** 2 / (2 * z ** 2 + 1)) ** (1 / 3)) # Hall-Sheather
    while tau - h < 0 or tau + h > 1:
        h /= 2
    fark = X @ (kantil(tau + h) - kantil(tau - h))
    f = np.maximum(0, 2 * h / (fark - np.finfo(float).eps ** 0.5))
    Hinv = np.linalg.inv(X.T @ (f[:, None] * X))
    return tau * (1 - tau) * Hinv @ (X.T @ X) @ Hinv

rows = []
for tau in [0.10, 0.25, 0.50, 0.75, 0.90]:
    b, V = kantil(tau), hk_kovaryans(tau)
    rows.append({"tau": tau, "education": b[1], "se": np.sqrt(V[1, 1])})

```

`statsmodels` paketindeki `QuantReg` yinelemeli bir yaklaşım kullanır ve kesin çözüme yalnız yaklaşır: bu örnekte $\tau = 0,90$ eğitim katsayısını dördüncü ondalıkta 0,1225 verir. Aynı paketin `vcov="robust"` seçeneği bütün gözlemler için tek bir ortak yoğunluk kullandığından yukarıdaki standart hatalardan farklıdır. Uygulama ekranındaki Python, R ve Stata kodu [Tablo 7.2](#)'deki sayıların tamamını yeniden üretir.

Bir makalede yalnız tek bir medyan regresyonu göstermek mümkün olmakla birlikte, araştırma sorusu dağılımsal heterojenlik ise seçilen kantillerin önceden gerekçelendirilmesi ve tüm profilin aynı tabloda/grafikte gösterilmesi daha şeffaftır.

7.16.5 Hansen'in DDK örneği: nokta tahmini ile belirsizliğin birlikte okunması

Hansen, Duflo–Dupas–Kremer tracking verisinde kümeli bootstrap standart hatalarla $\tau = 0,1, 0,3, 0,5, 0,7$ ve $0,9$ kantillerini karşılaştırır. Nokta tahminleri üst kantillerde daha büyük görünse de güven aralıkları genişler ve genel kanıtın zayıf olduğu sonucuna varılır ([Hansen, 2021](#)). Bu örnek çok önemli bir raporlama dersidir: dağılımın uçlarında daha dramatik katsayılar görmek, o bölgelerde daha fazla bilgi bulunduğu anlamına gelmez; çoğu zaman tam tersine belirsizlik artar.

7.16.6 Kendi tezinizde kantil regresyon için protokol

1. Ortalama yerine neden kantil estimand'ına ihtiyaç duyduğunuzu açıklayın.
2. Kantil setini sonuçlara bakarak değil araştırma sorusuna göre belirleyin.
3. Her kantilde katsayı ve standart hatayı birlikte raporlayın.
4. Kümeli veri varsa gözlem değil küme yeniden örnekleyen bootstrap kullanın.

5. Katsayı profillerini grafikleştirin; kantil kesişmesi olup olmadığını kontrol edin.
6. Kantil farklarını yorumlayacaksanız doğrudan fark testleri veya ortak bootstrap kullanın.
7. Nedensel kantil yorumu için gereken ek tanımlama varsayımlarını açıkça yazın.

7.17 Temel Sonuçlar

1. Kantil regresyon OLS'nin “daha dayanıklı bir biçimi” değil, farklı bir tahmin hedefi ailesidir.
2. Medyan regresyonu mutlak sapmaları; genel kantil regresyon asimetrik check-loss'u minimize eder.
3. β_τ koşullu τ kantilinin doğrusal katsayısı veya en iyi doğrusal kantil yaklaşımıdır.
4. Kantil katsayılarının değişmesi dağılımsal heterojenlik göstergesidir; ancak bunun nedensel heterojenlik olması ek varsayımlar gerektirir.
5. Analitik robust standart hatalar ve bootstrap çıkarımı önemlidir.
6. Ayrı kantil regresyonları kesişebilir; bu durum fonksiyonel biçim ve örnekleme belirsizliği açısından incelenmelidir.
7. Kantil profilleri, tek bir ortalama katsayının sakladığı dağılımsal örüntüleri görünür kılabılır.

7.18 Bölüm Sonu Egzersizleri

Egzersiz 7.1: Kantil tanımı

Bir koşullu dağılım için $P(Y \leq 50 \mid X = x) = 0,25$ ve dağılım sürekli olsun.

1. $q_{0.25}(x)$ nedir?
2. Bu değer koşullu ortalama hakkında tek başına ne söyler?
3. $q_{0.5}(x)$ hangi özel isimle anılır?

Egzersiz 7.2: Medyan ve mutlak kayıp

Y gözlemleri 1, 2, 3, 10 olsun. Aday merkezler $a = 2$, $a = 2,5$ ve $a = 3$ için mutlak sapmalar toplamını hesaplayınız. Medyan minimizasyon özelliğini yorumlayınız.

Egzersiz 7.3: Check-loss hesabı

$u = -2$ ve $u = 3$ artıklarını kullanarak $\rho_\tau(u)$ değerlerini $\tau = 0,2, 0,5$ ve $0,8$ için hesaplayınız. Hangi kantilde negatif artık daha ağır cezalandırılır?

Egzersiz 7.4: Kantil moment koşulu

$\psi_\tau(u) = \tau - 1\{u < 0\}$ tanımını kullanınız. Bir model doğru 0,25 kantilini tahmin ediyorsa artıkların yaklaşık ne kadar negatif olmalıdır? Bağlantıyı $E[\psi_\tau(e)] = 0$ üzerinden

gösteriniz.

Egzersiz 7.5: Doğrusal kantil yorumu

$Q_{0.75}[Y | X] = 4 + 1,5X$ olsun.

1. $X = 2$ için koşullu 75. kantili hesaplayınız.
2. Eğim katsayısını doğru biçimde yorumlayınız.
3. Bu katsayının ortalama etki olduğunu söylemek neden yanlıştır?

Egzersiz 7.6: OLS ve medyan

Bir ücret dağılımı sağa çarpıktır. OLS eğitim katsayısı 0,14, medyan regresyon katsayısı 0,10 bulunmuştur.

1. İki katsayının farklı estimand'larını açıklayınız.
2. “OLS yanlıştır, kantil regresyon doğrudur” yorumunu değerlendiriniz.
3. Araştırma sorusu “tipik çalışanın ücreti” ise hangi sonuç daha doğrudan olabilir?

Egzersiz 7.7: CPS kantil profili

Tablo 7.1'i kullanınız.

1. Eğitim katsayısının $\tau = 0,10$ ile $0,90$ arasındaki farkını hesaplayınız.
2. Kadın katsayısının aynı iki kantil arasındaki değişimini hesaplayınız.
3. OLS katsayısının kantil profili içinde nerede bulunduğunu yorumlayınız.
4. Bu tablodan doğrudan nedensel eğitim getirisi çıkarılamamasının nedenini açıklayınız.

Egzersiz 7.8: Paralel kantiller

$Y = 2 + 3X + e$ ve e 'nin X 'ten bağımsız olduğu, e kantillerinin $q_{0.1}(e) = -2$, $q_{0.5}(e) = 0$, $q_{0.9}(e) = 2$ olduğu verilsin. Üç koşullu kantil fonksiyonunu yazınız ve neden paralel olduklarını açıklayınız.

Egzersiz 7.9: Kantil kesişmesi

Tahmin edilen iki doğrusal kantil

$$\hat{q}_{0.25}(x) = 2 + 0,9x, \quad \hat{q}_{0.75}(x) = 5 + 0,35x$$

olsun.

1. İki doğrunun kesiştiği x değerini bulunuz.
2. x bu değerin üzerindeyken hangi sıralama ihlal edilir?

3. En az iki olası düzeltme stratejisi belirtiniz.

Egzersiz 7.10: Standart hata sezgisi

Bir 0,95 kantil regresyonda hedef kantilin çevresinde çok az gözlem olduğunu varsayınız. Hedef yoğunluğun düşük olmasının standart hataya neden yukarı yönlü etkide bulunacağını sezgisel olarak açıklayınız.

Egzersiz 7.11: Bootstrap tasarımı

Bir araştırmacı $\hat{\beta}_{0.9,j} - \hat{\beta}_{0.1,j}$ farkı için güven aralığı kurmak istiyor.

1. Her bootstrap örnekleminde hangi iki modeli yeniden tahmin etmelidir?
2. Neden iki katsayıyı bağımsız bootstrap'lerden almak yerine aynı yeniden örneklem içinde hesaplamak daha uygundur?
3. Veri okullar içinde kümeliyse yeniden örnekleme birimi ne olmalıdır?

Egzersiz 7.12: Araştırma sorusundan estimand'a

Aşağıdaki sorular için ortalama regresyon mu, medyan/kantil regresyon mu daha doğrudan bir başlangıç noktasıdır? Gerekçenizi yazınız.

1. “Eğitim ortalama ücreti nasıl değiştiriyor?”
2. “Bir kira desteği düşük kira ödeyen haneler ile yüksek kira ödeyen hanelerde farklı ilişki gösteriyor mu?”
3. “Firmanın tipik teslim süresi nedir ve teknoloji yatırımıyla nasıl değişiyor?”
4. “Politika gelir dağılımının alt yüzde 10 eşikliğiyle nasıl ilişkilidir?”

Parametrik Olmayan ve Yarı Parametrik Regresyon

Bu bölümün amacı

Bu bölümün sonunda koşullu beklenti fonksiyonunu önceden belirlenmiş tek bir küresel fonksiyonel biçime zorlamadan tahmin etmenin neden gerekli olabileceğini açıklayabilecek; kernel ağırlıklarını ve Nadaraya–Watson tahmin edicisini kurabilecek; yerel doğrusal regresyonu ağırlıklı bir en küçük kareler problemi olarak türetebilecek; bant genişliğinin yanlılık–varyans dengesindeki rolünü değerlendirebilecek; çapraz doğrulama ile bant genişliği seçiminin mantığını açıklayabilecek; polinom ve spline tabanlı seri regresyonunu kernel yöntemleriyle karşılaştırabilecek; boyutluluk lanetinin neden ortaya çıktığını görebilecek ve kısmen doğrusal modelde parametrik bir katsayı ile parametrik olmayan bir fonksiyonun birlikte nasıl tahmin edildiğini anlayabileceksiniz.

Bağlantı

Bölüm 7’de doğrusal modelin hedeflediği dağılım özelliğini değiştirdik ve koşullu ortalama-dan koşullu kantillere geçtik. Bu bölümde hedef tekrar koşullu ortalamadır, fakat bu kez fonksiyonel biçimi gevşetiyoruz. Temel soru şudur: $m(x) = E[Y | X = x]$ fonksiyonunun doğrusal, karesel ya da önceden seçilmiş başka bir biçimde olduğundan emin değilsek biçim konusunda verinin kendisinin konuşmasına ne ölçüde izin verebiliriz? Hansen’in Bölüm 19 ve 20’si bu bölümün temel kaynağıdır (Hansen, 2021).

Ders içi öncelik

Derste çekirdek: kernel ağırlıkları; yerel doğrusal regresyon; bant genişliği; çapraz doğrulama; kısmen doğrusal model ve artıktırma.

Notta genişletme/ileri okuma: Nadaraya–Watson ayrıntıları, seri/polinom/spline yaklaşımları ve çok boyutlu parametrik olmayan tahminin teknik güçlükleri.

8.1 Fonksiyonel Biçim de Bir Varsayımdır

Doğrusal regresyonda

$$E[Y | X = x] = \beta_0 + \beta_1 x$$

varsayımı, koşullu ortalamanın bütün destek boyunca tek bir doğruyla temsil edilebildiğini söyler. Karesel model

$$E[Y | X = x] = \beta_0 + \beta_1 x + \beta_2 x^2$$

biraz daha esnektir; fakat yine bütün eğrinin biçimini sonlu sayıda katsayıyla önceden belirler.

Bu tür parametrik modeller çoğu uygulamada yararlıdır. Sorun, seçilen fonksiyonel biçim esas ilişkiyi yakalamıyorsa ortaya çıkar. Örneğin eğitim ile ücret arasındaki ilişki düşük eğitim düzeylerinde yatay, orta düzeylerde dik ve üst düzeylerde tekrar yatay olabilir. Tek bir doğru bu yapıyı ortalama bir eğime indirger. Kübik polinom daha esnek görünse de uçlarda yapay dalgalanmalar yaratabilir.

Parametrik ve parametrik olmayan yaklaşım

Parametrik regresyonda $m(x)$ sonlu boyutlu bir parametre vektörüyle tanımlanır; örneğin $m(x) = x'\beta$. Parametrik olmayan regresyonda ise $m(\cdot)$ fonksiyonunun biçimi sonlu sayıda katsayıyla önceden sabitlenmez. Yarı parametrik modeller, sonlu boyutlu bir parametre ile bilinmeyen bir fonksiyonu aynı modelde birlikte kullanır.

Sık yapılan hata

“Parametrik olmayan” ifadesi “varsayimsız” anlamına gelmez. Düzgünlük, bant genişliği, kernel, destek, örnekleme yapısı ve boyut gibi seçimler hâlâ önemlidir. Yöntem, fonksiyonel biçim varsayımını gevşetir; bütün varsayımları ortadan kaldırmaz.

Doğrusal veya karesel model seçtiğimizde koşullu ortalamanın biçimi hakkında güçlü bir kısıt koyarız. Parametrik olmayan regresyon, $m(x) = E[Y | X = x]$ fonksiyonunu sonlu sayıda sabit katsayıyla tamamen belirlemek yerine verinin yerel yapısından öğrenmeye çalışır. Bu esneklik, model yanlış belirtimi riskini azaltabilir; fakat bunun karşılığında daha fazla veri gerektirir ve ayar parametresi seçimlerini önemli hale getirir.

Dolayısıyla parametrik olmayan yöntem “varsayimsız” değildir. Düzgünlük, bant genişliği, kernel seçimi ve veri desteği gibi koşullar gerekir. Parametrik model biçimi varsayımını gevşetirken başka düzenlilik varsayımlarına geçeriz. Araştırmacı esneklik ile tahmin hassasiyeti arasındaki bu değiş tokuşu açıkça görmelidir.

8.2 En Basit Sezgi: Yakındaki Gözlemler Daha Fazla Bilgi Taşır

Belirli bir x noktasında $m(x) = E[Y | X = x]$ tahmin etmek istediğimizi düşünelim. X_i değeri x 'e çok yakın olan gözlemler, x noktasındaki koşullu ortalama hakkında daha doğrudan bilgi taşır. Çok uzaktaki gözlemler ise daha az bilgi taşır. Kernel regresyonu bu fikri ağırlıklarla uygular.


Bir kernel fonksiyonu $K(u)$, merkeze yakın gözlemlere daha yüksek, uzaktaki gözlemlere daha düşük ağırlık verir. Bant genişliği $h > 0$ ölçeği belirler:

$$K_h(X_i - x) = \frac{1}{h} K\left(\frac{X_i - x}{h}\right). \quad (8.1)$$

Örneğin Gauss kernelinde

$$K(u) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{u^2}{2}\right),$$

ağırlık hiçbir noktada tam sıfıra düşmez fakat uzaklaştıkça hızla küçülür. Dikdörtgen kernel ise belirli pencerenin içindeki gözlemlere eşit, dışındakilere sıfır ağırlık verir.



Şekil 8.1: Kernel yaklaşımında merkeze yakın gözlemlerin daha fazla ağırlık alması

Bir x_0 noktasındaki koşullu ortalamayı öğrenmek için X_i değeri x_0 'a yakın gözlemler daha doğrudan bilgi taşır. Kernel yöntemleri bu sezgiyi ağırlık fonksiyonuna dönüştürür. Uzaklık $|X_i - x_0|$ bant genişliği h 'ye göre ölçeklenir; kernel $K(\cdot)$ yakın gözlemlere yüksek, uzaktakilere düşük veya sıfır ağırlık verir.

Burada “yakın” kavramının ekonomik ölçeği önemlidir. Gelirde 1000 TL fark ile yaşta 1000 yıl fark aynı şey değildir; çok değişkenli nonparametrik modellerde değişkenlerin ölçekleri ve bant genişlikleri ayrı düşünülür. Bu da boyut arttıkça yöntemin neden hızla zorlaştığının bir parçasıdır.

8.3 Nadaraya–Watson Kernel Regresyonu

En basit kernel koşullu ortalama tahmin edicisi, yerel ağırlıklı ortalamaadır:

$$\hat{m}_{NW}(x) = \frac{\sum_{i=1}^n K_h(X_i - x)Y_i}{\sum_{i=1}^n K_h(X_i - x)}. \quad (8.2)$$

Bu ifade sıradan örneklem ortalamasına benzer. Fark, her gözlemin eşit değil x 'e uzaklığına bağlı ağırlıklı girmesidir. Payda ağırlıkları normalize ederek toplamalarının bire eşit olmasını sağlar. Bunun için paydanın sıfırdan büyük olması, yani x civarında pozitif ağırlık alan en az bir gözlem bulunması gerekir; dikdörtgen kernelde pencere boşsa tahmin tanımsızdır.

Nadaraya–Watson nasıl okunmalı?

$\hat{m}_{NW}(x)$, “ X değeri x civarında olan gözlemlerin ağırlıklı ortalama Y değeri” olarak okunabilir. Bu nedenle katsayı yorumundan çok eğrinin kendisi ve eğrinin farklı x noktalarındaki düzeyi önemlidir.

Nadaraya–Watson tahmin edicisi sezgisel olmakla birlikte özellikle destegin sınırlarında yanlış olabilir. Örneğin x en küçük gözlemlere yakınsa pencerenin sol tarafında veri yoktur. Yerel ortalama tek taraflı gözlemlerden oluşur ve eğimli bir gerçek fonksiyonun sınırdaki düzeyini sistematik olarak kaçırabilir.

Ayrıca $m(x)$ yerel olarak eğimli olduğunda sabit yerel ortalama bu eğimi hesaba katmaz. Yerel doğrusal regresyon her iki problemi de önemli ölçüde iyileştirir.

Kernel ölçeklemesi çoğu kaynakta $K_h(u) = K(u/h)/h$ olarak yazılır. Ağırlıklar normalize edildiği için ortak $1/h$ çarpanı NW oranında sadeleşir. Kernel genellikle simetrik ve integrali bir olan bir yoğunluk benzeri fonksiyondur. Asimptotik olarak kernel'in ayrıntılı şekli ikinci derecede, bant genişliği ise birinci derecede önem taşır.

İç noktada düzgün $m(x)$ altında NW yanlışlığı tipik olarak $O(h^2)$, varyansı $O((nh)^{-1})$ düzeyindedir. Bu kaba oranlar, h küçüldükçe yanlışlığın azalırken varyansın neden arttığını matematiksel olarak özetler.

8.4 Yerel Doğrusal Regresyon

Sınır yanlışlığını azaltan ve uygulamada çok kullanılan yöntem **yerel doğrusal regresyon**dur. Belirli bir x noktasında, x çevresinde koşullu ortalamayı küçük bir doğruyla yaklaşıtırırız:

$$m(X_i) \approx a + b(X_i - x).$$

Her x için ayrı ayrı ağırlıklı en küçük kareler problemi çözülür:

$$(\hat{a}(x), \hat{b}(x)) = \arg \min_{a,b} \sum_{i=1}^n K_h(X_i - x) [Y_i - a - b(X_i - x)]^2. \quad (8.3)$$

Koşullu ortalama tahmini

$$\hat{m}_{LL}(x) = \hat{a}(x) \quad (8.4)$$

olur.

Bu formül önemli bir bağlantı kurar: parametrik olmayan tahmin, tamamen farklı bir matematik değil; bildiğimiz OLS'nin *yerel ve ağırlıklı* kullanım biçimidir. Her hedef noktada ağırlıklar değiştiği için her noktada farklı küçük regresyon tahmin edilir.

Neden yerel doğrusal?

Yerel doğrusal tahmin, Nadaraya–Watson'a göre özellikle destek sınırlarında daha iyi davranır ve doğrusal bir gerçek koşullu ortalamayı yerel olarak tam temsil edebilir. Bu nedenle Hansen uygulamalarında da temel parametrik olmayan regresyon aracı olarak öne çıkar (Hansen, 2021).

Vurgulanması gereken nokta, modelin bütün veri üzerinde doğrusal olmamasıdır: yalnız küçük bir komşulukta doğrusal yaklaşım kurulur ve x değiştiğinde regresyon yeniden tahmin edilir. Yerel eğimi b ile hesaba katmak hem yanlışlığı azaltır hem de sınır noktalarında tek taraflı veri bulunsa bile sınır yanlışlığını düşürür. Bölüm 9'da RDD'nin yerel doğrusal regresyona dayanmasının temel nedeni budur.

Yerel doğrusal tahminin kesme terimi $\hat{a}$ koşullu ortalamayı, eğim $\hat{b}$ ise aynı noktadaki türevi yaklaşıklar. Böylece yöntem yalnız $m(x)$ değil marjinal eğim $m'(x)$ için de bilgi sağlar. Türev tahmini, ekonomik marjinal etkilerin doğrusal olmayan fonksiyon boyunca nasıl değiştiğini incelemek için yararlıdır.

Ancak türevler fonksiyon seviyesine göre daha gürültülüdür ve bant genişliği seçimine daha duyarlıdır. Bir grafikte küçük kıvrımlardan çok kesin ekonomik dönüm noktaları çıkarmak dikkat

gerektirir.

8.5 Bant Genişliği: Esnekliğin Asıl Düğmesi

Kernel türü önemlidir; fakat çoğu uygulamada asıl kritik seçim bant genişliği h 'dir.

- **Küçük h :** çok yerel bir tahmin üretir. Yanlılık azalabilir, fakat az sayıda etkili gözlem kullanıldığı için varyans yükselir ve eğri dalgalı görünür.
- **Büyük h :** daha fazla gözlem etkili olur. Varyans azalır ve eğri düzgünleşir; fakat gerçek eğrinin yerel ayrıntıları aşırı düzleştirilebilir.


Bir boyutlu yerel doğrusal tahminde iç noktalar için tipik asimptotik yapı kabaca

$$\text{Bias}\{\hat{m}(x)\} = O(h^2), \quad \text{var}\{\hat{m}(x)\} = O\left(\frac{1}{nh}\right) \quad (8.5)$$

şeklinde. Dolayısıyla yaklaşık ortalama karesel hata

$$MSE(x) \approx C_1 h^4 + \frac{C_2}{nh}$$

biçiminde düşünülebilir. İlk terim bant büyüdükçe, ikinci terim bant küçüldükçe büyür. Optimal bant genişliği bu iki bileşen arasında denge kurar; standart düzgünlük koşullarında ölçeği yaklaşık $n^{-1/5}$ mertebesinde.



Şekil 8.2: Bant genişliğinde yanlılık–varyans dengesi

Sık yapılan hata

Daha dalgalı bir eğrinin “veriye daha iyi uyduğu” düşüncesi yanıltıcı olabilir. Çok küçük bant genişliği örnekleme gürültüsünü gerçek fonksiyonel yapı gibi izleyebilir. Aşırı büyük bant ise gerçek eğriliği silebilir. Bant genişliği grafik estetiğine göre değil, açık bir seçim kuralıyla belirlenmelidir.

Bant genişliği seçiminin kernel türünden genellikle daha önemli olduğu vurgulanmalıdır. Gauss, Epanechnikov veya üçgen kernel arasında makul seçimler çoğu uygulamada ikinci derecede fark yaratırken, h 'deki büyük değişim tahmin edilen fonksiyonun görünümünü kökten değiştirebilir. Bu nedenle sonuçlar birkaç makul bant genişliği altında görsel olarak da kontrol edilmelidir.

8.6 Çapraz Doğrulama ile Bant Genişliği Seçimi

Bant genişliğini veriden seçmenin temel yollarından biri leave-one-out çapraz doğrulamadır. Her gözlem sırayla dışarıda bırakılır; kalan $n - 1$ gözlemle X_i noktasındaki tahmin hesaplanır:

$$\hat{m}_{-i,h}(X_i).$$

Sonra tahmin hatalarının karelerinin ortalaması alınır:

$$CV(h) = \frac{1}{n} \sum_{i=1}^n [Y_i - \hat{m}_{-i,h}(X_i)]^2. \quad (8.6)$$

Seçilen bant genişliği

$$\hat{h}_{CV} = \arg \min_h CV(h) \quad (8.7)$$

olur.

Bu ölçüt, modelin kendi gözlemini tahmin etme avantajını kaldırır. Çok küçük h eğitim verisini aşırı takip ediyorsa dışarıda bırakılan gözlemlerde hata büyür. Çok büyük h gerçek yapıyı aşırı düzleştiriyorsa yine hata büyür.

Kümelı örneklerde bir gözlemi tek başına silmek bağımlılığı yeterince kırmayabilir. Hansen'in Duflo–Dupas–Kremer test puanı uygulamasında öğrenciler okul içinde kümelidir ve Hansen standart CV ile küme silmeli CV'nin farklı bant genişlikleri önerebildiğini gösterir (Hansen, 2021).

CV veriye uyarlanmış nesnel bir seçim sağlar; fakat seçilen h tek “doğru” bant genişliği değildir. Tahmin hedefi nokta tahmini, türev, güven bandı veya RDD sınır değeri olduğunda optimal kriterler farklılaşabilir. Ayrıca CV yüzeyi düzse birbirine yakın çok sayıda h benzer performans gösterebilir. Bu durumda küçük sayısal farkları aşırı yorumlamamak gerekir.

8.7 Seri Regresyonu: Fonksiyonu Baz Fonksiyonlarla Yaklaştırmak

Kernel yaklaşımı yereldir. Alternatif yol, $m(x)$ fonksiyonunu giderek zenginleşen bir baz fonksiyon kümesiyle yaklaşık olarak temsil etmektir:

$$m(x) \approx p_K(x)' \beta_K, \quad (8.8)$$

burada $p_K(x)$, K adet dönüşümden oluşan vektördür.

Polinom regresyonunda

$$p_K(x) = (1, x, x^2, \dots, x^{K-1})'.$$

Tahmin sıradan OLS ile yapılır. Ancak yüksek dereceli küresel polinomlar özellikle sınır bölgelerinde güçlü dalgalanmalar gösterebilir. Bu nedenle daha yerel bazlar olan **spline**'lar çoğu zaman daha istikrarlıdır.

8.7.1 Kübik spline sezgisi

Kübik spline, X desteğini düğüm noktalarında parçalara ayırır ve her parçada kübik polinom kullanır. Parçalar düğümlerde düzey, birinci ve ikinci türev sürekli kalacak biçimde birleştirilir.

Truncated-power gösteriminde bir kübik spline şu biçimde yazılabilir:

$$m(x) = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 x^3 + \sum_{j=1}^J \gamma_j (x - \kappa_j)_+^3, \quad (8.9)$$

$$(a)_+ = \max(a, 0),$$

ve κ_j düğüm noktalarıdır. Düğümlerin sayısı ve yeri esnekliği kontrol eder.

Yerel ve küresel esneklik

Kernel ve yerel polinom tahminleri esas olarak hedef nokta çevresindeki gözlemlere dayanır. Seri regresyonunda bir baz katsayısı çoğu zaman eğrinin daha geniş bölümünü etkiler. Spline bazları, küresel polinomlara kıyasla bu etkiyi daha yerel hâle getirir.

Sabit K için model sıradan OLS ile tahmin edilir; esneklik, örneklem büyüdükçe K 'nın artmasına izin verilmesinden gelir.

Bu yaklaşım kernel regresyondan farklı bir esneklik kontrolüne sahiptir. Kernel'de ana tuning parametresi h iken, seri regresyonunda baz sayısı K belirleyicidir (spline'da K , düğüm sayısı J ile belirlenir). Çok küçük K yetersiz uyum, çok büyük K yüksek varyans ve aşırı uyum yaratabilir. Çapraz doğrulama veya teorik kurallar bu seçime yardım eder.

8.8 Hansen Verisiyle Uygulama: Test Puanı ve Başlangıç Başarısı

Hansen, Bölüm 19'da Duflo, Dupas ve Kremer'in Kenya'daki deneyinin verilerini kullanır; bu deneyde öğrencileri başlangıç başarı düzeyine göre ayrı sınıflara yerleştirme uygulaması (tracking) okul düzeyinde rastgele atanmıştır. Burada aynı veri paketindeki, tracking uygulanan okullarda bulunan kız öğrencilerin dönem sonu toplam test puanını başlangıç yüzdelik dilimine göre inceliyoruz. Eksiksiz örneklemde $n = 1.487$ öğrenci vardır. Hansen'in örneğinde yerel doğrusal tahmin için kümeli çapraz doğrulamadan gelen bant genişliği yaklaşık $h = 6,2$ 'dir (Hansen, 2021).


Şekil 8.3'te 1.487 tekil noktayı çizmek yerine yirmi aralığın ortalamaları gösterilmiştir; eğriler bütün bireysel gözlemler kullanılarak tahmin edilmiştir. Kübik spline denklem (8.9)'daki truncated-power bazıyla, düğümleri 25, 50 ve 75. yüzdelikte olacak biçimde kurulmuştur; yerel doğrusal tahmin Gauss kerneli ve $h = 6,2$ ile yapılmıştır. Bütün tahminler OLS veya ağırlıklı OLS'dir; uygulama ekranındaki kod tabloyu üç dilde yeniden üretir. Doğrusal model genel artışı yakalasa da düşük ve özellikle yüksek başlangıç yüzdeliklerinde yerel doğrusal ve spline uyumları daha belirgin eğrilik gösterir.

Seçilmiş üç noktadaki tahminler şöyledir:

Tablo 8.1: Başlangıç yüzdelik dilimine göre tahmini toplam test puanı

Yüzdelik	Doğrusal	Kübik polinom	Yerel doğrusal	Kübik spline
10	7,57	8,09	8,02	8,02
50	13,94	13,26	13,49	13,56
90	20,31	21,22	21,06	20,89

Tablo, esnek yöntemlerin de birbiriyle tamamen aynı sayıları vermediğini gösterir. Parametrik olmayan model “tek doğru cevabı” otomatik üretmez; farklı düzgünleştirme kararları farklı



Şekil 8.3: DDK2011 verisinde doğrusal, polinom, yerel doğrusal ve spline uyumlarının karşılaştırılması

tahminler doğurabilir. Bu nedenle sonuçlar bant genişliği, düğüm sayısı veya polinom derecesine duyarlılık bakımından incelenmelidir.

Uygulamadaki farklı uyum eğrileri tek bir “kazanan model” aramak için değil, fonksiyonel biçim varsayımının sonuçları nasıl şekillendirdiğini görmek için karşılaştırılmalıdır. Doğrusal model bütün aralığa tek eğim verir; kübik polinom küresel esneklik getirir; spline parçalı esneklik, yerel doğrusal regresyon ise komşuluk-temelli esneklik sağlar.

Eğrilerin veri yoğunluğunun yüksek olduğu bölgelerde benzer, uçlarda farklılaşması beklenebilir. Uç bölgelerde az gözlem varsa güven aralıklarının genişlemesi gerekir. Grafik yalnız tahmin çizgilerini değil mümkünse veri desteğini de göstermelidir.

8.9 Boyutluluk Laneti

Tek açıklayıcı değişkende “yakın gözlem” bulmak görece kolaydır. Fakat X çok boyutlu olduğunda bir gözlemin bütün koordinatlarda aynı anda hedef noktaya yakın olması zorlaşır. Örneğin her bir değişkenin yerel aralığı desteğin yalnız yüzde 20’sini kapsıyorsa, d bağımsız boyutta pencere hacmi kabaca

$$0,2^d$$

olur. $d = 1$ için yüzde 20 olan oran, $d = 5$ için yalnızca yüzde 0,032’dir.

Bu olgu **boyutluluk laneti** olarak adlandırılır. Çok sayıda kovaryatı tamamen parametrik olmayan biçimde modellemek büyük örneklemelerde bile zor olabilir. Bu nedenle iktisadi uygulamalarda yarı parametrik yapıların önemi artar.

Aynı olgu yakınsama hızında da görünür: kernel regresyonda optimal bant genişliği kabaca $h \asymp n^{-1/(4+d)}$ mertebesine kayar ve tahminin yakınsama hızı boyutla birlikte yavaşlar (Hansen, 2021). Boyut arttıkça aynı yerel hassasiyet için çok daha büyük örneklem gerekir.

Bu olgu, “çok kontrolüm var, hepsini nonparametrik modele koyayım” yaklaşımının pratik olmadığını açıklar. Çözümler arasında kısmen doğrusal/additif yapılar, boyut indirgeme ve yüksek boyutlu düzenleme yöntemleri bulunur. Bölüm 11 ve Bölüm 12’de Lasso ve DML bu probleme farklı bir açıdan dönecektir.

8.10 Kısmen Doğrusal Model

Hansen §19.24’te kısmen doğrusal modeli $Y = m(X) + Z'\beta + e$, $E[e | X, Z] = 0$ biçiminde yazar. Burada Z doğrusal bileşenin regresör vektörü, X ise esnek bileşenin kovaryat vektörüdür. DML bölümüne geçiş için bu modelin tek doğrusal regresörlü özel hâlini kullanıyoruz: $Z = D$, $\beta = \theta$ ve yapısal $m = g$ adlandırmasıyla sık kullanılan yarı parametrik model

$$Y = D\theta + g(X) + e, \quad E[e | D, X] = 0 \quad (8.10)$$

şeklinde. $g(X)$ yapısal esnek bileşendir; $m_Y(X) = E[Y | X] = \theta m_D(X) + g(X)$ ile aynı fonksiyon değildir. Burada D etkisini bir katsayıyla ölçmek istediğimiz temel değişken, X ise etkisi esnek biçimde kontrol edilen kovaryat vektörüdür.

X koşullu beklentisini alalım ($E[e | D, X] = 0$ olduğundan yinelenen beklentiler yasasıyla $E[e | X] = 0$):

$$E[Y | X] = \theta E[D | X] + g(X).$$

Tanımlayalım:

$$m_Y(X) = E[Y | X], \quad m_D(X) = E[D | X].$$

Ana denklemden koşullu ortalamayı çıkarınca

$$Y - m_Y(X) = \theta\{D - m_D(X)\} + e \quad (8.11)$$

elde edilir. Dolayısıyla süreç üç adıma ayrılabilir:

1. Y ’yi X üzerinde esnek biçimde tahmin et ve $\hat{m}_Y(X)$ elde et.
2. D ’yi X üzerinde esnek biçimde tahmin et ve $\hat{m}_D(X)$ elde et.
3. Artıkları

$$\tilde{Y}_i = Y_i - \hat{m}_Y(X_i), \quad \tilde{D}_i = D_i - \hat{m}_D(X_i)$$

oluştur ve $\tilde{Y}$ ’yi $\tilde{D}$ üzerine regres et.

Bu *artıklaştırma* (*partialling-out*) yapısı, Bölüm 12’de göreceğimiz Double/Debiased Machine Learning yaklaşımının kavramsal öncüsüdür. Burada esnek bileşen kernel veya seri regresyonuyla tahmin edilebilir; DML’de aynı roller daha genel makine öğrenmesi yöntemleriyle doldurulur.

Sık yapılan hata

$g(X)$ ’i esnek tahmin etmek, D ’nin nedensel olduğu anlamına gelmez. Bölüm 3’teki tanımlama sorunu aynen devam eder. Parametrik olmayan regresyon fonksiyonel biçim hatasını azaltabilir; gözlenmeyen içselliği ortadan kaldırmaz.

Kısmen doğrusal model

$$Y = D\theta + g(X) + e, \quad E[e | D, X] = 0$$

ilgilenilen düşük boyutlu D etkisini parametrik, karmaşık X etkisini nonparametrik bırakır. Bu yapı hem esneklik hem yorumlanabilirlik sağlar. Robinson yaklaşımında önce $E[Y | X]$ ve $E[D | X]$ tahmin edilir; ardından her iki değişken kendi X -öngörüsünden arındırılır:

$$\tilde{Y} = Y - \hat{E}[Y | X], \quad \tilde{D} = D - \hat{E}[D | X].$$

Son olarak $\tilde{Y}$ ile $\tilde{D}$ arasındaki regresyon θ 'yı tahmin eder.

Bu artıktırma mantığı FWL teoreminin parametrik olmayan bir akrabasıdır. Aynı fikir [Bölüm 12](#)'de yüksek boyutlu nuisance modelleri ve cross-fitting ile DML'e dönüşecektir. Böylece dersin farklı yöntemleri ortak "ilgilenilmeyen bileşeni ayır, hedef varyasyonu kullan" düşüncesinde birleşir ([Robinson, 1988](#); [Hansen, 2021](#)).

Robinson artıktırmasının anakütledeki ideal kimliği şu şekilde görülebilir. $Y = D\theta + g(X) + e$ için X koşullu beklentisini çıkaralım:

$$Y - E[Y | X] = \theta\{D - E[D | X]\} + e.$$

Eğer $E[e | D, X] = 0$ ise artıktırılmış D ile e ortogonaldır; ayrıca $E[\{D - E[D | X]\}^2] > 0$ ise, yani D , X tarafından tamamen belirlenmiyorsa, θ artık regresyonuyla tanımlanır:

$$\theta = \frac{E[\{D - E[D | X]\}\{Y - E[Y | X]\}]}{E[\{D - E[D | X]\}^2]}.$$

Bu kimlik, nuisance fonksiyonları doğru tahmin edildiğinde parametreyi yüksek boyutlu olmayan bir moment problemine indirger.

Bu bölümde düşük boyutlu X için kernel/seri regresyonuyla yapılan bu işlem, [Bölüm 12](#)'de ML ve cross-fitting ile genelleştirilecektir.

8.11 Çıkarım ve Güven Bantları

Parametrik olmayan tahminde standart hata yalnız örnekleme varyansını yansıtır; düzgünleştirme yanlılığı ayrıca önemlidir. Basit noktasal aralık

$$\hat{m}(x) \pm 1.96 s\{\hat{m}(x)\}$$

yanlılık ihmal edildiğinde gerçek $m(x)$ için nominal kapsama sağlamayabilir. Hansen bu nedenle undersmoothing (MSE açısından en iyi banttı daha küçük bir bant seçmek) gibi teknik çözümleri tartışır ve parametrik olmayan güven aralıklarının yorumunda temkinli olunması gerektiğini vurgular ([Hansen, 2021](#)).

Ayrıca **noktasal güven aralığı** ile **eşanlı güven bandı** aynı değildir. Eğrinin her noktasında ayrı yüzde 95 aralık çizmek, bütün eğrinin yüzde 95 olasılıkla bant içinde olduğu anlamına gelmez.

Bir noktadaki $m(x_0)$ için güven aralığı ile bütün bir fonksiyon için güven bandı aynı değildir. Noktasal yüzde 95 aralıklar her x için ayrı kapsama özelliği taşır; aynı anda bütün eğriyi yüzde 95 olasılıkla kapsayacak uniform bant daha geniş olmalıdır. Çok sayıda x noktasındaki ayrı aralıkları tek bir "yüzde 95 güven bandı" gibi sunmak yanlış olabilir.

Ayrıca düzgünleştirme yanlılığı (smoothing bias) çıkarımda önemlidir. Nokta tahmini için iyi MSE sağlayan bant genişliği, yanlılığın standart hataya göre ihmal edilebilir olmasını garanti etmeyebilir. Undersmoothing veya yanlılık düzeltmesi gibi yaklaşımlar bu nedenle geliştirilmiştir.

Bu fikir RDD çıkarımında daha görünür hale gelecektir.

8.12 Hangi Yöntem Ne Zaman?

Tablo 8.2: Fonksiyonel biçim seçeneklerinin karşılaştırılması

Yöntem	Güçlü yanı	Temel ayar	Temel risk
Doğrusal/polinom	Kolay yorum ve çıkarım	Derece	Yanlış küresel biçim
Kernel / yerel doğrusal	Yerel esneklik	Bant genişliği	Aşırı/eksik düzgünleştirme
Spline	Esnek ama hesaplaması OLS benzeri	Düğüm/baz sayısı	Düğüm seçimine duyarlılık
Kısmen doğrusal	Bir katsayıyı korurken kontrolleri esnekleştirir	Esnek yardımcı (nu-isanse) tahminleri	İçsellik çözmez

8.13 Ampirik Uygulama Laboratuvarı: DDK Verisinde Bant Genişliği Bir Model Kararıdır

Hansen’in nonparametrik regresyon uygulamasında Duflo–Dupas–Kremer veri setindeki tracking okullarında bulunan 1.487 kız öğrencinin dönem sonu test puanı, başlangıç yüzdelik diliminin esnek bir fonksiyonu olarak modellenir (Hansen, 2021). Bu uygulama, “nonparametrik” sözcüğünün “karar vermek gerekmiyor” anlamına gelmediğini çok açık biçimde gösterir.

8.13.1 Adım 1: Araştırma sorusu

Başlangıç başarısı ile dönem sonu test puanı arasındaki ilişki doğrusal mı, yoksa özellikle dağılımın alt ve üst uçlarında eğrilik gösteriyor mu? Parametrik doğrusal model

$$E[Y | X = x] = \beta_0 + \beta_1 x$$

tek bir eğim dayatır. Yerel doğrusal tahmin ise her x noktasında yakın gözlemlere daha fazla ağırlık vererek koşullu ortalama eğrisini tahmin eder.

8.13.2 Adım 2: Hansen’de iki farklı CV yaklaşımının farklı h seçmesi

Hansen aynı uygulamada konvansiyonel çapraz doğrulamanın yaklaşık


$$h_{CV} = 12,3$$

ve okul kümelerini birlikte dışarıda bırakan kümeli çapraz doğrulamanın yaklaşık

$$h_{\text{küme-CV}} = 6,2$$

seçtiğini raporlar. Kümeli CV kriteri yaklaşık 5–11 aralığında oldukça yassıdır; yani veri tek bir bant genişliğini çok keskin biçimde ayırt etmemektedir (Hansen, 2021).

Bu nokta tezlerde sık gözden kaçır. Yazılımın otomatik seçtiği tek sayı “doğru bant genişliği” olarak görülmemeli; amaç fonksiyonunun çevresindeki duyarlılık da incelenmelidir.



Şekil 8.4: DDK2011: doğrusal model ve iki farklı bant genişliğinde yerel doğrusal tahmin

8.13.3 Adım 3: Aynı veri, farklı düzgünlük

Tablo 8.3: DDK2011: seçilmiş başlangıç yüzdeliklerinde tahmin edilen test puanı

Başlangıç yüzdeliği	Doğrusal	LL $h = 6,2$	LL $h = 12,3$
10	7,57	8,02	8,04
50	13,94	13,49	13,56
90	20,31	21,06	21,33

Orta bölgede yöntemler birbirine yakındır. Üst uçta yerel doğrusal eğriler doğrusal modelden yaklaşık 0,7–1 puan daha yüksek tahmin üretmektedir. [Tablo 8.1](#) aynı karşılaştırmayı kübik polinom ve düğümleri 25, 50 ve 75. yüzdelikte olan kübik spline ile genişletir: 90. yüzdelikte kübik polinom 21,22, spline 20,89 puan verir; esnek yöntemler de birbirinin aynısı değildir. Daha büyük $h = 12,3$ eğriyi daha fazla düzleştirir; daha küçük $h = 6,2$ yerel değişimleri daha fazla izler.

Bu farklılıkların hiçbiri tek başına “doğru model” kanıtı değildir. Araştırmacı şu üç unsuru birlikte değerlendirmelidir:

1. veri desteği ve sınır bölgelerindeki gözlem yoğunluğu,
2. çapraz doğrulama veya başka tuning kriteri,
3. alternatif makul h değerlerinde bilimsel sonucun değişip değişmediği.

8.13.4 Adım 4: Kümeli yapıyı tuning aşamasına da taşımak

Öğrenciler okul içinde bağımlıdır. Standart leave-one-out CV tek bir öğrenciyi dışarıda bırakırken aynı okuldan çok benzer gözlemleri eğitim setinde tutar. Bu nedenle tahmin performansını

gereğinden iyimser değerlendirebilir. Hansen'in önerdiği küme silmeli (delete-cluster) yaklaşım, bir okulun bütün öğrencilerini birlikte dışarıda bırakır (Hansen, 2021).

Bu ders, bağımlılığın yalnız standart hata problemine indirgenemeyeceğini gösterir. Veri kümeli olduğunda

- standart hata,
- çapraz doğrulama,
- bootstrap,
- train/test bölmesi

gibi yeniden örnekleme veya doğrulama adımlarının da kümeyi koruması gerekir.

Kod 8.1: Yerel doğrusal tahminde iki bant genişliğinin karşılaştırılması

```
def yerel_dogrusal(x, y, noktalar, h):
    # Gauss kerneli; h kernelin standart sapması. Her noktada ağırlıklı EKK'nin sabit
    # terimi.
    d = x[None, :] - noktalar[:, None]
    w = np.exp(-0.5 * (d / h) ** 2)
    s0, s1, s2 = w.sum(axis=1), (w * d).sum(axis=1), (w * d * d).sum(axis=1)
    t0, t1 = w @ y, (w * d) @ y
    return (s2 * t0 - s1 * t1) / (s0 * s2 - s1 ** 2)

x, y = df["percentile"].to_numpy(), df["totalscore"].to_numpy()
izgara = np.linspace(0, 100, 101)
egriler = {h: yerel_dogrusal(x, y, izgara, h) for h in (6.2, 12.3)}
```

Fonksiyon, her ızgara noktasında [denklem \(8.3\)](#)'teki Gauss kernel ağırlıklı doğrusal EKK problemini kapalı biçimde çözer: $K_i = K\{(X_i - x)/h\}$, $S_k = \sum_i K_i(X_i - x)^k$ ve $T_k = \sum_i K_i(X_i - x)^k Y_i$ ise $\hat{m}(x) = (S_2 T_0 - S_1 T_1) / (S_0 S_2 - S_1^2)$ olur. Payda, pozitif ağırlık alan en az iki farklı X_i değeri bulunduğunda sıfırdan büyüktür.

8.13.5 Bir nonparametrik makale çıktısını okurken

1. Tahmin edilen nesne koşullu ortalama mı, yoğunluk mı, olasılık mı?
2. Kernel ve yerel polinom derecesi nedir?
3. Bant genişliği nasıl seçilmiştir?
4. Veri bağımlıysa CV/standart hata kümeyi koruyor mu?
5. Grafikte sınır bölgelerinde güven aralıkları genişliyor mu?
6. Farklı makul h değerleri ana ekonomik sonucu değiştiriyor mu?
7. Çok boyutlu X kullanılıyorsa boyutluluk laneti nasıl yönetiliyor?

Tez uygulaması için temel raporlama cümlesi

“Yerel doğrusal tahminde ana bant genişliği küme-silmeli çapraz doğrulama ile seçilmiş, ayrıca daha geniş bir bantla duyarlılık analizi yapılmıştır. Sonuç fonksiyonunun genel şekli korunmakla birlikte üst destek bölgesindeki tahminler bant genişliğine daha duyarlıdır.”

8.14 Temel Sonuçlar**Temel sonuç**

1. Parametrik olmayan regresyonun hedefi hâlâ koşullu ortalama olabilir; değişen şey fonksiyonel biçim kısıtının gücüdür.
2. Kernel yöntemlerinde en kritik ayar çoğu zaman bant genişliğidir.
3. Yerel doğrusal regresyon, hedef nokta çevresinde ağırlıklı OLS uygular ve sınır davranışı bakımından Nadaraya–Watson’a göre avantajlıdır.
4. Çapraz doğrulama, düzgünleştirme derecesini dışarıda bırakılan gözlemlerin tahmin hatasına göre seçer.
5. Polinom ve spline yöntemleri seri regresyonunun örnekleridir; spline’lar yüksek dereceli küresel polinomlardan daha yerel esneklik sağlayabilir.
6. Çok sayıda değişken tamamen parametrik olmayan tahmini zorlaştırır; bu boyutluluk lanetidir.
7. Kısmen doğrusal model, temel katsayıyı parametrik tutup diğer etkileri esnekleştirir ve artıkklaştırma (partialling-out) mantığına dayanır.
8. Esnek fonksiyonel biçim nedensel tanımlamanın yerine geçmez.

8.15 Bölüm Sonu Egzersizleri**Egzersiz 8.1: Kernel ağırlıkları**

Gauss kernel benzeri ağırlık $K(u) = \exp(-u^2/2)$ olsun. $x = 10$ ve $h = 2$ için $X_i = 10, 12$ ve 14 gözlemlerinin normalize edilmemiş ağırlıklarını hesaplayınız. Hangi gözlem en fazla bilgi taşır?

Egzersiz 8.2: Nadaraya–Watson hesabı

Bir hedef noktada üç gözlemin kernel ağırlıkları sırasıyla 0,5, 0,3, 0,2 ve Y değerleri 10, 20, 30 olsun. $\hat{m}_{NW}(x)$ değerini bulunuz.

Egzersiz 8.3: Yerel doğrusal amaç fonksiyonu

Denklem (8.3)'ü yazınız ve a ile b 'nin ekonomik/istatistiksel rollerini açıklayınız. Neden $\hat{m}_{LL}(x) = \hat{a}(x)$ olur?

Egzersiz 8.4: Bant genişliği

Aynı veri setinde $h = 1$, $h = 5$ ve $h = 20$ ile yerel doğrusal tahmin yapıldığını düşününüz. Hangi durumda eğrinin en dalgalı, hangi durumda en düzgün olmasını beklersiniz? Yanlılık ve varyans açısından yorumlayınız.

Egzersiz 8.5: MSE sezgisi

$MSE(h) = 0,1h^4 + 1/(100h)$ olsun. $h = 0,3$, $0,5$ ve $0,8$ için MSE'yi hesaplayınız ve bu üç aday arasından en küçüğünü seçiniz.

Egzersiz 8.6: Çapraz doğrulama

Üç aday bant için $CV(2) = 14,2$, $CV(4) = 10,8$ ve $CV(8) = 12,5$ bulunmuştur. Hangi bant seçilir? Bu karar " $h = 4$ gerçek fonksiyonu kesin olarak bilir" anlamına gelir mi?

Egzersiz 8.7: Spline bazı

Denklem (8.9)'da tek düğüm $\kappa = 50$ olsun. $x = 40$ ve $x = 60$ için $(x - 50)_+^3$ terimini hesaplayınız. Bu baz fonksiyonun neden düğümün solunda etkisiz olduğunu açıklayınız.

Egzersiz 8.8: Model karşılaştırması

Tablo 8.1'e göre 90. yüzdelikte doğrusal ve yerel doğrusal tahmin arasındaki farkı hesaplayınız. Bu farkı "yerel doğrusala göre doğrusal model yanlıdır" şeklinde kesin bir sonuç olarak yorumlamak neden doğru değildir?

Egzersiz 8.9: Boyutluluk laneti

Her değişkende hedef noktaya yakın aralık desteğin yüzde 25'ini kapsasın. Bir, üç ve altı boyutta bütün koordinatlarda aynı anda bu yerel kutuda bulunma oranını $0,25^d$ ile hesaplayınız.

Egzersiz 8.10: Kısmen doğrusal modelde artıktıştırma

$Y = D\theta + g(X) + e$ modelinde $\hat{m}_Y(X)$ ve $\hat{m}_D(X)$ tahmin edildikten sonra hangi iki artık oluşturulur? Son aşamada hangi regresyon tahmin edilir?

Egzersiz 8.11: Esneklik ve nedensellik

Bir araştırmacı eğitim ile ücret arasında kernel regresyonu tahmin etmiş ve çok düzgün bir artan eğri bulmuştur. "Kernel parametrik olmadığı için bu eğri eğitimin nedensel getirisiidir" sonucunu değerlendiriniz.

Egzersiz 8.12: Araştırma tasarımı

Bir işletme müşteri memnuniyetinin bekleme süresiyle ilişkisini incelemektedir. Doğrusal, kübik polinom, yerel doğrusal ve spline modellerini karşılaştırmak için kısa bir analiz planı yazınız. Model seçimini yalnız örneklem içi R^2 'ye dayandırmamanızın nedenini belirtiniz.

Regresyon Süreksizliği Tasarımı (RDD)

Bu bölümün amacı

Bu bölümün sonunda keskin (sharp) ve bulanık (fuzzy) regresyon süreksizliği tasarımlarını ayırabilecek; eşik değişkeni (running variable), eşik (cut-off) ve tedavi göstergesini tanımlayabilecek; süreklilik varsayımı altında eşikteki yerel ortalama tedavi etkisinin neden bir sıçrama ile tanımlandığını matematiksel olarak gösterebilecek; yerel doğrusal RDD tahminini kurabilecek; bant genişliği seçiminin yanlılık–varyans dengesini açıklayabilecek; kovaryatların rolünü doğru yorumlayabilecek; yoğunluk/manipülasyon kontrollerinin neyi sınıadığını değerlendirebilecek; bulanık RDD’deki yerel Wald oranını türetebilecek ve bir RDD uygulamasını grafik, tahmin ve duyarlılık analiziyle raporlayabileceksiniz.

Bağlantı

Bölüm 8’de yerel doğrusal regresyonun bir hedef nokta çevresinde ağırlıklı OLS uyguladığını gördük. RDD bu aracı nedensel tanımlama problemiyle birleştirir. Eşik çevresindeki gözlemler birbirine benzer kabul edilebiliyorsa, politika kuralının yarattığı tedavi sıçraması karşı-olguşal karşılaştırma sağlar. Hansen’in Bölüm 21’i bu bölümün temel kaynağıdır (Hansen, 2021).

Bu bölümün ek sembolleri

X koşu değişkeni, c eşik, $D = 1\{X \geq c\}$ tedavi göstergesidir. Y_1, Y_0 potansiyel sonuçlardır. Hansen §21.2 hedef etkiyi $\theta(c) = E[Y_1 - Y_0 \mid X = c]$ ile gösterir. Yerel regresyonlarda θ , eşikteki $\theta(c)$ hedefinin kısa adıdır. $R_i = X_i - c$ merkezlenmiş koşu değişkeni; $h > 0$ bant genişliğidir. Bulanık tasarımda θ_{FRD} eşikte tedavi kararı değişenlerin yerel ortalama etkisini gösterir.

9.1 Bir Eşik Neden Nedensel Bilgi Üretebilir?

Bir bursun yalnız sınav puanı 70 ve üzerindeki öğrencilere verildiğini düşünelim. 69,9 puan alan öğrenci burs alamazken 70,1 puan alan öğrenci burs alır. Bu iki öğrenci sınav başarısı bakımından çok benzerdir; fakat politika kuralı tedavi durumunu keskin biçimde değiştirir.

RDD’nin temel fikri şudur: sonuç değişkeninin tedavi olmasa nasıl değişeceği eşik çevresinde

düzgün ise, gözlenen sonuçtaki ani sıçrama tedaviye atfedilebilir.

Running variable ve cut-off

Tedaviyi belirleyen sürekli değişkene **eşik değişkeni (running variable)** denir ve X ile gösterilir. Politika eşiği c olsun. Sharp RDD'de tedavi

$$D = 1\{X \geq c\}$$

şeklinde tamamen eşik tarafından belirlenir.

RDD'nin gücü, tedavi atamasının belirli bir eşikte mekanik veya en azından keskin biçimde değişmesine dayanır. Eşiğin hemen solundaki ve sağındaki birimler, running variable bakımından birbirine çok yakındır; fakat tedavi alma durumları farklıdır. Eğer tedavi yokken ve tedavi altındaki potansiyel sonuçların koşullu ortalamaları eşik çevresinde düzgün değişiyorsa, gözlenen sonuçta tam eşikte oluşan sıçrama başka düzgün süreçlerle açıklanamaz ve tedavinin yerel etkisini tanımlar.

Bu argüman bütün örneklemin tedavi ve kontrol gruplarını karşılaştırmaz. Örneğin burs puanı 70 olan öğrencilere program veriliyorsa, 20 puanlı ve 90 puanlı öğrencileri karşılaştırmak güçlü seçim farkları içerir. RDD esas olarak 69,9 ile 70,1 gibi eşığe çok yakın gözlemlerden bilgi alır. Bu yerellik hem tasarımın gücü hem de dış geçerlilik sınırındır.

9.2 Potansiyel Sonuçlarla Sharp RDD

Her birim için tedavi yokken sonuç Y_0 , tedavi varken sonuç Y_1 olsun. Gözlenen sonuç

$$Y = (1 - D)Y_0 + DY_1 = Y_0 + D(Y_1 - Y_0) \quad (9.1)$$

şeklindedir. Bireysel tedavi etkisi

$$\theta = Y_1 - Y_0$$

ve eşik değişkenine koşullu ortalama tedavi etkisi

$$\theta(x) = E[Y_1 - Y_0 \mid X = x]$$

olsun. RDD'nin temel hedefi eşikteki yerel etkidir:

$$\theta(c) = E[Y_1 - Y_0 \mid X = c]. \quad (9.2)$$

Tanımlayalım:

$$m_0(x) = E[Y_0 \mid X = x], \quad m_1(x) = E[Y_1 \mid X = x].$$

Sharp tasarımda $x < c$ için yalnız Y_0 , $x \geq c$ için yalnız Y_1 gözlenir. Dolayısıyla gözlenen koşullu ortalama

$$m(x) = E[Y \mid X = x] = \begin{cases} m_0(x), & x < c, \\ m_1(x), & x \geq c. \end{cases} \quad (9.3)$$

Eğer $m_0(x)$ ve $m_1(x)$ eşikte sürekli ise

$$\lim_{x \uparrow c} m(x) = m_0(c), \quad \lim_{x \downarrow c} m(x) = m_1(c),$$

ve dolayısıyla

$$\theta(c) = \lim_{x \downarrow c} E[Y | X = x] - \lim_{x \uparrow c} E[Y | X = x] \quad (9.4)$$

elde edilir. Hansen’in sunduğu temel RDD tanımlama sonucu budur (Hansen, 2021).

RDD’nin tanımlama fikri

Nedensel etki, eşikte gözlenen sonuç ortalamasının sağ ve sol limitleri arasındaki sıçramadır. Kritik varsayım, tedavi olmasaydı ve tedavi olsaydı potansiyel sonuçların koşullu ortalamalarının eşik değişkeni boyunca eşikte düzgün davranmasıdır.

Bu türetimde dikkat edilmesi gereken nokta, RDD’nin nedensel gücünün seçilen regresyon polinomundan değil limit/süreklilik argümanından gelmesidir. Denklem (9.4) herhangi bir fonksiyonel biçim varsayımı içermez; yalnız m_0 ve m_1 ’in eşikte sürekli olmasını ister. Yerel doğrusal regresyon, spline veya polinom bu iki limiti *tahmin etmek* için kullanılan araçlardır; tanımlamayı üreten şey değildirler.

Sembol uyarısı

Bu bölümde eşikteki yerel nedensel etki tutarlı biçimde $\theta(c)$ ile gösterilir. Uygulamalı RDD literatüründe aynı büyüklük sık sık θ ile yazılır ve tahmin edicisi $\hat{\theta}$ olarak raporlanır. Bölümün ilerleyen kısımlarında regresyon gösteriminde θ katsayısı kullanıldığında bu katsayı $\theta(c)$ ’yi temsil eder; $\hat{\theta}$ ise $\theta(c)$ ’nin örneklem tahmin edicisidir.

9.3 Süreklilik Varsayımının İçeriği

Süreklilik varsayımı “ X ile Y arasında ilişki yoktur” demez. Tam tersine Y , X ile güçlü biçimde değişebilir. Gereken, tedavi dışında sonucu tam eşikte sıçratacak başka bir mekanizma olmamasıdır.

Örneğin burs eşiği 70 ise, aynı 70 puanda başka bir destek programı da başlıyorsa gözlenen sıçrama iki politikanın toplam etkisini yansıtabilir. Ya da bireyler puanlarını eşiğin üzerine hassas biçimde manipüle edebiliyorsa eşik sağındaki ve solundaki bireyler karşılaştırılabilir olmayabilir.

Sık yapılan hata

RDD “eşik etrafındaki gözlemler benziyor” diye otomatik geçerli olmaz. Politika kuralı, manipülasyon imkânı, diğer eşzamanlı eşikler ve sonucu belirleyen kurumlar araştırma tasarımının parçasıdır. Grafik tek başına tanımlama varsayımını kanıtlamaz.

Bu varsayım doğrudan test edilemez, çünkü aynı bireyin iki potansiyel sonucu gözlenmez. Ancak tedavi öncesi kovaryatların eşikte sıçramaması, eşik değişkeninin yoğunluğunda manipülasyon izi bulunmaması ve başka politikaların aynı eşikte devreye girmemesi tasarımın inandırıcılığını destekleyen dolaylı kanıtlardır. RDD bu nedenle yalnız bir regresyon formülü değil, kurumsal eşik bilgisinin ekonometrik tanımlamaya dönüştüğü bir araştırma tasarımıdır.

9.4 Yerel Doğrusal RDD Tahmini

Eşik etrafında koşullu ortalamayı iki ayrı yerel doğruyla tahmin edebiliriz. Merkezlenmiş eşik değişkeni

$$R_i = X_i - c$$

ve tedavi göstergesi

$$D_i = 1\{R_i \geq 0\}$$

olsun. Eşik çevresindeki yerel örnekleme (pencere aşağıda kernel ve bant genişliği h ile tanımlanır) şu regresyon tahmin edilebilir:

$$Y_i = \alpha + \theta D_i + \beta_1 R_i + \beta_2 (D_i R_i) + u_i. \quad (9.5)$$

Eşik solunda $D_i = 0$ olduğundan

$$E[Y_i \mid R_i, D_i = 0] \approx \alpha + \beta_1 R_i,$$

eşik sağında ise

$$E[Y_i \mid R_i, D_i = 1] \approx (\alpha + \theta) + (\beta_1 + \beta_2) R_i.$$

$R = 0$ noktasında iki doğru arasındaki fark

$$(\alpha + \theta) - \alpha = \theta$$

olduğundan $\hat{\theta}$ RDD etkisinin tahminidir.

Burada β_1 sol eğim, $\beta_1 + \beta_2$ ise sağ eğimdir. Aynı eğimi iki tarafa zorlamak ($\beta_2 = 0$) gereksiz bir kısıttır; eşik iki tarafındaki fonksiyonun türevi farklıysa bu kısıt sıçrama tahminini de bozar.

Dikdörtgen kernel kullanıldığında pencere içindeki gözlemler eşit ağırlık alır. Üçgen kernelde ise eşikten uzaklaştıkça ağırlık doğrusal biçimde azalır. [Hansen \(2021\)](#) kernelleri varyansı 1 olacak biçimde ölçekler; böylece h her kernelde çekirdeğin standart sapmasıdır ve farklı kernellerde aynı h aynı yerelliği ifade eder. Birim varyanslı üçgen kernel

$$K(u) = \frac{1}{\sqrt{6}} \left(1 - \frac{|u|}{\sqrt{6}}\right) 1\{|u| \leq \sqrt{6}\} \quad (9.6)$$

olup gözlem i 'nin ağırlığı $K(R_i/h)$ 'dir. Bu durumda [denklem \(9.5\)](#) ağırlıklı en küçük kareler ile tahmin edilir; eşik en yakın gözlemler en yüksek ağırlığı alır ve ağırlık eşikten $h\sqrt{6}$ uzaklıkta sıfıra iner. Birim varyanslı dikdörtgen kernel ise $|u| \leq \sqrt{3}$ aralığında sabittir; penceresi $\pm h\sqrt{3}$ 'tür.

Global yüksek dereceli polinom kullanmak yerine yerel yaklaşımın tercih edilmesinin nedeni, uzak gözlemlerin eşik hemen çevresindeki şekli belirlemesini önlemektir. Global polinomlar uçlarda salınım gösterebilir ve spesifikasyona çok duyarlı sıçramalar üretebilir ([Gelman ve Imbens, 2019](#)). Bu nedenle modern RDD uygulamasında yerel doğrusal veya yerel karesel tahmin ve veri-temelli bant genişliği daha güvenilir varsayılanlardır.

9.5 Bant Genişliği RDD’de Neyi Değiştirir?

h yalnız teknik bir tuning parameter değildir; hangi gözlemlerin yerel karşılaştırmaya esas olacağını belirler.

- Küçük h , eşik çevresindeki daha karşılaştırılabilir gözlemlere yoğunlaşır; fonksiyonel biçim yanlılığını azaltabilir fakat örneklem küçülür ve standart hata büyür.
- Büyük h , daha fazla gözlem kullanır ve varyansı azaltabilir; fakat eşikten uzakta koşullu ortalamanın doğrusal yaklaşımı zayıflayabilir.

Bu nedenle RDD sonucu tek bir keyfi bant genişliğine dayandırılmamalıdır. Farklı bant genişliklerinde katsayının ve güven aralığının nasıl değiştiğini göstermek, RDD sonuçlarının kırılganlığını değerlendirmede temel duyarlılık kontrolüdür. Hansen, veri-temelli bant genişliği kurallarını ve birkaç makul bantta duyarlılık raporlamayı birlikte önerir (Hansen, 2021).

Bant genişliği seçimi sonucu görüp istenen anlamlılığa göre yapılmamalıdır. Ana bant genişliği önceden tanımlı veya veri-temelli bir kriterle seçilmeli; daha dar ve daha geniş makul aralıklar sağlamlık analizi olarak raporlanmalıdır. Aynı ilke kernel ve polinom derecesi için de geçerlidir.

9.6 Nokta Tahmini ile Çıkarım İçin Bant Genişliği Aynı Problem Değildir

Yerel doğrusal RDD’de bant genişliği yalnız nokta tahmininin ortalama karesel hatasını değil, güven aralığının kapsama davranışını da etkiler. Standart düzgünlük koşulları altında eşikteki yerel doğrusal sıçrama tahmini için temel mertebeler

$$\text{Bias}(\hat{\theta}) = O(h^2), \quad \text{var}(\hat{\theta}) = O\left(\frac{1}{nh}\right) \quad (9.7)$$

şeklinde. Dolayısıyla standart hata yaklaşık $O((nh)^{-1/2})$ mertebesindedir. Yanlılığın standart hataya göre göreceli büyüklüğü

$$\frac{\text{Bias}(\hat{\theta})}{\text{se}(\hat{\theta})} = O(\sqrt{nh} h^2) = O(\sqrt{nh^5})$$

olur.

Nokta tahmininde AMSE’yi küçülten bant genişliği yaklaşık $n^{-1/5}$ mertebesindedir. Bu seçimde yanlılık ile standart hata aynı mertebede kalabildiği için, tahmini doğrudan merkez alan klasik normal güven aralığı yanlılığı ihmal etmiş olabilir. Hansen bu nedenle çıkarımda iki pratik önlem vurgular: eşik iki tarafında ortak bant genişliği kullanmak ve AMSE-optimal banttan daha küçük bir bant seçerek **undersmoothing** uygulamak (Hansen, 2021). Daha küçük bant yanlılığı azaltır; bunun bedeli daha büyük standart hatadır.

RDD’de çıkarımın temel mesajı

“En iyi nokta tahmini bant genişliği” ile “yanlılığı ihmal edilebilir kılan çıkarım bant genişliği” aynı kavram değildir. Güven aralığı raporlanırken yalnız varyans değil, düzgünleştirme yanlılığı da düşünülmelidir.

Güncel genişletme: yanlışlık düzeltilmiş RDD çıkarımı

Hansen'in anlatımı çıkarım yanlışlığını özellikle daha küçük bant genişliği (undersmoothing) üzerinden açıklar. Güncel RDD literatüründe bunun yanında yanlışlığı açıkça tahmin edip güven aralığını buna göre düzelteren *robust bias-corrected* prosedürler de yaygın olarak kullanılmaktadır; bkz. [Calonico et al. \(2014\)](#). Bu yaklaşım Hansen'deki temel yanlışlık–varyans probleminin modern bir uzantısıdır.

Pratik sonuç şudur: yazılımın otomatik bant genişliği seçeneğinin nokta tahminini mi yoksa çıkarımı mı hedeflediği kontrol edilmelidir. Tezde kullanılan seçim kuralı ve bunun hangi amaca göre optimal olduğu açıkça yazılmalıdır.

9.7 Hansen'in Head Start Uygulaması

Hansen, Ludwig ve Miller'in Head Start çalışmasını RDD örneği olarak kullanır. Birim ABD ilçesidir. Running variable 1960 yoksulluk oranı, eşik $c = 59,1984$ ve sonuç 1973–1983 döneminde 5–9 yaş için Head Start ile ilişkili nedenlerden ölüm oranıdır. Federal hükümet 1965'te en yoksul 300 ilçeye Head Start başvurusu hazırlama desteği vermiştir ([Hansen, 2021](#)).

Hansen'in temel yerel tahmini üçgen kernel ve $h = 8$ ile eşikte $-1,51$ büyüklüğünde, $0,71$ standart hatalı bir düşüştür: eşiğin solunda tahmini ölüm oranı $3,31$, sağında $1,80$ 'dir. Birim varyanslı üçgen kernelde $h = 8$, eşik $8\sqrt{6} \simeq 19,6$ puandan yakın 1.041 ilçeye pozitif ağırlık verir. Aynı bant genişliğinin dikdörtgen kernel karşılığı $\pm 8\sqrt{3} \simeq \pm 13,86$ puanlık penceredir ([Hansen, 2021](#)); bu penceredeki 757 ilçede D , R ve $D \cdot R$ üzerine basit EKK regresyonu $-1,55$ (SH $0,74$) verir (Hansen'in metni bu pencere için 482 ilçe ve $-2,20$ (SH $1,06$) basar; bu sayılar ± 8 penceresine aittir, bkz. [Bölüm 9.15.3](#)). Bant genişliği aynı ölçekte tanımlandığında iki kernelin birbirine yakın sonuç vermesi, bu uygulamada kernel seçiminin bant genişliğine göre ikinci derecede kaldığıyla uyumludur.

Aşağıdaki şekil, LM2007 verisi üzerinde $h = 8$ üçgen ağırlıklı yerel doğrusal koşullu ortalama tahminlerini ve yaklaşık yüzde 95 güven bantlarını gösterir. Hansen'in önerisi doğrultusunda grafik, binned means yerine doğrudan yerel doğrusal tahmini ve belirsizliğini görünür kılar.


[Şekil 9.1](#)'de eşik sağında tahmini koşullu ortalamanın daha düşük olması negatif bir yerel etkiyle uyumludur. Ancak grafiksel farkın büyüklüğü tek başına standart hata ve bant duyarlılığı hakkında bilgi vermez.

9.8 Bant Genişliği Duyarlılığı: Aynı Veri, Farklı Yerellik

LM2007 verisine üçgen kernelle yerel doğrusal tahmin uygulandığında aşağıdaki duyarlılık tablosu elde edilir. h değerleri Hansen'in ölçeğindedir ([denklem \(9.6\)](#)); n_h pozitif ağırlık alan, yani $|X_i - c| < h\sqrt{6}$ koşulunu sağlayan ilçe sayısıdır. Standart hatalar ağırlıklı regresyonun HC1 standart hatalarıdır; güven aralığı $\hat{\theta} \pm 1,96 \cdot \text{SH}$ 'dir.

Sık yapılan hata

Bant genişliği sayısı kernelin nasıl ölçeklendiğine bağlıdır. Hansen'in h 'si çekirdeğin standart sapmasıdır: üçgen kernelde $\pm h\sqrt{6}$, dikdörtgen kernelde $\pm h\sqrt{3}$ penceresine karşılık gelir ([Hansen, 2021](#)). Birçok yazılım ve kaynak ise h 'yi doğrudan pencerenin yarı genişliği



Şekil 9.1: LM2007 Head Start verisinde yerel doğrusal koşullu ortalama tahminleri ve yüzde 95 güven bantları

olarak kullanır. Aynı “ $h = 8$ ” bu ikinci anlamda okunursa pencere ± 8 ’e daralır ve tahmin $-2,25$ (SH 1,08) olur. Sayıları karşılaştırmadan önce h ’nin hangi ölçekte tanımlandığı kontrol edilmelidir.


Tablo 9.1: Head Start örneğinde bant genişliği duyarlılığı

h	n_h	$\hat{\theta}$	SH	Alt %95	Üst %95
4	565	-2,10	1,01	-4,08	-0,13
6	794	-1,86	0,83	-3,48	-0,24
8	1041	-1,51	0,71	-2,90	-0,11
10	1325	-1,38	0,62	-2,60	-0,15
12	1649	-1,25	0,57	-2,37	-0,12

Tablo ve şekil iki noktayı gösterir. Birincisi, daha dar pencerede tahmin daha negatif fakat daha belirsizdir. İkincisi, geniş bantlarda etki mutlak değerce küçülür ve standart hata azalır. Bu desen “doğru bant en küçük olan” veya “en anlamlı sonucu veren bant doğrudur” gibi mekanik kurallara izin vermez.

Sık yapılan hata

Bant genişliğini sonuç görüldükten sonra yalnız p-değerini küçülten değere göre seçmek spesifikasyon araştırmasıdır. Önceden belirlenmiş veya veri-temelli bir ana bant, ardından makul duyarlılık bantları raporlanmalıdır.



Şekil 9.2: Head Start örneğinde tahmini RDD etkisinin bant genişliğine duyarlılığı

9.9 Kovaryatlar RDD'yi Kurtarır mı?

Eşik çevresindeki önceden belirlenmiş kovaryatlar RDD'ye eklenebilir. Hansen, Head Start uygulamasında siyah nüfus oranı ve kentleşme oranını kullanır ve treatment effect tahmininin çok benzer kaldığını gösterir (Hansen, 2021).

Doğru tasarımı kovaryat eklemenin temel amacı çoğu zaman **hassasiyeti artırmaktır**; tanımlama parametresini değiştirmek değildir. Kötü bir tasarım, çok sayıda kontrol eklenerek otomatik olarak iyi hâle gelmez.

Kovaryatların eşikte kendilerinin sıçramaması da tasarımın makullüğünü destekleyen bir denge kontrolü olarak kullanılabilir. Ancak tek tek anlamsız kovaryat sıçramaları tanımlamanın matematiksel kanıtı değildir.

Geçerli bir sharp RDD'de tedavi tanımlaması kovaryat kontrolüne ihtiyaç duymaz; eşikteki süreklilik argümanı temel tanımlamayı sağlar. Önceden belirlenmiş kovaryatlar hassasiyeti artırabilir ve rassal örnekleme dengesizliklerini azaltabilir. Fakat kovaryat eklemek running variable manipülasyonu, aynı eşikte başka bir politika sıçraması veya potansiyel sonuç süreksizliği gibi temel tasarım ihlallerini düzeltemez.


Kovaryatlar ayrıca tasarım kontrolü olarak değerlidir. Yaş, cinsiyet veya geçmiş başarı gibi tedaviden önce belirlenmiş özelliklerde eşikte sistematik sıçrama görülmesi, birimlerin iki tarafta gerçekten karşılaştırılabilir olup olmadığına dair soru doğurur. Bu tür denge kontrolleri ana sonuç kadar dikkatle sunulmalıdır.

9.10 Manipülasyon ve Running Variable Yoğunluğu

RDD'nin ikna ediciliği, birimlerin eşik etrafındaki konumlarını hassas biçimde kontrol edememesiyle güçlenir. Eğer bireyler tedavi almak için X 'i eşik üzerine yığıbiliyorsa, eşik sağındaki popülasyon sistematik olarak farklı olabilir.

Bu fikir eşik değişkeni yoğunluğuyla incelenebilir. Manipülasyon yoksa $f_X(x)$ yoğunluğunun

eşikte düzgün olması beklenir. Basit ilk kontrol, hiçbir histogram kutusunun eşiği kesmediği dar aralıklı histogramdır.



Şekil 9.3: Head Start verisinde eşik değişkeni için eşik çevresi histogramı

Hansen, Head Start örneğinde ilçelerin 1960 yoksulluk oranını 1965'te tedavi almak için manipüle etmelerinin kurumsal olarak inandırıcı olmadığını belirtir; histogramda da eşik çevresinde belirgin bir yığılma görünmez. Daha formal yoğunluk süreksizliği testleri de uygulanabilir (Hansen, 2021).

Yoğunluk testi neyi söyler?

Eşik değişkeni yoğunluğunda sıçrama bulunması tasarıma karşı ciddi bir uyarı olabilir. Sıçrama bulunmaması ise manipülasyon olmadığıyla uyumludur; fakat diğer tanımlama tehditlerini otomatik olarak dışlamaz.

Bireyler eşik kuralını biliyor ve running variable'ı hassas biçimde ayarlayabiliyorsa eşiğin iki tarafındaki gözlemler seçilmiş olabilir. Örneğin uygunluk puanı başvuranın raporladığı bir değere dayanıyorsa, eşik üstünde olağandışı yığılma tedaviye erişmek için manipülasyon işareti olabilir. Bu durumda sağ ve sol limitlerdeki birimler yalnız çok küçük X farkıyla ayrılmayabilir; gözlenmeyen motivasyon veya bilgi bakımından da sistematik farklılaşabilir.

Yoğunluk grafiği bu nedenle bir görsel tanıdır. Histogram kutuları eşiği kesmeyecek biçimde kurulmalı ve mümkünse formal yoğunluk süreksizliği testiyle desteklenmelidir. Manipülasyon testinin reddetmemesi tasarımın geçerli olduğunu kanıtlamaz; yalnız belirli bir ihlal türüne karşı kanıt bulamadığımızı gösterir (Hansen, 2021).

9.11 Grafikselle Raporlama

Hansen'in önerdiği temel RDD grafiğinde ana nesne, eşik iki tarafında ayrı tahmin edilen **yerel doğrusal koşullu ortalama** ve bu tahminin **güven bantlarıdır** (Hansen, 2021). İyi bir grafik en az şu unsurları görünür kılar:

1. yatay ekseninde eşik değişkeni ve açık biçimde işaretlenmiş eşik,
2. eşik solunda ve sağında ayrı yerel doğrusal veya düşük dereceli yerel polinom uyumları,
3. uyumların belirsizliğini gösteren güven bantları,
4. kullanılan kernel, pencere/bant genişliği ve mümkünse grafiğin gösterdiği destek aralığı.

Hansen, yerel doğrusal tahmin ve güven bantlarının yerine *binned means* (kutulanmış ortalamalar) çizilmesini özellikle eleştirir: bunlar ham veri değildir ve dikdörtgen kernel kullanan kaba bir parametrik olmayan tahmin ediciye karşılık gelir. Ham gözlemler okunabilirlik elveriyorsa ikincil bir katman olarak gösterilebilir; fakat ana görsel kanıt yerel tahmin ve belirsizlik olmalıdır (Hansen, 2021).

Yüksek dereceli küresel polinomları bütün destek boyunca çizmek RDD için özellikle risklidir. Eşik etkisi yerel bir tahmin hedefi olduğundan yerel doğrusal veya düşük dereceli yerel polinomlar daha doğal başlangıç noktasıdır (Gelman ve Imbens, 2019).

RDD grafiği yalnız dekoratif bir şekil değildir; model spesifikasyonunun temel tanısıdır. İyi bir grafik running variable'ın her iki tarafındaki veri desteğini, yerel eğimleri, olası başka kırılmaları ve eşğin gerçekten bir sıçrama üretip üretmediğini görmeyi sağlar. Ana vurgu yerel doğrusal veya uygun nonparametrik uyum ve belirsizlik bantları üzerinde olmalıdır. Binned özetler kullanılıyorsa bin seçiminin görünümü değiştirebileceği açık olmalı ve ana tahminin yerine geçirilmemelidir.

Grafikte x eksenini gerçek running variable birimini, y eksenini sonuç birimini ve dikey çizgi eşik değerini açık göstermelidir. Aynı şekilde first-stage grafiği fuzzy RDD'de tedavi olasılığının eşığe tepkisini göstermelidir. Okuyucu yalnız tabloya bakmadan tasarımın temel discontinuity'sini değerlendirebilmelidir.

9.12 Bulanık (Fuzzy) RDD

Gerçek politikalarda eşik tedaviyi yüzde 0'dan yüzde 100'e taşıyabilir. Örneğin burs hakkı kazanmak burs alma olasılığını artırır fakat herkes bursu kullanmaz. Bu durumda gerçek tedavi D eşikte yalnız olasılıksal olarak sıçrar.

Tanımlayalım:

$$p(x) = E[D \mid X = x].$$

Bulanık tasarımda

$$\Delta_D = \lim_{x \downarrow c} p(x) - \lim_{x \uparrow c} p(x) \neq 0$$

olmalıdır. Sonuçtaki sıçrama

$$\Delta_Y = \lim_{x \downarrow c} E[Y \mid X = x] - \lim_{x \uparrow c} E[Y \mid X = x]$$

olsun. Uygun tanımlama varsayımları altında bulanık RDD estimand'ı yerel Wald oranıdır:

$$\theta_{FRD} = \frac{\Delta_Y}{\Delta_D}. \quad (9.8)$$

Bu yapı Bölüm 4'teki IV mantığıyla aynıdır. Eşığı geçme göstergesi tedavi için araç rolü görür. Payda "ilk aşama" sıçramasıdır; pay ise indirgenmiş-biçim (reduced-form) sonuç sıçramasıdır.

Hansen'in sunumunda oran kısa bir türetimle elde edilir (Hansen, 2021). m_0 ve m_1 eşikte sürekli olsun ve eşik yakınında ($X = x$ koşulunda) D , bireysel etki $\theta = Y_1 - Y_0$ 'dan bağımsız olsun. Denklem (9.1)'e göre $Y = Y_0 + D\theta$ olduğundan

$$E[Y | X = x] = m_0(x) + E[D\theta | X = x] = m_0(x) + p(x)\theta(x)$$

olur. m_0 ve $\theta(x) = m_1(x) - m_0(x)$ eşikte sürekli olduğundan sağ ve sol limitler yalnız $p(x)$ üzerinden ayrışır:

$$\Delta_Y = \theta(c) \left[\lim_{x \downarrow c} p(x) - \lim_{x \uparrow c} p(x) \right] = \theta(c) \Delta_D \quad \implies \quad \theta(c) = \frac{\Delta_Y}{\Delta_D} = \theta_{FRD} \quad (\Delta_D \neq 0).$$

Bulanık RDD'de hangi yerel etki tanımlanıyor?

Hansen'in Theorem 21.2 sunumunda, eşik yakınında tedavi göstergesinin bireysel tedavi etkisinden bağımsızlığı gibi güçlü bir koşul altında yerel Wald oranı $E[Y_1 - Y_0 | X = c]$ koşullu ortalama tedavi etkisini tanımlar (Hansen, 2021). Daha genel IV/LATE çerçevesinde ise $\Delta_D \neq 0$, monotonluk (defier yoktur: eşiği geçmek hiçbir birimi tedaviden çıkarmaz), dışlama (eşiği geçmek sonucu yalnız tedavi üzerinden etkiler) ve uygun süreklilik koşulları altında aynı Wald tipi oran, eşik civarında tedavi durumunu eşik nedeniyle değiştiren *uyucular* (compliers) için yerel ortalama tedavi etkisi olarak yorumlanır (Imbens ve Angrist, 1994; Hahn et al., 2001). Bu iki yorumun varsayımları aynı değildir. Uygulamada araştırmacı hangi tanımlama kümesini kullandığını açıkça belirtmelidir.

Sık yapılan hata

Bulanık RDD'de paydadaki tedavi sıçraması küçükse oran son derece belirsiz olabilir. Bu, zayıf araç problemine benzer. Sonuç grafiği kadar tedavi olasılığı grafiği de raporlanmalıdır.

Paydanın küçük olması, bulanık RDD'nin zayıf ilk aşama problemidir. Bu durumda oran tahmini çok oynaklaşır ve Bölüm 2.8'de gördüğümüz gibi delta yöntemi standart hatası yanıltıcı olabilir; klasik normal çıkarım güvenilir hâle gelir. Bulanık RDD raporu bu nedenle sonuç grafiğinin yanında tedavi olasılığı grafiğini de göstermelidir.

9.13 Plasebo ve Sağlamlık Kontrolleri

RDD uygulamasında tek bir ana tahmin yeterli değildir. Araştırma tasarımı şu kontrollerle desteklenebilir:

- farklı makul bant genişlikleri,
- önceden belirlenmiş kovaryatlarda sıçrama kontrolü,
- tedaviden önce ölçülmüş sonuçlarda plasebo sıçrama kontrolü,
- tedavi ile ilgisiz sonuçlarda kontrol,
- eşik değişkeni yoğunluğu,
- kurum tarafından tanımlanmamış sahte eşiklerde plasebo kontrolleri.

Hansen'in Head Start egzersizleri de yaralanmaya bağlı ölüm, yetişkin ölümü ve program öncesi ölüm gibi plasebo sonuçları incelemeyi önerir (Hansen, 2021).

Plasebo eşikleri, tedavinin gerçekte değişmediği X noktalarında yapay RDD tahminleri kurar. Çok sayıda sahte eşikte benzer sıçramalar bulunması, sonuç fonksiyonunun doğal kırılmalılığı veya yanlış fonksiyonel biçim konusunda uyarı olabilir. Benzer biçimde tedaviden önce belirlenmiş sonuçlarda eşik etkisi görülmemesi beklenir.

Sağlamlık analizleri ana tanımlamayı değiştirmemelidir. Farklı makul bant genişlikleri, kernel seçenekleri, yerel polinom derecesi ve kovaryat eklemeleri aynı temel sonucu ne ölçüde destekliyor sorusu sorulur. Çok sayıda spesifikasyondan yalnız anlamlı olanı seçmek RDD'nin tasarım avantajını zedeler.

9.14 RDD'nin Nedensel Yorumunun Sınırı

RDD etkisi genellikle **yereldir**. $\theta(c)$ eşikteki birimler için ortalama tedavi etkisidir. Eşiğin çok uzağındaki birimler için aynı etkiyi varsaymak ek homojenlik/taşınabilirlik varsayımları gerektirir.

Bu nedenle “program mortaliteyi 1,5 azalttı” ifadesinden daha doğru raporlama “eşik civarındaki ilçeler için program desteğinin yerel etkisi yaklaşık 1,5 birimlik azalma olarak tahmin edildi” biçimindedir.

Sharp RDD'nin doğal estimand'ı eşikteki yerel ortalama tedavi etkisidir. Bu sonuç, running variable'ın çok farklı değerlerindeki bireylere otomatik olarak genellenemez. Örneğin uygunluk eşiğinin hemen çevresindeki firmalar için bulunan teşvik etkisi çok küçük veya çok büyük firmalar için farklı olabilir. Dış geçerlilik için etki heterojenliği hakkında ek bilgi veya model gerekir.

Bu sınırlılık bir zayıflık olmaktan çok tasarımın dürüst tanımıdır. RDD güçlü iç geçerlilik karşılığında yerel bir parametre üretir. Tez yazımında “programın etkisi” yerine “eşik civarındaki birimler için programın yerel etkisi” ifadesi daha doğru olur.

9.15 Ampirik Uygulama Laboratuvarı: RDD Sonuç Tablosunu Tasarım Olarak Okumak

Head Start örneğinin veri ve yerel tahmin ayrıntıları bu bölümde daha önce işlendi. Burada aynı uygulamayı bir “makale okuma laboratuvarı” olarak yeniden ele alacağız. Amaç, RDD çıktısında yalnız sıçrama katsayısını değil, tasarım kararlarının tamamını birlikte okuyabilmektir. Hansen'in kullandığı LM2007 veri setinde eşik değişkeni 1960 yoksulluk oranı, sonuç değişkeni ise Head Start ile ilişkili 5–9 yaş ölüm oranıdır (Hansen, 2021).

9.15.1 Adım 1: Katsayıdan önce tasarım satırlarını okuyun

Bir RDD tablosu aşağıdaki bilgileri vermiyorsa katsayının tek başına değerlendirilmesi zordur:

- eşik c ,
- running variable'ın tanımı ve yönü,
- sharp mı fuzzy mi olduğu,
- kernel türü,

- yerel polinom derecesi,
- ana bant genişliği ve etkin örneklem büyüklüğü,
- standart hata/bias correction yöntemi.

Head Start uygulamasında eşik $c = 59,1984$ 'tür. Hansen'in LM2007 dosyasında 2.783 ilçe vardır; bunların 294'ü eşğin sağındadır. Eşğin sağı, 1960 yoksulluk oranı en yüksek olan ve 1965'te başvuru desteği alan 300 ilçeden sonuç verisi eksik olmayanlardır. "Eşğin sağındaki katsayı negatiftir" demek tek başına yeterli değildir; sağ tarafın hangi tedavi durumunu temsil ettiği kurumsal kuraldan okunmalıdır.

9.15.2 Adım 2: Bant genişliği tablosunu sonuç avcılığı için değil duyarlılık için kullanmak

Üçgen kernelle yerel doğrusal uygulamada (h Hansen'in ölçeğinde, pencere $\pm h\sqrt{6}$) şu desen görülmektedir:

Tablo 9.2: LM2007 uygulaması: bant genişliği duyarlılığı

h	n_h	$\hat{\tau}$	SH	Alt %95	Üst %95
4	565	-2,10	1,01	-4,08	-0,13
6	794	-1,86	0,83	-3,48	-0,24
8	1041	-1,51	0,71	-2,90	-0,11
10	1325	-1,38	0,62	-2,60	-0,15
12	1649	-1,25	0,57	-2,37	-0,12

Bant genişliği arttıkça etkin örneklem büyümekte, standart hata düşmekte ve tahmin mutlak değerce küçülmektedir. Bu tablo " $h = 4$ daha büyük etki verdiği için tercih edilir" veya " $h = 12$ en küçük standart hataya sahip olduğu için doğrudur" biçiminde okunmamalıdır. Her satır farklı bir yerellik-varyans dengesi kurar.

Ana sonuç, makul bant aralığında işaretin negatif kalmasıdır; fakat nokta tahmininin büyüklüğü yerellik kararına duyarlıdır. Tezde bu tür bir desen bulunursa ana bant veri-temelli/önceden tanımlı prosedürle seçilmeli ve tablo duyarlılık analizi olarak sunulmalıdır.

9.15.3 Adım 3: Hansen'in tahminini yeniden üretmek: bant genişliği ölçeği

Hansen'in kitap uygulamasında tercih edilen yerel tahmin $-1,51$ (SH 0,71) değeridir (Hansen, 2021). Tablo 9.2'deki $h = 8$ satırı bu sayıyı yeniden üretir; eşğin solunda tahmini ölüm oranı 3,31, sağında 1,80'dir. Aynı bant genişliğinin dikdörtgen kernel karşılığı olan $\pm 13,86$ puanlık penceredeki basit EKK regresyonu 757 ilçeyle $-1,55$ (SH 0,74) verir. Hansen'in metni (Bölüm 21.8) bu pencere için 482 ilçe ve $-2,20$ (SH 1,06) raporlar; bu sayılar, aynı regresyon ± 8 penceresinde (482 ilçe) tahmin edildiğinde birebir elde edilir. Kitap $\pm 13,8$ penceresini yazar, fakat basılı sayılar ± 8 penceresine aittir; fark büyük olasılıkla aşağıdaki ölçek karışıklığından kaynaklanır.

Aynı " $h = 8$ " pencerenin yarı genişliği olarak okunursa (ölçeklenmemiş üçgen kernel) pencere ± 8 'e daralır, 482 ilçe kalır ve tahmin $-2,25$ (SH 1,08) olur. Bu fark bir yöntem farkı değil, ölçek farkıdır: yazılımlar ve makaleler bant genişliğini farklı ölçeklerde raporlayabilir. Replikasyonda sayılar tutmadığında önce bu tür tanım farkları aranmalıdır.

Uygulamalı bir makalede “yazılım bana farklı katsayı verdi” durumunda şu sırayla kontrol yapılmalıdır:

1. analiz örnekleme aynı mı,
2. running variable aynı şekilde merkezlenmiş mi,
3. eşik aynı mı,
4. kernel aynı mı,
5. bant genişliği aynı ölçekte mi tanımlanmış (çekirdeğin standart sapması mı, pencerenin yarı genişliği mi) ve aynı mı,
6. yerel polinom derecesi aynı mı,
7. kovaryatlar aynı mı,
8. bias correction/standart hata prosedürü aynı mı?

9.15.4 Adım 4: RDD grafiğini “güzel sıçrama” diye değil belirsizlikle birlikte okumak

Bu bölümdeki ana Head Start grafiğinde eşik iki tarafında yerel doğrusal eğri ve güven bantları gösterilmektedir. Görsel değerlendirmede üç şey birlikte aranmalıdır:

1. eşikte koşullu ortalamada sıçrama,
2. eşik çevresinde yeterli veri desteği,
3. güven bantlarının sıçrama büyüklüğüne kıyasla genişliği.

Grafikte belirgin görünen bir sıçrama, bant genişliği veya standart hata dikkate alınmadığında aşırı ikna edici görünebilir. Tersine, nokta bulutunun gürültülü olması geçerli yerel tahminin bilgi taşımadığı anlamına gelmez.

Kod 9.1: RDD’de bant genişliği duyarlılığı: birim varyanslı üçgen kernel ve HC1 standart hataları

```
import numpy as np
import statsmodels.api as sm

c = 59.1984
r = df["povrate60"].to_numpy() - c          # merkezlenmiş eşik değişkeni R
y = df["mort_age59_related_postHS"].to_numpy()

def rdd(h):
    # Birim varyanslı üçgen kernel: ağırlık |R| = h*sqrt(6) uzaklıkta sıfır
    w = np.maximum(1 - np.abs(r) / (h * np.sqrt(6)), 0)
    m = w > 0
    d = (r[m] >= 0).astype(float)
    Z = np.column_stack([np.ones(m.sum()), d, r[m], d * r[m]])
    fit = sm.WLS(y[m], Z, weights=w[m]).fit(cov_type="HC1")
    return m.sum(), fit.params[1], fit.bse[1]

rows = []
```

```
for h in [4, 6, 8, 10, 12]:
    n_h, tau, se = rdd(h)
    rows.append([h, n_h, tau, se, tau - 1.96 * se, tau + 1.96 * se])
```

Aynı hesap diğer iki yazılımda şöyle yapılır; üç yazılım aynı sayıları verir:

- R: `lm(y ~ d + r + d:r, weights = w, subset = w > 0)` ve `sandwich::vcovHC(type = "HC1")`,
- Stata: `regress y d r dr [aw = w] if w > 0, vce(robust)`.

9.15.5 Bir RDD makalesini değerlendirmek için kısa kontrol listesi

1. Eşik kuralı kurumsal olarak açık mı?
2. Birimler running variable'ı hassas biçimde manipüle edebilir mi?
3. Tedavi olasılığı eşikte gerçekten değişiyor mu?
4. Önceden belirlenmiş kovaryatlarda/plasebo sonuçlarda sıçrama var mı?
5. Ana bandwidth nasıl seçildi?
6. Alternatif makul bandwidth sonuçları gösterildi mi?
7. Global yüksek dereceli polinom yerine yerel yöntem kullanılmış mı?
8. Tahmin eşik çevresindeki birimler için yerel etki olarak mı yorumlanıyor?

Makale dili için örnek

“Yerel doğrusal RDD tahminleri, eşik civarındaki ilçelerde program desteği ile ölüm oranı arasında negatif bir yerel etki bulunduğunu göstermektedir. Tahminin büyüklüğü bant genişliğine duyarlı olmakla birlikte işaret makul bant aralığında korunmaktadır. Sonuçlar eşikten uzak ilçelere otomatik olarak genellenmemektedir.”

9.16 Temel Sonuçlar

Temel sonuç

1. Keskin (sharp) RDD’de tedavi eşik fonksiyonuyla tam belirlenir; bulanık (fuzzy) RDD’de eşikte tedavi olasılığı sıçrar.
2. Nedensel tanımlama, potansiyel sonuç koşullu ortalamalarının eşikte sürekliliğine dayanır.
3. Sharp RDD etkisi gözlenen koşullu ortalamanın sağ ve sol limitleri arasındaki farktır.
4. Yerel doğrusal RDD, eşik çevresinde iki ayrı ağırlıklı doğru tahmin eder.
5. Bant genişliği yerellik ile hassasiyet arasında denge kurar; çıkarımda düzgünleştirme yanlılığı ayrıca dikkate alınmalı ve sonuç duyarlılığı raporlanmalıdır.

6. Kovaryatlar hassasiyeti artırabilir; kötü tanımlamayı onarmaz.
7. Eşik değişkeni yoğunluğundaki yığılma olası manipülasyon için uyarı sinyalidir.
8. Bulanık RDD, sonuç sıçramasının tedavi olasılığı sıçramasına oranıdır ve IV mantığıyla bağlantılıdır; nedensel yorum kullanılan ek varsayımlara bağlıdır.
9. RDD etkisi esas olarak cut-off çevresindeki popülasyon için yerel bir nedensel etkidir.

9.17 Bölüm Sonu Egzersizleri

Egzersiz 9.1: Sharp treatment kuralı

Bir sosyal yardım programı gelir puanı $X \leq 40$ olan hanelere veriliyor. Treatment göstergesini D ile tanımlayınız. Standart $D = 1\{X \geq c\}$ yazımından farkın yalnız yönü, estimand mı olduğunu tartışınız.

Egzersiz 9.2: RDD tanımlama

$\lim_{x \uparrow c} E[Y \mid X = x] = 12,4$ ve $\lim_{x \downarrow c} E[Y \mid X = x] = 9,9$ olsun. Sharp RDD etkisini hesaplayınız ve işaretini yorumlayınız.

Egzersiz 9.3: Yerel doğrusal denklem

Denklem (9.5)'te $\alpha = 5$, $\theta = -2$, $\beta_1 = 0,4$, $\beta_2 = 0,1$ olsun. Eşik solundaki ve sağındaki doğruları yazınız. Eşikteki sıçramayı bulunuz.

Egzersiz 9.4: Bant genişliği

Bir RDD'de $h = 3$ için $\hat{\theta} = -4,0$ ve $SH = 2,2$; $h = 10$ için $\hat{\theta} = -1,8$ ve $SH = 0,8$ bulunmuştur. İki sonucu yanlılık–varyans açısından karşılaştırınız. Sadece daha küçük p-değerine bakarak bant seçmek neden yanlıştır?

Egzersiz 9.5: Head Start duyarlılığı

Tablo 9.1'e göre $h = 4$ ile $h = 12$ arasındaki point estimate farkını hesaplayınız. Örneklem büyüklüğü ve standart hatadaki değişimi birlikte yorumlayınız.

Egzersiz 9.6: Manipülasyon

Üniversite bursu not ortalaması 3,00 ve üzerindekiilere veriliyor. Öğretim üyelerinin 2,98–2,99 ortalamalı öğrencilerin notlarını sıkça 3,00'a yuvarladığını öğreniyorsunuz. Bu bilgi RDD tanımlamasını neden zayıflatır? Hangi grafik ilk kontrol olarak kullanılabilir?

Egzersiz 9.7: Kovaryat dengesi

Eşik sağında yaş ortalaması 42, solunda 31 ve yaşın sonuç değişkeni üzerinde güçlü etkisi olduğu görülüyor. Bu bulgu neden araştırma tasarımı açısından kaygı yaratır? Yaşı regresyona eklemek sorunu otomatik çözer mi?

Egzersiz 9.8: Bulanık RDD

Eşikte tedavi alma olasılığı solda 0,30, sağda 0,70; sonuç değişkeninin koşullu ortalaması solda 50, sağda 44 olsun. Δ_D , Δ_Y ve bulanık RDD oranını hesaplayınız.

Egzersiz 9.9: Zayıf ilk aşama

Bir bulanık RDD'de sonuç değişkeni sıçraması $-1,0$, tedavi olasılığı sıçraması yalnız $0,05$ 'tir. Nokta tahminini bulunuz. Paydanın küçük olmasının standart hata ve güvenilirlik açısından neden sorun oluşturduğunu açıklayınız.

Egzersiz 9.10: Plasebo sonuç

Bir eğitim programı RDD'sinde tedavi başlamadan iki yıl önce ölçülmüş sınav puanında cut-off'ta belirgin sıçrama bulunuyor. Bu bulguyu nasıl yorumlarsınız?

Egzersiz 9.11: Yerel estimand

Eşik puanı 70 olan burs programında güçlü bir RDD etkisi bulunmuştur. Bu sonuç 30 puan alan öğrenciler için bursun aynı etkiye sahip olduğunu gösterir mi? Neden?

Egzersiz 9.12: RDD raporlama

Bir tezde RDD uygulaması için asgari raporlama paketini yazınız: eşik değişkeni, eşik, tedavi kuralı, yerel doğrusal ana grafik ve güven bantları, ana ve çıkarım için kullanılan bant genişliği, ana tahmin, standart hata ve en az üç sağlamlık/tasarım kontrolü içersin. Bulanık tasarımda ilk aşama sıçramasının nasıl raporlanacağını da belirtiniz.

Yeniden Örnekleme ile Çıkarım: Jackknife ve Bootstrap

Bu bölümün amacı

Bu bölümün sonunda jackknife’ın dışarıda bırakma mantığını ve regresyondaki kaldırıcı kısıyolunu kurabilecek; bootstrap’ın örnekleme dağılımını ampirik dağılım üzerinden yaklaşık olarak yeniden üretme fikrini açıklayabilecek; nonparametrik pairs bootstrap algoritmasını adım adım kurabilecek; bootstrap standart hatasını hesaplayabilecek; normal-yaklaşım, percentile ve percentile- t güven aralıklarını ayırabilecek; regresyonda bütün (Y_i, X_i) çiftlerinin birlikte yeniden örneklenmesi gerektiğini açıklayabilecek; parametrik ve wild bootstrap’ın hangi varsayımları değiştirdiğini görebilecek; bootstrap tekrar sayısı ve rassal sayı seed’inin yeniden üretilebilirlikteki rolünü değerlendirebilecek; jackknife ile bootstrap arasında hangi durumda hangisinin tercih edilmesi gerektiğini gerekçelendirebilecek ve bootstrap’ın tanımlama hatası, bağımlılık veya uygunsuz yeniden örnekleme birimini neden düzeltemeyeceğini açıklayabileceksiniz.

Bağlantı

Önceki bölümlerde standart hataları çoğunlukla asimptotik formüllerden elde ettik. Kantil regresyon ve RDD gibi yöntemlerde analitik belirsizlik hesapları daha karmaşık hâle gelebilir. Bootstrap farklı bir yaklaşım sunar: elimizdeki örnekleme “ampirik anakütle” kabul edip aynı tahmin sürecini çok kez tekrarlarız. Hansen’in Bölüm 10’u bu bölümün temel kaynağıdır ([Hansen, 2021](#)).

10.1 Temel Problem: Tahmin Edicinin Örnekleme Dağılımını Bilmiyoruz

Bir parametre θ ve tahmin edici $\hat{\theta} = T(Z_1, \dots, Z_n)$ olsun. İstatistiksel çıkarım için

$$\hat{\theta} - \theta$$

değişkeninin örnekleme dağılımını bilmek isteriz. Basit ortalama veya OLS için asimptotik teori bize yaklaşık normal dağılımlar sağlar. Ancak bazı tahmin edicilerde standart hata formülü zor olabilir, küçük örneklem davranışı normal yaklaşımdan uzaklaşabilir veya ilgilendiğimiz

büyüklik doğrusal olmayan bir fonksiyon olabilir.

Bootstrap'ın çıkış noktası, bilinmeyen anakütle dağılımı F yerine örneklemin ampirik dağılımını kullanmaktır.

Ampirik dağılım

Gözlemler $Z_1, \dots, Z_n$ ise ampirik dağılım $\hat{F}_n$, her gözleme $1/n$ olasılık verir. Bootstrap örneği

$$Z_1^*, \dots, Z_n^* \sim \hat{F}_n$$

şeklinde, yerine koyarak çekilen n gözlemden oluşur.

Aynı gözlem bir bootstrap örneğinde birkaç kez görünebilir, bazı gözlemler hiç seçilmeyebilir. Bu hata değil, yöntemin temel özelliğidir.

Temel fikir plug-in ilkesidir. Gerçek dağılım F bilinmiyorsa onu ampirik dağılım $\hat{F}_n$ ile değiştiririz. Sonra $\hat{F}_n$ 'den tekrar tekrar örneklem çekip aynı tahmin ediciyi hesaplarız. Bootstrap dağılımı, gerçek örnekleme dağılımının veri-temelli yaklaşımıdır. Yöntemin başarısı, ampirik dağılımın ilgili istatistiğin davranışını yeterince iyi taklit etmesine bağlıdır.

10.2 Jackknife: Bootstrap'tan Önceki Yeniden Örnekleme

Bootstrap'a geçmeden önce daha eski ve daha basit bir yeniden örnekleme fikrini görmek yararlıdır. Jackknife, örneklemden rassal çekim yapmaz; gözlemleri *sırayla birer birer dışarıda bırakır*.

$\hat{\theta}_{(-i)}$, i 'inci gözlem çıkarılarak aynı yöntemle hesaplanan tahmin olsun. Bu n tahminin ortalaması

$$\bar{\theta}_{(\cdot)} = \frac{1}{n} \sum_{i=1}^n \hat{\theta}_{(-i)}$$

ise jackknife varyans tahmini

$$\widehat{\text{var}}_{jack}(\hat{\theta}) = \frac{n-1}{n} \sum_{i=1}^n \left(\hat{\theta}_{(-i)} - \bar{\theta}_{(\cdot)} \right)^2 \quad (10.1)$$

olarak tanımlanır. Standart hata bunun kareköküdür.

Baştaki $\frac{n-1}{n}$ çarpanı neden var?

Bir gözlemin çıkarılması tahmini çok az değiştirir; $\hat{\theta}_{(-i)}$ değerleri birbirine oldukça yakın kümelenir. Bu nedenle ham yayılım gerçek örnekleme değişkenliğini olduğundan çok küçük gösterir ve $(n-1)$ mertebesinde bir büyütme çarpanı gerekir: toplamın önündeki $(n-1)/n$, kare sapmaların ortalamasını $n-1$ ile çarpmakla aynıdır. Katsayı, örneklem ortalaması için alınmış varyans tahminini tam olarak verecek biçimde seçilmiştir: $\hat{\theta} = \bar{Z}$ ise $\hat{\theta}_{(-i)} - \bar{\theta}_{(\cdot)} = (\bar{Z} - Z_i)/(n-1)$ olduğundan Denklem (10.1)'deki tahmin, $s^2 = \sum_i (Z_i - \bar{Z})^2 / (n-1)$ olmak üzere s^2/n 'ye eşittir. Bootstrap'ta böyle bir çarpana gerek yoktur, çünkü orada yeniden örneklem gerçekten n gözlem büyüklüğündedir.

10.2.1 Regresyonda hesap kısıyolu

Jackknife'in maliyeti ilk bakışta n ayrı regresyon gibi görünür. Fakat OLS'de bunu yapmaya gerek yoktur. Kaldıraç değerleri h_{ii} (Denklem (2.10)) kullanılarak dışarıda bırakma artıkları tek bir regresyondan elde edilir ($h_{ii} < 1$ olduğu sürece):

$$\tilde{e}_i = Y_i - X_i' \hat{\beta}_{(-i)} = \frac{\hat{e}_i}{1 - h_{ii}}. \quad (10.2)$$

Jackknife'in kullandığı dışarıda bırakma tahminleri de aynı regresyondan gelir:

$$\hat{\beta}_{(-i)} = \hat{\beta} - (\mathbf{X}'\mathbf{X})^{-1} X_i' \tilde{e}_i;$$

jackknife varyansı her katsayı için bu n tahminden Denklem (10.1) ile hesaplanır. Denklem (10.2)'deki kimlik iki yerde daha karşımıza çıkacaktır: Bölüm 11'de leave-one-out çapraz doğrulama kriteri (Denklem (11.8)) tam olarak bu artıklardan kurulur ve Bölüm 2'deki HC3 düzeltmesi de aynı $1 - h_{ii}$ bölmesini kullanır.

Üç kavram, tek cebir

Jackknife varyansı, leave-one-out çapraz doğrulama ve HC3 standart hatası birbirinden bağımsız teknikler değildir. Üçü de “bu gözlem kendi tahminini etkilemeseydi ne olurdu?” sorusunun aynı cebirsel cevabına dayanır. Bu bağlantıyı görmek, ders boyunca dağınık görünen araçları tek bir fikre bağlar.

10.2.2 Kümelenmiş veride jackknife

Bölüm 2.7'deki mantık burada da aynen geçerlidir. Gözlemler kümelenmişse tek bir gözlemi çıkarmak bağımlılığı kırmaz; bir seferde *bütün kümeyi* çıkarmak gerekir. Küme g çıkarılarak hesaplanan tahmin $\hat{\theta}_{(-g)}$ ve bu G tahminin ortalaması $\bar{\theta}_{(\cdot)} = G^{-1} \sum_{g=1}^G \hat{\theta}_{(-g)}$ ise

$$\widehat{\text{var}}_{jack}^{CL}(\hat{\theta}) = \frac{G-1}{G} \sum_{g=1}^G (\hat{\theta}_{(-g)} - \bar{\theta}_{(\cdot)})^2$$

kullanılır. Yeniden örnekleme biriminin veri yapısıyla uyumlu seçilmesi ilkesi, bu bölümün sonraki kısımlarında bootstrap için de tekrarlanacaktır.

10.2.3 Jackknife mi bootstrap mı?

Jackknife'in hesaplama maliyeti tahmin ediciye bağlıdır (genel olarak n ayrı tahmin gerektirir; OLS'de kaldıraç kısıyoluyla tek regresyon yeter); rassallık içermediği için aynı veride her zaman aynı sonucu verir ve seed sorunu yoktur. Buna karşılık iki önemli sınırı vardır.

Birincisi, bir varyans tahmini üretir, fakat tahmin edicinin dağılım biçimi hakkında bilgi vermez. Dolayısıyla çarpık dağılımlar için percentile türü aralıklar kurulamaz.

İkincisi ve daha ciddi, tahmin edici düzgün olmayan (nondifferentiable) bir fonksiyonsa jackknife tutarsız olabilir. Klasik örnek medyandır: bir gözlemi çıkarmak medyayı ya hiç değiştirmez ya da sıçratır; bu kesikli davranış varyansı doğru temsil etmez. Bölüm 7'deki kantil regresyon tahmin edicileri de bu sınıftadır. Bootstrap bu durumlarda daha güvenilirdir.

Sık yapılan hata

Jackknife'in düzgün olmayan tahmin edicilerde başarısızlığı teorik bir incelik değil, pratik bir tuzaktır. Medyan, kantil regresyon veya eşik içeren tahmin edicilerde jackknife standart hatası sessizce yanlış çıkabilir; yazılım uyarı vermez. Medyan ve kantil regresyonda varsayılan tercih bootstrap olmalıdır; eşik gibi sert seçim içeren ve sınır problemlerinde standart bootstrap da geçersiz kalabilir (Bölüm 10.15).

10.3 Nonparametrik Bootstrap Algoritması

Orijinal tahmin

$$\hat{\theta} = T(Z_1, \dots, Z_n)$$

olsun. B bootstrap tekrarı için:


1. n gözlemi orijinal örneklemden **yerine koyarak** çek ve $Z_1^*, \dots, Z_n^*$ bootstrap örneğini oluştur.

2. Aynı tahmin yöntemini bu örneğe uygula:

$$\hat{\theta}_b^* = T(Z_{1b}^*, \dots, Z_{nb}^*).$$

3. $b = 1, \dots, B$ için işlemi tekrarla.

4. $\{\hat{\theta}_1^*, \dots, \hat{\theta}_B^*\}$ ampirik dağılımını, $\hat{\theta}$ 'nın örnekleme dağılımının yaklaşık karşılığı olarak kullan.



Şekil 10.1: Nonparametrik bootstrap'ın temel akışı

Algoritmanın kritik noktası “aynı tahmin prosedürü” ifadesidir. Ana analizde değişken seçimi, standardizasyon veya tuning varsa bunların bootstrap tekrarının içinde yeniden yapılması gerekebilir; aksi halde yalnız son aşamanın belirsizliği taklit edilir. Bootstrap tasarımı tahmin edicinin gerçek veri-analiz zincirini olabildiğince doğru yeniden üretmelidir.

10.4 Bootstrap Standart Hatası

Bootstrap tahminlerinin ortalaması

$$\bar{\theta}^* = \frac{1}{B} \sum_{b=1}^B \hat{\theta}_b^*$$

olsun. Bootstrap standart hatası, bu tekrarların örneklem standart sapmasıdır:

$$\widehat{se}_{boot}(\hat{\theta}) = \left[\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\theta}^*)^2 \right]^{1/2}. \quad (10.3)$$

Temel sezgi açıktır: Eğer farklı bootstrap örneklerinde tahmin çok değişiyorsa tahmin belirsizdir; az değişiyorsa daha hassastır.

Sık yapılan hata

Bootstrap'ın çok sayıda tekrar üretmesi, yeni bağımsız veri üretildiği anlamına gelmez. Bütün tekrarlar aynı orijinal örneklem taşıdığı bilgiyi yeniden düzenler. B 'yi büyütmek Monte Carlo hatasını azaltır; orijinal örneklem örneklem belirsizliğini ortadan kaldırmaz.

Buradaki varyasyon iki düzeyi içerir: orijinal örneklem ekonometrik bilgi kaynağıdır; bootstrap tekrarları ise bu örneklemden hesaplanan belirsizlik yaklaşımını sayısal olarak değerlendirir. B arttıkça bootstrap hesabının Monte Carlo gürültüsü azalır, fakat orijinal verinin bilgi miktarı artmaz.

Bu ayrım önemlidir. 1000 yerine 100000 tekrar yapmak küçük bir örneklemdeki tanımlama veya veri eksikliğini çözmez; yalnız verilen bootstrap prosedürünün sayısal doğruluğunu artırır.

10.5 Regresyonda Gözlem Çiftleri Bootstrap'ı (Pairs Bootstrap)

Regresyon gözlemi $Z_i = (Y_i, X_i)$ çiftidir. Nonparametrik bootstrap'ta Y ve X ayrı ayrı çekilmez; bütün gözlem çifti birlikte yeniden örneklenir. Bootstrap tasarım matrisi ve bağımlı değişken

$$(Y^*, X^*)$$

oluşur ve OLS için

$$\hat{\beta}^* = (X^{*'} X^*)^{-1} X^{*'} Y^*. \quad (10.4)$$

Her tekrar aynı işlemi yeniden yapar. Hansen bu yöntemi **gözlem çiftleri bootstrap'ı (pairs bootstrap)** olarak adlandırır (Hansen, 2021).

Neden çiftleri birlikte çekiyoruz?

X_i ile Y_i arasındaki ortak yapı gözlemin kendisidir. Y 'leri ve X 'leri bağımsız listelerden yeniden çekmek bu yapıyı kırar ve farklı bir veri üretim süreci oluşturur.

Seyrek kukla değişkenlerde bootstrap örneği bazen yalnız tek kategori içerebilir ve $X^{*'} X^*$ tekil olabilir. Hansen bunun bootstrap regresyonda gerçek bir sayısal sorun olduğunu ve böyle tekrarların kontrol edilmesi gerektiğini vurgular (Hansen, 2021).

Gözlem çiftleri bootstrap'ı, yatay kesit çerçevesinde heteroskedastisiteye karşı doğal bir seçenektir; belirli X değerlerine bağlı artık büyüklükleri gözlemle birlikte taşındığı için koşullu varyans deseni korunur.

Alternatif artık bootstrap'ı ise, X 'i sabit tutup tahmin edilen artıkları yeniden örnekler. Bu yöntem homoskedastik hata yapısına daha sıkı dayanabilir; heteroskedastik tasarımda artıkları yer değiştirmek koşullu varyans desenini bozabilir. Dolayısıyla yeniden örneklem planı, verinin

hangi bileşenlerinin rassal kabul edildiği ve hangi bağımlılık yapısının korunması gerektiğiyle uyumlu seçilmelidir.

10.6 Normal-Yaklaşım Bootstrap Güven Aralığı

Bootstrap yalnız standart hata üretmek için kullanılırsa basit yaklaşık aralık

$$C_{N,boot} = \left[\hat{\theta} - z_{1-\alpha/2} \widehat{se}_{boot}, \hat{\theta} + z_{1-\alpha/2} \widehat{se}_{boot} \right] \quad (10.5)$$

şeklinde. Yüzde 95 için $z_{0,975} \simeq 1,96$ kullanılır.

Bu yöntem bootstrap dağılımının sadece yayılımını kullanır; çarpıklığını veya asimetrik biçimini doğrudan aralığa yansıtmaz.

Bootstrap dağılımı belirgin çarpıksa veya tahmin edicinin sonlu örneklem yanlılığı varsa bu simetri önemli bilgiyi kaybeder. Buna karşılık yöntem basittir, kolay raporlanır ve yaklaşık simetrik düzenli problemlerde yeterlidir.

Bu nedenle güven aralığı seçimi otomatik değildir. Bootstrap dağılımının histogramı veya kantilleri incelenerek normal yaklaşımın makul olup olmadığı görülebilir. Aynı veri için normal, percentile ve percentile- t aralıklarının karşılaştırılması yöntemin hassasiyetini öğretici biçimde gösterir.

10.7 Percentile Güven Aralığı

Bootstrap dağılımının ampirik α kantili q_{α}^* olsun. Percentile aralığı doğrudan bootstrap tahminlerinin alt ve üst kantilleridir:

$$C_{pc} = \left[q_{\alpha/2}^*, q_{1-\alpha/2}^* \right]. \quad (10.6)$$

Örneğin $B = 10000$ ve yüzde 95 aralık için yaklaşık yüzde 2,5 ve yüzde 97,5 bootstrap kantilleri kullanılır. Hansen, percentile aralığının standart hata hesaplamadan elde edilebilmesini ve monoton dönüşümlere uyumlu olmasını önemli avantajlar arasında sayar (Hansen, 2021).

Dönüşüme uyum özelliği

$g(\theta)$ monoton ise θ için percentile aralığının uçlarına $g(\cdot)$ uygulamak, $g(\theta)$ için bootstrap percentile aralığını verir. Bu özellik, örneğin varyanstan standart sapmaya geçerken kullanışlıdır.

Percentile yöntemi bootstrap dağılımının asimetrisini doğrudan aralığa taşır ve monoton dönüşümlere uyum özelliğine sahiptir. Ancak basit percentile aralığı yanlılığı otomatik olarak tam düzeltmez. Bias-corrected (BC) veya BCa türü yöntemler bootstrap dağılımının merkez kaymasını ve bazı durumlarda ivmeyi hesaba katarak iyileştirme amaçlar.

Hansen, bootstrap aralıklarını değerlendirirken yalnız hesaplama kolaylığına değil kapsama doğruluğuna dikkat eder (Hansen, 2021). Tez uygulamasında kullanılan aralık türü, tekrar sayısı ve bootstrap tasarımı açıkça yazılmalıdır; yalnız “bootstrap standart hataları kullanıldı” ifadesi çoğu zaman yetersizdir.

10.8 Percentile-t Güven Aralığı

Daha gelişmiş yaklaşım her bootstrap tahminini, o bootstrap örneğinde hesaplanan kendi standart hatasıyla studentize eder. $s(\hat{\theta})$, $\hat{\theta}$ 'nin standart hatası olmak üzere orijinal istatistik

$$T = \frac{\hat{\theta} - \theta}{s(\hat{\theta})}$$

ve her bootstrap tekrarında

$$T_b^* = \frac{\hat{\theta}_b^* - \hat{\theta}}{s(\hat{\theta}_b^*)} \quad (10.7)$$

hesaplanır. Bootstrap t dağılımının kantilleri $q_{\alpha/2,T}^*$ ve $q_{1-\alpha/2,T}^*$ olsun. Güven aralığı

$$C_{pt} = [\hat{\theta} - q_{1-\alpha/2,T}^* s(\hat{\theta}), \hat{\theta} - q_{\alpha/2,T}^* s(\hat{\theta})] \quad (10.8)$$

olur.

Percentile- t yönteminin ana maliyeti, her bootstrap tekrarında yalnız tahmin değil güvenilir bir standart hata da hesaplanmasıdır. Hansen uygun düzenlilik koşullarında studentized bootstrap'ın birinci-derece normal yaklaşımdan daha yüksek asimptotik doğruluk sağlayabileceğini tartışır (Hansen, 2021).

Sık yapılan hata

Percentile- t 'nin avantajı, bootstrap tekrarlarındaki standart hata hesabı doğruysa ortaya çıkar. Yanlış kovaryans formülünü binlerce kez tekrar etmek onu doğru hâle getirmez.

Yöntemin arkasındaki fikir, T istatistiğinin dağılımını bilinmeyen yardımcı parametrelere mümkün olduğunca az bağımlı (yaklaşık *pivotal*) hale getirmektir. Bunun bedeli her bootstrap örneğinde güvenilir bir standart hata hesaplamak, yani iç içe geçmiş daha pahalı bir hesaplama.

Özellikle karmaşık tahmin edicide bootstrap-içi standart hata da başka bootstrap gerektiriyorsa double bootstrap çok pahalı olabilir. Bu nedenle teorik doğruluk ile hesaplama maliyeti birlikte değerlendirilir.

10.9 Parametrik Bootstrap

Nonparametrik bootstrap ampirik dağılımdan yeniden örnekler. Parametrik bootstrap ise belirli bir dağılımsal model varsayar. Örneğin normal regresyonda

$$Y_i = X_i' \beta + e_i, \quad e_i \mid X_i \sim N(0, \sigma^2)$$

varsayımı altında X sabit tutulabilir ve

$$e_i^* \sim N(0, \hat{\sigma}^2), \quad Y_i^* = X_i' \hat{\beta} + e_i^*$$

üretilir.

Parametrik model doğruysa bu yöntem küçük örnekleme daha hassas olabilir; model yanlışsa bootstrap da yanlış modeli tekrarlar. Hansen bu ödünleşimi açık biçimde vurgular (Hansen, 2021).

Yanlış normalite, yanlış varyans yapısı veya yanlış fonksiyonel biçim her yapay örnekleme yeniden üretilir. Bu nedenle parametrik bootstrap bir duyarlılık analizinde nonparametrik bootstrap ile karşılaştırılabilir. İki yöntemin benzer sonuç vermesi güveni artırabilir; büyük fark model varsayımlarının çıkarım üzerinde önemli olduğunu gösterir.

10.10 Wild Bootstrap: Heteroskedastisiteyi Korumak

Heteroskedastik regresyonda artıkların dağılımı X 'e göre değişebilir. Basit artık bootstrap'ı, artıkların yerlerini rastgele değiştirerek bu yapıyı bozabilir. Wild bootstrap ise regresörleri sabit tutar ve artıkların büyüklük desenini koruyarak işaret/ölçek rassallaştırması yapar:

$$Y_i^* = X_i' \hat{\beta} + \hat{e}_i \xi_i^*, \quad (10.9)$$

burada ξ_i^* çarpanları veriden bağımsız, birbirinden bağımsız ve aynı dağılımlı, ortalaması 0 ve varyansı 1 olan yardımcı rassal değişkenlerdir; örneğin Rademacher değişkeni

$$P(\xi_i^* = 1) = P(\xi_i^* = -1) = \frac{1}{2}$$

kullanılabilir.

Veri verildiğinde $e_i^* = \hat{e}_i \xi_i^*$ 'in ortalaması 0, varyansı $\hat{e}_i^2$ 'dir: $\hat{e}_i$ her gözlemde kendi büyüklüğünü taşıdığı için koşullu varyans deseninin önemli bir kısmı korunur. Hipotez testlerinde kısıtlı modelden gelen artıkları kullanan kısıtlı wild bootstrap daha uygun olabilir (Hansen, 2021).

Regresörler sabit tutulduğu için yöntem sabit-tasarım bakışıyla da uyumludur.

Hipotez testi amacıyla bootstrap yapılırken veri H_0 altında üretilmelidir. Bu nedenle kısıtlı (restricted) wild bootstrap'ta önce kısıtlı model tahmin edilir, kısıtlı artıklar kullanılır ve test istatistiğinin sıfır hipotezi altındaki dağılımı taklit edilir. Ana modelden alınan artıklarla doğrudan bootstrap yapmak, test edilen kısıtı yapay örneklemlerde ihlal edebilir.

10.11 Uygulama: Analitik ve Bootstrap Belirsizliğini Karşılaştırmak

Kontrollü örnekte

$$Y_i = 1 + 1,8X_i + u_i, \quad u_i = (0,45 + 0,55|X_i|) \varepsilon_i, \quad X_i, \varepsilon_i \sim N(0, 1) \text{ bağımsız}$$

şeklinde heteroskedastik veri ürettik ve $n = 240$ kullandık. Hata terimi X 'ten bağımsız değildir: $\text{sd}(u_i | X_i) = 0,45 + 0,55|X_i|$. Rastgele sayılar tek bir üretecten (`np.random.default_rng(807)`) sırayla çekilmiştir: önce X ve ε , sonra pairs, en son wild bootstrap çekilişleri. Tek örnekleme eğim tahmini

$$\hat{\beta}_1 = 1,891$$


olarak bulundu. Geleneksel homoskedastik standart hata 0,057 iken HC1 standart hata 0,076'dır.

$B = 3000$ tekrar ile pairs bootstrap ve Rademacher çarpanlı wild bootstrap uygulandığında elde edilen ölçüler Tablo 10.1'de, pairs bootstrap dağılımı Şekil 10.2'de verilmiştir.

Bu özel örnekte HC1, pairs bootstrap ve wild bootstrap standart hataları çok benzerdir. Bu durum bootstrap'ın her zaman analitik yöntemden farklı sonuç üretmesi gerektiği anlamına

Tablo 10.1: Heteroskedastik örnekte analitik ve bootstrap belirsizlik ölçüleri

Büyüklik	Değer
Eğim tahmini	1,891
Geleneksel OLS SH	0,057
HC1 SH	0,076
Pairs bootstrap SH	0,077
Wild bootstrap SH	0,079
HC1 normal %95 GA	[1,741; 2,041]
Percentile %95 GA (pairs)	[1,735; 2,036]
Percentile- t %95 GA (pairs; s : HC1)	[1,741; 2,049]



Şekil 10.2: Pairs bootstrap eğim tahminlerinin ampirik dağılımı

gelmez. İyi çalışan asimptotik yaklaşım ile iyi kurulmuş bootstrap aynı örnekleme belirsizliğini hedeflediğinde benzer sonuçlar beklenebilir.

Karşılaştırmada yalnız iki standart hata sayısını yan yana koymak yerine bootstrap dağılımının şekline bakın. Simetrik ve tek tepeli dağılım analitik normal yaklaşımı destekleyebilir. Belirgin çarpıklık, kalın kuyruk veya çok-modluluk normal aralığın yetersiz olabileceğini gösterir. Ayrıca uç bootstrap tahminleri veri setindeki yüksek etkili gözlemlere duyarlılığı görünür kılabilir.

Bootstrap sonucu analitik sonuçtan farklıysa “bootstrap daha doğrudur” diye otomatik karar verilmez. Yeniden örnekleme tasarımının doğru olup olmadığı, modelin tanımlı olup olmadığı ve B sayısının yeterliliği kontrol edilir.

10.12 Kaç Bootstrap Tekrarı?

B büyüdükçe bootstrap dağılımının Monte Carlo yaklaşımı daha hassas olur. Hesaplama maliyeti yaklaşık B ile doğrusal artarken simülasyon hatası yaklaşık $B^{-1/2}$ oranında azalır. Dolayısıyla hassasiyeti iki kat artırmak yaklaşık dört kat tekrar gerektirir.

Hansen pratik bir ayırım önerir (Hansen, 2021):

- günlük hızlı araştırma hesaplarında $B \approx 100$ kaba kontrol için kullanılabilir;
- nihai raporlama için $B = 1000$ asgari bir tercih olarak görülebilir;
- nihai hassas hesaplarda $B = 10000$ tercih edilmelidir.

Bu rakamlar evrensel yasa değildir; özellikle çok küçük p-değerleri veya kuyruk kantilleri hedefleniyorsa daha fazla tekrar gerekebilir.

Gerekli B sayısı hesaplanan çıktıya bağlıdır. Yalnız standart hata için birkaç bin tekrar çoğu zaman yeterli olabilir; yüzde 2,5 gibi kuyruk kantillerine dayanan güven aralıkları veya p-değerleri daha fazla tekrar ister. Çünkü kuyruk olasılığı az sayıda bootstrap gözlemine dayanır. Hansen nihai uygulamalarda yüksek tekrar sayısını ve sabit seed kullanımını önerir (Hansen, 2021).

Monte Carlo hatasını basitçe düşünmek yararlıdır. Bootstrap p-değeri $\hat{p}$ yaklaşık bir binom oranıdır ve simülasyon standart hatası kabaca $\sqrt{\hat{p}(1 - \hat{p})/B}$ düzeyindedir. Böylece B seçiminin sadece gelenek değil sayısal hassasiyet kararı olduğu görülür.

10.13 Seed ve Yeniden Üretilbilirlik

Pseudo-rassal sayı üreteçleri bir başlangıç değeri, yani **seed**, kullanır. Aynı kod, aynı veri ve aynı seed aynı bootstrap örneklerini üretir. Bu bilimsel tekrar üretilebilirlik için önemlidir.

Hansen'in önerisi nüanslıdır: geliştirme aşamasında çok küçük B ile sabit seed kullanmak bootstrap sonucunun yapay biçimde istikrarlı görünmesine yol açabilir; nihai hesapta ise büyük B ve kaydedilmiş sabit seed sonuçların tekrar üretilebilmesini sağlar (Hansen, 2021).

İyi uygulama

Analiz sırasında bootstrap sonucunun B ve seed'e duyarlılığını görün. Nihai tablo için yeterince büyük B seçin, seed'i kodda kaydedin ve yeniden örnekleme birimini açıkça belgeleyin.

10.14 Bağımlı Veride Yeniden Örnekleme Birimi

Pairs bootstrap'ın standart biçimi i.i.d. gözlemlere dayanır. Eğer öğrenciler okul içinde, çalışanlar firma içinde veya bireyler hane içinde bağımlıysa bireyleri tek tek yeniden örnekleme bağımlılık yapısını kırabilir.

Kümeli veride doğal yaklaşım bütün kümeleri yeniden örnekleme. $g = 1, \dots, G$ kümeleri için

$$(\mathbf{Y}_g, \mathbf{X}_g)$$

çiftleri bootstrap birimi olur. Aynı biçimde wild cluster bootstrap'ta tek bir rassal çarpan kümenin bütün artık vektörüne uygulanabilir; Bölüm 2.7'de küme sayısı az olduğunda önerilen alternatiflerden biri budur. Hansen bu yöntemleri kümeli örnekler için ayrı olarak tartışır (Hansen, 2021).

Dersimizin panel veri kapsamına girmemesi bu ilkeyi değiştirmez: yeniden örnekleme birimi veri üretimindeki bağımsızlık birimiyle uyumlu olmalıdır.

Bootstrap gözlemler arasındaki gerçek bağımlılığı korumalıdır. Aynı okul içindeki öğrenciler veya aynı firma içindeki çalışanlar ortak şok taşıyorsa tek tek bireyleri çekmek kümeyi parçalar ve sahte bağımsızlık yaratır. Cluster bootstrap'ta bütün kümeler yerine koyarak seçilir ve küme içindeki gözlemler birlikte taşınır.

Zaman serisinde benzer gerekçe blok bootstrap gibi yöntemlere yol açar; ancak bu dersin zaman serisi kapsamı dışında kalır. Genel ilke değişmez: yeniden örnekleme birimi, veri üretim sürecindeki bağımsız bilgi birimine mümkün olduğunca karşılık gelmelidir.

10.15 Bootstrap Ne Zaman Sorunlu Olabilir?

Bootstrap güçlü bir genel araçtır fakat otomatik çözüm değildir.

10.15.1 Yanlış yeniden örnekleme birimi

Seri, mekânsal veya kümeli bağımlılığı i.i.d. yeniden örneklemeyle bozmak yanlış belirsizlik ölçüsü üretir.

Bir sınıftaki öğrenciler ortak öğretmen şoku taşıyorsa bireyleri bağımsız çekmek, gerçek veri setinde olmayan sınıf kombinasyonları üretir ve standart hatayı aşağı yönlü bozabilir. Doğru bootstrap birimi sınıf olabilir. Benzer şekilde eşleştirilmiş gözlemler, haneler veya firmalar birlikte tutulmalıdır.

10.15.2 Zayıf tanımlama

IV'de zayıf araç, bulanık (fuzzy) RDD'de çok küçük tedavi sıçraması veya genel olarak zayıf tanımlama varsa basit bootstrap beklenmedik davranabilir. Yeniden örnekleme tanımlama bilgisini yaratmaz.

Tahmin edicinin dağılımı tanımlama gücüne göre keskin biçimde değişiyorsa ampirik dağılımdan standart bootstrap bu değişimi doğru taklit etmeyebilir. Zayıf IV en bilinen örnektir. Bu tür problemlerde zayıf tanımlamaya dayanlı testler veya özel bootstrap tasarımları gerekir.

10.15.3 Sınır ve düzgün olmayan problemler

Parametre sınırdaysa veya tahmin edici sert seçim/kink içeriyorsa standart nonparametrik bootstrap geçersiz olabilir. "Bootstrap kullandım" ifadesi tek başına teorik geçerlilik garantisi değildir.

Parametre uzayının sınırında bulunan tahminler veya maksimum/minimum, model seçimi gibi düzgün olmayan fonksiyoneller standart bootstrap düzenlilik koşullarını ihlal edebilir. Tahmin edicinin küçük veri pertürbasyonlarına tepkisi süreksizse bootstrap dağılımı gerçek dağılıma yavaş veya yanlış yaklaşabilir.

10.15.4 Seyrek tasarım ve tekillik

Bootstrap örneğinde bazı kategorilerin hiç seçilmemesi tasarım matrisini tekil hâle getirebilir. Bu tekrarlar izlenmeli ve kullanılan sayısal kural raporlanmalıdır.

Kategorik regresörün çok nadir bir seviyesi varsa bazı bootstrap örneklemlerinde o kategori hiç seçilmeyebilir. Böylece tasarım matrisi rank kaybedebilir ve model tahmin edilemez. Bu

tekrarları sessizce atmak bootstrap dağılımını değiştirebilir; sorun raporlanmalı ve yeniden örnekleme tasarımı gözden geçirilmelidir.

10.15.5 Tanımlama ve model hatası

İçsel bir regresyonda yanlış estimand tahmin ediliyorsa bootstrap yalnız yanlış tahmin edicinin örnekleme dağılımını daha dikkatli hesaplar. Nedensel yorumu düzeltmez.

Sık yapılan hata

Bootstrap “varsayım kontrolü” değildir. Önce estimand, tanımlama, veri bağımlılığı ve tahmin yönteminin uygunluğu belirlenir; bootstrap daha sonra belirsizlik hesabına uygulanır.

Bootstrap güçlü fakat evrensel değildir. İstatistiğin dağılımı düzgün değilse, parametre sınırdaysa, model zayıf tanımlıysa veya örnekleme bazı tasarım noktaları çok seyrekse ampirik dağılımdan basit yeniden örnekleme gerçek asimptotik davranışı doğru taklit etmeyebilir. Zayıf araç problemi bunun önemli örneklerinden biridir: standart 2SLS bootstrap’ı zayıf tanımlama altında klasik dağılım bozukluğunu otomatik olarak çözmez.

Ayrıca bootstrap model yanlış belirtimini iyileştirmez. Yanlış estimand, endojenlik veya hatalı örneklem tanımı her tekrar içinde yeniden üretilir. “Bootstrap yaptık” ifadesi güvenilirliğin genel mührü değil, belirli bir örnekleme belirsizliği problemini çözmeye yönelik yöntemdir.

10.16 Analitik mi Bootstrap mı?

İkisini rakip ideolojiler gibi görmek doğru değildir. Uygulamada şu yaklaşım daha yararlıdır:

Tablo 10.2: Analitik ve bootstrap çıkarımın pratik karşılaştırması

Özellik	Analitik/asimptotik	Bootstrap
Hesaplama	Genellikle hızlı	B kez tahmin nedeniyle daha pahalı
Teori	Kapalı form/limit dağılım gerekir	Geçerli yeniden örnekleme şeması gerekir
Doğrusal olmayan fonksiyon	Delta yöntemi gerekebilir	Doğrudan yeniden hesaplanabilir
Küçük örneklem	Yaklaşım zayıf olabilir	Doğru bootstrap bazen iyileştirebilir
Bağımlılık	Uygun kovaryans gerekir	Uygun blok/küme şeması gerekir
Tanımlama hatası	Çözmez	Çözmez

Bir tezde analitik robust standart hata ile bootstrap sonucu birlikte raporlanabiliyorsa ve ikisi yakınsa bu yöntemsel güveni artırabilir. Büyük ayırım varsa hangi varsayım ve yeniden örnekleme kararının farkı yarattığı araştırılmalıdır.

Analitik asimptotik formül hızlı ve şeffaftır; düzenli büyük örneklem problemlerinde genellikle yeterlidir. Bootstrap özellikle karmaşık fonksiyoneller, küçük örneklem düzeltmeleri veya analitik kovaryansın zor olduğu durumlarda yarar sağlar. İki yaklaşım birbirinin rakibi olmak zorunda değildir: analitik standart hata ana sonuç, bootstrap duyarlılık kontrolü olabilir.

Yöntem seçimi hesaplama kolaylığına değil, örnekleme tasarımına ve hedef çıkarıma dayanmalıdır. Kümeli veri için analitik küme-dayanıklı standart hata ile cluster bootstrap aynı bağımlılık varsayımını farklı biçimlerde uygular; ikisinin karşılaştırılması yararlı olabilir.

10.17 Ampirik Uygulama Laboratuvarı: Aynı Katsayı İçin Analitik ve Bootstrap Belirsizliği

Bootstrap'ı yalnız soyut yeniden örnekleme algoritması olarak görmek yerine gerçek bir regresyon katsayısında uygulayalım. Hansen'in CPS verisindeki 50.742 gözlemin tamamını kullanıyoruz ve

$$\log(wage_i) = \beta_0 + \beta_1 education_i + \beta_2 experience_i + \beta_3 experience_i^2/100 + \beta_4 female_i + u_i$$

modelindeki eğitim katsayısına odaklanıyoruz. Amaç OLS katsayısını değiştirmek değil, $\hat{\beta}_1$ 'in örnekleme belirsizliğini iki farklı yolla ölçmektir.

10.17.1 Adım 1: Orijinal tahmin

Eğitim katsayısı

$$\hat{\beta}_{education} = 0,1148$$

ve HC1 standart hatası

$$se_{HC1} = 0,00107$$

olarak tahmin edilmektedir; bu, [Tablo 7.2](#)'deki OLS satırıyla aynı modeldir. Bu, gözlemsel ücret ilişkisidir; bootstrap uygulanması katsayının nedensel yorumunu değiştirmez.

10.17.2 Adım 2: Pairs bootstrap ile 1.000 yeniden örnekleme

Her bootstrap tekrarında gözlem satırları yerine koyarak yeniden örneklenmekte ve aynı regresyon baştan tahmin edilmektedir. Elde edilen 1.000 eğitim katsayısının standart sapması

$$se_{boot} = 0,00109$$


ve percentile güven aralığı yaklaşık

$$[0,1127; 0,1169]$$

olmaktadır.

Tablo 10.3: CPS eğitim katsayısı için analitik ve bootstrap çıkarım

Büüklük	Değer
$\hat{\beta}_{education}$	0,1148
HC1 standart hata	0,00107
Pairs bootstrap standart hata	0,00109
Bootstrap percentile alt sınır	0,1127
Bootstrap percentile üst sınır	0,1169
Bootstrap tekrar sayısı	1.000



Şekil 10.3: CPS eğitim katsayısının pairs bootstrap dağılımı

Bu örnekte analitik robust standart hata ile bootstrap standart hata neredeyse aynıdır. Bu yakınlık yararlı bir sağlamlık bulgusudur; ancak “iki yöntem aynı sonucu verdi, model doğrudur” anlamına gelmez. Her iki yöntem de aynı regresyon spesifikasyonunu ve aynı tanımlama varsayımlarını temel alır.

10.17.3 Adım 3: Bootstrap kodunda yeniden örnekleme birimini açıkça görmek

Kod 10.1: CPS regresyon katsayısı için pairs bootstrap

```
X = np.column_stack([np.ones(len(df)),
                     df[["education", "experience", "experience2_100", "female"]]])
y = df["lwage"].to_numpy()

rng = np.random.default_rng(807)
boot_beta = np.empty(1000)
for b in range(1000):
    idx = rng.integers(0, len(y), len(y))      # satırları yerine koyarak çek
    boot_beta[b] = np.linalg.lstsq(X[idx], y[idx], rcond=None)[0][1]

bootstrap_se = boot_beta.std(ddof=1)
percentile_ci = np.quantile(boot_beta, [0.025, 0.975])
```

Regresyon her tekrarda doğrudan tasarım matrisiyle çözülür; 50.742 gözlemde 1.000 tekrar birkaç saniye sürer. Formül arayüzüyle (`smf.ols`) aynı katsayılar elde edilir, fakat her tekrarda formülü yeniden işlemek hesabı belirgin biçimde yavaşlatır.

Bu kodda bireysel gözlemler yeniden örneklenmektedir; çünkü CPS uygulamasını bağımsız yatay kesit örneği olarak ele alıyoruz. Veri okul, firma, hane veya bölge içinde kümeli olsaydı bireyleri tek tek yeniden örnekleme bağımlılık yapısını bozabilirdi. O durumda yeniden örnekleme birimi küme olmalıdır.

10.17.4 Adım 4: Bootstrap tablosunu okurken dört soru

1. **Ne yeniden örneklenmiş?** Satırlar mı, kümeler mi, artıklar mı?
2. **Kaç tekrar yapılmış?** Nihai sonuç için Monte Carlo gürültüsü yeterince küçük mü?
3. **Hangi güven aralığı?** Normal, percentile, basic, BCa veya percentile- t mi?
4. **Bootstrap hangi varsayımı taklit ediyor?** Bağımsız örnekleme mi, heteroskedastisite mi, küme bağımlılığı mı?

Aynı “bootstrap” etiketi çok farklı yeniden örnekleme şemalarını kapsar. Makalede yalnız “standart hatalar bootstrap ile hesaplandı” ifadesi çoğu zaman yetersizdir.

10.17.5 Adım 5: Bootstrap’ın çözemediği problemi görünür kılmak

Eğitim katsayısında gözlenmeyen yetenek nedeniyle endojenlik varsa pairs bootstrap, endojen regresyonu 1.000 kez yeniden tahmin eder. Örnekleme dağılımını daha iyi yaklaşıklar; yanlış hedefi doğru hedefe dönüştürmez. Aynı mantık zayıf IV veya yanlış RDD tasarımı için de geçerlidir.

Tez yazımında örnek raporlama

“Eğitim katsayısının HC1 standart hatası 0,00107, 1.000 tekrarlı pairs bootstrap standart hatası 0,00109’dur. Bootstrap percentile yüzde 95 aralığı [0,1127; 0,1169]’dur. İki çıkarım yaklaşımının benzer sonuç vermesi örnekleme belirsizliği açısından bulgunun istikrarlı olduğunu göstermektedir; sonuç gözlemsel tanımlama sınırlarını değiştirmemektedir.”

10.18 Temel Sonuçlar

Temel sonuç

1. Nonparametrik bootstrap, orijinal örneklemin ampirik dağılımından yerine koyarak yeni örnekler üretir.
2. Bootstrap standart hatası, tekrar tahminlerinin standart sapmasıdır.
3. Regresyonda pairs bootstrap bütün (Y_i, X_i) gözlem çiftini birlikte çeker.
4. Percentile aralığı bootstrap tahminlerinin doğrudan kantillerini kullanır; percentile- t studentized bootstrap istatistiklerini kullanır.
5. Parametrik bootstrap belirli bir dağılımsal modeli, wild bootstrap ise özellikle heteroskedastik artık yapısını kullanır.
6. B büyütme Monte Carlo hatasını azaltır; veri miktarını artırmaz.
7. Nihai sonuçlarda büyük B ve kayıtlı seed yeniden üretilebilirliği destekler.
8. Yeniden örnekleme birimi bağımsızlık yapısıyla uyumlu olmalıdır.
9. Bootstrap zayıf tanımlama, içsellik veya yanlış araştırma tasarımını onarmaz.

10.19 Bölüm Sonu Egzersizleri

Egzersiz 10.1: Jackknife ve leave-one-out

Bir OLS regresyonunda üç gözlemin artıkları $\hat{e}_i = (1,2, -0,8, -0,4)$ ve kaldıraç değerleri $h_{ii} = (0,30, 0,45, 0,25)$ olsun.

1. denklem (10.2) ile dışarıda bırakma artıklarını hesaplayınız.
2. Bu artıkların sıradan artıklardan neden daha büyük olduğunu açıklayınız.
3. Jackknife, leave-one-out çapraz doğrulama ve HC3 arasındaki ortak cebri bir cümleyle özetleyiniz.
4. Tahmin edici medyan olsaydı jackknife varyansı neden güvenilmez olurdu?

Egzersiz 10.2: Bootstrap örneği

Orijinal örneklem $\{2, 5, 9\}$ olsun. Boyutu yine üç olan dört farklı geçerli bootstrap örneği yazınız. Aynı gözlemin birden fazla kez seçilebileceğini gösteriniz.

Egzersiz 10.3: Bootstrap standart hatası

Dört bootstrap tahmini 1,8, 2,1, 1,9 ve 2,2 olsun. Bootstrap ortalamasını ve Denklem (10.3) ile standart hatayı hesaplayınız.

Egzersiz 10.4: Pairs bootstrap

Bir regresyon veri setinde gözlemler (Y_i, X_i) çiftlerinden oluşuyor. Y listesini ve X listesini birbirinden bağımsız yeniden örnekleme neden yanlış olduğunu açıklayınız.

Egzersiz 10.5: Percentile aralığı

Sıralanmış 1000 bootstrap tahmininde 25. değer 0,42 ve 975. değer 0,91 olsun. Yüzde 95 percentile aralığını yazınız.

Egzersiz 10.6: Percentile- t

$\hat{\theta} = 3$, $s(\hat{\theta}) = 0,4$ ve bootstrap t dağılımının 0,025 ve 0,975 kantilleri sırasıyla $-2,2$ ve $1,8$ olsun. Denklem (10.8) ile yüzde 95 aralığı hesaplayınız.

Egzersiz 10.7: Parametrik ve nonparametrik bootstrap

Normal regresyon modeli altında parametrik bootstrap ile pairs bootstrap'ın veri üretme adımlarını ayrı ayrı yazınız. Parametrik model yanlışsa hangisinin daha kırılğan olmasını beklersiniz?

Egzersiz 10.8: Wild bootstrap

$\hat{e}_i = 2$ ve Rademacher çarpanı $\xi_i^* = -1$ ise bootstrap artığı nedir? Aynı gözlemde $\xi_i^* = 1$ olursa nedir? Bu mekanizma neden artık büyüklüğünü korur?

Egzersiz 10.9: Uygulama tablosu

Tablo 10.1’de geleneksel OLS standart hata ile HC1 standart hata arasındaki yüzde farkı yaklaşık olarak hesaplayınız. Pairs ve wild bootstrap sonuçlarının hangisine daha yakın olduğunu belirtiniz.

Egzersiz 10.10: Tekrar sayısı

Bootstrap Monte Carlo hatasının $B^{-1/2}$ ile orantılı olduğunu kabul edin. $B = 1000$ ’den $B = 4000$ ’e geçildiğinde simülasyon hatası yaklaşık kaç katına iner?

Egzersiz 10.11: Kümeli veri

50 okulda toplam 1500 öğrenci gözlenmiştir. Öğrenciler aynı okul içinde bağımlıysa standart pairs bootstrap’ta öğrencileri tek tek çekmek neden sakıncalıdır? Uygun yeniden örnekleme birimini belirtiniz.

Egzersiz 10.12: Bootstrap’ın sınırı

İçsel bir açıklayıcı değişken içeren OLS modelinde 10000 bootstrap tekrarı yapılıyor ve çok dar güven aralığı elde ediliyor. Bu sonuç OLS katsayısının nedensel olduğunu kanıtlar mı? Açıklayınız.

Egzersiz 10.13: Tez için bootstrap protokolü

Bir tezde nonlinear bir marjinal etkinin güven aralığını bootstrap ile hesaplayacağınızı düşünün. Yeniden örnekleme birimi, B , seed, her tekrarda yeniden tahmin edilecek nesneler ve raporlanacak aralık türünü içeren kısa bir replikasyon protokolü yazınız.

Model Seçimi, Çapraz Doğrulama ve Düzenleştirme

Bu bölümün amacı

Bu bölümün sonunda bir ampirik çalışmada “en iyi model” ifadesinin tahmin, açıklama ve çıkarım amaçlarına göre farklı anlamlar taşıdığını açıklayabilecek; yanlılık–varyans dengesini model karmaşıklığıyla ilişkilendirebilecek; AIC, BIC, ayırma örnekleme (hold-out) ve çapraz doğrulama ölçütlerinin temel mantığını kurabilecek; eğitim, doğrulama ve test örneklemlerinin rollerini ayırabilecek; yüksek boyutlu regresyon problemini tanıyabilecek; Ridge, Lasso, Elastic Net ve Post-Lasso tahmin edicilerini matematiksel amaç fonksiyonları üzerinden karşılaştırabilecek; ceza parametresinin katsayı küçültme ve değişken seçimine etkisini yorumlayabilecek ve model seçimi sonrasında standart çıkarımın neden otomatik olarak geçerli olmadığını açıklayabileceksiniz.

Bağlantı

Bölüm 8’de çapraz doğrulamayı bant genişliği ve esneklik seçimi için kullandık; Bölüm 10’da ise örnekleme belirsizliğini yeniden örnekleme yoluyla inceledik. Bu bölüm aynı iki fikri daha genel bir soruna taşır: çok sayıda olası spesifikasyon arasından nasıl seçim yapılır ve karmaşık modellerin varyansı nasıl kontrol edilir? Hansen’in Bölüm 28’i ile Bölüm 29.1–29.14 bu bölümün temel kaynağıdır (Hansen, 2021).

Ders içi öncelik

Derste çekirdek: eğitim/test ayrımı; çapraz doğrulama; Ridge ve Lasso amaç fonksiyonları; ceza parametresi seçimi; tahmin ile çıkarım amaçlarının ayrımı.

Notta genişletme/ileri okuma: AIC/BIC ayrıntıları, Elastic Net, Post-Lasso ve model seçimi sonrası çıkarımın ileri boyutları.

11.1 Model Seçimi Neden Bir Ekonometrik Problemdir?

Ampirik araştırmada tek bir regresyon tahmin etmek nadirdir. Aynı araştırma sorusu için farklı kontrol kümeleri, fonksiyonel biçimler, etkileşimler veya tahmin yöntemleri denenebilir. Örneğin ücret denkleminde eğitim doğrusal mı girmeli, eğitim düzeylerine kuklalar mı eklenmeli, deneyim ikinci dereceden mi yoksa daha yüksek dereceden bir polinomla mı modellenmelidir?

Bu seçeneklerin her biri aynı anakütle ilişkisini farklı bir tahmin ediciyle yaklaşıklar.

Hansen bu nedenle “model seçimi” ifadesinin aslında çoğu zaman *tahmin edici seçimi* olduğunu vurgular (Hansen, 2021). Araştırmacı aynı veri üretim süreci için farklı kısıtlar ve farklı tahmin kuralları arasında karar verir.

Model seçimi

Bir aday tahmin ediciler kümesi

$$\mathcal{M} = \{M_1, \dots, M_J\}$$

içinden, önceden tanımlanmış bir kayıp veya seçim ölçütüne göre bir tanesinin seçilmesidir. Seçim ölçütünün neyi ödüllendirdiği, “en iyi” modelin ne anlama geldiğini belirler.

Buradaki ilk temel ayrım şudur:

- **Tahmin amacı:** Yeni gözlemlerde düşük tahmin hatası isteriz.
- **Yapısal/ekonomik yorum amacı:** Belirli katsayıların ekonomik anlamıyla ilgileniriz.
- **Nedensel çıkarım amacı:** Bir tahmin hedefi için tanımlama ve geçerli standart hata isteriz.

Bu amaçlar her zaman aynı modeli seçmez. Bir algoritma dış-örneklem tahmininde çok başarılı olabilir; fakat katsayılarının tek tek nedensel yorumu olmayabilir. Tersine, nedensel bir tasarım tahmin performansını maksimize etmek amacıyla kurulmamış olabilir.

Sık yapılan hata

Yüksek R^2 , düşük eğitim hatası veya çok sayıda “anlamlı” katsayı tek başına iyi model seçimi ölçütü değildir. Model seçimi için önce hangi kaybın veya hangi estimand’ın önemli olduğu açıkça tanımlanmalıdır.

Bir araştırmacı çok sayıda aday regresör, dönüşüm veya etkileşim arasından veri kullanarak model seçtiğinde artık tek bir önceden sabit model tahmin etmiyordur. Seçim kuralı da tahmin prosedürünün parçasıdır. Aynı veri hem “hangi modeli kullanacağımıza” karar vermek hem de seçilen modelin katsayılarına klasik standart hata atamak için kullanıldığında, model seçimi belirsizliği sıradan OLS formülünde görünmez.

Bu ayrım öngörü ile çıkarım arasında önemlidir. Öngöründe amaç yeni gözlemlerde hata minimize etmek olabilir ve esnek seçim yöntemleri doğrudan bu hedefe göre değerlendirilebilir. Yapısal veya nedensel katsayı çıkarımında ise ilgilenilen düşük boyutlu parametrenin seçime rağmen güvenilir örnekleme dağılımına sahip olması gerekir. Bölüm 12’de double selection ve DML tam olarak bu ikinci probleme yanıt verecektir.

11.2 Yanlılık–Varyans Dengesi

Basit model daha az parametre tahmin eder. Bu, tahmin varyansını azaltabilir; fakat doğru ilişkinin bazı bileşenleri dışarıda kalırsa yanlılık doğurabilir. Karmaşık model daha esnek olduğu için yaklaşık yanlılığı azaltabilir; fakat daha çok katsayı tahmin edildiği için varyans artabilir.

Bir tahmin edici için ortalama karesel hata

$$MSE(\hat{\theta}) = \text{var}(\hat{\theta}) + \{\text{Bias}(\hat{\theta})\}^2 \quad (11.1)$$

şeklinde ayrıştırılır. Çok boyutlu durumda aynı mantık uygun matris ağırlıklarıyla uygulanır. Hansen'in Bölüm 28'deki basitleştirilmiş örneği, model seçiminin özündeki bu ödünleşimi görünür kılar: daha fazla serbestlik daha düşük kısıt yanlışlığı fakat daha yüksek tahmin varyansı getirebilir (Hansen, 2021).

Aşırı uyum nedir?

Model eğitim örneklemindeki rassal gürültünün bir bölümünü gerçek sinyalmiş gibi öğrenirse eğitim hatası düşer; fakat yeni gözlemlerde hata artabilir. Buna *aşırı uyum* (overfitting) denir. Düzenleştirme ve çapraz doğrulama bu riski yönetmek için kullanılan iki temel araçtır.

Modeli karmaşıktırmak örneklem içi uyumu hemen hemen her zaman artırır; fakat yeni verideki hata aynı yönde hareket etmek zorunda değildir.

Düzenleştirme bu dengeyi katsayıları bilinçli biçimde sıfıra doğru çekerek kurar. Böylece küçük bir yanlışlık kabul edilip tahmin varyansı azaltılabilir. Bu fikir klasik “yansız tahmin her zaman en iyidir” sezgisinin öngörü bağlamında neden eksik olduğunu gösterir. MSE hem yanlışlığın karesini hem varyansı içerir.

11.3 AIC ve BIC: Uyum ile Karmaşıklık Birlikte Değerlendirmek

Doğrusal regresyonda K tahmin edilen parametre sayısını ve

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n \hat{e}_i^2$$

OLS hata varyansı tahminini gösterebilir.

Sık yapılan hata

K sayılırken hata varyansı σ^2 de bir parametredir. Modelde k adet regresyon katsayısı varsa

$$K = k + 1$$

olur (Hansen, 2021). Yalnız eğim ve sabit terimleri sayıp σ^2 'yi unutmak, aday modeller aynı sayıda ek parametre içermediğinde AIC/BIC sıralamasını değiştirebilir. Ayrıca $\hat{\sigma}^2$ paydasında n kullanılır, $n - k$ değil.

Hansen'in kullandığı sabitleri de içeren biçimde

$$AIC = n + n \log(2\pi\hat{\sigma}^2) + 2K, \quad (11.2)$$

$$BIC = n + n \log(2\pi\hat{\sigma}^2) + K \log n. \quad (11.3)$$

Aynı aday modeller arasında karşılaştırma yapıldığında ilk sabit terimler ortak olduğundan esas olarak

$$n \log(\hat{\sigma}^2) + \text{karmaşıklık cezası}$$

karşılaştırılır. **Daha küçük AIC/BIC tercih edilir.**

Likelihood tabanlı modeller için genel biçimler

$$AIC = -2\ell_n(\hat{\theta}) + 2K, \quad (11.4)$$

$$BIC = -2\ell_n(\hat{\theta}) + K \log n. \quad (11.5)$$

şeklindedir.

$n > e^2 \simeq 7,39$ olduğunda $\log n > 2$ olduğu için BIC'in ek parametre cezası AIC'den daha yüksektir. Bu nedenle BIC çoğu tipik örneklemede daha parsimonik model seçmeye eğilimlidir.

AIC ile BIC aynı hedefi mi taşır?

Tam olarak değil. Hansen, AIC'nin tahmin/riske yakın bir ölçüt olarak, BIC'in ise doğru sonlu-boyutlu modelin aday kümede bulunduğu çerçevede daha güçlü model-tanımlama özellikleriyle motive edildiğini tartışır. Uygulamada ikisinin farklı modeller seçmesi olağandır (Hansen, 2021).

Hansen'in CPS ücret uygulamasında dokuz aday spesifikasyon karşılaştırılır. BIC daha parsimonik bir modeli seçerken AIC ve çapraz doğrulama daha zengin bir spesifikasyona yönelir; tahmin edilen 0–30 yıllık deneyim getirisi seçilen modele göre anlamlı biçimde değişir. Bu örnek, seçim ölçütünü raporlamanın neden önemli olduğunu gösterir (Hansen, 2021).

Bu nedenle “AIC mi BIC mi daha iyi?” sorusunun bağlamdan bağımsız cevabı yoktur. Amaç doğru model seçimi varsayımı altında parsimonik spesifikasyon mu, yoksa tahmin riskini azaltmak mı? Ayrıca aday model kümesi yalnızca iki kriter de yanlış adaylar arasında seçim yapar. Bilgi kriterleri araştırma tasarımının ve ekonomik gerekçenin yerine geçmez.

11.4 Ayırma Örnekleme (Hold-Out): Eğitim ve Test Örnekleme

Tahmin performansını değerlendirmenin en doğrudan yolu veriyi iki parçaya ayırmaktır:

- **eğitim örnekleme:** model tahmin edilir,
- **test örnekleme:** tahmin edilmiş modelin daha önce görmediği gözlemlerde performans ölçülür.

Regresyon için test kaybı örneğin

$$MSE_{test} = \frac{1}{n_{test}} \sum_{i \in test} (Y_i - \hat{Y}_i)^2 \quad (11.6)$$

olabilir.

Bu yöntem sezgiseldir fakat tek bölme iki sorun doğurur. Birincisi, model daha küçük eğitim örneklemeyle tahmin edilir. İkincisi, sonuç rassal bölmeye duyarlıdır. Hansen bu iki sorunu çapraz doğrulamanın temel motivasyonu olarak verir (Hansen, 2021).

Kritik nokta şudur: test verisi model seçimi sırasında tekrar tekrar kullanılırsa artık gerçek bir örneklem-dışı değerlendirme değildir; araştırmacı test kümesine de aşırı uyum sağlayabilir.

Özellikle küçük örneklemede tek bir train/test bölmesi sonuçları rastlantısal hale getirebilir. Farklı seed'ler farklı model sıralamaları üretebilir. K-katlı çapraz doğrulama veriyi daha verimli

kullanarak bu oynaklığı azaltır; ancak nihai performans raporunda bağımsız bir test seti varsa onun seçime karışmaması önemlidir.

11.5 Leave-One-Out ve K-Katlı Çapraz Doğrulama

Dışarıda bırakma çapraz doğrulaması (LOOCV) her gözlemi sırayla bir kez dışarıda bırakır. $\hat{\theta}_{(-i)}$ i 'inci gözlem olmadan tahmin edilmiş parametre ise tahmin hatası

$$\tilde{e}_i = Y_i - g(X_i, \hat{\theta}_{(-i)})$$

ve kareli kayıp için

$$CV_{LOO} = \frac{1}{n} \sum_{i=1}^n \tilde{e}_i^2 \quad (11.7)$$

olur.

OLS'de leverage değerleri h_{ii} kullanılarak LOOCV hatası yeniden n regresyon tahmin etmeden hesaplanabilir:

$$\tilde{e}_i = \frac{\hat{e}_i}{1 - h_{ii}}, \quad CV_{LOO} = \frac{1}{n} \sum_{i=1}^n \left(\frac{\hat{e}_i}{1 - h_{ii}} \right)^2. \quad (11.8)$$

Daha genel ve yaygın yöntem K -katlı çapraz doğrulamadır. Örneklem K yaklaşık eşit parçaya bölünür. Her turda bir kat değerlendirme için ayrılır, kalan $K - 1$ kat üzerinde model tahmin edilir. Kat kayıpları ortalananır:

$$CV_K = \frac{1}{K} \sum_{k=1}^K CV_k. \quad (11.9)$$

Hansen $K = 10$ seçiminin yaygın olduğunu belirtir. K çok büyürse hesaplama maliyeti artar; çok küçük K ise her eğitim örneklemini gereğinden fazla küçültür (Hansen, 2021).

Bir standart hata kuralı

En küçük CV'yi veren model yerine, minimum CV değerinin bir standart hatası içinde kalan *en parsimonik* model seçilebilir. Hansen bu "1se" kuralının daha güçlü düzenleştirmeye, dolayısıyla daha yüksek yanlılık ve daha düşük varyansa eğilimli olduğunu vurgular (Hansen, 2021).

LOOCV, $K = n$ özel durumudur; uygulamada $K = 5$ veya $K = 10$ yaygın seçimlerdir.

CV'nin doğru uygulanması için bütün veri-temelli ön işleme adımları kat içinde öğrenilmelidir. Standardizasyon ortalaması ve standart sapması, eksik değer imputasyonu, özellik seçimi ve hatta bazı dönüşüm kararları bütün veri üzerinde önceden hesaplanırsa değerlendirme gözlemleri eğitim sürecine bilgi sızdırır. Bu veri sızıntısı, tahmin performansını yapay biçimde iyimser gösterebilir.

11.6 Yüksek Boyutlu Regresyon

Klasik çoklu regresyonda genellikle p , yani açıklayıcı değişken sayısı, n 'den oldukça küçüktür. Modern veri setlerinde ise çok sayıda ham değişken, etkileşim, polinom, sabit etki veya metin/anket

göstergesi üretilebilir. p büyüdükçe

$$\mathbf{X}'\mathbf{X}$$

matrisi kötü koşullu olabilir. Bu bölümde ceza uygulanacak p eğim regresörü ortalanmış, sabit terim ayrı tutulmuştur. Ortalanmış tasarımın rankı en fazla $n - 1$ olduğundan $p \geq n$ iken standart OLS katsayı çözümü tek değildir.

Seyreklik (sparsity)

Yüksek boyutlu modelde çok sayıda aday değişken bulunmasına rağmen bunların görece küçük bir alt kümesinin önemli olduğu varsayımına seyreklik denir. Yaklaşık seyreklikte katsayıların çoğu tam sıfır olmak zorunda değildir; fakat küçük katsayıların toplu etkisi sınırlıdır.

Hansen'in Bölüm 29'u Ridge ve Lasso'yu bu yüksek boyutlu çerçevede ele alır (Hansen, 2021).

11.7 Düzenlileştirmenin Genel Fikri

OLS

$$\hat{\beta}_{OLS} = \arg \min_{\beta} \|\mathbf{Y} - \mathbf{X}\beta\|_2^2$$

ile yalnız örneklem içi uyumu maksimize eder. Düzenlileştirme, amaç fonksiyonuna katsayı büyüklüğünü cezalandıran bir terim ekler:

$$\hat{\beta}_{\lambda} = \arg \min_{\beta} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda P(\beta) \right\}. \quad (11.10)$$

Burada $\lambda \geq 0$ ceza parametresidir. $\lambda = 0$ OLS'ye döner; λ büyüdükçe katsayıların serbestliği azalır.

Ceza, tahmin ediciye bilinçli yanlılık ekleyebilir. Amaç, varyanstaki düşüşün yanlılıktaki artıştan daha değerli olduğu bir MSE dengesi elde etmektir.

11.7.1 Neden standartlaştırma gerekir?

Ridge ve Lasso katsayıların büyüklüğünü doğrudan cezalandırdığı için ölçü birimine duyarlıdır. Bir değişken TL, diğeri milyon TL cinsinden ölçülüyorsa aynı ekonomik ilişki farklı ceza görebilir. Bu nedenle açıklayıcı değişkenler çoğunlukla

$$X_{ij}^{std} = \frac{X_{ij} - \bar{X}_j}{s_j}$$

ile standartlaştırılır. Sabit terim genellikle cezalandırılmaz.

Sık yapılan hata

Standartlaştırmadan sonra Lasso katsayılarının büyüklüğü orijinal birimlerdeki ekonomik marjinal etki değildir. Ekonomik yorum için katsayılar gerektiğinde yeniden orijinal ölçeğe dönüştürülmelidir.

Standardizasyon parametreleri eğitim verisinden hesaplanmalı ve değerlendirme ile test verisine aynı değerlerle uygulanmalıdır. Bu küçük görünen adım, doğru CV protokolünün temel parçasıdır.

Ceza biçimi hangi katsayı yapılarını tercih ettiğimizi belirler: L_2 cezası (Ridge) yaygın biçimde küçültülmüş katsayılar, L_1 cezası (Lasso) ise seyrek sıfırlar üretmeye eğilimlidir. Her iki durumda da değerlendirme kriteri MSE veya örneklem-dışı kayıptır; örneklem içi uyum değil.

11.8 Ridge Regresyonu

Hansen §29.5'i izleyerek burada $\mathbf{X} \in \mathbb{R}^{n \times p}$ ortalanmış (gerektiğinde standartlaştırılmış) eğim regresörleri matrisi, $\mathbf{Y} \in \mathbb{R}^n$ ortalanmış sonuç vektörüdür. $\beta \in \mathbb{R}^p$ yalnız eğimleri içerir; sabit terim ceza dışında $\bar{Y} - \bar{X}'\hat{\beta}$ ile geri alınır. $\mathbf{I}_p$, $p \times p$ birim matristir. Ridge, L_2 cezası kullanır:

$$\hat{\beta}_{ridge}(\lambda) = \arg \min_{\beta} \{(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + \lambda\beta'\beta\}. \quad (11.11)$$

Birinci derece koşul

$$-2\mathbf{X}'(\mathbf{Y} - \mathbf{X}\beta) + 2\lambda\beta = 0$$

verir. Dolayısıyla

$$\hat{\beta}_{ridge} = (\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1}\mathbf{X}'\mathbf{Y}. \quad (11.12)$$

OLS'den fark, $\mathbf{X}'\mathbf{X}$ matrisine $\lambda\mathbf{I}_p$ eklenmesidir. Bu işlem küçük özdeğerleri yukarı iter ve kollineariteye karşı sayısal istikrar sağlar. Fakat $\lambda > 0$ olduğunda Ridge genel olarak yanlıdır. Hansen, belirli ceza aralıklarında bu yanlılığın varyans azalmasıyla telafi edilerek MSE'nin OLS'den daha düşük olabileceğini gösterir (Hansen, 2021).

Ridge katsayıları tipik olarak sifra yaklaşır fakat tam olarak sıfır olmaz. Bu nedenle Ridge esasen **küçültme** yöntemidir, doğrudan değişken seçimi yöntemi değildir.

Sık yapılan hata

Denklem (11.11) Hansen'in ölçeğidir; scikit-learn `Ridge(alpha= $\lambda$ )` aynı ölçeği kullanır. R'deki `glmnet` ve Stata'daki `elasticnet` ise Ridge amacını $\frac{1}{2n}(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + \frac{\lambda_y}{2}\beta'\beta$ biçiminde yazar; iki ölçek arasında $\lambda = n\lambda_y$ ilişkisi vardır. Yazılımdan bir ceza değeri raporlarken ölçeği de belirtmek gerekir.

Yüksek korelasyonlu regresörlerde OLS katsayıları çok oynakken Ridge öngörü performansını belirgin biçimde iyileştirebilir (Hoerl ve Kennard, 1970). Bunun nedeni **denklem (11.12)**'de görülür: ceza, $\mathbf{X}'\mathbf{X}$ matrisinin köşegenine pozitif bir miktar ekleyerek çok küçük özdeğerleri stabilize eder.

Standartlaştırılmış ve ortalanmış tasarımda Ridge çözümünün özdeğer sezgisi özellikle öğreticidir. Karışıklığı önlemek için ceza parametresini λ , özdeğerleri ise $r_1, \dots, r_p$ ile gösterelim. $\mathbf{X}'\mathbf{X} = \mathbf{H}'\mathbf{D}\mathbf{H}$ spektral ayrışımı olsun; burada $\mathbf{D} = \text{diag}(r_1, \dots, r_p)$ ve $\mathbf{H}$, $p \times p$ ortonormal matristir ($\mathbf{H}'\mathbf{H} = \mathbf{I}_p$). Bu $\mathbf{D}$ özdeğer matrisi, diğer bölümlerdeki skaler tedavi D ile farklıdır. OLS her öz-yönde $1/r_j$ ile ölçekler; küçük r_j değerleri gürültüyü büyütür. Ridge ise

$$(\mathbf{X}'\mathbf{X} + \lambda\mathbf{I}_p)^{-1} = \mathbf{H}'(\mathbf{D} + \lambda\mathbf{I}_p)^{-1}\mathbf{H}$$

kullanır. Böylece j 'inci öz-yöndeki ölçek $1/r_j$ yerine $1/(r_j + \lambda)$ olur. Büyük r_j yönlerinde λ göreceli olarak önemsizdir; küçük r_j yönlerinde ise küçültme çok daha güçlüdür. Bu, çoklu doğrusal bağlantı probleminin tahmin varyansı boyutunu doğrudan stabilize eder.

Ridge katsayılarının birim bağımlılığı standardizasyonun önemini tekrar gösterir. Ceza sonrası

katsayıları ekonomik birimlerde yorumlamak için gerekli geri dönüşüm yapılmalıdır.

11.9 Lasso: Küçültme ve Değişken Seçimini Birleştirmek

Lasso L_1 cezası kullanır:

$$\hat{\beta}_{Lasso}(\lambda) = \arg \min_{\beta} \left\{ (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + \lambda \sum_{j=1}^p |\beta_j| \right\}. \quad (11.13)$$

$|\beta_j|$ fonksiyonu sıfırda türevlenebilir değildir. Bu geometrik özellik, bazı katsayıların çözümde tam sıfıra oturmasına yol açar. Böylece Lasso hem shrinkage hem de değişken seçimi yapar. Özellikle p büyük olduğunda bu özellik yorumlanabilir bir alt model üretmek için çekicidir.

Sık yapılan hata

Denklem (11.13) Hansen'in SSE ölçeğidir. scikit-learn `Lasso(alpha= $\lambda_y$ )`, R `glmnet` ve Stata `lasso` aynı problemi

$$\hat{\beta}_{Lasso} = \arg \min_{\beta} \left\{ \frac{1}{2n} (\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + \lambda_y \sum_{j=1}^p |\beta_j| \right\}$$

biçiminde çözer. İki ölçek arasında $\lambda = 2n\lambda_y$ ilişkisi vardır: aynı çözüm SSE ölçeğinde $2n$ kat büyük bir ceza değerine karşılık gelir. Bu notlarda yazılımdan raporlanan Lasso ve Elastic Net cezaları λ_y ile gösterilir.

Ortogonalleştirilmiş basit tasarımda Lasso çözümü yumuşak eşikleme (soft-thresholding) biçiminde görülebilir. OLS katsayısı $\hat{\beta}_j^{OLS}$ olsun. Uygun ölçeklemede Lasso yaklaşık olarak

$$\hat{\beta}_j^{Lasso} = \text{sign}(\hat{\beta}_j^{OLS}) \left(|\hat{\beta}_j^{OLS}| - c_{\lambda} \right)_+ \quad (11.14)$$


şeklinde davranır. Burada $(a)_+ = \max(a, 0)$ ve c_{λ} ceza büyüklüğüne bağlı bir eşiktir. Küçük OLS katsayıları sıfırlanır; büyük katsayılar sıfıra doğru küçülür.

Lasso “doğru değişkenleri” mutlaka seçer mi?

Hayır. Özellikle yüksek korelasyon, zayıf sinyal veya küçük örneklemde Lasso eşdeğer değişkenlerden birini seçip diğerini dışarıda bırakabilir. Değişken seçimi sonuçları veri ve ceza parametresine bağlıdır. Lasso'nun tahmin başarısı ile doğru yapısal değişken kümesini bulması aynı hedef değildir.

Ancak seçilen değişkenleri “gerçek önemli değişkenler” olarak yorumlamak dikkat ister. Yüksek korelasyonlu regresörler arasında Lasso birini seçip diğerini dışlayabilir ve küçük örneklem değişiklikleri seçim setini değiştirebilir. Seçim kararlılığı, tahmin performansı ve hedef parametre çıkarımı ayrı meselelerdir. Lasso esas olarak bir öngörü ve düzenlileştirme aracıdır; klasik p -değerleri doğrudan Lasso katsayılarına uygulanmaz (Tibshirani, 1996; Hansen, 2021).

Denklem (11.14)'deki yumuşak eşikleme, OLS katsayısı eşikten küçükse tam sıfır, büyükse sıfıra doğru küçültülmüş bir değer verir. Çoklu korelasyonlu tasarımda çözüm daha karmaşıktır fakat bu basit form L_1 cezasının neden tam sıfırlar ürettiğini açıklar.



Şekil 11.1: Kontrollü örnekte (bölüm 11.14) Lasso katsayı yolu. Mavi çizgiler gerçek katsayısı sıfırdan farklı beş değişkendir; kesikli çizgi 10-katlı çapraz doğrulamayla seçilen ceza düzeyini (λ_y , yazılım ölçeği) gösterir.

Katsayı yolu grafiği λ azaldıkça değişkenlerin modele hangi sırada girdiğini gösterir. Bu sıra nedensel önem sırası değildir; ölçek, korelasyon ve örnekleme gürültüsünden etkilenir.


11.10 Ceza Parametresi Nasıl Seçilir?

λ çok küçükse model OLS'ye yaklaşır ve aşırı uyum riski artar. Çok büyükse katsayılar aşırı küçülür ve underfitting oluşabilir. En yaygın veri-temelli seçim K -katlı çapraz doğrulamadır:

1. Bir λ ızgarası belirle.
2. Her λ için K -katlı CV tahmin hatasını hesapla.
3. Minimum CV'yi veren $\hat{\lambda}_{min}$ veya 1se kuralıyla daha parsimonik $\hat{\lambda}_{1se}$ seç.
4. Seçilen ceza ile modeli tüm eğitim örnekleminde yeniden tahmin et.

λ model karmaşıklığını kontrol eder. Çok küçük λ OLS'e yakın, çok büyük λ aşırı küçültülmüş model üretir. Öngörü amacıyla λ çoğunlukla K -katlı CV ile seçilir. CV hatasını minimize eden değer kadar, minimumdan istatistiksel olarak çok farklı olmayan daha parsimonik bir değeri seçen “bir standart hata” türü kurallar da kullanılabilir.

Çıkarım amaçlı teorik Lasso uygulamalarında ise ceza parametresi yalnız öngörü CV'sine bırakılmayabilir; hata dağılımı ve yüksek boyutlu moment sınırlarıyla ilişkili teori-temelli seçimler vardır. Bölüm 12'de double selection bağlamında bu ayrımın neden önemli olduğunu göreceğiz.



Şekil 11.2: Kontrollü örnekte Ridge ceza parametresinin 10-katlı çapraz doğrulamayla seçimi. Kesikli çizgi CV hatasının en küçük olduğu cezadır.

11.11 Elastic Net

Ridge korelasyonlu değişkenleri birlikte küçültmeye eğilimliyken Lasso bunlardan bazılarını sıfırlayabilir. Elastic Net iki cezayı birleştirir. Hansen'in notasyonunda

$$\hat{\beta}_{EN} = \arg \min_{\beta} \left\{ \|\mathbf{Y} - \mathbf{X}\beta\|_2^2 + \lambda \left[\alpha \|\beta\|_2^2 + (1 - \alpha) \|\beta\|_1 \right] \right\}, \quad 0 \leq \alpha \leq 1. \quad (11.15)$$

$\alpha = 0$ Lasso, $\alpha = 1$ Ridge verir. Uygulamada λ ve karışım parametresi birlikte CV ile seçilebilir (Hansen, 2021).

Sık yapılan hata

Yazılımlarda karışım parametresi ters yönde tanımlanır: R `glmnet` `alpha` ve `scikit-learn` `l1_ratio` L_1 cezasının ağırlığıdır, yani $r = 1 - \alpha$ ve $r = 1$ Lasso'dur. Amaç fonksiyonu da $\frac{1}{2n}(\mathbf{Y} - \mathbf{X}\beta)'(\mathbf{Y} - \mathbf{X}\beta) + \lambda_y \left[r \|\beta\|_1 + \frac{1-r}{2} \|\beta\|_2^2 \right]$ ölçeğindedir.

Elastic Net L_1 ve L_2 cezalarını birleştirerek Lasso'nun seyrek seçim özelliği ile Ridge'in korelasyonlu değişken gruplarını birlikte küçültme davranışı arasında ara çözüm sunar. Çok güçlü korelasyon altında Lasso benzer değişkenlerden birini rastlantısal seçebilirken Elastic Net grup halinde tutmaya daha yatkın olabilir.

İki tuning boyutu vardır: toplam ceza gücü ve L_1 - L_2 karışım oranı. Bu parametreler çapraz doğrulama ile birlikte seçilebilir. Sonuçta seçilen özellik kümesi ve performans bu tuning ızgarasına duyarlı olduğundan protokol açık raporlanmalıdır.

11.12 Post-Lasso

Lasso seçtiği katsayıları da sıfıra doğru küçülttüğü için tahminde shrinkage yanlılığı yaratır. Post-Lasso iki aşamalı bir yöntemdir:

1. Lasso tahmin et ve sıfırdan farklı katsayılara sahip değişken kümesini S olarak belirle.
2. Y 'yi yalnız X_S üzerinde OLS ile yeniden tahmin et.

Dolayısıyla

$$\hat{\beta}_S^{PL} = (\mathbf{X}_S' \mathbf{X}_S)^{-1} \mathbf{X}_S' \mathbf{Y}. \quad (11.16)$$

Bu ikinci aşama shrinkage yanlılığını azaltır. Ancak seçim ilk aşamada aynı veriyle yapıldığı için Post-Lasso **post-model-selection** tahmin edicisidir.

Lasso katsayıları ceza nedeniyle sıfıra doğru küçültülür. Post-Lasso önce Lasso'nun seçtiği değişken kümesini belirler, sonra bu değişkenler üzerinde cezasız OLS çalıştırır. Amaç seçilen model sabit kabul edildiğinde shrinkage bias'ını azaltmaktır.

Post-Lasso öngöründe yararlı olabilir; ancak seçimin kendisi veriden geldiği için klasik OLS çıkarımı otomatik olarak geçerli değildir. Hedef katsayı çıkarımı için selection uncertainty'yi özel olarak ele alan yöntemlere ihtiyaç vardır.

11.13 Model Seçimi Sonrası Çıkarım Problemi

Klasik OLS standart hataları, modelin veri görülmeden sabitlenmiş olduğunu varsayan dağılım sonuçlarına dayanır. Oysa veri önce hangi değişkenlerin modele gireceğini belirliyor, sonra aynı veriyle katsayı ve standart hata hesaplanıyorsa seçim olayı tahmin edicinin dağılımının bir parçası hâline gelir.

Hansen'in Bölüm 28.17'deki simülasyonu, standart güven aralıklarının model seçimi sonrasında nominal kapsamanın çok altına düşebileceğini gösterir (Hansen, 2021). Sorun yalnız “fazla değişken denedik” biçiminde sözel bir endişe değildir; tahmin edicinin dağılımı artık seçim kuralına bağlı ve genellikle standart normal yaklaşım değildir.

Sık yapılan hata

Lasso'dan sonra seçilen değişkenler üzerinde sıradan OLS çalıştırıp klasik yüzde 95 güven aralığı vermek, yalnız Post-Lasso kullanıldığı için otomatik olarak geçerli çıkarım sağlamaz. Bölüm 12'de double selection, partialling-out ve DML bu problemi belirli bir düşük-boyutlu hedef parametre için çözmeye çalışan yöntemler olarak ele alınacaktır.

Bir değişken yalnız örnekleme güçlü görüldüğü için seçildiğinde, seçilen katsayıların dağılımı klasik “model önceden sabitti” dağılımından farklıdır. Küçük katsayılar elendiği için kalan katsayılar seçimden kaynaklanan winner's curse benzeri büyütülmüş değerler gösterebilir. Aynı süreç standart hata ve p-değerlerinde aşırı iyimserliğe yol açabilir.

Post-Lasso seçilen değişkenler üzerinde yeniden OLS çalıştırarak shrinkage bias'ını azaltır; fakat değişken seçiminin belirsizliğini tek başına ortadan kaldırmaz. Hedef düşük boyutlu bir D katsayısıysa, model seçiminin bu hedefe zarar vermesini önlemek için double selection, orthogonalization ve DML gibi özel yöntemler gerekir.

11.14 Kontrollü Uygulama: Ridge, Lasso ve Post-Lasso

Düzenlileştirmenin davranışını görünür kılmak için $n = 320$, $p = 40$ olan kontrollü bir veri üretim süreci kullandık. Açıklayıcı değişkenler birim varyanslı ve orta düzey korelasyonludur: $\text{corr}(X_j, X_k) = 0,45^{|j-k|}$. Gerçek katsayı vektöründe yalnız beş değişken ($X_1, X_2, X_5, X_{10}, X_{20}$) sıfırdan farklıdır; hata standart sapması 1,6'dır. İlk 224 gözlem (yüzde 70) eğitim, son 96 gözlem test örneklemidir. Ceza parametreleri eğitim örnekleminde 10-katlı CV ile seçilmiştir; kat, gözlem sırasının 10'a bölümünden kalana göre belirlenir. Gözlemler bağımsız çekildiği için sıraya dayalı bu bölme rastgele bölmeyle aynı dağılıma sahiptir. X 'ler birim varyansla üretildiği için standartlaştırma gerekmemiştir. Bu veri üretim süreci uygulamanın Sezgi sekmesindeki Konu 11 Deney 1'in varsayılan ayarlarıdır (tohum 80711).

On-katlı CV ile Ridge için $\hat{\lambda} = 20,1$ (SSE ölçeği), Lasso için $\hat{\lambda}_y = 0,138$ (yazılım ölçeği; SSE ölçeğinde $2 \cdot 224 \cdot 0,138 \simeq 62$) seçilmiştir. Lasso beş gerçek sinyalin tamamını yakalamış ve toplam sekiz değişkeni sıfırdan farklı bırakmıştır. Elastic Net için CV L_1 ağırlığı $r = 0,8$ (Hansen gösteriminde $\alpha = 0,2$) ve $\hat{\lambda}_y = 0,084$ seçmiş, 24 değişken bırakmıştır. Sonuçlar [tablo 11.1](#) içindedir.

Tablo 11.1: Kontrollü örnekte düzenlileştirme yöntemlerinin test performansı

Yöntem	Test MSE	$\ \hat{\beta}\ _2$	Sıfırdan farklı katsayı
OLS (tüm X)	2,836	2,305	40
Ridge	2,820	1,922	40
Lasso	2,584	1,615	8
Elastic Net	2,442	1,835	24
Post-Lasso	2,164	2,093	8


Bu tek simülasyonda en düşük test MSE'yi Post-Lasso vermektedir: Lasso'nun seçtiği sekiz değişken üzerinde cezasız EKK, Lasso'nun seçilen katsayılarla uyguladığı küçültmeyi geri alır. Ridge 40 katsayının hepsini küçülttüğü için OLS'e yakın kalır. Bunun evrensel bir sıralama olmadığını özellikle vurgulamak gerekir. Veri üretim süreci, sinyal gücü, korelasyon yapısı ve örneklem büyüklüğü değiştiğinde sıralama değişebilir. Burada temel ders, eğitim uyumu yerine dış-örneklem kaybının değerlendirilmesi ve ceza parametresinin veri-temelli fakat önceden tanımlanmış bir prosedürle seçilmesidir.

Uygulamada eğitim hatası, CV hatası ve bağımsız test hatasını ayrı izlemek önemlidir. Model karmaşıklığı arttıkça eğitim hatası monoton düşebilir; CV/test hatası ise U-biçimli davranabilir. Minimum test hatası yalnız değerlendirme için kullanılmalı, tuning test setine bakılarak yapılmamalıdır.

Test MSE'lerinin karşılaştırılması katsayı yapısını göstermez: Ridge 40 değişkenin hepsini küçültülmüş katsayılarla tutarken Lasso sekiz değişkenlik seyrek bir çözüm üretir. İki yöntem benzer test hatası verdiğinde bile seçilen yapı farklı olabilir. Yorumlanabilirlik, öngörü ve yapısal çıkarım farklı kriterlerdir.

11.15 Ampirik Uygulama Laboratuvarı: Model Seçimini Gerçek-ten Dış-Örnekleme Değerlendirmek

Kontrollü simülasyonlar Ridge ve Lasso'nun mekanizmasını öğretmek için yararlıdır; fakat tez öğrencisinin asıl görmesi gereken şey gerçek veride model seçiminin nasıl raporlandığıdır. Bu



Şekil 11.3: Kontrollü örnekte farklı tahmin edicilerin test örnekleme MSE değerleri.

uygulamada Hansen'in CPS ücret verisinin tamamını (50.742 gözlem) kullanıyor, gözlemlerin yaklaşık yüzde 75'ini eğitim ve yüzde 25'ini test örnekleme ayırıyoruz.

Bölme rastgele sayı üreticiyle değil, açık bir kuralla yapılır. Gözlemin dosyadaki sıra numarası i olmak üzere

$$u_i = \{i\varphi\}, \quad \varphi = \frac{\sqrt{5} - 1}{2} \simeq 0,618,$$

$\{\cdot\}$ kesirli kısmı gösterir. $u_i < 0,25$ olan 12.687 gözlem test, kalan 38.055 gözlem eğitim örnekle midir. Eğitim örnekleminde çapraz doğrulama katı $\lfloor (u_i - 0,25)/0,15 \rfloor + 1$ 'dir; beş kat 7.610–7.612 gözlem içerir. $\{i\varphi\}$ dizisi $[0, 1)$ aralığına düzgün yayıldığı için bu bölme dengeli bir rastgele bölme gibi davranır; kural açık olduğu için Python, R ve Stata aynı bölmeyi ve aynı sayıları üretir.

Araştırma amacı bu kez **nedensel eğitim getirisi değil, log ücret tahmin performansıdır**. Bu ayrım model seçimi bölümünün merkezindedir: tahmin için iyi bir model, belirli bir katsayı için güvenilir nedensel model olmak zorunda değildir.

11.15.1 Adım 1: Aday modeller

Dört yaklaşımı karşılaştırıyoruz:

1. yalnız eğitim, deneyim, deneyim karesi ve cinsiyet kullanan Basit OLS,
2. ek doğrusal olmayan terimler, etkileşimler ve kategori göstergeleri kullanan Zengin OLS,
3. aynı zengin özellik setinde Ridge,
4. aynı zengin özellik setinde Lasso.


Zengin özellik seti sekiz sürekli terimden (eğitim, eğitimin karesi, deneyim, deneyim²/100, deneyim³/1000, kadın, eğitim×kadın, deneyim×kadın) ve bölge, ırk ve Hispanik kökenli olma göstergelerinden oluşur. Göstergeler eğitim örnekleminde görülen düzeylerden kurulur ve ilk düzey referanstır: bölge için 3, ırk için eğitim örnekleminde görülen 19 düzeyden 18, Hispanik için 1 gösterge; toplam 30 terim.

Ridge ve Lasso için sürekli özellikler yalnız eğitim verisinden öğrenilen ortalama ve standart sapmayla standartlaştırılır; kategori göstergeleri ölçeklenmez. Ceza parametresi seçilirken bu

işlemler her çapraz doğrulama katında o katın eğitim verisinden yeniden öğrenilir; nihai modelde bütün eğitim örneklemiyle yapılır. Böylece değerlendirme katından ve test örnekleminde ön işleme aşamasına bilgi sızması engellenir.

Tablo 11.2: CPS uygulaması: test örnekleminde model performansı

Model	Test MSE	Sıfırdan farklı katsayı sayısı	Seçilen ceza
Basit OLS	0,3215	4	–
Zengin OLS	0,3121	30	–
Ridge CV	0,3120	30	$\hat{\lambda} = 3,455$
Lasso CV	0,3119	16	$\hat{\lambda}_y = 0,000143$



Şekil 11.4: CPS uygulamasında dış-örneklem test MSE karşılaştırması

Zengin OLS, Ridge ve Lasso’nun test MSE değerleri birbirine son derece yakındır. Bu sonuç “Ridge kazandı” veya “Lasso başarısız oldu” gibi dramatik bir dil gerektirmez. Veride ek esneklik basit modele göre küçük bir tahmin kazanımı sağlar (0,3215’ten 0,3121’e); düzenlenleştirilmiş modeller bu özellik setinde büyük bir üstünlük yaratmaz. 38.055 eğitim gözlemi ve 30 terimle ceza parametreleri çok küçük seçilmiştir ($\hat{\lambda} = 3,455$ SSE ölçeğinde, $\hat{\lambda}_y = 0,000143$ yazılım ölçeğinde); bu kadar büyük örnekleme düzenlenleştirme OLS’i ancak az değiştirir.

Lasso 30 yerine 16 katsayıyı sıfırdan farklı tutarak daha seyrek bir temsil üretmektedir. Sıfırladığı 14 terim eğitim×kadın etkileşimi ile gözlem sayısı küçük 13 ırk göstergesidir. Seyrek modelin test hatası Zengin OLS’ten yalnız dördüncü ondalıkta farklıdır. Parsimoniklik ile saf tahmin performansı arasında karar verirken araştırma amacı önemlidir.

11.15.2 Adım 2: Test setini tuning için kullanmamak

Lasso ve Ridge ceza parametreleri eğitim verisi içinde 5-katlı çapraz doğrulama ile, aynı katlarda seçilmiştir: Ridge için $\lambda \in [10^{-3}, 10^3]$ aralığında, Lasso için $\lambda_y \in [10^{-4}, 10^{-1}]$ aralığında logaritmik 40 noktalı ızgarada, kat ortalama karesel hatalarının ortalamasını en küçük yapan ceza. Test örneklemini yalnız nihai performans karşılaştırması için kullanılmıştır. Eğer araştırmacı farklı λ değerlerini test setinde deneyip en iyi sonucu seçerse test seti artık bağımsız değerlendirme verisi değildir.

Kod 11.1: Ölçeklemeyi ve ceza seçimini her çapraz doğrulama katının içinde yapmak

```

for k in range(1, 6):
    egt, dog = egitim[egitim.kat != k], egitim[egitim.kat == k]
    # ölçek ve kategori düzeyleri yalnız egt'den öğrenilir
    X_e, X_d = tasarim(egt, dog, surekli, kategorik)
    # ızgara boyunca Lasso yolu (sabit terim cezasız)
    tahmin = ceza_yolu(X_e, egt.lwage, X_d, ızgara, "lasso")
    cv[k - 1] = ((dog.lwage.to_numpy()[:, None] - tahmin) ** 2).mean(0)
lam = ızgara[np.argmax(cv.mean(0))]

```

Kodun önemli yönü Lasso komutunun kendisinden çok, standartlaştırma ve kategori kodlama işlemlerinin de çapraz doğrulama katının içinde yapılmasıdır. scikit-learn'de aynı hesap, `ColumnTransformer` ve `Lasso` içeren bir `Pipeline` nesnesini `GridSearchCV` ile ızgara üzerinde, katları `PredefinedSplit(kat)` ile vererek çalıştırarak da yapılabilir; işlem zinciri her katta yeniden kurulduğu için aynı cezayı seçer. Bu yol her cezada modeli sıfırdan tahmin ettiği için ızgara boyunca sıcak başlangıçlı yoldan belirgin biçimde yavaştır.

11.15.3 Adım 3: Model seçimi tablosunda hangi sayılar görünmeli?

Tahmin amaçlı bir makalede şu bilgiler önemlidir:

1. eğitim, değerlendirme ve test örnekleme tanımı,
2. kayıp fonksiyonu (MSE, MAE, log-loss vb.),
3. tuning yöntemi ve kat sayısı,
4. ön işleme zinciri,
5. seçilen ceza parametresi ve ölçeği,
6. dış-örneklem performans ve mümkünse belirsizliği,
7. farklı seed veya bölmelerde duyarlılık.

Tek bir test MSE'si model seçiminin mutlak sıralamasını kanıtlamaz. Test MSE birkaç aşırı gözleme de duyarlıdır: log ücreti çok düşük birkaç gözlemin test ya da eğitim örnekleme düşmesi MSE düzeyini belirgin biçimde değiştirebilir. Özellikle benzer sonuçlarda tekrarlı çapraz doğrulama veya bootstrap ile performans farkının ne kadar kararlı olduğu incelenebilir.

11.15.4 Adım 4: Tahmin ile yapısal çıkarım ayrımını korumak

Lasso'nun bir kontrol değişkenini sıfırlaması, bu değişkenin nedensel analizde "gereksiz" olduğu anlamına gelmez. Tahmin algoritması Y 'yi en iyi öngören seti arar. Bir hedef katsayının eksik değişken yanlılığından korunması farklı bir problemdir. Bu nedenle Bölüm 12'de outcome-only selection yerine double selection ve ortogonal moment yaklaşımına geçiyoruz.

Tez yazımında doğru sonuç dili

"Zengin OLS ve düzenlenileştirilmiş modeller test örnekleminde benzer hata üretmiştir. Lasso daha seyrek bir model elde etmiş, ancak tahmin performansında belirgin üstünlük sağlamamıştır. Bu karşılaştırma öngörü performansına ilişkindir; seçilen değişkenler nedensel kontrol seti olarak otomatik kabul edilmemiştir."

11.16 Tez Çalışmasında Model Seçimi İçin Pratik Protokol

1. **Estimand'ı belirle:** Bir katsayı mı, tahmin performansı mı, sınıflandırma doğruluğu mu?
2. **Aday model ailesini veri görülmeden mümkün olduğunca tanımla.**
3. **Dönüşümleri işlem zinciri içinde yap:** standartlaştırma, eksik veri işlemi ve özellik üretimi değerlendirme katına bakmadan öğrenilmelidir.
4. **Tuning'i CV ile yap:** test örneklemini tuning için kullanma.
5. **Mümkünse ayrı test örneklemini tut:** son performans değerlendirmesini yalnız bir kez yap.
6. **Seçim belirsizliğini raporla:** benzer CV değerlerine sahip alternatifler varsa tek modelin kesin doğru olduğu izlenimini verme.
7. **Çıkarım yapacaksan selection-aware yöntem kullan:** özellikle düşük boyutlu hedef katsayı için Bölüm 12'deki yöntemleri düşün.

Temel sonuçlar

- Model seçimi bir optimizasyon problemidir; seçilecek model kullanılan kayba bağlıdır.
- AIC ve BIC örneklem içi uyumu karmaşıklık cezasıyla dengeler; BIC tipik örneklemede daha güçlü ceza uygular.
- Çapraz doğrulama doğrudan dış-örneklem tahmin kaybını yaklaşıklar ve çok geniş bir yöntem ailesine uygulanabilir.
- Ridge L_2 cezasıyla katsayıları küçültür; Lasso L_1 cezasıyla küçültme ve değişken seçimini birlikte yapar.
- Post-Lasso shrinkage yanlılığı azaltabilir; fakat model seçimi sonrası standart çıkarım problemi devam eder.
- Tahmin amacı ile bir katsayı için güvenilir nedensel çıkarım amacı birbirinden ayrılmalıdır.

11.17 Bölüm Sonu Egzersizleri

Egzersiz 11.1: AIC–BIC cezası

$n = 200$ olan iki regresyon aynı örneklemede tahmin ediliyor. Model A'da $K = 5$, Model B'de $K = 8$ parametre var. B modelinin -2ℓ değeri A'dan 12 birim daha küçüktür. AIC ve BIC'e göre hangi model seçilir?

Egzersiz 11.2: Yanlılık–varyans

Bir tahmin edici için yanlılık 0,20 ve standart sapma 0,30; başka bir tahmin edici için yanlılık 0,05 ve standart sapma 0,42 olsun. Her iki tahmin edicinin MSE'sini hesaplayıp

karşılaştırm.

Egzersiz 11.3: LOOCV

Üç gözlem için OLS artıkları $(1, -2, 1)$ ve leverage değerleri $(0,2, 0,5, 0,1)$ olsun. denklem (11.8) ile LOOCV MSE'yi hesaplayın.

Egzersiz 11.4: K -katlı CV

Beş kat için MSE değerleri $2,1, 2,5, 2,2, 2,8, 2,4$ olsun. Ortalama CV değerini ve katlar arası örneklem standart sapmasını hesaplayın. Sonucun tek bir train/test bölmesinden neden daha istikrarlı olabileceğini açıklayın.

Egzersiz 11.5: Ridge çözümü

$\mathbf{X}'\mathbf{X} = \text{diag}(4, 1)$, $\mathbf{X}'\mathbf{Y} = (8, 2)'$ ve $\lambda = 1$ olsun. OLS ve Ridge katsayılarını hesaplayın. Hangi katsayı oransal olarak daha fazla küçülmüştür?

Egzersiz 11.6: Ölçekleme

Aynı regresyonda X_1 TL, X_2 milyon TL cinsinden ölçülüyor. Standartlaştırma yapılmadan Lasso uygulanırsa cezanın iki katsayıyı neden karşılaştırılabilir biçimde etkileyebileceğini açıklayın.

Egzersiz 11.7: Soft threshold

Basitleştirilmiş ortogonal tasarımda $c_\lambda = 0,20$ olsun. OLS katsayıları $(0,10, -0,35, 0,80)$ için denklem (11.14) kullanarak Lasso katsayılarını bulun.

Egzersiz 11.8: Post-Lasso

Lasso 30 aday değişkenden 7'sini seçti. Post-Lasso'nun ikinci aşamasını açık biçimde yazın. Post-Lasso katsayılarının Lasso'ya göre neden genellikle mutlak değerce daha büyük olabileceğini açıklayın.

Egzersiz 11.9: 1se kuralı

Üç ceza düzeyi için CV ortalamaları ve minimum noktadaki standart hata şu şekilde olsun: $\lambda = 0,05$: 1,00; $\lambda = 0,10$: 1,03; $\lambda = 0,20$: 1,08. Minimum CV'nin standart hatası 0,05'tir. Daha büyük λ daha parsimonik model veriyorsa 1se kuralı hangi λ 'yı seçer?

Egzersiz 11.10: Tahmin ve çıkarım

Bir Lasso modeli test MSE'yi yüzde 15 düşürüyor, fakat araştırma sorusu “eğitimin ücret üzerindeki nedensel etkisi nedir?” şeklinde. Düşük test MSE'nin neden tek başına bu soruyu yanıtlamadığını açıklayın.

Egzersiz 11.11: Model seçimi sonrası güven aralığı

Araştırmacı 100 alternatif kontrol kümesi deniyor, en yüksek t -istatistiğini veren modeli seçiyor ve o modeldeki klasik yüzde 95 güven aralığını raporluyor. Bu aralığın nominal kapsammasının neden yüzde 95 olmak zorunda olmadığını açıklayın.

Egzersiz 11.12: Uygulama tasarımı

Bir tez veri setinde $n = 1500$, $p = 120$ aday kontrol var. Amaç hem iyi tahmin hem de bir temel değişkenin katsayısı için güvenilir çıkarım yapmak. Eğitim/CV/test ayrımı, standardizasyon, Lasso/Ridge karşılaştırması ve çıkarım aşamasını içeren kısa bir analiz protokolü yazın.

Çift/Yanlılıktan Arındırılmış Makine Öğrenmesi ve Bütünleşik Araştırma Akışı

Bu bölümün amacı

Bu bölümün sonunda yüksek boyutlu kontrol değişkenleri altında düşük boyutlu bir hedef parametrenin neden özel bir çıkarım problemi yarattığını açıklayabilecek; naif değişken seçiminin eksik değişken yanlılığı (omitted-variable bias) üretebileceğini gösterebilecek; double-selection Lasso, artıkleştirme (partialling-out) ve Double/Debiased Machine Learning (DML) algoritmalarını adım adım kurabilecek; ortogonal moment fikrini matematiksel olarak yorumlayabilecek; örneklem bölme (sample splitting) ile çapraz uyarlama (cross-fitting) arasındaki farkı açıklayabilecek; DML’de yardımcı (nuisance) fonksiyonların rolünü ayırabilecek; çapraz-uyarlanmış artıklarla hedef katsayı ve heteroskedastisiteye dayanlı standart hata hesaplayabilecek ve bir tez uygulamasını araştırma sorusundan replikasyon paketine kadar bütünleşik biçimde tasarlayabileceksiniz.

Bağlantı

Bölüm 8’de kısmen doğrusal modelde Y ve D değişkenlerini X üzerinde artıkleştirerek bir hedef katsayının ayrıştırılabileceğini gördük. Bölüm 11’de Lasso’nun yüksek boyutlu tahminde yararlı olabileceğini, fakat model seçimi sonrası standart çıkarımın sorunlu olduğunu gördük. Bu bölüm bu iki hattı birleştirir. Hansen’in Bölüm 29.20–29.22’si temel kaynaktır (Hansen, 2021).

12.1 Temel Problem: Çok Kontrol, Tek Hedef Parametre

Birçok tez çalışmasında ilgi bütün katsayı vektöründe değildir. Araştırmacı örneğin bir politika değişkeninin, eğitim düzeyinin veya firma özelliğinin etkisini tahmin etmek ister; diğer yüzlerce değişken ise kontrol görevi görür. Kısmen doğrusal yüksek boyutlu model

$$Y = D\theta + X'\beta + e, \quad E[e \mid D, X] = 0 \quad (12.1)$$

olsun. Burada

- Y sonuç değişkeni,
- D temel ilgi değişkeni,
- θ düşük boyutlu hedef parametre,
- $X \in \mathbb{R}^p$ çok sayıda kontrol,
- β yardımcı (nuisance) katsayı vektörüdür.

Amaç β 'nin her elemanını yorumlamak değil, θ için güvenilir tahmin ve çıkarım yapmaktır. p büyük olduğunda bütün X 'leri OLS'ye koymak varyansı büyütebilir; $p \geq n$ olduğunda standart OLS mümkün olmayabilir. Öte yandan yanlış değişken seçimi θ için eksik değişken yanlılığı yaratabilir.

Yardımcı (nuisance) bileşen

Nihai araştırma sorusunun doğrudan hedefi olmayan fakat hedef parametrenin güvenilir tahmini için öğrenilmesi gereken fonksiyon veya parametrelere yardımcı (nuisance) bileşen denir. DML'in temel fikri yardımcı bileşenleri esnek makine öğrenmesiyle tahmin ederken θ için klasik kök- n çıkarımı korumaya çalışmaktır.

Bu ayrım, neden sıradan makine öğrenmesi başarısının yeterli olmadığını açıklar. Y 'yi çok iyi öngören model D ile ilişkili zayıf outcome belirleyicilerini dışlayabilir; oysa bu değişkenler θ yanlılığını önlemek için kritik olabilir. DML, öngörü algoritmasını hedef parametre çıkarımının hizmetine sokan bir çerçevedir; hedefi en düşük prediction error değil, geçerli düşük boyutlu inference'tır.

12.2 Neden “Y’yi En İyi Açıklayan Değişkenleri Seçmek” Yetmez?

Tek bir potansiyel karıştırıcı X_j düşünelim. Gerçek model

$$Y = \theta D + \beta_j X_j + u$$

ve temel değişken denklemi

$$D = \gamma_j X_j + v$$

olsun. X_j sonuç denkleminde doğrudan zayıf bir katsayıya sahip olabilir, yani $|\beta_j|$ küçük olabilir. Bu nedenle yalnız Y 'yi koşullu olarak açıklamaya odaklanan değişken seçimi X_j 'yi dışarıda bırakabilir. Fakat $|\gamma_j|$ büyükse X_j ile D güçlü ilişkilidir.

X_j dışarıda bırakıldığında basit eksik değişken yanlılığı sezgisi

$$\text{Bias}(\hat{\theta}) \approx \beta_j \frac{\text{cov}(D, X_j)}{\text{var}(D)} \quad (12.2)$$

şeklinde. Küçük β_j tek başına küçük bias garantisi vermez; D ile yüksek ilişki bu terimi büyütebilir.

Sık yapılan hata

Değişken seçimini yalnız sonuç değişkenini iyi tahmin etme problemi olarak kurmak, nedensel/koşullu hedef katsayı için kritik bazı kontrolleri dışarıda bırakabilir. DML ailesindeki yöntemler, kontrol seçimini hedef parametrenin moment koşuluna göre daha güvenli hâle getirmeye çalışır.

Bu, öngörü açısından küçük görünen bir değişkenin nedensel veya yapısal çıkarım açısından kritik olabileceğini gösterir.

Double selection bu nedenle iki seçim problemi çalıştırır: Y 'yi açıklayan kontroller ve D 'yi açıklayan kontroller. Birleşim kümesi nihai regresyonda tutulur. Böylece tedaviyle güçlü ilişkili fakat outcome modelinde zayıf görünen potansiyel karıştırıcıların kaybolması azaltılır (Belloni et al., 2014b; Hansen, 2021).

12.3 Double Selection Lasso

Hansen, Belloni–Chernozhukov–Hansen yaklaşımını model denklem (12.1) için iki ayrı seçim problemi üzerinden sunar (Hansen, 2021). Önce temel değişken için yardımcı denklem

$$D = X'\gamma + V, \quad E[V | X] = 0 \quad (12.3)$$

kurulur. Ayrıca Y 'nin X üzerindeki indirgenmiş biçimi

$$Y = X'\eta + U, \quad E[U | X] = 0 \quad (12.4)$$

olsun. Doğrusal modelde $\eta = \beta + \gamma\theta$ ilişkisi vardır.

Double-selection algoritması:

1. D 'yi X üzerinde Lasso ile tahmin et. Seçilen değişken kümesine S_D de.
2. Y 'yi X üzerinde Lasso ile tahmin et. Seçilen değişken kümesine S_Y de.
3. Birleşimi al:

$$S = S_D \cup S_Y.$$

4. Nihai OLS'yi

$$Y = D\theta + X'_S\beta_S + e$$

biçiminde tahmin et.

5. $\hat{\theta}_{DS}$ için heteroskedastisiteye dayanıklı standart hata hesapla.

Bu prosedür bir değişkeni ya sonuç için önemliyse ya da D ile ilişkiliyse nihai regresyona alma eğilimindedir. Böylece yalnız sonuç-denklemini seçimine göre karıştırıcı değişkeni kaçırma riski azaltılır.

Neden “double”?

İki ayrı seçim yapılır: biri sonuç değişkeni tarafında, diğeri tedavi/temel ilgi değişkeni tarafında. Nihai modelde iki seçimin birleşimi kullanılır. Amaç daha fazla değişken seçmek değil; θ 'nın biasına yol açabilecek değişkenleri iki kanaldan korumaktır.

Yaklaşık seyreklik (approximate sparsity) varsayımı, çok büyük kontrol uzayının gerçekte nispeten küçük bir aktif değişken kümesiyle yeterince iyi yaklaşıklığını söyler. Bu yapı yoksa Lasso nuisance modelleri yeterince iyi öğrenemeyebilir ve double-selection asimptotik sonucu bozulabilir. Dolayısıyla yüksek boyutlu yöntemler de yapısal varsayımlara dayanır; “çok değişken var” tek başına Lasso kullanım gereksesi değildir.

12.4 Artıklaştırma (Partialling-Out): Yüksek Boyutlu Bileşeni Ayırmak

denklem (12.1)’in X koşullu beklentisini alalım:

$$E[Y | X] = \theta E[D | X] + X'\beta.$$

Tanımlayalım:

$$m_D(X) = E[D | X], \quad m_Y(X) = E[Y | X].$$

Ana modelden koşullu ortalamayı çıkarırsak

$$Y - m_Y(X) = \theta\{D - m_D(X)\} + e. \quad (12.5)$$

Eğer m_Y ve m_D bilinseydi, θ yalnız iki artık arasındaki OLS eğimiyle tahmin edilebilirdi.

Doğrusal yardımcı (nuisance) modellerde

$$m_D(X) = X'\gamma, \quad m_Y(X) = X'\eta$$

olur. Tahmin adımları:

1. D 'yi X üzerinde Lasso/Post-Lasso ile tahmin et ve

$$\hat{V}_i = D_i - \hat{m}_D(X_i)$$

oluştur.

2. Y 'yi X üzerinde Lasso/Post-Lasso ile tahmin et ve

$$\hat{U}_i = Y_i - \hat{m}_Y(X_i)$$

oluştur.

3. $\hat{U} = (\hat{U}_1, \dots, \hat{U}_n)'$ ve $\hat{V} = (\hat{V}_1, \dots, \hat{V}_n)'$ yığılmış artık vektörleriyle $\hat{U}$ 'yu $\hat{V}$ üzerine regres ederek

$$\hat{\theta}_{PR} = \frac{\sum_i \hat{V}_i \hat{U}_i}{\sum_i \hat{V}_i^2} \quad (12.6)$$

elde et.

Hansen bunu düzenlileştirme sonrası veya artıklaştırma (partialling-out) yaklaşımı olarak açıklar (Hansen, 2021).

Kısmen doğrusal modelde

$$Y = D\theta + g(X) + e, \quad D = m_D(X) + V$$

yazalım. Y ve D 'nin X tarafından öngörülen kısımlarını çıkardığımızda

$$U = Y - E[Y | X], \quad V = D - E[D | X]$$

ve ideal koşullarda $U = \theta V + e$ ilişkisi kalır. Hedef katsayı, X tarafından açıklanamayan treatment değişimi ile benzer biçimde artıktırılmış outcome değişimi arasındaki ilişkiden öğrenilir.

Bu düşünce Bölüm 2'deki FWL teoremi ve Bölüm 8'deki Robinson kısmen doğrusal tahmininin doğrudan devamıdır. Değişen yalnız nuisance fonksiyonlarını tahmin etme aracıdır: düşük boyutta kernel/spline kullanılabilirken yüksek boyutta Lasso, random forest veya boosting gibi algoritmalar devreye girebilir.

12.5 Ortogonal Moment Fikri

Naif moment koşulu

$$M(\theta, \beta) = E[D\{Y - D\theta - X'\beta\}] = 0 \quad (12.7)$$

olsun. β 'daki küçük bir tahmin hatasının bu momenti ne kadar değiştirdiğine bakalım:

$$\frac{\partial M(\theta, \beta)}{\partial \beta} = -E[DX']. \quad (12.8)$$

D ile X ilişkiliyse bu türev sıfır değildir. Dolayısıyla yardımcı katsayı seçimindeki küçük hata, θ momentini birinci dereceden etkileyebilir.

Artıklaştırma momenti ise

$$M_{PR}(\theta) = E[\{D - m_D(X)\}\{Y - m_Y(X) - \theta(D - m_D(X))\}] = 0 \quad (12.9)$$

şeklindedir. Doğrusal durumda $V = D - X'\gamma$ olduğundan yardımcı model hatası yönündeki temel türevlerden biri

$$-E[VX'] = 0$$

olur; çünkü V yardımcı regresyon hatasıdır ve X 'e ortogonaldır.

Ortogonalizasyon

Hedef momentin yardımcı bileşendeki küçük tahmin hatalarına birinci dereceden duyarsız olacak biçimde kurulmasına ortogonalizasyon denir. Sezgi olarak yardımcı modeli tam doğru öğrenmek zorunda değiliz; fakat kalan hata hedef momenti ilk derecede sürüklemelidir.

Bu özellik, DML'in neden “debiased” veya “orthogonal” olarak anıldığını anlamanın anahtarıdır.

Bu özellik literatürde *Neyman ortogonalliği* olarak adlandırılır: gerçek yardımcı değerler çevresinde momentin yardımcı yöndeki türevi sıfırdır, dolayısıyla kalan etki daha yüksek derecedendir.

Kısmen doğrusal model için tipik moment

$$\psi(W; \theta, \nu) = \{D - m_D(X)\}\{Y - m_Y(X) - \theta[D - m_D(X)]\}, \quad \nu = (m_Y, m_D)$$

şeklindedir. Burada $W = (Y, D, X)'$ tek gözlemin veri vektörüdür. ν yardımcı fonksiyon çiftini gösteren ek bir parametredir; η ise yukarıdaki indirgenmiş biçimin katsayı vektörü olarak kalır. g

yapısal fonksiyon, m_Y sonuç değişkeninin koşullu ortalamasıdır: $m_Y = \theta m_D + g$. Gerçek m_Y ve m_D altında beklentisi sıfırdır ve uygun koşullarda nuisance perturbasyonlarına karşı ortogonaldır. Bu özellik, esnek ML tahminlerinin yavaş yakınsamasına rağmen θ için daha hızlı ve yaklaşık normal çıkarım elde edilmesini mümkün kılan merkezi mekanizmadır (Chernozhukov et al., 2018).

12.6 Örneklem Bölme (Sample Splitting) Neden Eklenir?

Artıklaştırmada yardımcı fonksiyonları ve θ aynı gözlemlerle öğrenilirse, özellikle esnek makine öğrenmesi modelleri eğitim örnekleminin gürültüsünü de öğrenebilir. Bu, tahmin edilen artıklar ile yardımcı tahmin hataları arasında karmaşık bağımlılık yaratır.

Basit örneklem bölme çözümü:

1. Örnekleme A ve B diye ikiye ayır.
2. Nuisance modellerini A'da öğren.
3. A'dan öğrenilen yardımcı tahminlerini B'ye uygula ve B'de θ tahmin et.

Bu bağımlılığı kırar; fakat verinin yalnız bir kısmı nihai hedef tahmininde kullanılır. Çapraz uyarlama bu bilgi kaybını azaltır.

Tek bölme veriyi verimsiz kullanır ve hangi gözlemlerin hangi tarafa düştüğüne duyarlı olabilir. Çapraz uyarlama bu nedenle kat rollerini döndürerek her gözlemin bir kez ayrılmış (hold-out) artık almasını, fakat bütün gözlemlerin nihai hedef tahminine katkı vermesini sağlar.

12.7 Çapraz Uyarlama (Cross-Fitting) ve DML2 Algoritması

Hansen'in sunduğu DML algoritması K -katlı bölme kullanır (Hansen, 2021). Örneklem K kata ayrılınsın:

$$A_1, \dots, A_K.$$

$A_1, \dots, A_K$ birbirinden ayrık gözlem-indis kümeleridir; birleşimleri $\{1, \dots, n\}$ 'dir. $\hat{m}_D^{(-k)}$ ve $\hat{m}_Y^{(-k)}$, A_k dışındaki eğitim örnekleminde öğrenilen fonksiyonlardır. Her k için:

1. A_k dışındaki gözlemlerle $m_D(X)$ ve $m_Y(X)$ yardımcı modellerini tahmin et.
2. Bu modelleri yalnız dışarıda bırakılan A_k katına uygula:

$$\hat{V}_i = D_i - \hat{m}_D^{(-k)}(X_i), \quad (12.10)$$


$$\hat{U}_i = Y_i - \hat{m}_Y^{(-k)}(X_i), \quad i \in A_k. \quad (12.11)$$

3. Bütün katlardaki çapraz uyarlanmış artıkları birleştir.
4. Nihai katsayısı

$$\hat{\theta}_{DML} = \frac{\sum_{i=1}^n \hat{V}_i \hat{U}_i}{\sum_{i=1}^n \hat{V}_i^2} \quad (12.12)$$

ile tahmin et.

Her gözlemin artığı, o gözlemi görmemiş bir yardımcı modeliyle hesaplandığı için aşırı uyum (overfitting) kaynaklı bağımlılık azaltılır. Aynı zamanda her gözlem nihai aşamada kullanıldığı için tek yönlü sample split'e göre veri daha etkin kullanılır.



Şekil 12.1: DML çapraz uyarlama (cross-fitting) algoritmasının temel akışı

Hansen, DML2 biçiminin tercih edildiğini ve $K = 10$ 'un yaygın bir seçim olduğunu belirtir (Hansen, 2021). Hesaplama maliyeti yaklaşık olarak K ile artar.

Çapraz uyarlama yalnız veri bölmek değildir; ön işleme zincirinin de kat sınırlarına saygı göstermesi gerekir. Standartlaştırma, eksik değer imputasyonu, değişken türetme veya tuning bütün veri üzerinde önceden öğrenilirse değerlendirme katı hakkında eğitim setine bilgi sızır. Doğru işlem zinciri her kat için yardımcı model eğitim örnekleminde kurulur; ayrılan kata yalnız dönüştürme ve tahmin adımı uygulanır.

Denklem (12.12) formülü, son aşamanın artığın artık üzerine OLS'i olduğunu gösterir. DML'in karmaşıklığı bu son regresyonda değil, artıkların dürüst (kat dışı) ve yeterince iyi yardımcı tahminlerden üretilmesindedir.

12.8 DML İçin Düzenlilik Koşulları: Ortogonallık Tek Başına Yeterli Değildir

Ortogonal moment ve çapraz uyarlama güçlü araçlardır; fakat “herhangi bir makine öğrenmesi algoritması kullanıldığında otomatik olarak geçerli çıkarım” sonucu vermez. Hansen’in Lasso tabanlı DML sunumundaki asimptotik sonuç, önceki düzenleştirme sonrası (post-regularization) teoreminin koşullarını devralır: yüksek boyutlu yardımcı regresyonların yeterince iyi yaklaşıklandırılması, uygun moment sınırları ve hedef parametrenin tanımlı olması gerekir (Hansen, 2021).

Pratik olarak dört koşul grubu ayrıştırılmalıdır:

1. **Tanımlama ve artık varyasyonu:** temel değişkenin kontrollerden sonra kalan bileşeni sıfıra çökmemelidir. Doğrusal kısmen modelde

$$V = D - m_D(X), \quad E[V^2] > 0$$

gerekir. Aksi hâlde θ veriden ayrılamaz.

2. **Yardımcı tahminlerin yeterli doğruluğu:** $m_Y(X)$ ve $m_D(X)$ tahmin hataları örneklem büyüdükçe yeterince küçülmelidir. Hansen’in Lasso çerçevesinde bu özellik seyrek veya yaklaşık seyrek temsil ve buna bağlı büyüme-hızı koşullarıyla elde edilir.

3. **Düzenli momentler:** hedef momentin varyansı sonlu olmalı ve heteroskedastisiteye dayanıklı varyans tahmini için gerekli ortalama/moment koşulları sağlanmalıdır.
4. **Gerçek kat dışı tahmin:** tuning, standardizasyon, imputasyon ve değişken seçimi dâhil veri-temelli bütün ön işlemler yalnız eğitim katında öğrenilmelidir. Aksi hâlde çapraz uyarlamanın ayırdığı bağımlılık yeniden oluşur.

Kullanılan artıkleştirme skoru için yüksek seviyeli yeterli bir hız koşulu aşağıdadır. $\|f\|_{P,2} = \{E[f(X)^2]\}^{1/2}$ anakütle L_2 normunu tanımlar; bu norm sonlu örneklem vektörünün Öklid normundan farklıdır. Her eğitim katında, diğer moment ve tanımlama koşullarıyla birlikte,

$$\|\hat{m}_D - m_D\|_{P,2} (\|\hat{m}_Y - m_Y\|_{P,2} + \|\hat{m}_D - m_D\|_{P,2}) = o_p(n^{-1/2}) \quad (12.13)$$

koşulu kullanılır. m_D hatasının karesi de bu skorda yer alır; yalnız iki farklı hatanın çarpımının küçük olması yeterli değildir. Her iki hata $o_p(n^{-1/4})$ ise bu koşul sağlanır. Bu, diğer düzenlilik koşullarının yerine geçen bağımsız bir teorem değil, onlarla birlikte kullanılan yüksek seviyeli yeterli koşuldur; Chernozhukov et al. (2018)'in kısmen doğrusal modeldeki artıkleştirme skoru için verdiği koşula karşılık gelir.

Sık yapılan hata

Ortogonal moment + çapraz uyarlama $\neq$ varsayımsız çıkarım. Çapraz uyarlama tahmin aşamaları arasındaki bağımlılığı azaltır; Hansen'in de belirttiği gibi temel düzenlilik koşullarını ortadan kaldırmaz (Hansen, 2021).

Lasso bağlamında yaklaşık seyreklik ve uygun kısıtlı-özdeğer (restricted eigenvalue) türü koşullar bu hızları sağlamaya yardım eder; diğer makine öğrenmesi algoritmalarında farklı karmaşıklık ve düzenlilik koşulları gerekir.

Ayrıca $V = D - m_D(X)$ için yeterli varyasyon bulunmalıdır. D neredeyse tamamen X tarafından belirleniyorsa, artıkleştirilmiş tedavi varyasyonu çok küçülür ve hedef katsayı zayıf biçimde tanımlanır. Sonlu momentler, bağımsız/kümelenmeye uygun örnekleme yapısı ve doğru hedef moment de çıkarım için gereklidir. Bu nedenle DML “herhangi bir ML algoritmasını koy ve robust SE al” reçetesi değildir.

12.9 DML Standart Hatası

Çapraz-uyarlanmış artıklar elde edildikten sonra son aşama tek açıklayıcı regresyon gibi düşünülebilir:

$$\hat{U}_i = \theta \hat{V}_i + \text{hata}_i.$$

Bu nedenle heteroskedastisiteye dayanıklı OLS standart hatası kullanılabilir. Eşdeğer olarak skor

$$\hat{\psi}_i = \hat{V}_i (\hat{U}_i - \hat{\theta}_{DML} \hat{V}_i) \quad (12.14)$$

ile yaklaşık varyans

$$\hat{V}_{\hat{\theta}_{DML}} = \frac{1}{n} \frac{\sum_i \hat{\psi}_i^2}{\left(\frac{1}{n} \sum_i \hat{V}_i^2\right)^2} \quad (12.15)$$

biçiminde yazılabilir. Sonuç

$$\hat{\theta}_{DML} \pm 1.96 \widehat{se}(\hat{\theta}_{DML})$$

ile yaklaşık yüzde 95 güven aralığına çevrilebilir. [Denklem \(12.15\)](#) büyük örneklem biçimidir; bu bölümdeki tablolarda aynı varyansın $n/(n-1)$ serbestlik düzeltmeli hali (HC1) kullanılır. Gözlemler kümeler halinde bağımlıysa skorlar küme içinde toplanarak küme-dayanıklı varyans hesaplanır.

Sık yapılan hata

DML'in "machine learning" kullanması standart hatayı gereksiz kılmaz. Nuisance tahmin, ortogonalizasyon ve çapraz uyarlama hedef katsayı için düzenli bir asimptotik dağılım elde etmeye hizmet eder; belirsizlik yine açık biçimde raporlanmalıdır.

Çapraz uyarlanmış artık momenti için basit kısmen doğrusal modelde etki fonksiyonu benzeri katkı

$$\hat{\varphi}_i = \hat{\psi}_i / \hat{J}, \quad \hat{J} = \frac{1}{n} \sum_j \hat{V}_j^2$$

olarak yazılabilir. $\hat{J}$ momentin eğiminin eksi işaretlisi, $\hat{\varphi}_i$ normalize etki katkısıdır; ham skor $\hat{\psi}_i$ ile aynı nesne değildir. Skaler tahmin edici varyansı $\hat{V}_{\hat{\theta}_{DML}} = n^{-2} \sum_i \hat{\varphi}_i^2$; $\sqrt{n}(\hat{\theta}_{DML} - \theta)$ için asimptotik varyans tahmini ise $\hat{V}_{\theta} = n^{-1} \sum_i \hat{\varphi}_i^2$ 'dir. Bu gösterim, standart hatanın yalnız son regresyon artığına değil artıktırılmış tedavi gücüne de bağlı olduğunu açıklar.

$\sum \hat{V}_i^2$ çok küçükse treatment X tarafından neredeyse tamamen tahmin ediliyor demektir; hedef parametre için efektif varyasyon azdır ve standart hata büyür. Bu, örtüşme ve tanımlama probleminin DML içindeki görünümüdür.

12.10 DML Hangi Problemi Çözmez?

DML çok sayıda gözlenen kontrolün esnek biçimde işlenmesini kolaylaştırır; fakat tanımlama problemini ortadan kaldırmaz. Eğer

$$E[e \mid D, X] \neq 0$$

ise, yani D gözlenmeyen karıştırıcılar nedeniyle içselse, yardımcı modeller ne kadar başarılı olursa olsun model [denklem \(12.1\)](#)'deki nedensel yorum geçerli değildir.

Sık yapılan hata

DML = "otomatik nedensellik" değildir. DML fonksiyonel biçim ve yüksek boyutlu kontrol problemini hedefler. Gözlenmeyen içsellik için IV, RDD veya başka bir tanımlama tasarımı gerekebilir. Önce [Bölüm 3](#)'teki tanımlama sorusu çözülmelidir.

DML esas olarak yüksek boyutlu veya esnek gözlenebilir kontrol fonksiyonlarının tahmininden kaynaklanan düzenleleştirme ve aşırı uyum yanlılığını yönetir. Bu paragrafta C , gözlenmeyen bir karıştırıcı rassal değişkeni gösterebilir. C hem D hem Y 'yi etkiliyorsa, ne kadar güçlü ML kullanılırsa kullanılsın C veride yoktur ve artıktırma onu ortadan kaldıramaz. Bu durumda IV, RDD, deneysel tasarım veya başka bir tanımlama stratejisi gerekir.

Benzer biçimde kötü ölçülmüş treatment, seçici örnekleme veya zayıf overlap otomatik olarak çözülmez. DML bir tahmin teknolojisidir; tanımlama varsayımının yerine geçmez. Tez yazımında DML kullanım gerekçesi "nedenselliği sağlamak" değil, belirli tanımlama varsayımı altında karmaşık nuisance yapıyı esnek biçimde kontrol ederek hedef çıkarımı korumaktır.

12.11 Kontrollü Uygulama: Naif Seçim, Double Selection ve DML

Yöntemler arasındaki farkı görünür kılmak için $n = 800$, $p = 180$ olan kontrollü bir kısmen doğrusal model ürettik. Gerçek hedef katsayı

$$\theta = 1$$

olarak belirlendi. Kontroller bağımsız standart normaldir. İlk sekiz X değişkeni D 'yi güçlü biçimde açıklarken (katsayılar $\pm 0,6$ – $\pm 0,9$) Y denkleminde doğrudan etkileri zayıftır ($\pm 0,10$); X_{21} – X_{24} yalnız Y 'yi etkiler. Bu tasarım, yalnız sonuç değişkeni tarafında seçim yapan bir yöntemin karıştırıcıları kaçırabileceği bir senaryo üretir. Veri üretim süreci uygulamanın Sezgi sekmesindeki Konu 12 Deney 1'in varsayılan ayarlarıdır (tohum 80712).

Bütün Lasso adımlarında ceza, 5-katlı CV ve bir standart hata kuralıyla seçilir (kat: gözlem sırasının 5'e bölümünden kalan); ölçekleme her katın eğitim verisinden öğrenilir. Yalnız-sonuç Post-Lasso'da D 'nin cezalandırılmaması için Y ve her X önce D üzerinde artıklaştırılır. Artıklaştırma yardımcı modelleri bütün örneklemde, DML ise ardışık 10 bloklu dış katlarla çapraz uyarlanmış olarak öğrenir; iki yöntemde de son aşama [denklem \(12.12\)](#)'deki gibi sabitsizdir.

Yalnız-sonuç Post-Lasso beş kontrol seçmiş ve ilk sekiz karıştırıcının hiçbirini almamıştır. D denklemi Lasso'su ise ilk sekiz karıştırıcının tamamını (toplam dokuz değişken) seçmiştir. Double selection birleşiminde 14 kontrol kullanılmış ve sekiz kritik karıştırıcının tümü korunmuştur.


Tablo 12.1: Kontrollü yüksek boyutlu örnekte hedef katsayı tahminleri

Yöntem	$\hat{\theta}$	HC1 SH	Yaklaşık %95 GA
Kısa OLS	1,163	0,027	[1,110; 1,215]
Yalnız sonuç değişkeni Post-Lasso	1,124	0,015	[1,095; 1,154]
Double selection	1,006	0,039	[0,930; 1,083]
Artıklaştırma	1,025	0,039	[0,949; 1,101]
DML (10 kat)	1,032	0,039	[0,955; 1,110]


Bu tek örneklemde double selection gerçek değere en yakın tahmini verir; DML ve artıklaştırma da gerçek değeri kapsayan aralıklar üretir. Bu bir “yöntem sıralaması” değildir. DML'in avantajı tek bir örneklemde mutlaka en küçük hatayı vermesi değil, yardımcı tahminini ortogonal moment ve çapraz uyarlama (cross-fitting) ile hedef parametre çıkarımından sistematik biçimde ayırmasıdır.

Simülasyon sonuçlarını tek bir örneklemde yöntem yarışı olarak okumamak gerekir. Daha bilimsel değerlendirme, aynı veri üretim sürecini yüzlerce kez tekrar edip yanlılık, RMSE ve güven aralığı kapsama oranlarını karşılaştırmaktır. Bir yöntemin tek örnekte gerçek değere en yakın olması tesadüfi olabilir.

Ders uygulaması mekanizmayı görünür kılmak için tek örneklem kullanır: outcome-only seçim kritik treatment belirleyicilerini kaçırabilir; double selection bu değişkenleri geri getirir; DML ise artıklaştırma ve çapraz uyarlama ile düzensileştirme etkisini hedef momentten ayırır. Tezde yöntem seçimi bu mekanizmayla, sadece bir simülasyon tablosundaki sıralamayla gerekçelendirilmemelidir.



Şekil 12.2: Kontrollü örnekte yöntemlerin $\theta = 1$ hedefi etrafındaki tahminleri ve yaklaşık yüzde 95 güven aralıkları.



Şekil 12.3: DML son aşamasında çapraz-uyarlanmış sonuç ve tedavi artıklarının ilişkisi. Doğru orijinden geçer; eğimi $\hat{\theta}_{DML}$ 'dir.

12.12 Yardımcı Modeller İçin Hangi Algoritmalar Kullanılır?

DML'in yardımcı adımlarında $m_Y(X)$ ve $m_D(X)$ fonksiyonlarını tahmin etmemiz gerekiyor. Buraya kadar bu adımı Lasso ile yaptık. Uygulamada başka algoritmalar da kullanıldığı için, en yaygın üç seçeneği kısaca tanımlamak gerekir. Amaç bu yöntemleri ayrıntılı öğrenmek değil, DML tablolarında karşılaştığınızda ne olduklarını bilmek ve hangi koşullarda uygun olduklarını değerlendirebilmektir.

12.12.1 Lasso ve Post-Lasso

Bölüm 11'de gördüğümüz L_1 cezalı tahmin edici, yardımcı fonksiyon yaklaşık seyrek doğrusal bir yapıya sahipse iyi çalışır. Yani çok sayıda aday kontrol içinden görece az sayıda değişken, dönüşüm ve etkileşim ilişkisi büyük ölçüde açıklyorsa uygundur.

Avantajı, teorik hızlarının en iyi bilinen durum olmasıdır: yaklaşık seyreklik ve kısıtlı-özdeğer koşulları altında Denklem (12.13)'teki ürün-hızı koşulunun sağlandığı gösterilebilir. Dezavantajı, gerçek ilişki güçlü biçimde doğrusal olmayan veya etkileşimliyse bu yapıyı yakalayabilmek için doğru dönüşümlerin aday kümesine elle konmuş olmasını gerektirmesidir.

12.12.2 Regresyon ağaçları

Regresyon ağacı, kovaryat uzayını ardışık ikili bölmelerle dikdörtgen bölgelere ayırır ve her bölgede sonucu o bölgedeki ortalama ile tahmin eder. Her bölmede, kareli hatayı en çok azaltan değişken ve eşik seçilir. Ağacın derinliği veya yaprak başına minimum gözlem sayısı esnekliği kontrol eden tuning parametresidir.

Ağaçların çekici yanı, etkileşimleri ve eşik etkilerini önceden belirtmeye gerek kalmadan yakalayabilmesidir. Zayıf yanı yüksek varyanstır: verinin küçük bir bölümü değişince ağaç yapısı tamamen değişebilir. Bu nedenle tek bir ağaç DML yardımcı modeli olarak nadiren tercih edilir.

12.12.3 Rassal ormanlar

Rassal orman, çok sayıda ağacı iki kaynaktan gelen rassallıkla üretir ve tahminlerini ortalama. Birincisi, her ağaç verinin yeniden örneklenmiş bir kopyası üzerinde kurulur. İkincisi, her bölmede bütün kovaryatlar değil rassal seçilmiş bir alt kümesi aday olarak değerlendirilir. Ortalama alma tek ağacın yüksek varyansını belirgin biçimde azaltır.

Uygulamada rassal ormanlar, doğrusal olmayan ve etkileşimli yardımcı fonksiyonlarda genellikle Lasso'dan daha iyi uyum sağlar. Buna karşılık yakınsama hızlarına ilişkin teori Lasso'daki kadar tamamlanmış değildir; bu nedenle Denklem (12.13) koşulunun sağlandığı otomatik varsayılmaz.

DML açısından kriter neden farklı?

Öngörü yarışmasında kazanan algoritma en düşük test hatasını veren algoritmadır. DML'de ise kriter bu değildir. İhtiyacımız olan şey, iki yardımcı tahminin hata oranlarının *çarpımının* $n^{-1/2}$ ölçeğinden küçük olmasıdır. Bir algoritma m_Y 'yi çok iyi, m_D 'yi kötü öğreniyorsa hedef parametre için sonuç güvenilir olmayabilir. Bu nedenle DML raporlarında her iki yardımcı modelin uyum ölçüleri ayrı ayrı gösterilmelidir.

Sık yapılan hata

Esnek algoritma seçmek tanımlama problemini çözmez ve otomatik olarak daha iyi DML sonucu vermez. Rassal orman kullanmak, yukarıda tanımlanan gözlenmeyen karıştırıcı C veride yoksa hiçbir şey değiştirmez. Ayrıca algoritmanın hiperparametreleri de veriye bağlı seçiliyorsa bu seçim kat içinde yapılmalıdır; aksi hâlde çapraz uyarlamamanın kırdığı bağımlılık geri gelir.

Pratik protokol

Tez uygulamasında makul bir yaklaşım şudur: ana sonucu Lasso/Post-Lasso yardımcı modelleriyle üretin, çünkü teorik dayanağı en açık olan seçenek budur. Ardından rassal orman gibi en az bir esnek alternatifle aynı analizi tekrarlayın ve hedef katsayının ne kadar değiştiğini duyarlılık tablosu olarak raporlayın. İki sonuç birbirine yakınsa güven artar; belirgin biçimde ayrışıyorsa bu bir sorun işaretidir ve yardımcı modellerin uyumu incelenmelidir.

12.12.4 Uygulama ilkeleri

Hangi algoritma seçilirse seçilsin şu kurallar değişmez:

- $m_D(X)$ ve $m_Y(X)$ mümkün olduğunca iyi örneklem-dışı tahmin yapmalıdır.
- Tuning yalnız eğitim katlarında yapılmalıdır; değerlendirme katı tuning'e sızmamalıdır.
- Aynı ön işleme adımları da eğitim katı içinde öğrenilmelidir.
- Algoritma seçimi ve hiperparametre aralığı önceden kaydedilmelidir.
- Yardımcı tahmin başarısı raporlanmalı, fakat yalnız yüksek R^2 DML'in geçerliliğinin kanıtı sayılmamalıdır.

Hansen'in anlatımı Lasso ve Post-Lasso üzerinde yoğunlaşır; DML fikri daha genel makine öğrenmesi tahmin edicilerine genişletilebilir (Hansen, 2021; Chernozhukov et al., 2018).

12.13 Çapraz Uyarlamada Veri Sızıntısı

DML uygulamasında en sık yapılan kodlama hatalarından biri, standardizasyon veya değişken seçimini bütün örneklemde yapıp sonra katlara bölmektir. Doğru sıra her kat için:

1. eğitim katlarını belirle,
2. ölçekleme ve değişken türetme işlemlerini eğitim verisi üzerinde öğren,
3. yardımcı modeli eğitim verisi üzerinde tune et ve tahmin et,
4. bütün bu dönüşümleri dışarıda tutulan kata yalnız uygula,
5. artığı dışarıda tutulan katta hesapla.

Sık yapılan hata

Çapraz uyarlama yalnız modelin “fit” komutunu ilgili kat dışında çalıştırmak değildir. Veri-temelli bütün ön işlemler yardımcı tahmininin parçasıdır. Tüm örneklemden öğrenilmiş standartlaştırma, imputasyon veya özellik seçimi dışarıda tutulan kat hakkında bilgi sızdırabilir.

Veri sızıntısı yalnız standartlaştırmayla sınırlı değildir. Bütün veri kullanılarak Lasso cezası seçmek, kategorileri nadirliğe göre birleştirmek, eksik değer imputasyon modeli kurmak veya sonuç değişkenine bakarak değişken türetmek de ayrılmış kat bilgisini yardımcı model eğitime sızdırabilir. Çapraz uyarlama teorisinin “gözlem kendi tahmin modelini eğitmesin” ilkesi bütün ön işleme zincirine uygulanmalıdır.

En güvenli yazılım mimarisi, her kat için ayrı kurulan tek bir işlem zinciri nesnesidir. Eğitim katında bütün dönüşümler öğrenilir, ayrılmış kat yalnız dönüştürme ve tahmin adımını görür. Bu yaklaşım replikasyonu da kolaylaştırır.

12.14 Rassal Bölme ve Yeniden Üretilbilirlik

DML katları rassal olduğu için aynı veri farklı seed ile bir miktar farklı tahmin verebilir. Hansen bu keyfiliği yöntemin dezavantajlarından biri olarak not eder (Hansen, 2021). Uygulamada:

- seed açıkça kaydedilmelidir,
- kat sayısı önceden belirlenmelidir,
- sonuç çok duyarlıysa birkaç bağımsız bölme altında duyarlılık raporlanabilir,
- nihai çalışmada tek “en iyi” bölme seçilmemelidir.

Büyük K her eğitim örneklemini büyütür, fakat hesaplama maliyetini artırır. Hansen’in aktardığı yaygın tercih $K = 10$ ’dur (Hansen, 2021).

Çapraz uyarlamada kat ataması rassal yapıldığında farklı seed’ler yardımcı model tahminlerini ve dolayısıyla son $\hat{\theta}$ değerini az da olsa değiştirebilir. Tek bir seed’i seçip yalnız o sonucu raporlamak yerine seed’i önceden sabitlemek ve gerekirse birkaç alternatif bölme altında duyarlılığı incelemek daha şeffaftır.

Bölüm 12.15’deki DDK uygulamasında aynı veri, aynı öğrenici ve aynı kat sayısı ile, yalnız okulların katlara atanma kuralı değiştirildiğinde tracking etkisi tahmini 1,27 ile 1,55 arasında değişir. Chernozhukov et al. (2018) bu keyfiliği azaltmak için birçok bağımsız bölmenin tahminlerinin medyanını ve varyans tahminini

$$\hat{\theta}_{med} = \text{medyan}_s \hat{\theta}_s, \quad \hat{V}_{\hat{\theta}_{med}} = \text{medyan}_s \left\{ \hat{V}_{\hat{\theta}_s} + (\hat{\theta}_s - \hat{\theta}_{med})^2 \right\}$$

biçiminde birleştirmeyi önerir. Burada s bölme indisi, $\hat{V}_{\hat{\theta}_s}$ her bölmenin sonlu örneklem varyans tahmini, $\hat{V}_{\hat{\theta}_{med}}$ birleşik varyans tahminidir; birleşik standart hata bunun kareköküdür.

Replikasyon paketinde kat sayısı, seed, öğrenici hiperparametreleri, tuning ızgarası ve ön işleme zinciri kaydedilmelidir. Böylece DML sonucu yalnız “Python’da çalıştırıldı” düzeyinde değil, aynı artıkları yeniden üretecek ayrıntıda belgelenir.

12.15 Ampirik Uygulama Laboratuvarı: DML’i Tanımlama Stratejisinin Yerine Koymamak


DML’in en iyi öğretilbileceği bağlamlardan biri, tanımlamanın zaten açık olduğu bir veri setidir. Bu nedenle Hansen’in Duflo–Dupas–Kremer tracking deneyini yeniden kullanıyoruz. Tracking okul düzeyinde rastgele atanmıştır; dolayısıyla nedensel tanımlama makine öğrenmesinden gelmez. DML burada esnek kovaryat ayarlaması ve çapraz uyarlama mantığını öğretmek için kullanılmaktadır (Hansen, 2021).

Eksiksiz kovaryat örnekleminde 108 okuldan 5.135 öğrenci vardır. Yardımcı değişkenler başlangıç standart puanı, cinsiyet, test yaşı, okul yönetim komitesi, ek öğretmen ve başlangıç yüzdelik dilimidir. Yardımcı modeller Lasso’dur ve bu altı değişkenden kurulan 27 terimli bir sözlük kullanır: altı değişkenin kendisi (yaş 9’dan sapma, yüzdelik dilim (yüzdelik – 50)/25 olarak ölçeklenir), üç sürekli değişkenin ikinci ve üçüncü kuvvetleri ve altı değişkenin 15 ikili etkileşimi.

12.15.1 Adım 1: Aynı estimand için üç tahmin yolu

Tablo 12.2: DDK2011: tracking etkisi için OLS ve DML karşılaştırması

Yöntem	$\hat{\theta}$	SH	n
Ham fark, okul-küme SH	1,134	0,708	5.135
Kovaryat ayarlı OLS, okul-küme SH	1,383	0,699	5.135
DML, Lasso, okul-kümeli çapraz uyarlama, okul-küme SH	1,497	0,704	5.135
DML, 11 kat kuralının medyanı	1,464	0,705	5.135



Şekil 12.4: DDK2011: aynı tracking estimand’ı için üç tahmin yaklaşımı. Gri noktalar 11 farklı kat kuralıyla elde edilen DML tahminleridir.

Üç yöntem aynı büyüklük bölgesinde sonuç vermektedir. Kovaryat ayarlı OLS 1,38, DML 1,50 test puanıdır; standart hatalar neredeyse aynıdır (0,699 ve 0,704). Aradaki fark standart hatanın beşte birinden azdır. Bu tek uygulamadan “DML daha hassastır” ya da “daha az hassastır” sonucu çıkarılamaz. Nuisance model kalitesi, örneklem büyüklüğü ve veri yapısı bu karşılaştırmayı değiştirebilir.

En önemli yorum şudur: tracking etkisinin nedensel anlamı DML sayesinde ortaya çıkmamıştır. Randomized design zaten temel tanımlamayı sağlamaktadır. DML yalnız

$$E[Y | X], \quad E[D | X]$$

yardımcı fonksiyonlarını esnek biçimde öğrenip hedef momenti artıklar üzerinden kurmaktadır. Tasarımın izi yardımcı modellerde de görünür: tracking okul düzeyinde rastgele atandığı için Lasso'nun cezasını seçen iç CV bütün katlarda D için sabit modeli seçer (sıfırdan farklı katsayı yoktur); $\widehat{V}$ tracking'in eğitim katındaki ortalamasından sapmasıdır. Y için Lasso 27 terimden 17 ile 26 arasını tutar.

12.15.2 Adım 2: Çapraz uyarlamayı okul kümelerine saygılı yapmak

Tedavi okul düzeyinde atandığı için rastgele kat oluşturup aynı okulun bazı öğrencilerini eğitim, bazılarını değerlendirme katına koymak uygun değildir. Bu uygulamada okullar beş kata açık bir kurala atanır: okulun numarasına göre sıra numarası $r = 1, \dots, 108$ olmak üzere

$$\text{kat} = \lfloor 5\{r\varphi\} \rfloor + 1, \quad \varphi = \frac{\sqrt{5} - 1}{2}.$$

Böylece bütün okul aynı kat içinde kalır ve yardımcı model aynı okulun değerlendirme örneklemindeki öğrencileri hakkında doğrudan eğitim görmez. Her eğitim katında Lasso cezası da okul düzeyinde katlarla seçilir: iç kat $\lfloor 5\{r\sqrt{2}\} \rfloor + 1$ 'dir; ceza $\lambda_y \in [10^{-3}, 10]$ aralığında 41 noktalı logaritmik ızgarada iç CV hatasını en küçük yapan değerdir. scikit-learn'deki `GroupKFold` okulları büyüklüklerine göre dengeler; eşit büyüklükteki okulların hangi kata gideceği kütüphanenin sıralama ayrıntısına bağlı olduğundan R ve Stata aynı katları kuramaz. Açık kural üç dilde aynı katları ve aynı sayıları verir.

Kod 12.1: Okul-kümeli cross-fitting ile kısmen doğrusal DML iskeleti

```
y_hat, d_hat = np.zeros(n), np.zeros(n)
for k in range(1, 6):
    e = dis_kat != k          # eğitim: k dışındaki okullar
    # her yardımcı model için ceza, eğitim katının okullarıyla iç CV'de seçilir
    y_hat[~e] = lasso_cv_tahmin(X[e], y[e], ic_kat[e], X[~e])
    d_hat[~e] = lasso_cv_tahmin(X[e], d[e], ic_kat[e], X[~e])
u_hat, v_hat = y - y_hat, d - d_hat
theta = (v_hat @ u_hat) / (v_hat @ v_hat)    # sabitsiz artık regresyonu
final = sm.OLS(u_hat, v_hat[:, None]).fit(
    cov_type="cluster",
    cov_kwds={"groups": school_id},
)
```

Bu kod iki farklı bağımlılık sorununu ayrı yerlerde ele alır. Okul-kümeli katlar veri sızıntısını azaltır; final aşamadaki cluster-robust kovaryans ise okul içi hata bağımlılığını çıkarıma taşır. Birini yapmak diğerinin yerini tutmaz.

12.15.3 Adım 3: DML makalesindeki sonuç tablosunu nasıl okumalıyız?

DML çıktısında yalnız hedef katsayı ve p-değerini görmek yeterli değildir. En az şu ayrıntılar raporlanmalıdır:

1. hedef parametre ve tanımlama varsayımı,
2. treatment ve outcome tanımları,
3. kullanılan yardımcı model öğrencileri,
4. tuning prosedürü,
5. kat sayısı ve bölme birimi,
6. ön işlemenin kat içinde yapılıp yapılmadığı,
7. hedef katsayı için standart hata türü,
8. farklı öğrenci, kat ve seed seçimlerinde duyarlılık.

Son maddenin önemi bu veride açıkça görülür. Aynı hesabı dış katlarda φ yerine 3 ile 31 arasındaki on asal sayının kareköküyle ($\sqrt{3}$, $\sqrt{5}$, $\sqrt{7}$, $\sqrt{11}$, $\sqrt{13}$, $\sqrt{17}$, $\sqrt{19}$, $\sqrt{23}$, $\sqrt{29}$, $\sqrt{31}$) kurulan on farklı kuralla tekrarladığımızda tahmin 1,267 ile 1,554 arasında değişir. Yalnız okulların katlara dağılımı değişmiştir; veri, öğrenci ve kat sayısı aynıdır. On bir bölmenin medyanı 1,464, Chernozhukov et al. (2018)’in medyan standart hatası 0,705’tir. Tek bir bölmenin sonucunu “en iyi” bölme olarak seçmek yerine bölme kuralı önceden kaydedilmeli ve bölmeler arası değişim raporlanmalıdır.

DML tablosunda yalnız “Lasso kullanıldı” ifadesi yöntem tanımı değildir. Aday terim sözlüğü, ceza ızgarası, ceza seçim kuralı ve cross-fitting yapısı yeniden üretilebilir biçimde açıklanmalıdır; rassal orman gibi bir öğrencide ağaç sayısı, minimum yaprak büyüklüğü ve hiperparametre seçimi de buna eklenir.

12.15.4 Adım 4: Benzer OLS ve DML sonuçlarını nasıl yorumlamalıyız?

Bu örnekte ayarlı OLS ile DML nokta tahminleri birbirine yakındır. Bunun iki olası okuması vardır. Birincisi, doğrusal kontrol spesifikasyonu bu veri için yeterli olabilir. İkincisi, randomized design nedeniyle kovaryat fonksiyonel biçiminin hedef katsayı üzerindeki etkisi zaten sınırlı olabilir. Her iki durumda da yakınlık, gözlenmeyen confounding olmadığına ilişkin yeni bir test değildir; randomization tasarımından gelen bilgiyle uyumludur.

Gözlemsel bir tezde OLS ve DML’in yakın çıkması “içsellik yoktur” anlamına gelmez. Her ikisi de yalnız gözlenen X üzerinde koşullandırıyor, gözlenmeyen karıştırıcı problemi ortak kalabilir.

Sık yapılan hata

DML, karmaşık fonksiyonel biçimi ve yüksek boyutlu gözlenen kontrolleri yönetmek için güçlüdür; fakat geçerli araç, randomization, unconfoundedness veya başka bir tanımlama kaynağının yerine geçmez.

12.15.5 Kendi tezinizde DML için uygulama protokolü

1. Önce estimand ve tanımlama varsayımını düz yazıyla açıklayın.
2. Hangi değişkenlerin treatment sonrası olduğunu kontrol edin; post-treatment kontrolleri nuisance setine mekanik biçimde eklemeyin.

3. Fold yapısını bağımlılık birimine göre kurun.
4. Ön işleme ve tuning'i her eğitim katı içinde yapın.
5. En az iki makul yardımcı model öğrencisi ile duyarlılık düşünün.
6. Hedef katsayı için veri yapısına uygun robust/küme standart hata kullanın.
7. DML sonucunu basit benchmark modellerle yan yana raporlayın.
8. Replikasyon paketinde kat kuralını veya seed'i, öğrenci ayarlarını ve paket sürümlerini saklayın; birkaç bölme altında duyarlılığı raporlayın.

Makale sonuç paragrafı örneği


“Tracking etkisi kovaryat ayarlı OLS’de 1,38, okul-kümeli cross-fitting kullanan Lasso-DML’de 1,50 olarak tahmin edilmiştir; on bir farklı kat kuralında DML tahminleri 1,27 ile 1,55 arasında değişmiş, medyanları 1,46 olmuştur. Tahminlerin benzer büyüklükte olması ana bulgunun gözlenen kovaryatların fonksiyonel biçimine karşı sınırlı duyarlılık gösterdiğini düşündürmektedir. Nedensel yorum DML’den değil, programın okul düzeyindeki rastgele atama tasarımından gelmektedir.”

12.16 Bütünleşik Tez Araştırma Akışı

Bu dersin 12 konusu bir yöntem listesi değil, tek bir ampirik araştırma zincirinin parçalarıdır. Tez çalışması için önerilen akış şöyledir:

1. **Araştırma sorusu:** Ekonomik/örgütsel/mühendislik sorusunu açık cümleyle yaz.
2. **Estimand:** Ortalama etki, kantil etkisi, marjinal etki, yerel RDD etkisi veya tahmin kaybı gibi hedefi matematiksel olarak tanımla.
3. **Veri yapısı ve ölçüm:** Sonuç değişkeni, tedavi değişkeni, kontroller, örneklem ve eksik veri mekanizmasını açıkla.
4. **Tanımlama:** Hangi varsayım gözlenen dağılımdan hedef parametreyi çıkarıyor? Bölüm 3’teki tanımlama sorusunu cevapla.
5. **Tahmin edici:** OLS, IV, Logit/Probit, Tobit, kantil, nonparametrik, RDD, düzenleştirmeye veya DML seçimini estimand’a göre yap.
6. **Tuning ve model seçimi:** Veri-temelli kararların hangi eğitim/CV sürecinden geldiğini kaydet.
7. **Çıkarım:** Robust/clustered SE, bootstrap veya DML robust SE gibi uygun belirsizlik ölçüsünü kullan.
8. **Tanı ve duyarlılık:** Fonksiyonel biçim, bant genişliği, ceza parametresi, weak IV veya placebo kontrollerini yöntemle uyumlu seç.
9. **Ekonomik yorum:** Katsayıyı veri birimine ve estimand’a geri çevir; yalnız p-değerine odaklanma.

10. **Replikasyon:** Ham veri kaynağı, temizleme kodu, model kodu, seed, paket sürümleri, tablo/şekil üretim adımlarını arşivle.



Şekil 12.5: IKT 807 boyunca kullanılan bütünleşik ampirik araştırma akışı

Temel sonuçlar

- Yüksek boyutlu tahmin ile düşük boyutlu hedef parametre çıkarımı aynı problem değildir.
- Yalnız sonuç değişkenine odaklı değişken seçimi, D ile güçlü ilişkili fakat outcome denkleminde zayıf görünen karıştırıcıları dışarıda bırakabilir.
- Double selection, sonuç ve tedavi tarafındaki seçilen kontrol kümelerinin birleşimini kullanır.
- Artıklaştırma (partialling-out), Y ve D 'den X 'in öngörülebilir kısmını çıkararak hedef katsayıyı artık ilişkisinden tahmin eder.
- Ortogonal moment, yardımcı tahmin hatalarının hedef momentini birinci dereceden bozmasını azaltır.
- DML, artıklaştırmaya örneklem bölme/çapraz uyarlama ekler; her artık kendi gözlemini görmemiş yardımcı modeliyle üretilir.
- DML gözlenmeyen içselliği çözmez; tanımlama varsayımı yöntemden önce gelir.
- Tez uygulamasında ön işleme, tuning, kat, seed ve replikasyon adımları ekonometrik yöntemin ayrılmaz parçasıdır.

Bu akışın en önemli özelliği doğrusal bir “komut listesi” olmamasıdır. Tanılama veya veri incelemesi araştırma sorusunu yeniden düşünmeye yol açabilir; ancak bu geri dönüşler şeffaf olmalıdır. Örneğin outcome değişkeninin ciddi sansürlü olduğu fark edilirse estimand yeniden tanımlanabilir; araç zayıfsa IV sonucu zorlanmak yerine tanımlama stratejisi sorgulanabilir.

İyi tez, yöntem adlarının çokluğu ile değil karar zincirinin tutarlılığıyla güçlenir. Her ana sonuç için okuyucu şu soruların cevabını izleyebilmelidir: Hedef parametre nedir? Hangi varsayım onu tanımlıyor? Veri bu varsayımı ne ölçüde destekliyor? Tahmin edici neden bu hedefe uygun? Belirsizlik nasıl hesaplandı? Hangi duyarlılık analizleri sonucu değiştirebilir? Bu sorular cevaplandığında OLS gibi basit bir yöntem bile güçlü; cevaplanmadığında en ileri ML yöntemi bile zayıf bir ampirik tasarım olabilir.

12.17 Bölüm Sonu Egzersizleri

Egzersiz 12.1: Omitted-variable bias

$Y = \theta D + 0,20X + u$ ve $D = 1,5X + v$ olsun. $\text{var}(X) = 1$, $\text{var}(v) = 1$ ve $X \perp v$ varsayın. X dışarıda bırakılırsa D katsayısındaki yaklaşık biası hesaplayın.

Egzersiz 12.2: Double selection

Sonuç Lasso $S_Y = \{X_1, X_4, X_8\}$, tedavi Lasso $S_D = \{X_2, X_4, X_6\}$ seçsin. Double-selection nihai kontrol kümesini yazın ve neden ortak olmayan değişkenlerin de korunması gerektiğini açıklayın.

Egzersiz 12.3: Artıklaştırma (partialling-out)

Dört gözlem için $\widehat{\mathbf{V}} = (-1, 1, 2, -2)'$ ve $\widehat{\mathbf{U}} = (-0,8, 1,1, 2,2, -1,9)'$ olsun. Sabit terim olmadan denklem (12.6) ile $\widehat{\theta}'$ 'yi hesaplayın.

Egzersiz 12.4: Ortogonal moment

denklem (12.8)'i kullanarak $E[DX'] \neq 0$ olduğunda yardımcı katsayı hatasının naif momenti neden birinci dereceden etkilediğini sözel ve matematiksel olarak açıklayın.

Egzersiz 12.5: Çapraz uyarlama (cross-fitting)

$n = 1000$, $K = 5$ ise her kat yaklaşık kaç gözlem içerir ve her yardımcı modeli yaklaşık kaç gözlemle tahmin edilir? $K = 10$ olduğunda bu sayılar nasıl değişir?

Egzersiz 12.6: DML2 hesabı

$\widehat{\mathbf{V}} = (1, 2, -1)'$ ve $\widehat{\mathbf{U}} = (1,4, 3,0, -0,8)'$ olsun. denklem (12.12) ile DML2 katsayısını hesaplayın.

Egzersiz 12.7: Data leakage

Araştırmacı bütün veri üzerinde standardizasyon yapıyor, sonra 10 kat oluşturup DML çalıştırıyor. Bunun neden ideal çapraz uyarlama (cross-fitting) protokolü olmadığını ve doğru sırayı yazın.

Egzersiz 12.8: DML ve içsellik

D ile e arasında gözlenmeyen bir değişken nedeniyle korelasyon olduğunu düşünün. DML'in neden bu sorunu otomatik çözmediğini açıklayın. Hangi ders konusundaki yöntemler alternatif tanımlama sağlayabilir?

Egzersiz 12.9: Seçim örneği

Bir kontrol değişkeninin sonuç modelindeki Lasso katsayısı sıfır, tedavi modelindeki Lasso katsayısı güçlü biçimde sıfırdan farklıdır. Yalnız-sonuç Post-Lasso ve double selection bu değişkene nasıl davranır? θ çıkarımı açısından farkı açıklayın.

Egzersiz 12.10: Robust standart hata

DML son aşamasında neden homoskedastisite varsayımına bağlı klasik SE yerine heteroskedastisiteye dayanıklı SE kullanmak daha güvenli bir varsayılan seçimdir? denklem (12.15)'teki hangi terim gözleme özgü hata büyüklüğünü taşır?

Egzersiz 12.11: Rassal split duyarlılığı

Aynı veri üzerinde beş farklı seed ile DML tahminleri 0,94, 0,99, 1,02, 1,01, 0,97 bulunsun. Bu bilgiyi tek bir sonucu seçmeden nasıl raporladınız?

Egzersiz 12.12: Bütünleşik tez tasarımı

“Dijitalleşmenin firma verimliliği üzerindeki etkisi” sorusu için kesit veri ve 150 aday kontrol bulunduğunu varsayın. Estimand, tanımlama varsayımı, model seçimi/tuning, DML kullanımı, standart hata, duyarlılık ve replikasyon adımlarını içeren kısa fakat eksiksiz bir araştırma planı yazın.

Seçilmiş İleri Okumalar

Hansen (2021) bu dersin ana kaynağıdır. Aşağıdaki çalışmalar, belirli yöntemlerin özgün veya yaygın başvuru kaynakları olarak seçilmiştir. Bunlar ders notunun yerine geçen zorunlu okumalar değil; tez aşamasında yöntemin daha ileri ayrıntılarına geçmek isteyen öğrenciler için başlangıç noktalarıdır.

Nedensellik, araçsal değişkenler ve yerel etkiler

- [Imbens ve Angrist \(1994\)](#): araçsal değişkenlerde heterojen tedavi etkileri ve yerel ortalama tedavi etkisi (LATE) yorumunun temel kaynağı.

Sansürleme ve örneklem seçimi

- [Heckman \(1979\)](#): örneklem seçimi yanlılığı ve klasik iki aşamalı düzeltmenin temel çalışması.

Kantil regresyon

- [Koenker \(2005\)](#): kantil regresyon teorisi, çıkarımı ve uygulamaları için kapsamlı başvuru kaynağı.

Regresyon süreksizliği

- [Hahn et al. \(2001\)](#): RDD’de tanımlama ve tahmin teorisinin temel çalışmalarından biri.
- [Imbens ve Lemieux \(2008\)](#): uygulamalı RDD için klasik yöntemsel rehber.
- [Gelman ve Imbens \(2019\)](#): yüksek dereceli küresel polinomların RDD’de neden kaçınılması gereken bir varsayılan seçim olduğunu açıklar.
- [Calonico et al. \(2014\)](#): yanlılık düzeltmeli ve sağlam güven aralıklarıyla modern RDD çıkarımının önemli bir uzantısı.

Bootstrap

- [Efron \(1979\)](#): bootstrap yönteminin kurucu makalesi.
- [Efron ve Tibshirani \(1993\)](#): yeniden örnekleme yöntemleri için kapsamlı klasik kaynak.

Düzenleştirme ve yüksek boyutlu çıkarım

- [Hoerl ve Kennard \(1970\)](#): Ridge regresyonunun klasik kaynağı.
- [Tibshirani \(1996\)](#): Lasso tahmin edicisinin temel çalışması.
- [Belloni et al. \(2014a\)](#): yüksek boyutlu yöntemler ile yapısal/tedavi etkisi çıkarımı arasındaki bağlantıya erişilebilir bir giriş.
- [Belloni et al. \(2014b\)](#): yüksek boyutlu kontroller arasında seçim sonrasında tedavi etkisi çıkarımı ve double-selection yaklaşımı.
- [Robinson \(1988\)](#): kısmen doğrusal model ve artıkleştirme fikrinin temel yarı parametrik kaynağı.
- [Chernozhukov et al. \(2018\)](#): Double/Debiased Machine Learning, ortogonal momentler ve çapraz uyarılama için temel kaynak.

Bölüm Sonu Egzersizleri İçin Çözüm ve Açıklamalar

Konu 1

Egzersiz 1.1. (1) Y : gıda harcaması, X : hane geliri; doğal hedef $m(x) = E[Y | X = x]$. (2) Y : temerrüt göstergesi, X : mevcut müşteri özellikleri; hedef koşullu temerrüt olasılığı $P(Y = 1 | X = x) = E[Y | X = x]$. (3) Y : verimlilik, D : programa katılım; nedensel hedef $E[Y_1 - Y_0]$ gibi bir ortalama tedavi etkisidir. Son hedef yalnızca gözlenen $E[Y | D]$ karşılaştırması değildir.

Egzersiz 1.2.

$$E[Y] = 0,6(10) + 0,4(16) = 12,4.$$

Tanım gereği her iki X düzeyinde de $E[e | X] = 0$ 'dır. Koşullu ortalamanın sıfır olması bağımsızlık değildir; örneğin $\text{var}(e | X)$ iki grupta farklı olabilir.

Egzersiz 1.3.

$$E[X^2 e] = E\{E[X^2 e | X]\} = E\{X^2 E[e | X]\} = 0.$$

Bu ortogonalite, daha güçlü koşullu ortalama kısıtının sonucudur. Tersine genel olarak doğru değildir: $E[X^2 e] = 0$ tek bir moment kısıtıdır; $E[e | X] = 0$ ise e 'nin X 'in bütün uygun fonksiyonlarıyla ortogonal olmasını gerektirir.

Egzersiz 1.4. $Y = m(X) + e$ yazılır ve kare açılır. Çapraz terim

$$E[e\{m(X) - g(X)\}] = 0$$

olur; çünkü $m(X) - g(X)$, X 'in bir fonksiyonudur. İkinci kareli terim negatif olamayacağı için minimum $g(X) = m(X)$ ile elde edilir.

Egzersiz 1.5. FOC'lar

$$E[Y - a - bZ] = 0, \quad E[Z(Y - a - bZ)] = 0$$

şeklindedir. İlkinden $a = E[Y] - bE[Z]$ bulunup ikinciye yazılırsa

$$\text{cov}(Z, Y) - b \text{var}(Z) = 0$$

ve sonuç elde edilir.

Egzersiz 1.6. $m(x)$ karesel olduğu için doğrusal değildir. $a + bX$ gerçek CEF değil, doğrusal projeksiyondur. Bütün doğrusal öngörücüler arasında $E[(Y - a - bX)^2]$ değerini en küçükler.

Egzersiz 1.7. $\bar{X} = 2,5$, $\bar{Y} = 4,5$. Hesaplama

$$\hat{\beta} = 2, \quad \hat{\alpha} = -0,5$$

verir. Tahminler (1,5, 3,5, 5,5, 7,5); artıklar (0,5, -0,5, -0,5, 0,5)'tir. Hem artık toplamı hem X ile artıkların iç çarpımı sıfırdır.

Egzersiz 1.8. Amaç fonksiyonu $\mathbf{Y}'\mathbf{Y} - 2\mathbf{b}'\mathbf{X}'\mathbf{Y} + \mathbf{b}'\mathbf{X}'\mathbf{X}\mathbf{b}$ olur. Türev sıfıra eşitlenince $\mathbf{X}'\mathbf{X}\hat{\beta} = \mathbf{X}'\mathbf{Y}$ elde edilir. $\mathbf{X}'\mathbf{X}$ tekilse normal denklemlerin sonsuz sayıda çözümü vardır: bazı katsayı birleşimleri aynı uyumu verir ve tek bir çözüm belirlenemez.

Egzersiz 1.9. $\mathbf{X}'\hat{e} = 0$ kullanılan örnekleme OLS minimizasyonunun cebirsel sonucudur. $E[Xe] = 0$ anakütlerde en iyi doğrusal projeksiyonun normal denklemidir. $E[e | X] = 0$ doğrusal CEF modelinin daha güçlü koşuludur ve $E[h(X)e] = 0$ türü sonsuz sayıda moment kısıtı üretir.

Egzersiz 1.10. Güçlü tahmin ilişkisi öngörü amacı için doğrudan yararlıdır. X 'e müdahalenin Y 'yi değiştireceği sonucu ise yalnızca tahmin başarısından çıkmaz; nedensel tanımlama, uygun deneysel veya yarı-deneysel tasarım ya da savunulabilir bağımsızlık varsayımları gerekir.

Egzersiz 1.11. Olası yapı $U \rightarrow D$, $U \rightarrow Y$ ve $D \rightarrow Y$ oklarını içerir. Motivasyonu yüksek öğrenciler hem programa daha çok katılıyor hem daha yüksek not alıyorsa ham grup farkı seçim etkisini de içerir ve tedavi etkisini yukarı yönlü yansıtabilir. Yaş ve cinsiyet, motivasyon kaynaklı açık yolu kapatmıyorsa sorun devam eder.

Egzersiz 1.12. Uygun yapı ham veriyi salt-okunur tutar; temizleme kodu analiz verisini üretir; betimsel ve model kodları yalnızca üretilmiş temiz veriyi okur; tablolar ve şekiller kod tarafından yeniden oluşturulur. Ham verinin elle değiştirilmesi değişikliğin izini kaybettirir ve aynı sonucun yeniden üretilmesini zorlaştırır.

Konu 2

Egzersiz 2.1. r_1 , X_1 'in sabit ve X_2 üzerindeki doğrusal projeksiyon artığıdır; bu nedenle projeksiyon normal denklemlerinden $\text{cov}(r_1, X_2) = 0$ elde edilir. $\beta_1 = \text{cov}(r_1, Y) / \text{var}(r_1)$, X_2 ile doğrusal olarak açıklanan X_1 varyasyonu çıkarıldıktan sonra kalan değişimin Y ile ilişkisini ölçer. X_1 ile X_2 neredeyse kusursuz ilişkiliyse $\text{var}(r_1)$ küçülür ve katsayının örnekleme belirsizliği büyür.

Egzersiz 2.2. Düzey-düzey modelinde bir birim X farkı 0,12 birim Y farkıyla ilişkilidir. Log-düzey modelinde yaklaşık yüzde 12; kesin olarak

$$100(e^{0,12} - 1) \approx 12,75\%$$

sonucu elde edilir. Düzey–log modelinde X 'te yüzde 1 fark Y 'de yaklaşık 0,0012 birim farktır. Log–log modelinde katsayı esnekliktir: X 'te yüzde 1 fark Y 'de yaklaşık yüzde 0,12 farkla ilişkilidir.

Egzersiz 2.3. Marjinal ilişki $2,4 - 0,30X$ 'tir. $X = 2$ için 1,8, $X = 5$ için 0,9, $X = 8$ için 0 bulunur. Dönüm noktası $X^* = 8$ 'dir. Doğrusal katsayı 2,4 yalnızca $X = 0$ noktasındaki marjinal eğimi verir; karesel modelde marjinal ilişki sabit değildir.

Egzersiz 2.4. $D = 0$ için $\hat{Y} = 12 + 1,5X$; $D = 1$ için $\hat{Y} = 16 + 0,9X$. Grup farkı $4 - 0,6X$ 'tir. $X = 3$ için 2,2, $X = 8$ için $-0,8$ bulunur. Eşitlik $4 - 0,6X = 0$ ile $X = 6,67$ civarında gerçekleşir.

Egzersiz 2.5. $\tilde{\beta}_1 - \beta_1 = \beta_2\pi_1$ olduğundan sırasıyla yukarı, aşağı, yukarı ve sıfır yanlılık elde edilir.

Egzersiz 2.6. Homoskedastisite altında $\Omega = \sigma^2 Q_{XX}$ olduğundan

$$Q_{XX}^{-1} \Omega Q_{XX}^{-1} = Q_{XX}^{-1} (\sigma^2 Q_{XX}) Q_{XX}^{-1} = \sigma^2 Q_{XX}^{-1}.$$

Heteroskedastisitede $E[XX'e^2]$ genel olarak $\sigma^2 E[XX']$ biçiminde ayrışmaz.

Egzersiz 2.7. Klasik $t = 0,080/0,020 = 4$. HC1 altında $t \approx 2,29$. Klasik yüzde 95 aralık yaklaşık $[0,0408, 0,1192]$, HC1 aralığı $[0,0114, 0,1486]$ 'dir. Aynı örneklem ve aynı OLS amaç fonksiyonu kullanıldığı için katsayı değişmez; değişen kovaryans matrisi tahminidir.

Egzersiz 2.8. $R = I_2$ boyutu 2×2 , $r = (0, 0)'$ boyutu 2×1 'dir. Wald istatistiği

$$W = \hat{\beta}' \widehat{V}_{\hat{\beta}}^{-1} \hat{\beta}$$

şeklinde kurulur ve sıfır hipotezi altında büyük örneklemde χ_2^2 ile karşılaştırılır.

Egzersiz 2.9. (1) Program okul düzeyinde atandığı için program göstergesi okul içinde hiç değişmez; aynı okuldaki öğrenciler ortak öğretmen, yönetim ve yerel şoklara maruz kaldığından hata terimleri ilişkilidir. Örneklemde 2.700 gözlem vardır fakat programa ilişkin bağımsız bilgi birimi sayısı 60'tır.

(2) denklem (2.29) ile

$$\tau = 1 + (45 - 1) \times 0,08 = 1 + 3,52 = 4,52, \quad \sqrt{4,52} \approx 2,13.$$

Yani doğru standart hata, kümelenmeyi yok sayan standart hatanın yaklaşık 2,1 katıdır.

(3) $0,021 \times 2,13 \approx 0,045$. Katsayı değişmez; yalnız belirsizlik ölçüsü değişir. HC1 ile t istatistiği yaklaşık iki kat büyük görünürdü; bu, kümelenmenin ihmal edilmesinin çıkarımı nasıl bozduğunun somut ölçüsüdür.

(4) $G = 60$, Bölüm 2.7'deki kaba eşğin (30–50) hemen üstündedir; yani asimptotik yaklaşım sınırdadır. Uygulamada $G - 1 = 59$ serbestlik dereceli t dağılımı kullanmak, wild cluster bootstrap ile kontrol etmek veya okul düzeyinde toplulaştırılmış veriyle analizi tekrarlamak makul duyarlılık adımlarıdır. Tabloda G mutlaka raporlanmalıdır.

Egzersiz 2.10. (1) Marjinal ilişki

$$0,036 + 2(10)(-0,00058) = 0,036 - 0,0116 = 0,0244.$$

Yani 10 yıl deneyime sahip gözlemler için bir yıllık ek deneyim yaklaşık yüzde 2,4'lük koşullu log ücret farkıyla ilişkilidir.

(2) Gradyan $H = (1, 2x)' = (1, 20)'$. [denklem \(2.31\)](#) ile

$$\text{var} = 6,4 \times 10^{-7} + 400(2,6 \times 10^{-10}) + 2(20)(-1,1 \times 10^{-8}).$$

Terim terim: $6,4 \times 10^{-7} + 1,04 \times 10^{-7} - 4,4 \times 10^{-7} = 3,04 \times 10^{-7}$. Standart hata $\sqrt{3,04 \times 10^{-7}} \approx 0,00055$.

(3) Kovaryans terimi ihmal edilirse varyans $7,44 \times 10^{-7}$ ve standart hata $\approx 0,00086$ olurdu; yani yaklaşık yüzde 56 daha büyük. Burada kovaryans negatif olduğu için ihmal etmek standart hatayı *şişirir*; pozitif kovaryansta ise gereğinden küçük gösterirdi. İki katsayı arasındaki ilişki bilinmeden yön önceden söylenemez, bu yüzden terim asla atlanmamalıdır.

(4) Dönüm noktası bir orandır ve gradyanında $\hat{\beta}_{exp^2}^2$ paydası bulunur. $\hat{\beta}_{exp^2}$ sifıra yakınsa (yani eğrilik zayıf biçimde tahmin edilmişse) birinci dereceden yaklaşım bozulur, dağılım çarpıklaşır ve delta yöntemi standart hatası güvenilirmez olur. Bu durumda güven aralığını doğrudan test ters çevirmesiyle kurmak (zayıf tanımlamaya dayanıklı çıkarım) tercih edilmelidir; standart bootstrap zayıf tanımlamayı onarmaz ([Bölüm 10](#)).

Egzersiz 2.11. (1) Bildirilen p -değeri, tek bir önceden belirlenmiş test yapıldığı varsayımı altında hesaplanır. Araştırmacı 12 spesifikasyon deneyip en küçük p -değerlisini seçtiğinde gerçek Tip I hata olasılığı nominal yüzde 5'in çok üzerindedir; raporlanan $p = 0,03$ bu seçim sürecini yansıtmaz.

(2) Bağımsızlık varsayımıyla en az bir reddetme olasılığı

$$1 - (0,95)^{12} \approx 1 - 0,540 = 0,460.$$

Yani bütün hipotezler doğru olsa bile yaklaşık yüzde 46 olasılıkla en az bir “anlamlı” sonuç çıkar. Spesifikasyonlar aynı veriyi kullandığı için gerçekte bağımsız değildir; bu hesap kaba bir üst sınır sezgisi verir, fakat problemin büyüklüğünü gösterir.

(3) Reddedememek H_0 'ın doğru olduğunun kanıtı değildir; test düşük güçlü olabilir. Doğru raporlama güven aralığı üzerindendir: “Katsayı $\hat{\beta}$ olarak tahmin edilmiş, yüzde 95 güven aralığı $[\cdot, \cdot]$ bulunmuştur. Aralık ekonomik olarak anlamlı büyüklükleri dışlamamaktadır” veya aralık darsa “ekonomik olarak önemli büyüklükler dışlanmaktadır” denmelidir. “Etki yoktur” ifadesi hiçbir durumda testten doğrudan çıkmaz.

Egzersiz 2.12. Katsayının standart hatasına oranı yaklaşık 4,29 olduğu için sıfırdan istatistiksel olarak hassas biçimde ayrılır. Ancak politika değişkeni en fazla 0,2 kadar değişebiliyorsa tahmin edilen maksimum sonuç değişimi yalnızca $0,003 \times 0,2 = 0,0006$ 'dır. Bunun ekonomik önemi sonuç değişkeninin ölçeği ve politika maliyetiyle birlikte değerlendirilmelidir.

Egzersiz 2.13. HC3 heteroskedastisite ve kaldıraç etkilerine karşı standart hata tahminini iyileştirebilir. U biçimli artık deseni ise koşullu ortalama/fonksiyonel biçim sorunudur; yalnızca kovaryans matrisini değiştirmek bunu çözmez. Yüksek kaldıraç gözlemlerinde leave-one-out, etki

ölçüleri ve gerekçeli duyarlılık karşılaştırmaları yapılabilir.

Egzersiz 2.14. Yaklaşık yorum yüzde -18 'dir. Kesin yorum

$$100(e^{-0,18} - 1) \approx -16,47\%$$

olur. δ sifıra yaklaştıkça $e^\delta - 1 \approx \delta$ olduğundan iki yorum yakınsar.

Egzersiz 2.15. Uygun bir raporlama örneği: “Eğitim katsayısı 0,065 ve HC1 standart hatası 0,014’tür; diğer model değişkenleri sabitken bir ek eğitim yılı yaklaşık yüzde 6,5 daha yüksek koşullu ücretle ilişkilidir.” “Bu katsayının nedensel eğitim getirisi olarak yorumlanabilmesi, eğitim seçimi ile ücretin gözlenemeyen belirleyicileri arasındaki ilişkiyi ortadan kaldıran ayrıca savunulabilir bir tanımlama stratejisi gerektirir.”

Egzersiz 2.16. (1) $ESS = TSS - SSE = 100$ ve $R^2 = 100/400 = 0,25$.

(2) denklem (2.9) ile $\bar{R}^2 = 1 - 0,75 \times 124/120 = 1 - 0,775 = 0,225$.

(3) denklem (2.36) ile

$$F = \frac{0,25/4}{0,75/120} = \frac{0,0625}{0,00625} = 10;$$

istatistik $F_{4,120}$ dağılımıyla karşılaştırılır.

(4) Yeni modelde $k = 6$ ve $R^2 = 1 - 297/400 = 0,2575$; R^2 monotonluk gereği artar. $s^2 = 297/119 \approx 2,4958$ ve $s_Y^2 = 400/124 \approx 3,2258$ olduğundan $\bar{R}^2 \approx 1 - 0,7737 = 0,2263$ bulunur; $\bar{R}^2$ de biraz artar. Yeni regresör için

$$F = \frac{300 - 297}{297/119} \approx 1,202 = t^2, \quad |t| \approx 1,10.$$

$|t| > 1$ olduğu için $\bar{R}^2$ artmıştır. Oysa $|t| \approx 1,10$ yüzde 5 düzeyinde anlamlı değildir ($p \approx 0,28$). $\bar{R}^2$ artışı bu nedenle bir regresörü modele almak için zayıf bir ölçüttür.

Egzersiz 2.17. (1) Sabit terim varken $\sum_i \hat{e}_i = 0$ olduğundan $\hat{Y}$ 'nin ortalaması $\bar{Y}$ 'dir. Normal denklemler çapraz terimi sıfırladığı için

$$\sum_i (Y_i - \bar{Y})(\hat{Y}_i - \bar{Y}) = \sum_i (\hat{Y}_i - \bar{Y})^2 + \sum_i \hat{e}_i(\hat{Y}_i - \bar{Y}) = ESS$$

olur. Böylece $\hat{\rho}_{Y\hat{Y}}^2 = ESS^2 / (TSS \cdot ESS) = ESS / TSS = R^2$.

(2) Çapraz terim $2 \sum_i (\hat{Y}_i - \bar{Y})\hat{e}_i = 2\hat{\beta}'\mathbf{X}'\hat{\mathbf{e}} - 2\bar{Y} \sum_i \hat{e}_i$ biçimindedir. İlk parça her zaman sıfırdır; ikinci parça yalnız $\sum_i \hat{e}_i = 0$ iken, yani sabit terim varken sıfırdır. Sabit terimsiz modelde yalnız $\sum_i Y_i^2 = \sum_i \hat{Y}_i^2 + \sum_i \hat{e}_i^2$ geçerlidir. `statsmodels`, R ve Stata bu durumda $R^2 = 1 - SSE / \sum_i Y_i^2$ raporlar. Bu merkezlenmemiş değer sabitli modellerin R^2 'siyle karşılaştırılmaz; Bölüm 2.1.2'deki CPS örneğinde sabitsiz model 0,951, sabitli model 0,193 verir.

(3) İki modelin bağımlı değişkenleri farklıdır: log ücretin TSS 'si log ölçeğe, ücret düzeyindeki dolar kare ölçeğinde hesaplanır. R^2 kendi bağımlı değişkeninin varyasyonuna göre bir paydır ve farklı paydalar karşılaştırılmaz. Karşılaştırma aynı hedef değişken ve aynı kayıp üzerinden, örneğin ücret düzeyinin örneklem dışı öngörü hatasıyla yapılmalıdır. Log modelden düzeye dönüş ayrıca yeniden dönüştürme düzeltmesi gerektirir.

(4) denklem (2.12) ile $R_{\text{kısmi}}^2 = 16/(16 + 400) = 16/416 \approx 0,038$. Regresör, diğer regresörlerden arındırılmış Y varyasyonunun yalnız yüzde 3,8'ini açıklar; buna karşın $t = 4$ bu küçük kısmi ilişkinin kesin tahmin edildiğini gösterir. Açıklama payı ile tahmin kesinliği farklı sorulardır.

(5) denklem (2.37) ile $VIF_j = 1/(1 - 0,9) = 10$. Homoskedastik standart hata $\sqrt{10} \approx 3,16$ kat büyür.

Konu 3

Egzersiz 3.1. (1) estimand, (2) estimator, (3) identification sonucu, (4) estimate'tir. Estimand neyin öğrenileceğini; identification bunun gözlenen veriden hangi varsayımlarla belirlenebildiğini; estimator örneklem kuralını; estimate ise belirli örneklemde elde edilen sayıyı ifade eder.

Egzersiz 3.2. Bireysel etkiler sırasıyla 4, 1 ve 6; ATE $11/3 \approx 3,67$ 'dir. Gerçekleşen sonuçlar $A = 9$, $B = 7$, $C = 10$ olur. Her bireyde diğer potansiyel sonuç gözlenmediği için bireysel etki doğrudan hesaplanamaz.

Egzersiz 3.3. Gözlenen fark $40 - 30 = 10$ 'dur. Tedavi görenlerin karşı-olgusal ortalaması 35 olduğundan $ATT = 40 - 35 = 5$ ve seçim farkı $35 - 30 = 5$ 'tir. Gözlenen fark $5 + 5 = 10$ olarak ayrışır; pozitif seçim ham farkı ATT'nin üzerinde gösterir.

Egzersiz 3.4. Rassal atama $E[Y_1 | D = 1] = E[Y_1]$ ve $E[Y_0 | D = 0] = E[Y_0]$ verir. Tutarlılık/gerçekleşen sonuç ilişkisiyle $E[Y | D = 1] = E[Y_1 | D = 1]$ ve benzeri yazılır; fark ATE'ye eşit olur.

Egzersiz 3.5. Koşullu bağımsızlık, aynı lise notu ve aile geliri profiline sahip öğrenciler arasında burs katılımının potansiyel mezuniyet sonuçlarından bağımsız olduğunu varsayar. Ortak destek, aynı X düzeyinde hem katılan hem katılmayan gözlem olmasını gerektirir. Program yalnızca notu 90 üzerindekiyle açıksa düşük not bölgesinde tedavi olasılığı sıfırdır; nedensel karşılaştırma orada veriden tanımlanmaz.

Egzersiz 3.6.

$$\beta^* = 1,5 + \frac{0,6}{2} = 1,8.$$

Büyük örneklem OLS 1,8'e yakınsar. Örneklemi büyütme standart hatayı küçültebilir fakat yapısal hedef 1,5'i geri getirmez.

Egzersiz 3.7. İlk durumda zayıflama çarpanı $4/(4 + 1) = 0,8$, OLS limiti $0,75 \times 0,8 = 0,60$ 'tır. Ölçüm hatası varyansı 4 olursa çarpan $4/(4 + 4) = 0,5$ ve limit 0,375 olur.

Egzersiz 3.8. Denge fiyatı hem talep hem arz şoklarına tepki verdiği için talep hata terimiyle korelasyonlu olabilir. OLS bu durumda fiyat-miktar ortak dağılımının projeksiyon eğimini verir, yapısal talep eğimini değil. Talebi tanımlamak için arzı kaydıran fakat talebi doğrudan etkilemeyen maliyet veya arz koşulu türü dışsal değişkenler araç adayı olabilir.

Egzersiz 3.9. Eşit grup paylarında

$$ATE = 0,5(8,5) + 0,5(5,5) = 7.$$

$P(H) = 0,70$ olduğunda

$$ATE = 0,7(8,5) + 0,3(5,5) = 7,6.$$

Koşullu etkiler değişmese bile anakütlede bu etkilerin hangi ağırlıklarla ortalandığı değiştiği için toplam ATE değişir.

Egzersiz 3.10. Asimptotik sapma her iki çalışmada da 0,20'dir. Büyük örneklemede standart hata çok küçülebilir; ancak tahmin daha hassas biçimde $\beta + 0,20$ civarında yoğunlaşır. İstatistiksel hassasiyet tanımlama doğruluğu değildir.

Egzersiz 3.11. Gelecek talep beklentileri hem inovasyon seçimini hem kârlılığı etkilediği için eksik değişken/karar temelli içsellik vardır. OLS yapısal inovasyon etkisini değil karışık projeksiyon ilişkisini ölçebilir. Geçerli kontrol stratejisi bu beklentileri veya yeterli vekillerini gözlemlemeyi gerektirir. Bu mümkün değilse inovasyonu etkileyen fakat kârlılığı yalnızca inovasyon üzerinden etkileyen dışsal bir araç veya doğal deney aranabilir.

Egzersiz 3.12. Her tekrarda yeni (U, v, ε) çekilir, X ve Y üretilir, iki OLS katsayısı kaydedilir. 1.000 tekrar sonunda katsayıların ortalaması, standart sapması ve gerçek 2 değerinden sapması karşılaştırılır. U dışarıdaki modelin ortalama katsayısı sistematik olarak 2'den büyük, U kontrollü modelin ortalaması ise yaklaşık 2 olmalıdır.

Konu 4

Egzersiz 4.1. (1) relevance, (2) dışsallık/ortogonallık, (3) dışlama kısıtıdır. İlk iddia aracın X 'i hareket ettirdiğini; diğer ikisi aracın Y 'ye yalnızca kabul edilen kanal üzerinden ve yapısal hatadan bağımsız biçimde ulaştığını savunur. Hiçbiri diğerinin mantıksal sonucu değildir.

Egzersiz 4.2. İndirgenmiş biçim farkı $18 - 15 = 3$, ilk aşama farkı $12,5 - 12 = 0,5$ ve Wald tahmini $3/0,5 = 6$ 'dır. İlk aşama farkı 0,05 olsaydı oran 60 olurdu; küçük payda örnekleme dalgalanmalarını büyüttüğü için tahmin son derece kırılğanlaşırdı.

Egzersiz 4.3. Moment koşulu $E[ZY] - \beta E[ZX] = 0$ verir; dolayısıyla $\beta = E[ZY]/E[ZX]$. Sabit terim varsa değişkenler merkezlenerek aynı ifade kovaryans oranına dönüşür.

Egzersiz 4.4. $P_Z' = Z(Z'Z)^{-1}Z' = P_Z$ çünkü $Z'Z$ simetriktir. Ayrıca

$$P_Z^2 = Z(Z'Z)^{-1}Z'Z(Z'Z)^{-1}Z' = P_Z.$$

Simetrik ve idempotent olması, P_Z 'nin Z sütun uzayına ortogonal projeksiyon olduğunu gösterir.

Egzersiz 4.5. $\widehat{X} = P_Z X$ olduğundan

$$\widehat{X}'\widehat{X} = X'P_Z'P_ZX = X'P_ZX$$

ve

$$\widehat{\mathbf{X}}'\mathbf{Y} = \mathbf{X}'\mathbf{P}_Z'\mathbf{Y} = \mathbf{X}'\mathbf{P}_Z\mathbf{Y}.$$

İlk eşitlikte simetri ve idempotentlik ($\mathbf{P}_Z'\mathbf{P}_Z = \mathbf{P}_Z^2 = \mathbf{P}_Z$), ikincisinde yalnız simetri ($\mathbf{P}_Z' = \mathbf{P}_Z$) kullanılır; sonuç 2SLS kapalı formudur.

Egzersiz 4.6. İlk aşamada $\mathbf{X}$, dışsal kontroller de dahil bütün araçlar üzerine regres edildiyse ($\widehat{\mathbf{X}} = \mathbf{P}_Z\mathbf{X}$), ikinci aşama OLS katsayısı projeksiyon cebri nedeniyle 2SLS katsayısına sayısal olarak her zaman eşittir: $(\widehat{\mathbf{X}}'\widehat{\mathbf{X}})^{-1}\widehat{\mathbf{X}}'\mathbf{Y} = (\mathbf{X}'\mathbf{P}_Z\mathbf{X})^{-1}\mathbf{X}'\mathbf{P}_Z\mathbf{Y}$ (Egzersiz 4.5). İlk aşamadan dışsal kontroller çıkarılırsa bu eşitlik genel olarak bozulur. Standart hata ise genel olarak yanlışır: ikinci aşama $\mathbf{X}$ yerine $\widehat{\mathbf{X}}$ kullandığından sıradan ikinci aşama artığı $\mathbf{Y} - \widehat{\mathbf{X}}\widehat{\beta}_{2SLS}$ yapısal artık değildir. Yapısal artık $\widehat{\mathbf{e}} = \mathbf{Y} - \mathbf{X}\widehat{\beta}_{2SLS}$ ile hesaplanmalı ve IV'ye uygun kovaryans matrisi kullanılmalıdır.

Egzersiz 4.7. İlk matriste ikinci satır birincinin iki katıdır; rank 1'dir. İki araç sayısal olarak mevcut olsa da yalnızca bir bağımsız ilk aşama yönü vardır ve iki endojen regresör ayrı tanımlanamaz. İkinci satır (2, 3) olursa determinant -1 ve rank 2 olur; tam rank sağlanır ve rank koşulu iki endojen regresörün ayrı ayrı tanımlanmasına izin verir.

Egzersiz 4.8. $F = 45$ olan tasarım relevance açısından çok daha güven vericidir. $F = 2,8$ zayıf araç belirtisidir; 2SLS'nin sonlu örneklem yanlışlığı, yaklaşık normal dağılımı, klasik t testleri ve güven aralıkları kırılganlaşabilir. İkinci aşama p -değeri araç gücü bilgisini içermeyiz.

Egzersiz 4.9. Aşırı tanımlama testinin sıfır hipotezi, bütün moment koşullarının ($E[Z\mathbf{e}] = 0$), dolayısıyla fazladan (aşırı tanımlayıcı) kısıtların modelle uyumlu olmasıdır. $p = 0,01$ bu ortak uyumu reddeder ve en az bir araç/moment veya yapısal spesifikasyon hakkında şüphe yaratır; hangi aracın sorunlu olduğunu tek başına söylemez. Yüksek p -değeri ise araçların geçerliliğini kanıtlamaz, yalnızca bu testte reddedilemediğini gösterir.

Egzersiz 4.10.

$$\widehat{LATE} = \frac{0,72 - 0,66}{0,60 - 0,30} = \frac{0,06}{0,30} = 0,20.$$

Gerekli IV ve monotonluk koşulları altında bu, davet nedeniyle programa katılım kararı değişen compliers grubunun ortalama etkisidir. Always-takers ve never-takers'ın tedavi statüsü araçla değişmediği için onların karşılaştırmalı etkisi bu araç varyasyonundan ayrı tanımlanamaz.

Egzersiz 4.11. IV'nin OLS'den büyük olması tek başına geçersizlik kanıtı değildir. Heterojen eğitim getirilerinde araç, yüksek getirili bir complier grubunu hareket ettiriyor olabilir ve IV LATE'yi ölçer. Değerlendirme için ilk aşama gücü, dışlama kısıtı, araç-kontrol dengesi, alternatif kanallar, robust zayıf araç çıkarımı ve ilgili tanımlama sonuçları birlikte incelenmelidir.

Egzersiz 4.12. $\ell > k$ olduğunda moment sayısı parametre sayısından fazladır; örnekleme bütün momentleri aynı anda tam sıfıra getiren bir b genellikle yoktur. GMM, $\widehat{g}(b)'W\widehat{g}(b)$ uzaklığını minimize eder; W momentlerin göreceli ağırlığını ve verimliliği belirler. Doğrusal IV/2SLS, belirli bir ağırlık seçimiyle bu çerçevenin özel durumudur.

Konu 5

Egzersiz 5.1. İkili bir değişkende koşullu ortalama doğrudan başarı olasılığıdır:

$$E[Y | X = x] = 0,37.$$

Bernoulli varyansı ise

$$\text{var}(Y | X = x) = 0,37(1 - 0,37) = 0,2331$$

olur. Genel olarak bu varyans $p(x)[1 - p(x)]$ biçiminde X ile değiştiği için ikili sonuç modelinde hata varyansı sabit olmak zorunda değildir; hatta $p(x)$ değişiyorsa heteroskedastisite doğal olarak ortaya çıkar.

Egzersiz 5.2. Eğim 0,055, X 'te bir birim artışın tahmin edilen olasılıkta 0,055, yani 5,5 yüzde puanlık bir farkla ilişkili olduğunu söyler. $X = 10$ için

$$\hat{P} = 0,18 + 0,055(10) = 0,73,$$

$X = 18$ için ise

$$\hat{P} = 0,18 + 0,055(18) = 1,17$$

bulunur. İkinci değer geçerli bir olasılık değildir. Bu, LPM'nin $[0, 1]$ sınırlarını otomatik olarak korumadığını gösterir.

Egzersiz 5.3. Logit dağılım fonksiyonu $\Lambda(a) = 1/(1 + e^{-a})$ 'dır. $X = 0$ için indeks -1 ve

$$P_0 = \Lambda(-1) \simeq 0,2689.$$

$X = 2$ için indeks 0,6 ve

$$P_2 = \Lambda(0,6) \simeq 0,6457.$$

Sürekli bir X için marjinal etki $\beta\Lambda(a)[1 - \Lambda(a)]$ olduğundan

$$ME(0) \simeq 0,8(0,2689)(0,7311) = 0,1573,$$

$$ME(2) \simeq 0,8(0,6457)(0,3543) = 0,1830.$$

Aynı katsayının farklı noktalarda farklı olasılık etkisi vermesinin nedeni bağlantı fonksiyonunun doğrusal olmamasıdır.

Egzersiz 5.4. İlk modelin olabilirliği

$$L = 0,8(1 - 0,3)0,6 = 0,336$$

ve log-olabilirliği $\log L \simeq -1,091$ 'dir. Alternatif model için

$$L_A = 0,6(1 - 0,5)0,5 = 0,15.$$

Dolayısıyla gözlenen örneklem altında ilk model daha yüksek olabilirliğe sahiptir.

Egzersiz 5.5. (1) Q , log-olabilirliğin ortalama eğriliğidir: maksimum noktasında fonksiyonun ne kadar keskin bir tepe oluşturduğunu ölçer. Ω ise skorun varyansdır: gözlemler arasında birinci derece koşuluna yapılan katkıların ne kadar oynak olduğunu ölçer.

(2) Bilgi matrisi eşitliği $\Omega = Q$, model doğru belirtilmişse geçerlidir; yani gerçek koşullu dağılım kullanılan parametrik aileye aitse. Bu durumda [denklem \(5.19\)](#)'daki klasik formül Q^{-1} kullanılır. Belirtim yanlışsa eşitlik bozulur ve [denklem \(5.17\)](#)'nin tam sandviç biçimi $Q^{-1}\Omega Q^{-1}$ geçerli kalır.

(3) Basık tepe düşük eğrilik, yani küçük Q demektir. [denklem \(5.19\)](#)'da Q^{-1} görüldüğü için varyans *büyük*. Sezgisel karşılığı şudur: birbirinden uzak çok sayıda parametre değeri veriyle neredeyse aynı derecede uyumluysa veri o parametre hakkında az bilgi taşır.

(4) LPM'de “robust”, bilinen ve yapısal olarak var olan bir heteroskedastisiteyi ($\text{var}(Y | X) = p(X)\{1 - p(X)\}$) düzeltir; doğal varsayılan seçimdir. Logit'te ise Bernoulli varyansı zaten modelin içindedir; sandviç formülü burada belirtim hatasına karşı bir düzeltmedir. Önemli sınır şudur: bağlantı fonksiyonu veya indeks yanlışsa robust standart hata katsayısı doğru hedefe getirmez, yalnız yanlış hedef etrafındaki belirsizliği daha dürüst ölçer.

Egzersiz 5.6. Probit katsayısı 0,14 doğrudan 14 yüzde puanlık olasılık değişimi değildir; latent indeksin katsayısıdır. Sürekli X_j için

$$\frac{\partial P(Y = 1 | X = x)}{\partial x_j} = \phi(x'\beta)\beta_j.$$

Ortalama marjinal etki, bu ifadenin her gözlem için tahmin edilip örneklem üzerinde ortalanmasıyla hesaplanır:

$$\widehat{AME}_j = \frac{1}{n} \sum_{i=1}^n \phi(X_i'\hat{\beta})\hat{\beta}_j.$$

Egzersiz 5.7. $X = 1$ iken $D = 0$ için indeks $-0,5 + 0,6 = 0,1$ ve

$$P_0 = \Lambda(0,1) \simeq 0,5250.$$

$D = 1$ için indeks 1,0 ve

$$P_1 = \Lambda(1) \simeq 0,7311.$$

Kukla değişkenin sonlu farkı yaklaşık

$$0,7311 - 0,5250 = 0,2061$$

yani 20,6 yüzde puandır.

Egzersiz 5.8. Tabloda yaşın AME'si Logit'te yaklaşık 0,0441, Probit'te 0,0445'tir; ekonomik büyüklük bakımından neredeyse aynıdır. “Siyah” göstergesinin AME'si (referans kategoriye göre sonlu fark) yaklaşık $-0,162$ ve $-0,158$ olduğundan, diğer kovaryatlar aynıken evli olma olasılığı beyazlara göre yaklaşık 16 yüzde puan daha düşüktür. Eğitim AME'si yaklaşık 0,003 ve standart hatası yaklaşık 0,002'dir; nokta tahmini küçüktür ve belirsizlik ihmal edilebilir değildir. Ham Logit ve Probit katsayıları farklı latent ölçek normalizasyonlarına sahip olduğundan salt katsayı büyüklükleri karşılaştırılmamalıdır; olasılıklar veya marjinal etkiler daha karşılaştırılabilir ölçülerdir.

Egzersiz 5.9. 1–5 kodunu doğrusal regresyonda nicel değişken gibi kullanmak kategoriler arası mesafelerin eşit olduğu varsayımını örtük biçimde getirir. Ordered Probit’te örneğin

$$Y^* = X'\beta + u, \quad u \sim N(0, 1) \quad (X \text{ sabit terim içermez}),$$

ve gözlenen kategori eşiklerle belirlenir:

$$Y = j \iff \alpha_{j-1} < Y^* \leq \alpha_j.$$

Bir regresörün katsayısı β_ℓ , latent indeksi kaydırır; her gözlenen kategori olasılığındaki değişim başlangıç noktasına ve eşiklere bağlıdır. Bu nedenle “kategori sayısını β_ℓ kadar artırır” yorumu doğru değildir.

Egzersiz 5.10. Multinomial modelde tüm alternatiflerin faydalarına aynı sabiti eklemek seçim olasılıklarını değiştirmez; bu nedenle parametrelerin mutlak düzeyi tanımlı değildir. Tren referans kategori seçilirse trenin katsayı vektörü sıfıra normalize edilebilir. IIA varsayımı, örneğin otobüs ve tren birbirine yakın ikame iken otomobil daha farklı bir seçenekse tartışmalıdır: IIA’ya göre otobüse çok benzer yeni bir seçeneğin eklenmesi mevcut alternatifler arasındaki göreceli olasılıkları değiştirmez, yani yeni seçenek payını bütün alternatiflerden orantılı biçimde alır; oysa yeni seçeneğin payının çoğunu otobüsten alması beklenir, bu nedenle IIA burada gerçekçi olmayabilir.

Egzersiz 5.11. $X = 0$ için beklenen sayı

$$\exp(0,4) \simeq 1,492,$$

$X = 2$ için

$$\exp(0,8) \simeq 2,226$$

olur. X ’in bir birim artışı koşullu ortalamayı $e^{0,20} \simeq 1,221$ ile çarpar; yani yaklaşık yüzde 22,1 artışla ilişkilidir. Küçük katsayı yaklaşımı yüzde 20 verir. Koşullu varyans Poisson’un ortalama–varyans eşitliğini sağlamıyorsa en azından heteroskedastisiteye dayanıklı/QMLE kovaryans matrisi düşünülmelidir; dağılımın kendisi de araştırma amacına göre yeniden değerlendirilmelidir.

Egzersiz 5.12. (i) İkili Logit/Probit veya LPM; (ii) sırasız çok kategorili sonuç için Multinomial Logit/Probit; (iii) sıralı kategoriler için Ordered Logit/Probit; (iv) negatif olmayan sayım sonucu için Poisson veya uygun daha esnek sayım modeli. İlk karar, sonuç değişkeninin desteği ve ölçüm yapısına dayanır.

Egzersiz 5.13. Logit kullanmak, tahmin edilen olasılıkların $[0, 1]$ aralığında kalmasını ve ikili sonuca uygun bir koşullu olasılık modeli kurulmasını sağlar; fakat uzaktan çalışma seçiminin içsel olup olmadığını çözmez. Nedensel yorum için seçim mekanizması, eksik değişkenler, ters nedensellik ve potansiyel sonuçlar bakımından tanımlama varsayımları ayrıca savunulmalıdır. Doğru sonuç modeli ile geçerli nedensel tasarım farklı problemlerdir.

Konu 6

Egzersiz 6.1. (1) Sansürlemedir: eşik altındaki gerçek değerlerin gözlemleri örnekleme kalır fakat aynı raporlanan değerde toplanır. (2) Kesilmedir (truncation): eşik altındaki firmalar veri

setine hiç girmez. (3) Örneklem seçimidir: ücret sonucu yalnız çalışanlarda gözlenirken seçim göstergesi ve bazı kovaryatlar bütün bireylerde gözlenir.

Egzersiz 6.2. Sansürlenme olasılığı

$$P(Y = 0 \mid X = x) = P(Y^* \leq 0 \mid X = x) = \Phi[-(1 + 0,5x)].$$

$X = 0$ için $\Phi(-1) \simeq 0,1587$; $X = 2$ için $\Phi(-2) \simeq 0,0228$ 'dir. X arttıkça latent ortalama sağa kaydığı için sıfır eşliğinin altında kalma olasılığı azalır.

Egzersiz 6.3. Latent koşullu ortalama

$$m^*(x) = x'\beta = 1.$$

Gözlenen sansürlü değişkenin koşullu ortalaması

$$m(x) = \Phi(1)(1) + \phi(1)(1) = 0,8413 + 0,2420 = 1,0833.$$

Pozitif gözlemler arasındaki koşullu ortalama ise

$$m^\#(x) = 1 + \frac{\phi(1)}{\Phi(1)} \simeq 1 + 0,2877 = 1,2877.$$

Biri latent sonucun ortalamasını, biri sıfırda sansürlenmiş gözlenen sonucun ortalamasını, diğeri yalnız sansürlenmeyenlerin ortalamasını hedeflediği için üç estimand farklıdır.

Egzersiz 6.4. $\beta_{BLP} = 2(1 - \pi)$ olduğundan sırasıyla

$$1,90, \quad 1,60, \quad 1,00$$

elde edilir. Sansür oranı yükseldikçe gözlenen değişken üzerindeki doğrusal projeksiyon eğimi sıfıra doğru küçülür. Bu ifade Hansen'de tartışılan özel normal-regresör durumuna aittir; genel Tobit modelinde evrensel bir küçülme formülü değildir.

Egzersiz 6.5. Sansürlü ilk gözlemin katkısı

$$\ell_1 = \log \Phi\left(-\frac{\mu_1}{\sigma}\right).$$

Pozitif ikinci gözlemin katkısı ise

$$\ell_2 = -\log \sigma + \log \phi\left(\frac{3 - \mu_2}{\sigma}\right).$$

İlk gözlemden yalnız latent değişkenin eşik altında kalma olasılığı bilinir; ikinci gözlemden sürekli pozitif değer bizzat gözlemlendiği için normal yoğunluk katkısı kullanılır.

Egzersiz 6.6. Gözlenen koşullu ortalama için Tobit marjinal etkisi

$$\frac{\partial E[Y \mid X = x]}{\partial x_j} = \Phi(x'\beta/\sigma)\beta_j$$

olduğundan

$$0,6915(1,5) = 1,03725.$$

Bu, latent denklem katsayısı 1,5'ten küçüktür; çünkü X_j hem pozitif olma olasılığını hem de pozitif değerlerin düzeyini etkilerken gözlenen ortalamadaki etki sansürleme nedeniyle ölçeklenir.

Egzersiz 6.7. Tam örneklem OLS eğimi yaklaşık 0,716 olduğundan gerçek 1 değerinden sapması $-0,284$ 'tür. Sıfırları silip yalnız pozitif gözlemlerde OLS yapmak yaklaşık 0,745 verir; sapma $-0,255$ olduğu için sorun ortadan kalkmaz. Tobit'in yaklaşık 1,002 eğimi üretmesi, benzetimde veri gerçekten doğrusal latent model, normal ve homoskedastik hata ile sabit sıfır sansürleme mekanizmasından üretildiği içindir. Bu varsayımlar bozulduğunda üstünlük otomatik değildir.

Egzersiz 6.8. Seçilmiş örneklemde OLS'nin yapısal β 'yı hedefleyebilmesi için kritik koşul

$$E[e \mid X, S = 1] = 0$$

olmasıdır. Seçim hata terimiyle ilişkiliyse bu koşullu beklenti sıfır değildir ve seçilmiş örneklem regresyonunda eksik değişken benzeri yanlılık oluşur. Seçim, X 'e koşullu olarak sonuç hatasından bağımsız ise seçim yapılması bu ortogonallığı bozmaz.

Egzersiz 6.9. Örneğin seçim denklemi

$$S_i^* = Z_i' \gamma + u_i, \quad S_i = 1\{S_i^* > 0\},$$

ücret denklemi

$$Y_i = X_i' \beta + e_i, \quad Y_i \text{ yalnız } S_i = 1 \text{ iken gözlenir}$$

şeklinde yazılabilir. İki aşama: (1) bütün bireylerde seçim Probit'ini tahmin et; (2) her birey için $\hat{\lambda}_i = \phi(Z_i' \hat{\gamma}) / \Phi(Z_i' \hat{\gamma})$ hesapla; (3) çalışan alt örneğine geç; (4) ücret regresyonuna $\hat{\lambda}_i$ 'yi ekleyerek β 'yı tahmin et. Küçük çocuk sayısının dışlama değişkeni olabilmesi için, diğer kontroller koşullu iken çalışma kararını etkilediği fakat teklif edilen/potansiyel ücret düzeyini doğrudan etkilemediği iktisadi olarak savunulmalıdır.

Egzersiz 6.10. İndeks sıfırken

$$\lambda(0) = \frac{0,3989}{0,5} = 0,7978.$$

İndeks birken

$$\lambda(1) = \frac{0,2420}{0,8413} \simeq 0,2877.$$

Seçilme olasılığı yüksek bir bireyin seçim eşliğini aşması daha az “uç” bir hata gerçekleşmesi gerektirdiğinden seçilmiş grubun koşullu hata düzeltmesi küçülür.

Egzersiz 6.11. Naif OLS eğiminin gerçek 2'ye mutlak uzaklığı

$$|1,849 - 2| = 0,151,$$

Heckman eğiminin uzaklığı ise

$$|2,038 - 2| = 0,038$$

dir. $\hat{\sigma}_{21} = 0,632$ tahmininin sıfırdan farklı olması, seçim denkleminin gözlenemeyenleri ile sonuç denkleminin gözlenemeyenleri arasında korelasyon bulunduğu ve dolayısıyla seçim düzeltmesinin gerekli olabileceği yapıyla uyumludur; benzetimde gerçek değer $\sigma_{21} = 0,6$ 'dır. Tek başına nedensel doğrulama değildir.

Egzersiz 6.12. “Çok sıfır” yalnız veri desenidir; sıfırların hangi mekanizmadan üretildiğini söylemez. Olasılıklar arasında gerçek köşe çözümü (harcama yapmama kararı), ölçüm/raporlama eşiğinde sansürleme, iki aşamalı katılım–pozitif harcama süreci, sayım-benzeri süreç veya yapısal sıfırlarla pozitif sürekli dağılımın karışımı vardır. Bu mekanizmalar Tobit, iki-parçalı/hurdle modelleri veya başka sınırlı sonuç modelleri gerektirebilir. Model, sıfır sayısına değil veri üretim sürecine göre seçilmelidir.

Konu 7

Egzersiz 7.1. Süreklilik altında $q_{0,25}(x) = 50$ 'dir. Bu bilgi tek başına koşullu ortalamanın değerini belirlemez; aynı 25. kantile sahip çok farklı dağılımların ortalamaları farklı olabilir. $q_{0,5}(x)$ koşullu medyandır.

Egzersiz 7.2. Mutlak sapmalar toplamı

$$Q(2) = |1 - 2| + |2 - 2| + |3 - 2| + |10 - 2| = 10,$$

$$Q(2,5) = 1,5 + 0,5 + 0,5 + 7,5 = 10,$$

$$Q(3) = 2 + 1 + 0 + 7 = 10.$$

Dört gözlemlili bu örnekte 2 ile 3 arasındaki her değer medyan kümesine dahildir ve mutlak sapmalar toplamını minimize eder.

Egzersiz 7.3. $\rho_\tau(u) = u[\tau - 1\{u < 0\}]$ kullanılır. $u = -2$ için değerler sırasıyla 1,6; 1,0; 0,4'tür. $u = 3$ için 0,6; 1,5; 2,4'tür. Düşük kantilde ($\tau = 0,2$) negatif artık daha ağır cezalandırılır; yüksek kantilde pozitif artık daha ağır cezalandırılır.

Egzersiz 7.4.

$$E[\psi_{0,25}(e)] = 0,25 - P(e < 0) = 0$$

ise

$$P(e < 0) = 0,25.$$

Dolayısıyla sürekli durumda doğru 0,25 kantil tahmininin altında gözlemlerin yaklaşık yüzde 25'i, üstünde ise yüzde 75'i kalır.

Egzersiz 7.5. $X = 2$ için

$$Q_{0,75}[Y | X = 2] = 4 + 1,5(2) = 7.$$

Eğim, X 'in bir birim artışının koşullu 75. kantilde 1,5 birimlik değişimle ilişkili olduğunu ifade eder. Hedef koşullu ortalama değil belirli bir kantil olduğundan bunu ortalama etki diye yorumlamak yanlıştır.

Egzersiz 7.6. OLS katsayısı koşullu ortalamanın doğrusal projeksiyonuna/ortalama ilişkisine, medyan regresyon katsayısı koşullu medyana ilişkin estimand'ı hedefler. İki katsayının farklı olması tek başına bir yöntemin yanlış olduğunu göstermez; farklı dağılım özelliklerini özetlerler. Araştırma sorusu gerçekten “tipik” koşullu konumu hedefliyorsa ve tipik ile medyan kastediliyorsa medyan regresyon daha doğrudan bir estimand olabilir.

Egzersiz 7.7. Eğitim katsayısının 0,90 ile 0,10 kantilleri arasındaki farkı

$$0,1226 - 0,1036 = 0,0190$$

dir (yuvarlanmamış tahminlerle 0,0189; Bölüm 7.16.2'deki fark testi bu farkın standart hatasını 0,0021 verir). Kadın katsayısındaki fark

$$-0,3134 - (-0,1969) = -0,1165$$

dir; üst kantilde kadın-erkek koşullu log ücret farkı daha negatiftir. OLS eğitim katsayısı 0,1148 ile orta kantillere yakın, kadın katsayısı $-0,2596$ ile medyan tahminine çok yakındır; ancak OLS herhangi bir kantilin tahmin edicisi değildir. Eğitim gözlemsel bir seçim değişkenidir ve eksik yetenek, aile koşulları vb. içsellik kaynakları bulunabileceğinden tablo tek başına nedensel eğitim getirisi tanımlamaz.

Egzersiz 7.8. Bağımsız hata nedeniyle koşullu kantiller yalnız hata kantili kadar dikey kayar:

$$q_{0.1}(x) = 2 + 3x - 2 = 3x,$$

$$q_{0.5}(x) = 2 + 3x,$$

$$q_{0.9}(x) = 2 + 3x + 2 = 4 + 3x.$$

Üçünün de eğimi 3 olduğu için doğrular paraleldir.

Egzersiz 7.9. Kesişim

$$2 + 0,9x = 5 + 0,35x$$

koşulundan $0,55x = 3$ ve

$$x \simeq 5,455$$

bulunur. Daha büyük x değerlerinde tahmin edilen 0,25 kantili 0,75 kantilinin üzerine çıkar; kantillerin monoton sıralaması ihlal edilir. Fonksiyonel biçimi daha esnek kurmak (örneğin dönüşüm/spline/seri yaklaşımı), ortak monotonluk kısıtı uygulamak veya tahmin edilen kantilleri rearrangement/monotonlaştırma yöntemiyle yeniden sıralamak olası çözümlerdir.

Egzersiz 7.10. Kantil tahmininin yerel hassasiyeti hedef kantil çevresindeki koşullu yoğunluğa bağlıdır. Yoğunluk düşükse küçük bir olasılık kütlelerini yakalamak için kantil değerinin daha fazla hareket etmesi gerekir; dolayısıyla örnekleme dalgalanmaları daha büyük katsayı değişimlerine dönüşür ve standart hata yükselir.

Egzersiz 7.11. Her bootstrap örnekleminde hem $\tau = 0,90$ hem $\tau = 0,10$ regresyonu yeniden tahmin edilip aynı tekrar içinde katsayı farkı kaydedilmelidir. Aynı yeniden örneklem, iki tahminin ortak örnekleme kovaryansını korur; bağımsız bootstrap'lar bu kovaryansı kaybeder ve farkın dağılımını yanlış temsil edebilir. Gözlemler okul içinde bağımlıysa yeniden örnekleme birimi birey değil okul/küme olmalıdır.

Egzersiz 7.12. (i) Koşullu ortalamayı doğrudan hedeflediği için ortalama regresyonu; (ii) düşük, orta ve yüksek kira konumları arasında heterojenlik sorulduğu için çoklu kantil regresyonları; (iii) “tipik” teslim süresi medyan anlamında kullanılıyorsa medyan regresyonu; (iv) alt yüzde 10 eşiği doğrudan hedeflediği için $\tau = 0,10$ kantil regresyonu daha doğal başlangıç noktalarıdır. Nedensel dil kullanılıyorsa yöntem seçimine ek olarak tanımlama varsayımları ayrıca gerekir.

Konu 8

Egzersiz 8.1. $u = (X_i - x)/h$ olduğundan $X_i = 10, 12, 14$ için sırasıyla $u = 0, 1, 2$ elde edilir. Normalize edilmemiş ağırlıklar

$$1, \quad e^{-1/2} \simeq 0,607, \quad e^{-2} \simeq 0,135$$

dir. En yüksek ağırlık hedef noktadaki $X_i = 10$ gözlemindedir.

Egzersiz 8.2. Ağırlıklar zaten bire toplandığı için

$$\hat{m}_{NW}(x) = 0,5(10) + 0,3(20) + 0,2(30) = 17.$$

Egzersiz 8.3. Amaç fonksiyonu

$$\sum_i K_h(X_i - x)[Y_i - a - b(X_i - x)]^2$$

dir. a , hedef x noktasındaki yerel doğrunun düzeyini; b , o çevredeki yerel eğimi temsil eder. $X_i = x$ olduğunda doğrusal yaklaşım $a + b(0) = a$ olduğu için $\hat{m}_{LL}(x) = \hat{a}(x)$ olur.

Egzersiz 8.4. $h = 1$ en yerel ve tipik olarak en dalgali; $h = 20$ en düzgün; $h = 5$ ara durumdur. Küçük h yanlılığı azaltıp varyansı artırabilir, büyük h varyansı azaltıp aşırı düzgünleştirme yanlılığını artırabilir.

Egzersiz 8.5.

$$MSE(0,3) \simeq 0,03414, \quad MSE(0,5) = 0,02625, \quad MSE(0,8) \simeq 0,05346.$$

Üç aday arasında $h = 0,5$ seçilir.

Egzersiz 8.6. En küçük çapraz doğrulama değeri 10,8 olduğu için $\hat{h} = 4$ seçilir. Bu yalnız adaylar içinde dışarıda-bırakma tahmin hatasının en düşük olduğunu gösterir; gerçek fonksiyonun kesin olarak bilindiği anlamına gelmez.

Egzersiz 8.7. $x = 40$ için $(40 - 50)_+^3 = 0$; $x = 60$ için $(60 - 50)_+^3 = 10^3 = 1000$ 'dir. Truncated-power baz fonksiyonu düğümün solunda sıfır olduğu için ilgili katsayı yalnız düğümün sağındaki eğriliği değiştirir.

Egzersiz 8.8. 90. yüzdelerde doğrusal tahmin 20,31, yerel doğrusal tahmin 21,06 olduğundan fark yaklaşık 0,75 puandır. Yerel doğrusal tahmin de örnekleme hatası ve bant seçimi içerdiği için onu “gerçek” kabul edip doğrusal modelin yanlışlığını doğrudan ölçemeyiz; yalnız fonksiyonel biçim duyarlılığını gözlüyoruz.

Egzersiz 8.9.

$$0,25^1 = 0,25, \quad 0,25^3 = 0,015625, \quad 0,25^6 \simeq 0,000244.$$

Boyut yükseldikçe hedef noktanın bütün koordinatlarında aynı anda yakın gözlem bulmak hızla zorlaşır.

Egzersiz 8.10.

$$\tilde{Y}_i = Y_i - \hat{m}_Y(X_i), \quad \tilde{D}_i = D_i - \hat{m}_D(X_i)$$

artıkları oluşturulur. Son aşamada $\tilde{Y}_i = \theta \tilde{D}_i + \text{hata}_i$ regresyonu tahmin edilir.

Egzersiz 8.11. Sonuç yanlışdır. Kernel regresyonu fonksiyonel biçimi esnekleştirir; fakat eğitim ile ücret arasındaki gözlenmeyen yetenek, aile geçmişi, seçim ve ters nedensellik gibi içsellik kaynaklarını ortadan kaldırmaz. Nedensel yorum için ayrıca tanımlama stratejisi gerekir.

Egzersiz 8.12. Önce aynı örneklem ve outcome ile dört model tahmin edilir; yerel doğrusal model için veri-temelli bant, spline için önceden belirlenmiş/çapraz doğrulamayla seçilmiş baz karmaşıklığı kullanılır. Uyumlar ortak eksenle çizilir, dış-örneklem veya çapraz doğrulama hatası karşılaştırılır ve tuning seçimlerine duyarlılık incelenir. Örneklem içi R^2 karmaşıklık arttıkça mekanik olarak iyileşebildiği için tek başına model seçme ölçütü değildir.

Konu 9

Egzersiz 9.1. Tedavi kuralı

$$D = 1\{X \leq 40\}$$

olarak yazılır. Tedavi eşik solunda olduğundan treated-minus-untreated estimand'ı sol limit eksi sağ limit biçiminde hesaplanır. Running variable'ın işaretini ters çevirmek de standart gösterime dönmeyi sağlar; ekonomik estimand değişmez.

Egzersiz 9.2. Sağ limit eksi sol limit

$$9,9 - 12,4 = -2,5$$

tir. Eşik sağındaki tedavi outcome'u 2,5 birim azaltan yerel etkiyle uyumludur.

Egzersiz 9.3. Sol doğru

$$5 + 0,4R,$$

sağ doğru

$$(5 - 2) + (0,4 + 0,1)R = 3 + 0,5R$$

dir. $R = 0$ noktasındaki sıçrama -2 'dir.

Egzersiz 9.4. Dar bant daha yerel karşılaştırma yapar ve fonksiyonel biçim yanlılığını azaltabilir, fakat $SH=2,2$ ile oldukça belirsizdir. Geniş bant daha fazla gözlem kullanarak SH 'yi $0,8$ 'e düşürür; ancak eşikten uzaktaki fonksiyonel biçime daha fazla dayanır. Sonuca bakıp en küçük p -değerini veren bandı seçmek veri-sonrası spesifikasyon aramasıdır.

Egzersiz 9.5. Nokta tahmini $-2,10$ 'dan $-1,25$ 'e gelir; tahmin $0,85$ birim sıfıra yaklaşır. Etkili örneklem 565 'ten 1.649 'a yükselirken standart hata $1,01$ 'den $0,57$ 'ye düşer. Daha geniş bant hassasiyeti artırırken tahmini sıfıra yaklaştırmıştır; bütün satırlarda güven aralığı sıfırı dışarıda bırakır.

Egzersiz 9.6. Notların eşige doğru sistematik yuvarlanması running variable'ın hassas manipülasyonuna işaret eder. Eşik sağındaki öğrenciler eşik solundakilerden gözlenmeyen özellikler bakımından seçilmiş olabilir. İlk görsel kontrol, eşığı hiçbir kutunun kesmediği dar-bin running-variable histogramıdır.

Egzersiz 9.7. Yaşın eşikte sıçraması iki tarafın önceden belirlenmiş özellikler bakımından dengesiz olabileceğini gösterir ve süreklilik temelli tasarımın inandırıcılığını zayıflatır. Yaşı regresyona eklemek hassasiyeti veya koşullu karşılaştırmayı değiştirebilir; fakat bu kadar güçlü tasarım dengesizliğini otomatik olarak nedensel tanımlamaya dönüştürmez.

Egzersiz 9.8.

$$\Delta_D = 0,70 - 0,30 = 0,40, \quad \Delta_Y = 44 - 50 = -6.$$

Dolayısıyla

$$\theta_{FRD} = \frac{-6}{0,40} = -15.$$

Egzersiz 9.9. Nokta tahmini

$$-1/0,05 = -20$$

dir. Küçük payda sampling noise'u çok büyütür; treatment sıçramasındaki küçük değişiklikler oranı büyük ölçüde oynatır. Bu yapı zayıf araç problemine benzer.

Egzersiz 9.10. Tedavi başlamadan önce ölçülen outcome treatment tarafından etkilenemez. Cut-off'ta önceden var olan sıçrama, eşik çevresinde başka bir ayırım veya seçim mekanizması bulunduğunu düşündürür ve ana nedensel yoruma karşı güçlü bir plasebo uyarısıdır.

Egzersiz 9.11. Hayır. RDD esas olarak $X = c$ civarındaki subpopülasyonun yerel etkisini tanımlar. $X = 30$ gibi uzaktaki birimler için aynı etkiyi taşımak ek etki homojenliği veya dış geçerlilik varsayımları gerektirir.

Egzersiz 9.12. Asgari rapor: eşik değişkeninin tanımı ve ölçümü; eşik ve tedavi kuralı; neden eşik bulunduğu kurumsal açıklaması; eşik iki tarafında yerel doğrusal koşullu ortalama tahminleri ve güven bantları; kullanılan kernel ile ana bant genişliği ve çıkarımda yanlışlığa nasıl yaklaşıldığı; $\hat{\theta}$, standart hata ve güven aralığı; makul alternatif bantlar; eşik değişkeni yoğunluğu; önceden belirlenmiş kovaryat dengesi; plasebo sonuç/eşik kontrollerinden en az biri. Kutulanmış ortalamalar (binned means) ana RDD grafiğinin yerine kullanılmamalıdır. Bulanık tasarımda tedavi olasılığındaki ilk-aşama sıçraması ve buna ait belirsizlik ayrıca raporlanır.

Konu 10

Egzersiz 10.1. (1) denklem (10.2) ile $\tilde{e}_i = \hat{e}_i / (1 - h_{ii})$:

$$\tilde{e}_1 = \frac{1,2}{0,70} \approx 1,714, \quad \tilde{e}_2 = \frac{-0,8}{0,55} \approx -1,455, \quad \tilde{e}_3 = \frac{-0,4}{0,75} \approx -0,533.$$

(2) OLS her gözlemi kendi tahminini üretmek için kullanır; bu nedenle sıradan artık, gözlemin gerçek öngörü hatasını olduğundan küçük gösterir. Gözlem dışarıda bırakıldığında bu “kendini açıklama” avantajı ortadan kalkar ve hata büyür. Büyütme çarpanı $1/(1 - h_{ii})$ ’dir; kaldıracağı kadar yüksekse gözlemin kendi tahmini üzerindeki etkisi ve dolayısıyla düzeltme o kadar büyüktür. Burada en yüksek kaldıracağı ikinci gözlemde oransal büyüme en fazladır.

(3) Üçü de aynı soruya dayanır: “bu gözlem kendi tahminini etkilemeseydi ne olurdu?” Jackknife bu dışarıda bırakma tahminlerinin yayılımından varyans üretir; LOOCV aynı artıkların karelerini model seçim kriteri olarak toplar; HC3 ise aynı $1 - h_{ii}$ bölmesini sandviç formülünün orta parçasında kullanır.

(4) Medyan düzgün olmayan (türevlenemez) bir fonksiyoneldir. Bir gözlem çıkarıldığında medyan ya hiç değişmez ya da komşu bir sıra istatistiğine sıçrar; ara değerler almaz. Bu kesikli davranış gerçek örnekleme değişkenliğini temsil etmez ve jackknife varyansı tutarsız olur. Aynı sorun Bölüm 7’deki kantil regresyon tahmin edicileri için de geçerlidir; bu tür problemlerde bootstrap tercih edilmelidir.

Egzersiz 10.2. Örneğin (2, 2, 5), (9, 5, 9), (5, 5, 5) ve (2, 9, 5) geçerli bootstrap örnekleridir. Yerine koyarak çekildiği için aynı değer birden çok kez görünebilir.

Egzersiz 10.3. Bootstrap ortalaması

$$\overline{\theta^*} = 2,0.$$

Kareli sapmalar toplamı 0,10 olduğundan

$$\widehat{se}_{boot} = \sqrt{0,10/3} \simeq 0,183.$$

Egzersiz 10.4. Regresyon gözlemi (Y_i, X_i) ortak realizasyonudur. İki listeyi bağımsız çekmek gözlenen ortak dağılımı ve korelasyon yapısını kırar. Pairs bootstrap bütün satırı birlikte seçmelidir.

Egzersiz 10.5. Yüzde 95 percentile aralığı doğrudan

$$[0,42; 0,91]$$

dir.

Egzersiz 10.6.

$$\text{Alt} = 3 - 1,8(0,4) = 2,28,$$

$$\text{Üst} = 3 - (-2,2)(0,4) = 3,88.$$

Dolayısıyla yüzde 95 percentile- t aralığı $[2,28; 3,88]$ 'dir.

Egzersiz 10.7. Gözlem çiftleri bootstrap'ı (pairs bootstrap) gözlenen (Y_i, X_i) satırlarını yerine koyarak çeker ve modeli yeniden tahmin eder. Parametrik bootstrap X_i 'leri sabit tutup varsayılan modelden, örneğin $e_i^* \sim N(0, \hat{\sigma}^2)$ çekerek $Y_i^* = X_i' \hat{\beta} + e_i^*$ üretir. Parametrik dağılım yanlışsa parametrik bootstrap daha kırılıgandır; pairs bootstrap bu özel dağılımsal kısıtı dayatmaz.

Egzersiz 10.8. $\xi_i^* = -1$ için $e_i^* = -2$, $\xi_i^* = 1$ için $e_i^* = 2$ olur. Mutlak büyüklük $|\hat{e}_i|$ değişmediği için gözleme özgü varyans deseninin önemli kısmı korunur.

Egzersiz 10.9. Standart hata artışı yaklaşık

$$\frac{0,076 - 0,057}{0,057} \times 100 \simeq \%33$$

tür. Pairs bootstrap 0,077 ve wild bootstrap 0,079 ile HC1 sonucuna çok daha yakındır; heteroskedastisiteyi yok sayan geleneksel standart hata belirsizliği küçümser.

Egzersiz 10.10. B dört katına çıktığında $B^{-1/2}$ yarıya iner. Dolayısıyla Monte Carlo hatası yaklaşık yüzde 50 azalır.

Egzersiz 10.11. Öğrencileri tek tek çekmek aynı okul içindeki ortak şok ve korelasyonu parçalar. Yeniden örnekleme birimi okul olmalı; 50 okul kümesi yerine koyarak çekilip seçilen okulun bütün öğrencileri birlikte alınmalıdır.

Egzersiz 10.12. Hayır. Dar bootstrap aralığı, kullanılan OLS tahmin edicisinin örnekleme dağılımının dar olduğunu gösterebilir. İçsellik nedeniyle OLS yanlış nedensel parametreye yakınsıyorsa bootstrap bu tanımlama hatasını gidermez.

Egzersiz 10.13. Protokol şu unsurları açıkça kaydetmelidir: bağımsızlık/küme yapısına uygun yeniden örnekleme birimi; nihai hesap için örneğin $B = 10000$; sabit ve kaydedilmiş seed; her bootstrap örneğinde bütün ilk-aşama/nuisance model ve nihai marjinal etkinin yeniden tahmini; başarısız/tekil tekrarların kuralı; percentile veya percentile- t gibi önceden seçilmiş aralık; kullanılan standart hata türü; sonuçların kodla yeniden üretilebildiği replikasyon dosyası.

Konu 11

Egzersiz 11.1. Model B, uyum teriminde -2ℓ 'yi 12 birim azaltmaktadır. AIC'de üç ek parametrenin cezası

$$2(8 - 5) = 6$$

olduğu için net olarak B modeli AIC'yi 6 birim düşürür ve B seçilir. BIC'de ek ceza

$$(8 - 5) \log(200) \simeq 3(5,298) = 15,89$$

dir. Uyum kazancı 12'den küçük olduğu için BIC Model A'yı seçer. Örnek, BIC'in daha güçlü parsimoniklik cezasını açıkça gösterir.

Egzersiz 11.2. Birinci tahmin edici için

$$MSE_1 = 0,30^2 + 0,20^2 = 0,13.$$

İkinci için

$$MSE_2 = 0,42^2 + 0,05^2 = 0,1789.$$

İkinci tahmin edici daha düşük yanlılığa sahip olmasına rağmen daha yüksek varyansı nedeniyle daha yüksek MSE verir.

Egzersiz 11.3. LOOCV artıklar

$$\tilde{e}_1 = \frac{1}{0,8} = 1,25, \quad \tilde{e}_2 = \frac{-2}{0,5} = -4, \quad \tilde{e}_3 = \frac{1}{0,9} \simeq 1,111.$$

Dolayısıyla

$$CV_{LOO} = \frac{1,25^2 + (-4)^2 + 1,111^2}{3} \simeq 6,27.$$

Yüksek leverage'a sahip ikinci gözlem için dışarıda-bırakma hatasının güçlü biçimde büyüdüğüne dikkat edilmelidir.

Egzersiz 11.4. Ortalama

$$\overline{CV} = \frac{2,1 + 2,5 + 2,2 + 2,8 + 2,4}{5} = 2,4.$$

Fold değerlerinin örneklem standart sapması yaklaşık

$$s \simeq 0,274$$

dir. K -katlı CV her gözlemi değerlendirme rolünde kullanıp fold sonuçlarını ortaladığı için tek bir rassal train/test bölmesinin keyfilikliğini azaltır.

Egzersiz 11.5. OLS:

$$\hat{\beta}_{OLS} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{Y} = \begin{pmatrix} 1/4 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} 8 \\ 2 \end{pmatrix} = \begin{pmatrix} 2 \\ 2 \end{pmatrix}.$$

Ridge:

$$\hat{\beta}_R = \begin{pmatrix} 5 & 0 \\ 0 & 2 \end{pmatrix}^{-1} \begin{pmatrix} 8 \\ 2 \end{pmatrix} = \begin{pmatrix} 1,6 \\ 1 \end{pmatrix}.$$

Birinci katsayı yüzde 20, ikinci katsayı yüzde 50 küçülmüştür. Veri tarafından daha zayıf tanımlanan ikinci yön, aynı cezada daha fazla küçülür.

Egzersiz 11.6. Ceza $|\beta_j|$ veya β_j^2 büyüklüğüne uygulanır. Ölçü birimi değiştiğinde aynı ekonomik ilişkiyi temsil eden katsayının sayısal büyüklüğü ters oranda değişir. Bu nedenle standartlaştırılmamış değişkenlerde ceza ekonomik önemden çok ölçü birimini yansıtabilir. Standartlaştırma katsayıları ortak ölçüye getirir.

Egzersiz 11.7. Soft-threshold kuralıyla

$$0,10 \mapsto 0, \quad -0,35 \mapsto -0,15, \quad 0,80 \mapsto 0,60.$$

Dolayısıyla Lasso katsayıları $(0, -0,15, 0,60)$ olur.

Egzersiz 11.8. İlk aşamada seçilen küme S yedi değişkenden oluşur. İkinci aşama

$$Y = X_S \beta_S + e$$

modelini OLS ile tahmin eder. Lasso katsayıları sıfıra doğru bilinçli olarak küçültür; Post-Lasso bu L_1 cezasını kaldırdığı için seçilmiş değişkenlerin katsayıları çoğu durumda mutlak değerce büyür. Bu, seçim belirsizliğinin ortadan kalktığı anlamına gelmez.

Egzersiz 11.9. Minimum CV 1,00 ve bir standart hata eşiği

$$1,00 + 0,05 = 1,05$$

dir. $\lambda = 0,10$ için $CV=1,03$ eşik içindedir; $\lambda = 0,20$ için 1,08 eşik dışındadır. Daha parsimonik adaylar içinde eşik içinde kalan en büyük ceza $\lambda = 0,10$ 'dur.

Egzersiz 11.10. Test MSE, modelin yeni gözlemlerde Y 'yi öngörme yeteneğini değerlendirir. Eğitimin ücret üzerindeki nedensel etkisi ise bir tanımlama problemidir. Gözlenmeyen yetenek, aile geçmişi veya seçim nedeniyle eğitim içselse çok iyi tahmin yapan bir Lasso modeli nedensel θ 'yı tanımlamaz. Önce hangi varsayımın karşı-olgusal etkiyi tanımladığı açıklanmalıdır.

Egzersiz 11.11. Model aynı veri üzerinde 100 kez aranmış ve raporlanan model seçim olayına bağlı hâle gelmiştir. En yüksek t değerini seçmek, tahmin edicinin ve test istatistiğinin dağılımını koşullandırır. Klasik yüzde 95 aralık model veri görülmeden sabitlenmiş gibi hesaplandığından gerçek kapsama yüzde 95'in altında olabilir. Bu, post-model-selection inference problemidir.

Egzersiz 11.12. Uygun protokol: veri önce training/test olarak ayrılır; test bölümü nihai değerlendirmeye kadar saklanır. Training içinde standardizasyon yalnız training fold'larından öğrenilerek Ridge ve Lasso için K -katlı CV yapılır. Tuning parametreleri CV ile seçilir; tahmin amacı için test MSE karşılaştırılır. Hedef katsayı için sıradan Post-Lasso standart hatası yerine

Konu 12'deki double selection/partialling-out/DML gibi selection-aware prosedür kullanılır. Bütün seed, fold, preprocessing ve aday ceza ızgaraları replikasyon dosyasında kaydedilir.

Konu 12

Egzersiz 12.1. $D = 1,5X + v$ ve $X \perp v$ olduğundan

$$\text{cov}(D, X) = 1,5, \quad \text{var}(D) = 1,5^2 + 1 = 3,25.$$

Yaklaşık omitted-variable bias

$$0,20 \frac{1,5}{3,25} \simeq 0,0923$$

dir. Dolayısıyla X dışarıda bırakılırsa D katsayısı yaklaşık $\theta + 0,092$ yönünde yukarı kayar.

Egzersiz 12.2. Birleşim

$$S = S_Y \cup S_D = \{X_1, X_2, X_4, X_6, X_8\}$$

dir. X_2 ve X_6 outcome seçiminde görünmese de D 'yi açıklıyorsa omitted-variable bias açısından kritik olabilir; X_1 ve X_8 ise outcome kanalı nedeniyle korunur.

Egzersiz 12.3.

$$\sum_i \hat{V}_i \hat{U}_i = 0,8 + 1,1 + 4,4 + 3,8 = 10,1,$$

$$\sum_i \hat{V}_i^2 = 1 + 1 + 4 + 4 = 10.$$

Dolayısıyla

$$\hat{\theta} = 10,1/10 = 1,01.$$

Egzersiz 12.4. Naif momentte

$$\frac{\partial m}{\partial \beta} = -E[DX'].$$

Bu ifade sıfır değilse $\hat{\beta} - \beta$ biçimindeki küçük nuisance hatası momentini yaklaşık

$$-E[DX'](\hat{\beta} - \beta)$$

kadar değiştirir. Yani nuisance tahmin hatası θ momentine birinci dereceden aktarılır. Ortogonal momentin amacı ilgili türevi gerçek nuisance değerinde sıfıra getirmektir.

Egzersiz 12.5. $K = 5$ için her fold yaklaşık $1000/5 = 200$ gözlem, nuisance training örneklemini yaklaşık 800 gözlemdir. $K = 10$ için her fold yaklaşık 100, training örneklemini yaklaşık 900 gözlem olur. Büyük K training setini büyütür fakat tahmin edilmesi gereken nuisance model sayısını artırır.

Egzersiz 12.6.

$$\sum_i \hat{V}_i \hat{U}_i = 1(1,4) + 2(3,0) + (-1)(-0,8) = 8,2,$$

$$\sum_i \hat{V}_i^2 = 1 + 4 + 1 = 6.$$

Bu nedenle

$$\hat{\theta}_{DML} = 8,2/6 \simeq 1,367.$$

Egzersiz 12.7. Bütün örneklem üzerinde scaler öğrenmek held-out fold'un ortalama ve standart sapma bilgisini training aşamasına taşır. Doğru sıra her fold için: training fold'larını seç; scaler/imputation/feature engineering'i yalnız training üzerinde fit et; nuisance tuning ve tahmini training üzerinde yap; dönüşümü ve tahminleri held-out fold'a uygula; residual'ları held-out fold'da üret.

Egzersiz 12.8. DML, gözlenen X ile Y ve D arasındaki esnek ilişkileri kontrol eder. Eğer gözlenmeyen U hem D hem Y ile ilişkiliyse $E[e \mid D, X] = 0$ koşulu bozulur ve ortogonalizasyon bu eksik bilgiyi yaratamaz. Uygun kurumsal yapı varsa araçsal değişken/2SLS (Konu 4) veya eşik-temelli RDD (Konu 9) alternatif tanımlama stratejileri sağlayabilir.

Egzersiz 12.9. Outcome-only seçim değişkeni sıfırladığı için nihai regresyona almayabilir. Double selection ise treatment Lasso'da seçildiği için bu değişkeni birleşim kümesine dahil eder. Değişken D ile güçlü ilişkiliyse ikinci yaklaşım θ üzerindeki omitted-variable bias riskini azaltır.

Egzersiz 12.10. DML son aşamasındaki hata varyansı $\hat{V}$ ile değişebilir. HC tipi standart hata sabit koşullu varyans varsayımına gerek duymaz. [denklem \(12.14\)](#)'teki

$$\hat{\psi}_i^2 = \hat{V}_i^2 (\hat{U}_i - \hat{\theta} \hat{V}_i)^2$$

terimi gözleme özgü residual büyüklüğünü varyans hesabına taşır.

Egzersiz 12.11. Beş tahminin ortalaması yaklaşık

$$\bar{\theta} = 0,986$$

ve aralığı $[0,94, 1,02]$ 'dir. Tek bir “en iyi” seed seçmek yerine ana seed önceden sabitlenebilir ve bu beş split bir duyarlılık analizi olarak tablo/ek materyalde raporlanabilir. Duyarlılığın küçük olduğu, fakat split kaynaklı sınırlı rassallık bulunduğu belirtilir.

Egzersiz 12.12. Örnek plan: hedef parametre θ dijitalleşme göstergesinde bir birim artışın koşullu ortalama verimlilik farkı olarak tanımlanır. Nedensel yorum için gözlenen 150 kontrol verildiğinde koşullu dışsallık ve ortak destek varsayımı açıkça savunulmalıdır. $m_D(X)$ ve $m_Y(X)$ Lasso/Post-Lasso yardımcı (nuisance) modelleriyle, tuning yalnız eğitim katlarında yapılır; 10-kath çapraz uyarılama (cross-fitting) ile DML2 tahmini ve HC robust standart hata üretilir. Alternatif ceza/algorithm, fold seed'i ve değişken tanımları için duyarlılık verilir. Ham veri kaynağı, temizleme, preprocessing, seed, paket sürümleri, model ve tablo/şekil kodları replikasyon paketinde arşivlenir. Gözlenmeyen içsellik makul ise DML sonucu nedensel diye sunulmaz; ek tanımlama stratejisi gerekir.

Kaynakça

Kaynakça

- Belloni, A., Chernozhukov, V. ve Hansen, C. B. (2014a). High-dimensional methods and inference on structural and treatment effects. *Journal of Economic Perspectives*, 28(2), 29–50.
- Belloni, A., Chernozhukov, V. ve Hansen, C. B. (2014b). Inference on treatment effects after selection among high-dimensional controls. *Review of Economic Studies*, 81(2), 608–650.
- Calonico, S., Cattaneo, M. D. ve Titiunik, R. (2014). Robust nonparametric confidence intervals for regression-discontinuity designs. *Econometrica*, 82(6), 2295–2326. DOI: 10.3982/ECTA11757.
- Chernozhukov, V., Chetverikov, D., Demirer, M., Duflo, E., Hansen, C. B., Newey, W. ve Robins, J. (2018). Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, 21(1), C1–C68.
- Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *Annals of Statistics*, 7(1), 1–26.
- Efron, B. ve Tibshirani, R. J. (1993). *An Introduction to the Bootstrap*. Chapman & Hall.
- Gelman, A. ve Imbens, G. W. (2019). Why high-order polynomials should not be used in regression discontinuity designs. *Journal of Business & Economic Statistics*, 37(3), 447–456.
- Hahn, J., Todd, P. ve van der Klaauw, W. (2001). Identification and estimation of treatment effects with a regression-discontinuity design. *Econometrica*, 69(1), 201–209.
- Hansen, B. E. (2021). *Econometrics*. University of Wisconsin–Madison, 11 Mart 2021 revizyonu. <https://users.ssc.wisc.edu/~bhansen/econometrics/>
- Heckman, J. (1979). Sample selection bias as a specification error. *Econometrica*, 47(1), 153–161.
- Hendricks, W. ve Koenker, R. (1992). Hierarchical spline models for conditional quantiles and the demand for electricity. *Journal of the American Statistical Association*, 87(417), 58–68. <https://doi.org/10.1080/01621459.1992.10475175>
- Hoerl, A. E. ve Kennard, R. W. (1970). Ridge regression: Biased estimation for non-orthogonal problems. *Technometrics*, 12(1), 55–67.
- Imbens, G. W. ve Angrist, J. D. (1994). Identification and estimation of local average treatment effects. *Econometrica*, 62(2), 467–475.
- Imbens, G. W. ve Lemieux, T. (2008). Regression discontinuity designs: A guide to practice. *Journal of Econometrics*, 142(2), 615–635.
- Koenker, R. (2005). *Quantile Regression*. Cambridge University Press.

- Robinson, P. M. (1988). Root- n -consistent semiparametric regression. *Econometrica*, 56(4), 931–954.
- Theil, H. (1961). *Economic Forecasts and Policy*. North-Holland.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1), 267–288.
- Wooldridge, J. M. (2020). *Introductory Econometrics: A Modern Approach* (7. baskı). Cengage Learning.