

EKONOMI YAZ SEMİNERLERİ 2026

Pamukkale Üniversitesi

Uygulamalı Finansal Ekonometri

Ders Notları

Eğitmenler: Prof. Dr. Dündar KÖK
Doç. Dr. Burak Alparslan EROĞLU

Tarihler: 29–31 Temmuz 2026 (3., 4. ve 5. Günler)

Saatler: 15.30 – 18.30

Yazılımlar: Python (Jupyter / Streamlit)

Sürüm: 26 Temmuz 2026

İçindekiler

1 Çok Değişkenli Oynaklık Modelleri	5
Notasyon ve Kısaltmalar	5
1.1 Motivasyon: Neden Çok Değişkenli Oynaklık?	6
1.2 Sabit Koşullu Korelasyon (CCC) Modeli ve Sabit-Korelasyon Testi	7
1.2.1 CCC Modeli (Bollerslev, 1990)	7
1.2.2 Sabit-Korelasyon Testleri	8
1.3 DCC-GARCH Çerçevesi (Engle, 2002)	11
1.3.1 Ayrıştırma: $H_t = D_t R_t D_t$	11
1.3.2 Adım 1: Tek Değişkenli GARCH(1,1) Tahminleri	12
1.3.3 Adım 2: DCC Korelasyon Dinamiği	12
1.3.4 Log-olabilirlik Fonksiyonu	13
1.4 Dağılım Varsayımları ve Yarı-Maksimum Olabilirlik (QMLE)	13
1.4.1 Normal QMLE: Tutarlılık ve Verimlilik	13
1.4.2 Student-t DCC	14
1.4.3 Çarpık-t Genellemesi (Hansen, 1994)	14
1.5 Tahmin Prosedürü ve Sayısal Konular	16
1.5.1 İki Adımlı MLE: Adım Adım	16
1.5.2 Optimizasyon Algoritmaları	17
1.5.3 Parametre Korelasyonu ve Tanımlama Sorunu	17
1.5.4 Pozitif Tanımlılık Koruması	17
1.6 Korelasyon Dinamiği Yorumlama	18
1.6.1 Parametre Anlamları	18
1.6.2 Yarı-Ömür Hesaplama	18
1.6.3 Koşulsuz Korelasyon: Uzun Dönem Denge	19
1.7 cDCC Düzeltmesi (Aielli, 2013)	19
1.8 ADCC: Asimetrik DCC (Cappiello ve diğ., 2006)	20
1.9 Diğer Uzantılar	20
1.9.1 GO-GARCH (van der Weide, 2002)	20
1.9.2 DECO: Dinamik Eşkorelasyon (Engle ve Kelly, 2012)	20
1.9.3 Faktör-DCC: Büyük Boyut için Yapısal Model	21
1.9.4 DCC-NL: Doğrusal Olmayan Büzme (Engle, Ledoit ve Wolf, 2019)	21
1.10 Model Seçimi: İstatistiksel Testler	22
1.10.1 Olasılık Oranı Testi	22
1.10.2 Bilgi Kriterleri	22
1.10.3 Model Güven Kümesi	22
1.11 DCC Yeterlilik Tanıları ve Yüksek Boyutta Bileşik Olabilirlik	23
1.11.1 DCC Yeterlilik Tanıları	23
1.11.2 Yüksek Boyut: Bileşik Olabilirlik (Pakel vd., 2021)	24
1.12 Uygulama: Minimum Varyans Portföy	26
1.12.1 Ortalama-Varyans Etkin Sınır	26
1.12.2 MVP Ağırlıkları	26

1.12.3	Kısıtlı MVP: Açığa Satış Yasağı	26
1.12.4	İşlem Maliyeti ve Devir (Turnover)	27
1.12.5	Rolling Window Backtest Prosedürü	28
1.12.6	Portföy Performans Değerlendirmesi	28
1.13	Uygulama: Kontrollü Simülasyon Çalışması (DCC/cDCC/ADCC ve MVP)	29
1.13.1	Adım 1: Tanımlayıcı İstatistikler	29
1.13.2	Adım 2: Tek Değişkenli GARCH(1,1)	30
1.13.3	Adım 3: DCC / cDCC / ADCC Karşılaştırması ve Geri-Kazanım	30
1.13.4	Adım 4: Kriz Penceresinde Korelasyon Dinamiği	31
1.13.5	Adım 5: Örneklem-Dışı (OOS) MVP Backtest	31
1.14	Bilimsel Görselleştirme: DCC Çıktılarının Sunumu	35
1.14.1	İlkeler	35
1.14.2	Uygulamalı Örnekler	35
1.15	Üçüncü Kısım Köprüsü: Gerçekleşen Kovaryans ve Kopula Uzantıları	38
1.15.1	Çok-Değişkenli HEAVY / DCC-HEAVY (Noureldin vd., 2012)	38
1.15.2	Kopula-DCC: Eliptik-Olmayan ve Kuyruk-Bağımlı Bağımlılık	39
2	Risk Ölçütleri ve Geriye Dönük Test	40
	Notasyon ve Kısaltmalar	40
2.1	Risk Ölçütleri: Genel Çerçeve	42
2.2	Riske Maruz Değer (Value at Risk — VaR)	43
2.2.1	VaR'ın Alt-Toplayıcı Olmadığı Örnek	44
2.3	Beklenen Kayıp (Expected Shortfall — ES)	44
2.3.1	ES'nin VaR'a Göre Üstünlükleri	45
2.4	Belirlenebilirlik ve Kayıp Fonksiyonları	45
2.4.1	Fissler-Ziegel Ortak Puanlama Ailesi ve AL Skoru	46
2.4.2	Strictly Proper Scoring Rules Teorisi	47
2.5	Bireysel VaR ve ES Tahmini	47
2.5.1	(a) Parametrik Yöntemler: Normal ve Student- t	48
2.5.2	(b) Tarihsel Simülasyon (Historical Simulation — HS)	48
2.5.3	(c) Filtrelenmiş Tarihsel Simülasyon (Filtered HS — FHS)	49
2.5.4	(d) Genel Kuyruk-İntegrali Yöntemi	49
2.5.5	(e) Aşırı Değer Teorisi (Extreme Value Theory — EVT) ile Kuyruk Tahmini	49
2.5.6	(f) Cornish-Fisher Açılımı ile Modifiye VaR	53
2.6	Yarı-Parametrik VaR-ES Tahmincileri	53
2.6.1	Bir-Faktörlü GAS Modeli (FZ-GAS)	54
2.6.2	FZ-GARCH Modeli	54
2.6.3	CaViaR ve Asimetrik Laplace (AsL)	54
2.6.4	Gün İçi Açıklık Tabanlı VaR-ES: HAR-Range (basitleştirilmiş)	55
2.7	Öngörü Kombinasyonu (Forecast Combination)	55
2.7.1	Motivasyon	55
2.7.2	Basit Birleştirme Kuralları	56
2.7.3	VaR ve ES için Kombinasyon (Taylor, 2020)	56

2.8	Geriye Dönük Test (Backtesting)	57
2.8.1	VaR Geriye Dönük Test	57
2.8.2	Basel Trafik Işığı Yaklaşımı	58
2.8.3	ES Geriye Dönük Test: Acerbi-Szekely Testi	59
2.8.4	Berkowitz (2001) Testi: PIT Yaklaşımı	60
2.8.5	Model Karşılaştırma Testleri (DM, MCS, SPA)	60
2.9	PELVE: VaR–ES Dönüştürme Köprüsü	62
2.9.1	Ekonomik ve Finansal Yorum	62
2.9.2	Matematiksel Özellikler	63
2.9.3	Basel FRTB Eşleşmesi ve $c = 2.5$	63
2.10	Sistemik Risk Ölçütleri	64
2.10.1	CoVaR (Adrian ve Brunnermeier, 2016)	64
2.10.2	MES (Marginal Expected Shortfall)	64
2.11	Uygulama: Risk Paneli ve Model Karşılaştırması	65
2.11.1	Adım 1: VaR ve ES Tahminleri	65
2.11.2	Adım 2: Geriye Dönük Test Sonuçları	66
2.11.3	Adım 3: Öngörü Kombinasyonu ve Model Karşılaştırması	67
2.11.4	Adım 4: Python Kodu — Modüler Risk Paneli	69
3	Gerçekleşen Oynaklık ve Yüksek Boyutlu Kovaryans	73
	Notasyon ve Kısaltmalar	73
3.1	Gerçekleşen Varyans (Realized Variance — RV)	75
3.1.1	Mikroyapı Gürültüsü Problemi	75
3.1.2	Volatilite İmza Grafiği (Volatility Signature Plot)	76
3.1.3	İki Ölçekli RV (Two-Scale RV — TSRV)	78
3.1.4	Çekirdek Tabanlı RV Tahmin Edicileri	79
3.2	Sıçrama Ayrıştırması (Jump Decomposition)	81
3.3	HAR-RV Modeli (Corsi, 2009)	81
3.3.1	Heterojen Piyasa Hipotezi	82
3.3.2	HAR-RV-J: Sıçrama Bileşenli Uzantı	82
3.3.3	HAR-RV Tahmin ve Tanılama	83
3.3.4	HAR-RV-CJ: Sürekli Yol ve Sıçrama Ayrıştırması	83
3.4	HEAVY ve GARCH-X Modelleri	84
3.4.1	HEAVY Modeli (Shephard ve Sheppard, 2010)	84
3.4.2	GARCH-X Modeli	84
3.4.3	Realized GARCH (Hansen, Huang ve Shek, 2012)	85
3.5	Yüksek Boyutlu Kovaryans Tahmini	87
3.5.1	Sorun: Büyük Boyut Laneti	88
3.5.2	Rastgele Matris Teorisi (Random Matrix Theory)	88
3.5.3	POET Yaklaşımı (Fan, Liao ve Mincheva, 2013)	89
3.5.4	POET’te Faktör Sayısı Seçimi	90
3.5.5	Ledoit-Wolf Büzülme Tahmin Edicisi (2004)	91
3.5.6	Doğrusal Olmayan Ledoit-Wolf Büzülme (2017, 2020)	92

3.5.7	POET ile DCC'yi Birleştirmek: Koşullu Yüksek-Boyutlu Kovaryans	93
3.6	Entegre Uygulama: Gerçekleşen Oynaklık Tahmini	94
3.7	Kontrollü Simülasyon ile Ampirik Doğrulama	96
3.7.1	A. Gerçekleşen Ölçütlerin Entegre Varyansı Geri Kazanması	97
3.7.2	B. HAR Ailesi ve Realized GARCH: Öngörü Karşılaştırması	97
3.7.3	C. Yüksek Boyutlu Kovaryans: POET, Büzülme ve Faktör Sayısı	98

1 Çok Değişkenli Oynaklık Modelleri

Bölümün Amacı

Bu oturumda N varlıktan oluşan bir portföyün *zamanla değişen* kovaryans matrisini (H_t) modellemek için kullanılan DCC-GARCH ailesi ele alınacak; dinamik korelasyon yapısı tahmin edilecek ve sonuçlar minimum varyans portföy (MVP) optimizasyonuna uygulanacaktır.

Notasyon ve Kısaltmalar

Bu bölümde N varlıklı bir portföy ve T gözlemlik bir örneklem esas alınır. Notasyon, Bölüm 2 (risk ölçütleri) ile uyumludur; farklılaşan noktalar tabloda ayrıca belirtilmiştir.

Tablo 1: Temel notasyon

Sembol	Anlamı	Not
N, T	varlık sayısı, örneklem uzunluğu	Bölüm 2’de N ayrıca EVT’de gözlem sayısıdır
r_{it}, μ_{it}	varlık i ’nin getirisi ve koşullu ortalaması	
ε_{it}	şok terimi	$\varepsilon_{it} = r_{it} - \mu_{it}$
σ_{it}	varlık i ’nin koşullu oynaklığı	
$z_{it}, \mathbf{z}_t$	standartlaştırılmış artık	$z_{it} = \varepsilon_{it}/\sigma_{it}$; Bölüm 2 ile ortak
$\mathbf{z}_t^-$	negatif şok vektörü (ADCC)	$\mathbf{z}_t \odot \mathbf{1}[\mathbf{z}_t < 0]$; literatürde $\mathbf{n}_t$
H_t	koşullu kovaryans matrisi	$H_t = D_t R_t D_t$
D_t	koşullu oynaklıkların köşegen matrisi	$\text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$
R_t	koşullu korelasyon matrisi	köşegeni 1
Q_t	DCC yardımcı (yarı-korelasyon) matrisi	köşegeni 1 <i>değildir</i>
Ψ	cDCC hedef matrisi, $\mathbb{E}(\mathbf{z}_t^* \mathbf{z}_t^{*'})$	
$\bar{Q}, \bar{Q}^-$	$\mathbf{z}_t$ ve $\mathbf{z}_t^-$ ’nin koşulsuz kovaryansı	korelasyon hedeflemesinde kullanılır
$\omega_i, \alpha_i, \beta_i$	varlık i ’nin GARCH katsayıları	Bölüm 2’de α kuyruk olasılığı olduğundan orada a_1, b_1, g_1 yazılır
a, b	DCC parametreleri	$a, b > 0, a + b < 1$
c	ADCC asimetri parametresi	$c \geq 0$
ν	serbestlik derecesi (Student- t)	
θ	tahmin edilen parametre vektörü	$\hat{\theta}$: QMLE tahmini
ℓ	log-olabilirlik	
$\tau_{1/2}$	korelasyon şokunun yarı-ömrü	Bölüm 2’deki τ (test düzeyi) ile karıştırılmamalıdır
ρ_{ij}	varlıklar arası korelasyon	
$\mathbf{w}_t$	portföy ağırlık vektörü	MVP: minimum varyans portföyü
Λ_t, A	GO-GARCH faktör varyansları ve karışım matrisi	

Tablo 2: Kısaltmalar

Kısaltma	İngilizce açılımı	Türkçe karşılığı
GARCH	Generalized Autoregressive Conditional Heteroskedasticity	Genelleştirilmiş otoregresif koşullu değişen varyans
CCC	Constant Conditional Correlation	Sabit koşullu korelasyon
DCC	Dynamic Conditional Correlation	Dinamik koşullu korelasyon
cDCC	corrected DCC	Düzeltilmiş DCC (Aielli, 2013)
ADCC	Asymmetric DCC	Asimetrik DCC
DECO	Dynamic Equicorrelation	Dinamik eşkorelasyon
GO-GARCH	Generalized Orthogonal GARCH	Genelleştirilmiş ortogonal GARCH
MLE / QMLE	(Quasi-) Maximum Likelihood Estimation	(Yarı-) en çok olabilirlik tahmini
LM	Lagrange Multiplier	Lagrange çarpamı (testi)
LR	Likelihood Ratio	Olabilirlik oranı (testi)
AIC / BIC	Akaike / Bayesian Information Criterion	Akaike / Bayesçi bilgi kriteri
MCS	Model Confidence Set	Model güven kümesi
MVP	Minimum Variance Portfolio	Minimum varyans portföyü
OOS	Out-of-Sample	Örnekleme-dışı
DGP	Data Generating Process	Veri üretme süreci
PSD	Positive Semi-Definite	Pozitif yarı-tanımlı
EWMA	Exponentially Weighted Moving Average	Üstel ağırlıklı hareketli ortalama
HEAVY	High-frequency-based Volatility	Yüksek frekans temelli oynaklık
DCC-NL	DCC with Non-Linear shrinkage	Doğrusal olmayan büzmeli DCC

1.1 Motivasyon: Neden Çok Değişkenli Oynaklık?

Tek değişkenli GARCH (*Generalized Autoregressive Conditional Heteroskedasticity*) modelleri her bir varlığın koşullu varyansını (σ_{it}^2) ayrı ayrı tahmin eder; ancak portföy riski varlıklar arasındaki *koşullu korelasyonların* ($\rho_{ij,t}$) da zamana bağlı olarak değişmesiyle ilintilidir. Çok değişkenli oynaklık modelleri şu soruları ele alır:

1. Kriz dönemlerinde korelasyonlar sistematik olarak artar mı?
2. Portföy ağırlıkları bu değişime ne kadar duyarlıdır?
3. Büyük boyutlu ($N > 50$) sistemlerde hesaplanabilirlik nasıl sağlanır?

Tanım 1.1 (Koşullu Kovaryans Matrisi). $\mathbf{r}_t = (r_{1t}, \dots, r_{Nt})'$ getiri vektörü verildiğinde, koşullu kovaryans matrisi

$$H_t = \text{Cov}(\mathbf{r}_t \mid \mathcal{F}_{t-1}) = \mathbb{E}[(\mathbf{r}_t - \boldsymbol{\mu}_t)(\mathbf{r}_t - \boldsymbol{\mu}_t)' \mid \mathcal{F}_{t-1}] \quad (1)$$

olarak tanımlanır; burada $\mathcal{F}_{t-1}$ geçmişe ait bilgi kümesidir ve $\boldsymbol{\mu}_t = \mathbb{E}[\mathbf{r}_t \mid \mathcal{F}_{t-1}]$ koşullu ortalama vektörüdür.

H_t matrisinin her t döneminde *simetrik* ve *pozitif tanımlı* (Positive definite: PD) olması zorunludur; aksi hâlde portföy varyansı negatif çıkabilir. DCC ailesinin temel tasarım ilkesi, bu kısıtı yapısal olarak güvence altına almasıdır.

Ampirik Motivasyon: Kriz Dönemlerinde Korelasyon Dinamiği

Kriz dönemlerinde *ölçülen* varlıklar arası korelasyonların yükseldiği yaygın biçimde raporlanır; 1997 Asya krizi, 2008 Küresel Finans Krizi ve 2020 COVID-19 şokunda örüntü benzerdir: getiriler eş zamanlı düşer, ham korelasyonlar zirve yapar. Ancak **Forbes and Rigobon (2002)** kritik bir uyarı getirir: korelasyon katsayıları piyasa oynaklığına *koşulludur* ve yüksek-oynaklık dönemlerinde yukarı yanlıdır (heteroskedastisite yanlılığı). Bu yanlılık düzeltildiğinde 1987, 1994 ve 1997 kriz dönemlerinde koşulsuz korelasyonlarda neredeyse hiç artış bulunmaz — yani gerçek bir bağlantı sıçraması (*contagion*) değil, süregelen yüksek *karşılıklı bağımlılık* (*interdependence*). Ölçülen artışın ne kadarının gerçek olduğu, olası ekonomik kanallarla birlikte değerlendirilmelidir:

- **Sürü davranışı (herding):** Yatırımcılar belirsizlik altında aynı yönde hareket eder; tüm varlıkların satılması korelasyonları artırır.
- **Kaliteye kaçış (flight to quality):** Riskli varlıklar eş zamanlı terk edilir; bu da aralarındaki korelasyonu geçici olarak yükseltir.

Bu ayrım doğrudan DCC'nin tasarım gerekçesine bağlanır: $H_t = D_t R_t D_t$ ayrıştırması koşullu oynaklığı (D_t) koşullu korelasyondan (R_t) ayırdığından, korelasyon dinamiği oynaklık sıçramasıyla *karıştırılmadan* modellenebilir — Forbes–Rigobon yanlılığına yapısal yanıt budur. Sabit korelasyon varsayımı ise hem gerçek dinamiği hem de bu ayrımı tümüyle gözardı eder.

1.2 Sabit Koşullu Korelasyon (CCC) Modeli ve Sabit-Korelasyon Testi

Zaman-değişken R_t 'ye geçmeden önce, onu özel durum olarak içeren temel modeli — sabit koşullu korelasyon (CCC) — ve ampirik soruyu netleştirmek gerekir: sabit- R varsayımı savunulabilir mi? Değilse, DCC genellemesi ampirik olarak gereklidir.

1.2.1 CCC Modeli (Bollerslev, 1990)

Bollerslev (1990) koşullu kovaryansı, zaman-değişken oynaklıklar ile *sabit* bir korelasyon matrisine ayırır:

$$H_t = D_t R D_t, \quad D_t = \text{diag}(\sqrt{h_{1t}}, \dots, \sqrt{h_{Nt}}), \quad (2)$$

burada h_{it} tek değişkenli GARCH ile modellenir ve R zamanla değişmeyen, pozitif tanımlı korelasyon matrisidir ($r_{ii} = 1$). Tahmin iki adımlıdır: (i) her seri için GARCH(1,1) $\rightarrow$ standardize artık $z_{it} = (r_{it} - \hat{\mu}_{it})/\hat{\sigma}_{it}$ (koşullu ortalama sıfır kabul edilmiyorsa $\hat{\mu}_{it}$ çıkarılmalıdır; bkz. Denklem (16)); (ii) standardize artıkların örnek ikinci moment matrisi hesaplanır ve birim köşegene

normalize edilir:

$$\hat{S}_z = \frac{1}{T} \sum_{t=1}^T \hat{z}_t \hat{z}_t', \quad \hat{R} = \text{diag}(\hat{S}_z)^{-1/2} \hat{S}_z \text{diag}(\hat{S}_z)^{-1/2}.$$

Birinci-aşama parametreleri sabit kabul edildiğinde bu, Gaussian CCC korelasyon aşamasının doğal kapalı-form tahminidir.

CCC'nin cazibesi hesaplama ve pozitif tanımlılıktır: H_t 'nin PD olması için her $h_{it} > 0$ ve R 'nin tam-ranklı bir korelasyon matrisi olması yeterlidir (Bollerslev, 1990). Kestirilen parametre sayısı $\underbrace{3N}_{\text{marjinal}} + \underbrace{N(N-1)/2}_{\text{sabit korelasyon}}$; $N = 8$ için $24 + 28 = 52$. Orijinal biçimiyle CCC, çok-aşamalı tutarlı standart hatalar için bir yöntem sunmaz; modern uygulamada iki-adımlı DCC sandviç düzeltmesi (§1.5) kullanılır. Temel kısıt açıktır: R zamanla sabit varsayılır — kriz-dönemi korelasyon dinamiğini (§1.1) yakalayamaz. DCC (Engle, 2002) tam olarak bu varsayımı gevşetir: $R \rightarrow R_t$.

1.2.2 Sabit-Korelasyon Testleri

Her iki test de *skor (LM) mantığıyla* kurulur: yalnızca kısıtlı model — CCC — tahmin edilir, alternatif model hiçbir zaman kestirilmez. Alternatif spesifikasyon yalnızca skorun hangi yönde değerlendirileceğini tanımlar. Bu, DCC'nin 2001–2002'de henüz yaygınlaşmadığı bir dönemde pratik bir zorunluluktur; bugün de tahmin maliyeti düşük olduğu için tercih edilir.

(1) Tse (2000) LM testi. Tse (2000), CCC'yi özel durum olarak kapsayan bir modelde korelasyonu geçmiş standartlaştırılmış artıkların çapraz çarpımına bağlar:

$$\rho_{ij,t} = \rho_{ij} + \delta_{ij} z_{i,t-1} z_{j,t-1}, \quad i < j, \quad (3)$$

$$H_0 : \delta_{ij} = 0 \quad \forall i < j \quad (q = \frac{N(N-1)}{2} \text{ kısıt}). \quad (4)$$

Adım 1 — genelleştirilmiş artık. $H_t = D_t R_t D_t$ ayrıştırması sayesinde $\log |H_t| = \sum_i \log h_{it} + \log |R_t|$ ve $\varepsilon_t' H_t^{-1} \varepsilon_t = \mathbf{z}_t' R_t^{-1} \mathbf{z}_t$ olduğundan

$$\ell_t = -\frac{N}{2} \log 2\pi - \frac{1}{2} \sum_{i=1}^N \log h_{it} - \frac{1}{2} \log |R_t| - \frac{1}{2} \mathbf{z}_t' R_t^{-1} \mathbf{z}_t.$$

$\partial \log |R| / \partial R = R^{-1}$ ve $\partial (\mathbf{z}' R^{-1} \mathbf{z}) / \partial R = -R^{-1} \mathbf{z} \mathbf{z}' R^{-1}$ kullanılıp $\mathbf{e}_t \equiv R_t^{-1} \mathbf{z}_t$ tanımlanırsa korelasyon skoru sadeleşir:

$$\frac{\partial \ell_t}{\partial \rho_{ij,t}} = [R_t^{-1} (\mathbf{z}_t \mathbf{z}_t' - R_t) R_t^{-1}]_{ij} = e_{it} e_{jt} - (R_t^{-1})_{ij} \equiv u_{ij,t}. \quad (5)$$

$u_{ij,t}$ genelleştirilmiş artıktır; doğru belirtim altında $\mathbb{E}[u_{ij,t} | \mathcal{F}_{t-1}] = 0$ sağlanır.

Adım 2 — zincir kuralı. $\partial \rho_{ij,t} / \partial \delta_{ij} = z_{i,t-1} z_{j,t-1}$ olduğundan, H_0 altında ($R_t = R$):

$$\left. \frac{\partial \ell_t}{\partial \delta_{ij}} \right|_{H_0} = u_{ij,t} \cdot z_{i,t-1} z_{j,t-1}, \quad \left. \frac{\partial \ell_t}{\partial \rho_{ij}} \right|_{H_0} = u_{ij,t}. \quad (6)$$

Test şu sezgiyi biçimselleştirir: *genelleştirilmiş artık, gecikmeli çapraz çarpımla ilişkili midir?*

Adım 3 — varyans parametresi skoru. Bu blok atlanamaz; birinci-aşama belirsizliğini hesaba katan şey odur. $\partial z_{it}/\partial h_{it} = -z_{it}/(2h_{it})$ ile

$$\frac{\partial \ell_t}{\partial \theta_{1i}} = \frac{e_{it}z_{it} - 1}{2h_{it}} \cdot \frac{\partial h_{it}}{\partial \theta_{1i}}, \quad \theta_{1i} = (\omega_i, \alpha_i, \beta_i)',$$

ve GARCH türevleri özyinelemelidir:

$$\frac{\partial h_{it}}{\partial \omega_i} = 1 + \beta_i \frac{\partial h_{i,t-1}}{\partial \omega_i}, \quad \frac{\partial h_{it}}{\partial \alpha_i} = \varepsilon_{i,t-1}^2 + \beta_i \frac{\partial h_{i,t-1}}{\partial \alpha_i}, \quad \frac{\partial h_{it}}{\partial \beta_i} = h_{i,t-1} + \beta_i \frac{\partial h_{i,t-1}}{\partial \beta_i}.$$

Adım 4 — yardımcı regresyon ve istatistik. CCC tahmin edilir (N tek değişkenli GARCH + $\tilde{R}$), $\tilde{e}_t = \tilde{R}^{-1}\tilde{z}_t$ ve $\tilde{u}_{ij,t}$ kurulur. Satırları

$$\mathbf{s}_t = \left(\underbrace{\frac{\tilde{e}_{it}\tilde{z}_{it}-1}{2h_{it}} \frac{\partial \tilde{h}_{it}}{\partial \theta_{1i}}}_{3N}, \underbrace{\tilde{u}_{ij,t}}_{N(N-1)/2}, \underbrace{\tilde{u}_{ij,t}\tilde{z}_{i,t-1}\tilde{z}_{j,t-1}}_{N(N-1)/2} \right)' \quad (7)$$

olan $T \times K$ matris S için dış-çarpım (OPG) formundaki istatistik

$$LM_{\text{Tse}} = \boldsymbol{\iota}' S (S' S)^{-1} S' \boldsymbol{\iota} = T \cdot R_u^2 \xrightarrow{d} \chi_{N(N-1)/2}^2 \quad (8)$$

biçimindedir; $\boldsymbol{\iota}$ birler vektörü, R_u^2 ise $\boldsymbol{\iota}$ 'nin S üzerine regresyonundan elde edilen *merkezlenmemiş* R^2 'dir. Kısıtlı MLE'de ilk iki blok skoru sıfırlandığından istatistik fiilen üçüncü bloğu ölçer; o blokları matriste *tutmak* birinci-aşama düzeltmesini sağlar.

Ret kuralı. $LM_{\text{Tse}} > \chi_{q,1-a}^2$ ise (ya da $p < a$) H_0 reddedilir; $q = N(N-1)/2$, a anlamlılık düzeyi. Ret, “korelasyon sabit değildir” anlamına gelir — “DCC doğru modeldir” anlamına *gelmez*.

(2) Engle–Sheppard (2001) testi. Engle and Sheppard (2001) aynı boş hipotezi doğrudan korelasyon matrisi üzerinden kurar. $\text{vech}_u(\cdot)$ köşegen *üstündeki* elemanları seçen değiştirilmiş vech olmak üzere:

$$H_0 : R_t = \bar{R} \quad \forall t \quad \text{vs} \quad H_a : \text{vech}_u(R_t) = \text{vech}_u(\bar{R}) + \beta_1 \text{vech}_u(R_{t-1}) + \cdots + \beta_p \text{vech}_u(R_{t-p}). \quad (9)$$

Adım 1 — ortak standartlaştırma. Tek değişkenli GARCH'lar tahmin edilip $\mathbf{z}_t = D_t^{-1}\mathbf{r}_t$ elde edilir, ardından $\bar{R}$ kestirilir ve artıklar $\bar{R}$ 'nin *simetrik karekök* ayrıştırmasıyla *ortak* olarak standartlaştırılır:

$$\mathbf{y}_t = \bar{R}^{-1/2} \mathbf{z}_t = \bar{R}^{-1/2} D_t^{-1} \mathbf{r}_t. \quad (10)$$

H_0 altında $\mathbf{y}_t$ IID ve $\mathbb{E}[\mathbf{y}_t \mathbf{y}_t'] = I_N$ olmalıdır. Bu, testin sezgisel özüdür: sabit korelasyon doğruysa, ortak standartlaştırma *bütün* bağımlılığı temizler.

Adım 2 — yardımcı VAR. Dış çarpımın köşegen-üstü kısmı alınır:

$$\mathbf{Y}_t = \text{vech}_u(\mathbf{y}_t \mathbf{y}_t' - I_N) \quad (N(N-1)/2 \text{ boyutlu}), \quad (11)$$

ve kısıtlı bir vektör otoregresyon kurulur:

$$\mathbf{Y}_t = \boldsymbol{\alpha} + \beta_1 \mathbf{Y}_{t-1} + \cdots + \beta_s \mathbf{Y}_{t-s} + \boldsymbol{\eta}_t. \quad (12)$$

H_0 altında *hem sabit terim hem bütün gecikme katsayıları* sıfır olmalıdır. Sabit terimin de sınanması önemlidir: $\bar{R}$ örneklemden kestirildiği için sıfırdan sapma, sabit korelasyon düzeyinin kendisinin yanlış olduğunu gösterir.

Adım 3 — istatistik. $k = N(N - 1)/2$ regresand ve regresör bloğu üst üste yığılıp görünürde ilişkisiz regresyon (SUR) olarak tahmin edilir. $\hat{\delta}$ tahmin edilen katsayı vektörü, X regresör matrisi olmak üzere:

$$ES\text{-istatistiği} = \frac{\hat{\delta}' X' X \hat{\delta}}{\hat{\sigma}^2} \xrightarrow{d} \chi_{s+1}^2 \quad (13)$$

Serbestlik derecesindeki $s + 1$, s gecikme artı sabit terimden gelir ve — dikkat — N 'den *bağımsızdır*. Bu, Tse testine göre belirleyici bir ölçeklenme avantajıdır.

Varyant. Korelasyon yerine standartlaştırılmış artıkların *kovaryansı* kullanılırsa sabit terim yapısal olarak sıfır olur; test $N(N - 1) TR^2 \sim \chi_s^2$ biçiminde de yürütülebilir (Engle and Sheppard, 2001).

Ret kuralı. İstatistik $\chi_{s+1, 1-a}^2$ değerini aşarsa sabit korelasyon reddedilir. Engle–Sheppard tüm ampirik modellerinde H_0 'ı reddetmiştir.

Not 1.1 (İki testin karşılaştırması).

	Tse (2000)	Engle–Sheppard (2001)
Alternatif	$\rho_{ij,t} = \rho_{ij} + \delta_{ij} z_{i,t-1} z_{j,t-1}$	$\text{vech}_u(R_t)$ kendi gecikmelerine bağlı
Yardımcı regresyon	OPG: $\boldsymbol{\iota}$ üzerine skor matrisi	SUR/VAR: $\mathbf{Y}_t$ üzerine gecikmeleri
İstatistik	TR_u^2	$\hat{\delta}' X' X \hat{\delta} / \hat{\sigma}^2$
Serbestlik derecesi	$N(N - 1)/2$	$s + 1$
N ile ölçeklenme	kötü ($N = 50 \Rightarrow 1225$)	iyi (N 'den bağımsız)
Kalıcılık yakalar mı?	hayır (yalnız ARCH-tipi)	evet (s gecikme)

Her iki testin de ortak sınırları

(i) **Sonlu örneklem boyutu.** OPG tabanlı LM testleri sonlu örneklemden aşırı ret verme eğilimindedir. Engle–Sheppard testi ise ters yönde bozulur: yazarların Monte Carlo çalışmasında test *düşük boyutludur* — %5 nominal düzeyde gerçekleşen boyut tipik olarak %2–%3 civarındadır ve bunun nedeni birinci-aşama GARCH parametre belirsizliğidir. Yani test muhafazakârdır; reddettiğinde güvenilir, reddedemediğinde kesin sonuç değildir.

(ii) **Sıkıntılı parametre (nuisance).** DCC'nin β (kalıcılık) parametresi H_0 altında *tanımlanamaz*; bu, Davies/Andrews–Ploberger tipi bir problemdir. Engle–Sheppard bunu, β 'yı belirlemeyi gerektirmeyen yardımcı VAR ile aşar. Aynı nedenle CCC ile DCC arasında naif bir LR karşılaştırması geçerli değildir.

(iii) **Yerel test.** Tse'nin toplamsal alternatifi $\rho_{ij,t} \in [-1, 1]$ veya $R_t \succ 0$ garanti etmez. Sorun değil: skor yalnızca $\delta = 0$ noktasında değerlendirilir, alternatifi küresel olarak geçerli bir model olması gerekmez.

(iv) **Neyi ayırt edemezler.** Hiçbiri dinamik korelasyonu, *yanlış belirtilmiş tek değişkenli varyans* modelinden kesin biçimde ayıramaz. Engle–Sheppard'ın Monte Carlo'su bu konuda cesaret vericidir: GARCH(2,1), GARCH(2,2) ve GARCH(3,2) süreçlerine GARCH(1,1) uydurulduğunda testin boyutu neredeyse hiç bozulmamıştır. Yine de ret, önce oynaklık modelinin tanılarıyla birlikte okunmalıdır.

(v) **Güç.** Engle–Sheppard’ın güç deneylerinde test, uzak alternatiflerde birim güce ulaşır; yakın alternatiflerde ($a = 0.005$) $N = 2$ için ≈ 0.42 , $N = 10$ için ≈ 0.66 düzeyindedir. Güç N ile ve b ile artar.

Standart test ile öğretici tanıyı ayırın

Korelasyon dış-çarpımlarını tek bir havuzlanmış skaler regresyonda toplamak, yararlı bir omnibus seri-bağımlılık tanısı verebilir; ancak bu regresyon, ne Denklem (8)’teki Tse istatistiği ne de Denklem (13)’teki Engle–Sheppard istatistiğidir. Seriler arası hata kovaryansını ve çoklu kısıt yapısını yok sayan havuzlanmış regresyona analitik χ^2 kritik değeri uygulanmamalıdır; geçerli çıkarım için CCC altında parametrik bootstrap gerekir. Aşağıdaki kod bu *öğretici* tanıyı gösterir.

Python: öğretici omnibus tanı ve bootstrap ilkesi

```
1 import numpy as np
2
3 # Y_t = vech_u(eps_t eps_t' - I) serileri olusturulduktan sonra,
4 # her eleman icin gecikmeli regresyonlar veya ortak bir SUR/VAR
   kurulabilir.
5 # Asagidaki havuzlanmis regresyon yalnızca tanisal bir istatistik
   uretir;
6 # analitik chi-kare p-degeri atanmaz.
7 def pooled_diagnostic(Y, s):
8     T, P = Y.shape
9     yv = np.concatenate([Y[s:, p] for p in range(P)])
10    Z = np.vstack([
11        np.column_stack([np.ones(T - s)] +
12                        [Y[s-j:T-j, p] for j in range(1, s + 1)])
13        for p in range(P)
14    ])
15    beta = np.linalg.lstsq(Z, yv, rcond=None)[0]
16    resid = yv - Z @ beta
17    return float(beta @ (Z.T @ Z) @ beta / np.mean(resid**2))
18
19 # Gecerli p-degeri icin CCC modelinden parametrik bootstrap
   uygulanir;
20 # her yolda GARCH standardizasyonu ve tanisal istatistik bastan
   hesaplanir.
```

1.3 DCC-GARCH Çerçevesi (Engle, 2002)

1.3.1 Ayrıştırma: $H_t = D_t R_t D_t$

Engle (2002) koşullu kovaryans matrisini iki bileşene ayırır:

$$H_t = D_t R_t D_t \quad (14)$$

- $D_t = \text{diag}(\sigma_{1t}, \dots, \sigma_{Nt})$: her varlığın tek değişkenli GARCH(1,1) koşullu standart sapması.
- R_t : standartlaştırılmış artıkların *dinamik koşullu korelasyon* matrisi.

Bu ayrıştırma sayesinde:

- Marjinal dağılımlar ayrı ayrı modellenir (Adım 1),
- Korelasyon dinamiği daha az parametre ile yakalanır (Adım 2).

1.3.2 Adım 1: Tek Değişkenli GARCH(1,1) Tahminleri

Her $i = 1, \dots, N$ varlığı için:

$$\sigma_{it}^2 = \omega_i + \alpha_i \varepsilon_{i,t-1}^2 + \beta_i \sigma_{i,t-1}^2 \quad (15)$$

Burada $\varepsilon_{it} = r_{it} - \mu_{it}$ şok terimidir. Parametre kısıtları: $\omega_i > 0$, $\alpha_i \geq 0$, $\beta_i \geq 0$ ve $\alpha_i + \beta_i < 1$ (kovaryans durağanlığı).

Standardize artıklar:

$$z_{it} = \frac{\varepsilon_{it}}{\sigma_{it}} \quad (16)$$

Not 1.2. $\alpha_i + \beta_i$ toplamı 1'e ne kadar yakınsa, oynaklık o kadar *kahıcıdır* (persistent). Finansal varlıklarda tipik değerler: $\alpha \approx 0.03-0.10$, $\beta \approx 0.85-0.95$.

1.3.3 Adım 2: DCC Korelasyon Dinamiği

Standartlaştırılmış artık vektörü $\mathbf{z}_t = (z_{1t}, \dots, z_{Nt})'$ kullanılarak yardımcı matris Q_t şu şekilde güncellenir:

$$Q_t = (1 - a - b) \bar{Q} + a \mathbf{z}_{t-1} \mathbf{z}_{t-1}' + b Q_{t-1} \quad (17)$$

- $\bar{Q} = T^{-1} \sum_{t=1}^T \mathbf{z}_t \mathbf{z}_t'$: standartlaştırılmış artıkların *koşulsuz* korelasyon matrisi (örnek tahmini).
- $a > 0$, $b > 0$, $a + b < 1$: DCC parametreleri.

Q_t simetrik pozitif tanımlıdır, ancak köşegeninde 1 bulunmaz. Dolayısıyla normalleştirme yapılır:

$$R_t = Q_t^{*-1} Q_t Q_t^{*-1}, \quad Q_t^* = \text{diag}(\sqrt{q_{11,t}}, \dots, \sqrt{q_{NN,t}}) \quad (18)$$

Bu normalleştirme, R_t 'nin köşegenlerinin 1 olmasını ve matrisin geçerli bir korelasyon matrisi olmasını yapısal olarak garantiler.

İki Adımlı Tahmin Neden Tercih Edilir?

Skaler DCC ve korelasyon hedeflemesi altında tam ortak tahmin (full MLE) ile iki adımlı tahmin *aynı* $3N + 2$ serbest parametreyi kullanır. İki adımlı yaklaşımın kazancı parametre sayısını düşürmek değil, tek bir yüksek boyutlu ortak optimizasyonu N ayrı tek değişkenli GARCH problemine ve iki parametrelili bir korelasyon problemine *ayrıştırmaktır*. İki adımlı yaklaşımda:

1. Adım 1'de $3N$ parametre ayrı ayrı tahmin edilir $(\omega_i, \alpha_i, \beta_i)$.

2. Adım 2’de yalnızca 2 ortak parametre (a, b) tahmin edilir.

3. Toplam parametre sayısı: $3N + 2$ ($N = 50$ için 152 parametre).

Buradaki $3N+2$, MLE ile *kestirilen* serbest parametreleri sayar; korelasyon hedeflemesi ayrıca $\bar{Q}$ ’nun $N(N-1)/2$ koşulsuz korelasyonunu momentle pinler ($N = 50$ için 1225 değer), fakat bunlar optimizasyona girmez. $O(N^2)$ büyüme ancak hedefleme bırakılıp $\bar{Q}$ serbestçe kestirildiğinde *serbest parametre* olarak ortaya çıkar; hedefleme korunuyorsa $O(N^2)$ yalnızca hedef matrisinin elemanlarında ve matris işlemlerinde görülür (her t ’de R_t ’nin tersi ve determinantı $O(N^3)$ maliyetlidir). Karşılaştırma için tam BEKK(1,1) modeli aynı sistemde $2N^2 + N(N+1)/2 = 6275$ parametre gerektirir ($N = 50$; A ve B matrislerinden $2N^2$, C üçgeninden $N(N+1)/2$).

1.3.4 Log-olabilirlik Fonksiyonu

DCC parametreleri (a, b) için korelasyon log-olabilirlik fonksiyonu:

$$\mathcal{L}_{\text{corr}}(a, b) = -\frac{1}{2} \sum_{t=1}^T (\ln |R_t| + \mathbf{z}_t' R_t^{-1} \mathbf{z}_t - \mathbf{z}_t' \mathbf{z}_t) \quad (19)$$

İlk iki terim korelasyon yapısını yakalar; $\mathbf{z}_t' \mathbf{z}_t$ terimi sabit olduğundan optimizasyonu etkilemez, ancak tam log-olabilirliğin doğru hesaplanması için dahil edilir.

1.4 Dağılım Varsayımları ve Yarı-Maksimum Olabilirlik (QMLE)

1.4.1 Normal QMLE: Tutarlılık ve Verimlilik

DCC tahmincisinin teorik temeli [Bollerslev and Wooldridge \(1992\)](#) tarafından geliştirilen *quasi-maksimum olabilirlik tahmincisi* (QMLE) çerçevesine dayanır. Getiriler normal dağılımlı olmasa bile, normal log-olabilirlik fonksiyonu maksimize edilerek elde edilen tahminler belirli düzenlilik koşulları altında *tutarlıdır* ve *asimptotik olarak normaldir*.

Not 1.3 (DCC-QMLE’nin geçerlilik koşulları). Normal quasi-olabilirlik, getirilerin koşullu normal olmasını gerektirmez. Bununla birlikte tutarlılık; doğru belirtilmiş koşullu kovaryans dinamiği, tanımlanabilirlik, uygun parametre uzayı, pozitif tanımlılık, durağanlık ve uniform moment/düzenlilik koşulları altında elde edilir:

$$\hat{\theta} \xrightarrow{p} \theta_0.$$

Asimptotik normallik için skor ve Hessian üzerinde ilave moment ve düzgünlük koşulları gerekir. İki-aşamalı DCC tahmininde birinci aşama parametre belirsizliği ortak asimptotik kovaryansa dahil edilmelidir. Standart korelasyon hedeflemesi ayrıca [Aielli \(2013\)](#)’te gösterilen hedefleme uyumsuzluğunu doğurabilir.

Not 1.4 (Korelasyon hedeflemesi). Standart DCC’nin korelasyon hedefleme adımı, $\bar{Q}$ ’yu standardize artıkların örnek ikinci momentine eşitler. [Aielli \(2013\)](#), genel olarak $\mathbb{E}[Q_t] \neq \mathbb{E}[\mathbf{z}_t \mathbf{z}_t']$

olduğunu gösterir. cDCC (§1.7) özyinelemeyi değiştirerek hedefleme momentini tutarlı hale getirir. $\bar{Q}$ hedefleme yerine doğrudan tahmin edilirse boyut azaltma avantajı kaybolur.

Normal dağılım varsayımının hatalı olduğu durumlarda standart Fisher bilgi matrisi tahmincisi sapmalı standart hatalar üretebilir. Ortalama skor ve Hessian tanımları altında

$$\widehat{\text{Avar}}\left[\sqrt{T}(\hat{\theta} - \theta_0)\right] = \hat{A}^{-1} \hat{B} \hat{A}^{-1}, \quad (20)$$

$$\widehat{\text{Var}}(\hat{\theta}) = \frac{1}{T} \hat{A}^{-1} \hat{B} \hat{A}^{-1}, \quad (21)$$

burada

- $\hat{A} = -T^{-1} \sum_{t=1}^T \partial^2 \ell_t / (\partial \theta \partial \theta')$ ortalama negatif Hessian;
- $\hat{B} = T^{-1} \sum_{t=1}^T s_t s_t'$ ve $s_t = \partial \ell_t / \partial \theta$ skorudur.

Dağılım doğru belirtilmiş olsaydı $A = B$ olurdu. Toplam skor/Hessian kullanılırsa ölçeklerin buna göre yeniden düzenlenmesi gerekir.

1.4.2 Student-t DCC

Kalın kuyruklu getiri dağılımlarında daha verimli tahmin için Student- t dağılımı kullanılabilir. $\nu > 2$ serbestlik derecesi ile:

$$f(z_t; \nu, R_t) = \frac{\Gamma(\frac{\nu+N}{2})}{\Gamma(\frac{\nu}{2}) (\pi(\nu-2))^{N/2} |R_t|^{1/2}} \left(1 + \frac{z_t' R_t^{-1} z_t}{\nu-2}\right)^{-(\nu+N)/2} \quad (22)$$

Parametre ν küçüldükçe kuyruklar kalınlaşır; $\nu \rightarrow \infty$ sınırında normal dağılıma yaklaşır. Tipik finansal veriler için $\hat{\nu} \approx 5-10$ bulunur.

Denklem (22) ile aşağıdaki kodu karıştırmayın

Denklem (22), *ortak* bir ν ile tanımlanan çok değişkenli Student- t DCC yoğunluğudur; tahmini, korelasyon aşamasında bu yoğunluğun negatif log-olabilirliğinin ν ile *birlikte* optimize edilmesini gerektirir. Aşağıdaki kod ise yaygın kullanılan iki adımlı alternatifi uygular: marjinal kalın kuyruklar varlık bazında Student- t GARCH ile filtrelenir (her varlık kendi $\hat{\nu}_i$ 'sini alır), korelasyon aşamasında ise *Gaussian* quasi-olabilirlik kullanılır. Bu kod Denklem (22)'i tahmin etmez. QMLE argümanı gereği (a, b) tahmini yine tutarlıdır; bedeli verimlilik kaybı ve standart hatalarda sandviç düzeltmesi gerekliliğidir.

1.4.3 Çarpık-t Genellemesi (Hansen, 1994)

Hansen (1994) standart Student- t dağılımına asimetri ($\lambda \in (-1, 1)$) parametresi ekleyerek çarpık- t dağılımını önerir. Pozitif λ değerleri sağa çarpıklığı, negatif değerler sola çarpıklığı gösterir. Finansal getiri dağılımlarında sola çarpıklık ($\lambda < 0$) sıkça gözlemlenir; bu da büyük negatif şokların büyük pozitif şoklara kıyasla daha olası olduğunu gösterir.

Python: Student-*t* marjinal filtreleme + Gaussian DCC korelasyon QMLE

```

1 import numpy as np
2 from arch import arch_model
3 from scipy.optimize import minimize
4 from numba import njit
5
6 # 1. Adim: Student-t marjinal GARCH(1,1) -> standardize artiklar
7   z_t
8 N = returns.shape[1]
9 z = np.empty_like(returns, dtype=float)
10 nu = np.empty(N)
11 for i in range(N):
12     res = arch_model(returns[:, i] * 100.0, mean='Constant',
13                     vol='GARCH', p=1, q=1, dist='t').fit(dispatch='off')
14     z[:, i] = res.std_resid
15     nu[i] = res.params['nu'] # TANISAL: varlik bazinda t
16                               serbestlik derecesi
17 print("Marjinal nu tahminleri:", np.round(nu, 2)) # yalnizca
18 raporlama icin
19
20 # 2. Adim: DCC korelasyon-asamasi negatif log-olabilirlik (numba)
21 @njit(cache=True, fastmath=True)
22 def dcc_nll(a, b, z, Qbar):
23     T, N = z.shape; Q = Qbar.copy(); nll = 0.0
24     for t in range(1, T):
25         zp = z[t-1]
26         Q = (1.0 - a - b) * Qbar + a * np.outer(zp, zp) + b * Q
27         d = np.sqrt(np.diag(Q)); R = Q / np.outer(d, d)
28         s, ld = np.linalg.slogdet(R)
29         nll += 0.5 * (ld + z[t] @ np.linalg.inv(R) @ z[t] - z[t] @
30                     z[t])
31     return nll
32
33 Qbar = np.cov(z, rowvar=False)
34 def obj(p): # a,b>0 ve a+b<1 (duraganlik):
35     ceza-bariyeri
36     a, b = p
37     return dcc_nll(a, b, z, Qbar) if (a > 0 and b > 0 and a + b <
38         0.9999) else 1e10
39
40 res = minimize(obj, x0=np.array([0.04, 0.92]), method='L-BFGS-B',
41               bounds=[(1e-6, 0.5), (1e-6, 0.999)])
42 a, b = res.x
43 print(f"a={a:.4f} b={b:.4f} yari-omur={np.log(0.5)/np.log(a+b):.1
44     f} gun")

```



```

38
39 # NOT: İkinci asama GAUSSIAN quasi-olabilirliktir; metindeki ortak-
    nu çok
40 # değişkenli Student-t DCC yoğunluğunu tahmin ETMEZ. nu dizisi
    yalnizca
41 # marjinal kuyruk kalınlığını raporlamak için tutulur.
42 # NOT: arch (>=6) ÇOK DEĞİSKENLİ DCC sınıfı ICERMEZ; üstteki
    çekirdek bu boşluğu
43 # doldurur. Kurs paketi aynı iki adımı DCCGarch sınıfında paketler
44 # (DCC/cDCC/ADCC/DECO): std_resid = m.fit_univariate_garch(df); m.
    fit_dcc(std_resid).

```

1.5 Tahmin Prosedürü ve Sayısal Konular

1.5.1 İki Adımlı MLE: Adım Adım

DCC tahmin prosedürü aşağıdaki adımları izler:

1. **Tek değişkenli GARCH tahmini:** Her $i = 1, \dots, N$ için GARCH(1,1) parametreleri $(\hat{\omega}_i, \hat{\alpha}_i, \hat{\beta}_i)$ ayrı ayrı MLE ile tahmin edilir. Bu adım N ayrı tek boyutlu optimizasyon problemini çözer.
2. **Standardize artık hesaplama:** Her varlık için $\hat{z}_{it} = \hat{\varepsilon}_{it}/\hat{\sigma}_{it}$ elde edilir; burada $\hat{\varepsilon}_{it} = r_{it} - \hat{\mu}_{it}$.
3. **DCC hedef matrisi:** Standardize artıkların örnek ikinci moment matrisi hesaplanır:

$$\bar{Q} = \frac{1}{T} \sum_{t=1}^T \hat{z}_t \hat{z}_t'.$$

Standart hedeflemeli DCC'de bu matris sabit hedef ve başlangıç değeri $Q_0 = \bar{Q}$ olarak kullanılır. Bununla birlikte $\bar{Q}$ 'yu genel olarak $\mathbb{E}[Q_t]$ veya $\mathbb{E}[z_t z_t']$ ile özdeşleştirmek doğru değildir; bu nokta cDCC düzeltmesinin temelidir.

4. **DCC optimizasyonu:** (a, b) parametreleri için korelasyon log-olabilirliği (19) maksimize edilir. Kısıtlar: $a > 0$, $b > 0$, $a + b < 1$.
5. **Standart hata hesaplama:** Sandwich tahmincisi (21) uygulanır; bu adım pratik uygulamalarda genellikle atlanır, ancak çıkarım açısından kritiktir.

Not 1.5. $Q_0 = \bar{Q}$ pratik ve yaygın bir başlangıç seçimidir; başlangıç geçişini azaltır. Ancak standart hedeflemeli DCC'de $\mathbb{E}[Q_t] = \bar{Q}$ eşitliği genel olarak garanti edilmez. Kısa örneklerde ilk 50–100 gözlem ısınma dönemi olarak ayrılabilir ve başlangıç duyarlılığı ayrıca kontrol edilmelidir.

1.5.2 Optimizasyon Algoritmaları

DCC log-olabilirliği genellikle pürüzsüz ve iyi koşullandırılmıştır; bu nedenle L-BFGS-B (sınırlı kısıtlı quasi-Newton) algoritması tercih edilir. Nelder-Mead (türevsiz simplex yöntemi) daha yavaş ama daha dayanıklıdır; L-BFGS-B yakınsamazsa rezerv seçenek olarak kullanılabilir.

Tablo 3: DCC Optimizasyon Algoritması Karşılaştırması

Algoritma	Hız	Sağlamlık	Kullanım
L-BFGS-B	Hızlı	Orta	Birincil tercih, türev gerektirir
Nelder-Mead	Yavaş	Yüksek	Rezerv, türevsiz
SLSQP	Hızlı	Orta	Eşitlik kısıtları varsa

1.5.3 Parametre Korelasyonu ve Tanımlama Sorunu

DCC modelinde a ve b parametreleri arasında tipik olarak *negatif korelasyon* gözlemlenir: büyük a (kısa dönem tepki) ve küçük b (düşük kalıcılık) birbirinin ikamesi gibi davranır. Bu korelasyon sayısal kararsızlığa yol açabilir. Çözümler:

- Çoklu başlangıç değeri deneyin (grid search üzerinde).
- $(a + b)$ toplamını izleyin; 1'e yaklaşıyorsa modelin sınırına yaklaşılmaktadır.
- Güven elipsini çizin: a ve b için yüksek korelasyon görülürse parametre uzayı küçük veri ile iyi kapsamıyor olabilir.

1.5.4 Pozitif Tanımlılık Koruması

Sayısal hatalar nedeniyle Q_t matrisinin pozitif tanımlılığı bozulabilir. Her iterasyonda kontrol:

$$\lambda_{\min}(Q_t) > 10^{-8} \quad (23)$$

Bu koşul sağlanmıyorsa *en yakın pozitif yarı-tanımlı matris* projeksiyonu uygulanır (Higham, 1988):

$$Q_t^+ = \arg \min_{S \succeq 0} \|S - Q_t\|_F^2 \quad (24)$$

Geçerli a, b kısıtları ve pozitif tanımlı $\bar{Q}$ altında standart DCC özyinelemesi teorik olarak pozitif tanımlılığı korur. Özdeğer kırpması veya en-yakın-korelasyon projeksiyonu standart özyinelemenin parçası değildir ve sık uygulanırsa tahmin edilen modeli değiştirir. Bu işlemler yalnızca başlangıç/yuvarlama hatasına karşı acil sayısal koruma olarak kullanılmalı; devreye girme sayısı raporlanmalıdır. Geçerli korelasyon matrisi gerekiyorsa Higham (2002)'nin birim-köşegenli en-yakın-korelasyon problemi, basit PSD özdeğer kırpmadan ayrılmalıdır.

Tahmin Tuzakları ve Çözümleri

1. **Yerel minimum:** (a, b) uzayı çok modlu olabilir. *Çözüm:* Grid search ile birden fazla başlangıç noktası deneyin.

2. $a + b \geq 1$: Parametre durağanlık sınırına ulaşıyor. *Çözüm*: $a + b < 1 - 10^{-6}$ kısıtını ekleyin.
3. **Sayısal kararsız Q_t** : Önce kısıtları, başlangıç değerini ve veri ölçeklemesini denetleyin. Projeksiyonu yalnızca nadir yuvarlama hatalarına karşı koruma olarak kullanın ve kullanım sıklığını raporlayın.
4. **Başlangıç duyarlılığı**: $Q_0 \neq \bar{Q}$ seçilmesi ilk ~ 50 gözlemi etkiler. *Çözüm*: $Q_0 = \bar{Q}$ kullanın veya burn-in dönemi atın.
5. **Yüksek boyut ($N > 30$)**: Her adımda $N \times N$ matris tersi hesaplanır. *Çözüm*: Woodbury özdeşliği veya Cholesky ayrışımı kullanın.

1.6 Korelasyon Dinamiği Yorumlama

1.6.1 Parametre Anlamları

DCC modelinde a ve b parametrelerinin ekonomik yorumu:

- a (*reaksiyon parametresi*): Korelasyonun yeni bilgiye olan kısa dönem duyarlılığını ölçer. Büyük a , geçmiş şokların ($z_{t-1}z'_{t-1}$) korelasyonu hızla değiştirdiğini gösterir. Gelişmekte olan piyasalarda a genellikle gelişmiş piyasalara kıyasla daha büyüktür.
- b (*kalıcılık parametresi*): Korelasyonun geçmiş değerine olan bağımlılığını ölçer. Büyük b , korelasyon şoklarının uzun süre etkisini sürdürdüğünü gösterir. Finansal piyasalarda $b \approx 0.90-0.97$ değerleri tipiktir.

1.6.2 Yarı-Ömür Hesaplama

Standart scalar DCC'de $Q_t - \bar{Q}$ sapmasının koşullu-ortalama doğrusal kalıcılığı (Q_t sürecinin kendi uzun-dönem ortalaması $\bar{Q}$ 'ya ne hızla geri döndüğü) yaklaşık $a + b$ ile özetlenir. Buna karşılık normalize edilmiş R_t doğrusal olmayan bir dönüşümdür; aşağıdaki ifade korelasyonların tam yarı-ömrü değil, Q_t dinamiğinin yaklaşık yarı-ömrüdür:

$$\tau_{1/2} = \frac{\ln 0.5}{\ln(a + b)} \quad (25)$$

Örnek 1.1 (Yarı-Ömür Hesabı). $a = 0.05$, $b = 0.90$ ise $a + b = 0.95$ ve:

$$\tau_{1/2} = \frac{\ln 0.5}{\ln 0.95} = \frac{-0.693}{-0.0513} \approx 13.5 \text{ gün}$$

Yani Q_t sapmasının doğrusal yaklaşımı yaklaşık 13.5 günde yarıya iner; R_t için bu yalnızca yaklaşık bir yorumdur.

Tablo 4: Farklı $a + b$ Değerleri için Q_t Dinamiğinin Yaklaşık Yarı-Ömrü

$a + b$	$\tau_{1/2}$ (gün)	Yorum
0.80	3.1	Çok hızlı dönüş
0.90	6.6	Hızlı dönüş
0.95	13.5	Tipik gelişmekte olan piyasa
0.97	22.8	Yavaş dönüş
0.99	69.0	Çok yavaş dönüş

1.6.3 Koşulsuz Korelasyon: Uzun Dönem Denge

$\bar{Q}$, standart DCC özyinelemesinde sabit hedef matrisidir. Normalleştirilmiş hedef korelasyon matrisi $\bar{R} = \bar{Q}^{*-1} \bar{Q} \bar{Q}^{*-1}$ olarak yazılabilir; ancak hedefleme uyumsuzluğu nedeniyle bunu genel olarak $\mathbb{E}[R_t]$ veya gerçek koşulsuz korelasyonla özdeşleştirmemek gerekir. Bu matris:

- Sektörler arası yapısal bağlantıları yansıtır (ör. banka-sanayi),
- Kısa dönem kriz artışlarının temel noktasıdır,
- Portföy çeşitlendirmesinin "normal dönem" sınırını belirler.

1.7 cDCC Düzeltmesi (Aielli, 2013)

Aielli (2013), standart DCC modelinde $\bar{Q}$ 'nin tutarlı tahminine ilişkin bir asimptotik sapma sorunu tespit etmiştir. Sorunun kaynağı, (17) denklemindeki EWMA yapısının standartlaştırılmış artıklara değil, orijinal Q_t ölçeğine uygulanması gereğidir.

Tanım 1.2 (cDCC Güncellemesi).

$$Q_t = (1 - a - b) \Psi + a z_{t-1}^* z_{t-1}^{*'} + b Q_{t-1}, \quad z_t^* = Q_t^{*1/2} z_t \quad (26)$$

Burada $Q_t^{*1/2} = \text{diag}(\sqrt{q_{11,t}}, \dots, \sqrt{q_{NN,t}})$ ölçek matrisi, z_t^* ise *yeniden ölçeklendirilmiş yenilik* vektörüdür.

cDCC hedefi, standart DCC hedefiyle aynı matris değildir

cDCC'de hedef matris, standart DCC'de kullanılan ham $\hat{Q} = T^{-1} \sum_t z_t z_t'$ ile *özdeş değildir*. Yeniden ölçeklendirilmiş yenilikler $z_t^* = Q_t^{*1/2} z_t$ olmak üzere hedef

$$\Psi = \mathbb{E}(z_t^* z_t^{*'})$$

biçiminde tanımlanır. Uygulamada Ψ , dönüştürülmüş artık momentleri üzerinden yinelemeli (sabit-nokta) bir prosedürle kestirilir: bir Ψ adayı verildiğinde Q_t yolu, Q_t yolu verildiğinde z_t^* ve dolayısıyla yeni bir Ψ elde edilir; yineleme yakınsayana dek sürer. Bu yapı altında $\mathbb{E}[Q_t] = \Psi$ hedeflemesi tutarlı hâle gelir — Aielli (2013) düzeltmesinin özü budur. Ham $\hat{Q}$ 'yu cDCC özyinelemesinde hedef olarak kullanmak, düzeltilmek istenen sapmayı geri getirir.

Düzeltilmiş model, hedef matrisin koşulsuz beklentisinin $\mathbb{E}[Q_t]$ 'ye eşitlenmesini sağlar; bu sayede hedefleme tutarlı bir tahmin edici olarak kullanılabilir.

1.8 ADCC: Asimetrik DCC (Cappiello ve diğ., 2006)

Finansal piyasalarda negatif şoklar, korelasyonları pozitif şoklara kıyasla daha fazla artırma eğilimi gösterir. Bu *asimetrik korelasyon kaldıracı* etkisini yakalamak için Cappiello et al. (2006):

$$Q_t = (\bar{Q} - a\bar{Q} - b\bar{Q} - c\bar{Q}^-) + a z_{t-1} z'_{t-1} + b Q_{t-1} + c z_{t-1}^- (z_{t-1}^-)' \quad (27)$$

Burada:

- $z_t^- = z_t \odot \mathbb{1}[z_t < 0]$: yalnızca negatif şokları filtreleyen asimetri terimi (literatürde n_t ile de gösterilir).
- $\bar{Q}^- = T^{-1} \sum_t z_t^- (z_t^-)'$: koşulsuz negatif şok kovaryansı (literatürde $\bar{N}$).
- $c \geq 0$: asimetri yoğunluk parametresi.

Geçerli bir ADCC için yalnızca $a, b, c \geq 0$ yeterli değildir. Sabit terimin pozitif tanımlı olması gerekir:

$$(1 - a - b)\bar{Q} - c\bar{Q}^- \succ 0.$$

Durağanlık/kalıcılık koşulu da asimetri şokunun koşulsuz momentini dikkate almalıdır; bu nedenle ADCC'de yalnızca $a + b < 1$ kısıtı genel olarak yeterli değildir.

$c > 0$ olduğunda, piyasada düşüş dönemlerinde korelasyonlar ek olarak yükselir; bu etki “*kriz bulaşıcılığı*” (contagion) analizlerinde önemlidir.

1.9 Diğer Uzantılar

1.9.1 GO-GARCH (van der Weide, 2002)

GO-GARCH (Generalized Orthogonal GARCH) modeli, getirileri bağımsız bileşenlere dönüştürerek boyut sorununu çözer:

$$r_t = A f_t, \quad H_t = A \Lambda_t A' \quad (28)$$

- A : karıştırma matrisi (mixing matrix), ICA veya PCA ile tahmin edilir.
- f_t : bağımsız faktörler; her biri tek değişkenli GARCH ile modellenir.
- $\Lambda_t = \text{diag}(\sigma_{f_1,t}^2, \dots, \sigma_{f_k,t}^2)$.

Avantaj: H_t 'nin pozitif tanımlılığı yapısal olarak sağlanır.

Dezavantaj: A matrisinin yorumlanması güçtür; korelasyon dinamiği DCC kadar esnek değildir.

1.9.2 DECO: Dinamik Eşkorelasyon (Engle ve Kelly, 2012)

Büyük boyutlu sistemlerde ($N > 50$) tüm ikili korelasyonları ayrı ayrı modellemek yerine, DECO tüm çiftlerin ortalama korelasyonunu kullanır:

$$R_t^{\text{DECO}} = (1 - \bar{\rho}_t) I_N + \bar{\rho}_t \mathbf{1}\mathbf{1}' \quad (29)$$

Burada $\bar{\rho}_t = \frac{2}{N(N-1)} \sum_{i < j} \rho_{ij,t}$ olup DCC'den elde edilen ortalama korelasyondur. Matrisin pozitif tanımlı olması için $-1/(N-1) < \bar{\rho}_t < 1$ gerekir; uygulamada bağlantı fonksiyonu bu aralığı otomatik sağlamalıdır.

Avantaj: Parametre sayısı sabit (a ve b yeterlidir); $N = 500$ varlık için bile hesaplanabilir.

Dezavantaj: Heterojenik korelasyon yapısını ihmal eder.

1.9.3 Faktör-DCC: Büyük Boyut için Yapısal Model

Faktör-DCC modeli, Engle et al. (1990) tarafından önerilen faktör-ARCH kovaryans yapısını temel alır ve kovaryans matrisini ortak faktörler ile idiosinkratik bileşenlere ayrıştırır (faktör kovaryansı Λ_t DCC ile modellenir):

$$H_t = B \Lambda_t B' + \Omega \quad (30)$$

- B : $N \times K$ faktör yükleme matrisi, PCA ile tahmin edilir.
- Λ_t : $K \times K$ faktör kovaryans matrisi; DCC ile modellenir (yalnızca K^2 boyutlu problem).
- Ω : $N \times N$ idiosenktratik kovaryans matrisi; köşegen varsayımı altında yalnızca N parametre içerir.

Not 1.6. PCA burada yalnızca *koşulsuz* kovaryansı ($\hat{\Sigma} \approx \mathbb{E}[H_t]$) köşegenleştirir; yükler W sabittir. Koşullu öz vektörler zamanla döndüğünden $W' H_t W = \Lambda_t$ genel olarak köşegen *değildir*: faktörler tüm-örneklem ortalamada ilişkisiz olsa bile ($T^{-1} \sum_t f_{i,t} f_{j,t} = 0$), koşullu çapraz-faktör korelasyonu $\mathbb{E}_{t-1}[f_{i,t} f_{j,t}]$ zaman-değişken ve sıfırdan farklı kalabilir. İkinci aşama DCC tam da bu köşegen-dışı dinamiği $K \times K$ uzayında modeller. Λ_t 'yi köşegen kabul etmek (DCC'siz), tüm H_t 'lerin ortak öz vektörlere sahip olduğu güçlü varsayımına — yani GO-GARCH/O-GARCH'a (Alexander, 2001; van der Weide, 2002) — karşılık gelir ve bu varsayım ampirik olarak sıklıkla reddedilir.

Parametre tasarrufu belirgindir. Köşegen (sabit) idiosinkratik Ω altında faktör-DCC'nin kestirilen parametre sayısı $\underbrace{3K}_{\text{faktör GARCH}} + \underbrace{2}_{\text{DCC}} + \underbrace{N}_{\text{idiyo. varyans}} = 3(5) + 2 + 100 = 117$ 'dir (PCA ile kestirilen B yükleme matrisi genellikle olabilirlik-dışı sayılır). İdiosinkratik bileşenlere de GARCH dinamiği verilirse sayı $3N + 3K + 2 = 317$ olur. Karşılaştırma için tam DCC, $N = 100$ 'de $3N + 2 = 302$ kestirilen parametreye ek olarak hedefleme adımı $N(N-1)/2 = 4950$ koşulsuz korelasyonu sabitler.

1.9.4 DCC-NL: Doğrusal Olmayan Büzme (Engle, Ledoit ve Wolf, 2019)

Engle et al. (2019) standart DCC'nin büyük boyutlarda (N/T büyükse) $\bar{Q}$ tahmincisinin gürültüden zarar gördüğünü göstermiştir. Çözüm olarak *doğrusal olmayan büzme* (nonlinear shrinkage) ile düzeltilmiş bir koşulsuz korelasyon hedefi $\bar{Q}^{NL}$ önerilir:

$$Q_t = (1 - a - b) \bar{Q}^{NL} + a z_{t-1} z'_{t-1} + b Q_{t-1} \quad (31)$$

$\bar{Q}^{NL}$, Marchenko-Pastur yasası kullanılarak rassal matris teorisi çerçevesinde tahmin edilir: gürültülü öz değerler sıkıştırılır, sinyal öz değerleri korunur. DCC-NL'nin kazancı örneklem boyutuna,

N/T oranına, veri üreten sürece ve kullanılan portföy kaybına bağlı ampirik bir sonuçtur; tek bir evrensel yüzde iyileşme oranı yoktur.

1.10 Model Seçimi: İstatistiksel Testler

1.10.1 Olasılık Oranı Testi

DCC, ADCC'nin $c = 0$ özel durumudur; ancak $c \geq 0$ kısıtı altında sıfır parametre uzayının sınırındadır. Bu nedenle standart χ_1^2 Wilks sonucu genel olarak geçerli değildir. Tek düzenli sınır parametresi ve diğer parametreler tanımlıysa tipik limit

$$LR = 2(\hat{\ell}_{ADCC} - \hat{\ell}_{DCC}) \Rightarrow \frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2, \quad H_0 : c = 0, \quad (32)$$

şeklinde. Sonlu örnekleme ve ADCC kısıtları altında en güvenli çıkarım, DCC null modelinden parametrik bootstrap uygulamaktır.

1.10.2 Bilgi Kriterleri

İç içe geçmemiş modellerin karşılaştırması için:

$$AIC = -2\hat{\ell} + 2k \quad (33)$$

$$BIC = -2\hat{\ell} + k \ln T \quad (34)$$

k parametre sayısı, T örneklem büyüklüğüdür. Büyük T için BIC daha sıkı parametre cezası uygular.

1.10.3 Model Güven Kümesi

Tanım 1.3 (Model Güven Kümesi (MCS)). Hansen ve diğ. (2011) tarafından önerilen Model Güven Kümesi (Model Confidence Set, MCS), istatistiksel olarak birbirinden *ayrıt edilemeyen* modellerin kümesini belirler. $\alpha = 0.10$ anlamlılık düzeyinde MCS'de kalan modeller verideki bilgi düzeyi için "eşit derecede iyi" kabul edilir.

MCS prosedürü:

1. Bir kayıp fonksiyonu seç (örn. gerçekleşen portföy varyansı).
2. Modeller arasında istatistiksel olarak anlamlı fark olup olmadığını bootstrap testi ile sına.
3. Anlamlı olarak kötü performans gösteren modeli kümeden çıkar.
4. MCS yalnızca bir model kalana dek veya çıkarma testi ret edilene dek tekrarla.

Tablo 5: DCC Ailesi: Model Karşılaştırma Tablosu

Model	Kullanım Alanı	Parametre	Boyut Sınırı
DCC	Genel amaçlı, orta boyut	$3N + 2$	$N \leq 50$
cDCC	DCC + tutarlılık düzeltmesi	$3N + 2$	$N \leq 50$
ADCC	Kriz / asimetri analizi	$3N + 3$	$N \leq 30$
GO-GARCH	Faktör tabanlı ayrıştırma	spesifikasyona bağlı; $O(N^2)$	$N \leq 20$
DECO	Büyük boyutlu portföy	$3N + 2$	$N > 100$
Faktör-DCC	Büyük boyut, yapısal	$N + 3K + 2$	$N \leq 500$
DCC-NL	N/T büyük sistemler	$3N + 2$	$N \leq 1000$

Not: GO-GARCH parametre sayısı kullanılan tanımlama ve tahmin prosedürüne bağlıdır: karışım matrisi A PCA/ICA ile önceden kestirilirse koşullu varyans aşamasında yaklaşık $3N$ GARCH parametresi kalır; ortogonal dönme açıları faktör GARCH parametreleriyle *birlikte* kestirilirse buna $N(N - 1)/2$ dönme parametresi eklenir ($3N + N(N - 1)/2$). “Parametre” sütunu MLE ile kestirilen serbest parametreleri gösterir; DCC/cDCC/DECO ayrıca hedefleme adımında $N(N - 1)/2$ koşulsuz korelasyonu momentle pinler. Faktör-DCC sayısı köşegen (sabit) idiosinkratik Ω içindir; idiosinkratik GARCH eklenirse $N \rightarrow 3N$.

Boyut ve Hesaplanabilirlik Stratejisi

- $N < 20$: ADCC; tüm parametreler ayrı tahmin edilebilir.
- $20 \leq N < 50$: DCC veya cDCC; standart iki adımlı prosedür.
- $N \geq 50$: Faktör-DCC veya DECO; parametre tasarrufu kritik.
- $N \geq 200$: DCC-NL; doğrusal olmayan büzme ile $\bar{Q}^{NL}$.
- Hesaplama süresi karşılaştırması ($T = 3000$): $N = 100$ için standart DCC ~ 30 saniye, Faktör-DCC ($K = 5$) ~ 3 saniye.

1.11 DCC Yeterlilik Tanıları ve Yüksek Boyutta Bileşik Olabilirlik

1.11.1 DCC Yeterlilik Tanıları

Sabit-korelasyon testi (§1.2) CCC’yi reddettikten sonra, tahmin edilen DCC’nin korelasyon dinamiğini *yeterince* yakalayıp yakalamadığı denetlenmelidir. Temel araç, model-standardize artıkların $\varepsilon_t = R_t^{-1/2} z_t$ (R_t : tahmin edilen zaman-değişken korelasyon) doğru belirtilmiş ikinci momentlerle uyumlu olup olmadığının sınanmasıdır. DCC’nin *ikinci-moment yeterliliği* altında beklenen koşullar

$$\mathbb{E}(\varepsilon_t \mid \mathcal{F}_{t-1}) = \mathbf{0}, \quad \mathbb{E}(\varepsilon_t \varepsilon_t' \mid \mathcal{F}_{t-1}) = I_N$$

biçimindedir: yani ε_t bir martingal-fark dizisidir ve koşullu ikinci moment matrisi birimdir; DCC yeterliyse dış çarpımlarda kalan dinamik olmamalıdır. Daha güçlü olan “ ε_t IID’dir” sonucu, yalnızca tam koşullu dağılımın doğru belirtilmesi ve ek varsayımlar altında ileri sürülebilir; QMLE çerçevesinde gerekli değildir.

İki tamamlayıcı tanı:

- **Portmanteau (Ljung-Box):** DCC-standardize artıkların çapraz çarpımları $\varepsilon_{i,t} \varepsilon_{j,t}$ üzerinde çok değişkenli Ljung-Box Q ; korelasyonda kalan serisel bağımlılığı sınar.

- **Havuzlanmış (Engle–Sheppard tipi) artık-tanısı:** §1.2’teki yapay-regresyon testi, artık $\varepsilon_t = R_t^{-1/2} \mathbf{z}_t$ ’ye uygulanır. Bu bir *artık* tanısıdır; birinci-aşama DCC tahmini nedeniyle kesin boş dağılım parametre-belirsizliğinden etkilenir, dolayısıyla p -değerleri gösterge niteliğinde okunmalıdır.

Örnek 1.2 (Kontrollü simülasyonda filtreleme sonrası tanı). Aynı havuzlanmış (Engle–Sheppard tipi) yapay-regresyon ($s = 5$), CCC, DCC ve ADCC ile filtrelenmiş artıklara uygulandığında (§1.13 verisi):

Filtre	Havuzlanmış tanı ist.	Nitel okuma
CCC ($\bar{R}$)	275.7	büyük — güçlü kalan dinamik
DCC (R_t)	4.86	küçük — kalan dinamik izi yok
ADCC (R_t)	4.27	küçük — kalan dinamik izi yok

Not: Havuzlanmış istatistik özgün Engle–Sheppard LM testi değildir (§1.2); analitik χ^2 referansı geçerli değildir ve tabloda *bilinçli olarak p-değeri verilmemiştir*. Sayısal bir p -değeri ancak ilgili boş model (CCC/DCC/ADCC) altında bütün tahmin ve filtreleme adımları her bootstrap örnekleminde yeniden yürütülerek $\hat{p}_{\text{boot}} = (1 + \sum_{b=1}^B \mathbf{1}\{T_b^* \geq T_{\text{obs}}\}) / (B + 1)$ ile elde edilir. Aşağıdaki okuma bu nedenle biçimsel bir hipotez kararı değil, büyüklük mertebesine dayanan *öğretici nitel yorumdur*. Yay nettir: sabit korelasyon devasa kalıntı dinamik bırakırken (ist. ≈ 276), DCC/ADCC filtrelemesi artıkları dinamik olarak temizler (ist. ≈ 4 –5); iki mertebe arasındaki fark, bootstrap referansına gerek kalmadan yorumlanabilecek kadar büyüktür. Dikkat çekici bir nokta: DGP ADCC olmasına karşın DCC de reddedilemez — havuzlanmış tanı dış-çarpımlardaki *doğrusal* kalıntı dinamiği yakalar, ancak eksik *asimetriyi* (c terimi) saptayacak kadar güçlü değildir; asimetri için hedefli bir işaret-yanlılığı testi gerekir. Bu, tanı testlerinin gücünün boyuta ve alternatifin biçimine bağlı olduğunu vurgular.

1.11.2 Yüksek Boyut: Bileşik Olabilirlik (Pakel vd., 2021)

Tam DCC olabilirliğinin iki sorunu, varlık sayısı N yüzlere ulaştığında belirginleşir (Pakel et al., 2021): (i) *hesaplama* — her t ’de R_t ’nin $O(N^3)$ tersi ve determinanı; (ii) *yanlılık* — korelasyon hedeflemesindeki $O(N^2)$ boyutlu $\bar{Q}$, orta-büyük N ’de anlamlı biçimde yanlıdır (bu, Engle et al. (2019) DCC-NL büzülmesinin de motivasyonuydu).

Pakel et al. (2021), tam olabilirliği düşük-boyutlu marjinal olabilirliklerin toplamıyla değiştiren *bileşik olabilirlik* (composite likelihood, CL) yaklaşımını önerir. Anahtar gözlem: DCC’nin dinamik parametreleri (a, b) *skalerdir* ve tüm çiftlerde ortaktır; dolayısıyla bunları tutarlı biçimde tahmin etmek için tam N -boyutlu olabilirlik gerekmez — ikili (iki değişkenli) alt-olabilirlikler yeterlidir. Havuzlanmış bileşik log-olabilirlik:

$$cl(a, b) = \sum_{i < j} \ell_{ij}(a, b), \quad (35)$$

burada ℓ_{ij} yalnızca (i, j) çiftini içeren iki değişkenli DCC korelasyon-aşaması log-olabilirliğidir. Bileşik-olabilirlik kuramı gereği tahminci tutarlı ve asimptotik normaldir (Varin et al., 2011; Pakel et al., 2021); bedeli, tam ML’e kıyasla bir verimlilik kaybıdır.

Örnek 1.3 (İkili bileşik olabilirlik vs tam DCC). Kontrollü simülasyonda ($N = 8$, $P = 28$ çift) ikili CL, DCC dinamiğini tam ML’e çok yakın geri kazanır:

Yöntem	$\hat{a}$	$\hat{b}$	$\hat{a} + \hat{b}$
Tam DCC (ML)	0.0450	0.9153	0.9603
İkili CL (28 çift)	0.0448	0.9247	0.9696

$\hat{a}$ neredeyse özdeştir; $\hat{b}$ farkı (~ 0.01) CL’in verimlilik kaybını yansıtır. Hesaplama avantajı $N = 8$ ’de *görünmez* (bu boyutta tam ML zaten hızlıdır); avantaj asimptotiktir: N büyüdükçe tam ML’in $O(N^3)$ maliyeti patlarken ikili CL, $O(N^2)$ çift $\times$ çift başına $O(1)$ iş yükünde kalır — yüzlerce varlıkta uygulanabilir başlıca tahmin seçeneklerinden biridir (Pakel et al., 2021); Faktör-DCC, DECO ve DCC-NL aynı boyut sorununa *yapı* ve *büzülme* tarafından yanıt veren tamamlayıcı yollardır.

Bileşik olabilirlik yüksek-boyut sorununa *tahmin* tarafından yanıt verir; büzülme (Ledoit-Wolf, DCC-NL) ve faktör yapıları ise *yapı* tarafından. Her iki yol da burada *koşullu* kovaryans H_t ’yi hedefler: büzülme DCC’nin hedefine ($\bar{Q}$), faktör yapısı ise korelasyon dinamiğine uygulanır. Aynı tekniklerin *koşulsuz* kovaryans matrisi Σ ’ya uygulanması (POET, Ledoit–Wolf spektrum düzeltmesi) Bölüm 3’ün konusudur; iki hat orada POET-DCC olarak birleşir. Bu iki hat tamamlayıcıdır ve Bölüm 3’teki POET/büzülme gündemine bağlanır.

Python: ikili bileşik olabilirlik ile DCC (a, b)

```

1 import numpy as np
2 from scipy.optimize import minimize
3 from numba import njit
4
5 # z: (T,N) DCC standardize artıklar; Rbar = np.corrcoef(z, rowvar=
6     False)
7 iu = np.triu_indices(z.shape[1], k=1)
8 pairs = np.array(list(zip(*iu)), dtype=np.int64) # P = N(N-1)/2
9     çift
10 rho = np.array([Rbar[i, j] for i, j in pairs])
11
12 @njit(cache=True, fastmath=True)
13 def pair_cl_nll(a, b, z, pairs, rho):
14     T, N = z.shape; P = pairs.shape[0]; nll = 0.0
15     for k in range(P): # her çift: 2x2
16         DCC ozyineleme
17         i = pairs[k, 0]; j = pairs[k, 1]; r = rho[k]
18         q11 = 1.0; q22 = 1.0; q12 = r
19         for t in range(1, T):
20             zi = z[t-1, i]; zj = z[t-1, j]
21             q11 = (1 - a - b) + a*zi*zi + b*q11
22             q22 = (1 - a - b) + a*zj*zj + b*q22
23             q12 = (1 - a - b)*r + a*zi*zj + b*q12
24             rho_t = q12 / np.sqrt(q11*q22); det = 1.0 - rho_t*rho_t

```

```

22         u = z[t, i]; v = z[t, j]
23         nll += 0.5*(np.log(det) + (u*u - 2*rho_t*u*v + v*v)/det
24             - (u*u + v*v))
25
26     return nll
27
28 def obj(p):
29     # a, b > 0 ve a + b < 1
30     a, b = p
31     if not (a > 0 and b > 0 and a + b < 0.9999):
32         return 1e12
33     return pair_cl_nll(a, b, z, pairs, rho)
34
35 a_cl, b_cl = minimize(obj, np.array([0.04, 0.92]), method='L-BFGS-B',
36     bounds=[(1e-6, 0.5), (1e-6, 0.999)]).x
37
38 print(f"Pairwise CL: a={a_cl:.4f}, b={b_cl:.4f}")
39 # Kontrollu simulasyon: a=0.0448, b=0.9247 (tam DCC ML: 0.0450,
40     0.9153)

```

1.12 Uygulama: Minimum Varyans Portföy

1.12.1 Ortalama-Varyans Etkin Sınır

Modern portföy teorisinde (Markowitz, 1952) yatırımcı, beklenen getiri $\mu_p = \mathbf{w}'\boldsymbol{\mu}$ sabitlenerek portföy varyansını minimize eder:

$$\min_{\mathbf{w}} \mathbf{w}'H_t\mathbf{w} \quad \text{s.t.} \quad \mathbf{w}'\boldsymbol{\mu} = \mu^*, \quad \mathbf{w}'\mathbf{1} = 1 \quad (36)$$

μ^* hedef getiri düzeyidir. Bu problemi farklı μ^* değerleri için çözmek, *etkin sınırı* (efficient frontier) üretir.

DCC çerçevesinde H_t her gün güncellenir, dolayısıyla optimal portföy ağırlıkları $\mathbf{w}_t$ da dinamik olarak değişir.

1.12.2 MVP Ağırlıkları

DCC'den elde edilen H_t matrisi kullanılarak, dönem t için minimum varyans portföy ağırlıkları:

$$\mathbf{w}_t^{\text{MVP}} = \frac{H_t^{-1}\mathbf{1}}{\mathbf{1}'H_t^{-1}\mathbf{1}} \quad (37)$$

Bu ağırlıklar $\mathbf{w}_t'\mathbf{1} = 1$ (tam yatırım) kısıtını otomatik olarak sağlar.

1.12.3 Kısıtlı MVP: Açığa Satış Yasağı

Açığa satış kısıtı ($w_{it} \geq 0$, tüm i) altında analitik çözüm mevcut değildir; ikinci dereceden programlama (quadratic programming) gerekir:

$$\min_{\mathbf{w}} \mathbf{w}'H_t\mathbf{w} \quad \text{s.t.} \quad \mathbf{w}'\mathbf{1} = 1, \quad \mathbf{w} \geq \mathbf{0} \quad (38)$$

Python ile MVP Hesaplama

```
1 import numpy as np
2 from scipy.optimize import minimize
3
4 def mvp_weights(H_t):
5     """H_t: NxN pozitif tanımlı kovaryans matrisi (aciga satis
6         serbest)"""
7     N = H_t.shape[0]
8     ones = np.ones(N)
9     H_inv = np.linalg.inv(H_t)
10    w = H_inv @ ones / (ones @ H_inv @ ones)
11    return w
12
13 def mvp_weights_constrained(H_t):
14     """Aciga satis yasagi: w_i >= 0"""
15     N = H_t.shape[0]
16     w0 = np.ones(N) / N # esit agirlik baslangici
17     constraints = [{'type': 'eq', 'fun': lambda w: np.sum(w) - 1}]
18     bounds = [(0.0, 1.0)] * N # aciga satis yasagi
19     result = minimize(
20         fun=lambda w: w @ H_t @ w,
21         x0=w0,
22         method='SLSQP',
23         bounds=bounds,
24         constraints=constraints,
25         options={'ftol': 1e-12, 'maxiter': 1000}
26     )
27     return result.x
```

Ampirik çalışmalar, kısıtlı MVP'nin genellikle daha az çeşitlendirilmiş ama daha *kararlı* (stable) ağırlıklar ürettiğini göstermektedir. Devir ve dolayısıyla işlem maliyetleri de kısıtlı versiyonda tipik olarak daha düşüktür.

1.12.4 İşlem Maliyeti ve Devir (Turnover)

Dinamik portföy stratejilerinde gerçek yeniden dengeleme devri (turnover — bir dönemden diğerine yeniden dengelemede alınıp satılan portföy oranı), önceki hedef ağırlıklarla bugünkü getirilerin yarattığı işlem-öncesi ağırlıkları karşılaştırmalıdır:

$$\tilde{w}_{i,t^-} = \frac{w_{i,t-1}(1 + r_{i,t-1})}{1 + \mathbf{w}'_{t-1} \mathbf{r}_{t-1}}, \quad (39)$$

$$TO_t = \frac{1}{2} \sum_{i=1}^N |w_{i,t} - \tilde{w}_{i,t^-}|. \quad (40)$$

Zamanlama belgenin geri kalanıyla tutarlıdır: $\mathbf{w}_t, \mathbf{r}_t$ gözlenmeden önce seçilen $\mathcal{F}_{t-1}$ -ölçülebilir ağırlıktır. Dolayısıyla t döneminin başındaki işlem-öncesi ağırlık, bir önceki hedef $\mathbf{w}_{t-1}$ 'in $t - 1$

dönemi getirisiyle sürüklenmiş hâlidir; sürüklenme teriminde $\mathbf{r}_{t-1}$ kullanılır. Bu ifadede $\mathbf{r}_t$ kullanmak, aynı günün getirisi bilinmeden ağırlık seçildiği örneklem-dışı protokolle çelişir.

$1/2$ çarpanı tek-yönlü işlem hacmini verir; toplam alış ve satışı birlikte saymak istenirse kaldırılabilir. Bu nedenle TO_t bir *tek-yönlü* devirdir ($\frac{1}{2}L_1$); maliyet katsayısı ve tablo başlıkları da aynı konvansiyona göre okunmalıdır. Birim işlem maliyeti c ile net getiri

$$r_{p,t}^{\text{net}} = \mathbf{w}_t' \mathbf{r}_t - c TO_t \quad (41)$$

olarak yazılabilir. Basit $\sum_i |w_{i,t} - w_{i,t-1}|$ ifadesi kullanılacaksa “hedef-ağırlık değişimi yaklaşımı” olarak adlandırılmalıdır.

1.12.5 Rolling Window Backtest Prosedürü

1. $W = 252$ günlük eğitim penceresi belirle (yaklaşık 1 yıl).
2. Her dönem $t = W + 1, \dots, T$ için:
 - a. $t - W, \dots, t - 1$ verisiyle DCC modelini tahmin et.
 - b. $\hat{H}_t$ kovaryans tahminini elde et.
 - c. $\mathbf{w}_t = \text{MVP}(\hat{H}_t)$ ağırlıklarını hesapla.
 - d. t . günün gerçekleşen getirisini $r_{p,t} = \mathbf{w}_t' \mathbf{r}_t$ olarak kaydet.
3. Kümülatif getiri, Sharpe oranı ve maksimum çekilme hesapla.

1.12.6 Portföy Performans Değerlendirmesi

- **Öngörülen koşullu portföy varyansı:** $\hat{\sigma}_{p,t+1|t}^2 = \mathbf{w}_t' \hat{H}_{t+1|t} \mathbf{w}_t$
- **Yıllık Sharpe oranı:** $SR = \frac{\bar{r}_p^{\text{net}}}{\hat{\sigma}_p} \times \sqrt{252}$
- **Sortino oranı:** $SO = \frac{\bar{r}_p^{\text{net}}}{\hat{\sigma}_{\text{aşağı}}} \times \sqrt{252}$; yalnızca negatif getiri standart sapması kullanılır.
- **Maksimum çekilme (Maximum Drawdown):** $V_t = \prod_{s=1}^t (1 + r_{p,s}^{\text{net}})$ ($V_0 = 1$) kümülatif portföy değeri (servet) olmak üzere, $P_t = \max_{0 \leq s \leq t} V_s$ (koşan tepe / high-water mark), $DD_t = (P_t - V_t)/P_t$ ve $MDD = \max_t DD_t$.
- **Devir (Turnover):** $TO_t = \frac{1}{2} \sum_i |w_{i,t} - \tilde{w}_{i,t-}|$

Pozitif tanımlılık: model kısıtı ve sayısal koruma

Geçerli parametre kısıtları ve pozitif tanımlı hedef altında DCC özyinelemesi pozitif tanımlılığı korur. Özdeğer projeksiyonu standart tahmin adımı değildir. Yalnızca nadir yuvarlama hatasında acil koruma olarak kullanılmalı ve kaç kez devreye girdiği raporlanmalıdır; sık kullanım model/kısıt/veri işleme sorununa işaret eder.

1.13 Uygulama: Kontrollü Simülasyon Çalışması (DCC/cDCC/ADCC ve MVP)

Neden kontrollü simülasyon?

Bu bölümdeki bütün sayılar, *bilinen* bir veri üreten süreçten (DGP) türetilen, tohumla (seed) tam yeniden-üretilebilir sentetik bir veri kümesi üzerinde hesaplanmıştır. Gerekçe iki yönlüdür: (i) tahmincilerin gerçek parametreleri geri kazanıp kazanmadığını denetlemek — gerçek piyasa verisinde imkânsız olan bir doğrulama; (ii) okuyucunun her tabloyu kendi çalıştırıp birebir yeniden üretebilmesi, böylece modeli “kara kutu” olarak değil mekanik olarak kavraması. Aynı akış *gerçek BIST sektör endeksleri* üzerinde tekrarlanabilir; buradaki simülasyon, gerçek veriye geçmeden önce doğru cevabın önceden bilindiği bir referans deneydir.

Veri Üreten Süreç (DGP)

$N = 8$ sentetik sektör (BANKA, SANAYI, HOLD, GAYRIM, TEKNOLOJİ, ENERJİ, PERAK, OTOMOT), $T = 1500$ iş günü (2018-01-02 – 2023-10-02).

- **Marjinaler:** varlığa özgü, heterojen GARCH(1,1) (farklı α, β ve hedef yıllık oynaklık).
- **Korelasyon dinamiği:** gerçek ADCC süreci — $a_0 = 0.040$, $b_0 = 0.930$ (kalıcılık $a_0 + b_0 = 0.97$), asimetri $c_0 = 0.030$; sektör-bloklu koşulsuz korelasyon.
- **Kalın kuyruk:** Student- t yenilikleri, $\nu = 7$.
- **Kriz penceresi:** indeks $t \approx 555$ (2020-02-18 – 2020-04-07) çevresinde tasarlanmış sistemik stres: koşullu oynaklık çarpanı $\times 2.7$, korelasyon çekicisinin $\rho = 0.80$ 'e kayması ve ortak negatif şok. Mart-2020 benzeri bir epizoda kalibre edilmiştir.

Tohum 20260729. DGP, öğretim uygulamasının `data/generate_sample.py` betiğiyle özdeştir; dolayısıyla ders notu ile uygulama *aynı* sayıları üretir.

1.13.1 Adım 1: Tanımlayıcı İstatistikler

Tablo 6: Kontrollü simülasyon: tanımlayıcı istatistikler (Ort./Std./Min/Maks günlük %).

Sektör	Ort.	Std.	Min	Maks	Çarpıklık	Basıklık
BANKA	0.035	1.785	-13.66	7.17	-0.79	8.28
SANAYI	0.024	1.528	-19.30	4.62	-1.79	21.03
HOLD	0.054	1.639	-12.88	6.58	-0.77	8.53
GAYRIM	0.019	1.664	-10.44	8.02	-0.74	7.18
TEKNOLOJİ	0.053	1.841	-20.01	7.40	-1.51	18.16
ENERJİ	0.119	1.877	-15.45	10.23	-0.54	8.78
PERAK	0.100	1.475	-9.83	7.69	-0.37	8.77
OTOMOT	0.071	1.515	-11.72	5.01	-1.11	8.91

Basıklık değerleri 7.2 ile 21.0 arasında; hepsi normal dağılımın 3 değerini büyük farkla aşar. Jarque–Bera istatistiği tüm serilerde normalliği reddeder ($\min = 1230$, $\max = 21121$; $p < 0.001$). Kalın kuyruk, DGP’nin $\nu = 7$ Student- t yeniliklerinin doğrudan sonucudur; en yüksek basıklık ve en negatif çarpıklık, kriz penceresine en duyarlı sektörlerde (SANAYI, TEKNOLOJİ) belirginleşir. Bu, tek değişkenli GARCH tahmininde Student- t dağılımını tercih etmenin ampirik gerekçesidir.

1.13.2 Adım 2: Tek Değişkenli GARCH(1,1)

Tablo 7: Tek değişkenli GARCH(1,1) tahminleri. `arch` kütüphanesi getiriler $\times 100$ ölçeğinde kestirdiğinden $\hat{\omega}$ yüzde-kare ölçeğindedir; $\hat{\alpha}$, $\hat{\beta}$ ölçekten bağımsızdır.

Sektör	$\hat{\omega}$	$\hat{\alpha}$	$\hat{\beta}$	$\hat{\alpha} + \hat{\beta}$	Yorum
BANKA	0.146	0.111	0.842	0.953	Yüksek $\hat{\alpha}$
SANAYI	0.392	0.111	0.701	0.812	En düşük kalıcılık
HOLD	0.165	0.097	0.836	0.934	
GAYRIM	0.057	0.077	0.903	0.980	Yüksek kalıcılık
TEKNOLOJİ	0.094	0.092	0.877	0.969	
ENERJİ	0.069	0.112	0.872	0.984	En yüksek kalıcılık
PERAK	0.074	0.102	0.862	0.964	
OTOMOT	0.120	0.077	0.866	0.944	

Kalıcılık $\hat{\alpha} + \hat{\beta}$ sektörler arasında 0.812 ile 0.984 arasında *heterojendir*. Bu heterojenlik DGP’nin varlığa özgü GARCH parametrelerinin doğal sonucudur ve gerçek serilerin tipik davranışını yansıtır; tüm serilerde aynı ≈ 0.99 değerinin çıkması beklenmez.

1.13.3 Adım 3: DCC / cDCC / ADCC Karşılaştırması ve Geri-Kazanım

Tablo 8: DCC ailesi: korelasyon-aşaması (ikinci adım) tahminleri. $\hat{\ell}_{\text{kor}}$ korelasyon-aşaması log-olabilirliği; AIC bu aşama üzerinden. Parantez içi: birinci-adım tahminlerine *koşullu* inverse-Hessian standart hataları.

Parametre	DCC		cDCC		ADCC	
	Tahmin	SE	Tahmin	SE	Tahmin	SE
a	0.0450	(0.0025)	0.0399	(0.0022)	0.0353	(0.0027)
b	0.9153	(0.0050)	0.9214	(0.0048)	0.9162	(0.0048)
c	—	—	—	—	0.0280	(0.0048)
$a + b$	0.9603		0.9612		0.9515	
Q_t yaklaşık yarı-ömür (gün)	17.1		17.5		14.0	
$\hat{\ell}_{\text{kor}}$	3893.85		3866.51		3912.78	
AIC	−7783.70		−7729.02		−7819.56	

Geri-kazanım denetimi. Gerçek DGP değerleri $(a_0, b_0, c_0) = (0.040, 0.930, 0.030)$; ADCC tahminleri $(\hat{a}, \hat{b}, \hat{c}) = (0.0353, 0.9162, 0.0280)$, DCC kalıcılığı $\hat{a} + \hat{b} = 0.960$ (gerçek 0.97). Tahminciler dinamiği ve asimetriyi doğru geri kazanır.

Model seçimi. ADCC, DCC'yi $c = 0$ sınır kısıtı altında yuvalar:

$$LR = 2(3912.78 - 3893.85) = 37.86.$$

Tek sınır-parametre için $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ referansı kullanıldığında $p \approx 3.8 \times 10^{-10}$ elde edilir; parametrik bootstrap da aynı nitel kararı vermelidir. Asimetri terimi güçlü biçimde anlamlıdır ($\hat{c}/SE \approx 5.8$). cDCC ise DCC ile *yuvalanmadığından* karşılaştırma AIC üzerinden gayriresmîdir; burada cDCC ile DCC neredeyse özdeş dinamik verir ($a+b$: 0.961 vs 0.960). Bu beklenen bir sonuçtur: cDCC'nin değeri in-örneklem uyum kazancında değil, hedefleme adımının tutarlılığındadır (Aielli, 2013). Ortalama koşullu korelasyon (DCC) 0.466'dır.

1.13.4 Adım 4: Kriz Penceresinde Korelasyon Dinamiği

Tasarlanmış kriz penceresi, ADCC ile filtrelenmiş ortalama çift korelasyonda belirgin bir sıçrama üretir:

- Kriz-öncesi (Kas. 2019 – Şub. 2020): $\bar{\rho} = 0.459$.
- Kriz zirvesi (2020-03-02): $\bar{\rho} = 0.750$.
- Kriz-sonrası (Haz. – Tem. 2020): $\bar{\rho} = 0.501$.
- BANKA–SANAYİ çifti: $0.672 \rightarrow 0.866 \rightarrow 0.774$.

Tüm-örneklem ortalama korelasyonu 0.463'tür. ADCC, ortak düşüşlerde $c > 0$ terimi nedeniyle DCC'ye kıyasla daha yüksek kriz-dönemi korelasyonu üretir; bu, portföy riskini stres dönemlerinde daha muhafazakâr yansıtır. Burada kriz, DGP'ye *yerleştirilmiş* bir yapısal kırılmadır (gerçek bir olay değil); amaç, dinamik-korelasyon modellerinin böyle bir rejim değişimini denetlenebilir biçimde nasıl yakaladığını göstermektir.

1.13.5 Adım 5: Örneklem-Dışı (OOS) MVP Backtest

Protokol: ilk $W = 500$ günde GARCH + DCC/ADCC tahmin edilir; parametreler *sabitlenip* tüm örnekleme ileri-filtrelenir — σ_t ve R_t , $\mathcal{F}_{t-1}$ -ölçülebilir olduğundan w_t geçerli bir tek-adım-ileri ağırlıktır — ve ağırlıklar gerçekleşen r_t 'ye uygulanır. Kriz penceresi OOS bloğundadır. İşlem maliyeti, birim tek-yönlü devir ($\frac{1}{2}L_1$) başına 10 bp.

Tablo 9: OOS MVP performansı (2019-12-03 – 2023-10-02; 1000 gün). Yıllık Std ve Maks. DD % (MDD pozitif büyüklük olarak, $\max_t DD_t \geq 0$); Devir günlük ortalama tek-yönlü devir ($\frac{1}{2}L_1$) %; Net Sharpe 10 bp maliyet sonrası.

Strateji	Yıllık Std.	Sharpe	Maks. DD	Devir	Net Sharpe
Eşit Ağırlık (1/N)	20.9	0.10	51	0	0.10
Statik MVP (kısıtsız)	21.5	0.07	51	0	0.07
Statik MVP (long-only)	21.0	0.12	50	0	0.12
LW-Statik (long-only)	21.0	0.12	50	0	0.12
DCC-MVP (kısıtsız, günlük)	18.2	0.11	45	11	−0.05
DCC-MVP (long-only, günlük)	19.1	0.11	48	6	0.02
DCC-MVP (long-only, aylık)	19.0	−0.09	49	1	−0.11
ADCC-MVP (kısıtsız, günlük)	18.2	0.12	45	11	−0.04
ADCC-MVP (long-only, günlük)	19.1	0.12	48	6	0.04
ADCC-MVP (long-only, aylık)	18.9	−0.09	49	1	−0.11

Yorum.

1. *Kısıtsız statik MVP* $< 1/N$ (net Sharpe 0.07 vs 0.10): klasik tahmin-hatası problemi (DeMiguel et al., 2009). Açığa satış serbestisi tahmin hatasını kaldıracak eder ve beklenti değerini düşürür.
2. *Açığa satış yok kısıtı büzülme gibi davranır* (Jagannathan and Ma, 2003): statik MVP net Sharpe $0.07 \rightarrow 0.12$; DCC/ADCC-MVP’de long-only kısıt günlük deviri 11–12’den 6’ya indirir. Kısıt, aşırı ve negatif ağırlıkları budayıp ağırlık titremesini kırar.
3. *Dinamik kovaryans risk azaltır — günlük yenilemede*: günlük DCC/ADCC-MVP yıllık oynaklığı $20.9 \rightarrow 18.2$ ’ye, maksimum çekilmeyi $51 \rightarrow 45$ ’e düşürür; ADCC-MVP (long-only, günlük) en yüksek brüt Sharpe’ı (0.12) üretir. Brüt fayda gerçek, ancak yüksek devir maliyeti (10 bp/devir) net Sharpe’ı kısıtsızda negatife (−0.04) çekiyor; long-only günlük ise marjinal pozitif (0.04) kalıyor.
4. *Yenileme sıklığı belirleyicidir*: aylık dengelenen DCC/ADCC-MVP negatif Sharpe üretir (−0.09). Ağırlıklar bir ay boyunca sabit kaldığında koşullu kovaryans bilgisi eskir; yenileme zamanlaması piyasa dönüşleriyle örtüşmediğinde kayıp birikir. Dinamik kovaryansın değeri ancak yeterince sık yenilemede gerçekleşir — fakat sık yenileme de devir maliyetini artırır, ödünleşim buradadır.
5. *Büzülme ve boyut*: Ledoit–Wolf büzülmesi (Ledoit and Wolf, 2004) long-only statik MVP ile neredeyse özdeş Sharpe veriyor (0.12 vs 0.12); $N = 8 \ll T = 500$ ’de örnek kovaryansı iyi-kışıldır ($\delta \approx 0.02$). Büzülmenin kritiklediği rejim yüksek boyuttur (N büyüdükçe $\delta \uparrow$); bu, Bölüm 3’teki POET/büzülme gündeminin doğrudan motivasyonudur.

Yorumlama sınırları

(i) Tablo 8’deki standart hatalar birinci-adım GARCH tahminlerine *koşulludur*; iki-adımlı DCC’de asimptotik geçerli çıkarım, birinci-adım belirsizliğini içeren sandviç/iki-adımlı düzeltmeyi gerektirir (bkz. *Tahmin Prosedürü ve Sayısal Konular* altbölümü). (ii) Tüm sayı-

lar tohumlu (20260729) kontrollü simülasyondandır; farklı tohum farklı örneklem-içi gerçeşleme verir, ancak nitel sonuçlar (geri-kazanım, LR, kriz sıçraması) sağlamdır. (iii) Marjinaller burada t -dağılımıyla kestirilmiştir; normal dağılımla QMLE de tutarlıdır.

Python: doğrulanmış DCC-MVP iş akışı (look-ahead'siz)

```

1 import numpy as np, pandas as pd
2 from arch import arch_model
3 from scipy.optimize import minimize
4 from numba import njit
5
6 # 1) Marjinal GARCH(1,1)-t: kosullu vol (sig) ve standardize artik
   (z)
7 def fit_marginals(returns, W):
8     """Ilk W gozlemde tahmin et, parametreleri sabitle, tum seriyi
        filtrele."""
9     T, N = returns.shape
10    sig = np.empty((T, N)); z = np.empty((T, N))
11    for i in range(N):
12        r = returns.iloc[:, i].values * 100.0
13        am_is = arch_model(r[:W], mean='Constant', vol='GARCH', p
            =1, q=1, dist='t')
14        res_is = am_is.fit(dis='off') # egitim:
            yalnizca r[:W]
15        am_full = arch_model(r, mean='Constant', vol='GARCH', p
            =1, q=1, dist='t')
16        res_fixed = am_full.fix(res_is.params) #
            parametreler sabit, tum T
17        sig[:, i] = res_fixed.conditional_volatility / 100.0
18        z[:, i] = res_fixed.std_resid
19    return z, sig
20
21 # 2) DCC korelasyon-asamasi negatif log-olabilirliigi (numba ile
   derlenir)
22 @njit(cache=True, fastmath=True)
23 def dcc_nll(a, b, z, Qbar):
24     T, N = z.shape; Q = Qbar.copy(); nll = 0.0
25     for t in range(1, T):
26         zp = z[t-1]
27         Q = (1.0 - a - b) * Qbar + a * np.outer(zp, zp) + b * Q
28         d = np.sqrt(np.diag(Q)); R = Q / np.outer(d, d)
29         s, ld = np.linalg.slogdet(R); Ri = np.linalg.inv(R)
30         zt = z[t]
31         nll += 0.5 * (ld + zt @ Ri @ zt - zt @ zt)
32     return nll
33

```

```

34 # 3) Ceza-bariyeriyle kisitli optimizasyon:  $a, b > 0$  ve  $a+b < 1$ 
35 def fit_dcc(z):
36     Qbar = np.cov(z, rowvar=False)
37     def obj(p):
38         a, b = p
39         if a <= 0.0 or b <= 0.0 or a + b >= 0.9999:
40             return 1e10 # duraganlik/PD
41             bariyeri
42         return dcc_nll(a, b, z, Qbar)
43     r = minimize(obj, x0=np.array([0.04, 0.92]), method='L-BFGS-B',
44                 bounds=[(1e-6, 0.5), (1e-6, 0.999)])
45     return r.x, Qbar
46
47 # 4)  $R_t$  ileri-filtre (SABIT parametre) ve long-only MVP
48 def filter_R(a, b, z, Qbar):
49     T, N = z.shape; Q = Qbar.copy(); R = np.empty((T, N, N))
50     dd = np.sqrt(np.diag(Qbar)); R[0] = Qbar / np.outer(dd, dd)
51     for t in range(1, T):
52         zp = z[t-1]
53         Q = (1 - a - b)*Qbar + a*np.outer(zp, zp) + b*Q
54         d = np.sqrt(np.diag(Q)); R[t] = Q / np.outer(d, d)
55     return R
56
57 def mvp_long(H): # min  $w'Hw$ , s.t.
58     1'w=1, w>=0
59     N = H.shape[0]; one = np.ones(N)
60     r = minimize(lambda w: w @ H @ w, one/N, jac=lambda w: 2*H@w,
61                 method='SLSQP', bounds=[(0.0, 1.0)]*N,
62                 constraints=({'type': 'eq', 'fun': lambda w: w.sum() - 1.0},))
63     w = np.clip(r.x, 0.0, None)
64     return w / w.sum()
65
66 # --- Kullanım: yalnızca ilk W günde tahmin, sonra ileri-filtre
67 W = 500
68 z, sig = fit_marginals(returns, W) # W-only eğitim +
69     .fix() ile ileri filtre
70 (a, b), Qbar = fit_dcc(z[:W]) # sadece ic-
71     ornekleme
72 R = filter_R(a, b, z, Qbar) # tüm örnek, SABIT
73     (a, b)
74 port = []
75 for t in range(W, len(z)):
76     D = np.diag(sig[t]); H = D @ R[t] @ D #  $H_t = D_t R_t$ 
77     D_t
78     w = mvp_long(H) #  $F_{t-1}$ -
79     olculebilir ağırlık

```

```

73     port.append(w @ returns.values[t])
74 port = pd.Series(port)
75 print(f"00S Sharpe: {port.mean()/port.std()*np.sqrt(252):.3f}")

```

Not 1.7. Yukarıdaki çekirdek, öğretim uygulamasının `DCCGarch` sınıfında `numba` ile hızlandırılmış biçimde paketlenmiştir (DCC/cDCC/ADCC + DECO + MVP). cDCC ve ADCC yalnızca Q_t özyinelemesini değiştirir: cDCC’de $z_{t-1}^* = \{Q_{t-1}^*\}^{1/2} z_{t-1}$ yeniden-ölçeklemesi, ADCC’de $-c\bar{Q}^- + c z_{t-1}^-(z_{t-1}^-)'$ asimetri terimi eklenir. Büyük N için R_t tersine Cholesky ile bakılması ve bileşik-olabilirlik kestirimi önerilir.

1.14 Bilimsel Görselleştirme: DCC Çıktılarının Sunumu

Çok değişkenli oynaklık çıktıları — zaman-değişken korelasyon matrisleri ve portföy ağırlık yolları — yüksek boyutlu ve dinamiktir; etkili görselleştirme, doğru istatistiksel temsil ile algısal ilkelerin birlikte gözetilmesini gerektirir.

1.14.1 İlkeler

- **Algısal-düzgün, renk-körü-güvenli renk haritaları:** sıralı veriler için `viridis/cividis`; kategorik veriler için renk-körü-güvenli qualitative paletler. Algısal olarak düzgün olmayan (`jet`) ve kırmızı-yeşil şemalardan kaçının.
- **Karşılaştırılabilirlik:** birden çok panelde *sabit* renk ve eksen ölçeği (ör. iki korelasyon matrisini aynı $v_{\min}, v_{\max}$ ile); aksi hâlde paneller yanıltıcı biçimde karşılaştırılır.
- **Yüksek veri-mürekkep oranı:** doğrudan etiketleme (legend yerine), gereksiz çerçeve/ızgara yok, sade eksenler.
- **Rejim vurgusu:** kriz/olay pencerelerini gölgeleme ve açıklama ile işaretleme; okuyucunun dikkatini dinamiğin kaynağına yönlendir.
- **Vektör çıktı (PDF):** baskıda ölçekten bağımsız netlik.


1.14.2 Uygulamalı Örnekler

Şekil 1, §1.13 verisinde ADCC koşullu korelasyon matrisini kriz-öncesi ve kriz-zirvesi için karşılaştırır. *Ortak* renk ölçeği, kriz-zirvesindeki topyekûn korelasyon artışı (ortalama $0.453 \rightarrow 0.750$) tek bakışta görünür kılar — bu, Forbes-Rigobon (§1.1) yanlışlığından bağımsız olarak, DCC’nin ayrıştırdığı gerçek koşullu-korelasyon dinamiğidir.


Şekil 2, ADCC-MVP (long-only) ağırlıklarının örneklem-dışı evrimini gösterir. Yığılmış-alan gösterimi, ağırlıkların toplamının bire eşit olduğu kısıtını görsel olarak korur; kriz penceresinde yeniden-tahsis dinamiği izlenebilir.

Şekil 3, ortalama koşullu korelasyonu ve iki temsili çifti zaman içinde izler; kriz-dönemi sıçraması ($\bar{\rho}_t \approx 0.75$) doğrudan etiketlenmiştir.


Şekil 4, DCC ile ADCC ortalama koşullu korelasyonunu ve farkını karşılaştırır; alt panel, asimetri teriminin ($c > 0$) kriz ve sonrasında ADCC’yi DCC’nin üzerine taşıdığını izole eder.




Şekil 1: Kriz-öncesi (31.07.2019) ve kriz-zirvesi (02.03.2020) ADCC koşullu korelasyon matrisleri (panel-içi ortalama korelasyonlar sırasıyla 0.453 ve 0.750). Ortak renk ölçeği (viridis, $v_{\max} = 0.90$) karşılaştırmayı mümkün kılar; kriz-zirvesinde tüm sektör çiftlerinde korelasyon belirgin biçimde yükselir.



Şekil 2: ADCC-MVP (long-only) portföy ağırlıklarının örneklem-dışı evrimi (§1.13). Kriz penceresi gölgeli; renk-körü-güvenli qualitative palet kullanılmıştır. Ağırlıklar her t 'de $\mathbf{1}'\mathbf{w} = 1$, $\mathbf{w} \geq 0$ kısıtıyla çözülür.



Şekil 3: ADCC koşullu korelasyon dinamiği: tüm-çift ortalaması (siyah) ve iki temsili sektör çifti. Kriz penceresinde ortalama korelasyon ≈ 0.75 'e sıçar, sonrasında kısmen geri çekilir.



Şekil 4: DCC ve ADCC ortalama koşullu korelasyonu (üst) ve farkı $ADCC - DCC$ (alt). ADCC, ortak düşüşlerdeki asimetri ($c > 0$) nedeniyle kriz ve sonrasında sistematik olarak daha yüksek korelasyon üretir; fark tepe noktasında ≈ 0.04 'e ulaşır.

```

1 import matplotlib.pyplot as plt
2
3 # SABIT olacak her iki panelde: karşılaştırılabilirlik için kritik
4 vmin = min(R_pre[iu].min(), R_peak[iu].min()); vmax = 0.90
5 fig, ax = plt.subplots(1, 2, figsize=(10.6, 4.7))
6 for a, M, ttl in [(ax[0], R_pre, "Kriz-oncesi"), (ax[1], R_peak, "
    Kriz zirvesi")]:
7     im = a.imshow(M, cmap="viridis", vmin=vmin, vmax=vmax) #
        algısal - düzgün, CB-güvenli
8     a.set_xticks(range(N)); a.set_yticks(range(N))
9     a.set_xticklabels(assets, rotation=45, ha="right"); a.
        set_yticklabels(assets)
10    a.set_title(f"{ttl} (ort={M[iu].mean():.3f})"); a.grid(False)
11    for i in range(N): #
        dogrudan deger etiketleme
12        for j in range(N):
13            a.text(j, i, f"{M[i,j]:.2f}", ha="center", va="center",
                fontsize=6,
14                color="white" if M[i,j] < (vmin + vmax)/2 else "
                    black")
15 fig.colorbar(im, ax=ax, fraction=0.026, label=r"$\rho_{ij,t}$")
16 fig.savefig("fig_corr_heatmap.pdf") # vektor çıktı

```

1.15 Üçüncü Kısım Köprüsü: Gerçekleşen Kovaryans ve Kopula Uzantıları

DCC ailesi, koşullu korelasyonu *geçmiş günlük getirilerden* — düşük frekanslı bilgidir — günceller. İki güncel yön, birinci kısmın DCC çekirdeğini üçüncü kısmın yüksek-frekanslı ve yüksek-boyutlu risk gündemine bağlar: (i) gerçekleşen (realized) ölçütleri korelasyon dinamiğine katmak; (ii) eliptik-olmayan, kuyruk-bağımlı bağımlılık için kopulalar.

1.15.1 Çok-Değişkenli HEAVY / DCC-HEAVY (Noureldin vd., 2012)

DCC'nin Q_t özyinelemesi korelasyonu geçmiş standardize getirilerin dış çarpımından ($z_{t-1}z'_{t-1}$) günceller; bu, kovaryans için gürültülü, düşük-frekanslı bir sinyaldir. Gerçekleşen kovaryans matrisi (RCov), gün-içi yüksek-frekanslı veriden çok daha kesin bir ex-post kovaryans ölçütü sağlar. [Noureldin et al. \(2012\)](#), çok değişkenli HEAVY modelini önerir: koşullu kovaryans, gerçekleşen ölçütlerin gecikmelerinin düzgün (smoothed) bir fonksiyonu olarak modellenir (HEAVY-P ve HEAVY-V denklemleri), kovaryans hedeflemesi ve çok-adım öngörü için kapalı-form ifadeler sağlar. Tek değişkenli HEAVY ([Shephard and Sheppard, 2010](#)) GARCH'ı örneklem-içi ve -dışı — özellikle kısa öngörü ufuklarında — yenerken, çok değişkenli versiyon aynı kazancı kovaryans ve korelasyon boyutunda gösterir.

Yöntemsel bağlantı: gerçekleşen varyansı GARCH'a *dışsal* regresör olarak katmak (üçüncü kısımdaki GARCH-X) oynaklık tarafının analogudur; DCC-HEAVY bunun *korelasyon* tarafındaki

karşılığdır. Böylece üçüncü kısmın gerçekleşen-oynaklık, HAR ve GARCH-X gündemi, buradaki dinamik-korelasyon çerçevesiyle doğrudan birleşir.

1.15.2 Kopula-DCC: Eliptik-Olmayan ve Kuyruk-Bağımlı Bağımlılık

Gauss veya Student- t olabilirliğiyle tahmin edilen DCC, *eliptik* bağımlılık varsayar; bu, kuyruk bağımlılığını ve bağımlılık *asimetrisini* — ortak düşüşlerin ortak yükselişlerden daha güçlü bağımlı olması — sınırlı biçimde yakalar. Kopulalar, marjinaleri (tek değişkenli GARCH) bağımlılık yapısından ayırır (Sklar teoremi): her seri kendi GARCH dinamiğini izlerken, ortak dağılım esnek bir kopula ile birleştirilir.

Patton (2006), kopula kuramını koşullandırma değişkenlerine genişleterek *koşullu kopula* çerçevesini kurar; böylece bağımlılık parametresi zamanla (DCC-tipi bir dinamikle) evrilebilir — kopula-DCC. Patton, mark-dolar ve yen-dolar kurlarının ortak *değer kaybında* ortak değer kazanmaya kıyasla daha yüksek korele olduğunu bulur: doğrudan bir kuyruk-asimetrisi kanıtı. ADCC'nin asimetri terimi ($c > 0$, §1.8) bu olgunun eliptik çerçevedeki bir yaklaşımıdır; kopulalar ise kuyruk bağımlılığını (ör. Clayton kopulası ile alt-kuyruk yoğunlaşması) daha genel biçimde modeller. Bu esneklik, kriz-dönemi eş-kuyruk riski ve dolayısıyla portföy VaR/ES tahmini (İkinci Kısım) için doğrudan önem taşır.

Özetle, gerçekleşen-ölçüt-tabanlı (HEAVY) ve kopula-tabanlı uzantılar, Birinci Kısımın DCC çekirdeğini iki eksenle genişletir — bilgi kümesi (yüksek frekans) ve bağımlılık geometrisi (eliptik-olmayan kuyruklar) — ve Üçüncü Kısımın gündemine köprü kurar.

2 Risk Ölçütleri ve Geriye Dönük Test

Bölümün Amacı

Bu oturumda finansal risk yönetiminin temel taşları olan Riske Maruz Değer (VaR), Beklenen Kayıp (ES) ve PELVE (*Probability Equivalent Level of VaR and ES*) risk ölçütleri tanıtılacak; farklı tahmin yöntemleri karşılaştırılacak; öngörü kombinasyonu teknikleri uygulanacak ve geriye dönük test (backtesting) prosedürleri ile model geçerliliği sınanacaktır.

Notasyon ve Kısaltmalar

Bu bölüm boyunca aşağıdaki notasyon tutarlı biçimde kullanılır. Kayıp $L_t = -r_t$ olarak tanımlanır; *kayıp ölçeğinde* risk ölçütleri pozitif, *getiri ölçeğinde* (v_t, e_t) negatiftir.

Tablo 10: Temel notasyon

Sembol	Anlamı	Not
r_t, L_t	getiri, kayıp	$L_t = -r_t$
α	kuyruk olasılığı (VaR/ES düzeyi)	%99 VaR $\Rightarrow \alpha = 0.01$; yalnızca bu anlamda kullanılır
τ	test anlamlılık düzeyi	α 'dan farklıdır; ör. $\tau = 0.05$
$\text{VaR}_\alpha, \text{ES}_\alpha$	risk ölçütleri (kayıp ölçeği, pozitif)	yarı-parametrik modellerde
v_t, e_t	VaR ve ES öngörüsü (getiri ölçeği, negatif)	
σ_t, κ_t	koşullu oynaklık / koşullu ölçek	
z_t	standartlaştırılmış artık ya da yenilik	$z_t = r_t/\kappa_t$; FHS ve FZ-GARCH'ta ortak
F_z	z_t 'nin dağılımı	parametrik (Normal, t) veya ampirik
I_t	hit (ihlal) göstergesi	$I_t = \mathbb{1}[L_t > \widehat{\text{VaR}}_{\alpha,t}]$
u	EVT eşik	u_t ise Berkowitz testindeki PIT değeridir
ξ	kuyruk indeksi (GEV/GPD şekil parametresi)	PELVE asimptotığında de aynı anlamda
β_u	GPD ölçek parametresi	eşik u 'ya bağlıdır
k	Hill tahmincisinde kullanılan üst-kuyruk gözlem sayısı	
q	ki-kare serbestlik derecesi	
T	örneklem uzunluğu	
$\mathcal{T}(F)$	fonksiyonel (kantil $\Rightarrow$ VaR, kuyruk ortalaması $\Rightarrow$ ES)	örneklem uzunluğu T ile karıştırılmamalıdır
$S(\cdot)$	puanlama (skor) fonksiyonu	FZ ortak skoru dâhil
J	birleştirilen model sayısı	$\mathcal{M}$ ise model kümesidir (MCS)
w_i	kombinasyon ağırlığı	
η	görelî-skor ağırlıklandırma parametresi	
c_α	PELVE değeri	$\text{ES}_{c_\alpha\alpha} = \text{VaR}_\alpha$
a_1, b_1, g_1	GARCH-ailesi katsayıları (ARCH, GARCH, kaldırmaç)	Kuyruk olasılığı α , test düzeyi τ ve CaViaR/HAR katsayıları β_j ile çakışmaması için seçilmiştir; Bölüm 1'de aynı katsayılar α_i, β_i ile gösterilir
a, b	FZ modellerinde VaR ve ES çarpanları	$a = F_z^{-1}(\alpha), b = \mathbb{E}[z \mid z \leq a]$
$\beta_1, \dots, \beta_4$	CaViaR ve HAR-Range regresyon katsayıları	yalnızca ilgili modele özgüdür
δ	DQ testinde regresyon katsayı vektörü	
θ	ihtiyatî sermaye oranı (SRISK)	
M_b	blok maksimumu (EVT)	

Tablo 11: Kısaltmalar

Kısaltma	İngilizce açılımı	Türkçe karşılığı
VaR	Value at Risk	Riske maruz değer
ES	Expected Shortfall	Beklenen kayıp
PELVE	Probability Equivalent Level of VaR and ES	VaR–ES olasılık eşdeğer düzeyi
FRTB	Fundamental Review of the Trading Book	Alım-satım hesabının temel göz- den geçirmesi
HS	Historical Simulation	Tarihsel simülasyon
WHS	Weighted Historical Simulation	Ağırlıklı tarihsel simülasyon
FHS	Filtered Historical Simulation	Filtrelenmiş tarihsel simülasyon
EVT	Extreme Value Theory	Aşırı değer teorisi
BM	Block Maxima	Blok maksima
POT	Peaks Over Threshold	Eşik aşma
GEV	Generalized Extreme Value	Genelleştirilmiş aşırı değer
GPD	Generalized Pareto Distribution	Genelleştirilmiş Pareto dağılımı
CF	Cornish–Fisher	Cornish–Fisher (açılımı)
MLE	Maximum Likelihood Estimation	En çok olabilirlik tahmini
GARCH	Generalized Autoregressive Conditional Heteroskedasticity	Genelleştirilmiş otoregresif koşullu değişen varyans
GJR	Glosten–Jagannathan–Runkle (GARCH)	Eşik (kaldıraçlı) GARCH
EGARCH	Exponential GARCH	Üstel GARCH
FZ	Fissler–Ziegel	Fissler–Ziegel (ortak skor ailesi)
FZG	Fissler–Ziegel–Gneiting	–
NZ	Nolde–Ziegel	–
AL	Asymmetric Laplace	Asimetrik Laplace
AsL	Asymmetric Laplace	Asimetrik Laplace (model adı)
GAS	Generalized Autoregressive Score	Genelleştirilmiş otoregresif skor
CaViaR	Conditional Autoregressive Value at Risk	Koşullu otoregresif VaR
SAV	Symmetric Absolute Value	Simetrik mutlak değer (CaViaR türü)
AS	Asymmetric Slope	Asimetrik eğim (CaViaR türü)
HAR	Heterogeneous Autoregressive	Heterojen otoregresif
POF	Proportion of Failures	Başarısızlık (ihlal) oranı
DQ	Dynamic Quantile	Dinamik kantil
PIT	Probability Integral Transform	Olasılık integral dönüşümü
DM	Diebold–Mariano	–
MCS	Model Confidence Set	Model güven kümesi
SPA	Superior Predictive Ability	Üstün öngörü yeteneği
HAC	Heteroskedasticity and Autocorrelation Consistent	Değişen varyans ve otokorelasyona dayanıklı
LRV	Long-Run Variance	Uzun dönem varyans
CoVaR	Conditional Value at Risk (Adrian–Brunnermeier)	Koşullu VaR (sistemik)
MES	Marginal Expected Shortfall	Marjinal beklenen kayıp
LRMES	Long-Run Marginal Expected Shortfall	Uzun dönem marjinal beklenen kayıp
SRISK	Systemic Risk (capital shortfall)	Sistemik risk (sermaye açığı)
SIFI	Systemically Important Financial Institution	Sistemik önemi haiz finansal kuru- luş
DCC	Dynamic Conditional Correlation	Dinamik koşullu korelasyon
ADCC	Asymmetric DCC	Asimetrik DCC
GED	Generalized Error Distribution	Genelleştirilmiş hata dağılımı
CDF	Cumulative Distribution Function	Birikimli dağılım fonksiyonu
DGP	Data Generating Process	Veri üretme süreci

2.1 Risk Ölçütleri: Genel Çerçeve

Bir *risk ölçütü*, rassal bir kayıp L 'yi tek bir parasal büyüklüğe indirgeyen $\rho(\cdot)$ fonksiyoneldir. Amaç, kayıp dağılımının tamamını taşımak yerine karar almaya yetecek bir özet üretmektir: ne kadar sermaye tutulmalı, bir işlem masasına hangi limit verilmeli, iki portföyden hangisi daha riskli?

Risk Ölçütü Ne İşe Yarar?

Üç temel kullanım alanı vardır:

- **Sermaye belirleme:** düzenleyici (Basel) ve ekonomik sermaye, uç kayıpları soğurmak için tutulan tampondur.
- **Limit ve risk tahsisi:** masalar, stratejiler ve varlık sınıfları arasında risk bütçesinin paylaşılması.
- **Performans değerlendirme:** risk-ayarlı getiri karşılaştırmaları.

Bu kullanımların her biri ölçütten farklı özellikler talep eder. Hangi özelliklerin *zorunlu* sayılması gerektiği sorusu, aşağıdaki tutarlılık aksiyomlarına götürür.

Bu alt bölümde X ve Y pozitif kayıp değil, servet/P&L pozisyonlarıdır; dolayısıyla daha küçük değer daha kötü sonucu gösterir. Bu konvansiyon, yukarıdaki pozitif kayıp değişkeni L 'den farklıdır. Kayıp konvansiyonu kullanılsaydı monotonluk ve nakit öteleme işaretleri tersine dönerdi: $L_1 \leq L_2 \Rightarrow \rho(L_1) \leq \rho(L_2)$ ve $\rho(L + m) = \rho(L) + m$.

Bir risk ölçütünün finansal açıdan anlamlı ve matematiksel olarak tutarlı olması için belirli özellikleri taşıması gerekir. Artzner et al. (1999), tutarlı (coherent) risk ölçütlerini dört aksiyomla karakterize etmiştir.

Tanım 2.1 (Tutarlı Risk Ölçütü — Artzner vd. (1999)). $\rho : \mathcal{L} \rightarrow \mathbb{R}$ risk ölçütü aşağıdaki dört aksiyomu sağlıyorsa **tutarlı (coherent)** olarak adlandırılır:

A1. Monotonluk (Monotonicity):

$$X \leq Y \Rightarrow \rho(X) \geq \rho(Y) \quad (42)$$

Daha kötü sonuçlar veren pozisyon daha yüksek risk gerektirir.

A2. Alt-toplayıcılık (Sub-additivity):

$$\rho(X + Y) \leq \rho(X) + \rho(Y) \quad (43)$$

Çeşitlendirme riski azaltır; portföy riski bileşenlerin toplamını aşamaz.

A3. Pozitif Homojenlik (Positive Homogeneity):

$$\rho(\lambda X) = \lambda \rho(X), \quad \lambda > 0 \quad (44)$$

Pozisyon büyüklüğü ile risk orantılı olarak büyür.

A4. Öteleme Değişmezliği (Translation Invariance):

$$\rho(X + r) = \rho(X) - r \quad (45)$$

r tutarında risksiz varlık eklenmesi riski tam olarak r kadar düşürür.

Bu Bölümün İzleği

Aksiyomlar bir ölçütün *ne yapması gerektiğini* söyler; izleyen bölümler bunu somutlaştırır. Önce iki temel ölçüt tanımlanır: §2.2 **VaR**, §2.3 **ES**. VaR'ın alt-toplayıcılığı sağlamadığı, ES'nin ise dört aksiyomu da sağladığı orada gösterilir. §2.4 **belirlenebilirlik** sorusunu sorar: bu ölçütler nasıl kestirilir ve nasıl karşılaştırılır? Yanıt, izleyen üç bölümün yöntem seçimini belirler: §2.5 ölçütleri *tek tek* tahmin eden yöntemler, §2.6 ise VaR ile ES'yi *birlikte* tahmin eden yarı-parametrik modeller. §2.7 birden çok modelin öngörülerini birleştirir, §2.8 bunları sınar. §2.9 **PELVE** ile VaR–ES köprüsünü niceler; §2.10 ise ölçüm birimini tek portföyden *finansal sisteme* genişletir.

2.2 Riske Maruz Değer (Value at Risk — VaR)

Tanım 2.2 (VaR). Kayıp dağılımı L ve anlamlılık düzeyi $\alpha \in (0, 1)$ verildiğinde, α -düzeyinde VaR:

$$\text{VaR}_\alpha(L) = \inf\{x \in \mathbb{R} : P(L > x) \leq \alpha\} = F_L^{-1}(1 - \alpha) \quad (46)$$

Diğer bir ifadeyle, VaR_α kayıp dağılımının $(1 - \alpha)$ -kantilidir.

VaR'ın Ekonomik Yorumu ve Önemi

Matematiksel olarak bir kantil olan VaR_α , ekonomik açıdan bir portföyün belirli bir zaman ufkunda (örn. 1 gün, 10 gün) ve $1 - \alpha$ güven düzeyinde *aşmayacağı* kayıp eşliğini tek bir parasal büyüklükle özetler. Örneğin günlük %99 VaR'ın ($\alpha = 0.01$) 5 milyon TL olması, “normal piyasa koşullarında günlerin %99'unda kaybın 5 milyon TL'yi aşmayacağı; buna karşılık herhangi bir günde bu eşğin aşılma olasılığının yaklaşık %1 olduğu” biçiminde okunur. VaR'ı önemli kılan, karmaşık bir kayıp dağılımının tamamını tek, iletilebilir ve işlem masaları (trading desks) ile varlık sınıfları arasında *karşılaştırılabilir* bir sayıya indirgemesidir. Bu özellik onu risk limitlerinin belirlenmesi, sermaye tahsisi ve risk-ayarlı performans değerlendirmesinde ortak bir dil hâline getirmiş; düzenleyici çerçevelerce de standart bir ölçüt olarak benimsenmesini sağlamıştır.

Not 2.1 (Sermaye Çıkarımları). VaR, bir kurumun uç kayıpları soğurabilmek için ne kadar sermaye tutması gerektiğini belirlemede doğrudan kullanılır. *Düzenleyici sermayede*, Basel piyasa riski çerçevesi uzun süre 10 günlük %99 VaR'ı esas almış ve asgari sermaye yükünü bunu bir çarpanla — geriye-dönük test ihlallerine göre tipik olarak 3 ile 4 arasında — ölçekleyerek hesaplamıştır. *Ekonomik sermayede* ise güven düzeyi $1 - \alpha$ doğrudan bir solvabilite/derecelendirme hedefine bağlanır: daha yüksek güven (örn. %99.9) daha kalın bir sermaye tamponu ve dolayısıyla daha düşük iflas olasılığı anlamına gelir. Böylece VaR, soyut bir dağılım özelliğini bilanço üzerinde somut bir sermaye gereksinimine dönüştürür.

Bununla birlikte VaR yalnızca eşğin *aşılıp aşılmayacağını* bildirir; eşik aşıldığında kaybın ne kadar *şiddetli* olacağı hakkında bilgi vermez ve genel olarak alt-toplayıcı (dolayısıyla tutarlı) değildir. Bu sınırlamalar, Beklenen Kayıp’a (ES) ve güncel Basel/FRTB (*Fundamental Review of the Trading Book*) çerçevesinde %97.5 ES’ye geçişin temel gerekçesini oluşturur.

2.2.1 VaR’ın Alt-Toplayıcı Olmadığı Örnek

VaR, Aksiyom A2’yi (alt-toplayıcılık) genel olarak sağlamaz. Bu durum, çeşitlendirme yapılan bir portföyün bileşen VaR’larının toplamından daha yüksek bir VaR değeri almasına yol açabilir — finansal açıdan anlamsız bir sonuçtur.

Not 2.2 (VaR’ın Alt-Toplayıcı Olmadığı Sayısal Örnek). Yalnızca iki olası çıktı alan iki bağımsız varlığı ele alalım. Her varlık için:

- Olasılık 0.96: Kayıp 0 (zararsız durum)
- Olasılık 0.04: Kayıp 100 (büyük zarar)

%95 VaR hesabı:

- $\text{VaR}_{0.05}(X) = 0$ (çünkü $P(X > 0) = 0.04 < 0.05$)
- $\text{VaR}_{0.05}(Y) = 0$
- $\text{VaR}_{0.05}(X + Y) = ?$

$X + Y$ için: $P(X + Y > 0) = 1 - P(X = 0, Y = 0) = 1 - 0.96^2 = 0.0784 > 0.05$

Dolayısıyla $\text{VaR}_{0.05}(X + Y) > 0 = \text{VaR}_{0.05}(X) + \text{VaR}_{0.05}(Y)$.

Bu durum, iki sıfır-VaR’lı varlığın birleşiminin pozitif VaR’a yol açması anlamına gelir; yani VaR, çeşitlendirmeyi *cezalandırır*. Bu nedenle VaR **incoherent** (tutarsız) bir risk ölçütüdür.

ES ise dört aksiyomu da sağladığından **coherent** (tutarlı) olarak kabul edilir.

2.3 Beklenen Kayıp (Expected Shortfall — ES)

Tanım 2.3 (ES).

$$\text{ES}_\alpha(L) = \frac{1}{\alpha} \int_0^\alpha \text{VaR}_p(L) dp = \mathbb{E}[L \mid L > \text{VaR}_\alpha(L)] \quad (47)$$

ES, VaR eşğini aşan kayıpların *koşullu ortalamasıdır*. (İkinci eşitlik, $\text{ES}_\alpha = \mathbb{E}[L \mid L > \text{VaR}_\alpha]$, yalnızca *sürekli* L için geçerlidir; genel dağılımlarda tutarlılığı koruyan integral tanımı esas alınır, [Acerbi and Tasche 2002](#).)

ES’nin Ekonomik Yorumu ve Önemi

VaR yalnızca bir kayıp eşği verirken ES_α , ekonomik açıdan “işler kötü gittiğinde ne kadar kötü?” sorusunu yanıtlar: kayıp VaR eşğini aştığı *koşuluyla* beklenen kaybı, yani kuyruğun *ortalama şiddetini* ölçer. Örneğin günlük %99 ES’nin ($\alpha = 0.01$) 8 milyon TL olması, “en kötü %1’lik günlerde kaybın ortalama 8 milyon TL olacağı” biçiminde okunur; buna karşılık aynı düzeydeki VaR yalnızca eşğin (örn. 5 milyon TL) aşılıp aşılmayacağını söyler, eşik

ötesindeki kayıp büyüklüğü hakkında bilgi vermez. ES'yi önemli kılan iki özellik vardır: (i) VaR'ın gözden kaçırdığı *kuyruk şiddetini* yakalaması ve (ii) *tutarlı* (coherent) bir risk ölçütü olması — özellikle alt-toplayıcı olduğundan çeşitlendirmeyi tutarlı biçimde ödüllendirir ve işlem masaları ile varlık sınıfları arasında riskin sağlıklı biçimde toplulaştırılmasına izin verir. Bu üstünlükler nedeniyle Basel III/FRTB, piyasa riski sermaye ölçütünü %99 VaR'dan %97.5 ES'ye taşımıştır.

Not 2.3 (Sermaye Çıkarımları ve Belirlenebilirlik). *Düzenleyici sermayede*, FRTB kapsamında %97.5 ES artık piyasa riski sermaye yükünün temelidir; ES, eşik-ötesi ortalama kaybı yansıttığından VaR'a kıyasla daha tutucu ve kuyruk-duyarlı bir tampon üretir. Tutarlılık (alt-toplayıcılık) özelliği ayrıca sermayenin iş birimleri arasında, VaR'ın yol açtığı çeşitlendirme paradoksu olmaksızın tahsis edilebilmesini sağlar; böylece toplam sermaye, alt-portföylerin toplamını aşmaz.

Bununla birlikte ES'nin temel bir bedeli vardır: tek başına *belirlenebilir* (elicitable) değildir. Bu, ES tahminlerinin doğrudan tek bir kayıp fonksiyonuyla sıralanamayacağı ve geriye-dönük testinin VaR'a göre daha zor olduğu anlamına gelir; tutarlı doğrulama ancak (VaR, ES) ikilisini birlikte puanlayan Fissler–Ziegel türü ortak skorlar üzerinden yapılabilir (bkz. §2.4 ve §2.6). Kısacası ES, daha iyi risk *ölçümü* ile daha zor *doğrulama* arasında bir ödünleşim sunar.

2.3.1 ES'nin VaR'a Göre Üstünlükleri

Tablo 12: VaR ile ES Karşılaştırması

Özellik	VaR	ES
Alt-toplayıcılık (sub-additivity)	✗ ¹	✓
Kuyruk bilgisi	Yok (tek nokta)	Var (ortalama)
Elicitability (tek başına)	Evet	Hayır
Düzenleyici standart (Basel III)	Eski (99%)	Yeni (97.5%)

2.4 Belirlenebilirlik ve Kayıp Fonksiyonları

Tanım 2.4 (Elicitability — Belirlenebilirlik). Bir fonksiyonel $\mathcal{T}(F)$ *elicitable*'dir eğer ve ancak $\mathbb{E}_F[S(x, Y)]$ 'yi minimize eden x değeri $\mathcal{T}(F)$ 'ye eşit olan bir *puanlama fonksiyonu* (scoring function) S varsa:

$$\mathcal{T}(F) = \arg \min_x \mathbb{E}_F[S(x, Y)] \quad (48)$$

Burada F , sonucun Y 'nin (ör. getiri) *öngörücü dağılım fonksiyonu*; $\mathbb{E}_F[\cdot]$ bu F altında beklenti; $\mathcal{T}(F)$ ise F 'ye uygulanan *fonksiyoneldir* — örneğin α -kantil $\Rightarrow$ VaR, kuyruk koşullu ortalaması $\Rightarrow$ ES. $S(x, y)$ ise x tahminini y gerçekleşmesiyle karşılaştıran *puanlama (kayıp) fonksiyonudur*.

- VaR $\rightarrow$ **elicitable** (kontrol kaybı: $S(v, \ell) = (\mathbb{1}[\ell > v] - \alpha)(\ell - v)$).
- ES $\rightarrow$ **tek başına elicitable değil** (Gneiting, 2011); ancak (VaR, ES) çifti olarak **jointly elicitable**.

¹VaR, genel olarak alt-toplayıcı değildir; bu nedenle “tutarlı” (coherent) bir risk ölçütü değildir (Artzner et al., 1999).

Belirlenebilirlik Neden Önemli? — Uygulamacı Bakışı

Belirlenebilirlik, bir risk ölçütünün *adil biçimde karşılaştırılabilir* ve *geriye-dönük test edilebilir* olup olmadığını belirleyen temel özelliktir: eğer $\mathcal{T}$ belirlenebilirse, doğru tahmin bir puanlama fonksiyonunun beklenen değerini *benzersiz* biçimde minimize eder; böylece risk modeller ortalama skorlarına göre nesnel olarak sıralanabilir. Uygulamada iki doğrudan sonucu vardır: (i) VaR belirlenebilir olduğundan tek başına kantil kaybıyla (İng. *pinball loss*) kestirilip sıralanabilir ve test edilebilir; (ii) ES tek başına belirlenebilir *olmadığından* doğrudan tek bir skorla sıralanamaz — bu, ES için model seçimini ve düzenleyici geriye-dönük testi zorlaştıran temel güçlüktür. Çözüm, (VaR, ES) ikilisini *birlikte* belirlenebilir kılan Fissler–Ziegel skor ailesidir; bu dersteki hem model kestirimi (§2.6) hem de backtest (§2.11) bu aileye dayanır.

2.4.1 Fissler-Ziegel Ortak Puanlama Ailesi ve AL Skoru

Fissler and Ziegel (2016), VaR (Q) ve ES'nin *ortak* elicitable olduğunu kanıtlar: ikisini birlikte değerlendiren tutarlı puanlama fonksiyonları şu genel forma sahiptir:

$$\begin{aligned} S(Q, ES; y) = & (\mathbb{1}[y \leq Q] - \alpha)G_1(Q) - \mathbb{1}[y \leq Q]G_1(y) \\ & + G_2(ES)\left(ES - Q + \frac{1}{\alpha}\mathbb{1}[y \leq Q](Q - y)\right) - G_2(ES) + a(y), \end{aligned} \quad (49)$$

burada G_1 artan veya en azından azalmayan; $G_2 = \mathcal{G}_2'$ pozitif ve uygun düzenlilik altında artandır. Dolayısıyla $\mathcal{G}_2$ dışbükeydir; kesin tutarlılık için ilgili monotonluk ve dışbükeylik koşullarının kesin biçimleri gerekir (Fissler and Ziegel, 2016). AL seçiminde $G_2(e) = -1/e > 0$, $\mathcal{G}_2(e) = -\log(-e)$ ve $\mathcal{G}_2''(e) = 1/e^2 > 0$ olduğundan $\mathcal{G}_2$ kesin dışbükeydir.

Konvansiyon — işaret tutarlılığı

FZ/AL bölümü alt-kuyruk getiri konvansiyonundadır. Pozitif kayıp L 'den geçiş

$$y = -L, \quad Q_\alpha = -\text{VaR}_\alpha(L), \quad e_\alpha = -\text{ES}_\alpha(L)$$

ile yapılır; böylece $e_\alpha \leq Q_\alpha < 0$ olur. AL skorunun $\log(-e)$ biçimi yalnızca $e < 0$ alanında tanımlıdır. Pozitif kayıp VaR/ES ifadeleri bu dönüşüm yapılmadan aynı formüle doğrudan yerleştirilmemelidir.

$G_1, G_2, \mathcal{G}_2$ seçimi (49) ailesinden farklı skorlar üretir (Taylor, 2020). Aşağıda kullanılan üç üye şunlardır (kısaltmalar): **AL** = Asimetrik Laplace (Taylor 2019), **NZ** = Nolde–Ziegel (Nolde and Ziegel 2017), **FZG** = Fissler–Ziegel–Gneiting (Fissler et al. 2016). Üçü de aynı ortak-belirlenebilir aileden gelir; yalnızca $G_1, G_2, \mathcal{G}_2$ seçimiyle ayrışır ve farklı sonlu-örneklem ayırt-etme gücü sunar:

Tablo 13: Eq. (49) içindeki fonksiyonlar: AL, NZ, FZG skorları (Taylor 2020, Tablo 1).

Skor	$G_1(x)$	$G_2(x)$	$\mathcal{G}_2(x)$	$a(y)$
AL	0	$-1/x$	$-\ln(-x)$	$1 - \ln(1 - \alpha)$
NZ	0	$\frac{1}{2}(-x)^{-1/2}$	$-(-x)^{1/2}$	0
FZG	x	$e^x/(1 + e^x)$	$\ln(1 + e^x)$	$\ln 2$

AL (asimetrik Laplace) skoru. $G_1 = 0$ ile skor, kantil-doğruluğunu ve ES'yi birlikte değerlendirir; Taylor (2019) bunun zaman-değişken konum ve ölçekli bir asimetrik Laplace yoğunluğunun negatif log-olabilirliğine eşit olduğunu gösterir (kantil regresyonun doğal uzantısı; teorik destek için Patton et al. 2019). Sabit terimler düşürülünce:

$$S_{AL}(Q, ES; y) = \frac{Q}{ES} - \frac{\mathbb{1}[y \leq Q](Q - y)}{\alpha ES} + \ln(-ES). \quad (50)$$

Bu skor, §2.7'de kombinasyon ağırlıklarının kestiriminde ve §2.11'daki backtest'te kullanılır.

2.4.2 Strictly Proper Scoring Rules Teorisi

Bir S puanlama fonksiyonu **kesinlikle uygun (strictly proper)** olarak adlandırılır eğer:

$$\mathcal{T}(F) = \arg \min_x \mathbb{E}_F[S(x, Y)] \quad \text{ve minimum değerde tek minimizör mevcutsa} \quad (51)$$

Strictly proper puanlama fonksiyonları, tahmin eden kişiyi *gerçek* inancını raporlamaya teşvik eder: beklenen skor yalnızca doğru fonksiyonelde minimize olduğundan, tahminciyi “oynayarak” (ör. raporlanan riski sistematik biçimde düşük/yüksek göstererek) skoru iyileştirmek mümkün değildir. Uygulamacı açısından bu, model karşılaştırmasını ve düzenleyici raporlamayı *teşvik-uyumlu* kılar — risk masalarının veya satıcıların skoru manipüle etme güdüsü ortadan kalkar. Belirlenebilir bir fonksiyonel ile kesin-tutarlı (strictly consistent) bir skorun birleşimi, hem tahmin (kestirim) hem de değerlendirme (backtest) için tutarlı bir zemin sağlar.

2.5 Bireysel VaR ve ES Tahmini

Bu bölümdeki yöntemler ortak bir mantık izler: önce kayıp dağılımının kuyruğu hakkında bir varsayım ya da yaklaşım kurulur, ardından *aynı* yaklaşımdan hem VaR_α hem ES_α türetilir. ES her durumda (47)'teki kuyruk-integrali tanımının ilgili VaR tahmincisine uygulanmasıyla elde edilir; bu nedenle yöntemler VaR ve ES için ayrı ayrı değil, **yöntem ailesi** bazında sunulur.

Yöntem Ailelerine Genel Bakış

Aile	Kuyruk hakkındaki varsayım	Temel sınırı
(a) Parametrik	Belirli bir dağılım (Normal, Student- t)	Dağılım yanlışsa kuyruk sistematik hatalı
(b) Tarihsel Simülasyon	Yok; ampirik pencere	Sabit varyans varsayımı; dinamiğe tepkisiz
(c) Filtrelenmiş TS	Koşullu oynaklık + ampirik artık kuyruğu	İki aşamalı; GARCH spesifikasyonuna bağlı
(d) Kuyruk-integrali	Yok; herhangi bir VaR motorunu kullanır	Sayısal; VaR tahmincisinin kalitesine bağlı
(e) Aşırı Değer Teorisi	Kuyruk için asimptotik GPD	Eşik seçimine duyarlı
(f) Cornish–Fisher	Momentlerle kantil düzeltmesi	Yalnızca ılımlı çarpıklık/basıklıkta geçerli

2.5.1 (a) Parametrik Yöntemler: Normal ve Student- t

Getirilerin $r_t \sim N(\mu_t, \sigma_t^2)$ dağıldığı varsayılır:

$$\text{VaR}_\alpha^{(N)} = -(\mu_t + \sigma_t z_\alpha) \quad (52)$$

Burada $z_\alpha = \Phi^{-1}(\alpha)$ standart normal dağılımın α -kantilidir (ör. $z_{0.05} = -1.645$).

Kalın kuyruk özelliğini yakalamak için t_ν dağılımı varsayılır:

$$\text{VaR}_\alpha^{(t)} = -(\mu_t + s_t t_{\alpha, \nu}), \quad s_t = \sigma_t \sqrt{\frac{\nu - 2}{\nu}} \quad (53)$$

Aynı dağılım varsayımı altında ES kapalı formda elde edilir. Normal dağılımda ES kapalı formdadır:

$$\text{ES}_\alpha^{(N)} = -\mu + \sigma \frac{\phi(z_\alpha)}{\alpha}, \quad (54)$$

burada $\phi(\cdot)$ standart normal yoğunluk fonksiyonudur. Student- t dağılımında (t_ν , birim varyansa ölçeklenmiş $s_t = \sigma_t \sqrt{(\nu - 2)/\nu}$):

$$\text{ES}_\alpha^{(t)} = -\mu_t + s_t \frac{g_\nu(t_{\alpha, \nu})}{\alpha} \cdot \frac{\nu + t_{\alpha, \nu}^2}{\nu - 1}, \quad \nu > 1, \quad (55)$$

burada $t_{\alpha, \nu}$ standart t_ν 'nin α -kantili, $g_\nu(\cdot)$ ise yoğunluğudur. Kalın kuyruk (ν küçük) ES–VaR farkını büyütür.

2.5.2 (b) Tarihsel Simülasyon (Historical Simulation — HS)

Son W gözlemden oluşan penceredeki kayıpların deneysel kantili:

$$\text{VaR}_\alpha^{(\text{HS})} = \text{Kantil}_{1-\alpha}(\{L_{t-W+1}, \dots, L_t\}) \quad (56)$$

ES, VaR eşğini aşan pencere-içi kayıpların basit ortalamasıdır:

$$ES_{\alpha}^{(HS)} = \frac{\sum_s L_s \mathbf{1}\{L_s > VaR_{\alpha}^{(HS)}\}}{\sum_s \mathbf{1}\{L_s > VaR_{\alpha}^{(HS)}\}}. \quad (57)$$

Ağırlıklı HS'de (WHS) ilgili gözlemler üstel ağırlıklarla, RiskMetrics'te ise σ_t^2 özyinelemesinden gelen ölçekle değerlendirilir.

2.5.3 (c) Filtrelenmiş Tarihsel Simülasyon (Filtered HS — FHS)

GARCH(1,1) artıklarından $\hat{z}_s = \varepsilon_s / \hat{\sigma}_s$ hesaplanır; bunların deneysel dağılımından örnekleme yapılarak $t + 1$ dönemi için:

$$VaR_{\alpha}^{(FHS)} = -\hat{\sigma}_{t+1} \text{Kantil}_{\alpha}(\{\hat{z}_1, \dots, \hat{z}_T\}) \quad (58)$$

Standartlaştırılmış artıkların $\{\hat{z}_s\}$ eşik-altı ortalaması koşullu oynaklıkla ölçeklenir:

$$ES_{\alpha}^{(FHS)} = -\hat{\sigma}_{t+1} \frac{\sum_s \hat{z}_s \mathbf{1}\{\hat{z}_s < q_{\alpha}\}}{\sum_s \mathbf{1}\{\hat{z}_s < q_{\alpha}\}}, \quad q_{\alpha} = \text{Kantil}_{\alpha}(\{\hat{z}_s\}). \quad (59)$$

Not 2.4. FHS yöntemi, parametrik yöntemlerin dağılım varsayımlarından ve tarihsel simülasyonun sabit varyans varsayımından kaçınır; bu nedenle pratikte sıklıkla tercih edilir.

2.5.4 (d) Genel Kuyruk-İntegrali Yöntemi

Analitik ES formülü bulunmayan (ör. FHS, ampirik) modellerde ES, VaR'ın alt olasılık düzeyleri üzerinden sayısal integrasyonu ile elde edilir:

$$ES_{\alpha} = \frac{1}{\alpha} \int_0^{\alpha} VaR_p dp \approx \frac{1}{N_d} \sum_{j=1}^{N_d} VaR_{p_j}, \quad p_j = \frac{(j-0.5)\alpha}{N_d}. \quad (60)$$

Bu yaklaşım, aynı VaR tahmin motoruyla tutarlı bir ES üretmesi bakımından temel/parametrik ailelerde tercih edilir (McNeil–Frey 2000).

2.5.5 (e) Aşırı Değer Teorisi (Extreme Value Theory — EVT) ile Kuyruk Tahmini

Neden EVT?

Normal ve Student- t dağılımları, finansal kayıp dağılımlarının kuyruk kısmını sistematik olarak küçümseme eğilimindedir. 2008 Küresel Mali Krizinde Goldman Sachs risk yöneticisi David Viniar “25 sigma olayları” yaşandığını belirtmiştir; oysa bu olasılık normal dağılım altında pratikte sıfırdır. EVT, bu tür aşırı değerlerin asimptotik dağılım teorisini doğrudan modeller.

Aşırı Değer Teorisi'nin temel sorusu şudur: n bağımsız özdeş dağılımlı rasgele değişkenin *maksimumu* hangi dağılıma yakınsar? Bu soruya verilen yanıt, iki tamamlayıcı yöntemle dayanır.

Blok Maksima Yöntemi (Block Maxima — BM) T günlük kayıp gözlemlerini n eşit bloğa bölelim; her bloktan maksimum kayıp alınsın: $M_b = \max_{t \in \text{blok } b} L_t$.

Teorem 2.1 (Gnedenko-Fisher-Tippett). *Uygun normalleştirme sabitlerinin varlığı halinde, blok maksimumlarının sınır dağılımı Genelleştirilmiş Aşırı Değer (GEV) dağılımıdır:*

$$F(x; \mu, \sigma, \xi) = \exp \left\{ - \left[1 + \xi \frac{x - \mu}{\sigma} \right]^{-1/\xi} \right\}, \quad \xi \neq 0, \quad (61)$$

$1 + \xi(x - \mu)/\sigma > 0$ desteğinde tanımlıdır. $\xi = 0$ için sürekli Gumbel limiti ayrıca

$$F(x; \mu, \sigma, 0) = \exp \left[- \exp \left(- \frac{x - \mu}{\sigma} \right) \right]$$

şeklindedir; $\mu \in \mathbb{R}$ konum, $\sigma > 0$ ölçek ve ξ şekil parametresidir.

Şekil parametresi ξ , dağılımın kuyruk tipini belirler:

- $\xi > 0$: **Fréchet dağılımı** — kalın kuyruk (power-law), hisse senedi getirileri ve döviz kurları bu gruba girer.
- $\xi = 0$: **Gumbel dağılımı** — orta kuyruk, normal dağılım bu limite karşılık gelir.
- $\xi < 0$: **Weibull dağılımı** — ince ve sonlu sağ uç.

Eşik Aşma Yöntemi (Peaks Over Threshold — POT) Blok maksima yöntemi veri israfına neden olur. POT yöntemi yalnızca belirli bir eşik u 'yu aşan gözlemleri kullanır, bu nedenle daha verimlidir.

$L_t > u$ olan gözlemler için *aşım* (excess) değerleri $Y = L - u > 0$ tanımlanır.

Tanım 2.5 (Genelleştirilmiş Pareto Dağılımı — GPD).

$$G(y; \xi, \beta_u) = 1 - \left(1 + \frac{\xi y}{\beta_u} \right)^{-1/\xi}, \quad y > 0 \quad (62)$$

$\beta_u > 0$ ölçek (eşik u 'ya bağlı), ξ şekil parametresidir. $\xi = 0$ iken $G(y) = 1 - e^{-y/\beta_u}$ (üstel dağılım).

Teorem 2.2 (Pickands-Balkema-de Haan). *GEV dağılımının çekim bölgesine giren bir dağılım için, yeterince büyük eşik u 'da koşullu aşım dağılımı GPD'ye yakınsar:*

$$P(L - u \leq y \mid L > u) \xrightarrow{u \uparrow x_F} G(y; \xi, \beta_u), \quad x_F = \sup\{x : F_L(x) < 1\}. \quad (63)$$

Bu teorem, eşik üst son noktaya yaklaştıkça aşım dağılımının GPD ile yaklaştırılabileceğini söyler. $u \rightarrow \infty$ yalnızca $x_F = \infty$ olan dağılımların özel durumudur.

Ağır Kuyruklar İçin Hill Kuyruk-İndeksi Tahmincisi Hill tahmincisi genel bir GPD şekil-parametresi tahmincisi değildir. Pozitif ve düzenli değişen ağır sağ kuyruklarda, $\xi > 0$

koşulu altında kuyruk indeksini tahmin eder. $\xi = 0$ veya $\xi < 0$ kuyruklarında geçerli değildir. Bu koşullar altında Hill (1975) tahmincisi:

$$\hat{\xi}_H = k^{-1} \sum_{j=1}^k \ln \left(\frac{X_{(n-j+1)}}{X_{(n-k)}} \right) \quad (64)$$

Burada $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ sıralı istatistiklerdir ve k , eşik üzerinde kaç gözlem kullanılacağını belirler.

- **k seçimi:** Hill grafiği ($\hat{\xi}_H$ vs k) çizilir; $\hat{\xi}_H$ 'nin kararlı görüldüğü (plateau) bölge optimal k 'ya karşılık gelir.
- **Mean Excess Plot:** $e(u) = E[L - u | L > u]$ değeri u 'ya karşı çizilir. GPD varsayımı altında bu fonksiyon doğrusal olmalıdır; doğrusallığın başladığı nokta eşik u 'yu önerir.

EVT ile VaR ve ES Formülleri N toplam gözlem, N_u eşik u 'yu aşan gözlem sayısı olmak üzere, MLE ile tahmin edilen $\hat{\xi}$ ve $\hat{\beta}_u$ parametreleri kullanılarak (McNeil-Frey 2000; α kuyruk olasılığı):

$$\text{VaR}_\alpha^{\text{EVT}} = u + \frac{\hat{\beta}_u}{\hat{\xi}} \left[\left(\frac{N}{N_u} \alpha \right)^{-\hat{\xi}} - 1 \right], \quad \hat{\xi} \neq 0, \quad (65)$$

$$\text{ES}_\alpha^{\text{EVT}} = \frac{\text{VaR}_\alpha^{\text{EVT}} + \hat{\beta}_u - \hat{\xi}u}{1 - \hat{\xi}}, \quad \hat{\xi} < 1. \quad (66)$$

$\hat{\xi} = 0$ limitinde $\text{VaR}_\alpha = u + \hat{\beta}_u \log\{N_u/(N\alpha)\}$ ve $\text{ES}_\alpha = \text{VaR}_\alpha + \hat{\beta}_u$ olur. $\xi \geq 1$ ise teorik ES sonsuzdur.

Not 2.5. Koşullu risk modellemesinde (GARCH + kuyruk) EVT, *standartlaştırılmış artıkların* $\hat{z}_t = \varepsilon_t/\hat{\sigma}_t$ kayıp kuyruğuna uygulanır; tek-adım VaR/ES, elde edilen artık-kantili $\hat{\sigma}_{t+1}$ ile ölçeklenerek bulunur (McNeil-Frey 2000). Eq. (65)'de α kuyruk olasılığıdır (%99 VaR için $\alpha = 0.01$); α yerine $(1 - \alpha)$ kullanmak VaR'ı eşik altına iterek anlamsız sonuç verir.

Tablo 14: Normal, Student- t ve Veri-Temelli Yöntemler: %99 VaR ve %97.5 ES

Model	VaR (%99)	ES (%97.5)	Not
Normal	2.326σ	2.338σ	Analitik referans
Student- $t(5)$, birim varyanslı	2.606σ	2.728σ	Analitik referans
EVT/GPD	Veriye bağlı	Veriye bağlı	Eşik ve kuyruk parametrelerine bağlı
FHS	Veriye bağlı	Veriye bağlı	Standardize artıkların deneysel kuyruğuna bağlı

Not: Normal ve Student- t satırları analitiktir; EVT ve FHS değerleri veri, eşik ve tahmin penceresine bağlıdır.

Python ile POT/EVT Uygulaması

```
1 import numpy as np
2 from scipy.stats import genpareto
3
4 def gpd_fit(losses, u_quantile=0.90):
5     """GPD parametrelerini MLE ile tahmin eder."""
6     u = np.quantile(losses, u_quantile)
7     excesses = losses[losses > u] - u
8     # scipy: genpareto.fit(x, floc=0) -> (xi, loc=0, beta)
9     xi, loc, beta = genpareto.fit(excesses, floc=0)
10    return xi, beta, u, excesses
11
12 def evt_var_es(losses, alpha=0.01, u_quantile=0.90):
13     """EVT/GPD ile VaR ve ES; alpha ust-kuyruk olasiligidir."""
14     xi, beta, u, excesses = gpd_fit(losses, u_quantile)
15     N, Nu = len(losses), len(excesses)
16     A = (N / Nu) * alpha
17     if abs(xi) < 1e-8:
18         var = u - beta * np.log(A)
19         es = var + beta
20     else:
21         var = u + beta * np.expm1(-xi * np.log(A)) / xi
22         if xi >= 1:
23             es = np.inf
24         else:
25             es = (var + beta - xi * u) / (1 - xi)
26     return var, es, xi, beta
27
28 def hill_estimator(losses, k):
29     """Hill kuyruk indeksi tahmincisi."""
30     x = np.sort(losses)[::-1] # azalan siralama
31     xi_h = np.mean(np.log(x[:k]) - np.log(x[k]))
32     return xi_h
33
34 # Ornek kullanim
35 np.random.seed(42)
36 losses = -np.random.standard_t(df=4, size=2000) * 0.01 # t(4)
37     kayiplar
38 var99, es99, xi, beta = evt_var_es(losses, alpha=0.01)
39 _, es975, _, _ = evt_var_es(losses, alpha=0.025)
40 print(f"EVT VaR(99%): {var99:.4f}")
41 print(f"EVT ES(99%): {es99:.4f}")
42 print(f"EVT ES(97.5%): {es975:.4f}")
43 print(f"Sekil parametresi (xi): {xi:.4f}")
```

2.5.6 (f) Cornish–Fisher Açılımı ile Modifiye VaR

Cornish-Fisher (1937; CF) açılımı, standart normal kantilin yerine dağılımın çarpıklık ve basıklık bilgisini kullanan bir düzeltme önermektedir. Bu yöntem, tam bir dağılım varsayımı olmadan daha gerçekçi kantil tahminleri üretir.

CF Düzeltmeli Kantil Dağılımın çarpıklığı S ve fazla basıklığı (excess kurtosis) K olmak üzere:

$$z_{\alpha}^{\text{CF}} = z_{\alpha} + \frac{1}{6}(z_{\alpha}^2 - 1)S + \frac{1}{24}(z_{\alpha}^3 - 3z_{\alpha})K - \frac{1}{36}(2z_{\alpha}^3 - 5z_{\alpha})S^2 \quad (67)$$

Burada $z_{\alpha} = \Phi^{-1}(\alpha)$ standart normal kantildir.

Modifiye VaR

$$\text{VaR}_{\alpha}^{\text{CF}} = -(\hat{\mu} + \hat{\sigma} z_{\alpha}^{\text{CF}}) \quad (68)$$

Tablo 15: Normal VaR ile CF-VaR Karşılaştırması (Örnek: $\alpha = 0.01$)

Senaryo	S	K	$z_{0.01}^{\text{CF}}$	VaR artışı
Normal (referans)	0.0	0.0	-2.326	—
Hafif sola çarpık	-0.5	1.0	-2.834	+21.8%
Orta sola çarpık	-1.0	3.0	-3.387	+45.6%
Yüksek basıklık	-0.3	5.0	-3.682	+58.3%

Değerler Denklem (67)'den $z_{0.01} = \Phi^{-1}(0.01) = -2.32635$ ile doğrudan hesaplanmıştır. Sıralamaya dikkat: üçüncü senaryoda çarpıklık daha ılımlı olmasına karşın basıklık düzeltmesi baskındır ve en büyük VaR artışını bu satır üretir — kalın kuyruk, orta düzeydeki asimetriden daha belirleyicidir.

- **Avantaj:** Hızlı hesaplama; tam dağılım varsayımı gerekmez; yüksek frekanslı veya portföy düzeyinde uygulamalarda pratik.
- **Dezavantaj:** S ve K tahminleri güvenilir büyük örneklem gerektirir; çok yüksek basıklık değerlerinde Taylor açılımı hatalı sonuç verebilir (z_{α}^{CF} bazen monoton olmayabilir).

Not 2.6. Yukarıdaki yöntemler ES'yi bir VaR tahmincisinden *türetir*. Buna karşılık yarı-parametrik yaklaşımlar (Fissler–Ziegel skoru temelli GAS, CaViaR–AL ve HAR–Range modelleri) VaR ile ES'yi *birlikte* ve doğrudan tahmin eder; bunlar §2.6'de ele alınmaktadır. ES tek başına belirlenebilir (elicitable) olmadığından, doğrudan ES tahmini ancak (VaR, ES) ikilisini birlikte puanlayan FZ kayıp aileleri üzerinden tutarlı biçimde yapılabilir.

2.6 Yarı-Parametrik VaR–ES Tahmincileri

§2.2 ve §2.3'teki yöntemler ES'yi bir VaR tahmincisinden *türetir*. Buna karşılık bu bölümdeki yarı-parametrik modeller, (VaR, ES) ikilisini §2.4'te tanıtilen Fissler–Ziegel (FZ) kayıp ailesini minimize ederek *doğrudan ve birlikte* kestirir. ES tek başına belirlenebilir olmadığından, bu ortak yaklaşım herhangi bir tam dağılım varsayımı yapmadan ES'yi tutarlı biçimde hedeflemenin temel yoludur. Aşağıda α üst-kuyruk olasılığını, r_t getiri, $v_t = \text{VaR}_t$ ve $e_t = \text{ES}_t$ 'yi (getiri ölçeğinde, negatif) gösterir.

2.6.1 Bir-Faktörlü GAS Modeli (FZ-GAS)

Patton et al. (2019), VaR ve ES dinamiğini tek gizli faktörle yönetir:

$$v_t = a \exp(\kappa_t), \quad e_t = b \exp(\kappa_t), \quad b < a < 0, \quad (69)$$

burada faktör, Genelleştirilmiş Otoregresif Skor (GAS) özyinelemesiyle evrilir:

$$\kappa_t = \omega + \beta \kappa_{t-1} + \gamma s_{t-1}, \quad (70)$$

ve s_{t-1} FZ kaybının ölçekli skorudur (gradyanı). $b < a < 0$ oransal kısıtı $e_t \leq v_t$ (yani $ES \leq VaR$) sıralamasını yapısal olarak korur; tüm parametreler FZ kaybının örneklem toplamı minimize edilerek kestirilir.

2.6.2 FZ-GARCH Modeli

Aynı FZ-optimizasyon ilkesi, oynaklığı bir GARCH-ailesi spesifikasyonu ile modelleyerek uygulanır; ayırt edici fark, oynaklık parametrelerinin olabilirlik (MLE) yerine FZ kaybıyla kestirilmesidir. Getiri modeli $r_t = \kappa_t z_t$, $z_t \sim \text{iid } F_z(0, 1)$ olmak üzere risk ölçütleri ölçek κ_t (koşullu oynaklık) ile orantılıdır:

$$v_t = a \kappa_t, \quad e_t = b \kappa_t, \quad a = F_z^{-1}(\alpha), \quad b = \mathbb{E}[z \mid z \leq a]. \quad (71)$$

Burada a, b katsayıları standartlaştırılmış yenilik dağılımı F_z 'den gelir; oynaklık parametreleri MLE yerine FZ kaybıyla kestirilir (Patton et al., 2019).

Bu ünitenin uygulama panelinde κ_t için kullanılan GARCH-ailesi varyantları ve temel farkları aşağıdadır ($z_t = r_t/\kappa_t$ standart artık; rejim-değişimli MSGARCH ve bootstrap-tabanlı sürümler hesaplama maliyeti nedeniyle kapsam dışıdır):

- **GARCH(1,1)** — $\kappa_t^2 = \omega + a_1 r_{t-1}^2 + b_1 \kappa_{t-1}^2$: simetrik temel model; oynaklık kümelenmesini yakalar, ancak kaldıraç etkisini içermez (pozitif ve negatif şoklar oynaklığı eşit etkiler).
- **GJR-GARCH (eşik)** — $\kappa_t^2 = \omega + (a_1 + g_1 \mathbb{1}\{r_{t-1} < 0\}) r_{t-1}^2 + b_1 \kappa_{t-1}^2$: kaldıraç ekler; $g_1 > 0$ ise negatif getiriler oynaklığı pozitiflerden daha fazla artırır — hisse getirilerinde tipik asimetri.
- **EGARCH** — $\ln \kappa_t^2 = \omega + a_1(|z_{t-1}| - \mathbb{E}|z|) + g_1 z_{t-1} + b_1 \ln \kappa_{t-1}^2$: log-oynaklık modellediğinden pozitiflik kısıtı gerekmez; asimetriyi $g_1 z_{t-1}$ (işaret) ve büyüklüğü $|z_{t-1}|$ ile ayrı ayrı yakalar.

Yenilik dağılımı F_z olarak Normal (ince kuyruk) ve Student- t (kalın kuyruk) kullanılır; a ve b bu seçime göre değişir (ör. Student- t daha büyük $|a|, |b|$ üretir). Son olarak, F_z parametrik yerine ampirik (eğitim standart-artıklarınının kuyruğu) alındığında aynı GARCH oynaklığı Filtrelenmiş Tarihsel Simülasyon (FHS) verir; panelde GARCH-FHS ve GJR-FHS bu yolla elde edilir.

2.6.3 CaViaR ve Asimetrik Laplace (AsL)

Taylor (2019), Engle and Manganelli (2004)'nın koşullu kantil özyinelemesini (CaViaR) asimetrik Laplace (AL) yoğunluğu üzerinden ortak VaR-ES kestirimine genişletir. Koşullu kantil v_t dört spesifikasyondan biriyle modellenir:

$$\text{SAV: } v_t = \beta_1 + \beta_2 v_{t-1} + \beta_3 |r_{t-1}|, \quad (72)$$

$$\text{Asimetrik Eğim (AS): } v_t = \beta_1 + \beta_2 v_{t-1} + \beta_3 (r_{t-1})^+ + \beta_4 (r_{t-1})^-, \quad (73)$$

$$\text{Dolaylı GARCH: } v_t = -(\beta_1 + \beta_2 v_{t-1}^2 + \beta_3 r_{t-1}^2)^{1/2}, \quad (74)$$

$$\text{Uyarlanır: } v_t = v_{t-1} + \beta_1 (\mathbb{1}\{r_{t-1} \leq v_{t-1}\} - \alpha). \quad (75)$$

ES, AL yoğunluğu altında kantile bağlanır: *basit* sürümde e_t/v_t oranı sabit, *dinamik* sürümde zaman-değişkendir. Parametreler AL log-olabilirliğini (eşdeğer olarak FZ kaybını) optimize ederek kestirilir.

2.6.4 Gün İçi Açıklık Tabanlı VaR–ES: HAR–Range (basitleştirilmiş)

Gün-içi en düşük fiyat ve açıklık (range) bilgisinin VaR–ES kestiriminde kullanılması Meng and Taylor (2020)’ye dayanır. Özgün çalışma, açıklık ve gün-içi düşük getiriyi *CaViaR-FZ-Range* spesifikasyonu içinde kullanır ve VaR ile ES’yi ortak FZ skoruyla birlikte kestirir; aşağıdaki HAR regresyonu bu modelin kendisi *değil*, aynı bilgi kaynağını kullanan basitleştirilmiş bir ders modelidir.

Açıklık $\text{Range}_t = \log(P_t^h) - \log(P_t^l)$ (P_t^h, P_t^l : gün-içi en yüksek/en düşük fiyat) olmak üzere, Corsi (2009)’nin heterojen otoregresif yapısı açıklığa uygulanır:

$$\widehat{\text{Range}}_{t|t-1} = \beta_1 + \beta_2 \text{Range}_{t-1} + \beta_3 \overline{\text{Range}}_{t-1}^{(5)} + \beta_4 \overline{\text{Range}}_{t-1}^{(22)}, \quad (76)$$

$\overline{\text{Range}}^{(5)}$ ve $\overline{\text{Range}}^{(22)}$ haftalık ve aylık ortalamalardır. Koşullu varyans, gerçekleşen açıklığa değil *öngörülen* açıklığa bağlanır:

$$\text{var}(r_t | \mathcal{F}_{t-1}) = \delta_0 + \delta_1 \widehat{\text{Range}}_{t|t-1}, \quad (77)$$

ve VaR–ES Normal, Çarpık- t ve GED dağılımları altında hesaplanır.

Zamanlama: Range_t neden sağ tarafta yer alamaz?

Range_t , gün t ’nin en yüksek ve en düşük fiyatından hesaplanır; dolayısıyla r_t tahmin edilirken $\mathcal{F}_{t-1}$ -ölçülebilir *değildir*. Koşullu varyans denkleminde doğrudan Range_t kullanmak look-ahead yaratır ve elde edilen VaR/ES rakamları örneklem-dışı olarak yorumlanamaz. Denklem (77) bu nedenle (76)’in öngörüsünü kullanır.

Not 2.7 (Uygulanabilirlik ve Kapsam). Uygulama panelinde **FZ-GAS**, **FZ-GARCH**, **CaViaR-AsL** (sağlam SAV ve AS spesifikasyonları) ve **HAR-Range** yer alır. Rejim değişimli (MSGARCH), bootstrap-tabanlı (Rob-GARCH-boot), fraksiyonel (FIGARCH) ve yakınsama sorunlu bazı egzotik GARCH türevleri hesaplama maliyeti ve kararlılık nedeniyle kapsam dışı bırakılmıştır.

2.7 Öngörü Kombinasyonu (Forecast Combination)

2.7.1 Motivasyon

Tek bir “en iyi” model yerine, birden fazla modelin öngörülerini birleştirmek, *sapma-varyans* (bias-variance) ödünleşiminden faydalanarak daha sağlam tahminler üretebilir (Bates and Granger, 1969).

Neden ağırlık kestirimi VaR/ES’ye doğrudan taşınamaz?

Ortalama (nokta) öngörü yazınındaki ağırlık-kestiren yöntemler — OLS regresyonu, Bates–Granger ters-varyans, Ridge/Lasso büzülme, Bayesçi model ortalaması — *kareli kayıp* varsayımına dayanır ve VaR/ES’ye *doğrudan* uygulanamaz: (i) VaR bir kantildir ve kareli kayıp bir kantil için tutarlı değildir (tutarlı skor kantil kaybıdır); (ii) ES tek başına belirlenebilir değildir (§2.4), dolayısıyla bir ES-kayıp minimize edilerek ES-ağırlığı kestirilemez. Bu nedenle bu bölümde yalnızca (1) ağırlık kestirimi *gerektirmeyen* basit birleştirme operatörlerini ve (2) ağırlıkları FZ *ortak* skoruyla kestiren Taylor (2020) yaklaşımını (§2.7.3) ele alıyoruz.

2.7.2 Basit Birleştirme Kuralları

Aşağıdaki kurallar, bireysel VaR ve ES öngörülerine *doğrudan* uygulanan, ağırlık kestirimi gerektirmeyen basit operatörlerdir ve VaR-ES yazınında yaygın biçimde *sağlam kıyas ölçütü* olarak kullanılır. Bu operatörlerin gerçek koşullu VaR veya ES için istatistiksel *tutarlılığı otomatik değildir*: bireysel öngörüler farklı limitlere yakınsıyorsa ortalama ya da medyan, gerçek koşullu kantile değil bir karışıma yakınsar (kantillerin ortalaması, karışım dağılımının kantiline eşit değildir). Tutarlılık, bireysel öngörülerin özelliklerine ve veri üretme sürecine ilişkin ilave varsayımlar gerektirir. $\hat{f}_{m,t}$, model m 'nin t anındaki öngörüsünü (VaR ya da ES) ve J model sayısını gösterebilir.

(a) Basit Ortalama (Mean).

$$\hat{f}_t^{\text{ort}} = \frac{1}{J} \sum_{m=1}^J \hat{f}_{m,t}. \quad (78)$$

VaR-ES yazınında *aktif olarak* en yaygın kullanılan birleştirme kuralıdır; sıklıkla çok daha karmaşık yöntemlere yakın performans gösterir (*forecast combination puzzle*).

(b) Medyan.

$$\hat{f}_t^{\text{med}} = \text{medyan}\{\hat{f}_{1,t}, \dots, \hat{f}_{J,t}\}. \quad (79)$$

Ortalamaya göre *aykırı* (outlier) bireysel öngörülere daha dayanıklıdır; birkaç modelin uç değer ürettiği durumlarda tercih edilir. Ortalama ile birlikte, çok sayıda modelin birleştirilmesinde temel sağlam kıyaslardır (Taylor 2020; Taylor–Wang 2025).

(c) Minimum ve Maksimum.

$$\hat{f}_t^{\min} = \min_m \hat{f}_{m,t}, \quad \hat{f}_t^{\max} = \max_m \hat{f}_{m,t}. \quad (80)$$

Kayıp (pozitif) ölçeğinde $\hat{f}_t^{\max}$ en *tutucu* (en yüksek risk tahmini), $\hat{f}_t^{\min}$ ise en *agresif* birleştirmedir; düzenleyici ihtiyat açısından maksimum kuralı, raporlanan risk rakamı için bir taban — yani bireysel öngörülerin *muhafazakâr üst zarfı* — oluşturur; bu, gerçek VaR/ES'nin alttan sınırlandığı anlamına gelmez. Bireysel öngörülerin uç değerini (min/maks/medyan) seçen bu kurallar McAleer vd. (2013) tarafından Basel çerçevesinde incelenmiştir.

Not 2.8. Yukarıdaki dört operatör (ort./med./min/maks) $\text{ES}_m \geq \text{VaR}_m$ sıralamasını korur: her operatör $\{\text{VaR}_m\}$ ve $\{\text{ES}_m\}$ kümelerine ayrı uygulandığında, $\text{ES}_m \geq \text{VaR}_m$ ($\forall m$) varsayımı altında birleşik $\text{ES} \geq$ birleşik VaR olur (sıralı istatistiklerin monotonluğundan). Bu kurallar bireysel modellerin *görelî başarısını* kullanmaz; performansa dayalı ağırlıklandırma için §2.7.3'deki Taylor (2020) yaklaşımı kullanılır.

2.7.3 VaR ve ES için Kombinasyon (Taylor, 2020)

Taylor (2020), FZ ortak-elicitability sonucunu kullanarak VaR ve ES ağırlıklarını *birlikte*, bir ortak skoru (Eq. (50)) minimize ederek kestirir. İki yöntem önerir.

(a) Minimum-Skor Kombinasyonu. Getiri konvansiyonunda $\text{ES}_{i,t} \leq Q_{i,t} < 0$ olduğundan pozitif açıklığı $S_{i,t} = Q_{i,t} - \text{ES}_{i,t} \geq 0$ olarak tanımlamak daha açıktır:

$$\hat{Q}_t^{\text{kom}} = \sum_{i=1}^J w_i^Q \hat{Q}_{i,t}, \quad (81)$$

$$\widehat{\text{ES}}_t^{\text{kom}} = \hat{Q}_t^{\text{kom}} - \sum_{i=1}^J w_i^S (\hat{Q}_{i,t} - \widehat{\text{ES}}_{i,t}). \quad (82)$$

$w_i^Q, w_i^S \geq 0$ ve her ağırlık kümesinin toplamı birdir. Böylece $\widehat{\text{ES}}_t^{\text{kom}} \leq \hat{Q}_t^{\text{kom}}$ sıralaması yapısal olarak korunur. Ağırlıklar örneklem-içi ortak FZ skorunu minimize ederek birlikte kestirilir.

(b) Göreli-Skor Kombinasyonu. Yöntemler geçmiş ortak-skor performansına göre (softmax) ağırlıklandırılır:

$$w_i = \frac{\exp(-\eta \sum_{j=1}^{t-1} S(\hat{Q}_{i,j}, \widehat{\text{ES}}_{i,j}, y_j))}{\sum_{k=1}^M \exp(-\eta \sum_{j=1}^{t-1} S(\hat{Q}_{k,j}, \widehat{\text{ES}}_{k,j}, y_j))}, \quad (83)$$

$\hat{Q}_t^{\text{kom}} = \sum_i w_i \hat{Q}_{i,t}$, $\widehat{\text{ES}}_t^{\text{kom}} = \sum_i w_i \widehat{\text{ES}}_{i,t}$. Tek ayar parametresi $\eta > 0$: $\eta \rightarrow 0$ basit ortalamaya, $\eta \rightarrow \infty$ en iyi tek yöntemin seçimine indirger; η örneklem-içi skoru minimize ederek seçilir.

Taylor (2020), beş hisse endeksinde (%1 ve %5 olasılık düzeyleri) *tüm* kombinasyon yöntemlerinin *tüm* bireysel yöntemleri (endeksler arası ortalama) yendiğini bulur; basit ortalama özellikle %5'te çok rekabetçidir (kötü yöntem — tarihsel simülasyon — dışlandığında). Bu, ortalama öngörüdeki “kombinasyon bulmacası”nın VaR/ES'ye taşındığını gösterir.

2.8 Geriye Dönük Test (Backtesting)

2.8.1 VaR Geriye Dönük Test

Tanım 2.6 (Hit (İhlal) Serisi). $I_t = \mathbb{1}[L_t > \widehat{\text{VaR}}_{\alpha,t}]$: t anındaki kaybın L_t 'nin, o gün için öngörülen VaR eşliğini aşıp aşmadığını gösteren ihlal (violation) göstergesidir. VaR koşullu ve zamanla değişen bir tahmin olduğundan $\widehat{\text{VaR}}_{\alpha,t}$ bir t alt-indisi taşır.

Doğru belirtilmiş bir modelde hit serisinin iki özelliği olmalıdır: (i) **doğru koşulsuz kapsama** — ihlal olasılığı hedef düzey α 'ya eşittir ($\mathbb{E}[I_t] = \alpha$); ve (ii) **bağımsızlık** — ihlaller zamanda kümelenmez, bir ihlalin gelmesi bir sonrakini haber vermez. İkisi birlikte $I_t \sim \text{i.i.d. Bernoulli}(\alpha)$ demektir. Aşağıdaki testler bunları ayrı ayrı (Kupiec: sıklık; Christoffersen: bağımsızlık) ve birlikte (koşullu kapsama) sınar. Test anlamlılık düzeyini, VaR kuyruk olasılığı α ile karıştırmamak için τ (ör. $\tau = 0.05$) ile gösteririz; $\chi_{q, 1-\tau}^2$, q serbestlik dereceli χ^2 dağılımının $(1 - \tau)$ -kantilidir.

(a) Kupiec POF Testi (Koşulsuz Kapsama). **Amaç.** İhlal (“başarısızlık”) *sıklığının* hedef düzey α ile tutarlı olup olmadığını sınar; ihlallerin zamanlamasını (bağımsızlığı) dikkate almaz. Testin adındaki **POF**, *Proportion of Failures* (başarısızlık/ihlal oranı) kısaltmasıdır.

Hipotezler. $H_0 : \mathbb{E}[I_t] = \alpha$ (doğru kapsama) karşı $H_1 : \mathbb{E}[I_t] \neq \alpha$.

Test istatistiği. $x = \sum_t I_t$ ihlal sayısı ve $\hat{p} = x/T$ gözlenen ihlal oranı olmak üzere olabilirlik-oranı istatistiği:

$$LR_{\text{uc}} = -2 \ln \left(\frac{(1 - \alpha)^{T-x} \alpha^x}{(1 - \hat{p})^{T-x} \hat{p}^x} \right). \quad (84)$$

Dağılım ve red kuralı. H_0 altında $LR_{\text{uc}} \xrightarrow{d} \chi^2(1)$. Anlamlılık düzeyi τ 'da, $LR_{\text{uc}} > \chi_{1, 1-\tau}^2$ (eşdeğer olarak p -değeri $< \tau$) ise H_0 reddedilir.

Yorum. Red, ihlal sıklığının α 'dan anlamlı biçimde saptığını gösterir: $\hat{p} > \alpha$ ise model riski *eksik* tahmin etmektedir (çok fazla ihlal — tehlikeli); $\hat{p} < \alpha$ ise *aşırı tutucudur* (gereksiz sermaye). Test yalnızca ihlal *sayısına* bakar, zamanlamasına değil.

(b) Christoffersen Bağımsızlık Testi. **Amaç.** İhlallerin zamanda *kümelenip* kümelenmediğini, yani bir ihlalin bir sonrakinin olasılığını değiştirip değiştirmediğini sınar.

Hipotezler. $\{I_t\}$ birinci dereceden Markov zinciri olarak modellenir; $\pi_{ij} = \Pr(I_t = j \mid I_{t-1} = i)$ geçiş olasılıkları olsun. $H_0 : \pi_{01} = \pi_{11}$ (ihlal olasılığı bir önceki günün durumundan bağımsız) karşı $H_1 : \pi_{01} \neq \pi_{11}$.

Test istatistiği. Oranın *payı* bağımsızlık-kısıtlı modelin olabilirliği ($L_{\text{restricted}}$), *paydası* ise kısıtsız birinci-derece Markov modelinin olabilirliğidir ($L_{\text{unrestricted}}$):

$$LR_{\text{ind}} = -2 \ln \left(\frac{L(\hat{\pi})}{L(\hat{\pi}_{01}, \hat{\pi}_{11})} \right). \quad (85)$$

Dağılım ve red kuralı. H_0 altında $LR_{\text{ind}} \xrightarrow{d} \chi^2(1)$; $LR_{\text{ind}} > \chi^2_{1,1-\tau}$ ($p < \tau$) ise reddedilir.

Yorum. Red, ihlallerin *kümelendiğini* gösterir — tipik olarak model oynaklık rejim değişimlerine yeterince hızlı tepki vermediğinde art arda ihlaller görülür. Sıklık doğru olsa bile bu, modelin *dinamiğinin* hatalı olduğuna işaret eder.

(c) Koşullu Kapsama Testi. Amaç. Doğru sıklık *ve* bağımsızlığı *birlikte* sınar.

Hipotezler. $H_0 : \mathbb{E}[I_t] = \alpha$ *ve* ihlaller bağımsız karşı H_1 : en az biri ihlal edilir.

Test istatistiği ve dağılımı. İki bileşenin toplamıdır:

$$LR_{\text{cc}} = LR_{\text{uc}} + LR_{\text{ind}} \xrightarrow{d} \chi^2(2). \quad (86)$$

Red kuralı ve yorum. $LR_{\text{cc}} > \chi^2_{2,1-\tau}$ ($p < \tau$) ise reddedilir. Bileşenlere ayrı bakmak tanı koydurur: Kupiec'i geçip Christoffersen'de kalan model *kümeleme*, tersi ise *yanlış sıklık* sorunu yaşıyordur.

(d) Dinamik Kantil Testi (DQ, Engle–Manganelli). Amaç. Koşullu kapsamayı *regresyonla* sınar: hit serisinin hem kendi geçmişinden hem de VaR seviyesinden bağımsız olup olmadığını *birlikte* test eder. Kupiec/Christoffersen'den daha güçlüdür, çünkü ikili değil sürekli bilgiyi (VaR düzeyi, birden çok gecikme) kullanır (Engle and Manganelli, 2004).

Hipotezler. Ortalaması sıfırlanmış hit $\text{Hit}_t = I_t - \alpha$ olsun ($\mathbb{E}[\text{Hit}_t] = 0$ doğru kapsamada). Açıklayıcı değişken matrisi X (sabit, gecikmeli hit'ler ve $\widehat{\text{VaR}}_{\alpha,t}$) üzerine regresyon $\text{Hit} = X\delta + \varepsilon$ kurulur. $H_0 : \delta = \mathbf{0}$ (hit hiçbir geçmiş bilgiyle ilişkili değil) karşı $H_1 : \delta \neq \mathbf{0}$.

Test istatistiği.

$$DQ = \frac{\hat{\delta}'(X'X)\hat{\delta}}{\alpha(1-\alpha)} = \frac{\text{Hit}'X(X'X)^{-1}X'\text{Hit}}{\alpha(1-\alpha)}. \quad (87)$$

Dağılım ve red kuralı. H_0 altında $DQ \xrightarrow{d} \chi^2(q)$, $q = \text{rank}(X)$ (regresör sayısı; standart dört-gecikme + VaR + sabit için $q = 6$). $DQ > \chi^2_{q,1-\tau}$ ($p < \tau$) ise reddedilir.

Yorum. Red, hit'lerin *öngörülebilir* olduğunu — kümelendiğini ya da VaR seviyesiyle sistematik ilişki taşıdığını — gösterir. Kupiec/Christoffersen'i geçen bir model DQ'da kalabilir; bu, kuyruk dinamiğinde daha ince bir hataya işaret eder.

2.8.2 Basel Trafik Işığ Yaklaşımı

Basel Komitesi, 250 günlük geriye dönük test penceresinde ihlal sayısına göre üç bölge tanımlamıştır:

Tablo 16: Basel Trafik Işığ Bölgesi (%99 VaR, 250 Günlük Pencere)

Renk	İhlal Sayısı (x)	Sonuç
Yeşil (Green)	$x \leq 4$	Yeşil bölge; ihlal sayısı düzenleyici eşğin altında
Sarı (Yellow)	$5 \leq x \leq 9$	Artı-faktör +0.40 ile +0.85 (çarpan 3.40–3.85)
Kırmızı (Red)	$x \geq 10$	Model reddedildi; acil revizyon gerekli

Not 2.9. Basel III/FRTB (Fundamental Review of the Trading Book) güncellemesiyle birincil değerlendirme kriteri %99 VaR ihlal sayısından %97.5 ES tabanlı değerlendirmeye geçmiştir. Ancak trafik ışığı yaklaşımı hâlâ iç model onay sürecinde referans alınmaktadır.

2.8.3 ES Geriye Dönük Test: Acerbi-Szekely Testi

Amaç. ES tek başına belirlenebilir olmadığından (§2.4), VaR gibi basit bir olabilirlik-oranı testiyle sına-namaz. [Acerbi and Szekely \(2014\)](#), ES tahmininin kuyruk kaybının *büyükliğini* doğru yakalayıp yakala-madığını ölçen simülasyon-temelli iki istatistik önerir.

Hipotezler. H_0 : ES tahmini doğrudur (VaR aşıldığında kaybın koşullu ortalaması $\widehat{ES}_t$ 'ye eşittir) karşı H_1 : ES riski *eksik* tahmin edilir (tek yönlü — uygulamada en önemli yön).

Test istatistikleri. İki istatistik yalnızca *normalleştirmede* ayrışır: Z_1 ihlal *sayısına* koşulludur (yal-nızca büyüklüğü sınırlar), Z_2 sıklığı da içerir:

$$Z_1 = \frac{1}{N_T} \sum_{t=1}^T \frac{L_t I_t}{\widehat{ES}_t} - 1, \quad N_T = \sum_{t=1}^T I_t, \quad (88)$$

$$Z_2 = \frac{1}{T\alpha} \sum_{t=1}^T \frac{L_t I_t}{\widehat{ES}_t} - 1. \quad (89)$$

H_0 altında $\mathbb{E}[Z_1] = \mathbb{E}[Z_2] = 0$ 'dır.

Dağılım ve red kuralı (Monte Carlo). İstatistiklerin kapalı-form asimptotik dağılımı yoktur; p -değeri simülasyonla elde edilir:

1. Gözlemlenen Z^{obs} (Z_1 veya Z_2) değerini hesapla.
2. Tahmin edilen model altında (ör. Student- t parametreleriyle) $B = 10,000$ yol simüle et ve her biri için $Z^{(b)}$ hesapla.
3. Tek yönlü eksik-risk testi için $p = B^{-1} \sum_b \mathbb{1}[Z^{(b)} \geq Z^{\text{obs}}]$.

$p < \tau$ ise H_0 reddedilir.

Yorum. Pozitif kayıp ve pozitif ES konvansiyonunda ES'nin eksik tahmini $L_t/\widehat{ES}_t$ oramını büyü-tür; dolayısıyla anlamlı derecede *pozitif* bir istatistik, kuyruk riskinin *eksik* tahmin edildiğini (tehlikeli) gösterir. Z_1 'in reddi büyüklük hatasına, Z_2 'nin reddi büyüklük ve/veya sıklık hatasına işaret eder.

McNeil–Frey (2000) Aşım-Artığı Testi. **Amaç.** ES'yi, VaR ihlali günlerindeki *aşım artıkları* (exceedance residuals) üzerinden sınırlar; ES yazının ilk ve hâlâ en yaygın testlerindendir ([McNeil and Frey, 2000](#)).

Hipotezler. İhlal günlerinde ($I_t = 1$) aşım artığı $er_t = L_t - \widehat{ES}_t$ (veya oynaklıkla ölçeklenmiş $er_t/\hat{\sigma}_t$) tanımlansın. Doğru ES altında bunların koşullu ortalaması sıfırdır. $H_0 : \mathbb{E}[er_t | I_t = 1] = 0$ karşı $H_1 : \mathbb{E}[er_t | I_t = 1] > 0$ (ES eksik tahmin — tek yönlü).

Test istatistiği ve dağılımı. İhlal günlerindeki artıkların ortalaması $\bar{er}$ üzerine kuruludur; standart hatası ve dağılımı, artıkların dağılımı bilinmediğinden *parametrik olmayan bootstrap* (Efron–Tibshirani, tipik olarak 1000 tekrar) ile elde edilir.

Red kuralı ve yorum. Bootstrap $p < \tau$ ise H_0 reddedilir. Pozitif $\bar{er}$, gerçekleşen kuyruk kaybının ES'yi aştığını — yani ES'nin *eksik* tahmin edildiğini — gösterir. Dağılım varsayımı yapmaması ve yalnızca ihlal günlerine odaklanması güçlü yanındır; zayıflığı, ihlal sayısı azken düşük güçlü olmasıdır.

Nolde–Ziegel (2017) Koşullu Kalibrasyon Testi. **Amaç.** Belirlenebilirlik kuramındaki *ta-nımlama (identification) fonksiyonlarını* kullanarak (VaR, ES) ikilisini *birlikte* sınavan birleşik bir çerçeve

sunar; ayrıca düzenleyici karar için bir *karşılaştırmalı* (comparative) backtest önerir (Nolde and Ziegel, 2017); §2.4'teki FZ ailesiyle doğrudan bağlantılıdır.

Hipotezler. $(\text{VaR}_t, \text{ES}_t)$ için, doğru kalibrasyonda koşullu beklentisi sıfır olan iki-boyutlu bir tanımlama fonksiyonu $\mathbf{V}(\text{VaR}_t, \text{ES}_t, r_t)$ vardır. $H_0 : \mathbb{E}[\mathbf{V}_t \mid \mathcal{F}_{t-1}] = \mathbf{0}$ (koşullu kalibrasyon); uygulamada $\mathcal{F}_{t-1}$ -ölçülebilir bir test-fonksiyonu (araç) $\mathbf{h}_{t-1}$ ile $\mathbb{E}[\mathbf{h}_{t-1} \mathbf{V}_t] = \mathbf{0}$ sınanır.

Pozitif-büyüklik konvansiyonunda $(\text{VaR}_t, \text{ES}_t > 0; \text{ihlal } \{r_t \leq -\text{VaR}_t\})$ tanımlama fonksiyonunun bileşenleri:

$$V_{1,t} = \mathbb{1}\{r_t \leq -\text{VaR}_t\} - \alpha, \quad (90)$$

$$V_{2,t} = (\text{VaR}_t - \text{ES}_t) + \frac{1}{\alpha} \mathbb{1}\{r_t \leq -\text{VaR}_t\} (-r_t - \text{VaR}_t), \quad (91)$$

öyle ki doğru (VaR, ES) öngörüsü altında $\mathbb{E}[V_{1,t}] = \mathbb{E}[V_{2,t}] = 0$ 'dır: V_1 kantil (VaR) kalibrasyonunu, V_2 ihlal günlerindeki ortalama aşımı ES 'ye bağlar. V_2 'deki $(\text{VaR} - \text{ES})$ teriminin işareti kritiktir — ters işaret H_0 altında $\mathbb{E}[V_2] = 2(\text{ES} - \text{VaR}) \neq 0$ verir ve doğru belirtilmiş modelde bile daima red üretir.

Test istatistiği ve red kuralı. Örneklem ortalaması $\bar{\mathbf{V}}_h = T^{-1} \sum_t \mathbf{h}_{t-1} \mathbf{V}_t$ üzerine kurulu Wald istatistiği H_0 altında χ^2 dağılır; kritik değeri aşarsa ($p < \tau$) reddedilir.

Yorum. Basit sürüm ($\mathbf{h} = \mathbf{1}$) koşulsuz, genel sürüm koşullu kalibrasyonu sınar. NZ'nin ayırt edici katkısı *karşılaştırmalı backtest*tir: bir modeli bir kıyas modeline karşı skor farkıyla (DM ruhunda) sınavıp “kabul / belirsiz / ret” üç-bölgeli bir karar verir — “model en az kıyas kadar iyi mi?” sorusu, düzenleyici pratiğe geç/kal ikilisinden daha uygundur.

2.8.4 Berkowitz (2001) Testi: PIT Yaklaşımı

Amaç. Yalnızca kuyruğu (ihlalleri) değil, modelin *tüm öngörü dağılımının* doğruluğunu sınar.

Hipotezler. Model CDF'i $F_t(\cdot)$ doğruysa, olasılık integral dönüşümü (*Probability Integral Transform*, PIT) $u_t = F_t(L_t)$ i.i.d. $U[0, 1]$ 'dir; normal-skora dönüştürülmüş $x_t = \Phi^{-1}(u_t)$ ise i.i.d. $N(0, 1)$ olmalıdır. AR(1) alternatifi $x_t = \mu + \rho(x_{t-1} - \mu) + \varepsilon_t$, $\varepsilon_t \sim N(0, \sigma^2)$ altında:

$$H_0 : \mu = 0, \sigma^2 = 1, \rho = 0 \quad \text{karşı} \quad H_1 : \text{en az biri ihlal.} \quad (92)$$

Test istatistiği ve dağılımı. Kısıtlı (H_0) ve kısıtsız modelin olabilirlik-oranı:

$$LR_B = -2[\ell(0, 1, 0) - \ell(\hat{\mu}, \hat{\sigma}^2, \hat{\rho})] \xrightarrow{d} \chi^2(3) \quad (93)$$

(üç kısıt: konum, ölçek, bağımlılık).

Red kuralı. $LR_B > \chi_{3, 1-\tau}^2$ ($p < \tau$) ise H_0 reddedilir.

Yorum. Tek bir istatistikle kalibrasyonu (konum μ , ölçek σ^2) ve AR(1) bağımlılığı (ρ) birlikte değerlendirir. Kupiec/Christoffersen'in *kuyruk-odaklı* hipotezinden farklı bir *tüm-dağılım* hipotezi sınar; bu nedenle onları *kapsamaz, tamamlar* — kuyruğa özgü hatalar tüm-dağılım testinde maskelenebilir, tersi de mümkündür.

2.8.5 Model Karşılaştırma Testleri (DM, MCS, SPA)

Yukarıdaki testler *tek* bir modelin geçerliliğini (kalibrasyon, bağımsızlık) sınar; aşağıdaki testler ise *iki ya da daha çok modelin* öngörü doğruluğunu karşılaştırır. Kritik bir notasyon noktası: bu testler bir kayıp/skor fonksiyonu üzerinden çalışır ve VaR/ES bağlamında değerlendirilen “öngörü” skaler bir hata değil, *iki boyutlu* $(\text{VaR}_t, \text{ES}_t)$ ikilisidir; kullanılan kayıp ise §2.4'teki Fissler–Ziegel ortak skoru $S(\text{VaR}_t, \text{ES}_t, r_t)$ 'dir (kareli kayıp bir kantil için tutarlı olmadığından burada kullanılamaz).

(a) Diebold–Mariano (DM) testi. Genel öngörü değerlendirmesinde kayıp-fark serisi, iki modelin *skaler* öngörü hatalarına uygulanan tek-değişkenli bir kaybın (MSE, MAE) farkıdır. VaR/ES’de ise değerlendirilen nesne skaler bir hata değil ($\text{VaR}_{jt}, \text{ES}_{jt}$) ikilisi olduğundan, kayıp doğrudan FZ ortak skoru üzerinden yazılır:

$$d_t = S(\text{VaR}_{1t}, \text{ES}_{1t}, r_t) - S(\text{VaR}_{2t}, \text{ES}_{2t}, r_t). \quad (94)$$

Yani d_t , iki modelin *ortak skorları* arasındaki farktır; r_t gerçekleşen getiridir. Diebold and Mariano (1995) test istatistiği:

$$DM = \frac{\sqrt{T} \bar{d}}{\hat{\omega}_d} \xrightarrow{d} N(0, 1), \quad \bar{d} = \frac{1}{T} \sum_{t=1}^T d_t, \quad \hat{\omega}_d^2 = \widehat{\text{LRV}}(d_t), \quad (95)$$

burada $\bar{d}$ ortalama skor farkı, $\hat{\omega}_d^2$ ise d_t ’nin *uzun-dönem varyansının* HAC (Newey–West) tahminidir; $\hat{\omega}_d/\sqrt{T}$, $\bar{d}$ ’nin standart hatasıdır.

- $H_0 : \mathbb{E}[d_t] = 0$ (eşit öngörü performansı). $DM > 0$ ise model 1 daha *yüksek* skor, yani daha *kötü* performans üretmiştir; $DM < 0$ tersi.
- HAC düzeltmesi, d_t ardışık bağımlı olduğunda (ör. h -adım öngöründe $\text{MA}(h-1)$ yapısı) zorunludur; aksi hâlde standart hata küçük tahmin edilir ve test aşırı-red verir.
- Uygulamacı için: DM, “A modeli B’den istatistiksel olarak daha mı iyi?” sorusunu, ortalama skor farkının sıfırdan anlamlı sapıp sapmadığını sınavarak yanıtlar.

İkiliden Çokluya: Neden MCS/SPA?

DM yalnızca *ikili* karşılaştırma yapar. $J > 2$ model eşzamanlı karşılaştırıldığında çoklu test sorunu oluşur, nominal tip I hata oranı şişer ve “en iyi” modeli veriye bakarak seçmek (data snooping) sonucu yanıltıcıdır. Bu durumda tüm rakipleri birlikte ele alan MCS veya SPA testleri kullanılmaktadır.

(b) Model Confidence Set (MCS). Hansen et al. (2011), “en iyi” tek modeli seçmek yerine, verinin *istatistiksel olarak ayırt edemediği* en iyi modeller kümesini $\mathcal{M}_{1-\tau}^*$ döndürür. $\bar{d}_{mj}$, m ve j modellerinin ortalama skor farkı olsun.

1. Tüm J modelden oluşan küme $\mathcal{M}_0$ ile başla.
2. Eleme istatistiği $t_m = \bar{d}_m / \hat{\sigma}_m$, burada $\bar{d}_m = (J-1)^{-1} \sum_{j \neq m} \bar{d}_{mj}$ (model m ’nin diğerlerine ortalama göreli kötülüğü).
3. H_0 : kümedeki tüm modeller eşit performanslı — bootstrap ile p -değeri hesapla.
4. H_0 reddedilirse en kötü modeli ($\hat{m} = \arg \max_m t_m$) çıkar, kalanlarla tekrarla; reddedilemeyince dur.

Sonuç $\mathcal{M}_{1-\tau}^*$: $1 - \alpha$ güvenle en iyi modelleri içeren küme. Uygulamacı için değeri, birçok modelin yakın performans gösterdiği durumda tek bir “kazanan” dayatmak yerine hangi modellerin *gerçekten* ayrışamadığını göstermesidir.

(c) Superior Predictive Ability (SPA). Hansen (2005) SPA testi, belirli bir *referans* modelin (ör. mevcut üretim modeli) tüm rakiplerine karşı anlamlı biçimde üstün olup olmadığını sınar. Tek taraflı bir testtir ve data-snooping’e karşı bootstrap p -değeri kullanır. MCS *bir küme* döndürürken, SPA *tek bir referansı* tüm alternatiflere karşı değerlendirir — “mevcut modelimi bir rakip anlamlı biçimde geçiyor mu?” sorusuna uygundur.

Geriye Dönük Test Sınırları ve Çözümler

Temel kısıtlar:

- **Küçük örneklem:** 250 günlük Kupiec testi düşük güçlüdür; gerçek bir model hatasını yakalamak için çoğu zaman yeterli değildir.
- **Çoklu test sorunu:** Birçok model ve test istatistiği eş zamanlı kullanıldığında tip I hata oranı şişer.
- **Asimetrik kayıp:** Eksik tahmin ve aşırı tahmin farklı maliyetlere sahiptir; standart testler bunu yansıtmaz.

Çözüm önerileri:

- Uzun örneklem penceresi (500–1000 gün) kullanın.
- MCS ile kontrollü çoklu karşılaştırma yapın.
- FZ kayıp fonksiyonu ile düzenleyici skoru birlikte değerlendirin.
- Berkowitz PIT testi ile tüm dağılım geçerliliğini sınavın.

Geriye Dönük Test Sonuçlarının Yorumu

- $p < 0.05 \Rightarrow$ Model **reddedilir** (ihlaller çok sık veya kümeleme var).
- $p \geq 0.05 \Rightarrow H_0$ **reddedilemez** (ihlal oranı ve bağımsızlığı uygun).
- Kupiec testi geçen ancak Christoffersen testi kalan bir model, ihlal *kümelenmesi* sorunu yaşıyor demektir.

2.9 PELVE: VaR–ES Dönüştürme Köprüsü

Tanım 2.7 (PELVE (Li and Wang, 2023)). L pozitif kayıp değişkeni ve $\alpha \in (0, 1)$ üst-kuyruk olasılığı olsun. PELVE, kuyruk olasılığını genişleterek ES'yi başlangıç VaR düzeyine eşleyen çarpandır:

$$c_\alpha := \inf \{c \in [1, 1/\alpha) : ES_{c\alpha}(L) \leq VaR_\alpha(L)\}. \quad (96)$$

Düzenli ve tekil olmayan durumda bu tanım $ES_{c_\alpha\alpha}(L) = VaR_\alpha(L)$ eşitliğine indirgenir.

2.9.1 Ekonomik ve Finansal Yorum

PELVE, “ES'nin belirli bir düzeyde VaR'a göre ne kadar tutucu olduğunu” tek, boyutsuz ve konum-ölçek değişmez bir sayıyla ifade eder. Aynı α düzeyinde daima $ES_\alpha \geq VaR_\alpha$ olduğundan, ES'yi VaR seviyesine indirmek için kuyruk olasılığını α 'dan $c_\alpha\alpha$ 'ya genişletmek gerekir; c_α bu genişletme oranıdır. Finansal açıdan üç işlevi öne çıkar:

- **Düzenleyici geçiş köprüsü.** Basel III/FRTB ile piyasa riski sermaye ölçütü %99 VaR'dan ($VaR_{0.01}$) %97.5 ES'ye ($ES_{0.025}$) geçmiştir. PELVE, bir VaR-temelli sermaye gereksinimini eşdeğer bir ES-temelli gereksinime *çevirmenin* analitik aracıdır; kurumların geçişin sermaye üzerindeki etkisini nicelendirmesini sağlar.
- **Kuyruk-riski göstergesi.** PELVE kuyruk ağırlığıyla artar (aşağıda); yüksek tahmini PELVE, kalın kuyruk ve dolayısıyla ES-temelli sermayenin VaR-temelli sermayeden *belirgin biçimde* daha yüksek olacağı uyarısını verir — sermaye yeterliliği açısından doğrudan bir sinyal.

- **Model karşılaştırması.** Farklı modellerin ima ettiği kuyruk davranışı, ortak ve ölçekten bağımsız tek bir sayı üzerinden kıyaslanabilir.

2.9.2 Matematiksel Özellikler

Sınırlar. Tanım gereği $1 \leq c_\alpha < 1/\alpha$. Alt sınır $c_\alpha \geq 1$, ES'nin VaR eşliğini aşan kayıpların ortalaması olması ($ES_\alpha \geq VaR_\alpha$) nedeniyle zorunludur; üst sınır $c_\alpha < 1/\alpha$ ise $c_\alpha \alpha < 1$ olarak geçerli bir kuyruk olasılığı sağlar.

Kuyruk indeksiyle asimptotik ilişki. L , uç-değer indeksi ξ olan bir çekim-alanında (max-domain of attraction) ise:

$$\lim_{\alpha \rightarrow 0} c_\alpha = \begin{cases} (1 - \xi)^{-1/\xi}, & \xi \in (0, 1) \quad (\text{ağır kuyruk}), \\ e \approx 2.718, & \xi = 0 \quad (\text{ince/normal kuyruk}). \end{cases} \quad (97)$$

Bu limit ξ 'de *artandır*: normal ($\xi = 0$) için e , Student- t_5 ($\xi = 0.2$) için $(0.8)^{-5} \approx 3.05$, t_3 ($\xi = 1/3$) için $(2/3)^{-3} = 3.375$. Dolayısıyla $c_\alpha > e$ kalın kuyruğa işaret eder; $\xi \geq 1$ durumunda ES sonsuz olduğundan PELVE tanımsızdır.

Sonlu düzey referansları. Yakınsama yavaşır: normal dağılımda $\alpha = 0.05$ için $c_\alpha \approx 2.510$, $\alpha = 0.01$ için $c_\alpha \approx 2.577$ olup her ikisi de asimptotik e 'nin altındadır.

2.9.3 Basel FRTB Eşleşmesi ve $c = 2.5$

FRTB'nin %99 VaR'dan %97.5 ES'ye geçişinde örtük kuyruk-olasılığı genişletme oranı $0.025/0.01 = 2.5$ 'tur. Bunun *tam* bir PELVE eşdeğerliği ($ES_{0.025} = VaR_{0.01}$) olması için $c_{0.01} = 2.5$ gerekirdi; oysa normal dağılımda $c_{0.01} \approx 2.577 > 2.5$ 'tur. Bu nedenle normal koşulda %97.5 ES, %99 VaR'dan bir miktar daha tutucudur (2.338σ 'ya karşı 2.326σ). Kuyruk kalınlaştıkça (ξ arttıkça) $c_{0.01}$ büyür ve bu fark açılır: ES'ye geçiş, VaR'ın en yetersiz kaldığı kalın-kuyruklu portföylerde bilinçli olarak *daha fazla* kuyruk riskini sermayeleştirir. Basel'in 2.5'i pratik bir yuvarlak değerdir; gerçek $VaR \leftrightarrow ES$ eşdeğerliği ise kuyruğa bağlıdır.

Örnek 2.1 (Sermaye Tabanlı Örnek: VaR'dan ES'ye Geçiş). 100 milyon TL değerinde, günlük oynaklığı $\sigma = \%2$ (yani 2 milyon TL) olan bir portföy düşünelim. Basel II'de %99 VaR, FRTB'de ise %97.5 ES sermaye ölçütüdür.

İnce kuyruk (Normal). $VaR_{0.01} = 2.326\sigma = 4.65$ milyon TL ve $ES_{0.025} = 2.338\sigma = 4.68$ milyon TL neredeyse eşittir (fark yalnızca %0.5); tahmini PELVE $c_{0.01} \approx 2.58$, Basel'in varsaydığı 2.5'e yakındır. Bu koşulda ES'ye geçiş sermayeyi kayda değer biçimde değiştirmez.

Kalın kuyruk (Student- t_5). Aynı σ ile $VaR_{0.01} = 2.606\sigma = 5.21$ milyon TL, ama $ES_{0.025} = 2.728\sigma = 5.46$ milyon TL. Şimdi %97.5 ES, %99 VaR'dan %4.7 *daha yüksek* sermaye gerektirir ve PELVE $c_{0.01} \approx 2.93$ 'e (2.5'in belirgin üstüne) çıkar.

Çıkarım. PELVE iki rejim arasındaki farkı tek sayıyla özetler: normalde VaR ve ES sermayesi örtüşür, kuyruk kalınlaştıkça ES-temelli sermaye VaR-temelliye giderek aşar. FRTB'nin ES'ye geçişinin amacı tam da budur — VaR'ın körleştirdiği kuyruk şiddetini sermayeye yansıtmak. Risk yöneticisi için yüksek tahmini PELVE, ES'ye geçişin sermaye yükünü artıracağının erken sinyalıdır.

PELVE'nin Deneysel Tahmin Algoritması

1. Hedefi $VaR_\alpha(L) = \widehat{Q}_{1-\alpha}(L)$ olarak hesapla.
2. $c \in [1, 1/\alpha)$ için üst-kuyruk olasılığını $u = c\alpha$ olarak kur.

3. Her c için $ES_u(L)$ 'yi, yani $1 - u$ kantilini aşan kayıpların ortalamasını hesapla.
4. $ES_{c\alpha}(L) - VaR_\alpha(L) = 0$ kökünü bisection/Brent yöntemiyle bul.

2.10 Sistemik Risk Ölçütleri

Bireysel kurumların risk ölçütleri, sistemik riski — yani bir kurumun başarısızlığının tüm finansal sistemi etkileme kapasitesini — tam olarak yansıtmaz. 2008 Krizi sonrasında gelişen makroihtiyati (macroprudential) gözetim çerçevesi, bu açığı kapatmak amacıyla aşağıdaki ölçütleri önermiştir.

2.10.1 CoVaR (Adrian ve Brunnermeier, 2016)

Tanım 2.8 (CoVaR). X_j kurum j 'nin durum değişkeni olsun. Kurum i 'nin koşullu kantil fonksiyonunu

$$\text{CoVaR}_q^{i|j}(x) := Q_q(r_i | X_j = x) \quad (98)$$

olarak tanımlayalım. Stres CoVaR'ı bu koşullu kantil fonksiyonunun $x = Q_q(X_j)$ noktasında değerlendirilmesidir. Bu yazım, sürekli değişkende sıfır olasılıklı $X_j = Q_q(X_j)$ olayına sıradan koşullama yapma sorununu önler.

Sistemik risk katkısı, koşullu kantil fonksiyonunun stres ve medyan durumlarında aldığı değerlerin farkıdır:

$$\Delta \text{CoVaR}_q^{i|j} = \text{CoVaR}_q^{i|j}(Q_q(X_j)) - \text{CoVaR}_q^{i|j}(Q_{0.5}(X_j)). \quad (99)$$

Böylece fark yalnızca kurum j 'nin durum değişkeninin medyandan stres kantiline hareketine atfedilen koşullu risk değişimini ölçer.

Tahmin yöntemi: Quantile (kantil) regresyon. r_i 'yi r_j 'ye koşullu kantil regresyonu ile tahmin edilir; GARCH ile zamana değişen varyans hesaba katılır.

2.10.2 MES (Marginal Expected Shortfall)

Tanım 2.9 (MES — Acharya vd. (2017)). $L_i = -r_i$ kurum kaybı ve $L_m = -r_m$ piyasa kaybı olsun. Pozitif kayıp konvansiyonunda marjinal beklenen kayıp

$$\text{MES}_{i,\alpha}^L = \mathbb{E}[L_i | L_m > VaR_\alpha(L_m)] = -\mathbb{E}[r_i | r_m < Q_\alpha(r_m)] \quad (100)$$

şeklinde. Getiri konvansiyonundaki koşullu beklenti tipik olarak negatiftir; “beklenen kayıp” olarak raporlanırken işaret çevrilmelidir.

MES, SRISK (Systemic Risk) hesabında temel bileşendir:

$$\text{SRISK}_i = \max\{0, \theta D_i - (1 - \theta)W_i(1 - \text{LRMES}_i)\}. \quad (101)$$

Burada θ ihtiyati sermaye oranı, D_i borç, W_i özkaynağın piyasa değeri ve LRMES_i sistemik olay ufkundaki beklenen özkaynak kayıp oranıdır.

Not 2.10 (LRMES ile MES Aynı Şey mi?). Hayır. *LR*, “Long Run” (uzun dönem) demektir; LRMES, MES'in çok-dönemli ve kriz-senaryosu uzantısıdır. MES (100) *günlük* bir ölçüttür: piyasanın kötü (kuyruk) bir gününde kurumun beklenen günlük kaybını verir. LRMES ise kurum özkaynağının *uzun bir ufukta* (tipik olarak 6 ay) ve *sistemik bir çöküş* koşuluyla (ör. piyasanın altı ayda %40 düşmesi) beklenen *kümülatif yüzdesel değer kaybıdır*; dolayısıyla $\text{LRMES}_i \in [0, 1]$ bir kayıp *oranıdır*, MES ise günlük bir

kayıp *düzeyidir*. LRMES ya iki-değişkenli GARCH–DCC dinamiğinin ufuk boyunca simülasyonu, ya da günlük MES’ten yaklaşık olarak

$$\text{LRMES}_i \approx 1 - \exp(-18 \cdot \text{MES}_i) \quad (102)$$

biçiminde elde edilir; buradaki ≈ 18 katsayısı, altı aylık %40’lık bir düşüşü günlük dinamiğe bağlayan ampirik bir ölçeklemedir (V-Lab; Brownlees and Engle 2017). SRISK’in MES yerine LRMES kullanması, sermaye açığının tek bir günde değil çok-dönemli bir kriz boyunca değerlendirilmesi gerektiğindendir.

Not 2.11. CoVaR ve MES, Türkiye Cumhuriyeti Merkez Bankası ve BDDK gibi düzenleyici kurumların makroihtiyati analizlerinde kullanılmaktadır. Bu ölçütler, hangi kurumların sistemik açıdan kritik olduğunu (too-big-to-fail) belirlemede yardımcı olur.

Sistemik Ölçütlerin Ekonomik ve Yatırım Anlamı

VaR ve ES tek bir portföyün *kendi başına* riskini ölçerken, sistemik ölçütler *ilişkiseldir*: bir kurumun sistemle birlikte nasıl hareket ettiğini — yani kuyruk bağımlılığını ve yayılma (spillover) etkisini — niceler. Bu ikisi tamamlayıcı iki soruyu yanıtlar: CoVaR bir kurumun sistemin riskine *katkısını* (kurum streteyken sistemin VaR’ı ne kadar artıyor?), MES ise kurumun sistemik riske *maruziyetini* (sistem kötüyken kurum ne kadar kaybediyor?) ölçer. Ekonomik ve yatırım açısından üç kullanım öne çıkar:

- **Düzenleyici / makroihtiyati:** Sistemik açıdan önemli kurumların (SIFI, “too-big-to-fail”) belirlenmesi ve bunlara ek sermaye tamponu getirilmesi. Kurumlar arası toplulaştırılan SRISK, sistemin toplam sermaye açığının bir erken-uyarı göstergesidir.
- **Portföy inşası:** Yüksek MES / kuyruk-betası olan varlıklar krizlerde birlikte çöker. Bu *sistemik kuyruk riski* çeşitlendirmeye giderilemez; dolayısıyla varlık tahsisi ve riskten korunma (hedging) kararlarında — özellikle kuyruk-bağımlılığı yüksek pozisyonların sınırlandırılmasında — doğrudan kullanılır.
- **Getiri-risk ödünleşimi:** Yüksek sistemik-riskli varlıklar normal dönemlerde daha yüksek getiri sunabilir, ancak kayıplarını tam da çeşitlendirmenin işe yaramadığı kriz dönemlerinde yoğunlaştırır. Bu, kuyrukta gizlenmiş bir risk primidir: ortalama getiri cazip görünse de, kriz-koşullu kayıp (MES/LRMES) gerçek maliyeti açığa çıkarır.

2.11 Uygulama: Risk Paneli ve Model Karşılaştırması

Kontrollü Simülasyonda Genişletilmiş Risk Paneli

Bu uygulama, ADCC+kriz+Student- $t(\nu = 7)$ DGP’sinden üretilen kontrollü simülasyon veri kümesinin ($N = 8$ sektör endeksi, $T = 1500$ iş günü; tohum 20260729) getirileri üzerinde 15 model ve 6 kombinasyon yöntemini karşılaştırır.

Protokol (app ile birebir): İlk $W = 500$ gün eğitim; $n_{\text{OOS}} = 1000$ gün örneklem-dışı değerlendirme. Temel (kayan-pencere) modeller son 250 gün üzerinden yeniden kalibre edilir; GARCH ailesi tüm seri üzerinde filtrelendir; yarı-parametrik (SP) modeller $W = 500$ eğitim bölümünde optimize edilir. Düzeyler: $\alpha = 0.01$ ve 0.05 . Tüm istatistikler 8 varlık üzerinde ortalananır.

2.11.1 Adım 1: VaR ve ES Tahminleri

Tablo 17, 15 modelin $n_{\text{OOS}} = 1000$ gün ortalaması VaR(%) ve ES(%) değerlerini gösterir (kayıp konvansiyonu; pozitif).

Tablo 17: Kontrollü simülasyon: ortalama VaR ve ES tahminleri (% , $n_{\text{OOS}} = 1000$, 8 varlık ortalaması).

Grup	Model	$\alpha = 0.01$ (%99)		$\alpha = 0.05$ (%95)	
		VaR	ES	VaR	ES
Temel	Normal	3.92	4.49	2.76	3.47
	Student- t	4.39	5.82	2.62	3.77
	Tarihsel Sim.	4.99	6.33	2.62	4.15
	Cornish-Fisher	5.68	7.68	2.94	4.68
GARCH	GARCH-Normal	3.69	4.23	2.61	3.27
	GARCH- t	3.94	4.94	2.44	3.35
	GJR-N	3.62	4.13	2.54	3.17
	EGARCH- t	3.92	4.91	2.43	3.33
	GARCH-FHS	3.73	4.81	2.45	3.37
	GJR-FHS	3.70	4.85	2.46	3.40
SP	FZ-GAS [†]	4.24	5.02	2.63	3.51
	FZ-GARCH-N	3.84	4.40	2.45	3.08
	FZ-GARCH- t	3.80	4.49	2.37	3.28
	CaViaR-AsL (basit)	3.79	4.73	2.32	3.25
	CaViaR-AsL (din.)	3.79	5.05	2.32	3.20

[†] $\alpha = 0.05$: 6/8 varlık; $\alpha = 0.01$: 5/8 varlık (GAYRIM ve PERAK yakınsama sorunu; PERAK $\alpha = 0.01$ 'de de hariç).

Üç belirgin örüntü öne çıkar. *Birincisi*, statik temel modeller GARCH ailesine kıyasla daha yüksek ortalama VaR ve ES üretir; çünkü kayan pencere krizdeki kayıpları diğer dönemlere de taşır. *İkincisi*, Cornish-Fisher, düzeltilmiş Kuyruk İntegrali ES formülüyle $\alpha = 0.01$ 'de %7.68 ile Tarihsel Sim. (%6.33) ve Student- t (%5.82)'ı bile geçen en temkinli ES tahminini üretir; çarpıklık-basıklık düzeltmesi kalın kuyruğu güçlü şekilde etkiler. *Üçüncüsü*, FZ-GAS ve FZ-GARCH modelleri ES'i dinamik-oyunaklık GARCH modellerinden daha temkinli kestirirken CaViaR ailesi VaR'ı agresif biçimde aşağı iter.

2.11.2 Adım 2: Geriye Dönük Test Sonuçları

Tablo 18, 8 varlıkta %5 anlamlılıkta reddedilen varlık sayısını ve ortalama ihlal oranını gösterir ($\alpha = 0.05$, $n_{\text{OOS}} = 1000$). Sekiz test iki sütun grubuna bölünür: VaR testleri (Kupiec, Christoffersen, DQ) ve ES/ortak testler (Acerbi-Sz. Z1, AS-Z2, McNeil-Frey, Nolde-Ziegel).

Tablo 18: Geriye dönük test: 8 varlıkta %5 düzeyinde reddedilen varlık sayısı ($n/8$) ve ortalama ihlal oranı (%); $\alpha = 0.05$, $n_{\text{OOS}} = 1000$.

Grup	Model	VaR testleri			ES / ortak testler				İhl.%
		Kup.	Chris.	DQ	AS-Z1	AS-Z2	MF	NZ	
Temel	Normal	0/8	8/8	8/8	8/8	5/8	8/8	8/8	4.65
	Student- t	0/8	8/8	8/8	8/8	3/8	8/8	0/8	5.15
	Tar. Sim.	0/8	8/8	8/8	8/8	0/8	2/8	0/8	5.06
	Cornish-F.	0/8	8/8	8/8	8/8	0/8	2/8	0/8	4.49
GARCH	GARCH-N	0/8	8/8	3/8	8/8	1/8	8/8	5/8	4.68
	GARCH- t	0/8	8/8	3/8	3/8	2/8	1/8	0/8	5.58
	GJR-N	0/8	8/8	3/8	8/8	1/8	8/8	4/8	5.04
	EGARCH- t	0/8	8/8	4/8	5/8	3/8	1/8	0/8	5.61
	GARCH-FHS	3/8	8/8	4/8	5/8	2/8	4/8	3/8	5.58
	GJR-FHS	3/8	8/8	4/8	4/8	2/8	2/8	3/8	5.55
SP	FZ-GAS [†]	1/6	6/6	3/6	5/6	0/6	3/6	2/6	4.62
	FZ-GARCH-N	3/8	8/8	7/8	8/8	4/8	8/8	7/8	5.73
	FZ-GARCH- t	3/8	8/8	7/8	6/8	3/8	4/8	4/8	6.25
	CaViaR-AsL (b.)	5/8	8/8	8/8	6/8	6/8	6/8	7/8	6.56
	CaViaR-AsL (d.)	5/8	8/8	8/8	7/8	6/8	5/8	7/8	6.56

Kup.=Kupiec; Chris.=Christoffersen; DQ=Dinamik Kantil ($p = 4$); AS-Z1/Z2=Acerbi-Székely; MF=McNeil-Frey; NZ=Nolde-Ziegel. [†] 6/8 varlık (yakınsama kısıtı).

Üç temel bulgu öne çıkar. (i) *Bağımsızlık sorunu evrenseldir*: Christoffersen testi *tüm* modellerde *tüm* 8 varlıkta reddedilir (8/8); DGP'nin kriz penceresi (gün 555–590) ihlalleri kümeleyerek bağımsızlık varsayımını çiğner ve bu etki kayan-pencere dahil hiçbir model tarafından tam giderilemez. (ii) *Kapsama (Kupiec) aygımlaşır*: Normal/Student- t /Tarihsel/Cornish-Fisher ve tüm saf GARCH- t /EGARCH- t modelleri kapsama testinden geçer (0/8); buna karşın CaViaR modelleri 5/8 reddedilir (ortalama ihlal %6.56 $\gg$ %5). (iii) *ES kalitesi test bazı ayırır*: Tarihsel Sim., Student- t , Cornish-Fisher, GARCH- t ve EGARCH- t Nolde-Ziegel ortak kalibrasyon testinden geçer (0/8); düzeltilmiş Kuyruk-İntegrali ES formülü sayesinde Cornish-Fisher artık Tarihsel Sim. ile eşdeğer bir ES kalibrasyon profiline sahiptir. Normal ise ES'i küçümsediği için reddedilir (8/8).

DQ testinin yüksek reddi

FZ-GARCH modelleri DQ testinde 7/8 reddedilir; bu, koşullu VaR öngörülerinin gecikmeli hit serisiyle güçlü ilişki içinde olduğuna işaret eder. FZ-GAS benzer kalıba sahipken DQ reddi daha düşüktür (3/6) — score-driven güncellenmenin gecikmeli dinamiği daha iyi özümlediğinin göstergesi.

2.11.3 Adım 3: Öngörü Kombinasyonu ve Model Karşılaştırması

Tablo 19, Fissler-Ziegel/AL beceri skorunu gösterir (Tarihsel Sim. referansa göre %; 8 varlık ort., $n_{\text{eval}} = 750$; *yüksek = daha iyi*). Kombine havuz: Normal, Student- t , Cornish-Fisher, GARCH-Normal, GARCH-FHS, GJR-FHS, FZ-GARCH-N, FZ-GARCH- t , CaViaR-AsL (din.) (9 model; $\alpha = 0.01$ 'de CaViaR hariç, 8 model). Kombinasyon ağırlıkları ilk $W_c = 250$ OOS gözlemi üzerinde kestirilmiş; beceri skorları yalnızca $t = 251, \dots, 1000$ değerlendirme alt-örnekleminde ($n_{\text{eval}} = 750$) hesaplanmıştır — bireysel ve kombine modeller dahil. Kalibrasyon ve değerlendirme örneklemeleri örtüşmez. **Önemli**: bu ayırım sızıntıyı giderir, fakat DGP'nin kriz penceresini değerlendirme dışında bırakır; tablo bu nedenle bir *sakin dönem* karşılaştırmasıdır (bkz. aşağıdaki uyarı kutusu).

Tablo 19: Fissler-Ziegel / AL beceri skoru (% , Tarihsel Sim. referansına göre; 8 varlık ort., $n_{\text{eval}} = 750$, değerlendirme: $t = 251-1000$).

Tür	Yöntem / Model	$\alpha = 0.01$	$\alpha = 0.05$
Seçili bireysel	Normal	+1.4	+0.4
	Student- t	+3.7	+0.7
	Tarihsel Sim.	0.0 (ref)	0.0 (ref)
	GARCH- t	+8.7	+4.2
	EGARCH- t	+8.6	+4.1
	GARCH-FHS	+8.8	+3.8
	FZ-GAS [†]	+2.9 [†]	+2.3
	FZ-GARCH- t	+3.0	+2.2
	CaViaR-AsL (d.)	n.a. [‡]	-1.3
Kombinasyon	Basit ortalama	+6.7	+3.1
	Medyan	+7.7	+3.8
	Maksimum	+0.1	-1.0
	Minimum	-2.6	-1.4
	Min-skor (Taylor)	+7.8	+3.4
	Görelî-skor (Taylor)	+8.7	+3.9

[†] FZ-GAS: $\alpha = 0.05$ 'te 6/8, $\alpha = 0.01$ 'de 5/8 varlık (GAYRIM/PERAK yakınsama sorunu); farklı panel, diğer satırlarla doğrudan sıralanamaz. [‡] CaViaR-AsL (d.) $\alpha = 0.01$: FZ kaybı ihlal taşıması nedeniyle uç; tablo dışı.

Dört önemli bulgu özetlenebilir. (i) *GARCH üstünlüğü — sakin dönemde*: Tüm dinamik-oyunluk modelleri (GARCH- t , EGARCH- t , GARCH-FHS, GJR-FHS) Tarihsel Sim. referansını değerlendirme alt-örnekleminde ($n_{\text{eval}} = 750$) $\alpha = 0.05$ 'te yaklaşık %4 geçer; bu fark $\alpha = 0.01$ 'de %8–%9'a çıkar. Bu rakamlar kriz epizodunu *içermez*; kriz dahil edildiğinde üstünlük yaklaşık üç katına çıkar (aşağıdaki kutu). (ii) *SP modellerin konumu*: FZ-GAS, $\alpha = 0.05$ 'te GARCH ailesinin belirgin gerisinde kalır (+%2.3, 6 varlık); $\alpha = 0.01$ 'de 5-varlık alt panelinde +%2.9 ile GARCH modellerinin altındadır (farklı panel, dikkatli yorumlanmalı). (iii) *Kombinasyon avantajı*: $\alpha = 0.01$ 'de Görelî-skor (+%8.7) en iyi bireysel model GARCH-FHS (+%8.8) ile hemen hemen eşit güçtedir; $\alpha = 0.05$ 'te ise Görelî-skor (+%3.9) en iyi bireysel GARCH- t (+%4.2)'nin gerisinde kalır. Minimum kombinasyon değerlendirme alt-örnekleminde de olumsuz beceri üretir ($\alpha = 0.05$: -%1.4; $\alpha = 0.01$: -%2.6). (iv) *Medyan ve Görelî-skorun dayanıklılığı*: $\alpha = 0.05$ 'te Medyan (+%3.8) ve Görelî-skor (+%3.9) Basit ortalama (+%3.1)'yî aşar; $\alpha = 0.01$ 'de sıralama korunur (+%7.7 ve +%8.7 vs +%6.7).

Değerlendirme penceresi kriz epizodunu dışlar

Kalibrasyon/değerlendirme ayrımı sızıntıyı giderir; ancak bu veri setinde belirleyici bir yan etkisi vardır. Örneklem-dışı blok mutlak indeks 500'de başlar, DGP'nin tasarlanmış kriz penceresi ise 555–590 günleridir — yani OOS koordinatında 55–90. Kalibrasyon bloğu OOS 0–249 olduğuna göre **kriz epizodu bütünüyle kalibrasyon bloğunda kalır** ve değerlendirme alt-örnekleminde hiç görünmez. Tablo 19 bu nedenle bir *sakin dönem* model karşılaştırmasıdır. Etkinin büyüklüğü bireysel modellerde doğrudan okunabilir: bu satırlar ağırlık kestirimi içermediğinden iki pencere arasında birebir karşılaştırılabilir (aynı öngörüler, yalnızca değerlendirme dilimi farklı).

Model	$\alpha = 0.01$		$\alpha = 0.05$	
	kriz dahil ($n=1000$)	kriz hariç ($n=750$)	kriz dahil ($n=1000$)	kriz hariç ($n=750$)
Normal	-17.0	+1.4	-1.0	+0.4
Student- t	-1.5	+3.7	-0.1	+0.7
GARCH- t	+27.4	+8.7	+10.3	+4.2
EGARCH- t	+26.9	+8.6	+10.0	+4.1
GARCH-FHS	+26.0	+8.8	+10.0	+3.8

İki okuma çıkar. Birincisi: GARCH ailesinin Tarihsel Simülasyon karşısındaki üstünlüğünün büyük bölümü *kriz epizodunda* kazanılır; sakin dönemde üstünlük yaklaşık üçte bire iner. İkincisi ve daha çarpıcısı: Normal dağılım varsayımı kriz dahil edildiğinde ağır biçimde cezalandırılırken ($-\%17.0$) sakin dönemde hafifçe olumlu görünür ($+\%1.4$). Normal'in başarısızlığı bir *kuyruk olayı* başarısızlığıdır ve ortalama bir dönemde görünmez — risk modeli seçimini sakin dönem performansına bakarak yapmanın tehlikesi tam olarak budur.

Bu bulgu, Bölüm 1'in dinamik kovaryans sonucuyla aynı yöndedir: dinamik modellerin değeri stres dönemlerinde üretilir. Kriz içeren bir *kombinasyon* değerlendirmesi isteniyorsa ağırlıklar örneklem-dışı bloktan önceki bir eğitim bölmesinde kestirilmeli ya da genişleyen pencereyle güncellenmelidir; her iki tasarımda da 1000 gözlemin tamamı değerlendirmede kahr.

Not 2.12 (Örneklem farkı: bu alt bölümdeki tablolar aynı dönemi ölçmez). Tablo 17 (ortalama VaR/ES) ve Tablo 18 (geriye dönük test) tam örneklem-dışı blokta hesaplanmıştır ($n_{\text{OOS}} = 1000$, kriz dahil). Tablo 19 (beceri skoru) ise değerlendirme alt-örnekleminde ($n_{\text{eval}} = 750$, kriz hariç). Satırlar her tablonun kendi içinde karşılaştırılabilir; tablolar arasında doğrudan karşılaştırma yapılmamalıdır. Özellikle §2.11'daki Christoffersen bulgusu (kriz penceresinin ihlalleri kümelemesi) tam örneklemde geçerlidir ve beceri skoru tablosuyla aynı dönemi paylaşmaz.

Dürüst nüans: kombinasyon avantajı sınırlı ve değerlendirme dönemine özgüdür

Görelî-skor ve Min-skor kombinasyonu, değerlendirme alt-örnekleminde ($n_{\text{eval}} = 750$) en iyi bireysel modellerle tek seride zayıf anlamlılıkla rekabet eder ya da geride kalır ($|t_{\text{DM}}| < 1.0$); avantaj, çok sayıda seri üzerinde ortalandığında ancak $\alpha = 0.01$ 'de gözlemlenebilir hale gelir. Tam Model Güven Kümesi (Hansen et al., 2011) analizi app'te mevcuttur.

2.11.4 Adım 4: Python Kodu — Modüler Risk Paneli

Python: 15-Model Risk Paneli

```

1 import numpy as np, pandas as pd
2 from risk_metrics import (calculate_var_es,
3                             calculate_cornish_fisher_var,
4                             fessler_ziegel_loss, backtest_var,
5                             backtest_es_acerbi_szekely, dq_test,
6                             mcneil_frey_test,
7                             nz_conditional_calibration,
8                             min_score_combine, relative_score_combine
9                             )

```

```

7 from sp_estimators import compute_garch_universe,
  compute_sp_estimators
8 from scipy.stats import norm, skew, kurtosis
9
10 # --- 1. Veri ---
11 df = pd.read_csv("data/sample_returns.csv", index_col=0,
  parse_dates=True)
12 returns = df["BANKA"].values[:1500] # ornek: tek
  varlik
13 alpha, n_oos = 0.05, 1000
14 start_idx = len(returns) - n_oos # 500
15
16 # --- 2. Temel modeller (kayan pencere 250 gun) ---
17 TRAIN_WIN = 250
18 LABELS = ["Normal", "Student-t", "Hist.Sim.", "CF"]
19 n_mono_fix = 0 # CF monotonluk
  ihlali sayaci
20 var_base = {m: [] for m in LABELS}
21 es_base = {m: [] for m in LABELS}
22 for i in range(n_oos):
23     cur = start_idx + i; lo = max(0, cur - TRAIN_WIN)
24     rw = returns[lo:cur]
25     for lbl, meth in [("Normal", "parametric_normal"),
26                       ("Student-t", "parametric_student_t"),
27                       ("Hist.Sim.", "historical")]:
28         v, e = calculate_var_es(rw, alpha, meth)
29         var_base[lbl].append(v); es_base[lbl].append(e)
30     # CF: VaR Cornish-Fisher kivantiyle, ES ust kuyruk integraliyle
31     # ES_alpha = (1/alpha) * integral_0^alpha F_L^{-1}(1-u) du
32     us = np.linspace(1e-6, alpha, 500)
33     zus = norm.ppf(1 - us) # ust kuyruk: F^{-1}(1-u), not
  F^{-1}(u)
34     losses = -rw; mu, sig = losses.mean(), losses.std(ddof=1)
35     S, K = skew(losses), kurtosis(losses, fisher=True)
36     z_cf = zus + (1/6)*(zus**2-1)*S + (1/24)*(zus**3-3*zus)*K \
37         - (1/36)*(2*zus**3-5*zus)*S**2
38     q_cf = mu + sig*z_cf # pozitif kayip kantilleri, u'
  nun fonksiyonu
39
40 # MONOTONLUK DENETIMI. u arttikca p=1-u azalir, dolayisiyla
  kayip
41 # kantili q_cf AZALAN olmalidir. CF acilimi bazi (S,K)
  bolgelerinde bunu
42 # ihlal eder; ham egrinin integrali gecerli bir ES vermez.
43 if np.any(np.diff(q_cf) > 0):
44     n_mono_fix += 1
45     q_cf = np.sort(q_cf)[::-1] # monoton yeniden duzenleme (

```

```

rearrangement)
46
47     cf_v = float(q_cf[-1])          # u=alpha noktası -> VaR_alpha
48     cf_e = float(np.trapz(q_cf, us) / alpha)
49     assert np.all(np.diff(q_cf) <= 1e-10)
50     assert cf_e >= cf_v - 1e-10      # pozitif kayıp olceğinde ES
        >= VaR
51     var_base["CF"].append(cf_v); es_base["CF"].append(cf_e)
52
53 # --- 3. GARCH ailesi (5+1 model; tek cagri) ---
54 garch_models = compute_garch_universe(returns, alpha, n_oos)
55 # Donus: {"GARCH-t": (var_oos, es_oos), "GJR-N": ..., ...}
56
57 # --- 4. SP modeller (FZ-GAS, FZ-GARCH, CaViaR) ---
58 sp_models = compute_sp_estimators(returns, alpha, n_oos, start_idx)
59 # Donus: {"FZ-GAS": (...), "FZ-GARCH-N": (...), "FZ-GARCH-t": (...),
        ,
60 #         "CaViaR-AsL(simple)": (...), "CaViaR-AsL(dyn)": (...)}
61
62 # --- 5. Geriye donuk testler (ornek: Tarihsel Sim.) ---
63 r_oos = returns[-n_oos:]
64 v_hs = np.array(var_base["Hist.Sim."]); e_hs = np.array(es_base["
    Hist.Sim."])
65 bt     = backtest_var(r_oos, v_hs, alpha)          #
        Kupiec + Christoffersen
66 es_bt = backtest_es_acerbi_szekely(r_oos, v_hs, e_hs, alpha) # AS-
        Z1/Z2
67 dq     = dq_test(r_oos, v_hs, alpha)              #
        Dinamik Kantil (p=4)
68 mf     = mcneil_frey_test(r_oos, v_hs, e_hs, alpha) #
        McNeil-Frey
69 nz     = nz_conditional_calibration(r_oos, v_hs, e_hs, alpha) #
        Nolde-Ziegel
70
71 # --- 6. Kombinasyon (9 model havuzu) ---
72 # Kalibrasyon: ilk W_c=250 OOS gozlemi (ayrisik ornekleme)
73 # Degerlendirme: t=251..1000 (n_eval=750); kalibrasyon ile
        ortusmuyor.
74 # Bireysel modeller de AYNI eval_slice uzerinde degerlendiriliyor.
75 W_c = 250
76 eval_slice = slice(W_c, n_oos)          # t=251..1000, n_eval=750
77 # Havuz sozlugu: model adi -> (VaR dizisi, ES dizisi)
78 SRC = {m: (np.array(var_base[m]), np.array(es_base[m])) for m in
        var_base}
79 SRC.update(garch_models)                # {"GARCH-Normal": (var, es), ...}
80 SRC.update(sp_models)                   # {"FZ-GARCH-N": (var, es), ...}
81 POOL9 = ["Normal", "Student-t", "CF", "GARCH-Normal",

```



```

82         "GARCH-FHS", "GJR-FHS", "FZ-GARCH-N", "FZ-GARCH-t",
83         "CaViaR-AsL(dyn)"]                                     # alpha=0.01'de
                        CaViaR haric
84 Vm = np.column_stack([SRC[m][0] for m in POOL9])              # (n_oos x 9)
                        VaR matrisi
85 Em = np.column_stack([SRC[m][1] for m in POOL9])              # (n_oos x 9) ES
                        matrisi
86 r_cal, V_cal, E_cal = r_oos[:W_c], Vm[:W_c], Em[:W_c]
87 # Agirlik tahmini -> YALNIZCA kalibrasyon alt-ornekleminde
88 _, _, wQ, wS = min_score_combine(r_cal, V_cal, E_cal, alpha)
89 _, _, w, lam = relative_score_combine(r_cal, V_cal, E_cal, alpha)
90 # Statik agirlik uygulaması -> YALNIZCA degerlendirme alt-
                        ornekleminde
91 Vm_ev = Vm[eval_slice]; Em_ev = Em[eval_slice]               # (750 x 9)
92 Qm_ev = -Vm_ev; ESm_ev = -Em_ev
93 v_min = -(Qm_ev @ wQ)
94 e_min = -(np.minimum(Qm_ev@wQ + (ESm_ev-Qm_ev)@wS, Qm_ev@wQ - 1e-9)
95 )
96 v_rel = Vm_ev @ w; e_rel = np.maximum(Em_ev @ w, v_rel + 1e-9)
97 # Beceri skoru referansi da ayni dilimde
98 r_eval = r_oos[eval_slice]
99 print(f"Min-skor agirliklari: {wQ.round(3)}")

```

Not 2.13. Tüm sayılar `data/sample_returns.csv` üzerinde `SEED=20260729`, $T = 1500$, $W = 500$, $n_{\text{OOS}} = 1000$ protokolüyle üretilmiştir. Cornish-Fisher ES, üst-kuyruk integrali formülüyle ($ES_\alpha = \frac{1}{\alpha} \int_0^\alpha F_L^{-1}(1-u) du$) hesaplanmıştır; kantil yolu integrasyondan önce monotonluk denetiminden geçirilir (bkz. §2.11 kodu). Kombinasyon ağırlıkları ilk $W_c = 250$ OOS gözlemi üzerinde kestirilmiştir; tablo beceri skorları yalnızca $t = 251, \dots, 1000$ değerlendirme alt-örnekleminde ($n_{\text{eval}} = 750$) hesaplanmıştır — bireysel modeller dahil. Kalibrasyon ve değerlendirme örneklemeleri örtüşmez. FZ-GAS: $\alpha = 0.05$ 'te 6/8 varlık, $\alpha = 0.01$ 'de 5/8 varlık (GAYRIM ve PERAK Nelder-Mead yerel minimum sorunu); robust çok-başlangıçlı versiyon kullanıcının riginde çalıştırılması önerilir.

3 Gerçekleşen Oynaklık ve Yüksek Boyutlu Kovaryans

Bölümün Amacı

Bu oturumda gün içi yüksek frekanslı veriden *parametrik olmayan* volatilité tahmini yapılacak; HAR-RV (*Heterogeneous Autoregressive Realized Volatility*) modeli ile uzun bellek (long memory) yapısı basit bir doğrusal çerçeveye yakalanacak; HEAVY (*High-frequency-based Volatility*) ve GARCH-X (dışsal regresörlü GARCH) modelleri ile gerçekleşen varyans bilgisi parametrik modellere entegre edilecek ve son olarak büyük boyutlu kovaryans matrisi tahmini için POET ve Ledoit-Wolf büzülme yaklaşımları ele alınacaktır.

Notasyon ve Kısaltmalar

Bu bölümde gün-içi yüksek frekanslı veriden oynaklık tahmini ve N varlıklı bir portföyde yüksek boyutlu kovaryans tahmini ele alınır. Notasyon, Bölüm 1 ve Bölüm 2 ile uyumludur; farklılaşan noktalar tabloda belirtilmiştir.

Tablo 20: Temel notasyon

Sembol	Anlamı	Not
N, T	varlık sayısı, gün sayısı	
M, Δ	gün-içi gözlem sayısı, örnek- leme aralığı	
$r_{t,j}$	t gününün j 'inci gün-içi geti- risi	
RV_t	gerçekleşen varyans	$\sum_j r_{t,j}^2$
IV_t	entegre varyans (gözleneme- yen hedef)	$\int \sigma^2(s) ds$
BPV_t, J_t	çift-kuvvet varyasyonu, sıç- rama bileşeni	sıçrama ayrıştırması
μ_1	$\mathbb{E} Z = \sqrt{2/\pi}$, standart nor- malin mutlak momenti	BPV ölçek çarpımı $\pi/2 = \mu_1^{-2}$
$\psi_{t,j}, \sigma_\psi^2$	mikroyapı gürültüsü ve var- yansı	literatürde ϵ, η, u ile de gösterilir
ϱ^2	gürültü-sinyal oranı	çekirdek bant genişliğinde; c_k çekir- değe özgü sabit
σ_t^2	koşullu varyans	Bölüm 1 ve Bölüm 2 ile ortak
z_t	standart artık	$z_t = r_t/\sigma_t$; Bölüm 1 ve Bölüm 2 ile ortak
$\beta_0, \beta_d, \beta_w, \beta_m$	HAR-RV katsayıları (gün- lük/haftalık/aylık)	
$\omega, \alpha, \beta, \gamma$	HEAVY / GARCH-X katsayı- ları	Bölüm 1'de varlık-indisli (α_i, β_i) , Bölüm 2'de a_1, b_1, g_1
$\xi, \varphi, \tau_1, \tau_2$	Realized GARCH ölçüm denk- lemi	$\tau(z_t) = \tau_1 z_t + \tau_2(z_t^2 - 1)$: kaldıraç. Bölüm 2'de ξ kuyruk indeksi, τ test düzeyidir
$\hat{\gamma}_h$	h gecikmeli gerçekleşen otoko- varyans	GARCH-X katsayısı γ ile karıştırıl- mamalı
$\Sigma, \hat{\Sigma}$	(koşulsuz) kovaryans matrisi ve örnek tahmini	Bölüm 1'de koşullu kovaryans H_t
B, Σ_f, Σ_u	faktör yüklemeleri, faktör ve idiyosenkratik kovaryans	POET ayrıştırması
K	faktör sayısı	$\hat{K}$: tahmin edilen
$\lambda_i, \lambda_\pm$	öz değerler ve Marchenko- Pastur sınırları	
κ	büyük-boyut oranı, $c = N/T \rightarrow \kappa$	Bölüm 2'de κ_t koşullu ölçektir
τ_{ij}	POET eşik değeri	Realized GARCH'ın τ_1, τ_2 'sinden farklıdır (çift indis)
$\mathbf{w}$	portföy ağırlık vektörü	

Tablo 21: Kısaltmalar

Kısaltma	İngilizce açılımı	Türkçe karşılığı
RV	Realized Variance	Gerçekleşen varyans
IV	Integrated Variance	Entegre varyans
BPV	Bipower Variation	Çift-kuvvet varyasyonu
TSRV	Two-Scale Realized Variance	İki ölçekli gerçekleşen varyans
RK	Realized Kernel	Gerçekleşen çekirdek
HAR	Heterogeneous Autoregressive	Heterojen otoregresif
HMH	Heterogeneous Market Hypothesis	Heterojen piyasa hipotezi
HEAVY	High-frequency-based Volatility	Yüksek frekans temelli oynaklık
GARCH-X	GARCH with eXogenous regressor	Dışsal regresörlü GARCH
POET	Principal Orthogonal complEment Thresholding	Temel ortogonal tümleyen eşikleme
RMT	Random Matrix Theory	Rastgele matris teorisi
MP	Marchenko–Pastur (law)	Marchenko–Pastur yasası
PCA	Principal Component Analysis	Temel bileşen analizi
LW	Ledoit–Wolf (shrinkage)	Ledoit–Wolf büzülmesi
NL-LW	Non-Linear Ledoit–Wolf	Doğrusal olmayan LW büzülmesi
MVP	Minimum Variance Portfolio	Minimum varyans portföyü
DCC	Dynamic Conditional Correlation	Dinamik koşullu korelasyon
MSE / QLIKE	Mean Squared Error / Quasi-Likelihood loss	Kayıp fonksiyonları
DGP	Data Generating Process	Veri üretme süreci
OOS	Out-of-Sample	Örnekleme-dışı

3.1 Gerçekleşen Varyans (Realized Variance — RV)

Tanım 3.1 (Gerçekleşen Varyans). Gün t boyunca M eşit aralıklı gün içi getiri $\{r_{t,1}, \dots, r_{t,M}\}$ gözleendiğinde, gerçekleşen varyans:

$$RV_t = \sum_{j=1}^M r_{t,j}^2 \quad (103)$$

olarak tanımlanır. Etkin log-fiyat süreci sürekli bir semimartingale ise, örnekleme aralığı sıfıra giderken

$$RV_t \xrightarrow{P} IV_t := \int_{t-1}^t \sigma_s^2 ds. \quad (104)$$

Burada IV_t *entegre varyanstır* (integrated variance — IV): gözlenemeyen hedef büyüklük. Fiyat süreci sıçramalar içeriyorsa limit yalnızca entegre varyans değildir:

$$RV_t \xrightarrow{P} [X, X]_t = IV_t + \sum_{t-1 < s \leq t} (\Delta X_s)^2, \quad (105)$$

yani toplam kuadratik varyanstır. Bu ayrım, aşağıdaki sıçrama ayrıştırmasının temelini oluşturur.

3.1.1 Mikroyapı Gürültüsü Problemi

Pratikte gözlenen fiyatlar, alış-satış yayılması (bid-ask spread), fiyat basamakları ve piyasa yapıcı faaliyetleri nedeniyle *mikroyapı gürültüsü* içerir. Bu, RV'nin asimptotik davranışını kökten değiştirir; aşağıda etkiyi açıkça türetiliyoruz.

Gürültülü fiyat modeli. Gözlenen log-fiyat, etkin (gözlenemeyen) log-fiyat ile toplamsal bir gürültü teriminin toplamı olsun:

$$p_{t,j} = p_{t,j}^* + \psi_{t,j}, \quad \psi_{t,j} \text{ i.i.d.}, \quad \mathbb{E}[\psi_{t,j}] = 0, \quad \text{Var}(\psi_{t,j}) = \sigma_\psi^2, \quad (106)$$

Burada $p_{t,j}^*$ etkin (efficient) log-fiyat, $\psi_{t,j}$ ise ondan bağımsız gürültü terimidir. (Literatürde gürültü ϵ , η ya da u ile de gösterilir.) Buna karşılık gelen etkin getiri $r_{t,j}^* := p_{t,j}^* - p_{t,j-1}^*$ olmak üzere, gözlenen gün-içi getiri:

$$r_{t,j} = p_{t,j} - p_{t,j-1} = r_{t,j}^* + (\psi_{t,j} - \psi_{t,j-1}). \quad (107)$$

Sapmanın türetilmesi. Gerçekleşen varyans üç terime ayrışır:

$$RV_t = \sum_{j=1}^M r_{t,j}^2 = \underbrace{\sum_j (r_{t,j}^*)^2}_{\rightarrow IV_t} + 2 \underbrace{\sum_j r_{t,j}^* (\psi_{t,j} - \psi_{t,j-1})}_{\text{beklentisi } 0} + \sum_j (\psi_{t,j} - \psi_{t,j-1})^2. \quad (108)$$

İkinci terimin beklentisi bağımsızlık nedeniyle sıfırdır. Üçüncü terimde $\mathbb{E}[(\psi_{t,j} - \psi_{t,j-1})^2] = 2\sigma_\psi^2$ olduğundan ve toplam M terim içerdiğinden:

$$\boxed{\mathbb{E}[RV_t] \approx IV_t + 2M\sigma_\psi^2} \quad (109)$$

Üç sonuç.

1. **Sapma frekansla doğrusal büyür.** $M \rightarrow \infty$ iken $\mathbb{E}[RV_t] \rightarrow \infty$: “daha çok veri daha iyi tahmin” sezgisi burada tersine döner. Örneklemeyi sıklaştırmak sapmayı azaltmaz, artırır.
2. **RV tutarlılığını yitirir.** (109)’i $2M$ ’ye bölersek $RV_t/(2M) \xrightarrow{P} \sigma_\psi^2$; yani çok yüksek frekansta RV, entegre varyansı değil fiilen gürültü varyansını ölçer. (Bu ilişki aynı zamanda σ_ψ^2 için basit bir tahminci verir.)
3. **Negatif birinci-derece otokorelasyon.** (107)’den $\text{Cov}(r_{t,j}, r_{t,j-1}) = -\sigma_\psi^2$: gürültü, ardışık getirilerde negatif otokorelasyon yaratır. Bu, gürültünün varlığının doğrudan ampirik belirtisidir ve çekirdek tabanlı düzeltmelerin (§3.1.4) çıkış noktasıdır — otokovaryansları toplayarak gürültü katkısı geri alınır.


Sapma–varyans gerilimi. Örnekleme aralığı Δ büyütülürse (M küçülür) sapma $2M\sigma_\psi^2$ azalır, ancak gözlem sayısı düştüğü için tahmin varyansı artar. Uygulamada frekans bu iki hata kaynağı arasında seçilir; bu gerilimin görsel tanısı *volatility imza grafiğidir* (§3.1.2), doğrudan çözümleri ise TSRV (§3.1.3) ve gerçekleşen çekirdeklerdir (§3.1.4).

3.1.2 Volatilite İmza Grafiği (Volatility Signature Plot)

Gerçekleşen varyans $RV(\Delta)$, örnekleme aralığı Δ ’ya bağlı olarak nasıl değişir? Bu soruyu yanıtlamak için *volatility imza grafiği* yatay ekseninde Δ , dikey ekseninde $RV(\Delta)$ gösterecek şekilde çizilir.

Teorik beklenti (gürültüsüz ortam): Fiyat sürecinde mikroyapı gürültüsü yoksa, $\Delta \rightarrow 0$ iken $RV(\Delta) \rightarrow IV = \int_0^1 \sigma_t^2(s) ds$ (entegre varyans) sabit bir değere yakınsır. Bu durumda imza grafiği yatay bir düzlem olur.

Gerçek veri davranışı: Mikroyapı gürültüsü varlığında, $\Delta \rightarrow 0$ iken $RV(\Delta) \rightarrow \infty$. Bu, §3.1.1’te türetilen $\mathbb{E}[RV_t] \approx IV_t + 2M\sigma_\psi^2$ sapmasının doğrudan görsel karşılığıdır: Δ küçüldükçe M büyür ve sapma doğrusal olarak artar. Öte yandan Δ büyüdükçe gözlem sayısı azalır ve $RV(\Delta)$ tahmin varyansı yükselir.



Şekil 5: Volatilite imza grafiği, kontrollü simülasyon. Veri üreten süreç: 6.5 saatlik (23,400 saniye) işlem günü, etkin fiyat için sabit oynaklıklı Brownian hareket (günlük $\sqrt{IV} = \%1.5$, yani yıllık $\approx \%23.8$), üzerine i.i.d. mikroyapı gürültüsü ($\sigma_\psi = 10^{-4}$); 400 gün tekrar. Mavi eğri ortalama $RV(\Delta)$, kırmızı kesikli eğri (109) sapma formülünün öngörüsü $IV + 2M\sigma_\psi^2$ ($M = 23,400/\Delta$), noktalı yatay çizgi gürültüsüz hedef IV 'dir. Gölge bant %10–%90 aralığını gösterir. $\Delta = 1$ sn'de tahmin gerçek değerinkini yaklaşık iki katıdır (%41.8'e karşı %23.8); $\Delta \gtrsim 2$ dakikada sapma pratik olarak kaybolur, ancak Δ büyüdükçe bant genişler — sapma–varyans gerilimi grafikte doğrudan görünür.

Pratik sonuç: Şekil 5'de imza grafiğinin görece yataylaştığı bölge, sapma–varyans dengesi için uygulanabilir örnekleme aralıklarını gösterir. Beş dakika, birçok likit piyasada kullanılan ampirik bir uzlaşmadır; matematiksel olarak evrensel bir optimum değildir. Uygun frekans varlığa, piyasa yapısına, likiditeye ve gürültü düzeyine göre imza grafiği veya veri-temelli bir yöntemle seçilmelidir.

Python ile Volatilite İmza Grafiği

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4 def volatilite_imza_grafigi(tick_prices, max_interval=60, step=1):
5     """
6     tick_prices : pd.Series, saniye bazlı fiyat serisi
7     max_interval: maksimum örnekleme aralığı (dakika)
8     """
9     intervals = range(1, max_interval + 1, step)
10    rv_values = []
11    for delta in intervals:
12        # Her delta dakikada bir örnekleme
13        sampled = tick_prices.resample(f'{delta}min').last().dropna()
14        log_returns = np.log(sampled).diff().dropna()
```

```

15     rv = (log_returns**2).sum()
16     rv_values.append(rv)
17
18     plt.figure(figsize=(10, 5))
19     plt.plot(intervals, np.sqrt(252 * np.array(rv_values)) * 100,
20             marker='o', linewidth=1.5, color='steelblue')
21     plt.axvline(x=5, color='red', linestyle='--',
22               label='5 dakika kuralı')
23     plt.xlabel('Örnekleme aralığı (dakika)')
24     plt.ylabel('Yillik oynaklık tahmini (%)')
25     plt.title('Volatilité Imza Grafiği')
26     plt.legend(); plt.grid(True, alpha=0.3)
27     plt.tight_layout(); plt.show()
28     return rv_values

```

3.1.3 İki Ölçekli RV (Two-Scale RV — TSRV)

Zhang et al. (2005) tarafından önerilen TSRV, tek bir yavaş ızgarayı değil, K ayrık alt-ızgara üzerinde hesaplanan gerçekleşen varyansların ortalamasını kullanır. n tüm-ızgaradaki getiri sayısı ve $\bar{n}$ bir alt-ızgaradaki ortalama getiri sayısı olsun. Alt-ızgara ortalaması


$$[Y, Y]_t^{(\text{avg}, K)} = \frac{1}{K} \sum_{k=1}^K [Y, Y]_t^{(k)} \quad (110)$$

ve sonlu örneklem düzeltmeli tahminci

$$\widehat{IV}_t^{\text{TSRV}} = \left(1 - \frac{\bar{n}}{n}\right)^{-1} \left\{ [Y, Y]_t^{(\text{avg}, K)} - \frac{\bar{n}}{n} [Y, Y]_t^{(\text{all})} \right\} \quad (111)$$

biçimindedir. İlk terim, seyrek alt-ızgaralarda gürültünün etkisini azaltır; ikinci terim tüm-ızgaradan tahmin edilen gürültü sapmasını çıkarır. Tam indeksleme, gün içi gözlem sayısının K 'ya tam bölünüp bölünmemesine göre küçük sonlu-örneklem uyarlamaları gerektirir.

İzgaraların nasıl konumlandığı Şekil 6'de gösterilmektedir. Yöntemin özü, *aynı* veriyi iki farklı ölçekte kullanmaktır: seyrek alt-ızgaralar sinyali görece temiz taşır (her alt-ızgarada $\bar{n} \approx n/K$ getiri vardır, dolayısıyla (109) uyarınca gürültü sapması yaklaşık K kat küçüktür), yoğun tüm-ızgara ise gürültünün kendisi hakkında bilgi taşır ve bu bilgi sapmayı çıkarmak için kullanılır. “İki ölçekli” adı buradan gelir.



Şekil 6: TSRV’de alt-ızgaraların konumlanması ($M = 21$ gözlem, $K = 4$). En üstte tüm-ızgara: ardışık gözlemler Δ aralıklıdır ve $[Y, Y]^{(all)}$ bu ızgaradan hesaplanır. Altındaki dört satır alt-ızgaraları gösterir: k ’nci alt-ızgara $k, k + K, k + 2K, \dots$ indeksli gözlemleri alır; içi dolu noktalar o alt-ızgarada kullanılan, içi boş halkalar kullanılmayan gözlemlerdir. Her alt-ızgarada ardışık gözlemler arası aralık $K\Delta$ ’dır — yani her biri *seyrek* örneklenmiş bir seridir. Alt-ızgaralar örtüşmez ve birlikte tüm veriyi tüketir; bu nedenle K tahmin ortalandığında veri kaybı olmaz.

3.1.4 Çekirdek Tabanlı RV Tahmin Edicileri

Barndorff-Nielsen et al. (2008) tarafından önerilen *Realized Kernel (RK)*, yüksek frekanslı gürültüyü otokovaryansların çekirdek ağırlıklı toplamıyla düzeltir.

Tanım 3.2 (Realized Kernel: şematik çekirdek formu).

$$\widehat{RV}_t^K = \sum_{h=-H}^H k\left(\frac{h}{H+1}\right) \hat{\gamma}_h, \quad \hat{\gamma}_h = \sum_j r_{t,j} r_{t,j-h}. \quad (112)$$

Bu ifade tahmincinin çekirdek yapısını gösterir. Uygulanabilir realized kernel; sınır gözlemlerinin işlenmesi, jittering/subsampling ve veri-temelli bant genişliği seçimi gibi ek adımlar içerir. Dolayısıyla aşağıdaki kısa kod, tam Barndorff-Nielsen vd. uygulamasının yerine geçen değil, mekanizmayı gösteren pedagojik bir prototip olarak okunmalıdır.

Parzen Çekirdeği:

$$k(x) = \begin{cases} 1 - 6x^2 + 6|x|^3 & 0 \leq |x| \leq \frac{1}{2} \\ 2(1 - |x|)^3 & \frac{1}{2} < |x| \leq 1 \\ 0 & |x| > 1 \end{cases} \quad (113)$$

Parzen çekirdeğinde $k(1) = 0$, en yüksek gecikme katkısının sınırda yumuşak biçimde sıfıra inmesini sağlar. Realized-kernel tahmincisinin pozitif yarı-tanımlılık özelliği ise yalnızca bu sınır koşulundan değil; çekirdeğin uygun *pozitif-tip* özelliğinden ve realized-kernel inşasının bütününden (uç etkisi düzeltmesi ve gecikme yapısı dahil) kaynaklanır.

Asimptotik bant genişliği: Belirli gürültü ve örnekleme varsayımları altında, bant genişliğinin tipik asimptotik mertebesi

$$H^* = c_k \varrho^{4/5} n^{3/5} \quad (114)$$

biçiminde yazılabilir; burada ρ^2 gürültü–sinyal oranı ve c_k seçilen çekirdeğe özgü sabittir. Bu ifade evrensel bir tak-çalıştır kuralı değildir; uygulamada gürültü–sinyal oranı ρ^2 ve sınır (uç etkisi) düzeltmeleri veriden tahmin edilmelidir.

Yakınsama Hızı Pratikte Ne Anlama Gelir?

Yakınsama hızı, “gün içinde daha sık örneklersem tahminim ne kadar iyileşir?” sorusunun yanıtıdır. Tahmin hatası n^{-a} mertebesindeyse, üs a ne kadar büyükse ek veri o kadar işe yarar.

Tahminci	Hız	Hatayı yarıya indirmek için	Pratik anlamı
Ham RV	—	mümkün değil	Sapma (109) ile <i>büyür</i> ; daha sık örnekleme durumu kötüleştirir. Çare veri atmaktır (5 dk).
TSRV	$n^{-1/6}$	veri $\times 64$	Tüm veriyi kullanır, ama ek verinin getirisi yavaştır.
Realized Kernel	$n^{-1/4}$	veri $\times 16$	Aynı ek veriden <i>çok daha fazla</i> yararlanılır.

Somut örnek: örnekleme dakikalıktan saniyelige geçirilirse (n yaklaşık 60 kat artar) TSRV’nin hatası *yarıya* inerken RK’ninki *üçte bire* yaklaşır. Buradaki $n^{-1/4}$ hızı, *gürültülü* yüksek-frekanslı semimartingale modeli altında entegre varyans tahmini için bilinen optimal hızdır (gürültüsüz bir ortamda hız $n^{-1/2}$ olurdu; gürültü hızı düşürür). Uygun biçimde tasarlanmış realized kernel bu hıza ulaşır; asimptotik varyans ve verimlilik sabiti ise kullanılan çekirdeğe, bant genişliği seçimine ve düzenlilik varsayımlarına bağlıdır — “daha iyisi mümkün değildir” türü mutlak bir ifade doğru değildir.

Neden RK daha hızlı? TSRV yalnızca iki ölçek (seyrek ve yoğun ızgara) kullanır; RK ise *birçok* otokovaryans gecikmesini çekirdek ağırlıklarıyla birlikte değerlendirir ve gürültü yapısından daha fazla bilgi çıkarır. Bedeli, çekirdek ve bant genişliği seçimidir.

Tablo 22: RV Tahmincilerinin Karşılaştırması

Tahminci	Gürültü Toleransı	Sapma	MSE Sırası	Karmaşıklık
Ham RV (5 dk)	Orta	Düşük	Yüksek	Basit
TSRV	Yüksek	Çok Düşük	Orta	Orta
Realized Kernel	Yüksek	Çok Düşük	Düşük	Orta

Tablo 22 üç tahminciyi uygulamacı ölçütleriyle özetler. Okurken üç noktaya dikkat edilmelidir. Birincisi, *ham RV’nin sapmasının “düşük” görünmesi* yalnızca 5 dakikalık seyrek örnekleme sayesinde; aynı tahminci saniyelik veriye uygulandığında sapma (109) uyarınca hızla büyür. İkincisi, buna karşın ham RV’nin MSE sırası *yüksektir* (yani en kötüsüdür), çünkü günde yalnızca ≈ 78 gözlem kullanır ve tahmin varyansı yüksek kalır — Şekil 5’deki bandın büyük Δ ’da genişlemesi tam olarak budur. Üçüncüsü, TSRV ile RK sapma bakımından benzer, MSE bakımından ise farklıdır; aradaki fark yukarıdaki yakınsama hızlarından ($n^{-1/6}$ ’ya karşı $n^{-1/4}$) gelir.

Not 3.1 (Pratik seçim kuralı). Likit bir varlıkta 5 dakikalık ham RV, hızlı ve savunulabilir bir başlangıçtır. Gün-içi veri bol ve gürültü belirginse (dar tik adımı, yoğun kotasyon) RK tercih edilmelidir; TSRV ise uygulaması daha basit bir ara çözümdür. Karar, veri sıklığı ile hesaplama/uygulama karmaşıklığı arasındaki dengeye göre verilir.

3.2 Sıçrama Ayrıştırması (Jump Decomposition)

Tanım 3.3 (İki Kuvvet Varyasyonu (Bipower Variation — BPV)).

$$BPV_t = \frac{\pi}{2} \frac{M}{M-1} \sum_{j=2}^M |r_{t,j}| |r_{t,j-1}| \quad (115)$$

$M/(M-1)$ çarpanı sonlu örneklem düzeltmesidir ve asimptotik olarak bire yaklaşır. Uygun düzenlilik koşulları altında BPV, sürekli yol varyansının tutarlı tahmin edicisidir ve sonlu etkinlikli sıçramalara karşı sağlamdır.

$\pi/2$ **çarpanı nereden gelir?** Bu sabit keyfi değildir; *mutlak* getiri çarpımlarını varyans ölçeğine geri döndürür. Kısa bir aralıkta getiri yaklaşık $r_{t,j} \approx \sigma_t \sqrt{\Delta} Z_j$, $Z_j \sim N(0,1)$ bağımsız yazılabilir. Standart normalin *mutlak birinci momenti*

$$\mu_1 := \mathbb{E}|Z| = \sqrt{2/\pi} \approx 0.7979 \quad (116)$$

olduğundan, komşu getirilerin bağımsızlığı altında

$$\mathbb{E}[|r_{t,j}| |r_{t,j-1}|] = \mu_1^2 \sigma_t^2 \Delta = \frac{2}{\pi} \sigma_t^2 \Delta. \quad (117)$$

Yani düzeltilmemiş toplam, entegre varyansın yalnızca $2/\pi \approx 0.637$ katını yakalar. Çarpan bu eksikliği tam olarak kapatır:

$$\frac{\pi}{2} = \mu_1^{-2}. \quad (118)$$

Kısaca: $M/(M-1)$ *sonlu örneklem* düzeltmesi, $\pi/2$ ise *ölçek* düzeltmesidir — birincisi M büyüdükçe kaybolur, ikincisi kalıcıdır.

Sıçrama dayanıklılığı neden işler? Tek bir sıçrama, tek bir getiriye $O(1)$ mertebesinde büyütür. Bu getiri, RV_t 'de *karesi* alınarak girer ve katkısı $O(1)$ olarak kalır. BPV'de ise daima bir *komşu* getirile çarpılır; komşu ise sıçrama içermediğinden $O_p(\sqrt{\Delta})$ mertebesinde. Dolayısıyla sıçramanın BPV'ye katkısı $O_p(\sqrt{\Delta}) \rightarrow 0$ olur. Fark $RV_t - BPV_t$ bu nedenle sıçrama varyasyonunu izole eder.

Örnek 3.1 (Sayısal doğrulama). $M = 2340$, $IV = 2.5 \times 10^{-4}$, 4000 tekrarlı kontrollü simülasyonda: sıçrama yokken $\mathbb{E}[RV] = 2.501 \times 10^{-4}$ ve $\mathbb{E}[BPV] = 2.501 \times 10^{-4}$ — ikisi de IV 'yi yakalar; $\pi/2$ çarpanı *kaldırılırsa* $\mathbb{E}[BPV]$ $1.592 \times 10^{-4} = IV \times 0.637$ 'ye düşer, yani tam olarak $2/\pi$ katına. Gün ortasına tek bir %4'lük sıçrama eklendiğinde $\mathbb{E}[RV]$ %640 artarken $\mathbb{E}[BPV]$ yalnızca %13 artar; $J_t = RV_t - BPV_t$ ortalaması 1.567×10^{-3} olup gerçek sıçrama katkısı $0.04^2 = 1.6 \times 10^{-3}$ 'e yakındır.

Sıçrama varyasyonu için yaygın pozitif-kısım tahmini

$$\widehat{JV}_t = J_t := \max(0, RV_t - BPV_t) \quad (119)$$

biçimindedir. Ancak $J_t > 0$ tek başına bir sıçramanın istatistiksel olarak anlamlı olduğunu göstermez. Sonlu örneklemde ölçüm hatası ve mikroyapı gürültüsü küçük pozitif farklar üretebilir; anlamlılık için standardize edilmiş Barndorff-Nielsen-Shephard türü bir test veya uygun bootstrap gerekir.

Not 3.2. Sıçramalar genellikle makroekonomik veri açıklamaları (istihdam, faiz kararı) veya jeopolitik olaylarla ilişkilendirilir. HAR-RV-J modeli, sıçramaların gelecekteki oynaklığa olan etkisini ayrı bir katsayı ile ölçer.

3.3 HAR-RV Modeli (Corsi, 2009)

GARCH modelleri koşullu varyansı parametrik bir süreç olarak tanımlarken, [Corsi \(2009\)](#)'nin önerdiği HAR-RV modelinde *bağımlı değişken* doğrudan gözlemlenen RV_t 'dir.

Teorem 3.1 (HAR-RV Modeli).

$$RV_t^{(d)} = \beta_0 + \beta_d RV_{t-1}^{(d)} + \beta_w RV_{t-1}^{(w)} + \beta_m RV_{t-1}^{(m)} + \varepsilon_t \quad (120)$$

- $RV_{t-1}^{(d)}$: Bir önceki günün gerçekleşen varyansı.
- $RV_{t-1}^{(w)} = \frac{1}{5} \sum_{k=1}^5 RV_{t-k}$: Haftalık ortalama (son 5 iş günü).
- $RV_{t-1}^{(m)} = \frac{1}{22} \sum_{k=1}^{22} RV_{t-k}$: Aylık ortalama (son 22 iş günü).

3.3.1 Heterojen Piyasa Hipotezi

HAR modelinin teorik temeli *Heterojen Piyasa Hipotezi*'ne dayanır:

1. **Günlük yatırımcılar** (gün içi trader'lar) $\rightarrow \beta_d$
2. **Haftalık yatırımcılar** (portföy yöneticileri) $\rightarrow \beta_w$
3. **Aylık yatırımcılar** (kurumsal yatırımcılar) $\rightarrow \beta_m$

Bu üç grup farklı zaman ufuklarında işlem yapar ve farklı bilgi kümelerine tepki verir; birleşik etkisi gerçekleşen varyansın *uzun bellek* (long memory) özelliğini basit bir AR yapısıyla üretir.

Not 3.3. HAR modeli teknik olarak bir uzun bellek süreci değildir; ancak $\beta_d + \beta_w + \beta_m$ toplamı 1'e yakın olduğunda, otokorelasyon fonksiyonu uzun bellek süreçlerinininkine oldukça benzer bir yavaş azalma (slow decay) sergiler.

3.3.2 HAR-RV-J: Sıçrama Bileşenli Uzantı

Andersen et al. (2007), taban HAR-RV modelinin gecikme yapısını *değiştirmeden* — gecikmeler hâlâ toplam RV 'dir, Eq. (120) ile aynı — yalnızca bir sıçrama terimi ekler:

$$RV_t = \beta_0 + \beta_d RV_{t-1} + \beta_w RV_{t-1}^{(w)} + \beta_m RV_{t-1}^{(m)} + \beta_j J_{t-1} + \varepsilon_t \quad (121)$$

- Gecikmeler toplam RV 'dir; yalnızca sıçrama bileşeni $J_{t-1} = \max(0, RV_{t-1} - BPV_{t-1})$ ek regresör olarak eklenir.
- Ampirik olarak β_j genellikle *küçük ve çoğu zaman negatif ya da anlamsızdır*: sıçramalar sürekli bileşene kıyasla belirgin biçimde *daha az kalıcıdır*, dolayısıyla geçmiş sıçrama-şişirmeli RV gelecekteki oynaklığı yukarı taşımaz. Andersen et al. (2007) S&P 500 için işaretli sıçramaların gelecekteki varyansta hafif bir *düşüşe* yol açtığını, öngörülebilirliğin neredeyse tamamının *sürekli* bileşenden geldiğini bulur.
- Bu bulgu, §3.3.4'deki HAR-RV-CJ modelinde sürekli ($C=BPV$) gecikmelerin baskın ve anlamlı, sıçrama gecikmelerinin ise küçük/anlamsız çıkmasıyla tutarlıdır (bkz. §3.7 kontrollü simülasyon sonuçları).

HAR-RV-J ile HAR-RV-CJ Arasındaki Fark

HAR-RV-J gecikme yapısını *değiştirmeyi*; yalnızca J eklenir. §3.3.4'de ele alınan HAR-RV-CJ ise bir adım ileri gidip gecikmelerin *kendisini* sürekli ($C = BPV$) ve sıçrama bileşenlerine ayırır. Andersen et al. (2007), HAR-RV-CJ'yi HAR-RV-J'yi *özel (kısıtlı) durum olarak içeren* bir genelleme olarak sunar — ikisi farklı modellerdir, birbirinin yerine kullanılmamalıdır.

3.3.3 HAR-RV Tahmin ve Tanılama

HAR-RV modeli EKK (En Küçük Kareler) ile tahmin edilir. $\mathbf{y} = [RV_t]_{t=1}^T$ ve $X = [\mathbf{1}, RV^{(d)}, RV^{(w)}, RV^{(m)}]$ tasarım matrisi olmak üzere:

$$\hat{\beta} = (X'X)^{-1}X'\mathbf{y} \quad (122)$$

Standart hatalar: RV_t serisinin artıkları güçlü seri bağımlılık ve kalın kuyruk gösterir. Bu nedenle Newey and West (1987) HAC (Heteroscedasticity and Autocorrelation Consistent) standart hatalar kullanılır; $q = 5$ gecikme tipik olarak yeterlidir:

$$\hat{V}_{\text{HAC}} = (X'X)^{-1}\hat{S}_{\text{NW}}(X'X)^{-1} \quad (123)$$

Model tanılaması:

- *Otokorelasyon:* Artıkların Ljung-Box testi — RV_t serisinin kendisi güçlü seri bağımlı olduğundan tahmin artıkları da bağımlı kalabilir; yüksek q -değerleri sorunludur.
- *Normallik:* Jarque-Bera testi tipik olarak reddedilir; RV_t dağılımı log-normal'a daha yakındır.
- R^2 : Literatürde genellikle 0.50–0.75 aralığındadır. Ham getiri karesine karşı ($R^2 \approx 0.05$) büyük bir başarı.

h -adım ilerisi tahmin: HAR katsayılarının ayrı ayrı h 'inci kuvvetini almak doğru değildir; çünkü haftalık ve aylık ortalamalar her öngörü adımında yeni tahminler ile henüz pencerede kalan gerçekleşmiş değerlerin birleşiminden yeniden hesaplanır. Uygulamada bir-adım HAR denklemi iteratif olarak çalıştırılır. Eşdeğer olarak, yeterli gecikmeleri içeren durum vektörü s_t için

$$s_{t+1} = As_t + b + \eta_{t+1}, \quad RV_t = e_1' s_t \quad (124)$$

companion gösterimi kurulursa

$$\widehat{RV}_{t+h|t} = e_1' \left(A^h s_t + \sum_{j=0}^{h-1} A^j b \right). \quad (125)$$

Dolayısıyla uzun ufuk yorumları, A^h 'nin dinamiğine ve hareketli ortalama pencerelerinin iteratif güncellenmesine dayanmalıdır.

3.3.4 HAR-RV-CJ: Sürekli Yol ve Sıçrama Ayrıştırması

Andersen et al. (2007) HAR çerçevesini sürekli yol (Continuous path) ve sıçrama (Jump) bileşenlerine ayırarak geliştirir; tam model, her iki bileşeni de günlük/haftalık/aylık ufuklarda içerir (HAR-RV-J'yi özel durum olarak kapsar):

$$RV_t = \beta_0 + \beta_{cd} C_{t-1} + \beta_{cw} C_{t-1}^{(w)} + \beta_{cm} C_{t-1}^{(m)} + \beta_{jd} J_{t-1} + \beta_{jw} J_{t-1}^{(w)} + \beta_{jm} J_{t-1}^{(m)} + \varepsilon_t \quad (126)$$

burada $C_t = BPV_t$ ve $J_t = \max(0, RV_t - BPV_t)$.

Ampirik bulgular:

- $\hat{\beta}_{cw} \gg \hat{\beta}_{jd}$: Haftalık sürekli yol etkisi sıçrama etkisinden çok daha büyük ve kalıcıdır.
- $\hat{\beta}_{jd}$ tipik olarak küçük ve *çoğu zaman anlamsız ya da negatiftir*: sıçrama bileşenleri sürekli bileşene göre çok daha az kalıcı olup gelecekteki oynaklığı ileriye taşımaz — öngörülebilirliğin neredeyse tamamı sürekli bileşenden gelir (§3.7 kontrollü simülasyonda $\hat{\beta}_{jd}, \hat{\beta}_{jw}, \hat{\beta}_{jm}$ 'nin hepsi anlamsız çıkar).

- Model tanılaması: z -istatistiği (Barndorff-Nielsen and Shephard, 2006) ile sıçrama varlığının testi yapılabilir.

Not 3.4. HAR-RV-CJ genellikle HAR-RV-J'ye kıyasla daha iyi öngörü performansı sergiler. Bunun temel nedeni BPV'nin sıçrama etkisini J_t tahmininden daha temiz bir biçimde izole etmesidir; özellikle küçük sıçrama değerlerinde fark belirgindir.

3.4 HEAVY ve GARCH-X Modelleri

3.4.1 HEAVY Modeli (Shephard ve Sheppard, 2010)

Shephard and Sheppard (2010) gerçekleşen varyans bilgisini GARCH benzeri bir yapıya entegre eder:

$$\sigma_t^2 = \omega + \alpha RV_{t-1} + \beta \sigma_{t-1}^2 \quad (127)$$

$$\mu_t = \omega_r + \alpha_r RV_{t-1} + \beta_r \mu_{t-1} \quad (128)$$

μ_t neyin ortalamasıdır?

Sık yapılan bir okuma hatası, μ_t 'yi $r_t \sim (\mu_t, \sigma_t^2)$ türü bir modeldeki *getirinin koşullu ortalaması* sanmaktır. Öyle değildir. HEAVY'de iki farklı büyüklük modellenir:

$$\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1}^{HF}) \quad (\text{getiri denklemi})$$

$$\mu_t = \mathbb{E}[RV_t | \mathcal{F}_{t-1}^{HF}] \quad (\text{gerçekleşen ölçüt denklemi})$$

Yani μ_t , *gerçekleşen varyansın* koşullu ortalamasıdır — getirinin değil. Getirinin koşullu ortalaması modelde ayrıca ele alınmaz (pratikte sıfır veya sabit alınır).

Neden iki denklem? Birincisi, bilgi kümesi $\mathcal{F}_{t-1}^{HF}$ gün-içi yüksek frekanslı veriyi de içerir ve yalnızca günlük getirilere dayanan GARCH'ın bilgi kümesinden *daha zengindir*; bu, RV_{t-1} 'in ε_{t-1}^2 'den daha bilgilendirici olmasının kaynağıdır. İkincisi ve daha önemlisi, *çok-adımlı öngörü* için sistemin kapanması gerekir: σ_{t+2}^2 'yi öngörmek RV_{t+1} 'in öngörüsünü gerektirir, onu da (128) sağlar. Tek denklemlili bir kurgu bu noktada eksik kalır.

Tahmin. İki denklemin parametreleri $\theta_r = (\omega, \alpha, \beta)$ ve $\theta_R = (\omega_r, \alpha_r, \beta_r)$ *ayrık* (variation-free) olduğundan, yarı-olabilirlik (quasi-likelihood) çarpanlarına ayrışır:

$$\ell(\theta_r, \theta_R) = \underbrace{-\frac{1}{2} \sum_t \left[\log \sigma_t^2 + \frac{r_t^2}{\sigma_t^2} \right]}_{\ell_r(\theta_r)} + \underbrace{\ell_R(\theta_R)}_{RV_t \text{ için yarı-olabilirlik}}, \quad (129)$$

dolayısıyla iki denklem *ayrı ayrı* maksimize edilebilir; ortak optimizasyon gerekmez. ℓ_r Gauss yarı-olabilirliğidir ve r_t 'nin gerçekten normal olmasını gerektirmez — doğru belirtilmiş koşullu varyans altında tutarlıdır. ℓ_R için $RV_t > 0$ olduğundan Gamma ya da log-normal tipi bir yarı-olabilirlik kullanılır. Standart hatalar sandviç (QMLE) formülüyle hesaplanmalıdır. Bu yapı, HEAVY'nin “iki adımlı OLS” *olmadığını* da açıklar.

3.4.2 GARCH-X Modeli

Standart GARCH(1,1)'e eksojen RV değişkeni eklenir:

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma RV_{t-1} \quad (130)$$

Burada ε_{t-1}^2 korunur ve RV_{t-1} ona eklenir. $\gamma > 0$ ise gerçekleşen varyans, günlük getiri karesinin ötesinde ek bilgi taşır; $H_0 : \gamma = 0$ testi GARCH-X'i standart GARCH(1,1)'e indirger ve bu hipotezi doğrudan sınar. GARCH-X'in cazibesi budur: iç içe geçmiş (nested) bir yapı içinde “gün-içi veri gerçekten katkı sağlıyor mu?” sorusu tek bir katsayıyla test edilebilir.

$\gamma = 0$ bir sınır hipotezidir

$RV_{t-1} \geq 0$ olduğundan ve $\sigma_t^2 > 0$ güvence altına alınmak istendiğinden uygulamada genellikle $\gamma \geq 0$ kısıtı konur. Bu kısıt altında $H_0 : \gamma = 0$ parametre uzayının *sınırındadır*; dolayısıyla standart iki-tarafli t -testi ya da sıradan χ_1^2 LR referansı genel olarak geçerli değildir. Tek sınır parametresi için uygun asimptotik referans $\frac{1}{2}\chi_0^2 + \frac{1}{2}\chi_1^2$ karışımıdır; alternatif olarak parametrik bootstrap kullanılabilir. Bu, ADCC'de $c \geq 0$ için §1.10'de anlatılan durumun aynısıdır.

3.4.3 Realized GARCH (Hansen, Huang ve Shek, 2012)

Standart GARCH, koşullu varyansı yalnızca geçmiş getirilerden tahmin eder: $\sigma_t^2 = f(\sigma_{t-1}^2, r_{t-1})$. Realized GARCH ise bir *ölçüm denklemi* ekleyerek RV 'yi doğrudan modele entegre eder (Hansen et al., 2012):

$$\log(\sigma_t^2) = \omega + \beta \log(\sigma_{t-1}^2) + \gamma \log(RV_{t-1}) \quad (131)$$

$$\log(RV_t) = \xi + \varphi \log(\sigma_t^2) + \tau(z_t) + u_t \quad (132)$$

burada:

- $u_t \sim N(0, \sigma_u^2)$: gerçekleşen varyansın ölçüm hatası.
- $\tau(z_t) = \tau_1 z_t + \tau_2 (z_t^2 - 1)$: asimetrik *haber etkisi* (kaldıraç / leverage); $z_t = r_t / \sigma_t$ standardize getiridir.
- Tüm parametreler ($\omega, \beta, \gamma, \xi, \varphi, \tau_1, \tau_2, \sigma_u$) birlikte maksimum olabilirlik ile tahmin edilir.

Yorumlama:

- $\varphi \approx 1$: ölçüm denkleminin $\log \sigma_t^2$ üzerinde yaklaşık *birim eğime* sahip olduğunu gösterir. $\mathbb{E}[\tau(z_t)] = 0$ ve $\mathbb{E}[u_t] = 0$ olduğundan koşullu beklenti $\mathbb{E}[\log RV_t | \sigma_t^2] = \xi + \varphi \log \sigma_t^2$ 'dir; dolayısıyla $\mathbb{E}[\log RV_t | \sigma_t^2] \approx \log \sigma_t^2$ sonucu için $\varphi \approx 1$ *tek başına yeterli değildir*, ayrıca $\xi \approx 0$ gerekir.
- $\tau_1 < 0$: Olumsuz şoklarda RV daha yüksek, pozitif şoklarda daha düşük $\rightarrow$ kaldıraç etkisinin RV aracılığıyla yakalanması.
- $\gamma > 0$: RV_{t-1} günün GARCH varyansını güncelliyor; HEAVY modeliyle benzer sezgi, ama ortak parametre tahmini nedeniyle istatistiksel etkinlik daha yüksek.

Not 3.5. Realized GARCH'ı HEAVY'nin bir genellemesi olarak görmek *cebirselsel olarak tam doğru değildir*: $\xi=0, \varphi=1, \tau \equiv 0, \sigma_u=0$ kısıtları ölçüm denklemini $RV_t = \sigma_t^2$ 'ye (deterministik) indirger; bunu GARCH denkleminde yerine koyduğunuzda $\log \sigma_t^2 = \omega + (\beta + \gamma) \log \sigma_{t-1}^2$ — *tek* bir dejenere log-AR(1) elde edilir, HEAVY'nin σ_t^2 ve $\mu_t = \mathbb{E}[RV_t | \mathcal{F}_{t-1}]$ için *ayrı ayrı* işleyen iki-denklemlili yapısı değil. Doğru ilişki: iki model de RV_{t-1} 'i oynaklık güncellemesinde kullanan *akraba* çerçevelerdir; Realized GARCH getiri ve ölçüm denklemini ortak parametrik olabilirlik içinde tahmin eder; HEAVY ise getiri varyansı ile gerçekleşen ölçünün koşullu ortalamasına ait bağlantılı moment denklemlerini quasi-olabilirlik veya uygun tahmin denklemleriyle ele alır. Realized GARCH asimetri ve açık bir ölçüm hatası denklemi sunar; ancak biri diğerinin basit bir parametre kısıtlaması altında matematiksel olarak elde edilemez.

Tablo 23: Gerçekleşen varyansı GARCH'a entegre eden üç model: yapısal karşılaştırma

	GARCH-X	HEAVY	Realized GARCH
Denklem yapısı	Bir denklem	İki: getiri + gerçekleşen ölçüt	İki: oynaklık + ölçüm
ε_{t-1}^2 terimi	Korunur; RV_{t-1} eklenir	Yok; yalnızca RV_{t-1}	Yok; $\log RV_{t-1}$
GARCH'ı içerir mi?	Evet: $\gamma = 0$	Hayır	Hayır
Çok-adımlı öngörü	RV için ayrı model gerekir	Doğrudan; 2. denklem kapatır	Doğrudan; ölçüm denklemini kapatır
Kaldıraç	Yok (ayrıca eklenmeli)	Yok (asimetrik uzantıları var)	İşsel: $\tau(z_t)$
Ölçüm hatası	Modellenmez	Örtük	Açık: $u_t \sim N(0, \sigma_u^2)$
Tahmin	Tek denklemlilik QMLE	Ayrışabilir yarı-olabilirlik (129)	Ortak ML
Pozitiflik	Kısıt gerekir	Kısıt gerekir	Log ölçek: kendiliğinden

Üç modeli ayıran asıl noktalar

(1) Sistem kapanıyor mu? Tablo 23'in en belirleyici satırı çok-adımlı öngörüdür. GARCH-X'te σ_{t+2}^2 öngörüsü RV_{t+1} 'in öngörüsünü gerektirir; model bunu üretmez, dolayısıyla RV için dışarıdan bir denklem eklenmelidir — eklendiği anda kurgu fiilen HEAVY ya da Realized GARCH'a yaklaşır. HEAVY sistemi *gerçekleşen ölçütün koşullu ortalaması* denkleminde, Realized GARCH ise *ölçüm denkleminde* kapatır.

(2) İç içe geçme (nesting). Yalnızca GARCH-X standart GARCH'ı özel durum olarak içerir ($\gamma = 0$); bu, “gün-içi veri gerçekten katkı sağlıyor mu?” sorusunun tek katsayılı bir testle yanıtlanmasını sağlar. HEAVY ve Realized GARCH bu anlamda test aracı değil, alternatif çerçevelerdir — ve birbirlerini de içermezler; yukarıdaki not bunun cebirsel gerekçesini verir.

(3) Modelin neyi açıkça ele aldığı. Realized GARCH, diğer ikisinde bulunmayan iki bileşeni içselleştirir: kaldıraç fonksiyonu $\tau(z_t)$ ve ölçüm hatası u_t . Bedeli, tüm parametrelerin ortak olabilirlikte birlikte tahmin edilmesidir; kazancı ise istatistiksel etkinlik ve RV 'nin gürültülü bir ölçüt olduğunun modelde açıkça tanınmasıdır. HEAVY'nin ayrışabilir yapısı ise tahmini basitleştirir.

Ampirik örüntü. HEAVY'nin getiri denkleminde β genellikle düşüktür (oynaklık şoklara hızlı uyum sağlar), ölçüt denkleminde yüksek kalıcılık taşır. GARCH-X'te β standart GARCH'taki gibi yüksek kalır, γ ılımlı bir ek katkı ölçer. Realized GARCH'ta $\varphi \approx 1$ ve $\tau_1 < 0$ tipik bulgulardır.

Basit Realized GARCH Python Implementasyonu

```

1 import numpy as np
2 from scipy.optimize import minimize
3 from scipy.stats import norm
4
5 def realized_garch_loglik(params, r, rv):
6     """
7     Basitleştirilmiş Realized GARCH log-olabilirlik fonksiyonu.
```

```

8     params = [omega, beta, gamma, xi, phi, tau1, tau2, sigma_u]
9     r : gunluk getiriler (T,)
10    rv : gunluk gerceklesen varyans (T,)
11    """
12    omega, beta, gamma, xi, phi, tau1, tau2, sigma_u = params
13    # Kisitlar: sigma_u > 0, beta >= 0, gamma >= 0 ve indirgenmis-
        form kalicilik
14    if sigma_u <= 0.0 or beta < 0.0 or gamma < 0.0 or beta + gamma
        * phi >= 1.0:
15        return 1e10                                # kisit bariyeri
16    T = len(r)
17    log_sig2 = np.zeros(T)
18    log_sig2[0] = np.log(np.var(r))
19
20    ll = 0.0
21    for t in range(1, T):
22        log_sig2[t] = (omega
23                        + beta * log_sig2[t-1]
24                        + gamma * np.log(rv[t-1] + 1e-10))
25        sig2 = np.exp(log_sig2[t])
26        z = r[t] / np.sqrt(sig2)
27        # GARCH denklemleri log-olabilirlik katkilari
28        ll += norm.logpdf(r[t], 0, np.sqrt(sig2))
29        # Olcum denklemleri katkilari
30        mu_rv = xi + phi * log_sig2[t] + tau1*z + tau2*(z**2 - 1)
31        ll += norm.logpdf(np.log(rv[t] + 1e-10), mu_rv, sigma_u)
32    return -ll                                        # minimize icin
        negatif
33
34    # Kullanim ornegi (kisitlar ayrica bounds ile de uygulanmalidir)
35    # bnds = [(None, None), (0.0, 0.999), (0.0, 0.999), (None, None),
36    #          (None, None), (None, None), (None, None), (1e-6, None)]
37    # result = minimize(realized_garch_loglik,
38    #                    x0=[1e-6, 0.7, 0.3, 0, 1, -0.1, 0.05, 0.5],
39    #                    args=(r_series, rv_series), method='L-BFGS-B',
        bounds=bnds)

```

3.5 Yüksek Boyutlu Kovaryans Tahmini

Üçüncü Bölümle Sınır: Hangi Kovaryans?

Üçüncü bölümdeki DCC ailesi *koşullu* kovaryansı H_t modelliyordu; büzülme ve faktör yapıları orada DCC'nin *hedefine* ($\bar{Q}$) ve koşullu dinamiğine uygulanır. Bu bölümde ise aynı fikirler *koşulsuz* kovaryans matrisi Σ 'ya uygulanır: örnek kovaryansın büyük N/T 'de neden bozulduğu, faktör yapısı ve eşiklemeyle (POET) nasıl onarıldığı, büzülmenin öz değer spektrumunu nasıl düzelttiği. İki hat, §3.5.7'te POET-DCC olarak birleşir.

3.5.1 Sorun: Büyük Boyut Laneti

N varlıklı bir portföyde, örnek kovaryans matrisi $\hat{\Sigma} = T^{-1} \sum_{t=1}^T (\mathbf{r}_t - \bar{\mathbf{r}})(\mathbf{r}_t - \bar{\mathbf{r}})'$ şu durumda sorunludur:

- Ortalama çıkarılmış T gözlemde $\text{rank}(\hat{\Sigma}) \leq T - 1$ olduğundan $N \geq T$ ise matris *tekildir* (singular) ve olağan tersi alınamaz.
- N/T oranı büyük (ör. 0.5): Öz değerler aşırı dağınık (*Marchenko-Pastur yasası*); büyük öz değerler abartılır, küçükler küçümsenir.
- Portföy optimizasyonu bu hataları büyütür.

3.5.2 Rastgele Matris Teorisi (Random Matrix Theory)

$N, T \rightarrow \infty$ ve $c = N/T \rightarrow \kappa \in (0, \infty)$ şeklinde büyük boyut asimptotiğinde, bağımsız standart normal girdilerden oluşan bir örnek kovaryans matrisinin öz değer dağılımı *Marchenko-Pastur yasası*'na yakınsar.

Tanım 3.4 (Marchenko–Pastur Dağılımı). *Saf gürültü* referans modeli altında — yani gerçek kovaryans $\Sigma = \sigma^2 I_N$ olduğunda: tüm değişkenler eşit varyanslı ve karşılıklı ilişkisizdir, hiçbir yön diğerinden ayrıcalıklı değildir (literatürde *izotropik* null) — limit spektral ölçü

$$\mu_{MP} = \left(1 - \frac{1}{\kappa}\right)_+ \delta_0 + \rho_{MP}(\lambda) d\lambda, \quad (133)$$

ve sürekli kısmın yoğunluğu

$$\rho_{MP}(\lambda) = \frac{\sqrt{(\lambda_+ - \lambda)(\lambda - \lambda_-)}}{2\pi\sigma^2\kappa\lambda} \mathbf{1}_{[\lambda_-, \lambda_+]}(\lambda) \quad (134)$$

biçimindedir. Burada

$$\lambda_{\pm} = \sigma^2(1 \pm \sqrt{\kappa})^2, \quad \kappa = \frac{N}{T}. \quad (135)$$

Semboller. Yukarıdaki ifadelerde:

- λ : örnek kovaryans matrisinin bir *öz değeri*; ölçü λ ekseninde tanımlıdır. $\lambda_{\pm}$ ise *gürültü aralığının* — yani ρ_{MP} yoğunluğunun desteği olan $[\lambda_-, \lambda_+]$ aralığının; literatürde *bulk* — alt ve üst kenarlarıdır.
- μ_{MP} : *limit spektral ölçü* — $N, T \rightarrow \infty$ iken örnek öz değerlerinin ampirik dağılımının yakınsadığı dağılım. Kısaca “öz değerler nereye yayılır?” sorusunun yanıtıdır.
- $\rho_{MP}(\lambda)$: bu ölçünün *sürekli* kısmının yoğunluğu; yalnızca $[\lambda_-, \lambda_+]$ üzerinde pozitiftir.
- δ_0 : sıfır noktasındaki *Dirac (nokta) kütlesi*. Sürekli bir yoğunlukla ifade edilemeyen, tam olarak $\lambda = 0$ 'da toplanan olasılık kütlesini temsil eder.
- $(x)_+ = \max(x, 0)$: pozitif kısım operatörü. Dolayısıyla $\kappa \leq 1$ iken δ_0 teriminin katsayısı sıfırdır ve atom yoktur.
- σ^2 : saf gürültü referansında tüm değişkenlerin ortak varyansı ($\sigma^2 = 1$ alınırsa $\lambda_{\pm} = (1 \pm \sqrt{\kappa})^2$).

Marchenko–Pastur Yasası Sade Dille Ne Söyler?

Bir portföyün *gerçek* kovaryans matrisinin birim matris olduğunu, yani tüm gerçek öz değerlerin tam olarak 1 olduğunu varsayalım. Sonlu veriyle hesapladığımız *örnek* kovaryansın öz değerleri de 1 civarında toplanır mı? **Hayır.** MP yasası, bu öz değerlerin $[\lambda_-, \lambda_+]$ aralığına yayılacağını ve yayılmanın genişliğini yalnızca $\kappa = N/T$ oranının belirlediğini söyler.

N/T	κ	MP aralığı $[\lambda_-, \lambda_+]$	En büyük/en küçük oranı
50/500	0.10	[0.47, 1.73]	$\approx 4\times$
100/250	0.40	[0.14, 2.67]	$\approx 20\times$
200/250	0.80	[0.01, 3.59]	$\approx 322\times$
300/250	1.20	tekil (bkz. aşağıda)	tanımsız

Tablodaki yayılmanın *tamamı gürültüdür*: gerçekte hiçbir varlık diğerinden daha oynak değildir, hiçbir faktör yoktur. Yine de örneklem, en büyüğü en küçüğünün 322 katı olan bir öz değer yelpazesi üretir. Bu, “en büyük öz değer büyük çıktı, demek ki güçlü bir faktör var” çıkarımının neden tehlikeli olduğunu gösterir: karşılaştırma noktası 1 değil, λ_+ olmalıdır.

$\kappa > 1$ **durumu ve δ_0 'ın anlamı**. Varlık sayısı gözlem sayısını aştığında ($N > T$) örnek kovaryans matrisi *tekildir*: öz değerlerinin $1 - 1/\kappa$ oranındaki kısmı tam olarak sıfırdır. Denklemdaki δ_0 atomu tam olarak budur. Pratik sonucu ağırdır — matrisin tersi alınamaz, dolayısıyla $\mathbf{w} \propto \Sigma^{-1}\mathbf{1}$ minimum varyans portföyü **tanımsız** hâle gelir. Yukarıdaki $N = 300$, $T = 250$ satırında öz değerlerin tam olarak %16.7'si sıfırdır ve bu, teorik $1 - 1/1.2 = 0.167$ değeriyle birebir örtüşür.

Çıkarım. MP yasası bize bir *gürültü referansı* verir: λ_+ 'yı aşan öz değerler gerçek yapı adaydır, aralık içindekiler ise saf gürültüyle açıklanabilir. Faktör sayısı seçimi (§3.5.4) ve büzülme yöntemlerinin (§3.5.5) sezgisi buradan doğar.

Ampirik yorumlama:

- $\hat{\lambda}_i > \lambda_+$, saf gürültü referansına göre *gürültü aralığının dışında* kalan bir *aday faktör* öz değerine işaret eder.
- $\hat{\lambda}_i \leq \lambda_+$ gözlemi, yalnızca aynı özel referans model altında gürültü aralığıyla uyumludur; genel finansal panellerde “saf gürültü” sonucunu tek başına vermez.
- Örnek: $N = 100$, $T = 500$ ve $\sigma^2 = 1$ için $\kappa = 0.2$, $\lambda_+ = (1 + \sqrt{0.2})^2 \approx 2.09$ 'dur.

Heteroskedastisite, ağır kuyruklar, seri bağımlılık ve zayıf kesitsel bağımlılık MP gürültü aralığının kenarını değiştirebilir. Bu nedenle eşik, kesin bir sinyal-gürültü sınıflandırması değil, tanısal bir referanstır.

Not 3.6. Marchenko–Pastur üst kenarı, saf gürültü referans modeli altında faktör sayısı için basit bir başlangıç tahmini $\hat{K}_{MP} = \#\{\hat{\lambda}_i > \lambda_+\}$ sağlar ve spektral büzülmenin sezgisini açıklar. Finansal veride bu kural Bai–Ng ölçütleri, özdeğer-farkı yöntemleri ve sağlamlık kontrolleriyle birlikte kullanılmalıdır.

3.5.3 POET Yaklaşımı (Fan, Liao ve Mincheva, 2013)

Teorem 3.2 (POET: Principal Orthogonal Complement Thresholding). *Kovaryans matrisi, faktör bileşeni ve idiyosenkratik bileşen olarak ayrıştırılır:*

$$\Sigma = B \Sigma_f B' + \Sigma_u \quad (136)$$

1. PCA ile K temel bileşen çıkarılır $\rightarrow \hat{B}, \hat{\Sigma}_f$
2. İdiyosenkratik kovaryans $\hat{\Sigma}_u = \hat{\Sigma} - \hat{B} \hat{\Sigma}_f \hat{B}'$ hesaplanır.
3. $\hat{\Sigma}_u$ 'nın köşegen dışı elemanlarına eşik uygulama (*soft thresholding*) yapılır:

$$\hat{s}_{ij}^T = \text{sgn}(\hat{s}_{ij}) \max(0, |\hat{s}_{ij}| - \tau_{ij}), \quad \tau_{ij} = C \omega_T \sqrt{\hat{\theta}_{ij}}, \quad \omega_T = \sqrt{\frac{\log N}{T}} + \frac{1}{\sqrt{N}}, \quad (137)$$

burada $\hat{\theta}_{ij}$ artık çarpımlarının değişkenliğini tahmin eder. Daha basit $\tau_{ij} = C \sqrt{\hat{s}_{ii}\hat{s}_{jj}}$ kuralı kullanılabilir; ancak bu, canonical adaptive POET eşiği değil, POET-benzeri pratik korelasyon eşiklemesidir. Aradaki fark yalnızca biçimsel değildir: sabit C ile bu eşik örneklem büyüdükçe sifıra gitmez, dolayısıyla POET'in tutarlılık oranıyla uyumlu değildir. Oran-uyumlu sürüm $\tau_{ij} = C \omega_T \sqrt{\hat{s}_{ii}\hat{s}_{jj}}$ biçiminde yazılmalı; korelasyon ölçeğinde eşikleme yapılacaksa yaklaşık sabit eşik $C\omega_T$ olarak alınmalıdır.

4. Yeniden birleştirme: $\hat{\Sigma}^{POET} = \hat{B}\hat{\Sigma}_f\hat{B}' + \hat{\Sigma}_u^T$

Sezgisel açıklama: Büyük boyutlu kovaryans matrisinde çoğu varlık çifti arasındaki korelasyon, istatistiksel olarak anlamlı olmayan *gürültüden* ibarettir. POET, faktörlerin açıkladığı sistematik hareketi korurken, gürültülü kovaryansları sifıra bürzer.

3.5.4 POET'te Faktör Sayısı Seçimi

Faktör sayısı K 'nın doğru belirlenmesi POET'in performansını doğrudan etkiler. Başlıca üç yöntem mevcuttur:

Yöntem 1 — Marchenko-Pastur Kriteri:

$$\hat{K}_{MP} = \#\{\hat{\lambda}_i : \hat{\lambda}_i > \lambda_+\}, \quad \lambda_+ = (1 + \sqrt{N/T})^2 \hat{\sigma}^2 \quad (138)$$

Yöntem 2 — Bai-Ng (2002) Bilgi Kriterleri: Bai and Ng (2002) şu tip bilgi kriterini önermiştir:

$$IC_p(k) = \ln(V(k, \hat{F}^k)) + k \cdot g(N, T) \quad (139)$$

burada $V(k, F) = (NT)^{-1} \sum_{t,i} (x_{it} - \lambda'_i F_t)^2$ açıklanamayan ortalama kare hatadır. Log-biçimli IC_{p1} ölçütü

$$IC_{p1}(k) = \log V(k) + k \frac{N+T}{NT} \log\left(\frac{NT}{N+T}\right). \quad (140)$$

Bu ceza terimi ayrıca $\hat{\sigma}^2$ ile çarpılmaz. Ölçek tahmininin cezada yer aldığı seviye-biçimli PC_p ölçütleri ile log-biçimli IC_p ölçütleri birbirine karıştırılmamalıdır. Uygulamada $\hat{K}_{IC} = \arg \min_k IC_{p1}(k)$ seçilir.

Yöntem 3 — Onatski (2010) Kenar Testi: Ardışık öz değer farklarının oranını kullanır:

$$\hat{K}_O = \max\left\{k : \hat{\lambda}_k - \hat{\lambda}_{k+1} \geq c_\delta\right\} \quad (141)$$

burada c_δ asimptotik dağılımdan elde edilen kritik değerdir. (Bu, testin basitleştirilmiş özetidir; gerçek prosedür c_δ 'yı *tek bir sabit* olarak değil, aday k 'nin ötesindeki öz değerlerden *yinelemeli* olarak kestirir.)

Python ile Marchenko-Pastur Kriteri ve Bai-Ng IC

```
1 import numpy as np
2 from scipy.linalg import svd
3
4 def marchenko_pastur_k(returns):
5     """
6     Marchenko-Pastur kriteriyle faktor sayisi secer.
7     returns : (T, N) getiri matrisi
8
9     UYARI: sigma^2 = median(lambda) yalnızca OGRETICI amaçli kaba
10         bir
11         kestirimdir. MP dagiliminin medyani kappa = N/T'ye baglidir ve
12         N > 2T oldugunda sifir ozdegerler medyani bozar. Uygulamada
```

```

12     kappa-duzeltilmis, saglam bir gurultu olcegi kullanilmalidir.
13     """
14     T, N = returns.shape
15     kappa = N / T
16     # Orneklem kovaryansinin ozdegerleri (azalan siralama)
17     S = np.cov(returns.T)
18     eigenvalues = np.linalg.eigvalsh(S)[::-1]
19     sigma2 = np.median(eigenvalues) # gurultu varyansi
20     (kaba)
21     lambda_plus = sigma2 * (1 + np.sqrt(kappa))**2
22     K_mp = int(np.sum(eigenvalues > lambda_plus))
23     return K_mp, eigenvalues, lambda_plus
24
25 def bai_ng_ic(returns, k_max=10):
26     """
27     Bai-Ng (2002) IC_{p1} kriteri (log-form: sigma^2 CARPANI YOKTUR
28     ;
29     sigma^2 yalnizca seviye-formlu PC_{p1} kriterinde yer alır).
30     Aday kume k = 0 (faktorsuz model) dahil edilerek taranir.
31     """
32     T, N = returns.shape
33     ic_values = []
34     X = returns - returns.mean(axis=0)
35     U, s, Vt = svd(X, full_matrices=False)
36     for k in range(0, k_max + 1):
37         if k == 0:
38             residuals = X # faktorsuz model
39         else:
40             F_hat = U[:, :k] * s[:k]
41             Lambda_hat = Vt[:k, :].T
42             residuals = X - F_hat @ Lambda_hat.T
43             V_k = np.mean(residuals**2) # normalize
44             edilmis SSR
45             g_NT = (N + T) / (N * T) * np.log(N * T / (N + T))
46             ic = np.log(V_k) + k * g_NT # IC_{p1}: log(V_k)
47             + k*g
48             ic_values.append(ic)
49     K_ic = int(np.argmin(ic_values)) # k=0 dahil
50     oldugundan kaydirma yok
51     return K_ic, ic_values

```

3.5.5 Ledoit-Wolf Büzülme Tahmin Edicisi (2004)

Tanım 3.5 (Kimlik Hedefli Doğrusal Büzülme).

$$\hat{\Sigma}_{\text{LW}} = (1 - \delta) \hat{S} + \delta \hat{\mu} I_N \quad (142)$$

Bu, Ledoit–Wolf doğrusal büzülme ailesinin yaygın bir özel durumudur; literatürde sabit-korelasyon ve başka yapılandırılmış hedefler de kullanılabilir.

- $\hat{S}$: Örnek kovaryans matrisi (*hedef nokta: veri*).
- $\hat{\mu} I_N$: Yapılandırılmış hedef (*hedef nokta: yapı*).
- $\delta \in [0, 1]$: Büzülme yoğunluğu (analitik formülle hesaplanır).
- $\delta = 0$: Tam örnek kovaryans (büzülme yok).
- $\delta = 1$: Tam yapılandırılmış hedef (tüm kovaryanslar ihmal edilir).
- Optimal δ : $\mathbb{E}[\|\hat{\Sigma}_{LW} - \Sigma\|_F^2]$ Frobenius norm kaybını minimize eder.

Büzülme Yoğunluğunun Yorumu

- $\delta \approx 0$: Veri yeterli; örnek kovaryans güvenilir.
- $\delta > 0.5$: Veri yetersiz; yapısal kısıtlara güçlü ihtiyaç var.
- Belirleyici büyüklük N değil, *boyut oranı* $\kappa = N/T$ 'dir: δ , κ ile birlikte artar. Ancak δ yalnızca κ 'ya değil, nüfus spektrumuna, seçilen hedef matrise ve veri ölçeğine de bağlıdır; bu nedenle N 'e karşılık gelen evrensel bir “tipik δ ” tablosu yoktur. Karşılaştırma noktası olarak §1.13'teki kontrollü simülasyonda $N = 8$, $T = 500$ ($\kappa = 0.016$) için $\delta \approx 0.02$ elde edilmiştir; farklı bir veri üreten süreçte aynı κ farklı bir δ verebilir.

3.5.6 Doğrusal Olmayan Ledoit-Wolf Büzülme (2017, 2020)

Doğrusal büzülmenin sınırlılığı: $\hat{\Sigma}_{LW} = (1 - \delta)\hat{S} + \delta\hat{\mu}I_N$ tüm öz değerlere aynı büzülme yoğunluğunu uygular. Oysa Marchenko-Pastur teorisi, farklı öz değerlerin farklı ölçüde “şişirildiğini” gösterir: büyük öz değerler daha az, küçük öz değerler daha çok büzülmalıdır.

Analitik Doğrusal Olmayan Büzülme (Ledoit and Wolf, 2020): Optimal öz değer düzeltmesi (Ledoit-Péché 2011 "oracle" formülü):

$$\hat{d}_i^{\text{NL}} = \frac{d_i}{|1 - c - c d_i \check{m}(d_i)|^2} \quad (143)$$

burada d_i , $\hat{S}$ 'nin i . öz değeri; $c = N/T$ boyut oranı (aspect ratio); $\check{m}(\cdot)$, örnek öz değerlerin limit dağılımının Stieltjes dönüşümüdür (gerçek eksene yaklaşımla değerlendirilir). c payda içinde *açıkça* yer alır — büzülme yoğunluğu yalnızca d_i 'ye değil, boyut oranına da bağlıdır. Kapalı-form bir ifade olmadığından, $\check{m}$ 'nin değerlendirilmesi ya sayısal ters-çevirmeyle (“QuEST”, *Quantized Eigenvalues Sampling Transform*; Ledoit and Wolf 2020'nin öncül çalışmaları) ya da Ledoit and Wolf (2020)'nin Hilbert-dönüşümü tabanlı analitik yaklaşımıyla yapılır — elle hesaplanabilir kapalı bir formül değildir.

Tanım 3.6 (Doğrusal Olmayan Shrinkage Tahmincisi).

$$\hat{\Sigma}^{\text{NL}} = \hat{U} \text{diag}(\hat{d}_1^{\text{NL}}, \dots, \hat{d}_N^{\text{NL}}) \hat{U}' \quad (144)$$

burada $\hat{U}$, $\hat{S}$ 'nin özvektör matrisi ve $\hat{d}_i^{\text{NL}}$ düzeltilmiş özdeğerlerdir. Denklem (143), sıfırdan farklı örnek özdeğerler için oracle biçimini gösterir. $c = N/T > 1$ olduğunda örnek kovaryansta sıfır özdeğerler bulunur; bunların düzeltilmesi ayrı limit ifadeleri gerektirir. Bu rejimde formül bütün özdeğerlere mekanik olarak uygulanmamalı, doğrulanmış nonlinear-shrinkage yazılımı kullanılmalıdır.

Tablo 24: Kovaryans tahmincilerinin şematik karşılaştırması ($T = 500$ sabit, N değişken). Girdiler niteliksel sıralamadır; kesin değerler kayıp ölçütüne, gerçek spektruma ve faktör yapısının gücüne bağlıdır.

Yöntem	$N = 50, T = 500$	$N = 100, T = 500$	$N = 500, T = 500$
Örnek Kovaryans	yüksek hata	çok yüksek	tekil
Doğrusal LW	düşük hata	orta hata	orta hata
Doğrusal Olmayan LW	en düşük	en düşük	düşük hata
POET (K seçimli)	benzer	benzer	en iyi

Tablo 24 dört tahminciyi $T = 500$ sabitken artan N boyunca karşılaştırır; sütunlar $\kappa = N/T$ oranının 0.1, 0.2 ve 1.0 değerlerine karşılık gelir. Örüntünün nedeni her satır için farklıdır:

- **Örnek kovaryans:** hata κ ile birlikte büyür, çünkü öz değerlerin gürültü kaynaklı yayılması genişler (§3.5.2). $N = T$ olduğunda ($\kappa = 1$) matris *tekildir* — en küçük öz değer sıfıra iner, ters alınamaz ve minimum varyans portföyü tanımsız kalır.
- **Doğrusal LW:** tüm öz değerleri *ortak* bir hedefe doğru aynı oranda çeker. Bu, tekilliği ortadan kaldırır ve büyük kazanç sağlar; ancak tek bir büzülme yoğunluğu δ kullandığından, gerçekte farklı büyüklükteki öz değerlerin farklı düzeltmelere ihtiyaç duyduğu durumlarda eksik kalır.
- **Doğrusal olmayan LW:** her öz değere *kendi* düzeltmesini uygular. Gerçek spektrum yayvan olduğunda doğrusal LW’yi belirgin biçimde geçer; bu üstünlük N büyüdükçe artar.
- **POET:** ötekilerden farklı bir bilgi kullanır — *faktör yapısı*. Güçlü ortak faktörler varsa (hisse senedi panellerinde tipik olarak vardır) büyük N ’de en iyi sonucu verir; faktör yapısı zayıfsa üstünlüğü kaybolur ve LW ailesiyle benzer performans gösterir.

Rakip değil, tamamlayıcı

Büzülme ile POET farklı varsayımlara dayanır: LW ailesi kovaryansın *yapısı* hakkında bir şey varsaymaz, yalnızca öz değer spektrumunu düzeltir; POET ise düşük-ranklı bir *faktör* yapısı olduğunu varsayar ve kalanı seyrek kabul eder. Bu nedenle “hangisi daha iyi?” sorusunun evrensel bir yanıtı yoktur; yanıt verinin faktör yapısına sahip olup olmadığına bağlıdır. Uygulamada ikisi *birleştirilebilir*: POET’in idiyosenkratik bileşenine $\hat{\Sigma}_u$ büzülme uygulanması yaygın bir pratiktir.

Python uygulaması:

- Doğrusal LW: `sklearn.covariance.LedoitWolf`
- Doğrusal olmayan LW: `rmt` paketi (PyPI) veya `nlshrink`
- Referans: [Ledoit and Wolf 2020](#), *Annals of Statistics*

3.5.7 POET ile DCC’yi Birleştirmek: Koşullu Yüksek-Boyutlu Kovaryans

Bu bölümdeki araçlar (POET, Ledoit–Wolf, doğrusal olmayan büzülme) *koşulsuz* kovaryans matrisi Σ ’yı hedefler: tek bir matris üretirler, zaman indeksi taşımazlar. Buna karşılık Bölüm 1’deki DCC ailesi *koşullu* $H_t = D_t R_t D_t$ ’yi üretir. Portföy uygulamasında ihtiyaç duyulan nesne $\hat{\Sigma}_{t+1|t}$ olduğundan, iki yaklaşımın birleştirilmesi gerekir.

Doğal birleşim: faktörlerde DCC. POET ayrıştırması $\Sigma = B\Sigma_f B' + \Sigma_u$ zaten bir faktör yapısı verdiğinden, koşullu hâle geçmek için *yalnızca* K faktörün kovaryansını dinamikleştirmek yeterlidir:

$$\hat{\Sigma}_{t+1|t} = \hat{B} \hat{H}_{f,t+1|t} \hat{B}' + \hat{D}_{u,t+1|t}, \quad (145)$$

burada $\hat{H}_{f,t+1|t}$ K faktör üzerinde kurulan DCC-GARCH'ın bir-adım öngörüsü, $\hat{D}_{u,t+1|t}$ ise eşiklenmiş idiyosenkratik bileşenin (genellikle köşegen) koşullu sürümüdür.

Bileşenler nasıl elde edilir? POET'in statik adımları, koşullu sürüme aşağıdaki gibi bağlanır:

1. **Faktörler ve yüklemeler (POET, statik).** Örnek kovaryans $\hat{S}$ 'nin ilk K öz vektörü alınır; bunlar yükleme matrisi $\hat{B}$ 'yi ($N \times K$), karşılık gelen temel bileşenler ise faktör serisi $\hat{f}_t$ 'yi ($K \times 1$) verir. K seçimi §3.5.4'teki ölçütlerle yapılır.
2. **İdiyosenkratik bileşen (POET, eşikleme).** Artıklar $\hat{u}_t = r_t - \hat{B}\hat{f}_t$ hesaplanır; artık kovaryansına eşikleme uygulanarak seyrek $\hat{\Sigma}_u$ elde edilir. Uygulamada bu matris çoğu zaman köşegene indirgenir.
3. **Faktör tarafını dinamikleştirme.** K boyutlu $\hat{f}_t$ serisine DCC-GARCH kurulur; çıktısı $\hat{H}_{f,t+1|t}$ 'dir. Boyut $K \ll N$ olduğundan bu adım, N varlığa doğrudan DCC kurmaya kıyasla çok daha ucuz ve kararlıdır.
4. **İdiyosenkratik tarafı dinamikleştirme.** Her artık serisine tek değişkenli GARCH takılır; koşullu varyanslar köşegene yerleştirilerek $\hat{D}_{u,t+1|t}$ oluşturulur. (Eşiklemede köşegen dışı öğeler korunmuşsa, bu kısım sabit tutulup yalnızca köşegen dinamikleştirilebilir.)
5. **Birleştirme.** İki parça (145) ile toplanır. $\hat{H}_f$ pozitif tanımlı ve $\hat{D}_u$ pozitif köşegen olduğu sürece sonuç pozitif tanımlıdır — doğrudan $N \times N$ tahminde sağlanması zor olan bu özellik burada yapıdan gelir.

Hesaplama avantajı doğrudandır: DCC özyinelemesi $N \times N$ yerine $K \times K$ boyutunda çalışır ($K \ll N$), yani maliyet $O(N^2)$ 'den $O(K^2)$ 'ye iner ve $\bar{Q}$ hedefleme hatası K boyutlu bir matriste kalır.

Sık yapılan hata: “POET uyguladım, POET-DCC yaptım”

POET'i getiri paneline bir kez uygulamak *statik* bir kovaryans matrisi üretir; bu, adı ne olursa olsun koşullu bir tahmin **değildir**. Koşullu bir matris isteniyorsa faktörlere ve idiyosenkratik bileşene ayrıca bir dinamik model (DCC/GARCH) takılmalıdır — Eq. (145). Örneklem-dışı risk değerlendirmesinde bu ayrım sonucu belirler.

Not 3.7 (DCC tarafındaki ölçekleme yaklaşımları). DCC'nin kendi içinde büyük N 'e ölçeklenmesi — Faktör-DCC, DECO, Blok-DCC ve hedefleme adımını büzülmeyle sağlamlaştıran DCC-NL — Bölüm 1'de ele alınmıştır; parametre sayısı ve boyut sınırları karşılaştırması için bkz. §1.9 ve §1.10.

3.6 Entegre Uygulama: Gerçekleşen Oynaklık Tahmini

Uygulama Amacı

Bu uygulamada yüksek frekanslı BIST-30 verisi kullanılarak günlük volatilité tahmini yapılacak ve 20 varlıklı bir portföyde büyük kovaryans matrisi tahmin yöntemleri karşılaştırılacaktır. Amaç, teorik yöntemlerin gerçek portföy risk yönetimine nasıl katkı sağladığını görmektir.

Adım 1 — 5 Dakikalık Getirilerden RV Hesaplama: BIST seans saatleri içinde günlük M adet 5 dakikalık getiri gözlemlenir:

$$RV_t^i = \sum_{j=1}^M r_{t,j}^{i2}, \quad i = 1, \dots, 20 \quad (146)$$

Canlı oturum öncesi doğrulanmalı

M 'nin tam değeri güncel BIST seans saatlerine bağlıdır (seans uzunluğu / 5 dakika); burada sabit bir sayı verilmemiştir — canlı oturumdan önce kullanılacak günün gerçek seans takvimiyle teyit edilmelidir. (Örneğin 08:30–18:10 aralığı 580 dakikaya, yani $M = 116$ beş-dakikalık bara karşılık

gelir; farklı bir seans yapısı farklı M verir.)

Adım 2 — Volatilite İmza Grafiği: Optimal örnekleme frekansının teyidi için imza grafiği çizilir. Beklentiler: 1 dk'da gürültü baskın, 5 dk'da denge, 30 dk'da yüksek varyans.

Adım 3 — HAR-RV ve Realized GARCH Tahmin Karşılaştırması: Her iki model de 2018–2023 dönemi için tahmin edilir; 2024 yılı dışarıda bırakılır (geriye dönük test seti).

Adım 4 — POET ile 20-Varlıklı Statik Kovaryans Matrisi: Bir eğitim penceresinde $K = 3$ faktörlü POET tahmini kurulur; MP üst kenarı yalnızca K için tanısal referans olarak kullanılır. Bu adım tek bir statik kovaryans matrisi üretir ve bu nedenle “POET-DCC” değildir. Koşullu $\hat{\Sigma}_{t+1|t}$ isteniyorsa faktörlere DCC/GARCH ve idiyosenkratik bileşene uygun dinamik model ayrıca eklenmelidir.

Adım 5 — MVP + VaR Tahmini + Geriye Dönük Test: Kayıp değişkeni için kuyruk-olasılığı konvansiyonu kullanılarak, sıfır koşullu ortalama altında

$$\mathbf{w}^* = \frac{\hat{\Sigma}^{-1}\mathbf{1}}{\mathbf{1}'\hat{\Sigma}^{-1}\mathbf{1}}, \quad \hat{\sigma}_p^2 = \mathbf{w}^{*\prime}\hat{\Sigma}\mathbf{w}^*, \quad \widehat{\text{VaR}}_{0.01} = \Phi^{-1}(0.99)\hat{\sigma}_p. \quad (147)$$

Koşullu portföy ortalaması sıfır değilse pozitif kayıp büyüklüğü $-\hat{\mu}_p + \Phi^{-1}(0.99)\hat{\sigma}_p$ olur. Böylece alt indis, Gün 4 ile tutarlı olarak üst-kuyruk olasılığını gösterir.

Python Kodu: Entegre Analiz

```
1 import numpy as np
2 from scipy.stats import norm
3 from realized_volatility import estimate_har_rv, poet_covariance
4
5 # 1. HAR-RV tahmini (tek hisse ornegi)
6 result, df_har = estimate_har_rv(rv_series)
7 print(result.summary())
8
9 # 2. Gerçek bir-adim HAR ongorusu: son gun/hafta/ay regresorlerini
   kur
10 x_next = np.array([
11     1.0,
12     rv_series.iloc[-1],
13     rv_series.iloc[-5:].mean(),
14     rv_series.iloc[-22:].mean(),
15 ])
16 rv_forecast = float(x_next @ result.params.to_numpy())
17
18 # 3. POET kovaryans matrisi (yalnizca egitim/rolling penceresi
   kullan)
19 Sigma_poet = poet_covariance(returns_train, k_factors=3, threshold
   =0.1)
20
21 # 4. MVP agirliklari
22 ones = np.ones(Sigma_poet.shape[0])
23 H_inv = np.linalg.inv(Sigma_poet)
24 w = H_inv @ ones / (ones @ H_inv @ ones)
```



```

25 print("MVP agirliklari:", w.round(4))
26
27 # 5. Portföy riski; alt indis kuyruk olasiligidir (alpha = 0.01)
28 port_var = w @ Sigma_poet @ w
29 port_vol = np.sqrt(port_var)
30 alpha = 0.01
31 z = norm.ppf(1 - alpha)
32 VaR_01 = port_vol * z
33 ES_01 = port_vol * norm.pdf(z) / alpha
34 print(f"Portföy volatilite: {port_vol*100:.2f}% (gunluk)")
35 print(f"VaR alpha=1%: {VaR_01*100:.2f}%")
36 print(f"ES alpha=1%: {ES_01*100:.2f}%")

```

Son oturumda tüm bileşenler birleştirilir:

1. **Volatilite tahmini:** HAR-RV veya GARCH-X ile $\hat{\sigma}_{t+1}^2$.
2. **Kovaryans tahmini:** Statik/rolling POET veya Ledoit–Wolf $\hat{\Sigma}$; koşullu tahmin isteniyorsa açıkça tanımlanmış Faktör-DCC ile $\hat{\Sigma}_{t+1|t}$.
3. **Portföy:** MVP ağırlıkları $\mathbf{w}_{t+1} = \hat{\Sigma}_{t+1}^{-1} \mathbf{1} / (\mathbf{1}' \hat{\Sigma}_{t+1}^{-1} \mathbf{1})$.
4. **Risk tahmini:** Portföy VaR/ES: $\sigma_{p,t+1} = \sqrt{\mathbf{w}' \hat{\Sigma}_{t+1} \mathbf{w}}$.
5. **Değerlendirme:** Geriye dönük test + Fissler-Ziegel kaybı.

Yüksek Boyutun Pratik Sınırları

- İşlem maliyetleri: Sık ağırlık değişimi (turnover) getiriye yıpratır.
- Kısa satış kısıtları: $w_i \geq 0$ ek optimizasyon gerektirir.
- Likidite: Küçük sermayeli varlıklar portföyde aşırı ağırlık alabilir.
- POET'te faktör sayısı K seçimi: bilgi kriterleri veya çapraz doğrulama.
- $N > 50$ durumunda DCC tahmininde yakınsama sorunları yaşanabilir; Faktör-DCC veya DECO başlangıç noktası olarak tercih edilmelidir.

3.7 Kontrollü Simülasyon ile Ampirik Doğrulama

Gerçek finansal veride entegre varyans IV_t ve gerçek kovaryans matrisi Σ *gözlemlenemez*; dolayısıyla bir tahmincinin “doğru” cevaba ne kadar yakın olduğu doğrudan ölçülemez. Bu bölümde, doğru cevabın *tasarım gereği bilindiği* kontrollü bir veri üretim süreci (DGP) kullanarak bu bölümün yöntemlerini sayısal olarak doğruluyoruz. Tüm sonuçlar tek bir tohumla (*seed* = 20260731) yeniden üretilebilir.

Neden Kontrollü Simülasyon?

Kontrollü bir DGP'de gerçek IV_t , gerçek sıçrama bileşeni ve gerçek Σ bilindiğinden, tahmincileri *vekil* (proxy) yerine *gerçek* hedefe karşı puanlayabiliriz. Bu, gerçek veride mümkün olmayan bir denetim sağlar: örneğin bir gerçekleşen ölçütün yanlılığını doğrudan hesaplayabilir, bir kovaryans tahmincisinin minimum-varyans portföyünü gerçek varyansla kıyaslayabiliriz. Aşağıdaki sayılar, dersin düzeltilmiş kuramsal iddialarını (ör. RK'nin TSRV'den daha hızlı yakınsaması) ampirik olarak destekler.

3.7.1 A. Gerçekleşen Ölçütlerin Entegre Varyansı Geri Kazanması

Etkin log-fiyat $dX_t = \sqrt{v_t} dB_t$ (nokta varyansı v_t log-OU süreci), gözlenen fiyat ise mikroyapı gürültüsüyle $Y = X + \varepsilon$, $\varepsilon \sim \text{iid } N(0, \omega^2)$ biçiminde üretilir; günlük ızgara 5 saniyelik $N_{\text{fine}} = 4680$ adımdır. Mikroyapı gürültüsü mevcut, fakat fiyat sıçraması içermeyen günlerde ($T = 300$) tahmincilerin gerçek IV 'yi geri kazanımı Tablo 25'de özetlenmiştir.

Tablo 25: Gerçekleşen ölçütlerin gerçek IV 'yi geri kazanması (mikroyapı gürültülü, sıçramasız günler; $T = 300$). RMSE, IV ortalamasına oranlanmıştır.

Tahminci	Bağıl Yanlılık (%)	RMSE/ $\overline{IV}$	Kor. (IV)
RV (1 dk)	+5.33	0.101	0.975
RV (5 dk)	+0.78	0.165	0.902
RV (15 dk)	+0.38	0.277	0.780
TSRV	-1.55	0.127	0.936
Realized Kernel	+3.92	0.092	0.975
BPV (5 dk)	-1.08	0.194	0.861

Üç bulgu kuramla tutarlıdır:

- **RK, TSRV'den daha etkin.** Tüm yüksek-frekanslı (5 sn) veriyi kullanan iki tahminci arasında RK'nin RMSE'si (0.092) TSRV'ninkinden (0.127) düşüktür — bu, §3.1.4'te düzeltilen yakınsamalı sıralamasının ($n^{-1/4}$ RK, $n^{-1/6}$ TSRV; [Barndorff-Nielsen et al. 2008](#); [Zhang et al. 2005](#)) sonlu-örneklem imzasıdır.
- **5 dakika kuralı.** Volatilité imza oranı $RV(\Delta)/IV$ en yüksek frekansta gürültüyle şişer (5 sn: 1.60) ve 5 dakikadan itibaren ≈ 1 'e oturur ($1.05 \rightarrow 1.01 \rightarrow 1.00$; 1 dk, 2 dk, 5 dk).
- **Sıçrama sağlamlığı.** BPV, sürekli bileşeni yakalar (yanlılık -1.08%); $(RV - BPV)/IV$ oranı gerçek sıçrama günlerinde 0.630, sıçramasız günlerde 0.019 olup $J/RV > 0.2$ kuralı sıçramaların %50'sini %4 yanlış-alarmla yakalar.

3.7.2 B. HAR Ailesi ve Realized GARCH: Öngörü Karşılaştırması

Aynı DGP'den $T = 1500$ günlük RV serisi ve günlük getiriler üretilir; ilk 1000 gün tahmin, kalan 500 gün örneklem-dışı (OOS) öngörü için kullanılır. HAR modelleri Newey-West ([Newey and West 1987](#), 10 gecikme) HAC standart hatalarıyla EKK; Realized GARCH ([Hansen et al., 2012](#)) ortak ML ile kestirilir.

Tablo 26: HAR ailesi katsayı tahminleri (in-sample, $T_{\text{eğitim}} = 1000$; parantezde HAC- t). $J_{t-1} = \max(0, RV_{t-1} - BPV_{t-1})$.

Katsayı	HAR-RV	HAR-RV-J	HAR-RV-CJ
sabit	0.00 (1.98)	0.00 (1.15)	0.00 (0.46)
β_d / β_{cd}	0.083 (1.66)	0.498 (3.62)	0.307 (2.78)
β_w / β_{cw}	0.507 (4.63)	0.273 (2.00)	0.532 (3.92)
β_m / β_{cm}	0.319 (2.78)	0.227 (3.11)	0.242 (2.01)
β_j / β_{jd}	—	-0.687 (-3.89)	-0.059 (-1.03)
β_{jw}	—	—	-0.046 (-0.54)
β_{jm}	—	—	-0.550 (-1.71)
R^2	0.455	0.491	0.498

Bu tasarımda sürekli bileşen gecikmeleri baskındır; sıçrama gecikmelerinin bir bölümü küçük veya anlamsız tahmin edilmiştir. HAR-RV-J'deki $\hat{\beta}_j = -0.69$ ($t = -3.89$), diğer HAR regresörleri koşullu iken elde edilen negatif bir marjinal katsayıdır. Bu işaret tek başına, sıçramaların gelecekteki oynaklığı yapısal olarak artırmadığını kanıtlamaz; kollineariteye, J_t ölçüm hatasına ve ayrıştırma biçimine duyarlıdır.

Log-Realized GARCH(1,1)'de ölçüm denklemi eğimi φ serbestse uygun indirgenmiş-form kalıcılık ölçüsü $\beta + \gamma\varphi$ 'dır. Burada $\hat{\varphi} = 1.005 \approx 1$ olduğu için $\beta + \gamma$ sayısal olarak yakın bir kestirme olabilir; DGP'nin 0.98 kalıcılığıyla esas karşılaştırma $\hat{\beta} + \hat{\gamma}\hat{\varphi}$ üzerinden yapılmalıdır.

Tablo 27: Örneklem-dışı 1-adım öngörü kaybı ($T_{\text{OOS}} = 500$), gerçek IV hedefine karşı. DM: Diebold-Mariano istatistiği ($< 0 \Rightarrow$ ilgili model GARCH(1,1)'den iyi).

Model	QLIKE	MSE ($\times 10^8$)	DM (GARCH'a karşı)
HAR-RV	0.0238	0.030	-14.62
HAR-RV-CJ	0.0142	0.018	-15.80
Realized GARCH	0.0157	0.022	-15.43
GARCH(1,1)	0.0700	0.127	—

Gerçekleşen ölçüt kullanan üç model de yalnızca getiriye dayanan GARCH(1,1)'i büyük farkla geçer (QLIKE $\approx 3-5\times$ daha düşük; $|DM| \approx 15 \gg 1.96$). HAR-RV-CJ hem in-sample R^2 hem OOS QLIKE'de en iyidir; Realized GARCH çok yakın ikincidir.

3.7.3 C. Yüksek Boyutlu Kovaryans: POET, Büzülme ve Faktör Sayısı

K -faktörlü bilinen $\Sigma = B\Sigma_f B' + \Sigma_u$ (Σ_u köşegen/seyrekle) yapısından N varlık $\times T$ gün paneli üretilir. Örnek-kovaryans, Ledoit-Wolf doğrusal büzülme (Ledoit and Wolf, 2004) ve POET (Fan et al., 2013) tahminçileri, gerçek Σ 'ya Frobenius hatası ve gerçek Σ altında minimum-varyans portföyü (MVP) varyansı ile puanlanır (Tablo 28).

Tablo 28: Kovaryans tahmincisi karşılaştırması. MVP sütunu, tahminciden kurulan portföyün *gerçek* Σ altındaki varyansının oracle’a (gerçek Σ) oranıdır; 1.00 idealdir. $c = N/T_{\text{eğitim}}$. “—” = tanımsız: $c \geq 1$ rejiminde örnek-kovaryans tekil ($\text{rank} < N$) olduğundan MVP oluşturulamaz.

Rejim	Tahminci	Frob. (bağıl)	MVP/oracle
$N=100, c=0.20$	Örnek-kov.	0.134	1.30
	LW-doğrusal	0.139	1.27
	POET(K)	0.129	1.01
$N=150, c=1.50$	Örnek-kov.	0.219	—
	LW-doğrusal	0.227	2.02
	POET(K)	0.209	1.17
$N=300, c=1.20$	Örnek-kov.	0.130	—
	LW-doğrusal	0.136	2.34
	POET(K)	0.125	1.08

$c = N/T$ büyüdükçe örnek-kovaryansın MVP’si önce bozulur, sonra tamamen tanımsız hale gelir: $c < 1$ ’de (Rejim 1) gerçek varyansın 1.30 katında makul kalırken, $c \geq 1$ ’de (Rejimler 2 ve 3) örnek-kovaryans tam kertesini yitirir ($\text{rank } \hat{\Sigma} \leq \min\{N, T_{\text{eğitim}} - 1\} < N$), MVP’yi oluşturmak için gereken $\hat{\Sigma}^{-1}$ mevcut değildir ve MVP varyansı **tanımsızdır** (tablo: —). Doğrusal büzülme düzenleme sayesinde $c \geq 1$ ’de de çalışır (2.02–2.34); faktör yapısını kullanan POET neredeyse oracle’a (1.01–1.17) ulaşır.

Frobenius normu pratik kazancı gizler

Tablo 28’de Frobenius hataları birbirine yakındır: bu norm, tüm tahmincilerin yakaladığı büyük faktör öz değerlerince domine edilir. Oysa portföy/risk uygulamasında önemli olan $\hat{\Sigma}^{-1}$ ’dir; MVP metriği tahminciler arasındaki farkı çok daha keskin gösterir. Kovaryans tahmincilerini yalnızca Frobenius ile değerlendirmek yanıltıcıdır.

Faktör sayısı K , üç yöntemle de — Bai and Ng (2002) bilgi kriteri (IC_{p1}), Marchenko-Pastur üst kenarı λ_+ üstündeki öz değer sayısı, ve Onatski (2010) öz değer-farkı testi — her üç rejimde de tam geri kazanılır (Tablo 29).

Tablo 29: Faktör sayısı K geri kazanımı. Üç yöntem de gerçek K ’yı bulur.

Rejim	Gerçek K	Bai-Ng	MP-eşiği (λ_+)	Onatski
$N=100, c=0.20$	3	3	3 (1.73)	3
$N=150, c=1.50$	3	3	3 (3.48)	3
$N=300, c=1.20$	4	4	4 (3.15)	4

Not 3.8. Yukarıdaki tüm sayılar `hf_sim.py` (A), `har_fit.py` (B) ve `highdim_cov.py` (C) betikleriyle, `seed = 20260731` altında yeniden üretilebilir. Canlı oturumda katılımcılar bu betikleri BIST/S&P 500 gerçek yüksek-frekanslı verisine uygulayarak aynı boru hattını gerçek veriye taşıyacaktır; kontrollü simülasyon, gerçek veri sonuçlarının doğru yorumlanması için bir “altın standart” referansı sağlar.

Kaynaklar

- Acerbi, C. and Szekely, B. (2014). Back-testing expected shortfall. *Risk Magazine*, 27(11):76–81.
- Acerbi, C. and Tasche, D. (2002). On the coherence of expected shortfall. *Journal of Banking & Finance*, 26(7):1487–1503.
- Aielli, G. P. (2013). Dynamic conditional correlation: On properties and estimation. *Journal of Business & Economic Statistics*, 31(3):282–299.
- Andersen, T. G., Bollerslev, T., and Diebold, F. X. (2007). Roughing it up: Including jump components in the measurement, modeling, and forecasting of return volatility. *The Review of Economics and Statistics*, 89(4):701–720.
- Artzner, P., Delbaen, F., Eber, J.-M., and Heath, D. (1999). Coherent measures of risk. *Mathematical Finance*, 9(3):203–228.
- Bai, J. and Ng, S. (2002). Determining the number of factors in approximate factor models. *Econometrica*, 70(1):191–221.
- Barndorff-Nielsen, O. E., Hansen, P. R., Lunde, A., and Shephard, N. (2008). Designing realized kernels to measure the ex post variation of equity prices in the presence of noise. *Econometrica*, 76(6):1481–1536.
- Barndorff-Nielsen, O. E. and Shephard, N. (2006). Econometrics of testing for jumps in financial economics using bipower variation. *Journal of Financial Econometrics*, 4(1):1–30.
- Bates, J. M. and Granger, C. W. J. (1969). The combination of forecasts. *Operational Research Quarterly*, 20(4):451–468.
- Bollerslev, T. (1990). Modelling the coherence in short-run nominal exchange rates: A multivariate generalized ARCH model. *The Review of Economics and Statistics*, 72(3):498–505.
- Bollerslev, T. and Wooldridge, J. M. (1992). Quasi-maximum likelihood estimation and inference in dynamic models with time-varying covariances. *Econometric Reviews*, 11(2):143–172.
- Brownlees, C. and Engle, R. F. (2017). SRISK: A conditional capital shortfall measure of systemic risk. *The Review of Financial Studies*, 30(1):48–79.
- Cappiello, L., Engle, R. F., and Sheppard, K. (2006). Asymmetric dynamics in the correlations of global equity and bond returns. *Journal of Financial Econometrics*, 4(4):537–572.
- Corsi, F. (2009). A simple approximate long-memory model of realized volatility. *Journal of Financial Econometrics*, 7(2):174–196.
- DeMiguel, V., Garlappi, L., and Uppal, R. (2009). Optimal versus naive diversification: How inefficient is the 1/N portfolio strategy? *The Review of Financial Studies*, 22(5):1915–1953.
- Diebold, F. X. and Mariano, R. S. (1995). Comparing predictive accuracy. *Journal of Business & Economic Statistics*, 13(3):253–263.
- Engle, R. (2002). Dynamic conditional correlation: A simple class of multivariate generalized autoregressive conditional heteroskedasticity models. *Journal of Business & Economic Statistics*, 20(3):339–350.
- Engle, R. F., Ledoit, O., and Wolf, M. (2019). Large dynamic covariance matrices. *Journal of Business & Economic Statistics*, 37(2):363–375.

- Engle, R. F. and Manganelli, S. (2004). CAViaR: Conditional autoregressive value at risk by regression quantiles. *Journal of Business & Economic Statistics*, 22(4):367–381.
- Engle, R. F., Ng, V. K., and Rothschild, M. (1990). Asset pricing with a factor-ARCH covariance structure: Empirical estimates for treasury bills. *Journal of Econometrics*, 45(1-2):213–237.
- Engle, R. F. and Sheppard, K. (2001). Theoretical and empirical properties of dynamic conditional correlation multivariate GARCH. NBER Working Paper 8554, National Bureau of Economic Research.
- Fan, J., Liao, Y., and Mincheva, M. (2013). Large covariance estimation by thresholding principal orthogonal complements. *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, 75(4):603–680.
- Fissler, T. and Ziegel, J. F. (2016). Higher order elicibility and Osband’s principle. *The Annals of Statistics*, 44(4):1680–1707.
- Fissler, T., Ziegel, J. F., and Gneiting, T. (2016). Expected shortfall is jointly elicitable with value at risk: Implications for backtesting. *Risk Magazine*, pages 58–61.
- Forbes, K. J. and Rigobon, R. (2002). No contagion, only interdependence: Measuring stock market comovements. *The Journal of Finance*, 57(5):2223–2261.
- Gneiting, T. (2011). Making and evaluating point forecasts. *Journal of the American Statistical Association*, 106(494):746–762.
- Hansen, B. E. (1994). Autoregressive conditional density estimation. *International Economic Review*, 35(3):705–730.
- Hansen, P. R. (2005). A test for superior predictive ability. *Journal of Business & Economic Statistics*, 23(4):365–380.
- Hansen, P. R., Huang, Z., and Shek, H. H. (2012). Realized GARCH: A joint model for returns and realized measures of volatility. *Journal of Applied Econometrics*, 27(6):877–906.
- Hansen, P. R., Lunde, A., and Nason, J. M. (2011). The model confidence set. *Econometrica*, 79(2):453–497.
- Higham, N. J. (1988). Computing a nearest symmetric positive semidefinite matrix. *Linear Algebra and its Applications*, 103:103–118.
- Higham, N. J. (2002). Computing the nearest correlation matrix—a problem from finance. *IMA Journal of Numerical Analysis*, 22(3):329–343.
- Jagannathan, R. and Ma, T. (2003). Risk reduction in large portfolios: Why imposing the wrong constraints helps. *The Journal of Finance*, 58(4):1651–1683.
- Ledoit, O. and Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2):365–411.
- Ledoit, O. and Wolf, M. (2020). Analytical nonlinear shrinkage of large-dimensional covariance matrices. *The Annals of Statistics*, 48(5):3043–3065.
- Li, H. and Wang, Y. (2023). The probability equivalent level of value at risk and expected shortfall. *Journal of Risk*, 25(5):1–31.

- McNeil, A. J. and Frey, R. (2000). Estimation of tail-related risk measures for heteroscedastic financial time series: An extreme value approach. *Journal of Empirical Finance*, 7(3–4):271–300.
- Meng, X. and Taylor, J. W. (2020). Estimating Value-at-Risk and Expected Shortfall using the intraday low and range data. *European Journal of Operational Research*, 280(1):191–202.
- Newey, W. K. and West, K. D. (1987). A simple, positive semi-definite, heteroskedasticity and autocorrelation consistent covariance matrix. *Econometrica*, 55(3):703–708.
- Nolde, N. and Ziegel, J. F. (2017). Elicitability and backtesting: Perspectives for banking regulation. *The Annals of Applied Statistics*, 11(4):1833–1874.
- Noureldin, D., Shephard, N., and Sheppard, K. (2012). Multivariate high-frequency-based volatility (HEAVY) models. *Journal of Applied Econometrics*, 27(6):907–933.
- Onatski, A. (2010). Determining the number of factors from empirical distribution of eigenvalues. *The Review of Economics and Statistics*, 92(4):1004–1016.
- Pakel, C., Shephard, N., Sheppard, K., and Engle, R. F. (2021). Fitting vast dimensional time-varying covariance models. *Journal of Business & Economic Statistics*, 39(3):652–668.
- Patton, A. J. (2006). Modelling asymmetric exchange rate dependence. *International Economic Review*, 47(2):527–556.
- Patton, A. J., Ziegel, J. F., and Chen, R. (2019). Dynamic semiparametric models for expected shortfall (and value-at-risk). *Journal of Econometrics*, 211(2):388–413.
- Shephard, N. and Sheppard, K. (2010). Realising the future: Forecasting with high-frequency-based volatility (HEAVY) models. *Journal of Applied Econometrics*, 25(2):197–231.
- Taylor, J. W. (2019). Forecasting value at risk and expected shortfall using a semiparametric approach based on the asymmetric Laplace distribution. *Journal of Business & Economic Statistics*, 37(1):121–133.
- Taylor, J. W. (2020). Forecast combinations for value at risk and expected shortfall. *International Journal of Forecasting*, 36(2):428–441.
- Tse, Y. K. (2000). A test for constant correlations in a multivariate GARCH model. *Journal of Econometrics*, 98(1):107–127.
- Varin, C., Reid, N., and Firth, D. (2011). An overview of composite likelihood methods. *Statistica Sinica*, 21(1):5–42.
- Zhang, L., Mykland, P. A., and Aït-Sahalia, Y. (2005). A tale of two time scales: Determining integrated volatility with noisy high-frequency data. *Journal of the American Statistical Association*, 100(472):1394–1411.